








Cálculo de Probabilidades e Inferencia Estadística

con tópicos de Econometría

Rafael López Casuso



Cálculo de Probabilidades e Inferencia Estadística

con tópico de Econometría

Rafael López Casuso
Economista, M.S. Estadística
Universidad Católica Andrés Bello
Escuela de Economía
Instituto de Investigaciones Económicas

Quinta Edición
Revisada y ampliada
Caracas, 2009

*Cálculo de Probabilidades e Inferencia Estadística
con tópicos de Econometría*
Rafael López Casuso

Universidad Católica Andrés Bello
Montalbán. Caracas (1020)
Apartado 20.332

Diseño y producción: PUBLICACIONES UCAB
Diseño de portada: REYNA CONTRERAS

© Universidad Católica Andrés Bello
Quinta edición, 2009
ISBN: 978-980-244-123-6
Hecho el Depósito de Ley



Reservados todos los derechos.

No se permite reproducir, almacenar en sistemas de recuperación de la información, ni transmitir alguna parte de esta publicación, cualquiera que sea el medio empleado –electrónico, mecánico, fotocopia, grabación, etc.–, sin el permiso previo de los titulares de los derechos de la propiedad intelectual.

*A Cristina,
Rafael, Sandra y Daniela
Marcos, Rosario y Marcos Andrés
Isabel, José Mamiel y Valentina*

A mis alumnos

PREFACIO

En la mayoría de las ciencias tanto naturales como sociales existe una creciente convicción de la necesidad de dominar y entender los conceptos básicos de los métodos estadísticos. La correcta interpretación de datos estadísticos es trabajo de cada día de todo profesional; economistas, administradores, contadores, sociólogos, psicólogos, ingenieros, médicos, etc. deben tomar decisiones basadas en el análisis, usando métodos estadísticos, de la información disponible.

Por lo dicho anteriormente, este texto, aunque originalmente dirigido a estudiantes de Economía, fue escrito en forma más genérica de manera que pueda ser utilizado con provecho por los estudiantes de otras disciplinas que necesitan los conocimientos básicos de la inferencia estadística.

Entre los objetivos del libro están los siguientes: introducir al estudiante en una forma relativamente simple a los conceptos y métodos estadísticos que le servirán como base para el dominio de otras materias en sus estudios; además, me guía el deseo de motivar a los estudiantes tratando de que capten la fundamental importancia del análisis estadístico como complemento de los conocimientos propios de sus respectivas carreras; toda investigación que supone el uso de datos numéricos necesita inevitablemente de la correcta interpretación de los mismos mediante el análisis estadístico.

El texto está dividido en dos partes: Cálculo de Probabilidades e Inferencia Estadística; la primera se desarrolla en los seis capítulos iniciales y los tópicos más importantes de la segunda en los restantes siete capítulos.

Aunque he tratado de hacer la presentación sin demasiadas complejidades matemáticas, creo inevitable el uso adecuado de los instrumentos matemáticos en la exposición y desarrollo del material tratado; por eso, el estudiante debe dominar los

conceptos básicos de la estadística descriptiva, teoría combinatoria, teoría de conjuntos y cálculo diferencial e integral. El uso extensivo de ejemplos inmediatamente después de cada nuevo concepto expuesto ayudará al estudiante a su comprensión, así se desarrollan en el texto 211 ejemplos; asimismo al final de cada capítulo hay una serie de ejercicios y problemas totalmente resueltos (98) y otros propuestos (321) cuyos resultados se dan al final del libro.

Cada estudiante tiene su propia manera de dominar un libro de texto y cada profesor su forma particular de enseñar una disciplina; sin embargo, creo que estoy obligado a hacer alguna recomendación para que se pueda sacar provecho de este texto. En primer lugar, me he dado cuenta que la necesaria abstracción que conlleva el Cálculo de Probabilidades y la poca visible relación entre sus técnicas y los conocimientos concretos de cada profesión que interesan principalmente al estudiante, hacen surgir muchas veces un rechazo consciente o inconsciente que dificulta el aprendizaje y dominio de la estadística. Al adentrarse en el estudio de las probabilidades el estudiante difícilmente capta la necesidad de saber, por ejemplo, que la probabilidad de obtener una cara al lanzar una moneda es $1/2$; creo que una de las tareas principales del profesor es motivar al estudiante en este sentido y procurar hacerle ver que los conceptos abstractos de la probabilidad son totalmente aplicables, mediante la inferencia estadística, a las necesidades de su profesión, llámese ésta economía, ingeniería o sociología. En segundo lugar, para dominar el texto su lectura debe hacerse minuciosamente, leyendo cada sección con detenimiento, tratando de resolver los ejemplos antes de consultar su solución; la siguiente etapa es atacar los ejercicios resueltos en cada capítulo, viendo la solución en el libro sólo en última instancia; por último se deben resolver los ejercicios propuestos; este tipo de prácticas ayudará al dominio de los conceptos; sin embargo, debe estar claro que el objetivo del estudio no es resolver los problemas y ejercicios, sino que ello sirve como medio para conseguir el fin de dominar los conceptos estadísticos expuestos.

Han sido tantas las personas que han contribuido en este texto, que resultaría imposible nombrarlas a todas. Quiero agradecer explícitamente a todos los alumnos que han usado las ediciones mimeografiadas y que con sus sugerencias y descubrimiento de errores han mejorado sustancialmente el material original; a la hoy Economista Corina Arocha de Rubio por su ardua labor en la resolución de los problemas y ejercicios; a la Srta. Minerva Amaya por su excelente trabajo al mecanografiar los manuscritos; a la Sra. Rosario González a quien le debo la magnífica presentación mecanografiada de esta edición, a mi hijo Rafael López Rosales por su invaluable colaboración en la corrección de pruebas y a mis compañeros del Instituto de Investigaciones Sociales y Económicas de la Universidad Católica Andrés Bello por su constante ayuda y estímulo.

Demás está decir que las imperfecciones y errores que todavía se encuentren son de la única y exclusiva responsabilidad del autor.

Caracas, Septiembre 1978

RAFAEL LOPEZ CASUSO

PREFACIO A LA SEGUNDA EDICION

En esta segunda edición de "Introducción al Cálculo de Probabilidades e Inferencia Estadística" se han hecho algunas modificaciones que el autor espera mejoren la utilidad del libro como texto para los cursos básicos de probabilidades e inferencia estadística. Entre ellas están: La eliminación de los muchos errores detectados en la primera edición; en este sentido debo agradecer a mis alumnos del tercer año de Economía de la Universidad Católica Andrés Bello, quienes durante varios años han utilizado la versión correspondiente a la primera edición y que descubrieron la mayoría de los mencionados errores. En segundo lugar, se han indicado con asteriscos aquellas secciones o demostraciones que, por su complejidad conceptual o matemática, pueden oscurecer los objetivos específicos del tema tratado y que se pueden omitir sin pérdida de continuidad en la exposición; cuando se trata de secciones completas o ejercicios se marcan con un asterisco al inicio; si son párrafos insertados en un contexto más amplio, los asteriscos se han colocado al inicio y final del párrafo o prueba que se puede omitir. También se han añadido algunos ejercicios que el autor considera importantes para aclarar algunos conceptos (Ejercicios 7.24 y 9.66).

Por último se ha añadido un índice de materias que facilitará el manejo del texto como libro de consulta.

El autor espera que esta edición corregida siga contribuyendo con modesto aporte a la enseñanza y aprendizaje de la Ciencia Estadística.

RAFAEL LOPEZ CASUSO

Caracas, Septiembre de 1984

PREFACIO A LA TERCERA EDICION

En esta tercera edición del texto que originalmente se tituló “Introducción al Cálculo de Probabilidades e Inferencia Estadística” se han hecho algunas modificaciones que fueron exigidas por la experiencia obtenida de su uso en las aulas.

En primer lugar, el levantamiento completo del texto permitió hacer ajustes en el mismo y se agregaron o eliminaron algunos contenidos que permitirán aclarar conceptos y desarrollar demostraciones.

En segundo lugar, en cada capítulo se han añadido algunas preguntas sobre los contenidos teóricos estudiados y algunos ejercicios adicionales.

En tercer lugar, se añaden los Capítulos XIV y XV, en los cuales se introduce al estudiante a algunos conceptos básicos de la Econometría como herramienta de análisis que usa, a su vez, las técnicas y métodos estadísticos previamente desarrollados en el texto. El modelo de regresión lineal general, desarrollado en el Cap. XV permitirá también a estudiantes de otras disciplinas el estudio de ese importante instrumento estadístico, adaptándolo a las características propias de su ciencia.

El autor está consciente que los conceptos de Econometría que se exponen corresponden únicamente a un esbozo de esa ciencia o arte y que no se tocan la problemática, técnicas y métodos que han hecho de la Econometría una rama de la ciencia con características particulares que la diferencian de la ciencia estadística propiamente dicha.

Para la cabal comprensión del contenido del Capítulo XV el lector debe dominar los conceptos y técnicas fundamentales del álgebra lineal, pues se hace un uso intensivo y extensivo de vectores y matrices. Excelentes resúmenes de los conceptos y técnicas matriciales se pueden encontrar en los textos de Johnston o Goldberger mencionados en las referencias bibliográficas.

AGRADECIMIENTOS

Desco agradecer a todas aquellas personas que han hecho posible esta nueva edición. A mis alumnos de la Escuela de Economía de la Universidad Católica Andrés Bello, en especial a los Bachilleres Franca Schaeffler y Carlos Espina. A Patricia Hernández, Aurora Brito, José Montiel, Cecilia Morales, Emilio Piriz Pérez, Margarita Páez-Pumar y a todos aquellos que de una u otra manera han colaborado en la presente edición.

Caracas, julio de 1996

RAFAEL LOPEZ CASUSO

INDICE GENERAL

	Pág.
INTRODUCCION	
I.I. La Ciencia Estadística	1
I.II. Estadística Descriptiva y Estadística Estimativa	1
I.III. Inferencia Estadística y Econometría	3
CALCULO DE PROBABILIDADES	
CAPITULO I. ELEMENTOS DEL CALCULO DE PROBABILIDADES	7
1.1. Introducción	7
1.2. Concepto de Probabilidad a Priori	8
1.3. Concepto de Probabilidad a Posteriori	10
1.4. Concepto Axiomático de Probabilidad	10
1.5. Teoremas Sobre Probabilidad	13
1.6. Probabilidad Condicional	14
1.7. Probabilidad Producto y Sucesos Independientes	17
1.8. Probabilidad Suma	19
1.9. Teorema de Bayes	20
Ejercicios Resueltos	24
Ejercicios Propuestos	30
CAPITULO II. VARIABLES ALEATORIAS Y FUNCION DE PROBABILIDADES	37
2.1. Variables Aleatorias	37
2.2. Función de Probabilidades	38
2.3. Función de Distribución	40

2.4. Valor Esperado de una Variable Aleatoria	45
2.5. Varianza de una Variable Aleatoria	49
2.6. Momentos de una Variable Aleatoria	51
2.7. Funcion Generatriz de Momentos	52
Ejercicios Resueltos	54
Ejercicios Propuestos	64

CAPITULO III. VARIABLES ALEATORIAS DISTRIBUIDAS

CONJUNTAMENTE	71
3.1. Introducción	71
3.2. Función de Densidad Conjunta de Variables Aleatorias	71
3.3. Función de Densidad Marginal, Función de Densidad Condicional, Valor Esperado Condicional	74
3.3.1. Función de Densidad Marginal	74
3.3.2. Función de Densidad Condicional	77
3.3.3. Valor Esperado Condicional	80
3.4. Variables Aleatorias Independientes	81
3.5. Valor Esperado de Funciones de Varias Variables Aleatorias	83
Ejercicios Resueltos	96
Ejercicios Propuestos	103

CAPITULO IV. DISTRIBUCIONES DE VARIABLES ALEATORIAS

DISCRETAS	107
4.1. Introducción	107
4.2. Distribución Binomial	108
4.3. Valor Esperado y Varianza de una Variable Distribuida Binomialmente	111
4.4. Distribución Geométrica	113
4.5. Valor Esperado y Varianza de una Variable Distribuida Geométricamente	114
4.6. Distribución Hipergeométrica	115
4.7. Valor Esperado y Varianza de una Variable Distribuida Hipergeométricamente	116
4.8. Distribución Multinomial	116
4.9. Distribución de Poisson	118
4.10. Valor Esperado y Varianza de una Variable Distribuida según Poisson	119
4.11. La Distribución de Poisson como Aproximación a la Distribución Binomial	120
Ejercicios Resueltos	122
Ejercicios Propuestos	129

CAPITULO V. DISTRIBUCIONES DE VARIABLES ALEATORIAS

CONTINUAS	135
5.1. Introducción	135
5.2. Distribución Uniforme	136
5.3. Valor Esperado y Varianza de una Variable Distribuida Uniformemente	138
5.4. Distribución Exponencial	139
5.5. Valor Esperado y Varianza de una Variable Distribuida Exponencialmente	143
5.6. Distribución Gamma	143
5.7. Valor Esperado y Varianza de una Variable Distribuida según la Distribución Gamma	145
5.8. Distribución Beta	146
5.9. Valor Esperado y Varianza de una Variable Distribuida según la Distribución Beta	147
5.10. Distribución Normal	147
5.11. Valor Esperado y Varianza de una Variable Normalmente Distribuida	148
5.12. Propiedades de las Variables Normales	150
5.13. Cálculo de Probabilidades en la Distribución Normal	152
5.14. La Distribución Normal como Aproximación de la Distribución Binomial	159
5.15. Distribución χ^2 de Pearson	160
5.16. Valor Esperado y Varianza de una Variable χ^2	163
5.17. Distribución "t" de Student	163
5.18. Distribución "F" de Snedecor	165
Ejercicios Resueltos	168
Ejercicios Propuestos	170

CAPITULO VI. DESIGUALDAD DE CHEBYCHEV, LEY DE LOS GRANDES NUMEROS, TEOREMA DEL LIMITE CENTRAL

6.1. Introducción	175
6.2. Desigualdad de Chebychev	175
6.3. Ley de los Grandes Números	179
6.4. Teorema del Limite Central	181
Ejercicios Resueltos	185
Ejercicios Propuestos	186

INFERENCIA ESTADISTICA

CAPITULO VII. CONCEPTOS FUNDAMENTALES DE LA INFERENCIA ESTADÍSTICA

189

7.1. Introducción	189
7.2. Población, Muestra y Muestra Aleatoria	190
7.3. Estadístico Muestral	193
7.4. Reformulación de la Desigualdad de Chebychev, Ley de los Grandes Números y Teorema del Límite Central	196
7.5. Distribución de Probabilidades de Algunos Estadísticos	201
7.5.1. Distribución de la Media Muestral de una Población Normal	201
7.5.2. Distribución de la Media Muestral de una Población Distinta de la Normal	202
7.5.3. Distribución de la Varianza Muestral	202
7.5.4. Distribución de la Media Muestral cuando no se conoce la Varianza de la Población	205
7.5.5. Distribución de la Proporción Muestral	206
7.5.6. Distribución de la Diferencia de Medias Muestrales	207
7.5.6.1. Varianza de las Poblaciones Conocidas	207
7.5.6.2. Varianza de las Poblaciones Desconocidas	208
7.5.7. Distribución de la Diferencia de Proporciones Muestrales	209
Ejercicios Resueltos	210
Ejercicios Propuestos	213

CAPITULO VIII. ESTIMACION POR PUNTOS

217

8.1. Introducción	217
8.2. El Problema de la Elección	219
8.3. Propiedades de los Estimadores	222
8.3.1. Estimadores Insesgados	223
8.3.2. Estimadores Eficientes (Relativa Eficiencia)	225
8.3.3. Estimadores Consistentes	227
8.3.4. Estimadores Suficientes	230
8.4. Cálculo de Estimadores (Método de Máxima Verosimilitud)	234
Ejercicios Resueltos	240
Ejercicios Propuestos	246

CAPITULO IX. ESTIMACION POR INTERVALOS

251

9.1. Introducción	251
9.2. Intervalos de Confianza para la Media de una Población	257
9.2.1. Poblaciones con Varianza Conocida	257
9.2.2. Poblaciones con Varianza Desconocida	258
9.2.3. Poblaciones Finitas con Varianza Conocida	261
9.2.4. Poblaciones Finitas con Varianza Desconocida	263

9.2.5. Determinación del Tamaño de la Muestra	264
9.3. Intervalos de Confianza para la Proporción de una Población	265
9.3.1. Muestreo con Reemplazamiento	265
9.3.2. Muestreo sin Reemplazamiento	269
9.4. Intervalos de Confianza para la Varianza de una Población Normal	271
9.5. Intervalos de Confianza para la Varianza de una Población no Normal	273
9.6. Intervalos de Confianza para la Diferencia de Medias de dos Poblaciones	275
9.6.1. Poblaciones con Varianza Conocida	275
9.6.2. Poblaciones con Varianza Desconocida	276
9.6.3. Poblaciones Finitas (Muestreo sin Reemplazamiento)	278
9.7. Intervalos de Confianza para la Diferencia de Proporciones de dos Poblaciones	278
9.7.1. Muestreo con Reemplazamiento	278
9.7.2. Muestreo sin Reemplazamiento	279
Ejercicios Resueltos	279
Ejercicios Propuestos	289

CAPITULO X. CONTRASTE DE HIPOTESIS

297

10.1. Introducción	297
10.2. Contraste de Hipótesis	303
10.3. Errores Tipo I y Tipo II	305
10.4. Nivel de Significación, Función Característica de Operación y Función de Potencia de un Contraste	312
10.5. Elección del Contraste	319
Ejercicios Propuestos	331

CAPITULO XI. CONTRASTE DE HIPOTESIS (CONTINUACION)

333

11.1. Contraste de Hipótesis Sobre la Media de una Población	333
11.1.1. Cola por la Derecha	333
11.1.2. Cola por la Izquierda	337
11.1.3. Dos Colas	339
11.1.4. Determinación del Tamaño de la Muestra	342
11.2. Contraste de Hipótesis Sobre la Proporción de una Población	346
11.2.1. Cola por la Derecha	346
11.2.2. Cola por la Izquierda	347
11.2.3. Dos Colas	348
11.2.4. Determinación del Tamaño de la Muestra	349
11.3. Contraste de Hipótesis Sobre la Diferencia de Medias de dos Poblaciones	349
11.3.1. Dos Colas	350
11.3.2. Una Cola	353

11.4. Contraste de Hipótesis Sobre la Diferencia de Proporciones de dos Poblaciones	356
11.4.1. Dos Colas	356
11.4.2. Una Cola	358
11.5. Contraste de Hipótesis Sobre la Varianza de una Población	359
11.5.1. Dos Colas	360
11.5.2. Cola por la Derecha	360
11.5.3. Cola por la Izquierda	361
11.6. Contraste de Hipótesis Sobre la Igualdad de Varianzas de dos Poblaciones Normales	361
Ejercicios Resueltos	364
Ejercicios Propuestos	373
CAPITULO XII. CONTRASTE DE HIPOTESIS (CONTINUACION)	381
12.1. Introducción	381
12.2. Contraste χ^2 de Bondad del Ajuste	383
12.3. Contraste de Kolmogorov-Smirnov	395
12.4. Contraste de Independencia: Tablas de Contingencia	397
12.5. Coeficiente de Contingencia	403
Ejercicios Resueltos	404
Ejercicios Propuestos	413
CAPITULO XIII. ANALISIS DE VARIANZA	421
13.1. Introducción	421
13.2. Clasificación Simple	422
13.2.1. Planteamiento del Problema y Nomenclatura	422
13.2.2. Descomposición de la Suma de Cuadrados	426
13.2.3. Procedimiento del Contraste	429
13.2.4. Fórmulas Prácticas para Simplificación de Cálculos	432
13.2.5. Distintos Tamaños de Muestra	435
13.3. Clasificación Doble	439
13.3.1. Caso de una Observación Muestral en cada Celda	439
13.3.1.1. Descomposición de la Suma de Cuadrados	441
13.3.1.2. Procedimiento del Contraste	444
13.3.1.3. Fórmulas Prácticas para Simplificación de Cálculos	446
13.3.2. Caso de varias Observaciones Muestrales en cada Celda	449
13.3.2.1. Descomposición de la Suma de Cuadrados	452
13.3.2.2. Procedimiento del Contraste	456
13.3.2.3. Fórmulas Prácticas para Simplificación de Cálculos	458
13.4. Apéndice: Comparación de Varianzas de varias Poblaciones	461
Ejercicios Resueltos	465
Ejercicios Propuestos	475

ECONOMETRIA

CAPITULO XIV. CONCEPTOS BASICOS DE ECONOMETRIA	481
14.1. Introducción	481
14.2. Modelos Económicos	482
14.3. Ejemplos de Modelos	485
14.4. Clasificación y Componentes de los Modelos Económicos Matemáticos	488
14.5. Forma Estructural y Forma Reducida	490
14.6. Modelos Econométricos	493
14.7. Utilidad de los Modelos	495
14.8. La Econometría en Acción	497
14.9. El Modelo de Regresión Simle	499
Ejercicios Propuestos	507
CAPITULO XV. MODELO LINEAL GENERAL	511
15.1. Introducción	511
15.2. El Modelo de Regresión	512
15.3. Estimación del Modelo	516
15.4. Propiedades de los Estimadores Mínimocuadráticos	522
15.5. Estimador de la Varianza de las Perturbaciones	528
15.6. Bondad del Ajuste. Coeficiente de Determinación R^2	532
15.6.1. El Coeficiente de Determinación	532
15.6.2. Interpretación de R^2	537
15.6.3. Coeficiente de Determinación Modificado ($\bar{R}^2$)	540
15.7. Otros Resultados Estadísticos del Modelo	541
Ejercicios Propuestos	551
Resultados del Programa de Computación	557
APENDICE A	559
Tabla I. Distribución Normal	561
Tabla II. Distribución χ^2	562
Tabla III. Distribución t	564
Tabla IV. Distribución F	565
Tabla V. Valores Críticos para el Contraste KolmogorovSmirnov	569
RESPUESTAS DE LOS EJERCICIOS PROPUESTOS	571
INDICE BIBLIOGRAFICO	591
INDICE DE MATERIAS	593

INTRODUCCION

II. LA CIENCIA ESTADISTICA

El concepto de “estadística” originalmente significó la simple recolección de información económica y de población que era necesaria para el Estado. En este sentido fue utilizada por vez primera la palabra en el Siglo XVIII y fue definida como la “ciencia que nos enseña la situación política de los Estados Modernos del mundo conocido.” Zimmerman la definió como “una rama del conocimiento político que tiene por objeto estudiar la potencia real y relativa de los distintos estados modernos, la capacidad derivada de sus condiciones naturales, la industria y civilización de sus habitantes y la sabiduría de sus gobernantes”. De este modesto comienzo la estadística se ha desarrollado hasta llegar a ser un método científico de análisis que es aplicable en prácticamente todas las ciencias.

La estadística ha pasado a ser la ciencia de recoger, presentar, analizar e interpretar datos numéricos y constituye la rama del saber humano que tiene como objeto el estudio de ciertos métodos inductivos aplicables a fenómenos susceptibles de expresión cuantitativa.

El uso de la estadística ha llegado a ser, en parte gracias al desarrollo de las computadoras electrónicas, esencial en el desarrollo de prácticamente todas las disciplinas: física, economía, sociología, administración de empresas, ingeniería, psicología, etc., y los profesionales de estas ramas recogen e interpretan la información estadística para llevar a cabo sus actividades más eficientes.

LII. ESTADISTICA DESCRIPTIVA Y ESTADISTICA ESTIMATIVA

La mayoría de las personas ven la Estadística en relación al uso de datos, promedios, gráficos o cuadros que tratan de describir una determinada situación.

EJEMPLO I.I.

La totalidad de las transacciones realizadas en la Bolsa de Valores en una semana no pueden ser presentadas eficientemente una a una debido a su elevado número; en lugar de ello se describe la situación informando el número de transacciones, los precios más alto y más bajo, los precios en el momento de apertura y de cierre y el precio promedio alcanzado.

Este tipo de información y los métodos para implementarla corresponden al estudio de la Estadística Descriptiva.

La Estadística Descriptiva comprende los métodos de agrupamiento de datos numéricos y cálculo de ciertas magnitudes a partir de ellos con objeto de describir al grupo.

La Estadística Estimativa o Inferencia Estadística, contenido de este texto, no se conforma con una pura descripción sino que trata de inferir características generales de una población a partir del examen de un subconjunto de esa población. La importancia de la Inferencia Estadística se debe al papel que juega en la verificación de generalizaciones estadísticas, entendiéndose por tales aquellas que implican que habrá excepciones a lo que la generalización afirma. La afirmación "el sector campesino vota por un determinado partido" es una generalización estadística y el que existan uno o más campesinos que voten por otro partido no hace falsa la afirmación.

EJEMPLO I.II.

En los procesos de producción es importante controlar la calidad de las mercancías producidas. Supongamos que se trata de la producción de cauchos y que, para efectos de garantía, es deseable que el 90% por lo menos de los cauchos producidos duren más de 20.000 km. Es evidente que una forma de conocer la verdadera proporción de cauchos producidos que cumplen el requisito es someter a prueba todas las unidades producidas, pero también es evidente que esto, además de consumir demasiado tiempo que haría impracticable cualquier cambio en el proceso de producción, tiene la indeseable característica de que no quedarían cauchos para vender. En lugar de eso, se decide que cada cincuenta cauchos producidos en un día se toma uno y se somete a prueba; el porcentaje de los cauchos examinados que duran más de 20.000 km. puede ser usado para estimar el porcentaje de todos los cauchos producidos que duran más de 20.000 km.; al hacer esto, estamos generalizando los resultados de un subgrupo para sacar conclusiones de todo el grupo.

EJEMPLO I.III.

Antes de las elecciones presidenciales se realizan encuestas para tratar de estimar la proporción de electores que votará por cada candidato, y con base en los resultados se diseñan políticas en el proceso de elecciones. Los porcentajes obtenidos en las muestras son usados como una aproximación de los verdaderos porcentajes que obtendrá cada candidato.

EJEMPLO I.IV.

Se ha propuesto a una industria un nuevo proceso de producción, que según el oferente hará aumentar la producción diaria. Para decidir la instalación o no del nuevo proceso se pone éste a prueba durante un período de 60 días y con base en la comparación de la producción media del período y la producción media conocida del proceso anterior se toma una decisión.

EJEMPLO I.V.

El Gobierno está interesado en determinar el índice de desempleo en el área metropolitana de Caracas; para estimarlo se conduce una encuesta preguntando a 2.000 personas seleccionadas aleatoriamente. El resultado de esa encuesta puede ser utilizado con miras a modificar o no la política de empleo.

Todos estos ejemplos que abarcan problemas relativos a distintas profesiones son típicos de la aplicación de la Inferencia Estadística. En cada caso, podemos preguntarnos hasta qué punto los resultados obtenidos en el examen de una parte de la población son representativos de las características generales de la población. Para estar seguros de nuestras decisiones deberíamos examinar todos los elementos de la población, pero si las muestras han sido elegidas adecuadamente podemos tener confianza que los resultados muestrales estarán cercanos a los poblacionales con cierto margen de error. Las preguntas cruciales son: ¿Cuán grande es el error que estamos cometiendo? ¿Cuánta confianza tenemos en que estamos actuando correctamente?

Este tipo de preguntas se responden con las técnicas de la Estadística Estimativa tales como la estimación, los intervalos de confianza, los contrastes de hipótesis. Estas técnicas se basan necesariamente en el cálculo de probabilidades, porque, en definitiva, al tomar una muestra de una población, los elementos de la muestra se obtienen con determinada probabilidad y en consecuencia los resultados concretos obtenidos a partir de la muestra se obtienen también con determinadas probabilidades al igual que los errores que se pueden cometer al tomar decisiones basadas en resultados parciales; evidentemente el investigador al tomar esas decisiones quisiera minimizar la probabilidad de cometer errores y para poder hacerlo debe conocer cuál es esa probabilidad; de ahí, la necesidad del estudio de la Teoría de Probabilidades como paso previo al estudio de la Inferencia Estadística.

I.III. INFERENCIA ESTADÍSTICA Y ECONOMETRÍA


Para los estudiantes de Economía el estudio de la Inferencia Estadística es fundamental para el entendimiento de una nueva rama de la Economía que se ha desarrollado en las últimas décadas, la Econometría.

La Econometría se puede definir como una rama de la Economía en la cual los instrumentos de la Teoría Económica, las Matemáticas y la Inferencia Estadística son aplicados al análisis de fenómenos económicos. Esta aplicación se lleva a cabo fundamentalmente a través de la estimación y evaluación de modelos econométricos.

Los modelos econométricos se diferencian de los modelos económicos matemáticos en que éstos especifican relaciones funcionales "exactas" entre las variables. Si escribimos $C = a + bY$ (C = Consumo, Y = Ingreso) estamos especificando que a cada nivel concreto de ingreso le corresponde un nivel especificado e invariable de consumo. Estas relaciones exactas suponen una simplificación útil para propósitos de análisis teórico, pero cuando se trata de verificar estas relaciones teóricas con datos reales o usarlas para proyectar el valor de las variables en el futuro, su utilidad queda en entredicho, porque la más superficial visión del mundo real nos demuestra la inexistencia de exactitud en tales relaciones. Por eso, la teoría económica representada en ellas se amplía con la introducción de elementos probabilísticos con los cuales se trata de tomar en cuenta en el modelo las diferencias de comportamiento individual con respecto a la relación exacta.

EJEMPLO I.VI.

Si deseamos estimar la función de consumo de una economía a través del examen de n individuos, es evidente que no todos los individuos con el mismo ingreso tendrán el mismo consumo. Los datos aparecerán en un diagrama seguramente como una sombra dispersa de puntos que muestran la existencia de una relación pero sin que esté claramente determinada su forma.



En consecuencia, la relación exacta postulada por la teoría económica ($C = a + bY$) se amplía con la introducción de un término de error ($C = a + bY + u$) que permite tomar en cuenta las desviaciones individuales; este término de error toma valores de acuerdo a determinadas probabilidades; sus valores se reflejarían en el valor de los parámetros a y b estimados a partir de datos muestrales, y los métodos de la inferencia estadística permitirán conocer la bondad del ajuste a la relación teórica y lo significativo que puedan ser los estimadores de a y b que en este caso representan el consumo autónomo y la propensión marginal al consumo respectivamente.

En Economía y en las Ciencias Sociales en general para describir adecuadamente los fenómenos se necesita tomar en cuenta muchos factores incluso no cuantitativos; en consecuencia se trabaja con datos que, a priori, se sabe que no representan una exacta caracterización del fenómeno; la relación entre las variables puede estar difusa; por eso, cuanto menos estricta sea la relación teórica más importante es el uso de métodos estadísticos rigurosos para su estimación.

CAPITULO I

ELEMENTOS DEL CALCULO DE PROBABILIDADES

1.1. INTRODUCCION

Uno de los instrumentos más útiles en el campo de la estadística aplicada es el cálculo de probabilidades, el cual tuvo su origen y primera aplicación en los juegos de azar. En su desarrollo posterior se han ido encontrando campos de aplicación que abarcan prácticamente todas las ciencias.

El cálculo de probabilidades comprende los métodos de análisis que son comunes al estudio de fenómenos aleatorios, entendiéndose por tales unos fenómenos empíricos que tienen la propiedad de que su realización repetida bajo un determinado conjunto de circunstancias, puede dar lugar a distintos resultados. Cada realización concreta de un fenómeno aleatorio constituye un experimento aleatorio; nosotros estamos interesados en los posibles resultados de esos experimentos y en las probabilidades de que se den esos resultados.

EJEMPLO 1.1.

Si lanzamos un dado y observamos el resultado obtenido, estamos realizando un experimento cuyo resultado no puede saberse con certeza antes de haberse efectuado. Los posibles resultados son seis: obtener un 1, un 2, un 3, un 4, un 5 ó un 6.

Con la progresiva amplitud y profundidad en los estudios de la teoría de probabilidades, se desarrollaron diversos conceptos o definiciones de probabilidad. Históricamente se pueden señalar el surgimiento del concepto a priori, concepto a posteriori y concepto axiomático de probabilidad.

1.2. CONCEPTO DE PROBABILIDAD A PRIORI

Si la realización concreta de un fenómeno aleatorio puede dar lugar a x resultados mutuamente excluyentes e igualmente posibles, y x' de esos resultados corresponden a una modalidad A del fenómeno, se dice que la probabilidad de la modalidad A es el resultado de dividir el número de resultados favorables a la modalidad A (x') entre el número total de posibles resultados (x), y escribiremos:

$$P(A) = \frac{x'}{x}$$

Observen que decimos resultados mutuamente excluyentes e igualmente posibles. Dos resultados son mutuamente excluyentes si la realización de uno implica la imposibilidad de la realización del otro. El concepto de resultados igualmente posibles implica que no hay nada que haga pensar que alguno de los resultados tiene más posibilidad de darse que los otros.

EJEMPLO 1.2.

Consideremos el experimento del ejemplo anterior, que consistía en lanzar un dado. Decíamos que existían 6 posibles resultados: 1, 2, 3, 4, 5, 6. Es evidente que éstos son mutuamente excluyentes puesto que no se pueden dar dos o más resultados simultáneamente. Además, si el dado no está cargado cada uno de los resultados es igualmente posible.

Consideremos ahora la modalidad A, que representa que el resultado será un número impar. Tenemos $x = 6$, mientras que $x' = 3$ puesto que hay 3 resultados que son números impares: 1, 3, 5. Luego la probabilidad de obtener un número impar al lanzar un dado es:

$$P(A) = \frac{x'}{x} = \frac{3}{6} = \frac{1}{2}$$

EJEMPLO 1.3.

En una caja hay 5 fichas rojas, 2 fichas verdes y 3 fichas blancas. Supongamos que queremos saber la probabilidad de que al extraer 2 fichas al azar, éstas sean

rojas. Podríamos razonar que los posibles resultados son seis ($x = 6$), a saber: obtener 2 fichas rojas, obtener 2 fichas verdes, obtener 2 fichas blancas, una roja y una blanca, una roja y una verde o una verde y una blanca. De estos "6 posibles resultados" solamente uno, el primero, corresponde a la modalidad de que las 2 fichas sean rojas ($x' = 1$). Podríamos concluir entonces diciendo que la probabilidad de obtener 2 fichas rojas es:

$$P(A) = \frac{x'}{x} = \frac{1}{6}$$

Sin embargo, analizando el experimento más detenidamente, observaremos que tanto el razonamiento seguido, como la conclusión obtenida están erradas. En efecto, los 6 resultados considerados no son igualmente posibles. Veamos por qué: Supongamos que las fichas están numeradas; las rojas del 1 al 5, las verdes 6 y 7, y las blancas 8, 9, 10. Los posibles resultados al extraer 2 fichas son 45 y no 6, ($x = 45$):

(1,2),	(1,3),	(1,4),	(1,5),	(1,6),	(1,7),	(1,8),	(1,9),	(1,10)
	(2,3),	(2,4),	(2,5),	(2,6),	(2,7),	(2,8),	(2,9),	(2,10)
		(3,4),	(3,5),	(3,6),	(3,7),	(3,8),	(3,9),	(3,10)
			(4,5),	(4,6),	(4,7),	(4,8),	(4,9),	(4,10)
				(5,6),	(5,7),	(5,8),	(5,9),	(5,10)
					(6,7),	(6,8),	(6,9),	(6,10)
						(7,8),	(7,9),	(7,10)
							(8,9),	(8,10)
								(9,10)

De estos resultados 10 corresponden a la modalidad de que las 2 fichas sean rojas, ($x' = 10$): (1,2), (1,3), (1,4), (1,5), (2,3), (2,4), (2,5), (3,4), (3,5), (4,5). Luego la probabilidad de obtener 2 fichas rojas es:

$$P(A) = \frac{x'}{x} = \frac{10}{45}$$

Es preciso observar que la probabilidad es un número comprendido entre cero y uno, puesto que el número de resultados favorables a una modalidad no puede ser ni negativo, ni mayor que el número total de casos posibles.

Cuando una modalidad no puede darse su probabilidad es cero; así, en el primer ejemplo la probabilidad de obtener un 7 al lanzar un dado, es cero. Si una modalidad debe darse con certeza, su probabilidad es uno; así, la probabilidad de obtener un número menor o igual a 6 al lanzar un dado, es uno.

1.3. CONCEPTO DE PROBABILIDAD A POSTERIORI

El concepto de probabilidad a priori tiene la desventaja de que no es aplicable cuando el número de resultados posibles es infinito. Mas aún, este concepto es válido solamente cuando los resultados son igualmente posibles. Si lanzamos un dado cargado de forma que es más probable que aparezca un 6, los resultados del experimento no son igualmente posibles, de tal forma que no se puede aplicar el concepto de probabilidad a priori.

Estas dificultades dieron lugar a que surgiera un nuevo concepto de probabilidad; probabilidad a posteriori o de frecuencia relativa.

El concepto es muy simple; si realizamos un experimento aleatorio un número grande de veces (n), y una determinada modalidad A se da n_A veces, sabemos que la frecuencia relativa de la modalidad A es $f_A = n_A/n$. Según el concepto de probabilidad a posteriori la probabilidad de la modalidad A sería el límite de la frecuencia relativa de A cuando n tiende a infinito; es decir:

$$P(A) = \lim_{n \rightarrow \infty} f_A = \lim_{n \rightarrow \infty} \frac{n_A}{n}$$

En la práctica la probabilidad se aproxima por la frecuencia relativa al repetir el experimento un número grande de veces; es decir:

$$P(A) \approx f_A = \frac{n_A}{n}$$

EJEMPLO 1.4.

Si al lanzar 500 veces una moneda, resultan 275 caras, la frecuencia relativa de la modalidad cara es $275/500 = 0,55$. Según el concepto de probabilidad a posteriori, usaríamos 0,55 como una aproximación de la probabilidad de la modalidad cara para esa particular moneda.

1.4. CONCEPTO AXIOMATICO DE PROBABILIDAD ¹

Modernamente se ha desarrollado el concepto de probabilidad con base en el estudio de modelos matemáticos de fenómenos aleatorios.

¹ En esta sección y las siguientes se utilizan conceptos y notaciones de la teoría de conjuntos.

DEFINICION 1.1.

Cada uno de los posibles resultados de un experimento aleatorio se conoce como "punto muestral".

DEFINICION 1.2

El conjunto de todos los puntos muestrales de un experimento aleatorio constituye un "espacio muestral", y se representa por S.

EJEMPLO 1.5.

Si un experimento aleatorio consiste en lanzar una moneda 2 veces, los posibles resultados son: (Cara, Cara), (Cara, Sello), (Sello, Cara) y (Sello, Sello), donde el primer elemento de cada par corresponde al resultado del primer lanzamiento; y el segundo elemento, al resultado del segundo lanzamiento. Cada uno de estos 4 resultados es un punto muestral del experimento, y el espacio muestral contiene 4 puntos muestrales.

EJEMPLO 1.6.

Un experimento aleatorio consiste en seleccionar 200 unidades de la producción de cierto artículo, y observar cuántas son defectuosas. Los posibles resultados son el posible número de unidades defectuosas. Pueden encontrarse 0, 1, 2, 3, ó 200 unidades defectuosas. El espacio muestral contiene 201 puntos muestrales.

DEFINICION 1.3.

Un suceso A es un subconjunto de un espacio muestral, $A \subset S$. Si un suceso contiene un solo punto muestral, lo llamaremos suceso simple; si contiene 2 ó más puntos muestrales, lo llamaremos suceso compuesto.

Cuando se habla de la probabilidad de que se dé el suceso A, se quiere señalar la probabilidad de que se dé cualquiera de los puntos muestrales del suceso A.

En muchos problemas los espacios muestrales contienen un número finito de puntos y cada uno de éstos tiene la misma probabilidad de darse. En estos casos, siendo s_i un punto muestral ($i = 1, \dots, m$) y m el número de puntos muestrales del espacio, la probabilidad de que se dé el punto muestral s_i es:

$$P(s_i) = \frac{1}{m}; \quad \text{para } i = 1, \dots, m$$

Si el suceso A contiene m_A puntos muestrales,

$$P(A) = \frac{m_A}{m}$$

EJEMPLO 1.7.

Consideremos el experimento de lanzar un dado. $S = \{1, 2, 3, 4, 5, 6\}$. Cada punto muestral tiene una probabilidad de darse de $1/6$. Consideremos el suceso A de obtener un número mayor que 2. $A = \{3, 4, 5, 6\}$. Puesto que A contiene 4 puntos muestrales, $P(A) = m_A/m = 4/6 = 2/3$.

DEFINICION 1.4.

Sucesos mutuamente excluyentes. Sean A y B dos sucesos en un espacio muestral S., $A \subset S$ y $B \subset S$. A y B serán mutuamente excluyentes si su intersección es el conjunto vacío; es decir, si $A \cap B = \emptyset$. En otras palabras, dos sucesos son mutuamente excluyentes si la realización de uno implica la imposibilidad de la realización simultánea del otro.

EJEMPLO 1.8.

En el ejemplo anterior $S = \{1, 2, 3, 4, 5, 6\}$. Sean $A = \{1, 2\}$ y $B = \{3, 4, 5\}$. $A \cap B = \emptyset$, luego A y B son mutuamente excluyentes.

El concepto puede extenderse a más de 2 sucesos. Sean $A_1, A_2, \dots, A_n$ n sucesos en el espacio muestral S. Estos sucesos serán mutuamente excluyentes si todas las intersecciones de cada 2 conjuntos son vacías; es decir si $A_i \cap A_j = \emptyset$ para $i \neq j$

Veamos ahora los axiomas en que se basa el concepto axiomático de probabilidad.

Sea S un espacio muestral, y $A_1, A_2, \dots, A_n$ sucesos en S; es decir,

$$A_i \subset S, A_2 \subset S, \dots, A_n \subset S.$$

Axioma 1. La probabilidad de que se dé el suceso A_i es un número mayor o igual a cero para todo i, es decir:

$$P(A_i) \geq 0 \quad \forall i$$

Axioma 2. La probabilidad del suceso "espacio muestral" es igual a uno; es decir:

$$P(S) = 1$$

Axioma 3. Si $A_1, A_2, A_3, \dots$ son sucesos mutuamente excluyentes, la probabilidad de su reunión es igual a la suma de las probabilidades de cada suceso, es decir:

$$P(A_1 \cup A_2 \cup A_3 \cup \dots) = P(A_1) + P(A_2) + P(A_3) + \dots$$

EJEMPLO 1.9.

Un experimento aleatorio consiste en lanzar 2 dados. El espacio muestral contiene 36 puntos muestrales, a saber:

$$S = \{(1,1), (1,2), (1,3), (1,4), (1,5), (1,6), \\ (2,1), (2,2), (2,3), (2,4), (2,5), (2,6), \\ (3,1), (3,2), (3,3), (3,4), (3,5), (3,6), \\ (4,1), (4,2), (4,3), (4,4), (4,5), (4,6), \\ (5,1), (5,2), (5,3), (5,4), (5,5), (5,6), \\ (6,1), (6,2), (6,3), (6,4), (6,5), (6,6)\}$$

Suponiendo que los dados no están cargados la probabilidad de cada punto muestral es $P(i, j) = 1/36$ para $i = 1, \dots, 6, j = 1, \dots, 6$.

Sea A el suceso de que la suma de los 2 dados sea 6, y B el suceso de que la suma sea 11.

$$P(A) = \frac{m_A}{m} = \frac{5}{36}; \quad P(B) = \frac{m_B}{m} = \frac{2}{36}$$

¿Cuál es la probabilidad de que la suma sea 6 u 11? El suceso C de que la suma sea 6 u 11, es la reunión de los sucesos A y B; puesto que A y B son mutuamente excluyentes, por Axioma 3, se tiene:

$$P(C) = P(A \cup B) = P(A) + P(B) = \frac{5}{36} + \frac{2}{36} = \frac{7}{36}$$

1.5. TEOREMAS SOBRE PROBABILIDAD

Teorema 1: Sea $\bar{A}$ el suceso complemento de A respecto de S. Entonces

$$P(\bar{A}) = 1 - P(A)$$

En efecto:

$$S = A \cup \bar{A} \quad y \quad A \quad y \quad \bar{A} \quad \text{son mutuamente excluyentes.}$$

Por axioma 2, $P(S) = 1$,

$$1 = P(S) = P(A \cup \bar{A}) = P(A) + P(\bar{A})$$

$$P(\bar{A}) = 1 - P(A)$$

o sea, la probabilidad de que no se dé el suceso A es igual a uno menos la probabilidad de que se dé A.

Teorema 2: Sea A un suceso en el espacio muestral S; entonces:

$$P(A) \leq 1$$

Por Teorema 1, $P(A) = 1 - P(\bar{A})$

Por Axioma 1, $P(\bar{A}) \geq 0$

Luego: $P(A) \leq 1$

Este teorema unido al axioma permite decir que para cualquier suceso A en S, se cumple:

$$0 \leq P(A) \leq 1$$

O sea que la probabilidad de cualquier suceso en el espacio muestral S es un número comprendido entre cero y uno.

1.6. PROBABILIDAD CONDICIONAL

Consideren dos sucesos A y B, se entiende por probabilidad condicional del suceso B -dado el suceso A- la probabilidad de que B ocurra, dado que A ha ocurrido. El hecho de que A haya ocurrido nos da información adicional sobre la probabilidad de ocurrencia de B. La probabilidad condicional de B, dado A, se representa $P(B/A)$.

La diferencia entre la probabilidad simple que hasta ahora se ha visto, y la probabilidad condicional, se hará más clara con un ejemplo:

EJEMPLO 1.10.

Un experimento consiste en lanzar 2 dados sucesivamente. El espacio muestral del experimento ha sido dado en el Ejemplo 1.9. Vamos a clasificar los resultados siguiendo 2 criterios diferentes: 1° Según que el resultado del primer dado sea par o impar; y 2° Según que la suma de los dados sea menor que 5, esté entre 5 y 8 ambos inclusive, o sea mayor que 8. Esta clasificación da el siguiente cuadro de doble entrada:

		N° de Puntos Muestrales			
		Suma < 5	5 ≤ Suma ≤ 8	Suma > 8	Total
N° de Puntos Muestrales	Resultado 1er. Dado Par	2	10	6	18
	Resultado 1er. Dado Impar	4	10	4	18
Total		6	20	10	36

Sea B el suceso de que la suma sea mayor que 8

Sea A el suceso de que el resultado del primer dado sea par

$A \cap B$ será el suceso de que el resultado del primer dado sea par y que la suma de los dados sea mayor que 8.

$$P(B) = \frac{m_B}{m} = \frac{10}{36}; \quad P(A) = \frac{m_A}{m} = \frac{18}{36}; \quad P(A \cap B) = \frac{m_{A \cap B}}{m} = \frac{6}{36}$$

Podemos preguntar ahora cuál es la probabilidad de que la suma sea mayor que 8, dado que el resultado del primer dado fue par. A la luz de esta información adicional la probabilidad del suceso B se modifica. En efecto, sabiendo que el primer dado dio un número par, nuestro espacio muestral se ha reducido. Hay 18 resultados con esa característica, de los cuales 6 tienen la característica de que la suma es mayor que 8. Luego:

$$P(B/A) = \frac{6}{18} = \frac{m_{A \cap B}}{m_A}$$

Hay que observar que esta probabilidad tiene significado solamente, si $m_A > 0$

Dividiendo numerador y denominador por m, obtenemos:

$$P(B/A) = \frac{m_{A \cap B}/m}{m_A/m} = \frac{P(A \cap B)}{P(A)}$$

DEFINICION 1.5.

Sean A y B dos sucesos en el espacio muestral S, tales que $P(A) > 0$, la probabilidad condicional del suceso B, dado el suceso A, es

$$P(B/A) = \frac{P(A \cap B)}{P(A)}$$

Si $P(A) = 0$, $P(B/A)$ es indefinida.

EJEMPLO 1.11.

Una caja contiene 5 fichas blancas y 4 rojas. Dos fichas son extraídas al azar sin reemplazamiento. ¿Cuál es la probabilidad de que la segunda ficha sea blanca, si se sabe que la primera ha sido blanca?

Sea A el suceso de que la primera es blanca, y B el suceso de que la segunda es blanca. $A \cap B$ es el suceso de que ambas son blancas. Hay $C_{9,2}$ formas diferentes de extraer 2 fichas de una caja que contiene 9; luego los posibles resultados del experimento son $C_{9,2} = 36$. El número de formas diferentes de extraer 2 fichas blancas es $C_{5,2}$. Luego $m_{A \cap B} = C_{5,2} = 10$

$$P(A \cap B) = \frac{10}{36}$$

La probabilidad del suceso A, o sea de que la primera ficha sea blanca, es obviamente $P(A) = 5/9$. Luego:

$$P(B/A) = \frac{P(A \cap B)}{P(A)} = \frac{10/36}{5/9} = \frac{1}{2}$$

Evidentemente podríamos haber llegado a esta conclusión de una forma más sencilla. Si extraemos una ficha y sabemos que ésta es blanca, en la caja quedarán 8 fichas, 4 de ellas blancas, luego la probabilidad de extraer la segunda ficha blanca es $4/8 = 1/2$.

El uso del concepto de probabilidad condicional en este ejemplo es únicamente con propósitos didácticos.

EJEMPLO 1.12.

En un examen de Estadística pasó el 70% de los estudiantes. Por otro lado, el 60% de los que no pasaron arrastraba Cálculo, mientras que el 10% de los que pasaron arrastraba Cálculo. Si elegimos un estudiante al azar ¿Cuál es la probabilidad de haber elegido un estudiante que pasó el examen, si sabemos que arrastraba Cálculo?

Sea A el suceso de que el estudiante arrastre Cálculo

Sea B el suceso de que el estudiante haya pasado el examen de Estadística.

La proporción de estudiantes que arrastra Cálculo es:

$$60\% \times 30\% + 10\% \times 70\% = 25\%$$

$$P(A) = \frac{25}{100} = 0,25$$

La proporción de estudiantes que arrastra Cálculo y pasó el examen es $10\% \times 70\% = 7\%$.

$$P(A \cap B) = \frac{7}{100} = 0,07$$

$$P(B/A) = \frac{P(A \cap B)}{P(A)} = \frac{0,07}{0,25} = 0,28$$

¿Cuál es la probabilidad de elegir un estudiante que haya pasado el examen, si sabemos que no arrastra Cálculo?

Sea C el suceso de que un estudiante no arrastra Cálculo, y B definido como antes. La proporción de estudiantes que no arrastran Cálculo es 75%, luego $P(C) = 0,75$; y la proporción de estudiantes que no arrastran Cálculo y pasaron el examen de Estadística es 63%. Luego $P(B \cap C) = 0,63$. Entonces:

$$P(B/C) = \frac{P(B \cap C)}{P(C)} = \frac{0,63}{0,75} = 0,84$$

1.7. PROBABILIDAD PRODUCTO Y SUCESOS INDEPENDIENTES

Se entiende por probabilidad producto de 2 sucesos A y B en el espacio muestral S, la probabilidad de que los dos se den simultáneamente.

$$P(A \cap B) = P(B/A)P(A) = P(A/B)P(B)$$

Hemos visto que la probabilidad de un suceso B queda generalmente modificada cuando se tiene información de que otro suceso A ha ocurrido; es decir, la probabilidad del suceso B es generalmente diferente de la probabilidad condicional de B, dado A. Sin embargo, hay casos en que esto no sucede así, sino que la probabilidad simple y condicional de un suceso son iguales:

$$P(B) = P(B/A)$$

Si éste es el caso, se dice que los sucesos A y B son independientes.

$$P(B) = P(B/A) \Leftrightarrow P(A) = P(A/B)$$

porque,

$$P(A/B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A \cap B)}{P(B/A)} = \frac{P(A \cap B)}{P(A \cap B)/P(A)} = P(A)$$

Además,

$$P(A \cap B) = P(A)P(B)$$

porque,

$$P(A \cap B) = P(B/A)P(A) = P(B)P(A)$$

De forma que dos sucesos son independientes sí y solamente sí su probabilidad producto es igual al producto de sus probabilidades respectivas, o sea si,

$$P(A \cap B) = P(A)P(B)$$

En general si $A_1, A_2, \dots, A_n$ son n sucesos cada uno con probabilidad positiva $P(A_i) > 0 \forall i$, estos sucesos son independientes si y solo si la probabilidad de todas las posibles intersecciones de dos o más sucesos es igual al producto de las respectivas probabilidades de cada uno,

$$P(A_1 \cap A_2 \cap \dots \cap A_j) = P(A_1)P(A_2) \dots P(A_j) \quad j=2, \dots, n$$

EJEMPLO 1.13.

Supongamos una caja que contiene 3 fichas rojas y 2 negras. Extraemos 2 fichas de la caja con reemplazamiento, y queremos saber la probabilidad de que las 2 fichas sean rojas.

Sea A el suceso de que la primera ficha es roja, y B el suceso de que la segunda ficha es roja, $A \cap B$ será el suceso de que ambas sean rojas.

$$P(A \cap B) = \frac{m_{A \cap B}}{m} = \frac{3^2}{5^2} = \frac{9}{25}$$

Además $P(A) = 3/5$ y como devolvemos la ficha a la caja, $P(B) = 3/5$; o sea, $P(A \cap B) = P(A)P(B)$. Luego A y B son independientes.

EJEMPLO 1.14.

En el ejemplo 1.10., los sucesos A y B obviamente no son independientes; en efecto:

$$P(A \cap B) = \frac{6}{36}; \quad P(A) = \frac{18}{36}; \quad P(B) = \frac{10}{36}$$

$$P(A)P(B) = \frac{18}{36} \times \frac{10}{36} = \frac{5}{36} \neq \frac{6}{36} = P(A \cap B)$$

1.8. PROBABILIDAD SUMA

El axioma 3 dice que si dos sucesos son mutuamente excluyentes,


$$P(A \cup B) = P(A) + P(B)$$

Vamos a ver ahora cual es la $P(A \cup B)$, si los sucesos no son mutuamente excluyentes.

Teorema 3: Si A y B son 2 sucesos cualquiera no necesariamente mutuamente excluyentes en el espacio muestral S , entonces

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Intuitivamente podemos ilustrar el teorema con ayuda de un diagrama de Venn.



El área sombreada corresponde a la intersección de A y B , mientras que $A \cup B$ es toda el área rayada. Si el suceso A tiene m_A puntos muestrales, el suceso B , m_B puntos muestrales, y el suceso $A \cap B$, $m_{A \cap B}$ puntos muestrales, al sumar los puntos muestrales de A y B , estaremos contando 2 veces los puntos muestrales de $A \cap B$, por lo cual debemos restarlos una vez.

Al ser $A \cup B$ un suceso en el espacio muestral S , su probabilidad es:

$$\begin{aligned} P(A \cup B) &= \frac{m_{A \cup B}}{m} = \frac{m_A + m_B - m_{A \cap B}}{m} = \\ &= \frac{m_A}{m} + \frac{m_B}{m} - \frac{m_{A \cap B}}{m} = P(A) + P(B) - P(A \cap B) \end{aligned}$$

EJEMPLO 1.15.

Un experimento consiste en lanzar un dado y una moneda. ¿Cuál es la probabilidad de obtener un número par o una cara?

Sea A el suceso de obtener un número par al lanzar el dado.

Sea B el suceso de obtener una cara al lanzar la moneda.

$$P(A) = \frac{3}{6} = \frac{1}{2}; \quad P(B) = \frac{1}{2}; \quad P(A \cap B) = P(A)P(B) = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$$

P(obtener un número par o una cara) =

$$= P(A \cup B) = P(A) + P(B) - P(A \cap B) = \frac{1}{2} + \frac{1}{2} - \frac{1}{4} = \frac{3}{4}$$

EJEMPLO 1.16.

Al extraer una carta de una baraja queremos la probabilidad de obtener una figura o un diamante.

Sea A el suceso de obtener una figura.

Sea B el suceso de obtener un diamante.

$A \cap B$ será el suceso de obtener una figura de diamantes.

$$P(A) = \frac{12}{52} = \frac{3}{13}; \quad P(B) = \frac{13}{52}; \quad P(A \cap B) = \frac{3}{52}$$

Luego,

P(Obtener una figura o un diamante) =

$$= P(A \cup B) = P(A) + P(B) - P(A \cap B) = \frac{3}{13} + \frac{13}{52} - \frac{3}{52} = \frac{22}{52} = \frac{11}{26}$$

*** 1.9. TEOREMA DE BAYES**

Supongamos que hemos observado el resultado de un experimento, y preguntamos por la probabilidad de que el resultado es debido a una particular causa de una serie de posibles causas.

Sean $B_1, B_2, \dots, B_n$, n sucesos mutuamente excluyentes que representan las n posibles causas del resultado del experimento, siendo A el suceso que representa el resultado. Al realizar el experimento se dio el suceso A, y se desea saber la probabilidad de que habiéndose dado el suceso A, se haya dado uno de los sucesos B_i . En otras palabras, queremos saber si la causa de que se haya dado el suceso A fue el hecho de que se dio el suceso B_i ; o sea, interesa conocer $P(B_i/A)$. En este caso $P(B_i/A)$ no es la probabilidad de que se dé B_i dado A, sino la probabilidad de que se haya dado B_i puesto que se dio A.

$$P(B_i/A) = \frac{P(B_i \cap A)}{P(A)}$$

Sabemos que $P(B_i \cap A) = P(A/B_i) \cdot P(B_i)$

El suceso A debe darse en conjunción con una de las n mutuamente excluyentes causas, de forma que A ocurrirá si se da alguna de las posibles causas B_i .

Podemos escribir $A = (A \cap B_1) \cup (A \cap B_2) \cup \dots \cup (A \cap B_n)$, donde $(A \cap B_i)$ y $(A \cap B_j)$ son sucesos mutuamente excluyentes para $i \neq j$, luego

$$\begin{aligned} P(A) &= P(A \cap B_1) + P(A \cap B_2) + \dots + P(A \cap B_n) = \sum_{i=1}^n P(A \cap B_i) \\ &= \sum_{i=1}^n P(A/B_i) P(B_i) \end{aligned}$$

Entonces:

$$P(B_i/A) = \frac{P(B_i \cap A)}{P(A)} = \frac{P(A/B_i) P(B_i)}{\sum_{i=1}^n P(A/B_i) P(B_i)}$$

EJEMPLO 1.17.

Refiriéndonos al ejemplo 1.10., $P(B) = 5/18$ y $P(A) = 1/2$

Supongamos ahora que lanzamos el primer dado sin conocer su resultado, y que al lanzar el segundo, la suma de ambos resulta mayor que 8. ¿Cuál es la probabilidad de que el primer dado dio como resultado un número par, dado que la suma obtenida en los dos fue mayor que 8? El suceso de que la suma sea mayor que 8 pudo haberse dado en conjunción con dos sucesos: A_1 = Suceso que el primer dado haya sido par, y A_2 = Suceso que el primer dado haya sido impar.


Luego:

EJERCICIOS RESUELTOS

- 1.1. Dados 2 sucesos A y B en un espacio muestral S tales que $P(A) = 1/4$, $P(B) = 1/8$ y $P(A \cap B) = 1/16$. Calcular la probabilidad de que exactamente uno de los sucesos ocurra.

Solución:

Sea C el suceso de que ocurra exactamente uno de los sucesos A y B, entonces C es la reunión de dos sucesos D y F, definidos así:



D = Suceso de que ocurra A y no ocurra B

F = Suceso de que ocurra B y no ocurra A

El suceso D es la intersección de A con el complemento de B, y el suceso F es la intersección de B con el complemento de A. Además D y F son mutuamente excluyentes; luego:

$$P(C) = P(D \cup F) = P(D) + P(F) \text{ por axioma 3.}$$

$$P(C) = P(D) + P(F) = P[(A \cap \bar{B}) \cup (B \cap \bar{A})]$$

$P(A \cap \bar{B}) = P(A) - P(A \cap B)$, puesto que $A \cap \bar{B}$ y $A \cap B$ son sucesos mutuamente excluyentes, y su reunión es A,

$$P(A) = P(A \cap B) + P(A \cap \bar{B}) \Rightarrow P(A \cap \bar{B}) = P(A) - P(A \cap B)$$

$$\text{Similarmente, } P(B \cap \bar{A}) = P(B) - P(A \cap B)$$

Entonces,

$$P(C) = P(A) + P(B) - 2P(A \cap B)$$

Noten que esta expresión es válida para cualesquiera 2 sucesos en el espacio muestral S.

$$P(C) = \frac{1}{4} + \frac{1}{8} - 2 \frac{1}{16} = \frac{1}{4}$$

- 1.2. Dados dos sucesos A y B en el espacio muestral S. Sabiendo que $P(A) = 1/3$, $P(B/A) = 1/2$, $P(A/B) = 1/3$. Calcular la probabilidad de que se dé al menos uno de los sucesos A o B.

Solución

La probabilidad de que se dé al menos uno de los sucesos A o B, es la probabilidad que se dé sólo A, o que se dé sólo B, o que se den ambos, o sea la probabilidad de la reunión de A y B.

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Además,

$$P(B/A) = \frac{P(A \cap B)}{P(A)}; \quad P(A \cap B) = P(B/A) P(A) = \frac{1}{2} \frac{1}{3} = \frac{1}{6}$$

$$P(A/B) = \frac{P(A \cap B)}{P(B)}; \quad P(B) = \frac{P(A \cap B)}{P(A/B)} = \frac{1/6}{1/3} = \frac{1}{2}$$

En definitiva,

$$P(A \cup B) = \frac{1}{3} + \frac{1}{2} - \frac{1}{6} = \frac{2}{3}$$

- 1.3. Dados 3 sucesos A, B y C en el espacio muestral S, tales que $P(A/C) = 1/3$, $P(B/C) = 1/5$, $P[(A \cap B)/C] = 1/8$.

Calcular $P[(A \cup B)/C]$

Solución

Aplicando la expresión de probabilidad condicional, se tiene:

$$P[(A \cup B)/C] = \frac{P[(A \cup B) \cap C]}{P(C)}$$

El suceso $(A \cup B) \cap C = (A \cap C) \cup (B \cap C)$, luego:

$$\frac{P[(A \cup B) \cap C]}{P(C)} = \frac{P(A \cap C) + P(B \cap C) - P(A \cap B \cap C)}{P(C)} =$$

$$= P(A/C) + P(B/C) - P[(A \cap B)/C] = \frac{1}{3} + \frac{1}{5} - \frac{1}{8} = \frac{49}{120}$$

1.4. Un experimento consiste en lanzar dos dados bien balanceados. Sea A el suceso de que el resultado de ambos dados es el mismo. Sea B el suceso de que la suma de los resultados de los dos dados es un número par. Sea C el suceso de que al menos el resultado de uno de los dados es un 6. Calcular:

i) $P(A \cap B \cap C)$; ii) $P(\bar{A} \cup B)$; iii) $P(A \cap \bar{B})$; iv) $P(C/A)$

Solución

El espacio muestral S es:

$S = \{ (1,1), (1,2), (1,3), (1,4), (1,5), (1,6), (2,1), (2,2), (2,3), (2,4), (2,5), (2,6), (3,1), (3,2), (3,3), (3,4), (3,5), (3,6), (4,1), (4,2), (4,3), (4,4), (4,5), (4,6), (5,1), (5,2), (5,3), (5,4), (5,5), (5,6), (6,1), (6,2), (6,3), (6,4), (6,5), (6,6) \}$

$$m = 36$$

El suceso A es: $A = \{ (1,1), (2,2), (3,3), (4,4), (5,5), (6,6) \}$

$$m_A = 6 \quad P(A) = \frac{m_A}{m} = \frac{1}{6}$$

El suceso B es: $B = \{ (1,1), (1,3), (1,5), (2,2), (2,4), (2,6), (3,1), (3,3), (3,5), (4,2), (4,4), (4,6), (5,1), (5,3), (5,5), (6,2), (6,4), (6,6) \}$

$$m_B = 18 \quad P(B) = \frac{m_B}{m} = \frac{1}{2}$$

El suceso C es: $C = \{ (1,6), (2,6), (3,6), (4,6), (5,6), (6,1), (6,2), (6,3), (6,4), (6,5), (6,6) \}$

$$m_C = 11 \quad P(C) = \frac{11}{36}$$

i) El suceso $A \cap B \cap C$ es: $A \cap B \cap C = \{ (6,6) \}$; $m_{A \cap B \cap C} = 1$

$$P(A \cap B \cap C) = \frac{m_{A \cap B \cap C}}{m} = \frac{1}{36}$$

ii) $P(\bar{A} \cup B) = P(\bar{A}) + P(B) - P(\bar{A} \cap B) = P(\bar{A}) + P(B) - [P(B) - P(A \cap B)]$

$$= P(\bar{A}) + P(A \cap B)$$

$$A \cap B = \{ (1,1), (2,2), (3,3), (4,4), (5,5), (6,6) \} = A$$

$$P(\bar{A}) = 1 - P(A) = \frac{5}{6}; \quad P(A \cap B) = P(A) = \frac{1}{6}$$

$$P(\bar{A} \cup B) = \frac{5}{6} + \frac{1}{6} = 1$$

iii) $P(A \cap \bar{B}) = P(A) - P(A \cap B) = \frac{1}{6} - \frac{1}{6} = 0$

$$\text{iv) } P(C/A) = \frac{P(A \cap C)}{P(A)}$$

El suceso $A \cap C = \{ (6,6) \}$, $m_{A \cap C} = 1$, $P(A \cap C) = 1/36$

$$P(C/A) = \frac{1/36}{1/6} = \frac{1}{6}$$

1.5. Una caja contiene 9 fichas, de las cuales 6 son rojas, y 3 verdes. Al extraer dos fichas con reemplazamiento (Se extrae una, se observa el color, y se devuelve a la caja antes de extraer la segunda), calcular la probabilidad de que:

- i) ambas sean del mismo color ii) al menos una sea roja

Solución

Se supone que las fichas pueden distinguirse entre sí, para lo cual se numeran del 1 al 9: Las 6 rojas numeradas del 1 al 6 y las verdes del 7 al 9.

El espacio muestral S se puede describir como el conjunto de pares (x, y) tales que $x = 1, \dots, 9$, $y = 1, \dots, 9$

$$S = \{(x, y) / x = 1, 2, \dots, 9; y = 1, 2, \dots, 9\}$$

$$m = 9^2 = 81. S \text{ tiene } 81 \text{ puntos muestrales}$$

Sea A el suceso de que ambas fichas son rojas, A es el conjunto de pares (x, y) tales que $x = 1, \dots, 6$, $y = 1, \dots, 6$.

$$A = \{(x, y) / x = 1, \dots, 6; y = 1, \dots, 6\}$$

$$m_A = 6^2 = 36, A \text{ tiene } 36 \text{ puntos muestrales}$$

$$P(A) = \frac{36}{81}$$

Sea B el suceso de que ambas fichas son verdes, B es el conjunto de pares (x, y) tales que $x = 7, 8, 9$; $y = 7, 8, 9$.

$$B = \{(x, y) / x = 7, 8, 9; y = 7, 8, 9\}$$

$$m_B = 3^2 = 9. B \text{ tiene } 9 \text{ puntos muestrales}$$

$$P(B) = \frac{9}{81}$$

- i) La probabilidad de que ambas sean del mismo color es la probabilidad de que ambas sean rojas o que ambas sean verdes.

$$P(A \cup B) = P(A) + P(B) = \frac{36}{81} + \frac{9}{81} = \frac{45}{81}$$

- ii) Sea C el suceso que al menos 1 sea roja.

$$C = \bar{B}; \quad P(C) = 1 - P(B) = 1 - \frac{9}{81} = \frac{72}{81}$$

1.6. Supongamos que en las 11 escuelas de la UCAB cursan el mismo número de estudiantes. Si se escogen aleatoriamente 5 estudiantes de la UCAB. ¿Cuál es la probabilidad de que en el grupo de 5 no haya 2 o más que pertenezcan a la misma escuela?

Solución

Numeremos las escuelas de la 1 a la 11. El espacio muestral S puede ser descrito como el conjunto de 5-pleres $(x_1, x_2, x_3, x_4, x_5)$ tales que x_i va de 1 a 11, ($i = 1, \dots, 5$). Es decir cada elemento del 5-ple representa la escuela a que pertenece cada estudiante elegido. P. ej. (1, 11, 5, 5, 5) significa que la escuela del primer estudiante es la 1, la del 2º la 11 etc., de forma que:

$$S = \{(x_1, x_2, x_3, x_4, x_5) / x_i = 1, \dots, 11, \text{ para } i = 1, \dots, 5\}$$

Para que todos los puntos del espacio muestral tengan la misma probabilidad, hay que suponer que el número de estudiantes de cada escuela es igual o mayor que 5, porque si no, no se podría dar p. ej. el elemento (1, 1, 1, 1, 1).

El número de elementos de S será $m = 11^5$, porque el primer estudiante puede pertenecer a cualquiera de las escuelas, lo mismo el segundo, etc.

Sea A el suceso de que no hay dos o más estudiantes que pertenezcan a la misma escuela.

$$A = \{x_1, x_2, x_3, x_4, x_5 / x_i = 1, \dots, 11 \text{ para } i = 1, \dots, 5, x_1 \neq x_2 \neq x_3 \neq x_4 \neq x_5\}$$

$$\text{El número de puntos muestrales de A es } m_A = V_{11,5}$$

Luego

$$P(A) = \frac{m_A}{m} = \frac{V_{11,5}}{11^5} = \frac{11 \cdot 10 \cdot 9 \cdot 8 \cdot 7}{11^5} = 0,3442$$

1.7. Cuando ocurre un accidente de automóvil, las autoridades de tránsito hacen un análisis al conductor para determinar la presencia de alcohol en la sangre. Por experiencia se sabe que si el conductor ha ingerido licor, el análisis resultará positivo en el 97% de los casos. Por otro lado, el examen puede erróneamente resultar positivo en un 2% de los casos. Suponiendo que en el 1% de los accidentes el conductor haya

ingerido licor. ¿Cuál es la probabilidad de que en un accidente en particular en que el examen resultó positivo, el conductor haya ingerido realmente licor?

Solución

Aplicación del teorema de Bayes.

Sea A el suceso de haber ingerido licor, $P(A) = 0,01$

Sea B el suceso de que el examen es positivo.

$P(\bar{B}/\bar{A})$ = Probabilidad de que el examen sea positivo dado que no ha ingerido licor = 0,002.

$P(B/A)$ = Probabilidad que el examen sea positivo dado que ha ingerido licor = 0,97

$$P(A/B) = \frac{P(B/A)P(A)}{P(B/A)P(A) + P(\bar{B}/\bar{A})P(\bar{A})} = \frac{0,97 \times 0,01}{0,97 \times 0,01 + 0,002 \times 0,99} = 0,829$$

EJERCICIOS PROPUESTOS

1.8. En la sección 1.8 se demostró que dados 2 sucesos A y B en el espacio muestral S, $P(A \cup B) = P(A) + P(B) - P(A \cap B)$. Dados tres sucesos A, B y C en el espacio muestral S, calcular: $P(A \cup B \cup C)$.

1.9. Dados 3 sucesos A, B y C en el espacio muestral S, tales que

$$P(A) = 1/2; \quad P(B) = 14/25; \quad P(C) = 9/25; \quad P(A \cap B) = 3/10$$

$P(A \cap C) = P(B \cap C) = 4/25; \quad P(A \cap B \cap C) = 1/50$. Calcular las siguientes probabilidades:

- i) Que ninguno de los tres sucesos ocurra; ii) Que ocurra exactamente uno de los sucesos; iii) Que ocurran exactamente dos de los sucesos; iv) Que ocurran exactamente los tres sucesos.

1.10. Dados los sucesos del ejercicio anterior con sus correspondientes probabilidades. Calcular las siguientes probabilidades: i) Que ocurran al menos cero sucesos; ii) Que ocurra al menos 1 suceso; iii) Que ocurran al menos 2 sucesos; iv) Que ocurran al menos 3 sucesos.

1.11. Con los datos del ejercicio 1.9, calcular las siguientes probabilidades: i) Que no ocurran más de cero sucesos; ii) Que no ocurra más de un suceso; iii) Que no ocurran más de 2 sucesos; iv) Que no ocurran más de 3 sucesos.

1.12. Sean A y B 2 sucesos independientes en el espacio muestral S tales que $P(A) = 1/2, \quad P(B) = 1/3$. Calcular $P(A \cap \bar{B}) - P(\bar{A} \cap B)$.

1.13. Sean A, B y C sucesos exhaustivos ² y mutuamente excluyentes en el espacio muestral S. Siendo $P(\bar{A}) = 2/3$ y $P(\bar{B}) = 1/2$

Calcular la probabilidad de que no se dé el suceso C.

1.14. Con los datos del ejercicio 1.3, calcular la probabilidad de que no se dé el suceso A, dado el suceso C.

1.15. Supongamos que un espacio muestral tiene 42 puntos muestrales, cada uno con idéntica probabilidad. El suceso A contiene 15 puntos muestrales y el suceso B tiene 10 puntos muestrales; A y B tienen en común 4 puntos muestrales. Calcular la probabilidad de que se den los siguientes sucesos, y explicar el significado de cada uno de ellos.

$$i) \bar{A} \cap \bar{B}; \quad ii) A \cup \bar{B}; \quad iii) \bar{A} \cap \bar{B}; \quad iv) A \cap \bar{B}; \quad v) \bar{A} \cup \bar{B}; \quad vi) B \cap \bar{A}.$$

En los ejercicios del 1.16 al 1.25, establezca el espacio muestral S, así como los sucesos correspondientes.

1.16. Consideren el experimento del ejercicio 1.4. Sea x el resultado del primer dado. Sea y el resultado del segundo dado. Sea A el suceso de que $x - y = 0$. Sea B el suceso de que $x + y$ es un número par. Calcular: i) $P(A \cap B)$; ii) $P(A/B)$.

1.17. En una caja hay 100 fichas numeradas del 1 al 100. ¿Cuál es la probabilidad de que al extraer una ficha, su número sea múltiplo de 9?

² Sucesos exhaustivos son aquellos cuya reunión es el espacio muestral.

1.18. Calcular las probabilidades pedidas en el ejercicio 1.5, en el caso de que las fichas sean extraídas sin reemplazamiento (No se devuelven a la caja).

1.19. En un edificio viven 12 familias, de las cuales 3 tienen ingresos diarios mayores que Bs. 3.000, 4 tienen ingresos entre Bs. 1.500 y Bs. 3.000 y 5 con ingresos menores que Bs. 1.500. En el edificio vecino viven 18 familias, 5 con ingresos mayores que Bs. 3.000, 6 con ingresos entre Bs. 1.500 y Bs. 3.000 y 7 con ingresos menores que Bs. 1.500. Si se escogen 2 familias aleatoriamente, una de cada edificio. ¿Cuál es la probabilidad: i) de que ambas familias tengan ingresos entre Bs. 1.500 y Bs. 3.000, ii) de que ambas estén en el mismo intervalo de ingresos?

1.20. Considere el experimento de lanzar dos dados bien balanceados. ¿Cuál es la probabilidad de que la suma de los dados sea 5, dado que: i) la suma fue un número impar, ii) la suma fue mayor que 4, iii) el resultado del primer dado fue par?

1.21. En el ejercicio anterior: ¿Cuál es la probabilidad de que la suma de los dados sea 7, dado que: i) el resultado del segundo dado fue impar, ii) el resultado de al menos un dado fue impar, iii) el resultado de los dados fue el mismo, iv) el resultado de los dos dados fue diferente?

1.22. Durante 5 días de trabajo la semana pasada en una industria, han ocurrido los siguientes accidentes, distribuidos por departamento y por día según la tabla:

Dpto. \ Día	Lunes	Martes	Miércoles	Jueves	Viernes
A	32	21	23	29	35
B	14	10	11	10	15
C	12	12	13	11	11
D	24	22	23	21	22

El médico de la empresa recibe a uno de los accidentados. Estime la probabilidad de que el accidente haya ocurrido: i) en el departamento A el lunes; en el departamento B el viernes. ii) Ocurrido en el departamento C; ocurrido en el departamento B. iii) Ocurrido en el departamento A, dado que ocurrió el lunes; en el departamento A, dado que ocurrió el miércoles.

1.23. Tres amigos van a cenar a un restaurant, y proponen jugar quien va a pagar, de acuerdo con las siguientes reglas: Cada uno escribe un número entre cero y tres. El que acierte la suma de los tres números sale del juego. Uno de ellos elige el número

3, y trata de adivinar la suma de los otros dos números. Si designamos por k la suma de los tres números, calcular la probabilidad de que se dé cada uno de los posibles valores de k .

1.24. Un experimento consiste en lanzar 5 monedas bien balanceadas. Sabiendo que aparecieron al menos dos caras, calcular la probabilidad de que el número de caras fue exactamente tres.

1.25. Una compañía petrolera tiene actualmente 15 concesiones que debe explotar o renunciar a ellas. La empresa tiene recursos disponibles para explotar sólo cinco de las concesiones. Los estudios geológicos han indicado que las posibilidades de existencia de petróleo son iguales para cada concesión, de manera que se decide escoger aleatoriamente cinco de las quince concesiones. Si de hecho seis de los campos contienen petróleo económicamente explotable. ¿Cuál es la probabilidad de que todos los campos escogidos tengan petróleo?

1.26. En el ejercicio anterior, ¿cuál es la probabilidad de que por lo menos dos campos escogidos tengan petróleo?

1.27. En una materia del segundo año de Economía, el 10% de los estudiantes fue reprobado únicamente en el primer parcial; el 8% fue reprobado únicamente en el segundo parcial; y el 5% fue reprobado en ambos parciales. ¿Cuál es la probabilidad de que i) un estudiante que pasó el primer parcial, haya sido reprobado en el segundo; ii) un estudiante reprobado en el primero, haya sido reprobado en el segundo; iii) un estudiante reprobado en el segundo, hubiera sido reprobado en el primero?

1.28. De los 300 estudiantes que aprobaron el examen de admisión de la Escuela de Economía en un año determinado, el 50% habían nacido en Caracas, el 30% en el interior, y el 20% en el extranjero. De los estudiantes nacidos en Caracas, el 60% eran graduados en liceos públicos; de los nacidos en el interior el 30% y de los nacidos en el extranjero el 50%. Si se elige al azar un estudiante y éste resultó ser un egresado de liceo público. ¿Cuál es la probabilidad de que haya nacido en el interior?

1.29. En una partida de dominó ¿Cuál es la probabilidad de que el primer jugador que escoge las 7 fichas de las 28: i) tenga 7 blancas; ii) tenga 4 cincos; iii) 4 fichas de la misma pinta?

1.30. Dados los números 0, 1, 2, 3, 4. ¿Cuál es la probabilidad de que un número de cinco cifras formado al azar con las cifras dadas, empiece por uno? (Sin que se repitan)

Nota: Los números que comiencen por cero no se consideran de cinco cifras.

1.31. En una oficina hay seis secretarias para mecanografiar los trabajos que realizan cuatro supervisores. Cada secretaria tiene la misma probabilidad de recibir un trabajo por parte de un supervisor, (los trabajos son entregados aleatoriamente). Un día determinado cada supervisor tiene un trabajo para mecanografiar. ¿Cuál es la probabilidad que: i) los cuatro trabajos se le entregan a la misma secretaria; ii) ninguna secretaria reciba más de un trabajo?

1.32. Una empresa necesita cubrir cuatro vacantes, y tiene 10 aspirantes, de los cuales cuatro son competentes y 6 incompetentes. El proceso de selección consiste en un examen a los aspirantes uno por uno, hasta seleccionar los cuatro empleados. ¿Cuál es la probabilidad de que el cuarto empleado seleccionado sea el quinto aspirante examinado?

Nota: Se supone que los candidatos competentes aprueban el examen, y los incompetentes no.

1.33. Una compañía está pensando lanzar al mercado un nuevo producto. Se estima que la probabilidad de que el producto tenga éxito es 0,7, si la propaganda está bien orientada; si la propaganda no está bien orientada, la probabilidad de éxito se estima en 0,2. Por experiencia basada en similares productos se sabe que la propaganda está bien orientada en un 60% de los casos. ¿Cuál es la probabilidad de que el producto tenga éxito?

1.34. En el ejercicio anterior, si el producto al ser lanzado tuvo éxito, ¿cuál es la probabilidad de que la propaganda haya sido bien orientada?

1.35. En una caja hay 15 fichas, 8 blancas y 7 verdes. Al extraer 5 fichas con reemplazamiento, ¿son independientes el suceso de que la primera ficha sea blanca y el suceso de que la quinta ficha sea blanca?

1.36. En el ejercicio anterior, si las fichas se extraen sin reemplazamiento. ¿Son independientes los sucesos?

1.37. Una caja contiene 4 fichas, 1 blanca y 3 rojas. Una segunda caja contiene 6 fichas, 2 blancas y 4 rojas. Una tercera caja contiene 5 fichas, 2 blancas y 3 rojas. Una ficha es extraída de cada caja. ¿Cuál es la probabilidad de que de las tres fichas; i) exactamente una sea blanca; ii) al menos dos fichas sean rojas; iii) haya más fichas rojas que blancas?

1.38. En el departamento de control de calidad de una industria se inspecciona la producción diaria con dos chequeos realizados por dos personas diferentes de la siguiente forma: En el primer chequeo se inspecciona una unidad al azar; si la unidad es defectuosa se desecha, si está buena se devuelve al lote de producción; las mismas unidades que fueron objeto de la primera inspección son chequeadas posteriormente, inspeccionando una unidad al azar. Si en un día se han producido

8 unidades, de las cuales 3 son defectuosas. ¿Cuál es la probabilidad de que: i) la unidad inspeccionada en el primer chequeo sea defectuosa; ii) la unidad inspeccionada en el segundo chequeo sea defectuosa; iii) la unidad inspeccionada en el segundo chequeo sea defectuosa, dado que la unidad inspeccionada en el primero fue defectuosa; iv) la unidad inspeccionada en el primer chequeo haya sido defectuosa, dado que la unidad inspeccionada en el segundo fue defectuosa?; v) ¿son independientes el suceso de que la unidad chequeada en el primer chequeo sea defectuosa y el suceso de que la unidad inspeccionada en el segundo chequeo sea defectuosa?

1.39. En la caja N° 1 de un Banco, el cajero tiene 12 billetes de Bs. 500, de los cuales 4 son falsos. En la caja N° 2, el cajero tiene 7 billetes de Bs. 500, de los cuales 3 son falsos. El cajero N° 1 necesita billetes de Bs. 50 y le pide al cajero N° 2 que le cambie 2 billetes de Bs. 500 en billetes de Bs. 50. Posteriormente un cliente solicita al cajero N° 2 dos billetes de Bs. 500. Si se supone que en todos los casos los billetes son escogidos aleatoriamente. ¿Cuál es la probabilidad de que entre los billetes entregados al cliente haya exactamente uno falso?

1.40. En un comercio se venden dos artículos identificados como artículo A y artículo B. La probabilidad de que simultáneamente se demanden en un día una o más unidades del artículo A, y una o más unidades del artículo B, es $1/6$. Por otro lado, la probabilidad de que no se demande ninguno de los artículos es $1/3$. Si las demandas de ambos artículos son estadísticamente independientes, calcular la probabilidad de que se demanden: i) una o más unidades del artículo A; ii) una o más unidades del artículo B.

1.41. En el ejercicio anterior suponga que la probabilidad de que simultáneamente se demanden una o más unidades del artículo A y una o más unidades del artículo B, es $1/6$; y que la probabilidad de que se demanden una o más unidades del artículo A y no se demanden unidades del artículo B, es $1/3$. Calcular la probabilidad de que: i) se demanden una o más unidades del artículo A; ii) se demanden una o más unidades del artículo B.

1.42. Una casa fabricante de pulidoras está ofreciendo su producto a una gran tienda por departamentos. En ésta se suelen clasificar los productos en tres categorías: Calidad Superior, Calidad Media y Calidad Inferior. Para clasificarlos se escogen aleatoriamente 6 unidades de un lote de 50, y se inspeccionan minuciosamente. Si ninguna de las 6 unidades resulta defectuosa, el producto se clasifica como calidad superior; si hay 1 ó 2 defectuosas, de calidad media; y si hay más de 2 defectuosas, de calidad inferior. Si en el lote de 50 pulidoras hay 8 defectuosas. ¿Cuál es la probabilidad de que el producto sea clasificado en cada una de las tres calidades?

1.43. Una enciclopedia tiene 6 tomos. Si éstos se colocan al azar en una biblioteca. ¿Cuál es la probabilidad de que queden colocados en el orden correcto?

1.44. Determine razonadamente la veracidad o falsedad de las siguientes afirmaciones:

- a) Dados tres sucesos A, B y C en el espacio muestral S, si se cumple que A y B son independientes y B y C son independientes, se puede concluir que A y C son independientes.
- b) Dados dos sucesos A y B en el espacio muestral S tales que sus probabilidades simples son iguales, se puede concluir que sus probabilidades condicionales de uno de ellos dado el otro también son iguales.
- c) Sean A y B dos sucesos en el espacio muestral S, mutuamente excluyentes y no exhaustivos. Si $P(A) = 0,6$, entonces $P(B) < 0,4$.

1.45. Determine razonadamente cuál de las respuestas es correcta en:

La suma de las probabilidades de dos sucesos A y B es igual a su probabilidad suma, siempre que los sucesos:

- a) Sean independientes.
- b) Sean mutuamente excluyentes.
- c) No sean independientes.
- d) No sean mutuamente excluyentes.
- e) Ninguna de las anteriores.

Dados dos sucesos A y B en el espacio muestral S, se cumple que $P(A/B) = P(A) / P(B)$ si:

- a) $A \subset B$.
- b) $B \subset A$.
- c) $A = B$.
- d) Más de alguna es correcta.
- e) Ninguna de las anteriores.

CAPITULO II

VARIABLES ALEATORIAS Y FUNCION DE PROBABILIDADES

2.1. VARIABLES ALEATORIAS

Supongamos que se realiza el experimento de lanzar al aire 2 monedas. Sabemos que el espacio muestral de este experimento contiene 4 puntos muestrales.

$$S = \{s_1 = (c, c), s_2 = (c, s), s_3 = (s, c), s_4 = (s, s)\}$$

donde el primer elemento de cada par indica si se obtuvo cara (c) o sello (s) en la primera moneda, y el segundo lo mismo con respecto a la segunda moneda. La probabilidad de cada punto muestral es entonces $1/4$. Ahora bien, normalmente nosotros no estaremos interesados en los puntos muestrales, sino en alguna magnitud asociada con los puntos muestrales. P. ej. podríamos estar interesados en el número de caras que hay en cada punto muestral. Si definimos una variable x_i como el número de caras en el punto muestral s_i , x_i tomará los valores $x_1 = 2, x_2 = 1, x_3 = 1, x_4 = 0$: Pues bien, x_i es una variable aleatoria.

DEFINICION 2.1.

Una variable x es una variable aleatoria si es una magnitud susceptible de tomar diversos valores con determinadas probabilidades.


En el ejemplo (eliminando el subíndice) $x = 0$ con probabilidad $1/4$, $x = 1$ con probabilidad $1/2$, $x = 2$ con probabilidad $1/4$ y escribiremos,

$P(x = 0)$ [Léase probabilidad de que la variable aleatoria x sea igual a cero] = $1/4$;

$$P(x = 1) = \frac{1}{2}; \quad P(x = 2) = \frac{1}{4}$$

Otra definición mas precisa de variable aleatoria sería la siguiente: Sea S un espacio muestral; sea x una función real definida en S (es decir x transforma los puntos muestrales de S en puntos en el eje de abscisas). Entonces x es llamada una variable aleatoria.

(Véase diagrama con referencia al ejemplo anterior).



Una variable aleatoria es discreta cuando únicamente puede tomar un determinado número de valores en un intervalo. Por ejemplo, la variable aleatoria número de caras obtenidas al lanzar 2 monedas, es una variable aleatoria discreta en el intervalo $(0,2)$. Sólo puede tomar los valores 0, 1 y 2.

Una variable aleatoria es continua cuando puede tomar cualquier valor en un intervalo. Supongamos el experimento de lanzar una moneda hacia una línea marcada en el suelo. Supongamos que la distancia máxima a que puede caer la moneda de la raya es 1 metro (entendiendo como distancia la del centro de la moneda a la línea). Si definimos una variable aleatoria x que represente esa distancia, x puede tomar cualquier valor en el intervalo $[0,1]$.

2.2. FUNCION DE PROBABILIDADES

DEFINICION 2.2.

Una función de probabilidad es aquella función $f(x)$ que mide la probabilidad de que la variable aleatoria x tome determinados valores.

Cuando la variable aleatoria es discreta, la función de probabilidad toma el nombre de función de probabilidad masa; si la variable aleatoria es continua toma el nombre de función de densidad. Nosotros no haremos distinción, y en ambos casos le llamaremos **función de densidad**.

EJEMPLO 2.1.

Si lanzamos 2 dados bien balanceados, y definimos la variable aleatoria x como la suma de los 2 resultados, los posibles valores de x con sus respectivas probabilidades serán:

$f(x)$	1/36	2/36	3/36	4/36	5/36	6/36	5/36	4/36	3/36	2/36	1/36
x	2	3	4	5	6	7	8	9	10	11	12

Una función matemática de la variable aleatoria x_i puede ser considerada una función de densidad, si cumple las siguientes condiciones:

a) Si x_i es una variable discreta,

$$f(x_i) \geq 0 \quad \forall i \quad y \quad \sum_i f(x_i) = 1$$

b) Si x_i es una variable continua,

$$f(x_i) \geq 0 \quad \forall i \quad y \quad \int_{-\infty}^{+\infty} f(x_i) dx_i = 1$$

EJEMPLO 2.2.

Consideren la siguiente función de x ;

$$f(x) = \begin{cases} \frac{3}{8}(4x - 2x^2) & \text{para } 0 \leq x \leq 2 \\ 0 & \text{para cualquier otro valor de } x. \end{cases}$$

¿Es $f(x)$ una función de densidad?

$f(x) \geq 0$ para cualquier valor de x

$$\int_{-\infty}^{+\infty} f(x) dx = \int_{-\infty}^0 f(x) dx + \int_0^2 f(x) dx + \int_2^{+\infty} f(x) dx =$$

$$= \int_0^2 \frac{3}{8}(4x - 2x^2) dx = \frac{3}{8} \left(2x^2 - \frac{2x^3}{3} \right) \Bigg|_0^2 = 1$$

Luego $f(x) = 3/8 (4x - 2x^2)$ es una función de densidad de la variable aleatoria x .

EJEMPLO 2.3.

Consideren la siguiente función de x

$$f(x) = \begin{cases} \frac{2}{3} \left(\frac{1}{3}\right)^{x-1} & \text{para } x = 1, 2, 3, 4, \dots \\ 0 & \text{para cualquier otro valor de } x \end{cases}$$

¿Es $f(x)$ una función de densidad?

$f(x) \geq 0$ para cualquier valor de x

$$\begin{aligned} \sum_{x=1}^{\infty} f(x) &= \sum_{x=1}^{\infty} \frac{2}{3} \left(\frac{1}{3}\right)^{x-1} = \frac{2}{3} \sum_{x=1}^{\infty} \left(\frac{1}{3}\right)^{x-1} = \frac{2}{3} \left[1 + \frac{1}{3} + \left(\frac{1}{3}\right)^2 + \left(\frac{1}{3}\right)^3 + \dots \right] = \\ &= \frac{2}{3} \frac{1}{1 - \frac{1}{3}} = 1 \end{aligned}$$

La función de densidad nos mide la probabilidad de que la variable x tome un determinado valor (veremos que no es este el caso cuando la variable es continua). Muchas veces nos interesa la probabilidad de que la variable aleatoria x sea menor o igual a un número dado. Para contestar este tipo de preguntas, se introduce el concepto de función de distribución o función de distribución acumulativa.

2.3. FUNCION DE DISTRIBUCION**DEFINICION 2.3.**

Se entiende por función de distribución aquella función $F(x)$ de la variable aleatoria que mide la probabilidad de que la variable x sea menor o igual a un número dado h .

En el caso de que la variable aleatoria x sea discreta:

$$F(h) = P(x \leq h) = \sum_{x \leq h} f(x)$$

Si x es continua:

$$F(h) = P(x \leq h) = \int_{-\infty}^h f(x) dx$$

EJEMPLO 2.4.

Se desea saber cual es la función de densidad y de distribución de una variable aleatoria x que represente el número de caras obtenidas al lanzar 4 monedas.

La variable aleatoria x puede tomar los valores 0, 1, 2, 3, 4. El número de puntos muestrales de este experimento es obviamente 2^4 ; mientras que el número de puntos muestrales que contienen x caras es igual a las permutaciones con repetición de 4 elementos donde hay x elementos iguales y $4-x$ elementos iguales, luego:

$$f(x) = \frac{\binom{4}{x}}{2^4} \quad x = 0, 1, 2, 3, 4,$$

$$P(x = 0) = f(0) = \frac{\binom{4}{0}}{2^4}; \quad P(x = 1) = f(1) = \frac{\binom{4}{1}}{2^4};$$

$$P(x = 2) = f(2) = \frac{\binom{4}{2}}{2^4}; \quad P(x = 3) = f(3) = \frac{\binom{4}{3}}{2^4};$$

$$P(x = 4) = f(4) = \frac{\binom{4}{4}}{2^4};$$

x	$f(x)$	$F(x)$
0	1/16	1/16
1	4/16	5/16
2	6/16	11/16
3	4/16	15/16
4	1/16	16/16

EJEMPLO 2.5.

Calcular la función de distribución del ejemplo 2.2.

$$\text{Para } x < 0; F(x) = \int_{-\infty}^x f(x) dx = 0$$

$$\text{Para } 0 \leq x \leq 2; F(x) = \int_0^x f(x) dx = \int_0^x \frac{3}{8}(4x - 2x^2) dx = \frac{3}{4}x^2 - \frac{1}{4}x^3$$

$$\text{Para } x > 2; f(x) = \int_0^2 f(x) dx + \int_2^x f(x) dx = \frac{3}{4}x^2 - \frac{1}{4}x^3 \Big|_0^2 = 1$$

Entonces la función de distribución será

$$F(x) = \begin{cases} 0 & \text{Para } x < 0 \\ \frac{3}{4}x^2 - \frac{1}{4}x^3 & \text{Para } 0 \leq x \leq 2 \\ 1 & \text{Para } x > 2 \end{cases}$$

Cómputo de probabilidades a partir de las funciones de densidad o de distribución.

Primer Caso: Variable Aleatoria Discreta.

$$P(x = h) = f(h)$$

$$P(x \leq h) = \sum_{x \leq h} f(x) = F(h)$$

$$P(x < h) = \sum_{x < h} f(x) = F(h) - f(h)$$

$$P(x > h) = \sum_{x > h} f(x) = 1 - \sum_{x \leq h} f(x) = 1 - F(h)$$

$$P(x \geq h) = \sum_{x \geq h} f(x) = 1 - \sum_{x < h} f(x) = 1 - F(h) + f(h)$$

$$P(a < x \leq b) = \sum_{x \leq b} f(x) - \sum_{x \leq a} f(x) = F(b) - F(a)$$

$$P(a \leq x \leq b) = \sum_{x \leq b} f(x) - \sum_{x < a} f(x) + f(a) = F(b) - F(a) + f(a)$$

$$P(a \leq x < b) = \sum_{x \leq b} f(x) - f(b) - \sum_{x < a} f(x) + f(a) = F(b) - F(a) + f(a) - f(b)$$

$$P(a < x < b) = \sum_{x \leq b} f(x) - f(b) - \sum_{x \leq a} f(x) = F(b) - F(a) - f(b)$$

Segundo Caso: Variable Aleatoria Continua

$$P(x \leq h) = F(h) = \int_{-\infty}^h f(x) dx$$

$$P(x \geq h) = \int_h^{+\infty} f(x) dx = 1 - \int_{-\infty}^h f(x) dx = 1 - F(h)$$

$$P(a \leq x \leq b) = P(x \leq b) - P(x \leq a) = \int_{-\infty}^b f(x) dx - \int_{-\infty}^a f(x) dx = F(b) - F(a)$$

Se debe observar que la probabilidad de que una variable aleatoria continua tome un valor determinado es siempre cero; es decir, $P(x=h) \neq f(h)$ sino que $P(x=h) = 0 \forall h$.

Esto puede parecer paradójico, pero la razón es la siguiente:

$$P(h \leq x \leq h + \Delta_x) = \int_h^{h+\Delta_x} f(x) dx$$

Ahora bien, aplicando el teorema del valor medio

$$\int_h^{h+\Delta_x} f(x) dx = \Delta_x f(h + \theta \Delta_x) \quad 0 < \theta < 1$$

$$P(x = h) = \lim_{\Delta_x \rightarrow 0} \int_h^{h+\Delta_x} f(x) dx = \lim_{\Delta_x \rightarrow 0} \Delta_x f(h + \theta \Delta_x) = 0$$

de forma que la probabilidad de que una variable aleatoria continua tome un valor determinado, es siempre igual a cero. Basándonos en este hecho, se tiene:

$$P(x < b) = P(x \leq b) = F(b)$$

$$P(x > b) = P(x \geq b) = 1 - F(b)$$

$$P(a < x < b) = P(a \leq x < b) = P(a < x \leq b) = P(a \leq x \leq b) = F(b) - F(a)$$

EJEMPLO 2.6.

Calcular las siguientes probabilidades en el ejemplo 2.1. $P(x=5)$; $P(x \leq 7)$; $P(x < 7)$; $P(x \geq 8)$; $P(x > 8)$; $P(3 < x \leq 6)$; $P(3 \leq x \leq 6)$; $P(3 \leq x < 6)$; $P(3 < x < 6)$.

x	f(x)	F(x)
2	1/36	1/36
3	2/36	3/36
4	3/36	6/36
5	4/36	10/36
6	5/36	15/36
7	6/36	21/36
8	5/36	26/36
9	4/36	30/36
10	3/36	33/36
11	2/36	35/36
12	1/36	36/36

$$P(x=5) = f(5) = \frac{4}{36}; \quad P(x \leq 7) = F(7) = \frac{21}{36}$$

$$P(x < 7) = F(7) - f(7) = \frac{21}{36} - \frac{6}{36} = \frac{15}{36}$$

$$P(x \geq 8) = 1 - F(8) + f(8) = 1 - \frac{26}{36} + \frac{5}{36} = \frac{15}{36}$$

$$P(x > 8) = 1 - F(8) = \frac{10}{36}$$

$$P(3 < x \leq 6) = F(6) - F(3) = \frac{15}{36} - \frac{3}{36} = \frac{12}{36}$$

$$P(3 \leq x \leq 6) = F(6) - F(3) + f(3) = \frac{12}{36} + \frac{2}{36} = \frac{14}{36}$$

$$P(3 \leq x < 6) = F(6) - F(3) + f(3) - f(6) = \frac{12}{36} + \frac{2}{36} - \frac{5}{36} = \frac{9}{36}$$

$$P(3 < x < 6) = F(6) - F(3) - f(6) = \frac{12}{36} - \frac{5}{36} = \frac{7}{36}$$

EJEMPLO 2.7.

Calcular las siguientes probabilidades en el ejemplo 2.2.

i) $P(x=1)$; ii) $P(0,5 < x < 1,75)$; iii) $P(x < 1,5)$; iv) $P(x > 1)$; v) $P(1 < x < 4)$.

$$i) P(x=1) = 0$$

$$ii) P(0,5 < x < 1,75) = \int_{0,5}^{1,75} f(x) dx = F(1,75) - F(0,5) = \frac{3}{4}(1,75)^2 - \frac{1}{4}(1,75)^3 - \left[\frac{3}{4}(0,5)^2 - \frac{1}{4}(0,5)^3 \right] = 0,96 - 0,16 = 0,80$$

$$iii) P(x < 1,5) = \int_0^{1,5} f(x) dx = F(1,5) = \frac{3}{4}(1,5)^2 - \frac{1}{4}(1,5)^3 = 0,84$$

$$iv) P(x > 1) = \int_1^2 f(x) dx = F(2) - F(1) = 1 - \left(\frac{3}{4} - \frac{1}{4} \right) = \frac{1}{2}$$

$$v) P(1 < x < 4) = \int_1^4 f(x) dx = F(4) - F(1) = 1 - \left(\frac{3}{4} - \frac{1}{4} \right) = \frac{1}{2}$$

2.4. VALOR ESPERADO DE UNA VARIABLE ALEATORIA**DEFINICION 2.4.**

El valor esperado o esperanza matemática de una variable aleatoria puede ser definido de la siguiente forma: Sea x una variable aleatoria con función densidad $f(x)$; el valor esperado, que representaremos por $E(x)$, es

$$E(x) = \sum_x x f(x) \quad \text{si la } x \text{ es discreta;}$$

$$E(x) = \int_{-\infty}^{+\infty} x f(x) dx \quad \text{si la } x \text{ es continua.}$$

El valor esperado o esperanza matemática de x se conoce también como media ponderada de x , siendo las ponderaciones las probabilidades; y nosotros usaremos los 3 términos indiferentemente.

EJEMPLO 2.8.

En el ejemplo 2.1.

$$E(x) = \sum_x x f(x) = 2 \frac{1}{36} + 3 \frac{2}{36} + 4 \frac{3}{36} + 5 \frac{4}{36} + 6 \frac{5}{36} + 7 \frac{6}{36} + 8 \frac{5}{36} + 9 \frac{4}{36} + 10 \frac{3}{36} + 11 \frac{2}{36} + 12 \frac{1}{36} = \frac{252}{36} = 7$$

EJEMPLO 2.9.

En el ejemplo 2.2.

$$E(x) = \int_{-\infty}^{+\infty} x f(x) dx = \int_0^2 x \left[\frac{3}{8} (4x - 2x^2) \right] dx = \frac{6}{8} \int_0^2 (2x^2 - x^3) dx = \frac{6}{8} \left(\frac{2x^3}{3} - \frac{x^4}{4} \right) \Big|_0^2 = \frac{6}{8} \left(\frac{2 \cdot 2^3}{3} - \frac{2^4}{4} \right) = 1$$

Propiedades del valor esperado de una variable aleatoria.

- 1) Si x es una variable aleatoria y $g(x)$ es una función de x , entonces el valor esperado de $g(x)$ es

$$\sum_x g(x) f(x) \text{ si es discreta; y } \int_{-\infty}^{+\infty} g(x) f(x), \text{ si es continua}$$

$$E[g(x)] = \sum_x g(x) f(x)$$

$$E[g(x)] = \int_{-\infty}^{+\infty} g(x) f(x) dx$$

Al ser x una variable aleatoria, $g(x)$ como función de x es también aleatoria, $g(x)$ toma valores al tomar valores x , y las probabilidades corresponden a las probabilidades de x . Es decir si $x = x_0$ con probabilidad $f(x_0)$, implica que $g(x) = g(x_0)$ con probabilidad $f(x_0)$.

EJEMPLO 2.10.

Supongamos la variable aleatoria x con la siguiente función de densidad.

$f(x)$	1/9	2/9	3/9	2/9	1/9
x	0	1	2	3	4

Definamos una función de x ; $g(x) = 3x^2 - 2$; puesto que $x = 0, 1, 2, 3, 4$, $g(x) = -2, 1, 10, 25, 46$. Las respectivas probabilidades serían:

$f(x)$	1/9	2/9	3/9	2/9	1/9
x	0	1	2	3	4
$g(x)$	-2	1	10	25	46

$$E[g(x)] = -2 \frac{1}{9} + 1 \frac{2}{9} + 10 \frac{3}{9} + 25 \frac{2}{9} + 46 \frac{1}{9} = \sum_x g(x) f(x) = \frac{126}{9}$$

- 2) $E(c) = c$, donde c es una constante. Este es un caso particular del anterior. Si hacemos $c = g(x)$

$$E(c) = \sum_x c f(x) = c \sum_x f(x) = c \cdot 1 = c$$

- 3) $E[c \cdot g(x)] = c E[g(x)]$, donde c es una constante y $g(x)$ una función de x ; $cg(x)$ es a su vez una función de x , digamos $h(x) = cg(x)$. Si x es una variable aleatoria discreta tendremos:

$$E[cg(x)] = E[h(x)] = \sum_x h(x) f(x) = \sum_x cg(x) f(x) = c \sum_x g(x) f(x) = c E[g(x)]$$

Si x es una variable aleatoria continua, tendremos:

$$E[cg(x)] = E[h(x)] = \int_{-\infty}^{+\infty} h(x)f(x)dx = \int_{-\infty}^{+\infty} cg(x)f(x)dx =$$

$$= c \int_{-\infty}^{+\infty} g(x)f(x)dx = cE[g(x)]$$

4) $E[g_1(x) + g_2(x) + \dots + g_n(x)] = E[g_1(x)] + E[g_2(x)] + \dots + E[g_n(x)]$,
donde $g_i(x)$ es una función de x .

Es decir, el valor esperado de una suma de funciones de x es igual a la suma de los valores esperados.

Si x es una variable aleatoria discreta.

$$E[g_1(x) + g_2(x) + \dots + g_n(x)] = \sum_x [g_1(x) + g_2(x) + \dots + g_n(x)]f(x) =$$

$$= \sum_x [g_1(x)f(x) + g_2(x)f(x) + \dots + g_n(x)f(x)] =$$

$$= \sum_x g_1(x)f(x) + \sum_x g_2(x)f(x) + \dots + \sum_x g_n(x)f(x) =$$

$$= E[g_1(x)] + E[g_2(x)] + \dots + E[g_n(x)]$$

Se deja a cargo del lector la demostración en el caso de que x sea continua.

EJEMPLO 2.11.

Sea x una variable aleatoria con la siguiente función de densidad.

$f(x)$	1/36	2/36	3/36	4/36	5/36	6/36	5/36	4/36	3/36	2/36	1/36
x	2	3	4	5	6	7	8	9	10	11	12

Sabemos que x representa la suma de los resultados de 2 dados. Calcular el valor esperado del cuadrado de la suma de los dados multiplicado por 5, menos la suma multiplicada por 3.

$$g(x) = 5x^2 - 3x$$

$$E[g(x)] = E[5x^2 - 3x] = 5E[x^2] - 3E[x] =$$

$$= 5 \left(2^2 \frac{1}{36} + 3^2 \frac{2}{36} + 4^2 \frac{3}{36} + 5^2 \frac{4}{36} + 6^2 \frac{5}{36} + 7^2 \frac{6}{36} + 8^2 \frac{5}{36} + \right.$$

$$\left. + 9^2 \frac{4}{36} + 10^2 \frac{3}{36} + 11^2 \frac{2}{36} + 12^2 \frac{1}{36} \right) - 3 \cdot 7 =$$

$$= 5 \frac{1,974}{36} - 21 = \frac{2,171}{9} = 253,16$$

2.5. VARIANZA DE UNA VARIABLE ALEATORIA

La varianza de una variable x es una magnitud que mide la dispersión de los valores de x alrededor de su media, y se representa por σ_x^2 o $\text{Var}(x)$.

DEFINICION 2.5.

La varianza de una variable aleatoria x con función de densidad $f(x)$ es la esperanza matemática del cuadrado de las diferencias entre los valores de x y su valor esperado, es decir: $E[x - E(x)]^2$

$$\sigma_x^2 = \text{Var}(x) = \sum_x [x - E(x)]^2 f(x) \quad \text{si } x \text{ es discreta}$$

$$= \int_{-\infty}^{+\infty} [x - E(x)]^2 f(x) dx \quad \text{si } x \text{ es continua}$$

En ambos casos podremos escribir:

$$\sigma_x^2 = \text{Var}(x) = E[x - E(x)]^2 = E\{x^2 - 2xE(x) + [E(x)]^2\} =$$

$$= E(x^2) - 2E(x)E(x) + [E(x)]^2 = E(x^2) - [E(x)]^2$$

o sea que la varianza de una variable aleatoria x es igual al valor esperado del cuadrado de la variable, menos el cuadrado de su valor esperado. El valor positivo de la raíz cuadrada de la varianza es la desviación típica (σ_x).

EJEMPLO 2.12.

La varianza de la variable aleatoria definida en el ejemplo 2.11 será:

$$\text{Var}(x) = E(x^2) - [E(x)]^2$$

$$E(x^2) = 4 \frac{1}{36} + 9 \frac{2}{36} + 16 \frac{3}{36} + 25 \frac{4}{36} + 36 \frac{5}{36} + 49 \frac{6}{36} + 64 \frac{5}{36} +$$

$$+ 81 \frac{4}{36} + 100 \frac{3}{36} + 121 \frac{2}{36} + 144 \frac{1}{36} = \frac{1.974}{36}$$

$$E(x) = 7 \quad \text{luego} \quad \text{Var}(x) = \frac{1.974}{36} - 49 = 5,83$$

Propiedades de la Varianza

- 1) $\text{Var}(c) = 0$ donde c es una constante, porque

$$\text{Var}(c) = E(c^2) - [E(c)]^2 = c^2 - c^2 = 0$$

- 2) $\text{Var}(cx) = c^2 \text{Var}(x)$, donde c es una constante; en efecto.

$$\begin{aligned} \text{Var}(cx) &= E[(cx)^2] - [E(cx)]^2 = c^2 E(x^2) - [cE(x)]^2 = \\ &= c^2 E(x^2) - c^2 [E(x)]^2 = c^2 \{E(x^2) - [E(x)]^2\} = c^2 \text{Var}(x), \end{aligned}$$

- 3) $\text{Var}(cx + b) = c^2 \text{Var}(x)$ donde c y b son constantes, en efecto:

$$\begin{aligned} \text{Var}(cx + b) &= E[(cx + b)^2] - [E(cx + b)]^2 = \\ &= E[c^2x^2 + 2bcx + b^2] - [cE(x) + b]^2 = \\ &= c^2E(x^2) + 2bcE(x) + b^2 - \{c^2[E(x)]^2 + 2bcE(x) + b^2\} = \\ &= c^2E(x^2) - c^2[E(x)]^2 = c^2 \{E(x^2) - [E(x)]^2\} = c^2 \text{Var}(x) \end{aligned}$$

- 4) La varianza es siempre mayor o igual que cero, pues es la suma de cantidades no negativas.

EJEMPLO 2.13.

Dada la variable del ejemplo 2.12.

$$\text{Var}(3x) = 3^2 \text{Var}(x) = 9 \times 5,83 = 52,47$$

$$\text{Var}(2x + 3) = 4 \text{Var}(x) = 4 \times 5,83 = 23,32$$

2.6. MOMENTOS DE UNA VARIABLE ALEATORIA**DEFINICION 2.6.**

Los momentos de una variable aleatoria respecto al origen son los valores esperados de las potencias de la variable.

$$\alpha_n = E(x^n) = \begin{cases} \sum_x x^n f(x) & \text{si } x \text{ es discreta} \\ \int_{-\infty}^{+\infty} x^n (f(x)) dx & \text{si } x \text{ es continua} \end{cases}$$

Es decir, el momento enésimo de x es el valor esperado de x^n .

Es de inmediata evidencia que el primer momento de x es igual a su valor esperado.

DEFINICION 2.7.

Los momentos de una variable aleatoria con respecto a su media son los valores esperados de las potencias de las diferencias entre los valores de la variable y su media

$$\mu_n = E[x - E(x)]^n = \begin{cases} \sum_x [x - E(x)]^n f(x) & \text{si } x \text{ es discreta} \\ \int_{-\infty}^{+\infty} [x - E(x)]^n f(x) dx & \text{si } x \text{ es continua} \end{cases}$$

Casos Particulares

El primer momento respecto a la media es igual a cero, en efecto:

$$\mu_1 = E[x - E(x)] = E(x) - E(x) = 0$$

El segundo momento respecto a la media es la varianza de la variable.

$$\mu_2 = E[x - E(x)]^2 = \sigma^2$$

2.7. FUNCION GENERATRIZ DE MOMENTOS

DEFINICION 2.8.

La función generatriz de momentos $m_x(k)$ de una variable aleatoria x con función de densidad $f(x)$, es el valor esperado de e^{kx} , es decir,

$$m_x(k) = \begin{cases} \sum_x e^{kx} f(x) & \text{si } x \text{ es discreta} \\ \int_{-\infty}^{+\infty} e^{kx} f(x) dx & \text{si } x \text{ es continua} \end{cases}$$

La función generatriz de momentos es una función del parámetro k . Este parámetro no tiene significado real; el número e es la base de los logaritmos neperianos.

La importancia de la función generatriz de momentos es que a partir de ella se pueden calcular los momentos de las variables por simple diferenciación. En algunos casos es mucho más fácil calcular la función generatriz de momentos de una variable, y a partir de ella el valor esperado y la varianza, que obtener estas magnitudes directamente.

Suponiendo que la función generatriz de momentos existe, y puesto que

$$e^z = 1 + z + \frac{z^2}{2!} + \frac{z^3}{3!} + \dots$$

$$\begin{aligned} \text{tendremos, } m_x(k) &= E[e^{kx}] = E\left[1 + kx + \frac{k^2 x^2}{2!} + \frac{k^3 x^3}{3!} + \dots\right] = \\ &= 1 + kE(x) + \frac{k^2 E(x^2)}{2!} + \frac{k^3 E(x^3)}{3!} + \dots \end{aligned}$$

Si calculamos la primera derivada de $m_x(k)$ respecto a k y la valoramos para $k = 0$, obtendremos:

$$\frac{d}{dk} m_x(k) = E(x) + \frac{2k \cdot E(x^2)}{2!} + \frac{3k^2 \cdot E(x^3)}{3!} + \text{términos que contienen } k.$$

$$\text{entonces, } \left. \frac{d}{dk} m_x(k) \right|_{k=0} = E(x) + \text{términos iguales a } 0.$$

o sea que hemos obtenido el primer momento de x con respecto al origen. Si derivamos nuevamente,

$$\frac{d^2}{dk^2} m_x(k) = \frac{2E(x^2)}{2!} + \frac{2 \cdot 3kE(x^3)}{3!} + \text{términos que contienen } k$$

entonces,

$$\left. \frac{d^2}{dk^2} m_x(k) \right|_{k=0} = E(x^2) + \text{términos iguales a cero}$$

obteniendo así $E(x^2)$.

En general,

$$\left. \frac{d^n}{dk^n} m_x(k) \right|_{k=0} = \alpha_n$$

EJEMPLO 2.14.

Este ejemplo pretende mostrar la forma de aplicación de la función generatriz de momentos para el cálculo de los momentos de una variable.

Sea x una variable aleatoria con función de densidad $f(x) = e^{-(x-5)}$ para $x \geq 5$. Calcular la función generatriz de momentos de x , y a partir de ella la media y varianza de x .

$$m_x(k) = E(e^{xk}) = \int_5^{+\infty} e^{xk} e^{-(x-5)} dx = \lim_{b \rightarrow +\infty} \int_5^b e^5 e^{-x(1-k)} dx =$$

$$= \lim_{b \rightarrow +\infty} \left[-e^5 \frac{e^{-x(1-k)}}{1-k} \right]_5^b = \lim_{b \rightarrow +\infty} \frac{-e^5 e^{-b(1-k)}}{1-k} + \frac{e^5 e^{-5(1-k)}}{1-k}$$

$$\text{para } k < 1, \quad m_x(k) = \frac{e^{5k}}{1-k}$$

Como $E(x) = \frac{d}{dk} m_x(k) \Big|_{k=0}$, se tiene

$$\frac{d}{dk} \frac{e^{5k}}{1-k} \Big|_{k=0} = \frac{(1-k)e^{5k}5 + e^{5k}}{(1-k)^2} \Big|_{k=0} = 6$$

$$E(x) = 6$$

Para calcular la varianza, se calcula primero $E(x^2)$

$$E(x^2) = \frac{d^2}{dk^2} m_x(k) \Big|_{k=0} = 37$$

$$\text{Var}(x) = E(x^2) - [E(x)]^2 = 37 - 36 = 1$$

EJERCICIOS RESUELTOS

2.1. Al tomar una ficha al azar de un juego de dominó, se define una variable aleatoria x que representa los puntos de la ficha.

- i) Determinar la función de densidad de x ; ii) Determinar la función de distribución;
iii) Representar gráficamente ambas funciones.

Solución:

i) La variable aleatoria x puede tomar los valores cero, uno, dos, hasta doce.

El espacio muestral del experimento tiene 28 puntos muestrales, uno por cada ficha, cada uno con igual probabilidad $1/28$.



La variable aleatoria x toma el valor cero cuando se escoge la doble blanca [$P(x=0) = 1/28$]. Toma el valor uno cuando se escoge el uno - blanco [$P(x=1) = 1/28$]. El valor dos cuando se toma el doble uno o el blanco-dos [$P(x=2) = 2/28$]. Siguiendo este orden de ideas, la función de densidad de x será:

x	0	1	2	3	4	5	6	7	8	9	10	11	12
$f(x)$	1/28	1/28	2/28	2/28	3/28	3/28	4/28	3/28	3/28	2/28	2/28	1/28	1/28

ii) Sabemos que la función de distribución representa la probabilidad de que la variable aleatoria tome valores menores o iguales a uno dado, luego $F(x)$ se calcula acumulando (x) .

x	0	1	2	3	4	5	6	7	8	9	10	11	12
$F(x)$	1/28	2/28	4/28	6/28	9/28	12/28	16/28	19/28	22/28	24/28	26/28	27/28	1

iii)



2.2. Dada la función

$$f(x) = \frac{2}{c\sqrt{x}} \quad \text{para } 0 < x < 1$$

$$= 0 \quad \text{para cualquier otro valor de } x$$

i) Hallar el valor de c para que $f(x)$ sea una función de densidad; ii) Hallar la función de distribución; iii) Representar gráficamente ambas funciones.

Solución

i) Para que $f(x)$ sea una función de densidad debe cumplir dos condiciones:

$$1^\circ) \int_{-\infty}^{+\infty} f(x) dx = 1 \quad 2^\circ) f(x) \geq 0 \quad \forall x$$

En consecuencia,

$$\int_{-\infty}^{+\infty} f(x) dx = 1 \Rightarrow \int_{-\infty}^0 0 dx + \int_0^1 \frac{2}{c\sqrt{x}} dx + \int_1^{+\infty} 0 dx = 1$$

o sea,

$$\int_0^1 \frac{2}{c\sqrt{x}} dx = 1 \Rightarrow \left. \frac{2x^{\frac{1}{2}}}{c \cdot \frac{1}{2}} \right|_0^1 = 1 \Rightarrow \frac{4}{c} = 1 \quad \boxed{c = 4}$$

Por otro lado para $c = 4$, y tomando los valores positivos de la raíz es evidente que $f(x) \geq 0 \quad \forall x$; luego la función de densidad de x es:

$$f(x) = \frac{1}{2\sqrt{x}} \quad \text{para } 0 < x < 1$$

$$= 0 \quad \text{para cualquier otro valor de } x$$

ii) $F(x)$ se calcula integrando $f(x)$

$$F(x) = 0 \quad \text{para } x < 0$$

$$F(x) = \int_0^x \frac{1}{2\sqrt{x}} dx = x^{\frac{1}{2}} \quad \text{para } 0 < x < 1$$

$$F(x) = 1 \quad \text{para } x > 1$$

$$F(x) = 0 \quad \text{para } x < 0$$

$$= x^{\frac{1}{2}} \quad \text{para } 0 < x < 1$$


$$= 1 \quad \text{para } x > 1$$

iii) $f(x) \rightarrow \infty$ cuando $x \rightarrow 0^+$

$$f(x) = \frac{1}{2} \quad \text{cuando } x = 1$$

$$f'(x) = -\frac{1}{4} x^{-\frac{3}{2}} < 0 \quad \text{curva decreciente}$$


$$f''(x) = \frac{3}{8} x^{-\frac{5}{2}} > 0 \quad \text{cóncava hacia arriba}$$



$$F(0) = 0 \quad F(1) = 1$$

$$F'(x) = \frac{1}{2\sqrt{x}} > 0 \quad \text{Curva Creciente}$$

$$F''(x) = -\frac{1}{4}x^{-\frac{3}{2}} < 0 \quad \text{Cóncava hacia abajo}$$



2.3. En el ejercicio anterior calcular $E(x)$ y $\text{Var}(x)$.

Solución

$$E(x) = \int_0^1 x \cdot \frac{1}{2\sqrt{x}} dx = \int_0^1 \frac{x^{\frac{1}{2}}}{2} dx = \left. \frac{x^{\frac{3}{2}}}{\frac{3}{2}} \right|_0^1 = \frac{1}{3}$$

$$E(x^2) = \int_0^1 x^2 \cdot \frac{1}{2\sqrt{x}} dx = \int_0^1 \frac{x^{\frac{3}{2}}}{2} dx = \left. \frac{x^{\frac{5}{2}}}{\frac{5}{2}} \right|_0^1 = \frac{1}{5}$$

$$\text{Var}(x) = E(x^2) - [E(x)]^2 = \frac{1}{5} - \frac{1}{9} = \frac{4}{45}$$

$E(x) = \frac{1}{3}, \quad \text{Var}(x) = \frac{4}{45}$
--

2.4. Con la función de densidad del ejercicio 2.2, calcular:

i) $P(x < 1/2)$; ii) $P(1/4 < x \leq 3/4)$; iii) $P(x \geq 2/3)$; iv) $P(x \leq 3)$

Solución

i) $P(x < 1/2) = F(1/2) = \frac{1}{\sqrt{2}} = 0,707$

ii) $P(1/4 < x \leq 3/4) = F(3/4) - F(1/4) = \sqrt{3/4} - \sqrt{1/4} = \frac{\sqrt{3}-1}{2} = 0,366$

iii) $P(x \geq 2/3) = 1 - P(x \leq 2/3) = 1 - F(2/3) = 1 - \sqrt{2/3} = 0,183$

iv) $P(x \leq 3) = F(3) = 1$

2.5 Sea x una variable aleatoria cuya función de distribución es:

$$F(x) = 0 \quad \text{para } x \leq 1$$

$$= \frac{(x-1)^4}{16} \quad \text{para } 1 \leq x \leq 3$$

$$= 1 \quad \text{para } x > 3$$

i) Representar gráficamente $F(x)$; ii) Hallar $f(x)$ y comprobar que es una función de densidad; iii) Representar gráficamente $f(x)$; iv) Calcular $E(x)$; v) Calcular $\text{Var}(x)$.


Solución

$$F(1) = 0; \quad F(3) = 1$$

$$F'(x) = \frac{4(x-1)^3}{16} > 0 \quad F''(x) = \frac{12(x-1)^2}{16} > 0$$

(Creciente)

(Cóncava hacia arriba)



ii) Para encontrar $f(x)$ a partir de $F(x)$, basta recordar que $F(x)$ es la integral de $f(x)$, luego $f(x)$ es la derivada de $F(x)$

$$f(x) = \frac{4(x-1)^3}{16} = \frac{1}{4}(x-1)^3 \quad \text{para } 1 \leq x \leq 3$$

$$= 0 \quad \text{para cualquier otro valor de } x$$

$f(x)$ es una función de densidad porque $f(x) \geq 0 \quad \forall x, y$


$$\int_1^3 \frac{(x-1)^3}{4} dx = \frac{1}{4} \frac{(x-1)^4}{4} \Big|_1^3 = 1$$

iii) $f(x) = 0$ para $x = 1$

$$= 2 \quad \text{para } x = 3$$

$$f'(x) = \frac{12(x-1)^2}{16} > 0 \quad \text{creciente}$$

$$f''(x) = \frac{24}{16}(x-1) > 0 \quad \text{cóncava hacia arriba}$$



$$\begin{aligned} \text{iv) } E(x) &= \int_1^3 \frac{x(x-1)^3}{4} dx = \int_1^3 \frac{x^4 - 3x^3 + 3x^2 - x}{4} dx = \\ &= \frac{1}{4} \left[\frac{x^5}{5} - \frac{3x^4}{4} + \frac{3x^3}{3} - \frac{x^2}{2} \right]_1^3 = \frac{13}{5} \end{aligned}$$

$$\begin{aligned} \text{v) } E(x^2) &= \int_1^3 \frac{x^2(x-1)^3}{4} dx = \int_1^3 \frac{x^5 - 3x^4 + 3x^3 - x^2}{4} dx = \\ &= \frac{1}{4} \left[\frac{x^6}{6} - \frac{3x^5}{5} + \frac{3x^4}{4} - \frac{x^3}{3} \right]_1^3 = \frac{103}{15} \end{aligned}$$

$$\text{Var}(x) = E(x^2) - [E(x)]^2 = \frac{103}{15} - \left(\frac{13}{5}\right)^2 = \frac{8}{75}$$

2.6. La función de densidad de una variable aleatoria x viene dada en la tabla siguiente:

x	0	1	2	3
$f(x)$	0,3	0,2	0,4	0,1

Calcular: i) $E(x)$; ii) $\text{Var}(x)$; iii) $E(3x^2 + 4)$; iv) $\text{Var}\left(\frac{2x-4}{3}\right)$

Solución

$$i) E(x) = \sum xf(x) = 0 \times 0,3 + 1 \times 0,2 + 2 \times 0,4 + 3 \times 0,1 = 1,3$$

$$ii) E(x^2) = \sum x^2 f(x) = 0 \times 0,3 + 1 \times 0,2 + 4 \times 0,4 + 9 \times 0,1 = 2,7$$

$$\text{Var}(x) = E(x^2) - [E(x)]^2 = 2,7 - 1,69 = 1,01$$

$$iii) E(3x^2 + 4) = 3E(x^2) + 4 = 3 \times 2,7 + 4 = 12,1$$

De otra forma, $y = 3x^2 + 4$ es una función de x luego,

x	0	1	2	3
y	4	7	16	31

$$E(3x^2 + 4) = E(y) = \sum yf(x) = 4 \times 0,3 + 7 \times 0,2 + 16 \times 0,4 + 31 \times 0,1 = 12,1$$

$$iv) \text{Var}\left(\frac{2x-4}{3}\right) = \frac{1}{3^2} \text{Var}(2x-4) = \frac{1}{3^2} 2^2 \text{Var}(x) = \frac{4,04}{9} = 0,45$$

De otra forma, $y = \frac{2x-4}{3}$ es una función de x

x	0	1	2	3
y	-4/3	-2/3	0	2/3

$$E(y) = -\frac{4}{3} \times 0,3 - \frac{2}{3} \times 0,2 + 0 \times 0,4 + \frac{2}{3} \times 0,1 = -\frac{1,4}{3}$$

$$E(y^2) = -\frac{16}{9} \times 0,3 + \frac{4}{9} \times 0,2 + 0 \times 0,4 + \frac{4}{9} \times 0,1 = \frac{6}{9}$$

$$\text{Var}\left(\frac{2x-4}{3}\right) = \text{Var}(y) = E(y^2) - [E(y)]^2 = \frac{6}{9} - \frac{1,96}{9} = \frac{4,04}{9} = 0,45$$

- 2.7. Una persona A paga a otra B Bs. 2 y lanza 3 dados bien balanceados. Si sale un uno, B paga a A Bs. 3; si aparecen dos unos B paga a A Bs. 4 y si aparecen tres unos, B paga a A Bs. 7. i) ¿Es este un juego justo? ii) Si no lo es, ¿cuánto debería pagar B a A cuando aparezcan 3 unos?

Solución:

Un juego se define como justo cuando la esperanza matemática de las ganancias es cero.

Si x es una variable aleatoria que representa las ganancias de A, x puede tomar los valores -2, 1, 2, 5.

$$P(x = -2) = P(\text{no aparezcan unos}) = \frac{5}{6} \frac{5}{6} \frac{5}{6} = \left(\frac{5}{6}\right)^3$$

$$P(x = 1) = P(\text{aparezca un uno}) = \frac{1}{6} \frac{5}{6} \frac{5}{6} + \frac{5}{6} \frac{1}{6} \frac{5}{6} + \frac{5}{6} \frac{5}{6} \frac{1}{6} = \frac{75}{6^3}$$

$$P(x = 2) = P(\text{aparezcan dos unos}) = \frac{1}{6} \frac{1}{6} \frac{5}{6} + \frac{1}{6} \frac{5}{6} \frac{1}{6} + \frac{5}{6} \frac{1}{6} \frac{1}{6} = \frac{15}{6^3}$$

$$P(x = 5) = P(\text{aparezcan tres unos}) = \frac{1}{6} \frac{1}{6} \frac{1}{6} = \left(\frac{1}{6}\right)^3$$

$$E(x) = -2 \frac{5^3}{6^3} + 1 \frac{75}{6^3} + 2 \frac{15}{6^3} + 5 \frac{1}{6^3} = \frac{-140}{6^3} \neq 0$$

El juego no es justo.

- ii) Si llamamos y a lo que B debe pagar a A cuando aparecen tres unos, para que el juego sea justo debe cumplirse que $E(x) = 0$; o sea,

$$-2 \frac{125}{6^3} + \frac{75}{6^3} + 2 \frac{15}{6^3} + (y-2) \frac{1}{6^3} = 0$$

$$-250 + 75 + 30 + y - 2 = 0$$

$$y = 147$$

EJERCICIOS PROPUESTOS

- 2.8. En una caja hay 5 fichas marcadas con los números 3, 4, 5, 6, 7 respectivamente. La variable aleatoria x es la suma de los números de dos fichas tomadas al azar sin reemplazamiento.

Calcular: i) la función de densidad de x ; ii) La función de distribución; iii) Representar gráficamente ambas funciones; iv) $E(x)$; v) $Var(x)$

- 2.9. Dada la función $f(x) = c\left(\frac{1}{4}\right)^x$ para $x = 0, 1, 2, 3, 4, 5, \dots$

Calcular el valor de c para que $f(x)$ sea una función de densidad. Representarla gráficamente.

Nota: La suma de los términos de una progresión geométrica indefinida con razón (r) menor que la unidad es $S = \frac{a_1}{1-r}$

- 2.10. En el ejercicio anterior: i) calcular la función generatriz de momentos, ii) usarla para calcular $E(x)$ y $Var(x)$.
- 2.11. En el ejercicio 2.9. Calcular la probabilidad de que i) $x = 3$ ii) $x \leq 2$; iii) $x > 5$; iv) $5 < x \leq 7$.
- 2.12. Una empresa estima que sus beneficios pueden ser expresados en función de las ventas por la siguiente ecuación.

$$B = 1,4 V - 600.000$$

donde B = Beneficio, V = Volumen de ventas en unidades. La empresa considera que las ventas para el próximo periodo serán alguna de las siguientes cantidades; 700.000; 800.000; 1.100.000 ó 1.400.000 con las siguientes probabilidades; 0,10; 0,30; 0,50 y 0,10 respectivamente. ¿Cuál es el beneficio esperado?

- 2.13. Dada la siguiente función de x , $f(x) = c x(1-x)$ en el intervalo $(0,1)$. i) Calcular el valor de c para el cual $f(x)$ es una función de densidad; ii) Hallar la función de distribución; iii) Representar gráficamente ambas funciones.

- 2.14. En el ejercicio anterior calcular i) $E(x)$; ii) $Var(x)$; iii) $P(x > 2)$; iv) $P(0,5 < x < 1,5)$; v) $P(0,75 < x < 1)$; vi) $P(x \leq 0,25)$.

- 2.15. Dada la siguiente función $f(x) = c(4x - 2x^2)$ para $0 \leq x \leq 2$; $f(x) = 0$, para cualquier otro valor de x i) Calcular el valor de c para que $f(x)$ sea una función de densidad; ii) Calcular la función de distribución; iii) Representar gráficamente ambas funciones; iv) Calcular $E(x)$ y $Var(x)$.

- 2.16. Usted va a comprar un número de una lotería que tiene 100 números, y paga los siguientes premios: 20 premios de Bs. 10 cada uno, 10 premios de Bs. 100 cada uno, y un número no conocido de premios de Bs. 200 cada uno. Si cada número cuesta Bs. 30, ¿cuántos premios de Bs. 200 debe haber para que la lotería sea justa?

- 2.17. Sea x una variable aleatoria con la siguiente función de densidad.

x	-1	0	1	2
$f(x)$	1/8	1/4	?	3/8

$$F(x) = 0 \text{ para } x < -1$$

Calcular: i) $E(y)$ siendo $y = 3x + 2$; ii) $Var(z)$ siendo $z = 4x$; iii) $E(v)$ siendo $v = 3x^2$.

- 2.18. Dada la siguiente función

$$\begin{aligned} f(x) &= cx && \text{para } 0 < x < 5 \\ &= c(10 - x) && \text{para } 5 \leq x \leq 10 \\ &= 0 && \text{para cualquier otro valor de } x \end{aligned}$$

- i) Calcular el valor de c para que $f(x)$ sea una función de densidad.
- ii) Hallar la función de distribución.
- iii) Representar gráficamente ambas funciones.
- iv) Calcular $E(x)$ y $Var(x)$

- 2.19. Dada la siguiente función

$$\begin{aligned} f(x) &= \frac{1}{2} - cx && \text{para } 0 < x < 4 \\ &= 0 && \text{para cualquier otro valor de } x \end{aligned}$$

- i) Calcular c para que $f(x)$ sea una función de densidad
- ii) Calcular $F(x)$;

iii) Representar gráficamente ambas funciones

iv) Calcular $E(x)$ y $Var(x)$

2.20) Sea x una variable aleatoria con la siguiente función de densidad.

x	2	3	4	5
$f(x)$	?	?	$1/8$	$3/8$

Hallar $f(2)$ y $f(3)$, sabiendo que $E(3x + 4) = \frac{29}{2}$ y $Var(3x + 4) = \frac{63}{4}$

2.21) Dada la siguiente función

$$f(x) = c + \frac{x}{10.000} \quad \text{para } -100 \leq x \leq 0$$

$$= c - \frac{x}{10.000} \quad \text{para } 0 \leq x \leq 100$$

$$= 0 \quad \text{para cualquier otro valor de } x$$

i) Calcular el valor de c para que $f(x)$ sea una función de densidad

ii) Calcular la función de distribución

iii) Representar gráficamente ambas funciones

iv) Calcular $E(x)$ y $Var(x)$

2.22. Dada la función

$$f(x) = c \quad \text{para } 0 < x < 1$$

$$= 0 \quad \text{para cualquier otro valor de } x$$

i) Calcular c para que $f(x)$ sea una función de densidad

ii) Calcular la función de distribución

iii) Representar gráficamente ambas funciones

iv) Calcular $E(x)$ y $Var(x)$

2.23. Dada la función

$$f(x) = x \quad \text{para } 0 < x < 1$$

$$= c - x \quad \text{para } 1 < x < 2$$

$$= 0 \quad \text{para cualquier otro valor de } x$$

i) Calcular el valor de c para que $f(x)$ sea una función de densidad

ii) Calcular $F(x)$

iii) Representar gráficamente ambas funciones.

iv) Calcular $E(x)$ y $Var(x)$

2.24. Dada la siguiente función de distribución:

$$F(x) = 0 \quad \text{para } x < 0$$

$$= x^2 \quad \text{para } 0 < x < 1$$

$$= 1 \quad \text{para } x > 1$$

i) Calcular la función de densidad

ii) Representar gráficamente ambas funciones

2.25. Dada la siguiente función de distribución:

$$F(x) = \frac{x^3}{6} \quad \text{para } 0 < x < 1$$

$$= -\frac{x^3}{3} + \frac{3x^2}{2} - \frac{3}{2}x + \frac{1}{2} \quad \text{para } 1 < x < 2$$

$$= \frac{x^3}{6} - \frac{3x^2}{2} + \frac{9x}{2} - \frac{7}{2} \quad \text{para } 2 < x < 3$$

$$= 1 \quad \text{para } x > 3$$

i) Calcular $f(x)$; ii) Comprobar que $f(x)$ es una función de densidad; iii) Representar gráficamente ambas funciones.

2.26. Una variable aleatoria x tiene la siguiente función de densidad:

$$f(x) = cx(a - x) \quad \text{para } 0 < x < 1$$

$$= 0 \quad \text{para cualquier otro valor de } x$$

Sabiendo que $E(x) = \frac{1}{2}$ Calcular c y a

2.27. Una variable aleatoria x tiene la siguiente función de densidad.

$$f(x) = c(a - x)^4 \quad \text{para } 0 < x < 1$$

$$= 0 \quad \text{para cualquier otro valor de } x$$

Sabiendo que $F\left(\frac{1}{2}\right) = \frac{31}{32}$ Calcular c y a

2.28. Dada la siguiente función

$$f(x) = cx \quad \text{para } x = 1, 2, \dots, 50$$

$$= c(100 - x) \quad \text{para } x = 51, 52, \dots, 100$$

$$= 0 \quad \text{para cualquier otro valor de } x$$

i) Calcular el valor de c para que $f(x)$ sea una función de densidad; ii) Calcular la función de distribución; iii) Representar gráficamente ambas funciones; iv) Calcular $E(x)$

Nota: $\sum_{k=1}^n k^2 = \frac{n(n+1)(2n+1)}{6}$

2.29. Dada la variable aleatoria x con función de densidad $f(x) = x/2$ para $0 < x < 2$, hallar el valor de c tal que $P(x \leq c) = P(x \geq c)$

2.30. Una empresa vende un producto en Bs. 100 por unidad garantizando que si el producto resulta defectuoso, devolverá el dinero y dará una unidad gratis al comprador. El costo por unidad es Bs. 35; los porcentajes de unidades defectuosas con sus probabilidades son los siguientes:

%	Probabilidad
2	0,40
10	0,35
15	0,25

¿Cuál es la ganancia esperada por unidad?

2.31. La demanda en miles de unidades de un cierto bien se puede aproximar por una variable aleatoria continua x con función de densidad.

$$f(x) = \frac{1}{25}x \quad \text{para } 0 \leq x \leq 5$$

$$= \frac{1}{25}(10 - x) \quad \text{para } 5 \leq x \leq 10$$

$$= 0 \quad \text{para cualquier otro valor de } x.$$

El precio de venta es de Bs. 10 si vende menos de 2.500 unidades; si vende entre 2.500 y 6.000 unidades el precio es de Bs. 8 y si vende más de 6.000 unidades el precio es de Bs. 5. El costo medio de producción es constante e igual a Bs. 4. Calcular el beneficio esperado.

2.32. Determine razonadamente la veracidad o falsedad de las siguientes afirmaciones:

- a) Dada una variable continua x ; sean a y b dos valores de su campo de existencia ($b > a$). Se puede concluir que $f(b) = f(a)$ porque las probabilidades de que una variable aleatoria continua tome valores concretos es siempre cero.
- b) Para que dos variables aleatorias puedan tener igual valor esperado, sus intervalos de existencia deben tener puntos comunes.

2.33. Determine razonadamente cuál de las respuestas es correcta en:

Dada una variable discreta con función de densidad $f(x)$, se cumple que $P(a \leq x \leq c \text{ o } b \leq x \leq d)$, siendo $a < b < c < d$ valores de su campo de existencia, es igual a:

- a) $F(d) - f(c) - F(a) + f(d) - F(c)$.
- b) $F(d) - F(a) + f(a)$.
- c) $F(d) - F(b) + F(c) - F(a)$.
- d) $F(d) - F(a)$.
- e) Ninguna de las anteriores.

Sea x una variable aleatoria discreta que toma los valores enteros entre 0 y 8; entonces el valor esperado de x debe ser:

- a) Cualquier número.
- b) Un número entero entre 0 y 8.
- c) Cualquier número entre 0 y 8.
- d) Ninguna de las anteriores.

CAPITULO III

VARIABLES ALEATORIAS DISTRIBUIDAS CONJUNTAMENTE

3.1. INTRODUCCION

En el capítulo II se habló de la función de densidad de una sola variable aleatoria. En muchos casos es importante analizar en forma conjunta dos o más variables aleatorias; es decir, puede interesar conocer las probabilidades de que las variables tomen conjuntamente determinados valores, o la forma en que dos o más variables están relacionadas.

En este capítulo se trabajará con los conceptos definidos en el capítulo anterior, tales como función de densidad, valor esperado, varianza; pero referidos a dos o más variables o a funciones de dos o más variables.

3.2. FUNCION DE DENSIDAD CONJUNTA DE VARIABLES ALEATORIAS

DEFINICION 3.1.

Dadas varias variables aleatorias $x, y, z, w, \dots$, discretas definidas en el espacio muestral S , su función de densidad conjunta $f(x, y, z, w, \dots)$ es una función que mide la probabilidad de que $x, y, z, w, \dots$ tomen conjuntamente determinados valores.

$$f(x_0, y_0, z_0, w_0, \dots) = P(x = x_0, y = y_0, z = z_0, w = w_0)$$

En el caso de variables continuas la función de densidad conjunta servirá para calcular probabilidades de que las variables estén conjuntamente en determinados intervalos. Estas probabilidades se calculan mediante la integración múltiple:

$$P(x \leq x_0, y \leq y_0, z \leq z_0) = \int_{-\infty}^{x_0} \int_{-\infty}^{y_0} \int_{-\infty}^{z_0} f(x, y, z) dx dy dz$$

EJEMPLO 3.1.

Un experimento consiste en extraer dos fichas con reemplazamiento de una caja que contiene tres fichas numeradas del 1 al 3. Consideraremos la variable x como el número de la primera ficha, la variable y como el número de la segunda ficha, y procedemos a calcular la función de densidad conjunta de x e y .

El espacio muestral de este experimento contiene 9 puntos muestrales cada uno con probabilidad $1/9$.

S	(1,1)	(1,2)	(1,3)	(2,1)	(2,2)	(2,3)	(3,1)	(3,2)	(3,3)
x	1	1	1	2	2	2	3	3	3
y	1	2	3	1	2	3	1	2	3
f(x,y)	1/9	1/9	1/9	1/9	1/9	1/9	1/9	1/9	1/9

$$f(x, y) = \frac{1}{9} \quad \text{para } (x, y) = \begin{matrix} (1,1), & (1,2), & (1,3) \\ (2,1), & (2,2), & (2,3) \\ (3,1), & (3,2), & (3,3) \end{matrix}$$

De forma que la probabilidad de que $x = 3$ e $y = 2$

$$P(x = 3, y = 2) = f(3, 2) = \frac{1}{9}$$

EJEMPLO 3.2.

Dada la siguiente función de densidad conjunta de x, y, z .

$$\begin{matrix} f(0,1,1) = 1/6 & f(1,2,2) = 1/6 \\ f(0,1,2) = 1/6 & f(2,1,1) = 1/6 \\ f(1,2,1) = 1/6 & f(2,2,2) = 1/6 \end{matrix}$$

Calcular la probabilidad de que $x = 0, y = 1, z = 1$ ó de que $x = 1, y = 2, z = 2$.

La probabilidad pedida es:

$$f(0, 1, 1) + f(1, 2, 2) = \frac{1}{6} + \frac{1}{6} = \frac{1}{3}$$

EJEMPLO 3.3.

Dada la siguiente función de densidad conjunta

$$f(x, y) = x - \frac{1}{4}xy \quad \text{para } \begin{matrix} 0 \leq x \leq 1 \\ 0 \leq y \leq 4 \end{matrix}$$

Calcular i) $P(x \leq 0,5 \text{ e } y \leq 2)$; ii) $P(x < 2 \text{ e } 1 \leq y \leq 3)$

$$\begin{aligned} \text{i) } P(x \leq 0,5, y \leq 2) &= \int_0^2 \int_0^{0,5} \left(x - \frac{1}{4}xy \right) dx dy = \\ &= \int_0^2 \left(\frac{x^2}{2} - \frac{x^2}{8}y \right) \Big|_0^{0,5} dy = \int_0^2 \left(\frac{0,25}{2} - \frac{0,25}{8}y \right) dy = \\ &= \left(\frac{0,25}{2}y - \frac{0,25}{16}y^2 \right) \Big|_0^2 = 0,25 - \frac{0,25}{4} = 0,1875 \end{aligned}$$

$$\text{ii) } P(x < 2, 1 \leq y \leq 3) = \int_1^3 \int_0^2 f(x, y) dy dx$$

y por ser el campo de existencia de x el intervalo $(0,1)$ queda

$$\begin{aligned} P(x < 2, 1 \leq y \leq 3) &= \int_1^3 \int_0^1 \left(x - \frac{1}{4}xy \right) dy dx = \\ &= \int_0^1 \left(xy - \frac{1}{8}xy^2 \right) \Big|_1^3 dx = \int_0^1 x dx = \frac{1}{2} \end{aligned}$$

Se debe observar en los ejemplos anteriores que en el caso de variables discretas, la suma de la función de densidad es uno; mientras que en las variables continuas, la integral múltiple en los intervalos correspondientes es la unidad.

Análogamente a la existencia de la función de densidad conjunta, se puede hablar de la función de distribución conjunta de varias variables, que mide la probabilidad de que las variables tomen conjuntamente valores menores o iguales a ciertos valores dados.

3.3. FUNCION DE DENSIDAD MARGINAL, FUNCION DE DENSIDAD CONDICIONAL, VALOR ESPERADO CONDICIONAL

3.3.1. FUNCION DE DENSIDAD MARGINAL

Es posible que disponiendo de la función de densidad conjunta de varias variables, estemos interesados en analizar aisladamente una o más de las variables; es decir, en conocer las probabilidades de una variable sin importar los valores que tomen las otras.

Estas probabilidades vendrán dadas por la función de densidad individual de la variable en que estemos interesados, función que se deberá calcular a partir de la función de densidad conjunta. Esta función de densidad individual calculada a partir de la función de densidad conjunta, recibe el nombre de función de densidad marginal.

En el caso de dos variables aleatorias discretas, si $f(x, y)$ es la función de densidad conjunta, la probabilidad de que x tome un valor determinado, digamos x_0 , será:

$$P(x = x_0) = f(x_0) = P(x = x_0, y = \text{cualquier valor}) =$$

$$= \sum_y P(x = x_0, y) = \sum_y f(x_0, y)$$

o sea, que la función de densidad marginal de x se obtiene sumando la función de densidad conjunta con respecto a la otra variable y .

EJEMPLO 3.4.

Supongamos que en el ejemplo 3.1 estamos interesados únicamente en las probabilidades de x ; es decir, del número de la primera ficha extraída. x puede tomar los valores 1, 2, 3.³

$$P(x=1) = f_x(1) = \sum_y f(1, y) = \sum_y P(x=1, y) =$$

$$= P(x=1, y=1) + P(x=1, y=2) + P(x=1, y=3) = \frac{1}{9} + \frac{1}{9} + \frac{1}{9} = \frac{1}{3}$$

³ Cuando la notación no permita distinguir cual es la variable cuya función marginal estamos considerando, la subindicaremos con la variable correspondiente.

$$P(x=2) = f_x(2) = \sum_y f(2, y) = P(x=2, y=1) + P(x=2, y=2) + P(x=2, y=3) = \frac{1}{3}$$

$$\text{Similarmen te } P(x=3) = f_x(3) = \sum_y f(3, y) = \frac{1}{3}$$

Luego la función de densidad marginal de x es

$$f(x) = \frac{1}{3} \quad \text{para } x = 1, 2, 3.$$

Se deja al lector el cálculo de la función de densidad marginal de y .

En el caso de más de dos variables discretas, la función de densidad marginal de alguna de ellas se calcula sumando la función de densidad conjunta con respecto a las otras variables.

$$f(x) = \sum_{y, z, w, \dots} f(x, y, z, w, \dots)$$

EJEMPLO 3.5.

Calcular a partir de los datos del ejemplo 3.2 la función de densidad marginal de y .

y puede tomar los valores 1 ó 2.

$$f_y(1) = P(x = \text{cualquier valor}, y=1, z = \text{cualquier valor}) =$$

$$= \sum_{x, z} f(x, 1, z) = f(0, 1, 1) + f(0, 1, 2) + f(2, 1, 1) = \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = \frac{1}{2}$$

$$f_y(2) = f(1, 2, 1) + f(1, 2, 2) + f(2, 2, 2) = \frac{1}{2}$$

Luego la función de densidad marginal de y es

$$f(y) = \frac{1}{2} \quad \text{para } y = 1, 2.$$

Se deja como ejercicio al lector el cálculo de $f(x)$ y $f(z)$.

En el caso de variables aleatorias continuas, la función de densidad marginal de una de ellas se halla integrando la función conjunta respecto de las otras variables que no estamos considerando. Si la función de densidad conjunta es

$f(x, y, z, w, \dots)$, entonces,

$$f(x) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} f(x, y, z, w, \dots) dy dz dw \dots$$

$$f(y) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} f(x, y, z, w, \dots) dx dz dw \dots$$

EJEMPLO 3.6.

Calcular $f(x)$ en el ejemplo 3.3.

$$f(x) = \int_0^4 \left(x - \frac{1}{4}xy \right) dy = xy - \frac{xy^2}{8} \Big|_0^4 = 4x - 2x = 2x$$

$$f(x) = 2x \quad \text{para } 0 \leq x \leq 1$$

EJEMPLO 3.7

Dada la siguiente función de densidad conjunta $f(x, y, z) = e^{-(x+y+z)}$ para $x, y, z > 0$, la función de densidad marginal de y será:

$$f(y) = \int_0^{+\infty} \int_0^{+\infty} e^{-(x+y+z)} dx dz = \int_0^{+\infty} e^{-(y+z)} dz \int_0^{+\infty} e^{-x} dx =$$

$$= \int_0^{+\infty} e^{-(y+z)} dz = e^{-y}$$

$$f(y) = e^{-y} \quad \text{para } y > 0$$

Es evidente que cuando se trabaja con más de dos variables se pueden calcular a partir de la función de densidad conjunta de todas las variables funciones de densidad conjuntas de grupos de variables mediante la apropiada suma o integración de la función de densidad conjunta.

EJEMPLO 3.8.

En el ejemplo 3.2, calcular $f(y, z)$

y y y z toman conjuntamente los valores (1,1), (1,2), (2,1) y (2,2).

$$\begin{aligned} f(1,1) &= f(0,1,1) + f(2,1,1) = 1/3 \\ f(1,2) &= f(0,1,2) = 1/6 \\ f(2,1) &= f(1,2,1) = 1/6 \\ f(2,2) &= f(1,2,2) + f(2,2,2) = 1/3 \end{aligned}$$

$$\begin{aligned} \text{Luego } f(y,z) &= 1/3 \quad \text{para } (y,z) = (1,1), (2,2) \\ &= 1/6 \quad \text{para } (y,z) = (1,2), (2,1) \end{aligned}$$

EJEMPLO 3.9.

En el ejemplo 3.7 calcular $f(x, y)$

$$f(x, y) = \int_0^{+\infty} e^{-(x+y+z)} dz = e^{-(x+y)} \quad \text{para } x, y > 0$$

3.3.2. FUNCION DE DENSIDAD CONDICIONAL

Otro concepto que surge al trabajar con varias variables es el de probabilidad condicional, la cual se refiere a la probabilidad que una variable x tome determinados valores cuando el valor de y es conocido.

$$P(x = x_0 / y = y_0)$$

La función de densidad que mide estas probabilidades se conoce como función de densidad condicional de x dado y , y se obtiene dividiendo la función de densidad conjunta entre la función de densidad marginal de y .

$$f(x/y) = \frac{f(x, y)}{f(y)}; \quad f(y/x) = \frac{f(x, y)}{f(x)}$$

Una justificación simple de esta fórmula se consigue, si nos referimos a la probabilidad condicional de un suceso A dado otro B . Si el suceso A se define como el suceso de que la variable x tome un cierto valor, y B como el suceso de que la variable y tome un cierto valor, sabemos:

$$P(A/B) = \frac{P(A \cap B)}{P(B)} = \frac{P(x = x_0, y = y_0)}{P(y = y_0)} = \frac{f(x_0, y_0)}{f(y_0)}$$

EJEMPLO 3.10.

En una caja se tienen cuatro fichas, cada una marcada con dos números así: (3,4), (1,0), (1,4), (2,0). Se define una variable aleatoria x que representa el primer número de una ficha extraída al azar, y una variable aleatoria y que representa el segundo número de esa ficha.

La función de densidad conjunta de x e y será

$$f(x, y) = \frac{1}{4} \text{ para } (x, y) = (3, 4), (1, 0), (1, 4), (2, 0)$$

Las funciones de densidad marginales de x e y son:

$$f(x) = \frac{1}{2} \text{ para } x = 1 \quad f(y) = \frac{1}{2} \text{ para } y = 0, 4$$

$$= \frac{1}{4} \text{ para } x = 2, 3$$

Se quieren calcular las probabilidades condicionales de x , dados los valores de y . Al conocer el valor de y se reduce el espacio muestral del experimento; p. ej., si $y = 0$ los posibles resultados son $(1, 0)$ y $(2, 0)$, luego:

$$P(x = 1/y = 0) = \frac{1}{2} \quad P(x = 2/y = 0) = \frac{1}{2}$$

A ese resultado se llega aplicando la fórmula de la función de densidad condicional

$$P(x = 1/y = 0) = \frac{P(x = 1, y = 0)}{P(y = 0)} = \frac{f(1, 0)}{f_y(0)} = \frac{1/4}{1/2} = \frac{1}{2}$$

$$P(x = 2/y = 0) = \frac{P(x = 2, y = 0)}{P(y = 0)} = \frac{f(2, 0)}{f_y(0)} = \frac{1/4}{1/2} = \frac{1}{2}$$

Similarmente si $y = 4$, x puede tomar los valores 1 y 3

$$P(x = 1/y = 4) = \frac{f(1, 4)}{f_y(4)} = \frac{1/4}{1/2} = \frac{1}{2}$$

$$P(x = 3/y = 4) = \frac{f(3, 4)}{f_y(4)} = \frac{1/4}{1/2} = \frac{1}{2}$$

Luego, la función de densidad condicional de x , dado y es

$$f(x/y) = \begin{cases} f(x/y = 0) = 1/2 & \text{para } x = 1, 2 \\ f(x/y = 4) = 1/2 & \text{para } x = 1, 3 \end{cases}$$

Se deja como ejercicio al lector calcular $f(y/x)$.

EJEMPLO 3.11.

Dada la siguiente función de densidad conjunta

$$f(x, y) = \frac{3x^2 + 3y^2}{10} \text{ para } 0 \leq x \leq 2 \text{ e } 0 \leq y \leq 1$$

Calcular. i) $f(x/y)$; ii) $P(x \leq 1/y = 1)$; iii) $P(x \leq 1/y \leq 0,5)$

i) Para calcular $f(x/y)$ se procede primero a calcular $f(y)$

$$f(y) = \int_0^2 f(x, y) dx = \int_0^2 \frac{3x^2 + 3y^2}{10} dx = \frac{4 + 3y^2}{5} \text{ para } 0 \leq y \leq 1$$

$$f(x/y) = \frac{f(x, y)}{f(y)} = \frac{(3x^2 + 3y^2)/10}{(4 + 3y^2)/5}$$

$$f(x/y) = \frac{3x^2 + 3y^2}{8 + 6y^2} \text{ para } \begin{matrix} 0 \leq x \leq 2 \\ 0 \leq y \leq 1 \end{matrix}$$

ii) Para calcular $P(x \leq 1/y = 1)$ se procede primero a sustituir en $f(x/y)$ el valor $y = 1$

$$f(x/y = 1) = \frac{3x^2 + 3}{14} \text{ para } 0 \leq x \leq 2$$

$$P(x \leq 1/y = 1) = \int_0^1 \frac{3x^2 + 3}{14} dx = \frac{x^3 + 3x}{14} \Big|_0^1 = \frac{2}{7}$$

También se podría haber calculado integrando primero $f(x/y)$ entre 0 y 1, y después sustituyendo el valor de y .

iii) Este tipo de pregunta es la que la variable condicionante no toma un valor concreto, sino que está en un intervalo, no puede resolverse con la función de densidad condicional, pues ésta es aplicable únicamente cuando la variable condicionante toma un valor concreto.

Para calcular una probabilidad tal como la pedida, se acude simplemente al concepto de probabilidad condicional, dividiendo la probabilidad conjunta entre la probabilidad marginal.

$$P(x \leq 1/y \leq 0,5) = \frac{P(x < 1, y < 0,5)}{P(y \leq 0,5)} = \frac{\int_0^{0,5} \int_0^1 f(x, y) dx dy}{\int_0^{0,5} f(y) dy} =$$

$$= \frac{\int_0^{0,5} \int_0^1 \frac{3x^2 + 3y^2}{10} dx dy}{\int_0^{0,5} \frac{4 + 3y^2}{5} dy} = 0,147$$

3.3.3. VALOR ESPERADO CONDICIONAL

Cuando se trabaja con dos variables aleatorias distribuidas conjuntamente, a veces interesa conocer el valor esperado de una de ellas, dado el valor de la otra.

DEFINICION 3.2.

Dadas dos variables x, y con función de densidad $f(x, y)$, el valor esperado condicional de x dado y se define como:

$$E(x/y) = \sum_x x f(x/y) \quad \text{si son discretas}$$

$$= \int_{-\infty}^{+\infty} x f(x/y) dx \quad \text{si son continuas}$$

Se observará que el valor esperado condicional difiere del simple, visto antes, en que la función de densidad ponderadora es la condicional en lugar de la marginal.

EJEMPLO 3.12.

Calcular el valor esperado condicional de x dado y en el ejemplo 3.11.

$$E(x/y) = \int_0^2 x f(x/y) dx = \int_0^2 x \frac{3x^2 + 3y^2}{8 + 6y^2} dx$$

$$E(x/y) = \frac{12 + 6y^2}{8 + 6y^2} \quad \text{para } 0 \leq y \leq 1$$

Se observará que el valor esperado condicional de x queda en función de la variable condicionante; según los valores concretos que tome y , se obtendrán distintos valores esperados de x . Por ejemplo:

$$\text{Si } y = 0 \quad E(x/y = 0) = \frac{3}{2}$$

$$\text{Si } y = 0,5 \quad E(x/y = 0,5) = 1,42$$

3.4. VARIABLES ALEATORIAS INDEPENDIENTES

DEFINICION 3.3.

Dadas dos variables aleatorias x, y con función de densidad conjunta $f(x, y)$, se dice que son estadísticamente independientes, si y sólo si la función de densidad condicional de x dado y , $f(x/y)$, es igual a la función de densidad marginal de x , $f(x)$.

En otras palabras x e y son estadísticamente independientes, si $f(x/y)$ no es función de la variable y .

$$\text{Puesto que } f(x/y) = \frac{f(x, y)}{f(y)} = f(x)$$

se sigue que, si son independientes:

$$f(x, y) = f(x)f(y) \quad \forall (x, y)$$

Es decir, dos variables x, y son independientes, si y sólo si su función de densidad conjunta es igual al producto de las funciones de densidad marginales.

Es evidente que también $f(y/x) = f(y)$, si son independientes.

En general para más de dos variables $x, y, z, w, \dots$ con función de densidad conjunta $f(x, y, z, w, \dots)$, éstas serán independientes si y sólo si las funciones de densidad conjuntas de cada grupo de dos o más variables son iguales al producto de las funciones de densidad marginales es decir, si y sólo si,

$$f(x, y) = f(x)f(y); f(x, z) = f(x)f(z); \dots$$

$$f(x, y, z, w, \dots) = f(x)f(y)f(z)f(w) \dots$$

EJEMPLO 3.13.

En el ejemplo 3.1 x e y son variables independientes. En efecto $\forall (x, y)$ se cumple que $f(x, y) = f(x)f(y)$.

$$f(1, 1) = \frac{1}{9} = f(1) f(1) = \frac{1}{3} \frac{1}{3}$$

$$f(1, 3) = \frac{1}{9} = f(1) f(3) = \frac{1}{3} \frac{1}{3}$$

Se deja a cargo del lector la verificación para el resto de los valores de x e y .

EJEMPLO 3.14.

Las variables x, y, z definidas en el ejemplo 3.2. no son independientes. En efecto,

$$f(0, 1, 1) = \frac{1}{6}$$

$$f_x(0) = \frac{1}{3}; \quad f_y(1) = \frac{1}{2}; \quad f_z(1) = \frac{1}{2}$$

Obviamente:

$$f(0, 1, 1) \neq f_x(0) f_y(1) f_z(1)$$

EJEMPLO 3.15.

Las variables x, y definidas en el ejemplo 3.3. son independientes.

$$f(x, y) = x - \frac{1}{4}xy \quad \text{para } 0 \leq x \leq 1, \quad 0 \leq y \leq 4$$

$$f(x) = 2x \quad \text{para } 0 \leq x \leq 1 \quad (\text{según ejemplo 3.6})$$

$$f(y) = \int_0^1 \left(x - \frac{1}{4}xy \right) dx = \frac{x^2}{2} - \frac{x^2}{8} y \Big|_0^1 = \frac{1}{2} - \frac{1}{8}y$$

$$f(y) = \frac{1}{2} - \frac{1}{8}y \quad \text{para } 0 \leq y \leq 4$$

$$f(x, y) = f(x) f(y)$$

EJEMPLO 3.16.

Las variables x, y definidas en el ejemplo 3.11 no son independientes. Lo comprobaremos según la definición, utilizando la función de densidad condicional.

$$f(x/y) = \frac{3x^2 + 3y^2}{8 + 6y^2} \quad \text{para } \begin{matrix} 0 \leq x \leq 2 \\ 0 \leq y \leq 1 \end{matrix}$$

La función de densidad depende de la variable y , luego no son independientes.

Cuando dos variables x e y son independientes se deduce lógicamente que el valor esperado de x no debe ser afectado por la otra y viceversa, o sea, si las variables son independientes $E(x/y)$ debería ser igual a $E(x)$. Lo probaremos para el caso de variables discretas:

$$E(x/y) = \sum_x x f(x/y) = \sum_x x f(x) = E(x)$$

El recíproco no tiene por qué ser cierto, el hecho de que los valores esperados condicionales y simples sean iguales no implica que las variables son independientes.

En el ejercicio 3.5 las variables x e y no son independientes, y sin embargo

$$E(x/y) = E(x) = 0$$

Se concluye la exposición del concepto de independencia estadística con una fundamental propiedad de las variables aleatorias independientes.

Teorema: Sean $x_1, x_2, \dots, x_n$ n variables aleatorias, y sean $y_1, y_2, \dots, y_n$ variables aleatorias funciones de $x_1, x_2, \dots, x_n$, de tal forma que y_1 es sólo función de x_1 , y_2 , sólo función de x_2 , etc. La independencia de $x_1, x_2, \dots, x_n$ implica la independencia de $y_1, y_2, \dots, y_n$.⁴

3.5. VALOR ESPERADO DE FUNCIONES DE VARIAS VARIABLES ALEATORIAS

Se comenzará con el caso de dos variables, para luego generalizar a n variables.

Dadas dos variables aleatorias x e y , si $g(x, y)$ es una función de ellas, el valor esperado de $g(x, y)$ es:

$$(1) \quad E[g(x, y)] = \sum_{(x, y)} g(x, y) f(x, y) \quad \text{si son discretas}$$

$$= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y) f(x, y) dx dy \quad \text{si son continuas}$$

⁴ Para una prueba ver: E. Parzen, Modern Probability Theory & its Applications, E. Wiley, Pág. 295.

El subíndice (x, y) en la sumatoria indica que la suma debe hacerse sobre todos los posibles pares de x e y .

EJEMPLO 3.17.

Dadas las variables x, y definidas en el ejemplo 3.10, calcular $E(x - y)^2$

$$f(x, y) = \frac{1}{4} \text{ para } (x, y) = (3, 4), (1, 0), (1, 4), (2, 0)$$

$$E(x - y)^2 = \sum_{(x, y)} (x - y)^2 f(x, y) = (3 - 4)^2 \frac{1}{4} + (1 - 0)^2 \frac{1}{4} + (1 - 4)^2 \frac{1}{4} + (2 - 0)^2 \frac{1}{4} = \frac{15}{4}$$

EJEMPLO 3.18

$$\text{Si } f(x, y) = x - \frac{1}{4}xy \text{ para } 0 \leq x \leq 1, 0 \leq y \leq 4$$

Calcular $E(x^2 y^2)$

$$E(x^2 y^2) = \int_0^4 \int_0^1 x^2 y^2 \left(x - \frac{1}{4}xy \right) dx dy = \int_0^4 y^2 dy \int_0^1 \left(x^3 - \frac{1}{4}x^3 y \right) dx = \int_0^4 y^2 \left(\frac{1}{4} - \frac{1}{16}y \right) dy = \frac{4}{3}$$

A continuación se desarrolla el valor esperado de ciertas funciones, que por su importancia práctica conviene mencionarlas explícitamente.

El valor esperado de una suma de funciones de x e y , es igual a la suma de los valores esperados; si $g(x, y)$ y $h(x, y)$ son dos funciones de x e y entonces.

$$(2) E[g(x, y) + h(x, y)] = E[g(x, y)] + E[h(x, y)]$$

En efecto si x e y son discretas,

$$E[g(x, y) + h(x, y)] = \sum_{(x, y)} [g(x, y) + h(x, y)] f(x, y) =$$

$$= \sum_{(x, y)} g(x, y) f(x, y) + \sum_{(x, y)} h(x, y) f(x, y) =$$

$$= E[g(x, y)] + E[h(x, y)]$$

si x, y son continuas.

$$E[g(x, y) + h(x, y)] = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} [g(x, y) + h(x, y)] f(x, y) dx dy =$$

$$= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y) f(x, y) dx dy + \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} h(x, y) f(x, y) dx dy =$$

$$= E[g(x, y)] + E[h(x, y)]$$

En particular

$$(3) E(x + y) = E(x) + E(y)$$

$$(4) E(x - y) = E(x) - E(y)$$

Si bien el valor esperado de una suma de variables es igual a la suma de valores esperados, no es cierto que una propiedad similar sea válida en caso del producto. En general no es verdad que $E(xy) = E(x)E(y)$. Hay un caso especial para el cual esta relación es válida, cuando las variables x, y son independientes.

$$(5) E(xy) = E(x)E(y) \text{ si } x \text{ e } y \text{ son independientes.}$$

En efecto,

$$E(xy) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} xy f(x, y) dx dy =$$

$$= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} xy f(x) f(y) dx dy =$$

$$= \int_{-\infty}^{+\infty} x f(x) dx \int_{-\infty}^{+\infty} y f(y) dy = E(x) E(y)$$

Del teorema visto al final de la sección 3.4, se deduce inmediatamente que si se tienen dos funciones $g(x)$ y $h(y)$ el valor esperado del producto de esas funciones es igual al producto de los valores esperados, si x e y son independientes.

$$(6) E[g(x)h(y)] = E[g(x)]E[h(y)]$$

si x e y son independientes.

Hay que hacer notar que si $E(xy) = E(x)E(y)$ no implica que x e y sean independientes (Ver ejercicio 3.5).

EJEMPLO 3.19.

Consideremos de nuevo las variables x , y definidas en el ejemplo 3.10.

(x,y)	(3,4)	(1,0)	(1,4)	(2,0)
$f(x,y)$	1/4	1/4	1/4	1/4

Calcular: i) $E(3x^2 + y/2)$; ii) $E(x + y)$; iii) $E(xy)$; iv) $E[(2x + 4)(y + 5)]$

Los valores esperados anteriores se calcularán en este ejemplo aplicando directamente la fórmula general (1) para el valor esperado de funciones de varias variables, y usando las fórmulas de los casos particulares mencionados, con el objeto de que el lector se familiarice con ambos criterios y compruebe la igualdad de los resultados.

En la tabla siguiente se presentan los valores de las funciones de x e y consideradas.

(x,y)	$f(x,y)$	$3x^2 + y/2$	$x + y$	xy	$(2x+4)(y+5)$
3,4	1/4	29	7	12	90
1,0	1/4	3	1	0	30
1,4	1/4	5	5	4	54
2,0	1/4	12	2	0	40

$$f(x) = \frac{1}{2} \text{ para } x = 1; \quad f(y) = \frac{1}{2} \text{ para } y = 0, 4$$

$$= \frac{1}{4} \text{ para } x = 2, 3$$

$$i) g(x, y) = 3x^2 + \frac{y}{2}. \text{ Usando (1)}$$

$$E\left[3x^2 + \frac{y}{2}\right] = \sum_{(x,y)} g(x,y) f(x,y) = \sum_{(x,y)} \left(3x^2 + \frac{y}{2}\right) f(x,y) =$$

$$= 29\frac{1}{4} + 3\frac{1}{4} + 5\frac{1}{4} + 12\frac{1}{4} = \frac{49}{4}$$

Usando (2)

$$E\left[3x^2 + \frac{y}{2}\right] = E[3x^2] + E\left[\frac{y}{2}\right] = \sum_x 3x^2 f(x) + \sum_y \frac{y}{2} f(y) =$$

$$= \left(3\frac{1}{2} + 12\frac{1}{4} + 27\frac{1}{4}\right) + \left(0\frac{1}{2} + 2\frac{1}{2}\right) = \frac{49}{4}$$

$$ii) g(x, y) = x + y; \text{ Usando (1)}$$

$$E(x + y) = \sum_{(x,y)} (x + y) f(x,y) = 7\frac{1}{4} + 1\frac{1}{4} + 5\frac{1}{4} + 2\frac{1}{4} = \frac{15}{4}$$

Usando (3)

$$E(x + y) = E(x) + E(y) = \left(\frac{1}{2} + \frac{1}{4}2 + \frac{1}{4}3\right) + \frac{1}{2}4 = \frac{15}{4}$$

$$iii) g(x, y) = xy; \text{ usando (1)}$$

$$E(xy) = \sum_{(x,y)} xy f(x,y) = 12\frac{1}{4} + 0\frac{1}{4} + 4\frac{1}{4} + 0\frac{1}{4} = 4$$

Al no ser independientes, como el lector puede comprobarlo, el valor esperado del producto no es igual al producto de los valores esperados. En efecto,

$$E(x) = \frac{7}{4}; \quad E(y) = 2; \quad E(x)E(y) = \frac{14}{4}$$

$$iv) g(x, y) = (2x + 4)(y + 5)$$

$$E[(2x + 4)(y + 5)] = 90\frac{1}{4} + 30\frac{1}{4} + 54\frac{1}{4} + 40\frac{1}{4} = \frac{107}{2}$$

EJEMPLO 3.20.

Dadas x, y con $f(x, y) = x - \frac{1}{4}xy$ para $0 \leq x \leq 1, 0 \leq y \leq 4$

Calcular. i) $E(x - y)$; ii) $E(xy)$; iii) $E(x^2y^2)$; iv) $E(x^2y + xy^2)$

En el ejemplo 3.15 se calcularon

$$f(x) = 2x \text{ para } 0 \leq x \leq 1; f(y) = \frac{1}{2} - \frac{1}{8}y \text{ para } 0 \leq y \leq 4$$

i) $g(x, y) = x - y$; Usando (1)

$$\begin{aligned} E[x - y] &= \int_0^1 \int_0^4 (x - y) \left(x - \frac{1}{4}xy \right) dx dy = \\ &= \int_0^1 \int_0^4 \left(x^2 - \frac{1}{4}x^2y - xy + \frac{1}{4}xy^2 \right) dx dy = \\ &= \int_0^4 dy \left(\frac{x^3}{3} - \frac{x^3}{12}y - \frac{x^2}{2}y + \frac{x^2}{8}y^2 \right) \Big|_0^1 = \\ &= \int_0^4 \left(\frac{1}{3} - \frac{1}{12}y - \frac{1}{2}y + \frac{1}{8}y^2 \right) dy = \\ &= \left(\frac{y}{3} - \frac{y^2}{24} - \frac{y^2}{4} + \frac{y^3}{24} \right) \Big|_0^4 = -\frac{2}{3} \end{aligned}$$

Usando (4)

$$E(x - y) = E(x) - E(y)$$

$$E(x) = \int_0^1 x 2x dx = \frac{2x^3}{3} \Big|_0^1 = \frac{2}{3}$$

$$E(y) = \int_0^4 y \left(\frac{1}{2} - \frac{1}{8}y \right) dy = \left(\frac{y^2}{4} - \frac{y^3}{24} \right) \Big|_0^4 = \frac{4}{3}$$

$$E(x) - E(y) = -\frac{2}{3}$$

ii) $g(x, y) = xy$

$$\begin{aligned} E(xy) &= \int_0^1 \int_0^4 xy \left(x - \frac{1}{4}xy \right) dx dy = \\ &= \int_0^4 y dy \int_0^1 \left(x^2 - \frac{1}{4}x^2y \right) dx = \frac{8}{9} \end{aligned}$$

Sabiendo que son independientes (Ver ejemplo 3.15), se podría haber aplicado (5)

$$E(xy) = E(x)E(y) = \frac{2}{3} \cdot \frac{4}{3} = \frac{8}{9}$$

iii) El valor esperado de x^2y^2 fue calculado directamente en el ejemplo 3.18. Ahora se calcula usando (6)

$$g(x) = x^2 \quad h(y) = y^2$$

$$E[g(x)h(y)] = E[g(x)][h(y)] = E(x^2)E(y^2)$$

$$E(x^2) = \int_0^1 x^2 2x dx = \frac{x^4}{2} \Big|_0^1 = \frac{1}{2}$$

$$E(y^2) = \int_0^4 y^2 \left(\frac{1}{2} - \frac{1}{8}y \right) dy = \left(\frac{y^3}{6} - \frac{y^4}{32} \right) \Big|_0^4 = \frac{8}{3}$$

$$E(x^2)E(y^2) = \frac{4}{3}$$

iv) $g(x, y) = x^2y + xy^2$; usando (1)

$$\begin{aligned} E[x^2y + xy^2] &= \int_0^1 \int_0^4 (x^2y + xy^2) \left(x - \frac{1}{4}xy \right) dx dy = \\ &= \int_0^1 \int_0^4 \left(x^3y - \frac{1}{4}x^3y^2 + x^2y^2 - \frac{1}{4}x^2y^3 \right) dx dy = \frac{22}{9} \end{aligned}$$

Usando (2), $g(x, y) = x^2y$; $h(x, y) = xy^2$

$$E(x^2y + xy^2) = E(x^2y) + E(xy^2)$$

$$E(x^2y) = \int_0^4 \int_0^1 x^2y \left(x - \frac{1}{4}xy \right) dx dy = \frac{2}{3}$$

$$E(xy^2) = \int_0^4 \int_0^1 xy^2 \left(x - \frac{1}{4}xy \right) dx dy = \frac{16}{9}$$

$$E(x^2y + xy^2) = \frac{2}{3} + \frac{16}{9} = \frac{22}{9}$$

También en el procedimiento anterior se podría haber usado (6) puesto que x e y son independientes, quedando

$$\begin{aligned} E(x^2y + xy^2) &= E(x^2y) + E(xy^2) = E(x^2)E(y) + E(x)E(y^2) \\ &= \frac{1}{2} \cdot \frac{4}{3} + \frac{2}{3} \cdot \frac{8}{3} = \frac{22}{9} \end{aligned}$$

DEFINICION 3.4.

La covarianza de dos variables aleatorias x e y se define como el valor esperado del producto de las diferencias entre las variables y sus medias.

$$\text{cov}(x, y) = E\{[x - E(x)][y - E(y)]\}$$

Desarrollando la definición anterior,

$$\begin{aligned} \text{cov}(x, y) &= E[xy - xE(y) - yE(x) + E(x)E(y)] = \\ &= E(xy) - E(x)E(y) - E(y)E(x) + E(x)E(y) = \\ &= E(xy) - E(x)E(y) \end{aligned}$$

o sea, que la covarianza de dos variables aleatorias x e y es igual al valor esperado del producto menos el producto de los valores esperados.


Si las variables son independientes su covarianza es cero puesto que $E(xy) = E(x)E(y)$. El recíproco no es cierto, si $\text{cov}(x, y) = 0$ no implica que las variables son independientes.

Dos variables cuya covarianza es cero, o sea que $E(xy) = E(x)E(y)$, se dice que son "no correlacionadas". Si las variables son independientes, son "no correlacionadas"; pero si son "no correlacionadas", no implica que sean independientes.

La covarianza es una medida de la asociación de las variables; su signo indica como es la variación conjunta de x e y ; si la covarianza es positiva x e y varían en el mismo sentido; si es negativa varían en sentido opuesto; si es cero las variables aparentemente no se mueven en forma conjunta. En efecto, si la asociación es directa, los productos que se promedian al calcular la covarianza tienden a tener el mismo signo y su promedio tiende a ser positivo; si la asociación entre las variables es inversa, los productos tienden a tener signos contrarios y su promedio tiende a ser negativo.

Ilustraremos estas afirmaciones gráficamente. En la figura 3.1. se describe el comportamiento de dos variables que se mueven en el mismo sentido: a valores pequeños de x corresponden valores pequeños de y , a valores grandes de x corresponden valores grandes de y .

FIGURA 3.1.



Consideremos en el plano, el punto de coordenadas $[E(x), E(y)]$ y traslademos los ejes para que el origen esté en ese punto -los nuevos ejes son graficados con líneas no continuas-. Se puede observar que la mayoría de los puntos quedan en el primer y tercer cuadrante de los ejes trasladados y las diferencias $x - E(x)$ e $y - E(y)$ son del mismo signo, positivas ambas o negativas ambas, la mayoría de los productos $[x - E(x)][y - E(y)]$ son positivos y su promedio tiende a ser positivo.

Se deja como práctica al lector hacer la ilustración gráfica y su correspondiente razonamiento en el caso de que x e y varíen en forma inversa o no tengan aparentemente asociación en sus valores.

DEFINICION 3.5.

El coeficiente de correlación de dos variables x e y se define como el cociente entre la covarianza de las variables y el producto de sus desviaciones típicas.

$$\rho(x, y) = \frac{\text{cov}(x, y)}{\sigma_x \sigma_y}$$

Si las variables son independientes, su coeficiente de correlación es cero. Dos variables son no correlacionadas, si y sólo si su coeficiente de correlación es cero.

Se puede probar que el coeficiente de correlación es un número entre -1 y 1 y que su valor es ± 1 , si y sólo si las variables x e y son linealmente dependientes.⁵

Varianza de la suma de dos variables aleatorias. Si x e y son dos variables aleatorias, entonces:

$$\text{Var}(x + y) = \text{Var}(x) + \text{Var}(y) + 2 \text{cov}(x, y)$$

En efecto, la suma $x + y$ es una variable aleatoria, y su varianza será igual al valor esperado del cuadrado de la diferencia entre la variable y su media,

$$\begin{aligned} \text{Var}(x + y) &= E[(x + y) - E(x + y)]^2 = \\ &= E\{(x + y) - [E(x) + E(y)]\}^2 = \\ &= E\{[x - E(x)] + [y - E(y)]\}^2 = \\ &= E\{[x - E(x)]^2 + [y - E(y)]^2 + 2[x - E(x)][y - E(y)]\} = \\ &= E[x - E(x)]^2 + E[y - E(y)]^2 + 2E\{[x - E(x)][y - E(y)]\} = \\ &= \text{Var}(x) + \text{Var}(y) + 2 \text{cov}(x, y) \end{aligned}$$

Si las variables son independientes $\text{Var}(x + y) = \text{Var}(x) + \text{Var}(y)$ porque $\text{cov}(x, y) = 0$.

Varianza de la diferencia de dos variables aleatorias. Se deja como ejercicio al lector demostrar que la varianza de la diferencia de dos variables aleatorias x e y es:

$$\text{Var}(x - y) = \text{Var}(x) + \text{Var}(y) - 2 \text{cov}(x, y)$$

⁵ Para una prueba ver: E Parzen, op. cit., pág. 363 y siguientes.

Si las variables son independientes, la varianza de su suma es igual a la varianza de su diferencia.

EJEMPLO 3.21.

Dadas las variables x e y con la función de densidad conjunta

(x, y)	$(1, 1)$	$(1, 2)$	$(2, 1)$	$(2, 3)$
$f(x, y)$	$1/6$	$1/4$	$1/4$	$1/3$

Calcular: i) $\rho(x, y)$; ii) $\text{Var}(x + y)$; $\text{Var}(x - y)$

Cálculos preliminares

$$\begin{aligned} f(x) &= \frac{5}{12} \quad \text{para } x = 1 & f(y) &= \frac{5}{12} \quad \text{para } y = 1 \\ &= \frac{7}{12} \quad \text{para } x = 2 & &= \frac{1}{4} \quad \text{para } y = 2 \\ & & &= \frac{1}{3} \quad \text{para } y = 3 \end{aligned}$$

$$E(x) = \frac{5}{12} + \frac{14}{12} = \frac{19}{12}$$

$$E(y) = \frac{5}{12} + \frac{2}{4} + \frac{3}{3} = \frac{23}{12}$$

$$\text{Var}(x) = E(x^2) - [E(x)]^2 = \frac{5}{12} + \frac{28}{12} - \frac{19^2}{12^2} = \frac{35}{144}$$

$$\text{Var}(y) = E(y^2) - [E(y)]^2 = \frac{5}{12} + \frac{4}{4} + \frac{9}{3} - \frac{23^2}{12^2} = \frac{107}{144}$$

$$E(xy) = \sum_{(x,y)} xyf(x, y) = 1 \cdot \frac{1}{6} + 2 \cdot \frac{1}{4} + 2 \cdot \frac{1}{4} + 6 \cdot \frac{1}{3} = \frac{19}{6}$$

$$\text{cov}(x, y) = \frac{19}{6} - \frac{19}{12} \cdot \frac{23}{12} = \frac{19}{144}$$

$$\text{i) } \rho(x, y) = \frac{\text{cov}(x, y)}{\sigma_x \sigma_y} = \frac{\frac{19}{144}}{\sqrt{\frac{35}{144}} \sqrt{\frac{107}{144}}} = 0,31$$

$$\text{ii) } \text{Var}(x+y) = \frac{35}{144} + \frac{107}{144} + 2 \frac{19}{144} = \frac{5}{4}$$

$$\text{Var}(x-y) = \frac{35}{144} + \frac{107}{144} - 2 \frac{19}{144} = \frac{13}{18}$$

EJEMPLO 3.22.

Dadas las variables x, y definidas por la siguiente función de densidad $f(x, y) = x - 1/4 xy$ para $0 \leq x \leq 1$, $0 \leq y \leq 4$. Comprobar que $\text{Var}(x+y) = \text{Var}(x-y)$, calculando directamente ambas varianzas.

Por ser $x + y$ una variable aleatoria, su varianza será igual al valor esperado del cuadrado menos el cuadrado del valor esperado.

$$\text{Var}(x+y) = E(x+y)^2 - [E(x+y)]^2$$

$$E(x+y)^2 = \int_0^4 \int_0^1 (x+y)^2 \left(x - \frac{1}{4}xy\right) dx dy = \frac{89}{18}$$

$$[E(x+y)]^2 = [E(x) + E(y)]^2 = 4$$

$$\text{Var}(x+y) = \frac{89}{18} - 4 = \frac{17}{18}$$

$$\text{Var}(x-y) = E(x-y)^2 - [E(x-y)]^2$$

$$E(x-y)^2 = \int_0^4 \int_0^1 (x-y)^2 \left(x - \frac{1}{4}xy\right) dx dy = \frac{25}{18}$$

$$[E(x-y)]^2 = [E(x) - E(y)]^2 = \left(\frac{2}{3} - \frac{4}{3}\right)^2 = \frac{4}{9}$$

$$\text{Var}(x-y) = \frac{25}{18} - \frac{4}{9} = \frac{17}{18}$$

Los resultados anteriores pueden generalizarse fácilmente a n variables.

Sean $x_1, x_2, \dots, x_n$, n variables aleatorias en el espacio S , con función de densidad conjunta $f(x_1, x_2, \dots, x_n)$, entonces:

Sea $g(x_1, x_2, \dots, x_n)$ una función de $x_1, x_2, \dots, x_n$

$$E[g(x_1, x_2, \dots, x_n)] = \sum_{(x_1, x_2, \dots, x_n)} g(x_1, x_2, \dots, x_n) f(x_1, x_2, \dots, x_n)$$

si son discretas

$$= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} g(x_1, x_2, \dots, x_n) f(x_1, x_2, \dots, x_n) dx_1 dx_2 \dots dx_n$$

si son continuas

Sea $g_1(x_1, \dots, x_n), g_2(x_1, \dots, x_n), \dots, g_m(x_1, \dots, x_n)$ m funciones de $x_1, x_2, \dots, x_n$

entonces:

$$E[g_1(\cdot) + g_2(\cdot) + \dots + g_m(\cdot)] = E[g_1(\cdot)] + E[g_2(\cdot)] + \dots + E[g_m(\cdot)]$$

o sea, el valor esperado de una suma de funciones de las variables es igual a la suma de los valores esperados; en particular

$$E[x_1 + x_2 + \dots + x_n] = E(x_1) + E(x_2) + \dots + E(x_n)$$

$$E[x_1 - x_2 - \dots - x_n] = E(x_1) - E(x_2) - \dots - E(x_n)$$

o sea, el valor esperado de la suma (diferencia) de variables es igual a la suma (diferencia) de los valores esperados,

$$E(x_1 x_2 \dots x_n) = E(x_1) E(x_2) \dots E(x_n)$$

si $x_1, x_2, \dots, x_n$ son independientes.

El valor esperado del producto de n variables independientes es igual al producto de los valores esperados.

Sean $g_1(x_1), g_2(x_2), \dots, g_n(x_n)$ funciones de $x_1, x_2, \dots, x_n$ respectivamente, entonces

$$E[g_1(x_1) g_2(x_2) \dots g_n(x_n)] = E[g_1(x_1)] E[g_2(x_2)] \dots E[g_n(x_n)]$$

si $x_1, x_2, \dots, x_n$ son independientes; o sea, que el valor esperado del producto de funciones de variables independientes es igual al producto de los valores esperados.

$$\text{Var}(x_1 + x_2 + \dots + x_n) = \text{Var}(x_1) + \text{Var}(x_2) + \dots + \text{Var}(x_n)$$

si $x_1, x_2, \dots, x_n$ son independientes.

Por último, veamos una importante propiedad de las variables independientes:

Si $x_1, x_2, \dots, x_n$ son n variables independientes, la función generatriz de momentos de su suma es igual al producto de las funciones generatrices de momentos de cada una.

Prueba:

$$\text{Sea } W = x_1 + x_2 + x_3 + \dots + x_n$$

La función generatriz de momentos de W

$$\begin{aligned} m_w(k) &= E[e^{wk}] = E[e^{(x_1+x_2+\dots+x_n)k}] = \\ &= E[e^{x_1k} e^{x_2k} \dots e^{x_nk}] = E(e^{x_1k}) E(e^{x_2k}) \dots E(e^{x_nk}) = \\ &= m_{x_1}(k) m_{x_2}(k) \dots m_{x_n}(k) \end{aligned}$$

EJERCICIOS RESUELTOS

3.1. La función de densidad conjunta de dos variables aleatorias x e y es:

$$\begin{array}{ll} f(0,1) = 2/12 & f(1,1) = 2/12 \\ f(0,2) = 3/12 & f(1,2) = 3/12 \\ f(0,3) = 1/12 & f(1,3) = 1/12 \end{array}$$

- Comprobar que las variables x e y son independientes;
- Calcular $E(xy)$
- $\text{Var}(x+y)$.

Solución:

- Calculemos primero $f(x)$ y $f(y)$

$$f_x(0) = \sum_y f(0,y) = \frac{2}{12} + \frac{3}{12} + \frac{1}{12} = \frac{1}{2}$$

$$f_x(1) = \sum_y f(1,y) = \frac{2}{12} + \frac{3}{12} + \frac{1}{12} = \frac{1}{2}$$

$$f(x) = \frac{1}{2} \quad \text{para } x = 0, 1$$

$$f_y(1) = \sum_x f(x,1) = \frac{2}{12} + \frac{2}{12} = \frac{4}{12}$$

$$f_y(2) = \sum_x f(x,2) = \frac{3}{12} + \frac{3}{12} = \frac{6}{12}$$

$$f_y(3) = \sum_x f(x,3) = \frac{1}{12} + \frac{1}{12} = \frac{2}{12}$$

$$f(y) = \begin{cases} \frac{4}{12} & \text{para } y = 1 \\ \frac{6}{12} & \text{para } y = 2 \\ \frac{2}{12} & \text{para } y = 3 \end{cases}$$

Para que sean independientes $f(x,y) = f(x) f(y) \quad \forall (x,y)$

$$f(0,1) = \frac{2}{12} = \frac{1}{2} \frac{4}{12} = f_x(0) f_y(1)$$

$$f(0,2) = \frac{3}{12} = \frac{1}{2} \frac{6}{12} = f_x(0) f_y(2)$$

$$f(0,3) = \frac{1}{12} = \frac{1}{2} \frac{2}{12} = f_x(0) f_y(3)$$

$$f(1,1) = \frac{2}{12} = \frac{1}{2} \frac{4}{12} = f_x(1) f_y(1)$$

$$f(1,2) = \frac{3}{12} = \frac{1}{2} \frac{6}{12} = f_x(1) f_y(2)$$

$$f(1,3) = \frac{1}{12} = \frac{1}{2} \frac{2}{12} = f_x(1) f_y(3)$$

x e y son independientes

- $E(xy) = E(x)E(y)$ por ser independientes

$$E(x) = \sum x f(x) = 0 \frac{1}{2} + 1 \frac{1}{2} = \frac{1}{2}$$

$$E(y) = \sum y f(y) = 1 \frac{4}{12} + 2 \frac{6}{12} + 3 \frac{2}{12} = \frac{11}{6}$$

$$E(xy) = \frac{1}{2} \frac{11}{6} = \frac{11}{12}$$

iii) $\text{Var}(x+y) = \text{Var}(x) + \text{Var}(y)$ por ser independientes.

$$\text{Var}(x) = E(x^2) - [E(x)]^2$$

$$E(x^2) = 0 \frac{1}{2} + 1 \frac{1}{2} = \frac{1}{2} \Rightarrow \text{Var}(x) = \frac{1}{2} - \frac{1}{4} = \frac{1}{4}$$

$$\text{Var}(y) = E(y^2) - [E(y)]^2$$

$$E(y^2) = 1 \frac{4}{12} + 4 \frac{6}{12} + 9 \frac{2}{12} = \frac{23}{6} \Rightarrow \text{Var}(y) = \frac{23}{6} - \frac{121}{36} = \frac{17}{36}$$

$$\text{Var}(x+y) = \frac{1}{4} + \frac{17}{36} = \frac{13}{18}$$

3.2. Sean x y y dos variables aleatorias definidas en el espacio muestral S con la siguiente función de densidad conjunta:

$$f(x, y) = \frac{1}{13}x + \frac{2}{39}y \quad \text{para } 0 \leq x \leq 3, 0 \leq y \leq 2$$

Calcular: i) $P(0 \leq x \leq 1, y > 1)$; ii) función de densidad marginal de x ; iii) función de densidad marginal de y ; iv) función de densidad condicional de x dada y ; ¿Son x e y independientes?; v) $\text{Cov}(x, y)$; vi) $E(x/y = 1)$.

Solución:

$$\begin{aligned} \text{i) } P(0 \leq x \leq 1, y > 1) &= \int_1^2 \int_0^1 \left(\frac{1}{13}x + \frac{2}{39}y \right) dx dy = \\ &= \int_1^2 dy \left(\frac{1}{13} \frac{x^2}{2} + \frac{2}{39}xy \right) \Big|_0^1 = \int_1^2 \left(\frac{1}{26} + \frac{2}{39}y \right) dy = \\ &= \left(\frac{1}{26}y + \frac{y^2}{39} \right) \Big|_1^2 = \frac{2}{26} + \frac{4}{39} - \frac{1}{26} - \frac{1}{39} = \frac{3}{26} \end{aligned}$$

$$\begin{aligned} \text{ii) } f(x) &= \int_{-\infty}^{+\infty} f(x, y) dy = \int_0^2 \left(\frac{1}{13}x + \frac{2}{39}y \right) dy = \\ &= \left(\frac{1}{13}xy + \frac{y^2}{39} \right) \Big|_0^2 = \frac{2}{13}x + \frac{4}{39} \end{aligned}$$

$$f(x) = \frac{2}{13}x + \frac{4}{39} \quad \text{para } 0 \leq x \leq 3$$

$$\begin{aligned} \text{iii) } f(y) &= \int_{-\infty}^{+\infty} f(x, y) dx = \int_0^3 \left(\frac{1}{13}x + \frac{2}{39}y \right) dx = \\ &= \left(\frac{1}{13} \frac{x^2}{2} + \frac{2}{39}yx \right) \Big|_0^3 = \frac{9}{26} + \frac{2}{13}y \end{aligned}$$

$$f(y) = \frac{2}{13}y + \frac{9}{26} \quad \text{para } 0 \leq y \leq 2$$

$$\text{iv) } f(x/y) = \frac{f(x, y)}{f(y)} = \frac{\frac{1}{13}x + \frac{2}{39}y}{\frac{9}{26} + \frac{2}{13}y} \quad \text{para } 0 \leq x \leq 3, 0 \leq y \leq 2$$

$f(x/y) \neq f(x)$ No son independientes.

$$\text{v) } \text{Cov}(x, y) = E(xy) - E(x)E(y)$$

$$E(xy) = \int_0^2 \int_0^3 xy \left(\frac{1}{13}x + \frac{2}{39}y \right) dx dy = \frac{78}{39}$$

$$E(x) = \int_0^3 x \left(\frac{2}{13}x + \frac{4}{39} \right) dx = \frac{24}{13}$$

$$E(y) = \int_0^2 y \left(\frac{2}{13}y + \frac{9}{26} \right) dy = \frac{43}{39}$$

$$\text{Cov}(x, y) = \frac{78}{39} - \frac{24}{13} \frac{43}{39} = -\frac{6}{169}$$

$$\begin{aligned} \text{vi) } E(x/y) &= \int_{-\infty}^{+\infty} x f(x/y) dx = \int_0^3 x \frac{\frac{1}{13}x + \frac{2}{39}y}{\frac{2}{13}y + \frac{9}{26}} dx = \\ &= \frac{9/13 + 9/39 y}{2/13 y + 9/26} \quad \text{para } 0 \leq y \leq 2 \end{aligned}$$

$$E(x/y=1) = \frac{9/13 + 9/39}{2/13 + 9/26} = \frac{24}{13}$$

3.3. En una caja hay 8 fichas numeradas del 1 al 8. Se extrae una ficha al azar; sea z una variable aleatoria que representa el número de la ficha extraída; sean x e y dos variables aleatorias funciones de z definidas como sigue:

Si $z = 1, 2, 3, 4$ entonces $x = -2, y = 1$

Si $z = 5, 6$ entonces $x = 1, y = -2$

Si $z = 7$ entonces $x = 1, y = 0$

Si $z = 8$ entonces $x = 2, y = 3$

Calcular: i) La función de densidad conjunta de x e y ; ii) La función de densidad marginal de x ; iii) La función de densidad marginal de y .

Solución:

1) Si $z = 1, 2, 3, 4$ $(x, y) = (-2, 1)$

Si $z = 5, 6$ $(x, y) = (1, -2)$

Si $z = 7$ $(x, y) = (1, 0)$

Si $z = 8$ $(x, y) = (2, 3)$

$$P(x = -2, y = 1) = P(z = 1, 2, 3 \text{ o } 4) = \frac{1}{8} + \frac{1}{8} + \frac{1}{8} + \frac{1}{8} = \frac{1}{2}$$

$$P(x = 1, y = -2) = P(z = 5 \text{ o } 6) = \frac{1}{8} + \frac{1}{8} = \frac{1}{4}$$

$$P(x = 1, y = 0) = P(z = 7) = 1/8$$

$$P(x = 2, y = 3) = P(z = 8) = 1/8$$

Luego,

$f(x, y)$	1/2	1/4	1/8	1/8
(x, y)	(-2, 1)	(1, -2)	(1, 0)	(2, 3)

ii) Para calcular $f(x)$ tenemos que x puede ser igual a -2, 1, 2;

$$f(-2) = f(-2, 1) = 1/2$$

$$f(1) = f(1, 2) + f(1, 0) = 3/8$$

$$f(2) = f(2, 3) = 1/8, \text{ luego } f(x) \text{ será}$$

x	-2	1	2
$f(x)$	1/2	3/8	1/8

iii) Para calcular $f(y)$;

$$f(-2) = f(1, -2) = 1/4$$

$$f(0) = f(1, 0) = 1/8$$

$$f(1) = f(-2, 1) = 1/2$$

$$f(3) = f(2, 3) = 1/8$$

Luego $f(y)$ será,

y	-2	0	1	3
$f(y)$	1/4	1/8	1/2	1/8

3.4. Dos variables aleatorias x e y tienen la siguiente función de densidad conjunta:

$$f(x, y) = \frac{1}{4} \quad \text{para } 0 \leq x \leq 2, 0 \leq y \leq 2$$

$$= 0 \quad \text{para cualesquiera otros valores de } x \text{ e } y$$

Calcular: i) $P(x < 1, y < 1)$ ii) función de densidad marginal de x ; iii) función de densidad marginal de y ; iv) función de densidad condicional de x , dado y ; v) función de densidad condicional de y , dado x ; vi) ¿Son x e y independientes?

Solución:

$$\begin{aligned} \text{i) } P(x < 1, y < 1) &= \int_0^1 \int_0^1 \frac{1}{4} dx dy = \int_0^1 \frac{1}{4} dx \int_0^1 dy = \\ &= \int_0^1 \frac{1}{4} dx(y) \Big|_0^1 = \int_0^1 \frac{1}{4} dx = \frac{x}{4} \Big|_0^1 = \frac{1}{4} \end{aligned}$$

$$\text{ii) } f(x) = \int_{-\infty}^{+\infty} f(x, y) dy = \int_0^2 \frac{1}{4} dy = \frac{1}{2} \text{ para } 0 \leq x \leq 2$$

$$\text{iii) } f(y) = \int_{-\infty}^{+\infty} f(x, y) dx = \int_0^2 \frac{1}{4} dx = \frac{1}{2} \text{ para } 0 \leq y \leq 2$$

$$\text{iv) } f(x/y) = \frac{f(x, y)}{f(y)} = \frac{1/4}{1/2} = 1/2 \text{ para } 0 \leq x \leq 2, 0 \leq y \leq 2$$

$$\text{v) } f(y/x) = \frac{f(x, y)}{f(x)} = \frac{1/4}{1/2} = 1/2 \text{ para } 0 \leq y \leq 2, 0 \leq x \leq 2$$

$$\text{vi) } f(x, y) = \frac{1}{4} \text{ para } 0 \leq x \leq 2, 0 \leq y \leq 2$$

$$f(x) = \frac{1}{2} \text{ para } 0 \leq x \leq 2$$

$$f(y) = \frac{1}{2} \text{ para } 0 \leq y \leq 2$$

$$f(x)f(y) = f(x, y)$$

Luego son independientes.

Además, $f(x/y) = f(x)$ y $f(y/x) = f(y)$

3.5. Sean x e y dos variables aleatorias con la siguiente función de densidad conjunta $f(x, y) = 1/3$ para $(x, y) = (-1, 1), (0, 0), (1, 1)$.

i) ¿Son x e y independientes? ii) Calcular la covarianza de x e y .

Solución:

$$\text{i) } f(x) = \frac{1}{3} \text{ para } x = -1, 0, 1$$

$$f(y) = \frac{1}{3} \text{ para } y = 0$$

$$= \frac{2}{3} \text{ para } y = 1$$

Para que sean independientes $f(x, y) = f(x)f(y) \quad \forall (x, y)$

Sin embargo

$$f(-1, 1) = \frac{1}{3}; \quad f(-1)f(1) = \frac{1}{3} \cdot \frac{2}{3} = \frac{2}{9};$$

Luego x e y no son estadísticamente independientes.

$$\text{ii) } \text{Cov}(x, y) = E(xy) - E(x)E(y)$$

xy	Probabilidades
-1	1/3
0	1/3
1	1/3

$$E(xy) = -1 \cdot \frac{1}{3} + 0 \cdot \frac{1}{3} + 1 \cdot \frac{1}{3} = 0$$

$$E(x) = -1 \cdot \frac{1}{3} + 0 \cdot \frac{1}{3} + 1 \cdot \frac{1}{3} = 0$$

$$E(y) = 0 \cdot \frac{1}{3} + 1 \cdot \frac{2}{3} = \frac{2}{3}$$

$$\text{Cov}(x, y) = 0 - 0 = 0$$

EJERCICIOS PROPUESTOS

3.6. En el ejercicio 3.3, calcular i) $E(xy)$; ii) $P(y \leq 0/x < 2)$; iii) $P(x+y < 4/y \geq 0)$; iv) ¿Son x e y independientes?

3.7. Un experimento consiste en lanzar dos dados. Se define una variable aleatoria x como la suma de los dos dados y una variable aleatoria y que representa el resultado del primer dado.

Calcular: i) La función de densidad conjunta de x y y ; ii) La función de densidad marginal de x ; iii) La función de densidad marginal de y .

3.8. En el ejercicio anterior calcular: i) La función de densidad condicional de x , dado que $y = 4$; ii) $E(x+y)$; iii) $E(x, y)$; iv) $Cov(x, y)$.

3.9. Dadas las siguientes funciones de densidad conjunta y marginales de x y y .

$y \backslash x$	2	4	6	8	$f(y)$
2	14/100	4/100	2/100	0	20/100
4	4/100	18/100	26/100	2/100	50/100
6	2/100	8/100	12/100	8/100	30/100
$f(x)$	20/100	30/100	40/100	10/100	1

Calcular: i) $P(y < 2x)$; ii) $P(y \leq x/2)$; iii) $P(x = y)$

3.10. Una empresa produce tres artículos A, B y C. Las ventas diarias (en miles de bolívares) son variables aleatorias representadas por x, y, z respectivamente. La función de densidad conjunta de x, y, z es

$$f(x, y, z) = \frac{1}{2} y z^2 e^{-x} e^{-y} e^{-z} \quad \text{para } x, y, z > 0$$

= 0 para cualesquiera otros valores de x, y, z .

i) Calcular las funciones de densidad marginales de las ventas de cada artículo; ii) Calcular la probabilidad de que las ventas del artículo A sean mayores que Bs. 3.000, las ventas del artículo B mayores que Bs. 5.000, y las del artículo C menores que Bs. 6.000; iii) Calcular la probabilidad de que las ventas de A sean mayores que Bs. 3.000, dado que las ventas de B son mayores que Bs. 1.000.

$$\left(\text{Nota: } \int_0^{\infty} x^k e^{-x} dx = k! \right)$$

3.11. En el ejercicio anterior calcular: i) El valor esperado de las ventas de cada artículo y sus varianzas; ii) El valor esperado y varianza de las ventas totales.

3.12. Si se lanzan 3 monedas, sea U el número de caras y V el número de sellos que aparecen. Definamos las siguientes variables aleatorias:

$$W = U + V, \quad X = U - V, \quad Y = |U - V|, \quad Z = \max(U, V). \quad \text{Calcular: i) } P(W \leq 1);$$

$$\text{ii) } P(X \leq 1); \quad \text{iii) } P(Y \leq 1); \quad \text{iv) } P(Z \leq 1).$$

3.13. Dada la siguiente función de densidad conjunta

$$f(x, y) = 4y(1-x) \quad \text{para } 0 < x < 1, 0 < y < 1.$$

Encontrar la función de densidad condicional de y , dado que x es menor que $1/2$.

3.14. Demostrar que si x y y son 2 variables aleatorias continuas independientes, su covarianza es igual a cero, probando que: $E(xy) = E(x)E(y)$

3.15. Sea x una variable aleatoria que representa las ventas anuales medidas en millones de bolívares de una empresa, e y una variable aleatoria que representa los gastos anuales en propaganda, medidos en cientos de miles de bolívares, de una empresa competidora; x y y tienen la siguiente función de densidad conjunta.

$$f(x, y) = \frac{1}{8}(6 - x - y) \quad \text{para } 2 < x < 4, 0 < y < 2$$

i) ¿Son x y y independientes?; ii) Calcular el coeficiente de correlación.

3.16. En el ejercicio anterior calcular el valor esperado de las ventas, dado que los gastos de propaganda fueron i) Bs. 150.000, ii) Bs. 200.000; iii) ¿Cuál es la probabilidad de que las ventas sean mayores de Bs. 3.000.000, dado que los gastos fueron Bs. 150.000?

3.17. La demanda de gas doméstico medida en miles de m^3 es una variable aleatoria. Si x representa la demanda de un mes e y la demanda del mes siguiente, su función de densidad conjunta es:

$$f(x, y) = 6xy(2 - x - y) \quad \text{para } 0 \leq x, y \leq 1$$

i) ¿Son las demandas independientes?; ii) Calcular el valor esperado de la demanda del segundo mes si la demanda en el primer mes fue de 750 m^3 .

3.18. En el ejercicio anterior, calcular: i) La probabilidad de que las ventas del segundo mes sean mayores que 500, dado que las del primero fueron 750 m^3 ; ii) La probabilidad de que las ventas del segundo mes sean mayores que 500, dado que las del primer mes fueron menores que 250; iii) El valor esperado de la demanda total; iv) Covarianza y coeficiente de correlación de las ventas.

3.19. Sean x y y dos variables con la siguiente función de densidad conjunta:

$$f(x, y) = \frac{1}{4} \quad \text{para } (x, y) = (-2, 4), (-1, 1), (2, 4), (1, 1)$$

$$= 0 \quad \text{para cualesquiera otros valores de } x \text{ y } y$$

i) ¿Son x e y estadísticamente independientes? ii) Calcular el coeficiente de correlación.

3.20. Sean x e y dos variables aleatorias con la siguiente función de densidad conjunta.

$$f(x, y) = \frac{n!}{(n-y)!y!x!} e^{-\lambda} \lambda^{x+y} (1-\lambda)^{n-y} \quad \text{para } \begin{array}{l} x = 0, 1, 2, \dots \\ y = 0, 1, 2, \dots, n \\ 0 < \lambda < 1 \end{array}$$

Calcular i) La función de densidad marginal de x ; ii) La función de densidad condicional de y , dado x

3.21. Una empresa fabrica dos bienes cuya demanda es aleatoria con la siguiente función de densidad conjunta.

$$f(x, y) = \frac{x+y}{15.000} \quad \text{para } \begin{array}{l} 0 \leq x \leq 20 \\ 0 \leq y \leq 30 \end{array}$$

El ingreso y costo totales, funciones de las cantidades producidas y demandas son los siguientes:

$$\text{Ingresos} = 4x^2y^2 - xy + 3x + 2y; \text{Costos} = 2x^2y + xy^2$$

Calcular el beneficio esperado.

3.22. Determine razonadamente la veracidad o falsedad de las siguientes afirmaciones:

- Si x e y son dos variables aleatorias continuas con funciones de densidad $f(x) > 0$ para $a \leq x \leq b$ y $f(y) > 0$ para $c \leq y \leq d$, siendo $d > b$ y $c > a$, se puede concluir que $E(x) \geq E(y)$.
- Dadas tres variables aleatorias x, y, z , con función de densidad conjunta $f(x, y, z)$. Si se cumple que $f(x/y) = f(x)$ y que $f(z/y) = f(z)$ se puede concluir que x y z son independientes.
- Si la covarianza de x e y es mayor que la unidad se puede concluir que las variables son independientes.

3.23. Determine razonadamente cuál de las respuestas es correcta en:

La función generatriz de momentos de la suma de dos variables aleatorias x e y es igual a:

- La suma de las funciones generatrices de cada una de ellas.
- El producto de las funciones generatrices de cada una de ellas.
- Ninguna de las anteriores.

CAPITULO IV

DISTRIBUCIONES DE VARIABLES ALEATORIAS DISCRETAS

4.1. INTRODUCCION

En los Capítulos II y III se introdujeron los conceptos de variables aleatorias y sus correspondientes funciones de densidad.

El lector habrá notado que la mayoría de las variables usadas en ambos capítulos no representaban ningún fenómeno real sino que solamente se presentaban de tal forma que cumplieran las condiciones matemáticas que debe tener una función para ser una función de densidad; es decir $f(x) \geq 0$ y

$$\sum_x f(x) = 1 \quad \text{o} \quad \int_{-\infty}^{+\infty} f(x) dx = 1$$

De esta manera se cumplía el objetivo de esos capítulos que era el familiarizar al estudiante con el concepto y manejo de los distintos aspectos de las variables aleatorias.

Este capítulo y el que sigue se dedicarán al estudio de variables aleatorias que representan fenómenos reales y de sus distribuciones de probabilidades, aplicando los conceptos desarrollados anteriormente.

En este Capítulo se tratarán las variables aleatorias discretas y en el siguiente las variables aleatorias continuas.

4.2. DISTRIBUCION BINOMIAL

Consideremos un experimento en el cual sólo estamos interesados en la ocurrencia o no de un determinado suceso. Si designamos por "p" la probabilidad de que el suceso ocurra, "p" será un número comprendido entre 0 y 1. La probabilidad de que el suceso no ocurra la designamos por "q"; entonces $p + q = 1$, puesto que el suceso ocurre o no ocurre. Análogamente podríamos decir que si el suceso ocurre, se ha dado un éxito; mientras que si no ocurre, se ha dado una falla. La probabilidad de éxito será entonces "p", la de falla "q".

EJEMPLO 4.1.

Supongamos que al extraer una carta de un mazo de 52 cartas estamos interesados en el suceso de que la carta sea un 6. Aquí tenemos un experimento donde los posibles resultados pueden ser clasificados en dos: que obtengamos un 6 (éxito), o que no obtengamos un 6 (falla). En este caso $p = 4/52$ y $q = 48/52$.

Definamos una variable aleatoria x, que es igual a 1 si obtenemos un 6 e igual a cero si no obtenemos un 6. Evidentemente:

$$P(x = 1) = \frac{4}{52} \quad \text{y} \quad P(x = 0) = \frac{48}{52}$$

luego podríamos decir que la función de densidad de x es

$$f(x) = \left(\frac{4}{52}\right)^x \left(\frac{48}{52}\right)^{1-x} \quad \text{para } x = 0, 1$$

En general, en estos experimentos aleatorios con dos posibles resultados podremos definir una variable aleatoria x, con la siguiente función de densidad.

$$f(x) = p^x q^{1-x} \quad \text{para } x = 0, 1$$

Esta variable se conoce como variable Bernoulli, y su distribución se conoce como punto - binomial.

Obviamente f(x) cumple las condiciones matemáticas para ser una función de probabilidades.

Demos ahora un paso adelante e imaginemos que este tipo de experimento lo realizamos un número n de veces de forma independiente; es decir que el resultado obtenido una de las veces no afecta ni es afectado por los resultados de las otras. En el ejemplo anterior podemos extraer una carta, observar su resultado, devolver la carta, y volver a realizar este experimento n veces.

Definamos una variable aleatoria x como el número de éxitos obtenidos al realizar n veces el experimento. En el ejemplo x sería el número de veces que obtenemos un 6 al extraer una carta n veces. Es obvio que x puede tomar los valores 0, 1, 2, ..., n. Vamos ahora a determinar la probabilidad de obtener h éxitos en n intentos

Una de las posibles formas de obtener h éxitos en n veces sería obtener h éxitos consecutivos, y después n-h fallas consecutivas. Puesto que los sucesos son independientes esta probabilidad será:

$$\overbrace{ppp \dots p}^h \overbrace{qq \dots q}^{n-h} = p^h q^{n-h}$$

Indudablemente que hay otras formas de obtener h éxitos en n intentos; por ejemplo, obtener un éxito en el primer intento, una falla en el segundo, (h-1) éxitos consecutivos, y por último n-h-1 fallas consecutivas. La probabilidad de obtener cada una de las formas sería:

$$\overbrace{pq \dots pq}^{h-1} \overbrace{pp \dots p}^{n-h-1} q = p^h q^{n-h}$$

En general, cualquier forma de obtener h éxitos en n veces tendrá probabilidad $p^h q^{n-h}$.

Es necesario conocer ahora de cuántas formas diferentes se pueden obtener h éxitos y n-h fallas. Este número es igual al número de permutaciones que se pueden obtener con n elementos, entre los cuales hay h elementos iguales y n-h elementos iguales; o sea,

$$\frac{n!}{h!(n-h)!} = \binom{n}{h}$$

Ahora bien, cada una de estas $\binom{n}{h}$ formas son mutuamente excluyentes; luego la probabilidad de obtener h éxitos, es la suma de las probabilidades de cada forma posible.

$$P(x = h) = \overbrace{p^h q^{n-h} + p^h q^{n-h} + \dots + p^h q^{n-h}}^{\binom{n}{h}} = \binom{n}{h} p^h q^{n-h}$$

Concluimos entonces que la función de densidad de x es

$$f(x) = \binom{n}{x} p^x q^{n-x} \quad \text{para } x = 0, 1, 2, \dots, n$$

En este caso, x es una variable aleatoria distribuida según una distribución binomial de probabilidades, siendo n y p los parámetros de la función. También es posible decir que x es una variable aleatoria distribuida binomialmente con parámetros n y p .

Debemos comprobar que en efecto $f(x) = \binom{n}{x} p^x q^{n-x}$ para $x = 0, 1, \dots, n$ es una función de densidad. Como sabemos, debe cumplir dos propiedades:

$$f(x) \geq 0 \quad \forall x \quad \text{y} \quad \sum_x f(x) = 1$$

La primera propiedad obviamente se cumple. En cuanto a la segunda, observemos:

$$\sum_x f(x) = \sum_{x=0}^n \binom{n}{x} p^x q^{n-x} = \binom{n}{0} p^0 q^n + \binom{n}{1} p^1 q^{n-1} + \dots + \binom{n}{n} p^n q^0$$

Los términos de la sumatoria corresponden al desarrollo del binomio de Newton; luego,

$$\sum_{x=0}^n \binom{n}{x} p^x q^{n-x} = (p+q)^n = 1$$

EJEMPLO 4.2.

En el ejemplo anterior queremos saber la probabilidad de obtener 2 veces un 6, al sacar una carta con reemplazamiento 6 veces.

Si designamos por x el número de veces que obtenemos 6, tendremos $p = 4/52$, $q = 48/52$, $n = 6$.

$$P(x=2) = f(2) = \binom{6}{2} \left(\frac{4}{52}\right)^2 \left(\frac{48}{52}\right)^4 = 0,0644$$

EJEMPLO 4.3.

En una encuesta realizada en los barrios de Caracas, el 70% de los encuestados contestaron incorrectamente al cuestionario. De una muestra de 4 cuestionarios tomados al azar, ¿Cuál es la probabilidad de que 3 cuestionarios estuvieran correctamente contestados?

Si designamos por x el número de cuestionarios incorrectamente contestados, x será una variable aleatoria distribuida binomialmente con parámetros $n = 4$ y $p = 0,7$.

La probabilidad de que 3 cuestionarios estén correctamente contestados es igual a la probabilidad de que uno esté incorrectamente contestado, es decir, que x sea igual a 1.

$$P(x=1) = f(1) = \binom{4}{1} 0,7^1 0,3^3 = 0,0756$$

¿Cuál es la probabilidad de que más de 2 cuestionarios estén contestados correctamente?

$$P(x=0) + P(x=1) = \sum_{x=0}^1 \binom{4}{x} 0,7^x 0,3^{4-x} = 0,0081 + 0,0756 = 0,0837$$

4.3. VALOR ESPERADO Y VARIANZA DE UNA VARIABLE DISTRIBUIDA BINOMIALMENTE

La función generatriz de momentos de la variable aleatoria x distribuida binomialmente con parámetros n y p es:

$$m_x(k) = E[e^{xk}] = \sum_{x=0}^n e^{xk} \binom{n}{x} p^x q^{n-x} = \sum_{x=0}^n \binom{n}{x} (e^k p)^x q^{n-x} = (e^k p + q)^n$$

La primera derivada con respecto a k de $m_x(k)$ es:

$$\frac{d}{dk} m_x(k) = \frac{d}{dk} (e^k p + q)^n = n(e^k p + q)^{n-1} e^k p$$

$$E(x) = \left. \frac{d}{dk} m_x(k) \right|_{k=0} = n(e^0 p + q)^{n-1} e^0 p = np$$

Luego, la media de una variable binomial es igual al número de veces que el experimento se realiza por la probabilidad de éxito cada vez.

La segunda derivada con respecto a k de $m_x(k)$ es:

$$\frac{d^2}{dk^2} m_x(k) = np \left[(e^k p + q)^{n-1} e^k + e^k (n-1) (e^k p + q)^{n-2} e^k p \right]$$

Para $k = 0$,

$$E(x^2) = \left. \frac{d^2}{dk^2} m_x(k) \right|_{k=0} = np[1 + (n-1)p] = n(n-1)p^2 + np$$

La varianza de x es

$$\sigma_x^2 = \text{Var}(x) = n(n-1)p^2 + np - n^2p^2 = np(1-p) = npq$$

Luego, la varianza de una variable binomial es igual al producto del número de veces que el experimento se realiza por la probabilidad de éxito, por la probabilidad de falla.

EJEMPLO 4.4.

En el ejemplo 4.3 calcular $E(x)$ y $\text{Var}(x)$.

$$E(x) = 4 \cdot 0,7 = 2,8$$

$$\text{Var}(x) = 4 \cdot 0,7 \cdot 0,3 = 0,84$$

EJEMPLO 4.5.

Si se sabe que una variable aleatoria se distribuye binomialmente con media 18,2 y varianza 1,638, calcular n y p .

$$E(x) = np = 18,2; \quad \text{Var}(x) = np(1-p) = 1,638$$

$$18,2(1-p) = 1,638 \Rightarrow p = 0,91, \quad n = 20$$

Teorema: Si $x_1, x_2, \dots, x_m$ son variables independientes que se distribuyen binomialmente con parámetros n_1 y p , n_2 y $p, \dots, n_m$ y p respectivamente, entonces su suma $(x_1 + x_2 + \dots + x_m)$ se distribuye binomialmente con parámetros $n_1 + n_2 + \dots + n_m$ y p .

Prueba:

La función generatriz de momentos de una variable binomial es $m_x(k) = (e^k p + q)^n$

Luego:

$$m_{x_1}(k) = (e^k p + q)^{n_1}; \quad m_{x_2}(k) = (e^k p + q)^{n_2}; \dots$$

Sabemos que la función generatriz de momentos de la suma de variables aleatorias independientes es igual al producto de las funciones generatrices de momentos de cada una (Ver sección 3.5).

$$m_{x_1 + x_2 + \dots + x_m}(k) = m_{x_1}(k) m_{x_2}(k) \dots m_{x_m}(k) =$$

$$= (e^k p + q)^{n_1} (e^k p + q)^{n_2} \dots (e^k p + q)^{n_m} =$$

$$= (e^k p + q)^{n_1 + n_2 + \dots + n_m}$$

Esta es la función generatriz de momentos de una variable binomial con parámetros $n_1 + n_2 + \dots + n_m$ y p , y es la función generatriz de momentos de $x_1 + x_2 + \dots + x_m$; luego, esta suma es una variable binomial con parámetros $n_1 + n_2 + \dots + n_m$ y p .

4.4. DISTRIBUCION GEOMETRICA

Otra distribución de probabilidades de variables aleatorias discretas usada frecuentemente en la estadística aplicada es la conocida como distribución geométrica.

Si realizamos un experimento punto-binomial n veces, se puede definir una variable aleatoria x que represente el número de veces que se realiza el experimento hasta obtener el primer éxito o, lo que es lo mismo, hasta que el suceso en que estamos interesados se dé por primera vez. Los posibles valores de x serán 1, 2, 3, 4,

Para determinar la función de densidad de x , notemos que para que el primer éxito se dé en el intento h , $h = 1, 2, 3, \dots$, los primeros $h-1$ intentos deben haber sido fallas, luego:

$$P(x = h) = (1-p)(1-p) \dots (1-p)p = (1-p)^{h-1}p$$

en consecuencia $f(x)$ será:

$$f(x) = p(1-p)^{x-1} \quad \text{para } x = 1, 2, 3, 4, \dots$$

$$= 0 \quad \text{para cualquier otro valor de } x$$

EJEMPLO 4.6.

Queremos saber cuál es la probabilidad de que al extraer (con reemplazamiento) una carta aparezca el primer 6 en el intento número 4.

x es la variable aleatoria que nos dice el número de veces que debemos extraer la carta, hasta obtener el primer 6; $p = 4/52$; luego:

$$P(x = 4) = 4/52 (48/52)^3 = 0,0605$$

Vamos a comprobar que $f(x) = p(1-p)^{x-1}$ para $x = 1, 2, 3, 4, \dots$ es una función de densidad.

$f(x)$ es obviamente mayor o igual a cero para todo valor de x .

$$\sum_x f(x) = \sum_{x=1}^{\infty} p(1-p)^{x-1} = p \sum_{x=1}^{\infty} (1-p)^{x-1}$$

$\sum_{x=1}^{\infty} (1-p)^{x-1}$ es la suma de los términos de una progresión geométrica indefinida con razón $(1-p)$; luego:

$$\sum_x f(x) = p \sum_{x=1}^{\infty} (1-p)^{x-1} = p \frac{1}{1-(1-p)} = 1$$

4.5. VALOR ESPERADO Y VARIANZA DE UNA VARIABLE ALEATORIA DISTRIBUIDA GEOMETRICAMENTE

La función generatriz de momentos de la variable aleatoria x distribuida geoméricamente es

$$m_x(k) = E[e^{xk}] = \sum_{x=1}^{\infty} e^{xk} p(1-p)^{x-1} = p \sum_{x=1}^{\infty} e^{xk} (1-p)^{x-1}$$

$\sum_{x=1}^{\infty} e^{xk} (1-p)^{x-1}$ es la suma de los términos de una progresión geométrica indefinida con razón igual a $e^k(1-p)$; luego, para $e^k(1-p) < 1$

$$m_x(k) = p \frac{e^k}{1 - e^k(1-p)} = \frac{pe^k}{1 - (1-p)e^k}$$

La primera derivada con respecto a k de $m_x(k)$ es

$$\frac{d}{dk} m_x(k) = \frac{d}{dk} \frac{pe^k}{1 - (1-p)e^k} = \frac{pe^k}{[1 - (1-p)e^k]^2}$$

$$E(x) = \left. \frac{d}{dk} m_x(k) \right|_{k=0} = \frac{p}{p^2} = \frac{1}{p}$$

Calculando la segunda derivada con respecto a k de $m_x(k)$ tenemos:

$$\frac{d^2}{dk^2} m_x(k) = \frac{pe^k [1 - (1-p)^2 e^{2k}]}{[1 - (1-p)e^k]^4}$$

$$E(x^2) = \left. \frac{d^2}{dk^2} m_x(k) \right|_{k=0} = \frac{2-p}{p^2}$$

Luego, la varianza de x es:

$$\text{Var}(x) = E(x^2) - [E(x)]^2 = \frac{2-p}{p^2} - \frac{1}{p^2} = \frac{1-p}{p^2}$$

EJEMPLO 4.7.

En el ejemplo 4.6.

$$E(x) = \frac{52}{4} = 13; \quad \text{Var}(x) = \frac{48/52}{4^2/52^2} = 156$$

4.6. DISTRIBUCION HIPERGEOMETRICA

En la distribución binomial un supuesto fundamental era la independencia de los experimentos realizados y de los resultados obtenidos. Evidentemente que se podrían realizar experimentos con dos posibles resultados en los que la probabilidad de éxito se modifique cada vez que se efectúa el experimento; o sea, que los resultados no son independientes.

Un ejemplo típico de esta clase de experimentos aleatorios es el siguiente:

En una caja hay m fichas rojas y r fichas verdes. Se extraen n fichas sin reemplazamiento, siendo $n \leq m, r$ y se desea saber la probabilidad de que haya h fichas rojas en el grupo de n .

El número de fichas rojas que hay en el grupo de n es una variable aleatoria que puede tomar los valores $0, 1, 2, \dots, n$, y se dice que obedece a una distribución hipergeométrica.

Para calcular la función de densidad de x , obtengamos la probabilidad de que haya h fichas rojas al extraer n fichas.

$$P(x = h) = \frac{C_{m,h} C_{r,n-h}}{C_{m+r,n}}$$

luego la función de densidad de x será:

$$f(x) = \frac{\binom{m}{x} \binom{r}{n-x}}{\binom{m+r}{n}} \quad \text{para } x = 0, 1, 2, 3, \dots, n$$

En general, la distribución hipergeométrica se aplica a aquellas variables que representan el número de éxitos que se obtienen, al realizar n veces un experimento con dos posibles resultados, y en el cual la probabilidad de éxito se modifica con el resultado anterior (sin reemplazamiento).

EJEMPLO 4.8.

En una fábrica de camisas la producción de un determinado día fue de 30 camisas, de las cuales 6 tenían defectos que las hacían invendibles. ¿Cuál es la probabilidad de que de cinco camisas escogidas al azar de la producción del día, ninguna tenga defectos?

En este caso se define x como el número de camisas sin defectos de las 5 elegidas. x es una variable aleatoria hipergeométrica con campo de existencia 0, 1, 2, 3, 4, 5.

Queremos saber la probabilidad de que x sea igual a 5:

$$f(5) = \frac{\binom{24}{5} \binom{6}{0}}{\binom{30}{5}} = 0,2983$$

4.7. VALOR ESPERADO Y VARIANZA DE UNA VARIABLE DISTRIBUIDA HIPERGEOMETRICAMENTE

Se puede demostrar que :

$$E(x) = \frac{mn}{m+r}, \quad \text{Var}(x) = \frac{mn(m+r-n)}{(m+r)^n(m+r-1)}$$

4.8. DISTRIBUCION MULTINOMIAL

Hemos visto que la distribución binomial de la probabilidad de obtener x éxitos, cuando realizamos en forma independiente n veces un experimento aleatorio con dos posibles resultados. En muchos casos podemos realizar experimentos aleatorios con más de dos posibles resultados. En este caso debemos usar la distribución multinomial.

Consideren un experimento donde hay r posibles resultados, donde p_i , $i = 1, \dots, r$ representa la probabilidad de que se dé el suceso i al realizar una vez el experimento. Estamos interesados en conocer la probabilidad de A , siendo A el suceso de que se dé el

suceso 1, S_1 veces; el 2, S_2 veces; el suceso r , S_r veces, al realizar n veces el experimento; es evidente que S_i debe satisfacer la condición

$$\sum_{i=1}^r S_i = n$$

El suceso A puede darse de distintas formas, cada una de las cuales tendrá la probabilidad $p_1^{S_1} p_2^{S_2} \dots p_r^{S_r}$. Estas formas de darse el suceso A son mutuamente excluyentes, por lo cual la probabilidad de A será la suma de las probabilidades de cada una de las formas. El número de formas en que puede obtenerse S_i veces el suceso i , $i = 1, \dots, r$ es igual al número de permutaciones que se pueden obtener con n elementos donde existen S_1 elementos iguales, S_2 elementos iguales, ..., S_r elementos iguales, y este número es

$$\frac{n!}{S_1! S_2! \dots S_r!}$$

En consecuencia,

$$P(A) = \frac{n!}{S_1! S_2! \dots S_r!} p_1^{S_1} p_2^{S_2} \dots p_r^{S_r}$$

Definamos ahora x_i , $i = 1, \dots, r$ como la variable que representa el número de veces que el suceso i es obtenido, al realizar n veces el experimento. La función de densidad conjunta de $x_1, \dots, x_r$ será:

$$f(x_1, x_2, \dots, x_{r-1}) = \frac{n!}{\prod_{i=1}^r x_i!} p_1^{x_1} p_2^{x_2} \dots p_r^{x_r} \quad \text{para } x_i = 0, 1, \dots, n \quad \sum_{i=1}^r x_i = n$$

Observen que la función de densidad está definida para $r-1$ variables, puesto que x_r queda determinada cuando se conocen $x_1, \dots, x_{r-1}$. En el caso de la binomial había dos posibles resultados, pero la función de densidad se refería a una variable; en este caso hay r resultados, y la función de densidad se refiere a $r-1$ variables.

Es ilustrativo observar que la distribución binomial es un caso específico de la multinomial. En efecto, si solamente hay 2 resultados posibles, la distribución multinomial se reduce

$$f(x_1) = \frac{n!}{x_1! x_2!} p_1^{x_1} p_2^{x_2}; \quad x_1, x_2 = 0, 1, \dots, n; \quad x_1 + x_2 = n$$

o sea,

$$f(x_1) = \frac{n!}{x_1! (n-x_1)!} p_1^{x_1} (1-p_1)^{n-x_1}; \quad x_1 = 0, 1, \dots, n$$

que es la distribución binomial.

La distribución multinomial tiene r parámetros, a saber $n, p_1, \dots, p_{r-1}$, puesto que p_r queda determinado en forma única al conocer $p_1, \dots, p_{r-1}$.

EJEMPLO 4.9.

Supongamos que en una fábrica de leche en polvo se produce 3 tipos de leche, clasificados según su contenido en grasas en Tipos A, B y C. Diariamente se producen los distintos tipos en las siguientes proporciones: tipo A, 20%; tipo B, 50%; tipo C, 30%. Si se eligen al azar 6 latas de la producción de un día, ¿cuál es la probabilidad de elegir exactamente 2 latas de cada tipo?

Si definimos x_1 = número de latas del tipo A, x_2 = número de latas del tipo B y x_3 = número de latas del tipo C, tendremos:

$$f(2,2) = \frac{6!}{2!2!2!} 0,2^2 \cdot 0,5^2 \cdot 0,3^2 = 0,081$$

4.9. DISTRIBUCION DE POISSON

Junto con la distribución binomial, la distribución de probabilidades de variables aleatorias discretas más usada en la estadística aplicada es la distribución de Poisson.

La distribución de Poisson se aplica a una variedad grande de fenómenos aleatorios referidos ya sea al espacio o al tiempo. Estos fenómenos aleatorios a los que es aplicable la distribución de Poisson se caracterizan por el número de sucesos que ocurren en un determinado periodo de tiempo, o en un determinado espacio y en los que no tiene sentido hablar del número de sucesos que no han ocurrido. Por ejemplo, en el campo de Investigación de Operaciones, en la teoría de colas se estudian las características del fenómeno aleatorio representado por la llegada de clientes a recibir servicio en un determinado establecimiento, por ejemplo: el número de automóviles que llegan a un autolavado. En este caso, tiene sentido decir que en una hora han llegado x número de automóviles, pero es absurdo preguntar cuántos no han llegado. Otro ejemplo de fenómeno aleatorio que obedece aproximada o exactamente a la distribución de Poisson, sería el que se refiere a imperfecciones en una hoja de papel; tal como se apuntó antes, tiene sentido decir que tiene x defectos, pero no se puede hablar de cuantos no tiene. La hipótesis básica en este tipo de fenómenos es que los sucesos son independientes, es decir, que la ocurrencia de uno no modifica la probabilidad de ocurrencia de los otros. Con esta hipótesis, y siendo x una variable aleatoria que represente el número de sucesos, x se distribuye según la distribución de Poisson, y su función de densidad es

$$f(x) = \frac{e^{-\mu} \mu^x}{x!} \quad \text{para } x = 0, 1, 2, 3, 4, \dots$$

función con un parámetro μ que es mayor que cero. $f(x)$ es efectivamente una función de densidad; $f(x) \geq 0$ para todo valor de x ; además,

$$\begin{aligned} \sum_{x=0}^{\infty} f(x) &= \sum_{x=0}^{\infty} \frac{e^{-\mu} \mu^x}{x!} = \frac{1}{e^{\mu}} \sum_{x=0}^{\infty} \frac{\mu^x}{x!} \\ &= \frac{1}{e^{\mu}} \left(1 + \mu + \frac{\mu^2}{2!} + \frac{\mu^3}{3!} + \dots \right) = \frac{1}{e^{\mu}} e^{\mu} = 1 \end{aligned}$$

puesto que la expresión entre paréntesis es el desarrollo por series de e^{μ}

La justificación matemática de esta función de densidad se expondrá en la Sección 4.11.

4.10. VALOR ESPERADO Y VARIANZA DE UNA VARIABLE DISTRIBUIDA SEGUN LA DISTRIBUCION DE POISSON

La función generatriz de momentos de la variable aleatoria Poisson es

$$\begin{aligned} m_x(k) &= E[e^{xk}] = \sum_{x=0}^{\infty} \frac{e^{xk} e^{-\mu} \mu^x}{x!} = e^{-\mu} \sum_{x=0}^{\infty} \frac{(e^k \mu)^x}{x!} = \\ &= e^{-\mu} \left[1 + e^k \mu + \frac{(e^k \mu)^2}{2!} + \frac{(e^k \mu)^3}{3!} + \dots \right] = \\ &= e^{-\mu} e^{e^k \mu} = e^{e^k \mu - \mu} = e^{\mu(e^k - 1)} \end{aligned}$$

La primera derivada con respecto a k de $m_x(k)$ es:

$$\frac{d}{dk} m_x(k) = \frac{d}{dk} e^{\mu(e^k - 1)} = e^{\mu(e^k - 1)} \mu e^k = \mu e^{e^k \mu - \mu} = \mu e^{\mu(e^k - 1)}$$

$$E(x) = \left. \frac{d}{dk} m_x(k) \right|_{k=0} = e^0 \mu e^0 = \mu$$

De forma que el parámetro (μ) de la función de densidad es la media de la variable.

Noten que μ es la tasa media en que los sucesos ocurren por unidad de tiempo o espacio; es decir, en un intervalo de tiempo o espacio igual a 1. De forma que si nosotros estamos interesados en un tiempo o espacio igual a t , la media para ese intervalo será μt .

EJEMPLO 4.10.

Supongamos que la demanda de un determinado artículo en una tienda obedece a una distribución de Poisson con media de 5 por día. ¿Cuál es la probabilidad de que en 2 días se demanden 20 artículos?

El número de artículos demandados en 2 días es una variable aleatoria (Poisson) con media $5 \times 2 = 10$, luego la probabilidad de que se demanden 20 artículos será:

$$f(20) = \frac{e^{-10} 10^{20}}{20!}$$

La segunda derivada de $m_x(k)$ con respecto a k es,

$$\frac{d^2}{dk^2} m_x(k) = \mu e^{k+\mu(e^k-1)} (1 + \mu e^k)$$

$$E(x^2) = \left. \frac{d^2}{dk^2} m_x(k) \right|_{k=0} = \mu(1 + \mu)$$

La varianza de x será

$$\text{Var}(x) = E(x^2) - [E(x)]^2 = \mu + \mu^2 - \mu^2 = \mu$$

o sea, que en el caso de variables distribuidas según Poisson, la media y la varianza son iguales.

4.11. LA DISTRIBUCION DE POISSON COMO APROXIMACION A LA DISTRIBUCION BINOMIAL

Una de las aplicaciones más interesantes de la distribución es su uso como aproximación al cálculo de las probabilidades de variables binomialmente distribuidas. Cuando en el caso de la binomial el número de veces en que se realiza el experimento es muy grande y la probabilidad de éxito en cada intento es pequeña ($p \leq 0,1$), la distribución binomial puede aproximarse por la distribución de Poisson con parámetro $\mu = np$.

La base teórica de esta aproximación es la siguiente:

$$\begin{aligned} f(x) &= \binom{n}{x} p^x (1-p)^{n-x} = \frac{n(n-1)(n-2)\dots(n-x+1)}{x!} \left(\frac{\mu}{n}\right)^x \left(1 - \frac{\mu}{n}\right)^{n-x} \\ &= \frac{\mu^x \left(1 - \frac{\mu}{n}\right)^n}{x! \left(1 - \frac{\mu}{n}\right)^x} \frac{n(n-1)(n-2)\dots(n-x+1)}{\underbrace{n \cdot n \cdot n \dots n}_x} = \\ &= \frac{\mu^x \left(1 - \frac{\mu}{n}\right)^n}{x! \left(1 - \frac{\mu}{n}\right)^x} \left[\left(1 - \frac{1}{n}\right) \left(1 - \frac{2}{n}\right) \dots \left(1 - \frac{x-1}{n}\right) \right] \end{aligned}$$

Tomando límites cuando $n \rightarrow \infty$, y $p \rightarrow 0$, de tal forma que $np \rightarrow \mu$, tenemos,

$$\lim_{\substack{n \rightarrow \infty \\ p \rightarrow 0}} \binom{n}{x} p^x (1-p)^{n-x} = \lim_{\substack{n \rightarrow \infty \\ p \rightarrow 0}} \frac{\mu^x \left(1 - \frac{\mu}{n}\right)^n}{x! \left(1 - \frac{\mu}{n}\right)^x} \left[\left(1 - \frac{1}{n}\right) \dots \left(1 - \frac{x-1}{n}\right) \right]$$

$$\text{Ahora bien, } \lim_{\substack{n \rightarrow \infty \\ p \rightarrow 0}} \left(1 - \frac{\mu}{n}\right)^n = e^{-\mu}; \quad \lim_{\substack{n \rightarrow \infty \\ p \rightarrow 0}} \left(1 - \frac{\mu}{n}\right)^x = 1$$

y cada uno de los factores del corchete tiende a 1, luego

$$\lim_{\substack{n \rightarrow \infty \\ p \rightarrow 0}} \binom{n}{x} p^x (1-p)^{n-x} = \frac{\mu^x}{x!} e^{-\mu}$$

o sea, que el límite de la función de densidad binomial cuando n tiende a infinito y p tiende a cero, para un valor dado de x es la función de densidad de Poisson para ese mismo valor de x , de donde se puede concluir que para valores grandes de n

$$\binom{n}{x} p^x (1-p)^{n-x} \approx e^{-\mu} \frac{\mu^x}{x!}$$

siendo $\mu = np$.

EJEMPLO 4.11.

Es sabido que el 5% de las semillas de un cierto vegetal que están a la venta en un supermercado, no dan fruto. Las semillas se venden en cajas de 10, y se garantiza que el 90% de las semillas darán fruto. ¿Cuál es la probabilidad de que en una caja determinada la garantía no se cumpla?

La probabilidad pedida es la probabilidad de que una variable aleatoria distribuida binomialmente con parámetros 10 y 0,05, sea mayor que uno.

$$\begin{aligned} P(x > 1) &= 1 - P(x \leq 1) = 1 - \sum_{x=0}^1 \binom{10}{x} 0,05^x 0,95^{10-x} = \\ &= 1 - 0,5987 - 0,3151 = 0,0862 \end{aligned}$$

La aproximación por Poisson será

$$1 - e^{-0,5} 0,5^0 - e^{-0,5} 0,5 = 1 - 0,6065 - 0,3033 = 0,0902$$

Teorema: Si $x_1, x_2, \dots, x_n$ son variables independientes distribuidas según Poisson con medias $\mu_1, \mu_2, \mu_3, \dots, \mu_n$ respectivamente, entonces su suma $x_1 + x_2 + \dots + x_n$ es una variable Poisson con media igual a la suma de las medias ($\mu_1 + \mu_2 + \dots + \mu_n$).

La prueba de este teorema sigue los pasos del teorema de la sección 4.3. y se deja como ejercicio al lector.

EJERCICIOS RESUELTOS

4.1. Una persona lanza diez veces un dado bien balanceado. Halle la probabilidad de que obtenga;

- Un número par las primeras cinco veces, y un número impar las 5 siguientes.
- 5 veces un número par y 5 veces un número impar.
- Al menos 5 veces un número par.
- Un número par en los lanzamientos 2°, 4°, 6°, 8° y 10°, y un número impar en los lanzamientos 1°, 3°, 5°, 7° y 9°.
- Al menos 5 veces un número impar.

Solución:

Si definimos como “éxito” el obtener un número par cada vez que se lanza un dado, la probabilidad de “éxito” será $p = 1/2$. Sea x una variable aleatoria que representa el número de éxitos en 10 lanzamientos. $x = 0, 1, 2, \dots, 10$, será una variable aleatoria binomial con parámetro $p = 1/2$.

i) $P(\text{obtener un “éxito” las 5 primeras veces y una “falla” las 5 veces siguientes}) = p^5(1-p)^5 = \left(\frac{1}{2}\right)^5 \left(\frac{1}{2}\right)^5 = \frac{1}{2^{10}} = 0,00098$

ii) $P(x = 5) = \binom{10}{5} \left(\frac{1}{2}\right)^5 \left(\frac{1}{2}\right)^5 = \frac{126}{512} = 0,2461$

iii) $P(x \geq 5) = \sum_{x=5}^{10} \binom{10}{x} \left(\frac{1}{2}\right)^x \left(\frac{1}{2}\right)^{10-x} = 319/512 = 0,6230$

iv) $(1-p)p(1-p)p(1-p)p(1-p)p = \frac{1}{2^{10}} = 0,00098$

v) Obtener al menos 5 veces un número impar equivale a obtener no más de 5 veces un número par.

$$P(x \leq 5) = \sum_{x=0}^5 \binom{10}{x} \left(\frac{1}{2}\right)^x \left(\frac{1}{2}\right)^{10-x} = 319/512$$

- 4.2. Un juego de “bingo” consta de 90 números (1 al 90). Consideren un cartón de 15 números. Un cartón es ganador cuando se llenan los 15 números del cartón. Si han sido cantados 15 números. i) ¿Cuál es la probabilidad de que el cartón haya ganado? ii) ¿Cuál es la probabilidad de que no haya sido cantado ningún número del cartón?

Solución:

Sea x el número de números del cartón que están entre los 15 cantados. Obviamente con cada número cantado se modifica la probabilidad de que salga uno de los del cartón: Al cantar el primer número la probabilidad de que salga uno del cartón es $15/90$. Al cantar el segundo número, la probabilidad de que salga uno del cartón será $14/89$ ó $15/89$, dependiendo si el primero cantado pertenecía o no al cartón.

Entonces x será una variable aleatoria distribuida hipergeométricamente con parámetros $m = 15$, $r = 75$ y $n = 15$.

$$i) P(x = 15) = \frac{\binom{15}{15} \binom{75}{0}}{\binom{90}{15}} = \frac{1}{C_{90,15}}$$

$$ii) P(x = 0) = \frac{\binom{15}{0} \binom{75}{15}}{\binom{90}{15}} = \frac{C_{75,15}}{C_{90,15}}$$

- 4.3. Un radio de transistores funciona con 9 pilas colocadas en serie; si alguna de las 9 pilas es defectuosa, el radio no funciona. Suponga que las pilas puestas en el radio son escogidas de una caja que contiene 20, de las cuales se sabe que 5 son defectuosas. ¿Cuál es la probabilidad de que el radio funcione?

Solución:

Sea x el número de pilas en buen estado entre las 9 escogidas, x es una variable aleatoria distribuida hipergeométricamente con parámetros $m = 15$, $r = 5$, $n = 9$. La probabilidad de que la radio funcione es la probabilidad de que todas las pilas sean buenas; o sea, la probabilidad de que x sea igual a 9.

$$f(9) = \frac{\binom{15}{9} \binom{5}{0}}{\binom{20}{9}} = \frac{C_{15,9}}{C_{20,9}} = 0,0298$$

- 4.4. Consideren el problema anterior donde las 9 pilas son tomadas de un lote del que se sabe que el 25% son defectuosas. ¿Cuál es la probabilidad de que la radio funcione?

Solución:

En este caso la única información de que disponemos es que el 25% de las pilas son defectuosas; luego, si x es una variable aleatoria que representa el número de pilas en buen estado, x se distribuye binomialmente con parámetro $p = 0,75$.

$$P(x = 9) = \binom{9}{9} 0,75^9 0,25^0 = 0,0751$$

- 4.5. Un examen consiste en preguntas de escogencia múltiple. Cada pregunta tiene 3 respuestas, de las cuales sólo una es correcta. Un estudiante contesta las preguntas lanzando un dado. Si sale 1 o 2 elige la primera respuesta, si sale 3 ó 4 elige la segunda,

y si sale 5 o 6 elige la tercera. El examen se aprueba si se contestan correctamente la mitad o más de las 8 preguntas que contiene. ¿Cuál es la probabilidad que el estudiante pase el examen?

Solución:

En cada pregunta el estudiante contestará correctamente si le salen los números correspondientes a la respuesta correcta. Por ejemplo, si la respuesta correcta en la primera pregunta es la primera, contestará correctamente si sale un 1 ó un 2. Luego, la probabilidad de contestar correctamente cualquier pregunta es $1/3$. Si x es el número de preguntas contestadas correctamente, x se distribuye binomialmente con parámetro $p = 1/3$. Luego,

$$P(x \geq 4) = \sum_{x=4}^8 \binom{8}{x} \left(\frac{1}{3}\right)^x \left(\frac{2}{3}\right)^{8-x} = 0,2587$$

- 4.6. El 10% de los clientes de una Compañía de Seguros sufren accidentes en el período de un año. ¿Cuál es la probabilidad de que de 5 clientes que han cancelado su póliza de seguros un año dado, uno sólo tenga un accidente ese año?

Solución:

Sea x una variable aleatoria que representa el número de accidentados de los 5 ex-clientes, x se distribuye binomialmente con parámetros $p = 0,1$ y $n = 5$. Luego:

$$P(x = 1) = f(1) = \binom{5}{1} (0,1)^1 (0,9)^4 = 0,32805$$

- 4.7. La demanda que un distribuidor de automóviles tiene es una variable aleatoria con promedio de 5 por semana. En una semana dada, ¿cuál es la probabilidad de que se vendan 2 automóviles?

Solución:

Sea x la demanda de automóviles en una semana, x obedece a una distribución de Poisson con $\mu = 5$. Luego:

$$P(x = 2) = \frac{e^{-5} 5^2}{2!} = 0,0842$$

- 4.8. Una empresa que presta un determinado servicio tiene capacidad para atender 8 clientes por hora. Si los clientes llegan aleatoriamente a un promedio de 6 por hora.

¿Cuál es la probabilidad de que en una hora determinada, no se puedan atender a todos los clientes que lleguen en esa hora?

Solución:

Sea x el número de clientes que llegan en una hora; x se distribuye según Poisson con $\mu = 6$. La empresa no podrá atenderlos si llegan más de 8 en esa hora. Luego, la probabilidad de no poder atenderlos será la probabilidad de que x sea mayor que 8.

$$P(x > 8) = \sum_{x=9}^{\infty} \frac{e^{-6} 6^x}{x!} = 0,1526$$

- 4.9. En una fábrica las máquinas tienen que ser detenidas por accidentes, según la distribución de Poisson, a un promedio de 3 máquinas por día. Suponiendo que cada máquina dañada requiere un técnico mecánico para su arreglo. ¿Cuántos mecánicos debe tener la fábrica, de forma que la probabilidad sea al menos 0,95 de que todas las máquinas accidentadas un día cualquiera puedan ser reparadas? (Suponga que el mecánico asignado a una máquina tarde en su reparación el tiempo que falta para concluir la jornada de trabajo).

Solución:

Sea x el número de máquinas que se accidentan diariamente; x es una variable Poisson con $\mu = 3$. Tenemos que hallar un número de mecánicos (k) tal que la probabilidad de que x sea menor o igual que k sea al menos 0,95.

$$P(x \leq k) \geq 0,95 \Rightarrow \sum_{x=0}^k \frac{e^{-3} 3^x}{x!} \geq 0,95$$

vemos que $k = 6$, puesto que,

$$P(x \leq 6) = \sum_{x=0}^6 \frac{e^{-3} 3^x}{x!} \geq 0,9664$$

- 4.10. Considere un experimento que consiste en lanzar 2 dados. Realizamos el experimento varias veces hasta que la suma de los dados sea igual a 5. ¿Cuál es la probabilidad de que tengamos que realizar el lanzamiento 8 veces?

Solución:

Sea x el número de veces que tenemos que realizar el experimento, hasta que la suma sea 5; x es una variable aleatoria que se distribuye geoméricamente con parámetro $p = 1/9$. Luego,

$$P(x = 8) = \frac{1}{9} \left(1 - \frac{1}{9}\right)^7 = \frac{8^7}{9^8} = 0,0487$$

- 4.11. Consideren el siguiente concurso. El concursante tiene que abrir una puerta escogiendo al azar una llave de un grupo de 8, de las cuales una abre la puerta. Si la llave escogida no abre la puerta, se vuelve a mezclar en el grupo. El concursante tiene 3 oportunidades. ¿Cuál es la probabilidad de que gane?

Solución:

Sea x el número de llaves escogidas hasta encontrar la llave que abre la puerta, x es una variable geométrica con parámetro $p = 1/8$. Para ganar, el concursante debe abrir la puerta con la primera, la segunda o la tercera llave. Luego, la probabilidad de ganar es la probabilidad de que x sea menor o igual a 3.

$$P(x \leq 3) = \sum_{x=1}^3 \frac{1}{8} \left(\frac{7}{8}\right)^{x-1} = \frac{1}{8} \left(\frac{7}{8}\right)^0 + \frac{1}{8} \left(\frac{7}{8}\right)^1 + \frac{1}{8} \left(\frac{7}{8}\right)^2 = 0,33$$

- 4.12. Una empresa produce aparatos eléctricos. Se sabe que de su producción, un 10% tiene defectos eléctricos, un 5% defectos mecánicos, y un 3% defectos en el acabado. Si suponemos que los aparatos con un tipo de defecto no tienen los otros defectos. ¿Cuál es la probabilidad de que de un lote de 5 aparatos escogidos al azar de la producción de un día, 1 tenga defectos mecánicos, 2 defectos de acabado, y 2 no tengan defectos?

Solución:

Sea x_1 el número de aparatos con defectos eléctricos, x_2 el número de aparatos con defectos mecánicos, x_3 el número de aparatos con defectos de acabado.

x_1, x_2, x_3 obedecen a una distribución multinomial con parámetros $p_1 = 0,1$, $p_2 = 0,05$, $p_3 = 0,03$ y $n = 5$

$$P(x_1 = 0, x_2 = 1, x_3 = 2) = \frac{5!}{0!1!2!2!} (0,1)^0 (0,05)^1 (0,03)^2 (0,82)^2 = 0,0009$$

- 4.13. Una tienda de artículos para caballeros tiene a la venta trajes de 3 diferentes precios. Por experiencia pasada se sabe que el 30% de las personas que visitan la tienda no compran trajes, el 40% compran trajes de precio bajo, el 10% trajes de precio medio, y el 20% trajes del precio más alto. ¿Cuál es la probabilidad de que de 4 personas que visiten la tienda: i) Los 4 comprarán trajes de precio bajo, ii) No venderá ningún traje, iii) Al menos venderá un traje de cada precio?

Solución:

Sean x_1 = el número de trajes vendidos de precios bajos, x_2 = número de trajes vendidos de precio medio, x_3 = el número de trajes vendidos de precio alto, x_4 = número de clientes que no compran (trajes no vendidos). Entonces $x_i (i=1, 2, 3, 4)$ obedecen a una distribución multinomial, con parámetros $p_1 = 0,4$, $p_2 = 0,1$, $p_3 = 0,2$ y $p_4 = 0,3$ y $n = 4$.

i) La probabilidad de que los 4 compren trajes de precio bajo es:

$$P(x_1 = 4, x_2 = 0, x_3 = 0) = \frac{4!}{4!0!0!0!} (0,4)^4 (0,1)^0 (0,2)^0 (0,3)^0 = 0,0256$$

ii) La probabilidad de que no vendan ningún traje es:

$$P(x_1 = 0, x_2 = 0, x_3 = 0) = \frac{4!}{0!0!0!4!} (0,4)^0 (0,1)^0 (0,2)^0 (0,3)^4 = 0,0081$$

iii) La probabilidad de que compren al menos un traje de cada precio es:

$$P(x_1 = 1, x_2 = 1, x_3 = 1) + P(x_1 = 2, x_2 = 1, x_3 = 1) + P(x_1 = 1, x_2 = 2, x_3 = 1) +$$

$$P(x_1 = 1, x_2 = 1, x_3 = 2) = \frac{4!}{1!1!1!1!} (0,4)^1 (0,1)^1 (0,2)^1 (0,3)^1 +$$

$$+ \frac{4!}{2!1!1!0!} (0,4)^2 (0,1)^1 (0,2)^1 (0,3)^0 + \frac{4!}{1!2!1!0!} (0,4)^1 (0,1)^2 (0,2)^1 (0,3)^0 +$$

$$+ \frac{4!}{1!1!2!0!} (0,4)^1 (0,1)^1 (0,2)^2 (0,3)^0 = 0,0576 + 0,0384 + 0,0096 + 0,0192 = 0,1248$$

- 4.14. Un fabricante de artículos de vidrio inspecciona los artículos contando el número de defectos menores que tienen, y rechaza aquellos que tienen 2 ó mas defectos. Se sabe que el número promedio de defectos por artículo es 4. ¿Cuál es la probabilidad de que un artículo inspeccionado sea rechazado?

Solución:

Sea x el número de defectos en el artículo, x es una variable aleatoria Poisson con parámetro $\mu = 4$. La probabilidad que el artículo sea rechazado es:

$$P(x \geq 2) = \sum_{x=2}^{\infty} \frac{e^{-4} 4^x}{x!} = 1 - \sum_{x=0}^1 \frac{e^{-4} 4^x}{x!} = 1 - 0,0916 = 0,9084$$

- 4.15. Suponiendo que cada niño que nace tiene una probabilidad de 0,6 de ser varón. Calcular la probabilidad de que un matrimonio con 3 hijos tenga: i) Al menos un varón, ii) al menos una hembra.

Solución:

Sea x una variable aleatoria que representa el número de varones de los 3 hijos, x es una variable aleatoria con $p = 0,6$.

i) Probabilidad de al menos un varón:

$$P(x \geq 1) = \sum_{x=1}^3 \binom{3}{x} (0,6)^x (0,4)^{3-x} = 0,9360$$

ii) Probabilidad de al menos una hembra es la probabilidad de tener como máximo 2 varones.

$$P(x \leq 2) = \sum_{x=0}^2 \binom{3}{x} (0,6)^x (0,4)^{3-x} = 0,7840$$

EJERCICIOS PROPUESTOS

- 4.16) ¿Cuál es la probabilidad de obtener 5 caras y 7 sellos, al lanzar 12 veces una moneda bien balanceada?
- 4.17) Supongamos que una moneda está balanceada de tal forma que la probabilidad de obtener una cara al lanzarla es 0,8. i) ¿Cuál es la probabilidad de obtener exactamente una cara, al lanzar la moneda 5 veces? ii) ¿Cuál es la probabilidad de obtener como máximo una cara?
- 4.18) La probabilidad de que el motor de un avión se accidente en vuelo es 0,01. Si los 4 motores funcionan independientemente, ¿Cuál es la probabilidad de que en un vuelo no se accidente ningún motor?
- 4.19) Un grupo de 3 personas lanzan monedas bien balanceadas. ¿Cuál es la probabilidad de que: i) Las 3 monedas sean caras, ii) Las 3 monedas sean sellos, iii) Haya una sola cara, iv) Todas las monedas sean cara o sello?
- 4.20) Suponiendo que la probabilidad de que un niño que nace sea varón es 0,50. ¿Cuántos hijos debe tener un matrimonio para que la probabilidad de tener al menos 2 varones sea mayor que 0,75?

- 4.21. Si una máquina está ajustada, produce buenos productos un 60% del tiempo. Si se desajusta, produce buenos productos sólo el 20% del tiempo. Por experiencia se sabe que la máquina está ajustada el 70% del tiempo. Cualquiera que sea el estado de la máquina, la probabilidad de que un artículo sea bueno no afecta ni es afectada por los otros productos. i) ¿Cuál es la probabilidad de que 2 productos tomados de la producción sean ambos defectuosos, dado que la máquina está ajustada, ii) Si la máquina está desajustada? iii) ¿Cuál es la probabilidad que la máquina esté ajustada, dado que los 2 productos son defectuosos?
- 4.22. Una caja contiene 10 fichas rojas, 10 azules y 30 blancas. ¿Cuál es la probabilidad de que al extraer 6 fichas se obtengan 3 fichas rojas? i) Con reemplazamiento, ii) Sin reemplazamiento.
- 4.23. Calcule la media y varianza de la variable aleatoria que representa el número de caras obtenidas al lanzar 3 monedas bien balanceadas. Haga el cálculo directamente por las fórmulas del valor esperado y varianza de una variable aleatoria, y luego compare con los resultados obtenidos a partir de las fórmulas de la media y varianza de una variable binomial.
- 4.24. Se le pide a 5 personas que escriban una letra A, B, C, D o E. Suponiendo que la letra es escogida al azar. ¿Cuál es la probabilidad de que 2 o más personas escriban las letras A o B?
- 4.25. Consideren la serie final del campeonato de Base-Ball profesional. Suponiendo que uno de los equipos tiene mayor probabilidad ($p = 2/3$) de ganar cada juego, y los resultados de éstos son estadísticamente independientes. ¿Cuál es la probabilidad de que la serie termine en 4, 5, 6, y 7 juegos? Total 7 juegos.
- 4.26. Dada una variable aleatoria x binomial con media 2,5 y varianza 1,875. Calcular la probabilidad de que x sea mayor o igual a 4.
- 4.27. Una compañía de aviación sabe por records pasados que el 4% de las personas que tienen reservados pasajes para el vuelo Caracas - Maracaibo no se presentan. De forma que la compañía reserva 75 puestos en lugar de los 73 que tiene el avión. ¿Cuál es la probabilidad de que todos los pasajeros que se presenten tengan puestos disponibles?
- 4.28. Use la aproximación de Poisson para hallar la probabilidad del ejercicio (4.27).
- 4.29. Una máquina produce repuestos para automóviles; y en promedio, 2 de cada 100 repuestos son defectuosos. Estos repuestos se empaquetan en cajas de 200, para vender a los distribuidores. ¿Qué porcentaje de esas cajas no tienen repuestos defectuosos? (Use la aproximación de Poisson).

- 4.30. En la autopista Caracas - Valencia suceden accidentes fatales a un promedio de 2 por mes (4 semanas). ¿Cuál es la probabilidad de que en una semana determinada no se produzcan accidentes fatales?
- 4.31. Una tipografía edita una revista, y se sabe que el número medio de erratas por página es 1. Si la revista tiene 20 páginas, ¿Cuál es la probabilidad de que en un número de la revista haya entre 18 y 25 erratas?
- 4.32. Una central telefónica recibe un promedio de 60 llamadas por hora. ¿Cuál es la probabilidad de que en un período de 1 minuto no reciba ninguna llamada o al menos reciba dos llamadas?
- 4.33. Una investigación hecha por la Comisión de Prevención de Accidentes muestra que durante los 4 días feriados de la Semana Santa, se ahogan en promedio 20 personas en las playas del litoral. ¿Cuál es la probabilidad de que un día de Semana Santa haya 3 o más ahogados?
- 4.34. La probabilidad de que una máquina produzca una unidad defectuosa es 0,2, siendo la calidad de cada unidad estadísticamente independiente de la calidad de las otras unidades producidas. Si la máquina produce una unidad por hora, y empieza a trabajar a las 8 a.m. i) ¿Cuál es la probabilidad de que la primera unidad mala se produzca entre las 10 a.m. y 11 a.m.? ii) ¿Cuál es la probabilidad de que la primera unidad mala sea la sexta producida? iii) ¿Cuál es la probabilidad de que la primera unidad mala sea la sexta, si sabemos que las 3 primeras fueron buenas?
- 4.35. Un examen consta de 10 preguntas que son calificadas con 0 puntos, 1 punto ó 2 puntos. Un estudiante, después de ver el examen, considera que la probabilidad de recibir 2 puntos en una pregunta es 0,3, y de recibir 1 punto es 0,5; siendo la calificación en cada pregunta estadísticamente independiente de la calificación de las otras, ¿Cuál es la probabilidad de obtener: i) 0 puntos en exactamente 3 de las preguntas. ii) 0 puntos en 3 preguntas y 1 punto en 2 preguntas, iii) 0 puntos en 3 preguntas y 2 puntos en 4 preguntas?
- 4.36. Una empresa está considerando la compra de una máquina. Por experiencia pasada con máquinas similares, la empresa ha clasificado este tipo de máquina en 3 categorías, Categoría A, si produce un 80% de unidades buenas; Categoría B, si produce un 60% de unidades buenas; y Categoría C, si produce sólo un 40% de unidades buenas. El vendedor afirma que el 90% de sus máquinas son de la Categoría A, el 9% de Categoría B, y sólo el 1% de la Categoría C. La Empresa quiere probar la máquina antes de decidir la compra. A tal efecto se producen 10 unidades, y sólo 3 resultan buenas. Dado este resultado, la empresa compra la máquina, si hay al menos una probabilidad de 10% de que la máquina sea de Categoría A, y no más de un 20% de que sea de Categoría C. ¿Aconsejaría Ud. comprar la máquina en la hipótesis de que los resultados de la calidad de cada unidad en la prueba realizada son estadísticamente independientes?

- 4.37. En un concurso van a participar 5 personas. El concurso consiste en elegir un número entre los números 1 al 6. El número 3 es el ganador. Cada concursante tiene un número del 1 al 5 que corresponde al turno en que participan. Si el concursante de turno elige el número 3, gana, y el concurso termina; si no elige el número 3, queda eliminado, y el turno le toca al siguiente concursante. Si una persona tiene el turno 4, ¿Cuál es la probabilidad de que gane?
- 4.38. Todas las semanas una persona elabora un cuadro del "5 y 6". Recientemente ha encontrado una fórmula según la cual la probabilidad de ganar es de 0,3. Si empieza a aplicar la fórmula la próxima semana. i) ¿Cuál es la probabilidad de que la primera vez que gane ocurrirá dentro de 3 semanas? ii) ¿Cuál es la probabilidad de que no gane en las próximas 3 semanas? iii) ¿Cuál es la probabilidad de que gane al menos una vez en las próximas 3 semanas?
- 4.39. Una caja contiene 10 transistores, de los cuales 4 son defectuosos. Si tomamos 2 transistores al azar de la caja, ¿Cuál es la probabilidad de que ambos sean defectuosos?
- 4.40. El 20% de los aparatos de televisión de una cierta marca fallan dentro del primer año de operación. Un distribuidor recibe 10 aparatos y los vende con garantía anual sobre cualquier falla. ¿Cuál es la probabilidad de que la garantía no se cumpla en 4 de los aparatos?
- 4.41. Una máquina tiene 50 piezas susceptibles de dañarse. Estas piezas son revisadas periódicamente para determinar posibles fallas. Supongamos que la probabilidad de que una pieza dada falle en el período de tiempo entre revisiones es 0,01; i) ¿Cuál es la probabilidad de que ninguna pieza fallará en el período?, ii) Compare el resultado con el obtenido mediante la aproximación de Poisson.
- 4.42. Un embarque de fusibles eléctricos es empaquetado en cajas de 100 fusibles cada una. Las cajas se inspeccionan examinando al azar 20 de los fusibles, y se rechaza si alguno de los 20 es defectuoso. ¿Cuál es la probabilidad de que una caja con 2 fusibles defectuosos sea rechazada?
- 4.43. Se pretende que un proceso de fabricación produzca artículos con no más del 1% defectuosos. El proceso es inspeccionado cada hora, mediante la revisión de 10 artículos seleccionados al azar, de la producción de la hora. Si uno o más de los 10 es defectuoso, el proceso es detenido y examinado. Si de hecho la máquina está produciendo con 1% de defectuosos, ¿Cuál es la probabilidad de que el proceso sea detenido innecesariamente en un momento dado?
- 4.44. Un distribuidor de semillas de flores determina que el 5% de las semillas no florecerán. Las semillas son vendidas en cajas de 200, y el vendedor garantiza que el 90% de las semillas de la caja florecerán. ¿Cuál es la probabilidad de que en una caja determinada la garantía no se cumple? (Use la aproximación de Poisson).

- 4.45. En un autolavado llegan automóviles buscando servicio a una tasa de 10 por hora. Si el autolavado puede atender como máximo 20 automóviles por hora, ¿Cuál es la probabilidad de que en una hora determinada lleguen más automóviles de los que se pueden atender?
- 4.46. Una computadora recibe trabajos a un promedio de uno por hora. La computadora se avería y su reparación tarda 2 horas. ¿Cuál es la probabilidad de que el número de trabajos que lleguen durante el período de reparación sea i) cero, ii) dos, iii) cinco o más?
- 4.47. Supongamos que el número de artículos comprados en una tienda durante un día obedece a una distribución de Poisson con media igual a 10. ¿Cuántos artículos deben haber como mínimo en existencia, para que la probabilidad de que la tienda sea capaz de atender la demanda del día sea mayor o igual a 0,95? (Suponga que los artículos son perecederos, de forma que no puede mantenerse inventario de un día para otro).
- 4.48. En una urbanización de Caracas el 60% de las viviendas están aseguradas; 4 viviendas son elegidas aleatoriamente, ¿Cuál es la probabilidad de que al menos 3 están aseguradas?
- 4.49. El Ministerio de Hacienda estima que el 20% de la población tiene ingresos suficientemente elevados como para pagar Impuesto sobre la Renta. Si elegimos 9 personas al azar de entre la población, ¿Cuál es la probabilidad de que más de 4 no deban pagar Impuesto?
- 4.50. Supongamos que el peaje de la Autopista Caracas - La Guaira llegan en promedio 3 carros por minuto, ¿Cuál es la probabilidad de que en 3 minutos lleguen o uno, o al menos 3 carros?
- 4.51. Calcular el valor esperado y la varianza de la variable Bernoulli.
- 4.52. Determine razonadamente la veracidad o falsedad de las siguientes afirmaciones:
- Dada una variable x binomial con parámetros n y p , siempre se cumple que el valor esperado del número de éxitos más el valor esperado del número de fallas es igual a n .
 - Un experimento aleatorio tiene dos posibles resultados, que se dé A o que no se dé A . Sea x una variable que representa el número de veces que se da A al realizar n veces en forma independiente el experimento. Si queremos calcular $P(x=5)$, el éxito se define como el suceso de que se dé A cinco veces.
 - Sea x el número de veces que se da un suceso al realizar n veces un experimento. Si x es una variable hipergeométrica, el número de veces que no se da el suceso también es una variable hipergeométrica.

4.53. Determine razonadamente cuál de las respuestas es correcta en:

Sean x_1 y x_2 dos variables binomiales independientes; sabiendo que $P(x_1 \leq 5) = 0,4$ y $P(x_2 \leq 5) = 0,3$. ¿Cuánto vale $P(x_1 + x_2 \leq 10)$?

- a) $0,4 + 0,3$.
- b) $0,4 + 0,3 - 0,4 \times 0,3$.
- c) No puede saberse.
- d) Ninguna de las anteriores.

CAPITULO V

DISTRIBUCIONES DE VARIABLES ALEATORIAS CONTINUAS

5.1. INTRODUCCION

Como se dijo en el capítulo anterior, en este capítulo se tratarán las distribuciones de variables continuas más importantes y más utilizadas en la estadística aplicada.

Algunas de ellas pueden representar, exacta o aproximadamente, fenómenos reales; entre éstas destacan la distribución uniforme, la exponencial, la Beta, la Gamma y principalmente la distribución Normal o de Gauss.

Sin temor a exagerar se podría afirmar que la distribución de probabilidades normal constituye el instrumento más poderoso y útil de que dispone la ciencia estadística. Esta distribución tiene tal significación por varias razones: en primer lugar, una gran cantidad de fenómenos aleatorios reales en cualquier ciencia: economía, biología, psicología, ingeniería, etc., pueden ser representados adecuadamente por variables normales; en segundo lugar, como se verá más adelante, cualquiera que sea la distribución original de una población estudiada, los resultados muestrales, sumariados en los estadísticos muestrales, tienden a seguir la distribución normal o alguna de las distribuciones derivadas de ella.

Entre estas últimas, que también se estudian en este capítulo, están la distribución χ^2 , la distribución "t" y la distribución "F".

5.2. DISTRIBUCION UNIFORME

La distribución de probabilidades uniforme es la función de densidad de variables aleatorias continuas más sencilla. Es una función de densidad constante en un determinado intervalo (a, b) , y es igual a cero para los valores de la variable fuera del intervalo.

Sea x una variable aleatoria continua cuya función de densidad es:


$$f(x) = \frac{1}{b-a} \text{ para } a \leq x \leq b$$

$$= 0 \text{ para cualquier otro valor de } x:$$

entonces x es una variable aleatoria que obedece a la distribución uniforme.

Comprobemos que $f(x)$ es una función de densidad: $f(x) \geq 0$ para todo valor de x , además el área debajo de $f(x)$ es el área de un rectángulo con base $(b-a)$ y altura $\frac{1}{b-a}$, luego es igual a 1.

Gráficamente $f(x)$ es un segmento lineal paralelo al eje de abscisas en el intervalo (a, b) .




La función de distribución acumulativa de una variable distribuida uniformemente es:

$$F(x) = 0 \quad \text{para } x < a$$

$$F(x) = \int_a^x \frac{1}{b-a} dx = \frac{x-a}{b-a} \quad \text{para } a \leq x \leq b$$

$$F(x) = 1 \quad \text{para } x > b$$

La representación gráfica de $F(x)$ es:



Dado un intervalo (a_1, b_1) tal que dicho intervalo está contenido en el intervalo (a, b) , la probabilidad de que x esté en el intervalo (a_1, b_1) , o sea $P(a_1 \leq x \leq b_1)$, es igual a la longitud del intervalo (a_1, b_1) dividido por la longitud del intervalo (a, b) . En efecto,

$$P(a_1 \leq x \leq b_1) = F(b_1) - F(a_1) = \frac{b_1 - a}{b - a} - \frac{a_1 - a}{b - a} = \frac{b_1 - a_1}{b - a}$$

EJEMPLO 5.1.

El tiempo requerido por una persona para ir desde la UCAB en La Vega hasta el centro de Caracas, es una variable aleatoria distribuida uniformemente en el intervalo 30 a 50 minutos. Supongamos que una persona A tiene una cita en el centro de Caracas a un cuarto para las 12; si sale a las once y diez de la Universidad.

- ¿Cuál es la probabilidad de llegar a tiempo a la cita?
- Si la persona B con quien tiene la cita, espera hasta diez para las doce como máximo. ¿Cuál es la probabilidad de que la cita se realice?
- ¿Cuál es la probabilidad de que la persona A espere más de 5 minutos por la persona B?
- ¿A qué hora debe salir A para que la probabilidad de llegar a la cita sea mayor o igual a 0,6?

Solución:

Si el tiempo requerido para llegar desde la U.C.A.B. hasta el centro es una variable aleatoria distribuida uniformemente, entonces,

$$f(x) = \frac{1}{20} \quad \text{para } 30 \leq x \leq 50$$

- i) La probabilidad de llegar a tiempo a la cita es la probabilidad de llegar antes de un cuarto para las 12; o sea, la probabilidad de tardar 35 minutos o menos desde la UCAB hasta el centro.

$$P(x \leq 35) = F(35) = \frac{35 - 30}{20} = 0,25$$

- ii) En este caso, la cita se realiza si la persona A llega a 10 para las 12 o antes; o sea, si tarda 40 minutos o menos.

$$P(x \leq 40) = F(40) = \frac{40 - 30}{20} = 0,50$$

- iii) La persona A esperará más de 5 minutos si llega a la cita a 20 para las 12 o antes; o sea, si tarda 30 minutos o menos.

$$P(x \leq 30) = F(30) = 0$$

- iv) Siendo x el tiempo que tarda en llegar

$$P(x \leq h) = 0,6 \Rightarrow \frac{h - 30}{20} = 0,6 \Rightarrow h = 42$$

Ahora bien, si x_0 es la hora en que sale de la Universidad, necesitamos que el tiempo entre x_0 y 11.45 (hora límite de la cita) sea 42 o más minutos, luego debe salir a las 11,03 o antes.

$$x_0 = 11,03 \text{ o antes.}$$

5.3. VALOR ESPERADO Y VARIANZA DE UNA VARIABLE DISTRIBUIDA UNIFORMEMENTE

Si x se distribuye uniformemente en el intervalo (a, b)

$$E(x) = \int_a^b x \frac{1}{b-a} dx = \frac{x^2}{2(b-a)} \Big|_a^b = \frac{b^2 - a^2}{2(b-a)} = \frac{b+a}{2}$$

$$E(x^2) = \int_a^b x^2 \frac{1}{b-a} dx = \frac{x^3}{3(b-a)} \Big|_a^b = \frac{b^3 - a^3}{3(b-a)} = \frac{b^2 + a^2 + ab}{3}$$

$$\text{Var}(x) = E(x^2) - [E(x)]^2 = \frac{b^2 + a^2 + ab}{3} - \frac{(b+a)^2}{4} = \frac{(b-a)^2}{12}$$

Luego:

$$E(x) = \frac{b+a}{2} \quad \text{y} \quad \text{Var}(x) = \frac{(b-a)^2}{12}$$

EJEMPLO 5.2.

La media del tiempo en el ejemplo 5.1. es

$$E(x) = \frac{b+a}{2} = \frac{50+30}{2} = 40 \text{ minutos}$$

La varianza,

$$\text{Var}(x) = \frac{(50-30)^2}{12} = \frac{400}{12} = 33 \frac{1}{3}$$

5.4. DISTRIBUCION EXPONENCIAL

Una variable aleatoria continua x es distribuida según la distribución exponencial, si su función de densidad es:

$$f(x) = \frac{1}{\theta} e^{-x/\theta} \quad \text{para } x \geq 0$$


$$= 0 \quad \text{para cualquier otro valor de } x.$$

Donde θ es una constante mayor que cero.

Obviamente $f(x) \geq 0$ para cualquier valor de x . Además, $\int_{-\infty}^{\infty} f(x) dx = 1$. En efecto,

$$\int_{-\infty}^{\infty} f(x) dx = \int_0^{\infty} \frac{1}{\theta} e^{-x/\theta} dx = -e^{-x/\theta} \Big|_0^{\infty} = -\frac{1}{e^{\infty}} + e^0 = 1$$

La representación gráfica de $f(x)$ es.




La función de distribución es:

$$F(x) = 0 \quad \text{para } x < 0$$

$$F(x) = \int_0^x \frac{1}{\theta} e^{-x/\theta} dx = 1 - e^{-x/\theta} \quad \text{para } x \geq 0$$

y su representación gráfica es



La distribución exponencial es muy usada en el campo de la investigación de operaciones; existen muchos casos en la práctica en los que una variable aleatoria obedece exacta o aproximadamente a la distribución exponencial. Ejemplos concretos serían el tiempo que un cliente tiene que esperar para ser atendido; el tiempo entre 2 sucesivas llegadas de clientes buscando un determinado servicio, el tiempo que pasa entre el comienzo del servicio a un cliente y su terminación, etc. En este sentido la distribución exponencial está íntimamente ligada a la distribución de Poisson. Recordemos que la distribución de Poisson era aplicable al número de sucesos que ocurren en un determinado período de tiempo. Decir que el número de sucesos que ocurren en un período de tiempo obedece a la distribución de Poisson con media μ , es equivalente a decir que el tiempo entre sucesos consecutivos es una variable aleatoria distribuida exponencialmente con parámetro igual a θ donde $\theta = 1/\mu$.⁵

EJEMPLO 5.3.

Supongamos que el número de clientes que llega en 1 hora a un establecimiento es una variable aleatoria con $\mu = 5$. Esto equivale a decir que después de que un cliente llegue, el próximo cliente tardará un promedio 1/5 de hora = 12 minutos. En efecto, 5 clientes en promedio por hora equivale a decir que en promedio cada

⁵ E. Parzen, Modern Probability Theory e its Aplications, E Wiley, 1960, pág 261.

12 minutos llega un cliente. El tiempo entre llegadas de clientes es una variable aleatoria distribuida exponencialmente con parámetro $\theta = 12$ minutos. Si queremos saber la probabilidad de que el tiempo entre la llegada de un cliente y otro sea menor que 10 minutos, ésta será:

$$P(x \leq 10) = \int_0^{10} \frac{1}{12} e^{-x/12} dx = 1 - e^{-10/12} = 0,5654$$

EJEMPLO 5.4.

Supongamos que la vida útil promedio de un carro es de 7 años. ¿Cuál es probabilidad de que la vida útil sea mayor o igual a 10 años?

Consideremos como sucesos las compras de carros al terminar su vida útil, el tiempo entre la compra de dos carros es la vida útil y es una variable aleatoria x que obedece a la distribución exponencial con parámetro $\theta = 7$ años.

$$P(x \geq 10) = 1 - \int_0^{10} \frac{1}{7} e^{-x/7} dx = e^{-10/7} = 0,2397$$

El supuesto de que el tiempo entre dos sucesos se distribuye exponencialmente, tiene una consecuencia práctica importante que puede limitar la aplicabilidad de la distribución exponencial en ciertos casos. La probabilidad que un suceso no ocurra en cualquier intervalo de tiempo $(t, t+i)$ depende sólo de la longitud del intervalo i , y no de lo que haya sucedido hasta el momento t .

Hasta el momento t se pueden haber dado dos casos:

- 1º) Que no se haya dado ningún suceso hasta el momento t ,
- 2º) Que se haya dado el último suceso en un momento $a \leq t$.

En ambos casos la probabilidad de que no se dé un suceso en el intervalo $(t, t+i)$ es la misma e igual a:

$$P(x \geq i) = \int_i^{\infty} \frac{1}{\theta} e^{-x/\theta} dx = e^{-i/\theta}$$

En efecto, 1) Si no se ha dado ningún suceso hasta el momento t , la probabilidad de que no se dé ningún suceso en el intervalo $(t, t+i)$ es

$$P(x > t + i/x > t)$$

es decir, la probabilidad de que el primer suceso se dé después de $t+i$ dado que se da después de t .

$$P(x > t + i/x > t) = \frac{P(x > t + i \cap x > t)}{P(x > t)} = \frac{P(x > t + i)}{P(x > t)} =$$

$$= \frac{\int_{t+i}^{\infty} \frac{1}{\theta} e^{-x/\theta} dx}{\int_t^{\infty} \frac{1}{\theta} e^{-x/\theta} dx} = \frac{e^{-\frac{(t+i)}{\theta}}}{e^{-\frac{t}{\theta}}} = e^{-i/\theta} = P(x \geq i)$$

- 2) Si el último suceso se dio en el momento $a \leq t$, la probabilidad de que no se dé ningún suceso en el intervalo $(t, t+i)$ es:

$$P(x > t + i - a/x > t - a)$$

es decir, la probabilidad de que el próximo suceso se dé después de $t + i$ dado que se da después de t ,

$$P(x > t + i - a/x > t - a) = \frac{\int_{t+i-a}^{\infty} \frac{1}{\theta} e^{-x/\theta} dx}{\int_{t-a}^{\infty} \frac{1}{\theta} e^{-x/\theta} dx} = \frac{e^{-\frac{(t+i-a)}{\theta}}}{e^{-\frac{t-a}{\theta}}} = e^{-i/\theta} = P(x \geq i)$$

Según esto, la probabilidad que no ocurra ningún suceso en el intervalo $(t, t+i)$ es la misma, independientemente de si no se ha dado ningún suceso en el intervalo $(0, t)$ o si se ha dado algún suceso en ese intervalo, o sea la probabilidad pedida depende sólo de i y no del momento t en que comienza el intervalo. Por esta característica de la distribución exponencial se suele decir que esta distribución no tiene memoria.

EJEMPLO 5.5.

Supongamos que en el ejemplo 5.3. queremos conocer la probabilidad de que, habiendo pasado 5 minutos después de la llegada de un cliente, el próximo cliente tarde más de 6 minutos adicionales; o sea, que estamos preguntando la probabilidad de que el tiempo entre llegadas de dos clientes sea mayor que once minutos, dado que es mayor de cinco minutos: $t=5, i=6$.

$$P(x \geq 11/x \geq 5) = \frac{P(x \geq 11)}{P(x \geq 5)} = P(x \geq 6) = e^{-6/12} = 0,6065$$

EJEMPLO 5.6.

Si en el ejemplo 5.4, se pregunta la probabilidad que la vida útil de un carro sea mayor que diez años más, después que el carro ha durado seis años,

$$P(x \geq 16/x \geq 6) = \frac{P(x \geq 16)}{P(x \geq 6)} = P(x \geq 10) = 0,2397$$

Se observará que el resultado es el mismo del ejemplo 5.4.

Obviamente, la falta de memoria de la distribución exponencial limita su aplicación en algunas situaciones; parece lógico pensar, por ejemplo, que la probabilidad de que un activo dure cierto tiempo después de que ha durado un tiempo determinado debe ser menor que si el activo es nuevo; en este caso, no sería apropiado utilizar la variable exponencial para representar el tiempo de vida útil del activo.

5.5. VALOR ESPERADO Y VARIANZA DE UNA VARIABLE DISTRIBUIDA EXPONENCIALMENTE

La función generatriz de momentos de una variable aleatoria exponencial es, para $k < 1/\theta$

$$m_x(k) = E(e^{xk}) = \int_0^{\infty} e^{xk} \frac{1}{\theta} e^{-x/\theta} dx = \frac{1}{\theta} \int_0^{\infty} e^{x(k-1/\theta)} dx =$$

$$= \frac{1}{\theta} e^{x(k-1/\theta)} \frac{1}{k-1/\theta} \Big|_0^{\infty} = \frac{1/\theta}{1/\theta - k} = \frac{1}{1 - \theta k}$$

$$m_x(k) = \frac{1}{1 - \theta k}$$

Derivando $m_x(k)$ con respecto a k , tenemos:

$$\frac{d}{dk} m_x(k) = \frac{\theta}{(1 - \theta k)^2}$$

$$E(x) = \frac{d}{dk} m_x(k) \Big|_{k=0} = \theta$$

Derivando de nuevo,

$$\frac{d^2}{dk^2} m_x(k) = \frac{2\theta^2}{(1 - \theta k)^3}$$

$$E(x^2) = \frac{d^2}{dk^2} m_x(k) \Big|_{k=0} = 2\theta^2$$

$$\text{Var}(x) = 2\theta^2 - \theta^2 = \theta^2$$

$$E(x) = \theta \quad \text{Var}(x) = \theta^2$$

*5.6. DISTRIBUCION GAMMA

Si x es una variable aleatoria con función de densidad,

$$f(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} \quad \text{para } x \geq 0$$

$$= 0$$

para cualquier otro valor de x

entonces x es una variable aleatoria que obedece a la distribución Gamma. Esta densidad es una función de 2 parámetros α y β , siendo ambos positivos. Siendo:

$$\Gamma(\alpha) = \int_0^{\infty} y^{\alpha-1} e^{-y} dy$$

En la mayoría de las situaciones prácticas α no sólo es positivo sino también entero; en este caso integrando por partes tendremos:

$$\begin{aligned}\Gamma(\alpha) &= \int_0^{\infty} y^{\alpha-1} e^{-y} dy = -y^{\alpha-1} e^{-y} \Big|_0^{\infty} + (\alpha-1) \int_0^{\infty} e^{-y} y^{\alpha-2} dy = \\ &= (\alpha-1) \int_0^{\infty} e^{-y} y^{\alpha-2} dy = (\alpha-1) \Gamma(\alpha-1)\end{aligned}$$


En general, aplicando sucesivamente la integración por partes tendremos:

$$\Gamma(\alpha) = (\alpha-1)(\alpha-2)(\alpha-3)\dots\dots\Gamma(1)$$

y puesto que $\Gamma(1) = 1$, en definitiva

$$\Gamma(\alpha) = (\alpha-1)!$$

La representación gráfica de la función de densidad gamma es: ⁶



Cuando el número de sucesos que ocurren en un período de tiempo obedece a la distribución de Poisson, sabemos que el tiempo de espera entre 2 sucesos consecutivos obedece a una distribución exponencial con parámetro $\theta = 1/\mu$. Pues bien, el tiempo de espera hasta la ocurrencia del suceso r -ésimo obedece a una distribución gamma con parámetros $\alpha = r$ y $\beta = \theta$. Observen que la función de densidad gamma se convierte en la distribución exponencial cuando $\alpha = r = 1$ y $\beta = \theta$. Es decir, la suma de n variables independientes, exponencialmente distribuidas cada una con parámetro θ , se distribuye según la distribución gamma con parámetros $\alpha = n$ y $\beta = \theta$.

EJEMPLO 5.7.

En el ejemplo 5.3, cuál es la probabilidad de que el tiempo hasta la llegada del cuarto cliente sea mayor que 30 minutos.

⁶ Para una prueba de $\int_{-\infty}^{+\infty} f(x) dx = 1$. Introduction to the Theory of Statistics, A. Mood and F. Graybill, Mac Graw Book Co, N.Y., 1963, pág. 127.

Si x representa el tiempo de llegada del cuarto cliente, x se distribuye según la distribución gamma con parámetro $\alpha = 4$ y $\beta = 12$. Luego,

$$\begin{aligned}P(x \geq 30) &= \int_{30}^{\infty} \frac{1}{\Gamma(4)} \frac{1}{12^4} x^3 e^{-x/12} dx = 1 - \int_0^{30} \frac{1}{3!} \frac{1}{12^4} x^3 e^{-x/12} dx = \\ &= 1 - \frac{1}{6 \cdot 12^4} \int_0^{30} x^3 e^{-x/12} dx = 1 - \frac{1}{6 \cdot 12^4} \left[\frac{3!}{(1/12)^4} - e^{-30/12} \sum_{k=0}^3 \frac{3!}{k!} \frac{30^k}{(1/2)^{4-k}} \right] = \\ &= 1 - 1 + e^{-30/12} \frac{443}{48} = 0,758\end{aligned}$$

*5.7. VALOR ESPERADO Y VARIANZA DE UNA VARIABLE DISTRIBUIDA SEGUN LA DISTRIBUCION GAMMA

La función generatriz de momentos de una variable gamma es para $k < \frac{1}{\beta}$

$$\begin{aligned}m_x(k) &= \int_0^{\infty} e^{xk} \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} dx = \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^{\infty} x^{\alpha-1} e^{-x\left(\frac{1}{\beta}-k\right)} dx = \\ &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \frac{1}{\left(\frac{1}{\beta}-k\right)^\alpha} \Gamma(\alpha) = \frac{1}{\beta^\alpha \left(\frac{1-\beta k}{\beta}\right)^\alpha} = \left(\frac{1}{1-\beta k}\right)^\alpha = (1-\beta k)^{-\alpha}\end{aligned}$$

$$m_x(k) = (1-\beta k)^{-\alpha}$$

Derivando con respecto a k , tenemos:

$$\frac{d}{dk} m_x(k) = \alpha(1-\beta k)^{-\alpha-1} \beta$$

$$E(x) = \frac{d}{dk} m_x(k) \Big|_{k=0} = \alpha\beta$$

Hallando la segunda derivada,

$$\frac{d^2}{dk^2} m_x(k) = \alpha\beta^2(\alpha+1)(1-\beta k)^{-\alpha-2}$$

$$E(x^2) = \frac{d^2}{dk^2} m_x(k) \Big|_{k=0} = \alpha\beta^2(\alpha+1)$$

$$\text{Var}(x) = \alpha\beta^2(\alpha + 1) - \alpha^2\beta^2 = \alpha\beta^2$$

Luego,

$$E(x) = \alpha\beta$$

$$\text{Var}(x) = \alpha\beta^2$$

Al mismo resultado se llega enfocando el problema desde otro punto de vista. Recordemos que una variable gamma con parámetros α y β , es la suma de α variables exponenciales independientes con media β y varianza β^2 . Sabiendo que el valor esperado y varianza de una suma de variables independientes son la suma de los valores esperados y varianzas respectivamente, obtenemos que $E(x) = \alpha\beta$ y $\text{Var}(x) = \alpha\beta^2$.

*5.8. DISTRIBUCION BETA

Si x es una variable aleatoria comprendida en el intervalo $[A, B]$, siendo $B > A \geq 0$ y con función de densidad,

$$f(x) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \frac{1}{(B - A)^{\alpha + \beta - 1}} (x - A)^{\alpha - 1} (B - x)^{\beta - 1} \quad \text{para } A \leq x \leq B$$

$$= 0 \quad \text{para cualquier otro valor de } x$$


entonces x es una variable aleatoria que obedece a la distribución Beta en el intervalo $[A, B]$.

Un caso especial de la distribución Beta es aquel en que el intervalo $[A, B]$ es el intervalo $[0, 1]$, en cuyo caso la función de densidad se convierte en:

$$f(x) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha - 1} (1 - x)^{\beta - 1} \quad \text{para } 0 \leq x \leq 1$$

$$= 0 \quad \text{para cualquier otro valor de } x$$

$f(x)$ es función de 2 parámetros α y β ambos positivos. La representación gráfica de la distribución Beta es.



Obsérvese que para α y $\beta = 1$, la distribución Beta se convierte en la distribución uniforme en el intervalo dado.

La distribución Beta es usada frecuentemente en las técnicas PERT (Program Evaluation & Review Techniques) para control de proyectos. En la técnica PERT se supone que los tiempos de cada actividad que componen un proyecto son variables aleatorias que obedecen a la distribución Beta. Esta distribución tiene características que se avienen bien con las características de las variables aleatorias usadas en PERT: a) Pequeñas probabilidades de que se den los valores extremos, b) Es una distribución unimodal ⁷.

*5.9. VALOR ESPERADO Y VARIANZA DE UNA VARIABLE DISTRIBUIDA SEGUN LA DISTRIBUCION BETA.

El valor esperado y varianza de una variable aleatoria x que se distribuye según la distribución Beta en el intervalo $[A, B]$ son:

$$E(x) = A + (B - A) \frac{\alpha}{\alpha + \beta}$$

$$\text{Var}(x) = \frac{(B - A)^2 \alpha \beta}{(\alpha + \beta + 1)(\alpha + \beta)^2}$$

Si el intervalo es $[0, 1]$, el valor esperado y varianza de x se convierten respectivamente en:

$$E(x) = \frac{\alpha}{\alpha + \beta}$$

$$\text{Var}(x) = \frac{\alpha \beta}{(\alpha + \beta + 1)(\alpha + \beta)^2}$$

5.10. DISTRIBUCION NORMAL

Como se dijo en la introducción del capítulo, la distribución de variables aleatorias más importante es la llamada distribución Normal o de Gauss.

Si x es una variable aleatoria continua con función de densidad:


$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-1/2 \frac{(x - \mu)^2}{\sigma^2}} \quad \text{para } -\infty < x < +\infty$$

entonces x , es una variable aleatoria normalmente distribuida con parámetros μ y σ , siendo μ cualquier número y σ positivo ⁸.

⁷ Para una prueba de $\int_{-\infty}^{\infty} f(x)dx = 1$. Introduction to the Theory of Statistics, Alexander Mood, Franklin Graybill, op. cit., pág. 130.

⁸ Para una demostración de $\int_{-\infty}^{\infty} f(x)dx = 1$; Mood e Graybill, op. cit., pág. 123.

La representación gráfica de $f(x)$ es una curva en forma de campana.



Esta función de densidad tiene como peculiares características las siguientes:

- 1) $f(x)$ es asintótica al eje de abscisas: es decir $f(x)$ tiende a cero, cuando x tiende a $+\infty$ o a $-\infty$.
- 2) El máximo valor de $f(x)$ es $f(\mu)$
- 3) $f(x)$ es simétrica alrededor de μ
- 4) Los puntos de inflexión de $f(x)$ se dan en $x = \mu \pm \sigma$

Para indicar abreviadamente que una variable aleatoria se distribuye normalmente con parámetros μ y σ^2 , escribiremos $x \sim N(\mu, \sigma^2)$

5.11. VALOR ESPERADO Y VARIANZA DE UNA VARIABLE NORMALMENTE DISTRIBUIDA

La función generatriz de momentos de una variable que se distribuye normalmente es:

$$\begin{aligned} m_x(k) &= E[e^{xk}] = \int_{-\infty}^{\infty} e^{xk} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\frac{(x-\mu)^2}{\sigma^2}} dx = e^{k\mu} e^{k^2\sigma^2/2} \int_{-\infty}^{\infty} e^{xk} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\frac{(x-\mu)^2}{\sigma^2}} dx = \\ &= e^{k\mu} \int_{-\infty}^{\infty} e^{k(x-\mu)} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\frac{(x-\mu)^2}{\sigma^2}} dx = e^{k\mu} \int_{-\infty}^{\infty} e^{k(x-\mu)} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}[(x-\mu)^2 - 2k\sigma^2(x-\mu)]} dx \end{aligned}$$

Ahora bien:

$$\begin{aligned} (x-\mu)^2 - 2k\sigma^2(x-\mu) &= (x-\mu)^2 - 2k\sigma^2(x-\mu) + \sigma^4k^2 - \sigma^4k^2 = \\ &= [(x-\mu) - \sigma^2k]^2 - \sigma^4k^2 \end{aligned}$$

luego,

$$\begin{aligned} m_x(k) &= e^{k\mu} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}[(x-\mu) - \sigma^2k]^2 + \frac{1}{2}\sigma^2k^2} dx = \\ &= e^{k\mu} e^{1/2\sigma^2k^2} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\frac{[x-(\mu+\sigma^2k)]^2}{\sigma^2}} dx \end{aligned}$$

Haciendo $\mu + \sigma^2k = \beta$, tenemos:

$$m_x(k) = e^{k\mu + 1/2\sigma^2k^2} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\frac{(x-\beta)^2}{\sigma^2}} dx$$

Se puede observar que la integral de la expresión anterior es igual a uno, pues es la integral entre $-\infty$ y $+\infty$ de una función de densidad normal con parámetros β y σ^2 ; luego la función generatriz de momentos de $x \sim N(\mu, \sigma^2)$, es

$$m_x(k) = e^{k\mu + 1/2\sigma^2k^2}$$

Derivando $m_x(k)$ respecto a k , obtenemos

$$\frac{d}{dk} m_x(k) = e^{k\mu + 1/2\sigma^2k^2} (\mu + \sigma^2k)$$

La derivada para $k = 0$ es:

$$E(k) = \left. \frac{d}{dk} m_x(k) \right|_{k=0} = \mu$$

La segunda derivada es:

$$\frac{d}{dk} m_x(k) = e^{k\mu + \frac{\sigma^2k^2}{2}} \left[\sigma^2 + (\mu + \sigma^2k)^2 \right]$$

para $k = 0$, se tiene, $E(x^2) = \sigma^2 + \mu^2$, luego

$$\text{Var}(x) = \sigma^2 + \mu^2 - \mu^2 = \sigma^2$$

$$E(x) = \mu$$

$$\text{Var}(x) = \sigma^2$$

Es decir que los parámetros μ y σ de la función de densidad son respectivamente la media y desviación típica de la variable.

5.12. PROPIEDADES DE LAS VARIABLES NORMALES

Teorema: Una variable aleatoria combinación lineal de variables aleatorias normales independientes es una variable normal; en otras palabras:

Sean $x_1, x_2, \dots, x_n$ variables aleatorias normales independientes con medias $\mu_1, \mu_2, \dots, \mu_n$ y varianzas $\sigma_1^2, \sigma_2^2, \dots, \sigma_n^2$, sea

$$U = \sum_{i=1}^n a_i x_i$$

entonces U es una variable normal con media $\sum_{i=1}^n a_i \mu_i$ y varianza $\sum_{i=1}^n a_i^2 \sigma_i^2$, donde las a_i son constantes.

Prueba:

$a_i x_i$ es una variable con media $a_i \mu_i$ y varianza $a_i^2 \sigma_i^2$ (secciones 2.4 y 2.5).

El valor esperado de una suma es la suma de valores esperados (sección 3.5)

$$E(U) = E\left[\sum_{i=1}^n a_i x_i\right] = \sum_{i=1}^n a_i \mu_i$$

La varianza de una suma de variables independientes es igual a la suma de varianzas (sección 3.5),

$$\text{Var}(U) = \text{Var}\left(\sum_{i=1}^n a_i x_i\right) = \sum_{i=1}^n a_i^2 \sigma_i^2$$

Resta probar que U es normal; probaremos que la función generatriz de momentos de U es la función generatriz de momentos de una variable normal.

U es suma de variables aleatorias independientes y según sección 3.5, su función generatriz de momentos es el producto de las funciones generatrices de momentos de los sumandos.

$$\begin{aligned} m_U(k) &= m_{a_1 x_1}(k) \cdot m_{a_2 x_2}(k) \cdot \dots \cdot m_{a_n x_n}(k) = \\ &= E\left[e^{x_1(a_1 k)}\right] E\left[e^{x_2(a_2 k)}\right] \cdot \dots \cdot E\left[e^{x_n(a_n k)}\right] = \\ &= m_{x_1}(a_1 k) m_{x_2}(a_2 k) \cdot \dots \cdot m_{x_n}(a_n k) \end{aligned}$$

$m_{x_i}(a_i k)$ es la función generatriz de momentos de x_i con argumento $a_i k$ en lugar de k , $i = 1, 2, \dots, n$, luego

$$m_U(k) = e^{\mu_1 a_1 k + \frac{1}{2} \sigma_1^2 a_1^2 k^2} \cdot e^{\mu_2 a_2 k + \frac{1}{2} \sigma_2^2 a_2^2 k^2} \cdot \dots \cdot e^{\mu_n a_n k + \frac{1}{2} \sigma_n^2 a_n^2 k^2} \quad (\text{Ver sección anterior}).$$

$$m_U(k) = e^{\sum_{i=1}^n \left(\mu_i a_i k + \frac{1}{2} \sigma_i^2 a_i^2 k^2 \right)} = e^{k \sum_{i=1}^n a_i \mu_i + \frac{1}{2} k^2 \sum_{i=1}^n a_i^2 \sigma_i^2}$$

Esta es la función generatriz de momentos de una variable normal con media $\sum_{i=1}^n a_i \mu_i$ y varianza $\sum_{i=1}^n a_i^2 \sigma_i^2$.

Si, por ejemplo, $x \sim N(4, 8)$, $y \sim N(3, 2)$, $z \sim N(0, 4)$, independientes, entonces $U = 4x + 3y + 2z$ será normal con media $16 + 9 + 0 = 25$ y varianza $16 \times 8 + 9 \times 2 + 4 \times 4 = 162$. $U \sim N(25, 162)$.

Corolario 1: La suma de variables aleatorias normales independientes es normal, con media, suma de las medias y varianza, suma de varianzas.

Corolario 2: Si x es una variable normal con media μ y varianza σ^2 , entonces $Z = ax + b$, donde a y b son constantes, es una variable normal con media $a\mu + b$ y varianza $a^2 \sigma^2$.

Z es combinación lineal de una variable normal, luego Z es normal; además,

$$E(Z) = E(ax + b) = aE(x) + b = a\mu + b$$

$$\text{Var}(Z) = \text{Var}(ax + b) = a^2 \text{Var}(x) = a^2 \sigma^2$$

En particular si $y = \frac{x - \mu}{\sigma}$, entonces " y " es una variable normal con media cero y varianza uno. En efecto,

$$E(y) = \frac{E(x) - \mu}{\sigma} = \frac{\mu - \mu}{\sigma} = 0$$

$$\text{Var}(y) = \text{Var}\left(\frac{x - \mu}{\sigma}\right) = \frac{\text{Var}(x)}{\sigma^2} = \frac{\sigma^2}{\sigma^2} = 1$$

La variable normal " y ", con media cero y varianza uno, juega un papel importantísimo en el cálculo de probabilidades de las variables normales, como se verá en la próxima sección.

Por último, se mencionará, sin prueba, una importante propiedad de las variables normales. Se recordará que en el capítulo tres se estableció que dos variables independientes

eran no correlacionadas, pero el recíproco no era cierto en general. En el caso de variables normales si son no correlacionadas, i. e., su covarianza es cero, son independientes.

5.13. CALCULO DE PROBABILIDADES EN LA DISTRIBUCION NORMAL

Supongamos que se desea obtener la probabilidad de que una variable $x \sim N(\mu, \sigma^2)$ está en el intervalo (a,b) . Esta probabilidad es,

$$P(a \leq x \leq b) = \int_a^b \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2} \frac{(x-\mu)^2}{\sigma^2}} dx$$

El valor de la integral puede ser calculado por integración pero obviamente es un cálculo tedioso. Afortunadamente esta integral, y en consecuencia las probabilidades de cualquier variable normal, puede ser calculada fácilmente mediante una transformación de la variable x en otra variable “ y ” normal con parámetros 0 y 1. Las probabilidades correspondientes a esta variable “ y ” han sido tabuladas:

$$\text{Si hacemos } y = \frac{x - \mu}{\sigma}, \quad dy = \frac{1}{\sigma} dx$$

la integral anterior queda transformada:

$$P(a \leq x \leq b) = \int_a^b \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2} \frac{(x-\mu)^2}{\sigma^2}} dx = \int_{\frac{a-\mu}{\sigma}}^{\frac{b-\mu}{\sigma}} \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2} y^2} dy$$

Esta última integral representa la probabilidad de que la variable “ y ”, que sabemos es normal $(0,1)$, esté entre $\frac{a-\mu}{\sigma}$ y $\frac{b-\mu}{\sigma}$ y esta probabilidad se encuentra tabulada. (Tabla I).

Entonces

$$P(a \leq x \leq b) = P\left(\frac{a-\mu}{\sigma} \leq y \leq \frac{b-\mu}{\sigma}\right)$$

siendo $y \sim N(0,1)$.



La variable $y \sim N(0,1)$ se conoce como variable normal estandarizada o tipificada y el proceso de transformación de $x \sim N(\mu, \sigma^2)$ en $y \sim N(0,1)$ se conoce como “tipificación” o “estandarización” de la variable x .

EJEMPLO 5.8.

Dada una variable $x \sim N(20,9)$. Calcular:

i) $P(25 \leq x \leq 27)$

Gráficamente la probabilidad pedida es el área debajo de $f(x)$ entre 25 y 27 (área sombreada)




$$P(25 \leq x \leq 27) = P\left(\frac{25-20}{3} \leq y \leq \frac{27-20}{3}\right) = P(1,66 \leq y \leq 2,33) =$$

$$= F(2,33) - F(1,66) = 0,9901 - 0,9515 = 0,0386$$

Obviamente la escala del segundo gráfico que corresponde a la variable normal tipificada no guarda una correcta relación con el de la variable sin tipificar. Si la escala de ambos gráficos fuese la misma, la distancia entre 25 y 27 ciertamente no podría ser igual a la distancia entre 1,66 y 2,33. La gráfica de la variable tipificada debería ser más leptocúrtica y concentrada, pues tiene menor varianza. La razón por la cual los gráficos se presentan iguales es de tipo didáctico, de manera que se vea que las áreas bajo ambas curvas son iguales.

ii) $P(18 \leq x \leq 24)$

Gráficamente la probabilidad pedida es el área (sombreada) bajo la curva entre 18 y 24.




$$P(18 \leq x \leq 24) = P(-0,66 \leq y \leq 1,33) = F(1,33) - F(-0,66)$$

Las tablas no dan las probabilidades de que "y" sea menor que un número negativo; pero recordando que la curva normal es simétrica alrededor de cero, la probabilidad de que "y" sea menor que -0,66 (área a la izquierda de -0,66) es igual a la probabilidad de que "y" sea mayor que 0,66 (área a la derecha de 0,66). La probabilidad de que "y" sea mayor que 0,66 es uno menos la probabilidad que sea menor que 0,66; entonces $F(-0,66) = 1 - F(0,66)$; luego,

$$P(18 \leq x \leq 24) = P(-0,66 \leq y \leq 1,33) = F(1,33) - [1 - F(0,66)] =$$

$$\text{iii) } P(x \leq 23) = 0,9082 - 1 + 0,7454 = 0,6536$$


La probabilidad pedida es el área (sombreada) a la izquierda de 23



$$P(x \leq 23) = P(y \leq 1) = F(1) = 0,8413$$

$$\text{iv) } P(15 \leq x \leq 17)$$

La probabilidad pedida es el área (sombreada) entre 15 y 17.



$$P(15 \leq x \leq 17) = P(-1,66 \leq y \leq -1) = F(-1) - F(-1,66)$$


Siguiendo razonamiento similar al de la parte (ii); $F(-1) = 1 - F(1)$; $F(-1,66) = 1 - F(1,66)$; luego

$$P(-1,66 \leq y \leq -1) = 1 - F(1) - [1 - F(1,66)] = F(1,66) - F(1) = 0,1102$$

Al mismo resultado llegamos si observamos que por simetría el área entre -1,66 y -1 es igual al área entre 1 y 1,66; o sea, $P(1 \leq y \leq 1,66)$

$$\text{v) } P(x \leq 12,5)$$



La probabilidad pedida es el área (sombreada) a la izquierda de 12.5.





$$P(x \leq 12,5) = P(y \leq -2,5) = F(-2,5) = 1 - F(2,5) = 1 - 0,9938 = 0,0062$$

$$\text{vi) } P(x \geq 21,95)$$

La probabilidad pedida es el área (sombreada) a la derecha de 21,95.



$$P(x \geq 21,95) = P(y \geq 0,65) = 1 - F(0,65) = 1 - 0,7422 = 0,2578$$



$$P(x \geq 14,75) = P(y \geq -1,75) = P(y \leq 1,75) = F(1,75) = 0,9599$$

EJEMPLO 5.9.


Otro problema que se puede plantear al tratar la distribución normal es el siguiente: Dada una probabilidad, hallar el valor límite de la variable al que corresponde esa probabilidad. Sea $x \sim N(10,4)$

- i) Calcular el número k de tal forma que $P(x \geq k) = 0,7517$. Como sabemos que la curva normal es simétrica alrededor de la media, el número k debe ser un

número menor que 10, pues el área a la derecha de 10 es 0,5, mientras que el área a la derecha del número pedido es $0,7517 > 0,5$. Tipificando tenemos:

$$P(x \geq k) = P\left(y \geq \frac{k-10}{2}\right) = 0,7517$$

Por el razonamiento anterior $(k-10)/2$ debe ser negativo (menor que la media 0); gráficamente (área sombreada = 0,7517).



Por simetría, si el número $(k-10)/2$ tiene a su derecha un área igual a 0,7517, el número $-(k-10)/2$ tiene a su izquierda un área igual (0,7517); luego,


$$F\left[\frac{-(k-10)}{2}\right] = 0,7517. \text{ En las tablas encontramos que:}$$

$$\frac{-(k-10)}{2} = 0,68 \Rightarrow k = 8,64$$

- ii) Calcular el número k de tal forma que $P(x \geq k) = 0,0495$.

$$P(x \geq k) = P\left(y \geq \frac{k-10}{2}\right) = 0,0495$$

$(k-10)/2$ es mayor que cero, puesto que a su derecha tiene un área menor que 0,5.




El área a la izquierda de $(k-10)/2$ es uno menos el área a la derecha; luego:

$$F\left(\frac{k-10}{2}\right) = 1 - 0,0495 = 0,9505 \Rightarrow \frac{k-10}{2} = 1,65 \Rightarrow k = 13,30$$

- iii) Calcular el número k de tal forma que $P(x \leq k) = 0,2236$

$(k-10)/2$ es menor que cero, puesto que a su izquierda tiene un área menor que 0,5.



$-(k-10)/2$ tiene a su derecha un área igual a 0,2236; o sea, tiene a su izquierda un área igual a 0,7764. Luego,

$$F[-(k-10)/2] = 0,7764$$

En las tablas,


$$-(k-10)/2 = 0,76 \Rightarrow k = 8,48$$

iv) Calcular el número k de tal forma que $P(8 \leq x \leq k) = 0,8314$

$$P(8 \leq x \leq k) = P\left(-1 \leq y \leq \frac{k-10}{2}\right) = F\left(\frac{k-10}{2}\right) - F(-1) =$$

$$= F\left(\frac{k-10}{2}\right) - [1 - F(1)] = 0,8314$$

$$F\left(\frac{k-10}{2}\right) = 1 - F(1) + 0,8314 = 0,9901$$



$$\frac{k-10}{2} = 2,33 \Rightarrow k = 14,66$$

El número que tiene a su derecha un área igual a α , en la distribución normal tipificada, se representa por k_α , o sea

$$P(y > k_\alpha) = \alpha$$

Por ejemplo, $k_{0,2483} = 0,68$. En particular $k_{0,01} = 2,326$, $k_{0,025} = 1,96$, $k_{0,05} = 1,645$.

5.14. LA DISTRIBUCIÓN NORMAL COMO APROXIMACIÓN DE LA DISTRIBUCIÓN BINOMIAL

En el capítulo cuatro se estableció que las probabilidades de una variable binomialmente distribuida se podían aproximar por la distribución de Poisson, cuando n era grande y $p \leq 0,1$. Cuando n es grande, la probabilidad de que una variable binomial x esté entre 2 números a y b , se puede aproximar por la distribución normal.

Teorema:⁹ Si x es una variable aleatoria distribuida binomialmente con parámetros n y p , entonces la variable $y = (x - \mu)/\sigma$ se distribuye aproximadamente como normal con media cero y varianza uno, donde $\mu = np$ y $\sigma = \sqrt{npq}$; o sea

$$P(a \leq x \leq b) = \sum_{x=a}^b \binom{n}{x} p^x q^{n-x} = \int_{\frac{a-\mu-1/2}{\sigma}}^{\frac{b-\mu+1/2}{\sigma}} \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}y^2} dy =$$

$$= F\left(\frac{b-\mu+1/2}{\sigma}\right) - F\left(\frac{a-\mu-1/2}{\sigma}\right)$$

La razón de sumar y restar $1/2$ en el numerador de los límites de integración se basa en la aproximación de una variable binomial, —discreta— por una variable normal —continua—.

En la práctica esta aproximación se considera buena si $np > 5$ siendo $p \leq 1/2$; o si, $nq > 5$ siendo $p > 1/2$.

EJEMPLO 5.10.

Sabemos que una cierta máquina produce un 1% de artículos defectuosos. De la producción de un día que es de 20.000 unidades, ¿Cuál es la probabilidad de que el número de artículos defectuosos esté entre 185 y 220?

$$P(185 \leq x \leq 220) = \sum_{x=185}^{220} \binom{20.000}{x} 0,01^x 0,99^{20.000-x}$$

Según el teorema anterior:

$$P(185 \leq x \leq 220) = F\left(\frac{220-\mu+1/2}{\sigma}\right) - F\left(\frac{185-\mu-1/2}{\sigma}\right)$$

$$\mu = np = 20.000 \cdot 0,01 = 200; \quad \sigma = \sqrt{npq} = \sqrt{20.000 \times 0,01 \times 0,99} = 14,07$$

$$P(185 \leq x \leq 220) = F(1,46) - F(-1,10) = 0,7922$$

⁹ Para una prueba de este Teorema, ver E. Parzen, Modern Probability Theory and its Applications. Ed. Wiley. pp. 239 y siguientes.

5.15. DISTRIBUCION χ^2 DE PEARSON

Sean $x_1, x_2, \dots, x_n$ variables independientes normalmente distribuidas con medias $\mu_1, \mu_2, \dots, \mu_n$ y varianzas $\sigma_1^2, \sigma_2^2, \dots, \sigma_n^2$ respectivamente.

$y_1, y_2, \dots, y_n$ serán variables normalmente distribuidas, con medias cero y varianzas uno, siendo:

$$y_i = \frac{x_i - \mu_i}{\sigma_i} \quad \text{para } i = 1, \dots, n$$

Si elevamos al cuadrado estas variables y las sumamos, obtenemos una nueva variable.

$$u = \sum_{i=1}^n y_i^2 = \sum_{i=1}^n \left(\frac{x_i - \mu_i}{\sigma_i} \right)^2$$

Esta variable "u" obedece a una distribución χ^2 (ji-cuadrado) con n grados de libertad. Los grados de libertad indican el número de variables independientes cuyos cuadrados se suman.

La función de densidad de esta distribución χ^2 es

$$f(u) = \frac{1}{\left(\frac{n}{2} - 1\right)!} \frac{1}{2^{n/2}} (u)^{\left(\frac{n}{2} - 1\right)} e^{-u/2} \quad \text{para } u > 0 \quad (1)$$

$$= 0 \quad \text{para cualquier otro valor de } u$$

* Para obtenerla consideramos la función generatriz de momentos de "u".

Siendo "u" la suma de variables aleatorias independientes, su función generatriz de momentos será

$$m_u(k) = m_{y_1}(k) \cdot m_{y_2}(k) \cdot \dots \cdot m_{y_n}(k) = E(e^{ky_1^2}) \cdot E(e^{ky_2^2}) \cdot \dots \cdot E(e^{ky_n^2})$$

Ahora bien, $e^{ky_i^2}$ es una función de y_i , ($i = 1, \dots, n$), luego

$$E(e^{ky_i^2}) = \int_{-\infty}^{\infty} e^{ky_i^2} \frac{1}{\sqrt{2\pi}} e^{-1/2 y_i^2} dy_i = \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-1/2(1-2k)y_i^2} dy_i =$$

Multiplicando y dividiendo por $\sqrt{1-2k}$, se tiene:

$$E(e^{ky_i^2}) = \frac{1}{\sqrt{1-2k}} \int_{-\infty}^{\infty} \frac{\sqrt{1-2k}}{\sqrt{2\pi}} e^{-1/2(1-2k)y_i^2} dy_i$$

La integral es el área debajo de una curva normal con media cero y varianza $1/(1-2k)$; o sea la integral es igual a 1, de donde

$$E(e^{ky_i^2}) = \frac{1}{\sqrt{1-2k}}$$

Ahora bien,

$$m_u(k) = \left(\frac{1}{\sqrt{1-2k}} \right)^n = \left(\frac{1}{1-2k} \right)^{n/2} = (1-2k)^{-n/2}$$

Se observa que, para $k < 1/2$, ésta es la función generatriz de momentos de una variable que se distribuye según la distribución gamma con parámetros $\alpha = n/2$ y $\beta = 2$. Luego, su función de densidad es la dada en la expresión (1)*

La distribución χ^2 tiene una importante propiedad, y es la de su naturaleza aditiva expresada en el siguiente teorema.

Teorema: La suma de m variables independientes χ^2 con $n_1, n_2, \dots, n_m$ grados de libertad respectivamente, es una variable χ^2 con $n_1 + n_2 + \dots + n_m$ grados de libertad.

* Prueba:

La función generatriz de momentos de la suma es (sección 3.5).

$$m_{u_1+u_2+\dots+u_m}(k) = m_{u_1}(k) m_{u_2}(k) \cdot \dots \cdot m_{u_m}(k) =$$

$$= (1-2k)^{-n_1/2} (1-2k)^{-n_2/2} \cdot \dots \cdot (1-2k)^{-n_m/2} =$$

$$= (1-2k)^{\frac{-(n_1+n_2+\dots+n_m)}{2}}$$

Esta es la función generatriz de momentos de una variable χ^2 con $n_1 + n_2 + \dots + n_m$ grados de libertad.*

Las probabilidades de la distribución χ^2 están parcialmente tabuladas para ciertos valores de n (grados de libertad). (Tabla II).

La primera columna de la tabla indica los grados de libertad de la variable; y los correspondientes números en las filas hacia la derecha indican el límite para el cual la variable es menor o igual, con probabilidad dada en la primera fila.

EJEMPLO 5.11.

- i) Si u se distribuye como χ^2 con 10 grados de libertad, calcular $P(u \leq 3,94)$.

En las tablas se busca en la primera columna los grados de libertad (10), y se va hacia la derecha hasta hallar 3,94. En la primera fila se observa que la probabilidad pedida es 0,05.

- ii) Si u se distribuye como χ^2 con 24 grados de libertad. Calcular $P(u \geq 28,2)$.

Procediendo de igual forma, la tabla nos dice que la probabilidad de que " u " sea menor que 28,2 es 0,75; luego,

$$P(u \geq 28,2) = 1 - 0,75 = 0,25$$

- iii) Si " u " se distribuye como χ^2 con 16 grados de libertad. Calcular:
 $P(6,91 \leq u \leq 28,8)$


$$P(6,91 \leq u \leq 28,8) = P(u \leq 28,8) - P(u \leq 6,91) = 0,975 - 0,025 = 0,95$$

- iv) Cuando escribimos $\chi^2_{\alpha}(n)$ nos referimos a un número tal que la probabilidad de que una variable aleatoria χ^2 con n grados de libertad, sea mayor que él, es α ; o sea,

$$P[u \geq \chi^2_{\alpha}(n)] = \alpha$$

Así:

$$\chi^2_{0,25}(4) = 5,39, \quad \chi^2_{0,95}(20) = 10,85$$



5.16. VALOR ESPERADO Y VARIANZA DE UNA VARIABLE χ^2

Sabemos que la distribución χ^2 corresponde a una distribución Gamma con parámetros $\alpha = n/2$ y $\beta = 2$.

En (5.7) vimos que si x se distribuye como gamma,

$$E(x) = \alpha\beta \quad y \quad Var(x) = \alpha\beta^2$$

Luego, si u se distribuye como χ^2 con n grados de libertad,

$$E(u) = n \quad y \quad Var(u) = 2n$$

5.17. DISTRIBUCION "T" DE STUDENT


Sea x una variable aleatoria distribuida normalmente con media μ y varianza σ^2 . Sea U una variable aleatoria χ^2 con n grados de libertad independiente de la anterior.

$$\text{Sea } t = \frac{(x - \mu)/\sigma}{\sqrt{U/n}}$$

t es una variable aleatoria que obedece a la distribución "t" de Student con n grados de libertad. Es decir, el cociente de una variable $N(0,1)$ y la raíz cuadrada de una χ^2 , independiente de la anterior, dividida por sus grados de libertad, es una nueva variable t cuya función de densidad es:

$$f(t) = \frac{[(n-1)/2]!}{\sqrt{n\pi} [(n-2)/2]!} \frac{1}{[1 + t^2/n]^{n+1/2}} \quad \text{para } -\infty < t < \infty$$

La representación gráfica de $f(t)$ es una curva simétrica alrededor de su media, que es cero. Cuando el número de los grados de libertad es pequeño, la curva es aplanada con una gran proporción del área en los extremos. A medida que n se hace grande la distribución tiende a la forma de la distribución normal, de manera que para $n > 30$ se pueden utilizar los valores de la tabla normal, en lugar de los valores de distribución "t". La varianza de "t" es $Var(t) = n/n-2$ para $n > 2$.



Las probabilidades de la distribución "t" están parcialmente tabuladas para ciertos valores de n (grados de libertad). Las tablas de la "t" tienen la misma forma que las tablas de la χ^2 explicadas en el punto 5.15. (Tabla III).

EJEMPLO 5.12.

- i) Sea una variable t con 11 grados de libertad

$$P(t \leq 1,363) = 0,90$$

- ii) Sea una variable t con 6 grados de libertad

$$P(t \geq 3,143) = 1 - 0,99 = 0,01$$

- iii) Sea una variable t con 13 grados de libertad. Calcular, $P(t \geq -0,694)$


$$\text{Por simetría, } P(t \geq -0,694) = P(t \leq 0,694) = 0,75$$

- iv) Sea una variable t con 25 grados de libertad. Calcular $P(t \leq -2,06)$

$$\text{Por Simetría } P(t \leq -2,06) = P(t \geq 2,06) = 1 - P(t \leq 2,06) = 1 - 0,975 = 0,025$$

- v) $t_{\alpha}(n)$ es el número tal que la probabilidad de que una variable "t" con n grados de libertad sea mayor que él es α ; o sea,

$$P[t \geq t_{\alpha}(n)] = \alpha$$



$$t_{0,05}(15) \text{ es el número tal que } P[t > t_{0,05}(15)] = 0,05$$

En las tablas vemos que ese número es 1,753.

- vi) Calcular $t_{0,90}(10)$.

$t_{0,90}(10)$ es el número que tiene a su derecha un área igual a 0,90.

Ese número no viene dado directamente en las tablas; pero por simetría $-[t_{0,90}(10)]$ tiene a su derecha un área igual a 0,10; luego,

$$-t_{0,90}(10) = 1,372 \rightarrow t_{0,90}(10) = -1,372$$

- vii) Calcular el número k de tal forma que $P[t(13) > k] = 0,01$

$$k = t_{0,01}(13) = 2,650$$

- viii) Calcular el número k de tal forma que $P[t(21) < k] = 0,25$

k tiene a su derecha un área igual a 0,75, luego,
- k tiene a su derecha un área igual a 0,25

$$-k = t_{0,25}(21) = 0,686 \rightarrow k = -0,686$$

- ix) Calcular el número k de tal forma que $P[t(20) > k] = 0,95$

k tiene a su derecha un área igual a 0,95, luego,
- k tiene a su derecha un área igual a 0,05

$$-k = t_{0,05}(20) = 1,725 \rightarrow k = -1,725$$

- x) Calcular el número k de tal forma que $P[-k \leq t(20) \leq k] = 0,95$



En la figura se observa que k tiene a su derecha un área igual a 0,025; luego,

$$k = t_{0,025}(20) = 2,086.$$

5.18. DISTRIBUCION "F" DE SNEDECOR

Sea U una variable aleatoria χ^2 con m grados de libertad, y V una variable aleatoria χ^2 con n grados de libertad independiente de U.


$$\text{Sea } W = \frac{U/m}{V/n}$$

W es una variable aleatoria que obedece a la distribución "F" de Snedecor con m y n grados de libertad. Es decir, el cociente de 2 variables χ^2 independientes divididas por sus respectivos grados de libertad, es una nueva variable aleatoria cuya función de densidad es:

$$f(W) = \frac{\left(\frac{m+n-2}{2}\right)!}{\left(\frac{m-2}{2}\right)! \left(\frac{n-2}{2}\right)!} \left(\frac{m}{n}\right)^{\frac{m}{2}} \frac{W^{\frac{m-2}{2}}}{\left(1 + \frac{m}{n} W\right)^{\frac{m+n}{2}}} \text{ para } W > 0$$

Esta función de densidad tiene 2 parámetros m y n que son los grados de libertad de las variables χ^2 . Cuando escribimos $F(m,n)$ nos referimos a una variable "F" con m grados de libertad en el numerador (grados de libertad de la variable χ^2 del numerador), y n grados de libertad en el denominador (grados de libertad de la variable χ^2 del denominador).

La representación gráfica de la función de densidad de una variable F es:



Las probabilidades de la distribución "F" están parcialmente tabuladas para ciertos valores de m y n . Puesto que son 2 parámetros, son tablas de triple entrada. Las tablas dan las siguientes probabilidades acumuladas: 0,90, 0,95, 0,975, 0,99, 0,995. (Tabla IV)

EJEMPLO 5.13.

i) Si W es una variable "F" con 3 y 4 grados de libertad.


$$P(W \leq 9,98) = 0,975$$

ii) W es una variable "F" con 7 y 8 grados de libertad.

$$P(W > 6,18) = 1 - P(W \leq 6,18) = 1 - 0,99 = 0,01$$

iii) $F_\alpha(m,n)$ es el número tal que la probabilidad de que una variable "F" con m y n grados de libertad sea mayor que él es α ; o sea,

$$P[F \geq F_\alpha(m,n)] = \alpha$$




$$F_{0,05}(5,6) = 4,39$$

Se observa que la tabla da directamente los valores de $F_{0,10}$, $F_{0,05}$, $F_{0,025}$, $F_{0,01}$ y $F_{0,005}$. Sin embargo, indirectamente también da los valores de $F_{0,90}$, $F_{0,95}$, $F_{0,975}$, $F_{0,99}$ y $F_{0,995}$.

Esto es debido a que los valores de la variable que tienen un área a la derecha igual a $1 - \alpha$ con m y n grados de libertad, pueden ser encontrados tomando el recíproco del valor de F que tiene a su derecha un área igual a α con n (numerador) y m (denominador) grados de libertad. Es decir,

$$F_{1-\alpha}(m,n) = \frac{1}{F_\alpha(n,m)}$$

La razón de esta igualdad se ilustra a continuación



$$P(F > F_\alpha) = \alpha \quad \text{y} \quad P[F < F_{1-\alpha}(m,n)] = \alpha$$

Ahora bien,

$$P(F < F_{1-\alpha}) = P\left(\frac{1}{F} > \frac{1}{F_{1-\alpha}(m,n)}\right) = \alpha$$

Sea $1/F$ igual a F' , entonces

$$P\left(F' > \frac{1}{F_{1-\alpha}(m, n)}\right) = \alpha \quad (1)$$

Ahora bien $F' = \frac{1}{F} = \frac{1}{\frac{U/m}{V/n}} = \frac{V/n}{U/m}$ o sea F' es una variable F con n y m grados de

libertad, luego,

$$P[F' > F_{\alpha}(n, m)] = \alpha \quad (2)$$

De (1) y (2) deducimos que :

$$\frac{1}{F_{1-\alpha}(m, n)} = F_{\alpha}(n, m) \rightarrow F_{1-\alpha}(m, n) = \frac{1}{F_{\alpha}(n, m)}$$

EJEMPLO 5.14.

$$F_{0,95}(2, 3) = \frac{1}{F_{0,05}(3, 2)} = \frac{1}{19,2} = 0,0521$$

$$F_{0,90}(10, 12) = \frac{1}{F_{0,10}(12, 10)} = \frac{1}{2,28} = 0,4386$$

EJERCICIOS RESUELTOS

5.1. El tiempo que una persona tarda en llegar de su casa en Caracas al Aeropuerto de Maiquetía es una variable aleatoria uniformemente distribuida entre 40 y 60 minutos. Si esa persona tiene que tomar un avión que sale exactamente a las 8 p.m., y sale de su casa a las 7,15 p.m., ¿Cuál es la probabilidad de que llegará a tiempo para tomar el avión?

Solución:

Sea x el tiempo que tarda, x es una variable aleatoria cuya función de densidad es:

$$f(x) = \frac{1}{60 - 40} = \frac{1}{20} \text{ para } 40 \leq x \leq 60$$

Saliendo a las 7,15 p.m., la probabilidad de llegar a las 8 p.m. o antes, es la probabilidad que tarde 45 minutos o menos; o sea,

$$P(x \leq 45) = \int_{40}^{45} \frac{1}{20} dx = 0,25$$

5.2. Los clientes llegan a la caja de un Banco de acuerdo con una distribución de Poisson a un promedio de 2 por minuto. Un cliente llega y el cajero tarda en atenderlo medio minuto. Inmediatamente después cierra su caja durante dos minutos y medio para hacer una comprobación en el departamento de cuentas corrientes. ¿Cuál es la probabilidad de que no haya ningún cliente esperando cuando el cajero regrese? (Se supone que si llega algún cliente no se va).

Solución:

Si el número de clientes que llegan por minuto es Poisson con $\mu = 2$, el tiempo entre llegada de cliente es exponencial con $\theta = 1/2$ minuto.

La probabilidad de que no haya ningún cliente esperando es la probabilidad de que el cliente siguiente al que atendió antes de cerrar la caja, tarde 3 minutos o más después de la llegada del último cliente; o sea,

$$P(x \geq 3) = \int_3^{+\infty} 2e^{-2x} dx = e^{-6} = 0,002479$$

Con los mismos datos, calcular la probabilidad de que el tiempo transcurrido entre la llegada a la caja del segundo cliente y la del quinto sea menor que 4 minutos.

Solución:

Sabiendo que el tiempo de llegada entre clientes es exponencial con $\theta = 1/2$, el tiempo de espera entre la llegada del segundo cliente y del quinto es una variable gamma con parámetros $\alpha = 3$ y $\beta = 1/2$.

Luego, la probabilidad de que el tiempo sea menor que 4 minutos es:

$$P(x \leq 4) = \int_0^4 \frac{1}{\Gamma(3)(1/2)^3} x^2 e^{-2x} dx = \frac{1}{2!(1/2)^3} \int_0^4 x^2 e^{-2x} dx$$

Integrando por partes, tenemos :

$$P(x \leq 4) = 1 - 41e^{-8} = 0,9862$$

5.4. Calcular, aproximando por la normal, la probabilidad pedida en el problema 4.1. (parte iii) del Capítulo 4.

Solución:

$$n = 10 \quad p = \frac{1}{2} \quad \mu = np = 5 \quad \sigma^2 = npq = 2,5$$

Luego,

$$P(5 \leq x \leq 10) = F\left(\frac{10 - 5 + 1/2}{\sqrt{2,5}}\right) - F\left(\frac{5 - 5 - 1/2}{\sqrt{2,5}}\right) = F(3,48) - F(-0,32) = 0,6252$$

- 5.5. La demanda de un cierto bien es una variable aleatoria normalmente distribuida con media de 100 unidades. La probabilidad de que la demanda esté entre 80 y 120 unidades es 0,8. Calcular la desviación típica.

Solución:

$$x \sim N(100, \sigma^2)$$

$$P(80 \leq x \leq 120) = 0,8$$

Tipificando,

$$P(80 \leq x \leq 120) = P\left(\frac{80 - 100}{\sigma} < y < \frac{120 - 100}{\sigma}\right) = 0,8$$

$$F\left(\frac{20}{\sigma}\right) - F\left(-\frac{20}{\sigma}\right) = 0,8; \quad F\left(\frac{20}{\sigma}\right) - \left[1 - F\left(\frac{20}{\sigma}\right)\right] = 0,8$$

$$2F\left(\frac{20}{\sigma}\right) = 1,8; \quad F\left(\frac{20}{\sigma}\right) = 0,9$$

$$\text{Buscando en las tablas } \frac{20}{\sigma} \simeq 1,29 \Rightarrow \sigma = \frac{20}{1,29} = 15,5$$

EJERCICIOS PROPUESTOS

- 5.6. En el ejercicio 5.1. ¿A qué hora debe salir de la casa para que la probabilidad sea 0,75 o mayor de que llegará a tiempo?
- 5.7. Un automóvil viaja a 72 k.p.h.; la distancia en metros recorrida por el automóvil después de aplicar los frenos es una variable aleatoria uniformemente distribuida en el intervalo (10,15). Si el conductor observa un carro parado a 52 mts. y tarda dos segundos en aplicar los frenos. ¿Cuál es la probabilidad de que no choque? Nota:

Se supone que no hay posibilidad de desviarse, y que durante el tiempo entre ver el obstáculo y aplicar los frenos el automóvil sigue a la misma velocidad de 72 k.p.h.

- 5.8. Un número es escogido en el intervalo (2,4) de acuerdo con una distribución uniforme. ¿Cuál es la probabilidad de que el primer decimal del número sea un cinco?
- 5.9. Un aparato eléctrico doméstico tiene un tiempo de vida útil que obedece a una distribución exponencial con promedio de cuatro años. El vendedor quiere ofrecer una garantía por cierto tiempo, consistente en cambiar la unidad si ésta se daña irreparablemente. ¿Por cuánto tiempo debe darse la garantía, si se quiere que la probabilidad de que el aparato no se dañe durante el tiempo de garantía sea 0,95?
- 5.10. En el ejercicio 5.2, calcular:
- i) La probabilidad de que el intervalo de tiempo entre la llegada de dos clientes sucesivos sea mayor de dos minutos,
 - ii) La fracción de intervalos de tiempo entre llegadas de clientes sucesivos menores de tres minutos.
- 5.11. Considérese el problema 4.8 del capítulo 4. Supongamos que si un cliente tarda en llegar más de 20 minutos, después de que otro cliente ha llegado, hay una pérdida en eficiencia perjudicial a la empresa. ¿Cuál es la probabilidad de que esto ocurra?
- 5.12. Una empresa de servicios puede atender un promedio de 15 clientes por hora (Poisson). ¿Cuál es la probabilidad de que el servicio a un determinado cliente tarde más de 8 minutos?
- 5.13. En un examen oral se hacen tres preguntas; el tiempo que se tarda en responder cada pregunta es exponencialmente distribuido (independiente uno de otro) con media de 4 minutos. ¿Cuál es la probabilidad de que el examen de un estudiante tarde más de 10 minutos?
- 5.14. Una empresa tiene máquinas que constan de cuatro componentes. El departamento de mantenimiento está proyectado de tal forma que cada vez que una máquina llega al taller se revisan consecutivamente los cuatro componentes. El tiempo de revisión de cada componente se distribuye exponencialmente con media igual a medio día. Los tiempos de revisión son independientes entre sí. ¿Cuál es la probabilidad de que la revisión de los cuatro componentes tarde menos de 3 días?
- 5.15. Sea x una variable aleatoria normalmente distribuida con media cuatro y desviación típica dos. Calcular:
- i) $P(x \geq 3)$; ii) $P(x \leq 1)$; iii) $P(0 \leq x < 6)$; iv) el número k de tal forma que $P(x \geq k) = 0,1492$; v) El número k de tal forma que $P(k < x \leq 3.5) = 0,1467$; vi) $P(|x| \leq 2)$.

5.16. Las calificaciones de un examen de estadística dieron una media de doce con una desviación típica de tres. La calificación puede aproximarse por una variable normal. Si la calificación tipificada de un estudiante fue de menos uno, ¿qué calificación obtuvo?

5.17. Sea x una variable aleatoria normal (20,25). Calcular las siguientes probabilidades:

- i) $P(20 \leq x \leq 26)$; ii) $P(16,6 \leq x \leq 20)$; iii) $P(17,7 \leq x \leq 31,05)$;
iv) $P(24,05 \leq x \leq 29,7)$; v) $P(x \leq 17)$; vi) $P(x \geq 13,6)$; vii) $P(x \geq 30,25 \cup x \leq 12,8)$

5.18. Sea x una variable normal con media 12 y desviación típica 4. Calcular el valor de k de tal forma que:

- i) $P(12 \leq x \leq k) = 0,377$; ii) $P(x < k) = 0,8621$; iii) $P(6 \leq x \leq k) = 0,0217$;
iv) $P(k \leq x \leq 6) = 0,0217$; v) $P(13 \leq x \leq k) = 0,75$.

5.19 a 5.25.

Calcular aproximando por la normal, las probabilidades pedidas en los problemas 4.5, 4.17(ii), 4.27, 4.43, 4.44, 4.48 y 4.49 del capítulo cuatro. Se debe observar que en algunos de estos ejercicios no se cumplen las condiciones para una buena aproximación.

5.26. Una empresa productora de gas doméstico llena las bombonas mediante un proceso automático. La cantidad de gas en una bombona es una variable aleatoria normalmente distribuida, con media de 40 m³ y desviación típica de 5 m³. ¿Cuál es la probabilidad de que una bombona contenga más de 40 m³ dado que tiene más de 30 m³?

5.27. El diámetro de las rolineras producidas por cierta máquina se puede aproximar por una variable normalmente distribuida con media de 12 cm. y desviación típica de 0,10 cm. El diámetro de una rolinera es estadísticamente independiente del diámetro de las otras. De las rolineras producidas en un día no se aceptarán un 40%, el 20% de diámetros más largos y el 20% de diámetros más cortos. ¿Cuáles son los diámetros más largos y más cortos entre las aceptadas?

5.28. La duración de las baterías para automóvil producidas por una empresa puede aproximarse por una variable aleatoria normalmente distribuida, con media de 10 meses y desviación típica de 2 meses. Si se da una garantía de 8 meses a los compradores de baterías. ¿Qué proporción de las baterías no cumplirán la garantía?

5.29. Sea x una variable aleatoria normal con media 30 y varianza 5, y una variable aleatoria normal con media 10 y varianza 2, z una variable aleatoria normal con media 15 y varianza tres, siendo x , y , z independientes. Sea U la suma de los cuadrados de las variables x , y , z tipificadas. Calcular:

- i) $P(U \geq 4,11)$; ii) $P(U \leq 12,84)$; iii) $P(0,115 \leq U \leq 2,37)$.

5.30. Sean $x_1, x_2, \dots, x_{14}$ variables normales independientes con media 4 y varianza 1. ¿Cuál es la probabilidad de que la suma de los cuadrados de las desviaciones de las variables respecto a la media, sea menor que 17,12?

5.31. Sea x una variable aleatoria que se distribuye según la distribución "t" con 21 grados de libertad. Calcular:

- i) $P(x \geq 1,721)$; ii) $P(x \leq 2,518)$; iii) $P(0,686 \leq x \leq 2,831)$

5.32. Sea x una variable aleatoria que se distribuye según la distribución "t" con 13 grados de libertad. Calcular:

- i) $P(x \leq -1,35)$; ii) $P(x \geq -2,65)$; iii) $P(-1,771 \leq x \leq -0,694)$;
iv) $P(-2,16 \leq x \leq 3,012)$

5.33. Sea W una variable aleatoria "F" con 8 y 10 grados de libertad. Calcular:

- i) $P(W \leq 3,85)$; ii) $P(W \geq 6,12)$; iii) $P(2,38 \leq W \leq 5,06)$

5.34. Sea W una variable aleatoria "F" con 12 y 6 grados de libertad. Calcular:

- i) El número que tiene a su derecha un área igual a 0,1, ii) El número que tiene a su derecha un área igual a 0,95.

5.35. Supongamos que por los records del Observatorio de Caracas, se puede inferir que la lluvia diaria en mm. que cae en Caracas, obedece a una distribución gamma con parámetros $\alpha = 3$ y $\beta = 6$. ¿Cuál es la probabilidad de que en un día determinado caiga en Caracas menos de 18 mm?

5.36. Una persona tiene un sueldo mensual de Bs. 15.000. Sus gastos mensuales en alimentación y vivienda son una variable aleatoria normal con media de Bs. 9.000 y desviación típica de Bs. 3.000; asimismo sus otros gastos mensuales son una variable aleatoria normal, independiente de la anterior, con media de Bs. 4.000 y desviación típica de Bs. 1.000. Para contestar las siguientes preguntas haga los supuestos que considere necesarios.

- i) ¿Cuál es la probabilidad de que en un mes determinado ahorre menos de Bs. 500?
ii) ¿Cuál es la probabilidad de que sus gastos anuales en alimentación y vivienda sean mayores de Bs. 100.000?
iii) ¿Cuál debe ser su sueldo mensual para tener una probabilidad de 0,90 de que cubrirá sus gastos mensuales?
iv) Si en un determinado mes la persona tiene ingresos adicionales procedentes de una inversión de Bs. 500.000 y el rendimiento mensual de la inversión es una variable aleatoria normal con media de 1% y varianza de 0,0001. ¿Cuál es la probabilidad de que en ese mes sus ingresos totales sean mayores que sus gastos totales?

5.37. Determine razonadamente la veracidad o falsedad de las siguientes afirmaciones:

a) El número de hombres que llega a una peluquería unisex en un intervalo de tiempo es una variable Poisson con media μ_1 . El número de mujeres que llega en el mismo lapso es una variable Poisson independiente de la anterior con media μ_2 . Entonces el tiempo de llegada entre dos personas de cualquier sexo es una variable exponencial con media $1 / (\mu_1 + \mu_2)$.

b) La suma de cinco variables normales independientes, idénticamente distribuidas con media μ y varianza σ^2 , tipificadas es una variable normal tipificada.

5.38. Determine razonadamente cuál de las respuestas es correcta en:

Si una variable aleatoria tiene su campo de existencia $(-\infty, +\infty)$ puede obedecer a la siguiente distribución de probabilidades:

- a) Normal
- b) Uniforme
- c) Exponencial
- d) t de Student
- e) χ^2
- f) F
- g) Más de una es correcta
- h) Ninguna de las anteriores

Sean $x_1 \sim N(0, 4)$; $x_2 \sim N(2, 5)$ y $x_3 \sim N(1, 6)$ variables independientes, entonces $z = 3x_1 + x_2 - 2x_3$ es:

- a) $N(0, 1)$
- b) $N(3, 15)$
- c) $N(0, 17)$
- d) Ninguna de las anteriores.

CAPITULO VI

DESIGUALDAD DE CHEBYCHEV, LEY DE LOS GRANDES NUMEROS, TEOREMA DEL LIMITE CENTRAL

6.1. INTRODUCCION

En la mayoría de las distribuciones de probabilidades estudiadas, si sabemos la forma de la distribución (normal, binomial, etc.) el conocimiento de la media y varianza de las variables, nos ponen en capacidad de especificar en forma completa la función de densidad, y por lo tanto determinar en forma exacta las probabilidades relacionadas con la variable aleatoria en estudio. En muchos problemas prácticos se tiene información acerca del valor esperado de la variable y su varianza, pero no hay ninguna especificación acerca de la distribución de probabilidades asociada a la variable. Con los instrumentos hasta ahora vistos no es posible en este caso afirmar nada acerca de las probabilidades de la variable. Sin embargo, existen instrumentos en la estadística que nos dan alguna luz sobre las distribuciones probabilísticas, conociendo únicamente la media y la varianza. En este capítulo se van a desarrollar 3 instrumentos importantes en el cálculo de probabilidades y la estadística aplicada: La Desigualdad de Chebychev, la Ley de los Grandes Números, y el Teorema del Límite Central.

* 6.2. DESIGUALDAD DE CHEBYCHEV

Supongamos que tenemos una variable aleatoria con media finita $E(x)$ y varianza finita σ^2 y que queremos conocer la probabilidad de que la diferencia entre la variable x

y su media $E(x)$ sea menor o igual que en un valor dado $h > 0$; es decir, estamos interesados en determinar

$$P(|x - E(x)| \leq h) \quad \text{siendo } h > 0$$

Si conociéramos la función de densidad, podríamos calcular esta probabilidad en forma exacta.

$$\begin{aligned} P(|x - E(x)| \leq h) &= P(-h \leq x - E(x) \leq h) = \\ &= \int_{E(x)-h}^{E(x)+h} f(x) dx \quad \text{en el caso de que } x \text{ sea continua} \\ &= \sum_{x=E(x)-h}^{E(x)+h} f(x) \quad \text{en el caso de que } x \text{ sea discreta} \end{aligned}$$

Si no conocemos la función de densidad, la llamada Desigualdad de Chebychev nos da alguna información acerca de esa probabilidad.

Teorema: Si x es una variable con media y varianza finitas, $E(x)$ y σ^2 respectivamente. Para cualquier $h > 0$ tenemos:

$$P(|x - E(x)| \leq h) \geq 1 - \frac{\sigma^2}{h^2}$$

Prueba

$$\text{Sabemos que } \sigma^2 = E[x - E(x)]^2 = \int_{-\infty}^{+\infty} [x - E(x)]^2 f(x) dx$$

Esta integral podemos descomponerla en la suma de 3 integrales,

$$\sigma^2 = \int_{-\infty}^{E(x)-h} [x - E(x)]^2 f(x) dx + \int_{E(x)-h}^{E(x)+h} [x - E(x)]^2 f(x) dx + \int_{E(x)+h}^{+\infty} [x - E(x)]^2 f(x) dx$$

La segunda integral es necesariamente no negativa, puesto que el integrando $[x - E(x)]^2 f(x) \geq 0$ y $E(x) + h > E(x) - h$; luego, eliminando esa integral no negativa.

$$\sigma^2 \geq \int_{-\infty}^{E(x)-h} [x - E(x)]^2 f(x) dx + \int_{E(x)+h}^{+\infty} [x - E(x)]^2 f(x) dx$$

Por otro lado,

$$(1) \int_{-\infty}^{E(x)-h} [x - E(x)]^2 f(x) dx \geq \int_{-\infty}^{E(x)-h} h^2 f(x) dx$$

En efecto para $x \leq E(x) - h$, intervalo de integración en (1) tenemos que $[x - E(x)]^2 \geq h^2$ porque $x \leq E(x) - h \Rightarrow x - E(x) \leq -h \Rightarrow x - E(x) < 0$, luego su cuadrado debe ser mayor o igual que el cuadrado de $-h$.

Igualmente,

$$(2) \int_{E(x)+h}^{+\infty} [x - E(x)]^2 f(x) dx \geq \int_{E(x)+h}^{+\infty} h^2 f(x) dx$$

porque para $x \geq E(x) + h$, intervalo de integración en (2), tenemos que

$$[x - E(x)]^2 \geq h^2$$

Cumplíendose (1) y (2) es obvio que,

$$\sigma^2 \geq \int_{-\infty}^{E(x)-h} h^2 f(x) dx + \int_{E(x)+h}^{+\infty} h^2 f(x) dx$$

$$\therefore \sigma^2 \geq h^2 \left[\int_{-\infty}^{E(x)-h} f(x) dx + \int_{E(x)+h}^{+\infty} f(x) dx \right]$$

Las 2 integrales nos dan las probabilidades de que x sea menor o igual que $E(x) - h$, y que x sea mayor o igual que $E(x) + h$ respectivamente; es decir,

$$\sigma^2 \geq h^2 \{1 - P[E(x) - h \leq x \leq E(x) + h]\}$$

$$\therefore \sigma^2 \geq h^2 - h^2 P[|x - E(x)| \leq h]$$

$$P[|x - E(x)| \leq h] \geq 1 - \frac{\sigma^2}{h^2}$$

Debe notarse que esta desigualdad es trivial cuando $\sigma^2 > h^2$, pues en este caso

$$1 - \frac{\sigma^2}{h^2} < 0$$

La desigualdad de Chebychev puede expresarse también de la siguiente forma:

$$P[|x - E(x)| > h] \leq \frac{\sigma^2}{h^2}$$

En efecto, $P[|x - E(x)| \leq h] = 1 - P[|x - E(x)| > h]$,

$$\text{o sea, } 1 - P[|x - E(x)| > h] \geq 1 - \frac{\sigma^2}{h^2}$$

Restando uno a los dos miembros

$$-P[|x - E(x)| > h] \geq -\frac{\sigma^2}{h^2} \Rightarrow P[|x - E(x)| > h] \leq \frac{\sigma^2}{h^2}$$

EJEMPLO 6.1.

Una variable aleatoria tiene media igual a 10 y varianza igual a 25. Calcular un límite superior para la probabilidad de que la variable se desvíe de su media en más de 6 unidades.

$$E(x) = 10; \quad \sigma^2 = 25; \quad h = 6$$

$$P[|x - E(x)| > 6] \leq \frac{25}{36} = 0,69$$

La desigualdad de Chebychev se suele expresar también como la probabilidad de que la variable se desvíe de su media en menos de un múltiplo de la desviación típica. Si hacemos $h = k\sigma$, donde k es no negativo, tenemos:

$$P[|x - E(x)| \leq k\sigma] \geq 1 - \frac{1}{k^2} \quad \text{o} \quad P[|x - E(x)| > k\sigma] \leq 1 - \frac{1}{k^2}$$

Es decir, la probabilidad de que el valor de x esté entre la media y k desviaciones típicas es al menos $1 - \frac{1}{k^2}$

EJEMPLO 6.2.

Consideremos el ejemplo 6.1. ¿Qué se puede decir acerca de la probabilidad de que x esté entre 0 y 20?

Solución:

$$P(0 \leq x \leq 20) = P(|x - 10| \leq 10) = P(|x - 10| \leq 2\sigma) \geq 1 - \frac{1}{4} = 0,75$$

* 6.3. LA LEY DE LOS GRANDES NUMEROS

Consideremos la variable aleatoria x con función de densidad $f(x) = p^x q^{1-x}$ para $x = 0, 1$, definida en la sección 4.2 sabemos que " p " representa la probabilidad de obtener un éxito en un intento de un experimento con 2 posibles resultados. Si repetimos n veces el experimento, $x_i = 1$ representa que hemos obtenido un éxito en el intento i , mientras que $x_i = 0$ significa que hemos obtenido una falla en el intento i .

Luego la frecuencia relativa de éxitos en n veces será

$$\frac{S_n}{n} \quad \text{donde } S_n = x_1 + x_2 + \dots + x_n$$

La Ley de los Grandes Números establece que para $\epsilon > 0$

$$\lim_{n \rightarrow \infty} P\left[\left|\frac{S_n}{n} - p\right| \leq \epsilon\right] = 1$$

Es decir, cuando el número de veces que se realiza el experimento tiende a infinito la probabilidad de que la frecuencia relativa de éxitos se diferencie de la verdadera probabilidad (p) en menos de un número muy pequeño (ϵ) tiende a 1.

Prueba

S_n es una variable aleatoria con media np y varianza $np(1-p)$. Luego,

$$\frac{S_n}{n} \quad \text{tiene media } p \text{ y varianza } \frac{p(1-p)}{n}$$

Por la Desigualdad de Chebychev

$$P\left[\left|\frac{S_n}{n} - p\right| \leq \epsilon\right] \geq 1 - \frac{p(1-p)}{n\epsilon^2}$$

Ahora bien, $\lim_{n \rightarrow \infty} \frac{p(1-p)}{n\epsilon^2} = 0$, puesto que $p(1-p)$ es una constante

$$\lim_{n \rightarrow \infty} P\left[\left|\frac{S_n}{n} - p\right| \leq \epsilon\right] = 1$$

Esta ley tiene importancia en el sentido de que sirve para calcular el mínimo número de intentos necesarios para que la frecuencia relativa de éxito en un experimento no difiera

de la verdadera probabilidad en más de una magnitud determinada, con una probabilidad mayor o igual a una dada. En efecto, la ley nos dice que cuando $n \rightarrow \infty$, $S_n/n \rightarrow p$ con probabilidad uno, si el número de intentos es suficientemente grande pero finito, y se determina una probabilidad α , podemos hallar un valor de n tal que

$$(3) \quad P\left[\left|\frac{S_n}{n} - p\right| \leq \varepsilon\right] \geq \alpha \quad \text{para } 0 \leq p \leq 1$$

Por la desigualdad de Chebychev tenemos:

$$P\left[\left|\frac{S_n}{n} - p\right| \leq \varepsilon\right] \geq 1 - \frac{p(1-p)}{n\varepsilon^2}$$

para $0 \leq p \leq 1$; tenemos que $p(1-p) \leq 1/4$, luego

$$P\left[\left|\frac{S_n}{n} - p\right| \leq \varepsilon\right] \geq 1 - \frac{1}{4n\varepsilon^2}$$

La desigualdad (3) se cumple si $\alpha \leq 1 - \frac{1}{4n\varepsilon^2} \Rightarrow$

$$\Rightarrow (4) \quad n \geq \frac{1}{4\varepsilon^2(1-\alpha)}$$

Luego si el número de veces que se realiza el experimento satisface (4), se satisface necesariamente (3); es decir, tendremos una probabilidad mayor o igual a α de que la frecuencia relativa difiera de la verdadera probabilidad en un número tan pequeño como descemos.

EJEMPLO 6.3.

Supongamos que queremos encontrar la proporción de habitantes de Caracas que favorece la construcción de un metro. ¿A cuántos habitantes debemos preguntar para que la probabilidad de que la proporción observada a favor del proyecto difiera de la verdadera proporción en menos del 5%, sea 0,90 ó más?

Solución:

En este ejemplo $\alpha = 0,90$ $\varepsilon = 0,05$, luego:

$$n \geq \frac{1}{4\varepsilon^2(1-\alpha)} \Rightarrow n \geq \frac{1}{4(0,05)^2(0,10)} \Rightarrow n \geq 1.000$$

6.4. EL TEOREMA DEL LÍMITE CENTRAL

Teorema: Sean $x_1, x_2, x_3, \dots, x_n$ n variables aleatorias independientes e idénticamente distribuidas con media μ y varianza σ^2 . La suma $-S_n$ de esas variables es una variable aleatoria con media $n\mu$ y varianza $n\sigma^2$. Esa suma tiende a distribuirse normalmente. En consecuencia, la variable y tipificada,

$$y = \frac{S_n - n\mu}{\sqrt{n\sigma^2}}$$

se distribuye aproximadamente como una normal con media cero y varianza uno; es decir, $y \sim N(0,1)$.¹⁰

En otras palabras, el teorema expresa que cuando n crece sin límite, la variable y tiende a distribuirse normalmente.

* La prueba del teorema que se da a continuación es válida para aquellos casos en que las variables cuya suma se considera, tengan función generatriz de momentos.

Esta prueba restringida consiste en demostrar que cuando el número de variables aleatorias que se suman tiende a infinito, la función generatriz de momentos de y tiende a ser igual a la función generatriz de momentos de una variable normal $(0,1)$.

La función generatriz de momentos de y es:

$$m_y(k) = E[e^{yk}] = E\left[e^{\frac{(S_n - n\mu)k}{\sqrt{n\sigma^2}}}\right]$$

$$\text{como } S_n = \sum_{i=1}^n x_i$$

$$m_y(k) = E\left[e^{\frac{(x_1 + x_2 + \dots + x_n) - n\mu}{\sqrt{n\sigma^2}}k}\right] =$$

$$E\left[e^{\frac{(x_1 - \mu)k}{\sqrt{n\sigma^2}}} e^{\frac{(x_2 - \mu)k}{\sqrt{n\sigma^2}}} \dots e^{\frac{(x_n - \mu)k}{\sqrt{n\sigma^2}}}\right] =$$

Por ser las variables independientes,

¹⁰ Para una prueba general de este teorema ver E. Parzen, op. cit. pág. 430 y siguientes.

$$m_y(k) = E \left[e^{\frac{(x_1 - \mu)k}{\sqrt{n}\sigma^2}} \right] E \left[e^{\frac{(x_2 - \mu)k}{\sqrt{n}\sigma^2}} \right] \dots E \left[e^{\frac{(x_n - \mu)k}{\sqrt{n}\sigma^2}} \right]$$

Siendo $x_1, x_2, \dots, x_n$ idénticamente distribuidas, los valores esperados del segundo miembro son iguales; luego, representando cada x_i genéricamente por x tenemos,

$$m_y(k) = \left\{ E \left[e^{\frac{(x - \mu)k}{\sqrt{n}\sigma^2}} \right] \right\}^n$$

teniendo en cuenta que $e^z = 1 + z + \frac{z^2}{2!} + \frac{z^3}{3!} + \dots$

obtenemos,

$$m_y(k) = \left[E \left(1 + \frac{(x - \mu)k}{\sqrt{n}\sigma^2} + \frac{(x - \mu)^2 k^2}{2! n \sigma^2} + \frac{(x - \mu)^3 k^3}{3! n (\sqrt{n}\sigma)^3} + \dots \right) \right]^n =$$

$$= \left[1 + \frac{k}{\sqrt{n}\sigma^2} E(x - \mu) + \frac{k^2}{2! n \sigma^2} E(x - \mu)^2 + \frac{k^3}{3! n (\sqrt{n}\sigma)^3} E(x - \mu)^3 + \dots \right]^n$$

Como $E(x - \mu) = 0$, $E(x - \mu)^2 = \sigma^2$ y $E(x - \mu)^3 = \mu_3$, nos queda,

$$m_y(k) = \left[1 + \frac{k^2}{2n} + \frac{k^3}{3! n (\sqrt{n}\sigma)^3} \mu_3 + \dots \right]^n =$$

$$= \left[1 + \frac{1}{n} \left(\frac{k^2}{2} + \frac{k^3}{3! (\sqrt{n}\sigma)^3} \mu_3 + \dots \right) \right]^n =$$

Se observará que todos los términos en el paréntesis excepto el primero contienen n en el denominador; luego, si hacemos

$$U = \frac{k^2}{2} + \frac{k^3}{3! (\sqrt{n}\sigma)^3} \mu_3 + \dots$$

tenemos,

$$(5) \quad m_y(k) = \left[1 + \frac{U}{n} \right]^n \quad \text{y} \quad \lim_{n \rightarrow \infty} U = \frac{k^2}{2}$$

Sabemos que,

$$\lim_{\substack{n \rightarrow \infty \\ U = \text{constante}}} \left[1 + \frac{U}{n} \right]^n = e^{\lim U}$$

luego, tomando límites en ambos miembros de (5),

$$\lim_{n \rightarrow \infty} m_y(k) = e^{\frac{k^2}{2}}$$

Ahora bien, $e^{\frac{k^2}{2}}$ es la función generatriz de momentos de una variable normalmente distribuida con media cero y varianza uno (Ver sección 5.11), o sea que la función generatriz de momentos de y tiende a ser la función generatriz de momentos de una variable normal (0,1) cuando n tiende a infinito*. En otras palabras, la variable y se distribuye aproximadamente como una normal (0,1) cuando n es suficientemente grande. Resulta difícil determinar a partir de que valor de n es aplicable el teorema; pero en la práctica se considera útil para valores de n relativamente pequeños, a partir de $n = 10$.

Si las variables no son idénticamente distribuidas, se podría demostrar igualmente que:

$$y = \frac{\sum x_i - \sum \mu_i}{\sqrt{\sum \sigma_i^2}}$$

se distribuye aproximadamente como normal con media cero y varianza uno.

El hecho de que $y \sim N(0,1)$ implica que $S_n = \sum x_i$ es normal con media $\sum \mu_i$ y varianza $\sum \sigma_i^2$; o sea, **que la suma de variables independientes tiende a ser normal con media suma de medias y varianza suma de varianzas.**

Lo importante y útil del Teorema del Límite Central es que cualquiera que sea la distribución de las variables que se suman, ya sean discretas o continuas, su suma tiende a distribuirse normalmente, esto, como se verá más adelante, tiene un gran valor práctico.

EJEMPLO 6.4.

Una fábrica productora de alimentos envasa salsa mayonesa por medio de un proceso automático. El peso neto de un frasco se considera una variable aleatoria con un promedio de 420 gr. y una desviación típica de 15 gr.

El peso neto de cada frasco no afecta ni es afectado por el peso neto de los otros; esto es, las variables aleatorias son estadísticamente independientes. Una vez llenos

los frascos se empaquen en cajas de 72 frascos cada una; ¿Cuál es la probabilidad de que una caja contenga menos de 30 kilos de mayonesa?

Solución:

El peso neto de una caja es la suma de los pesos de los 72 frascos; luego el peso neto de la caja es una variable aleatoria S_n (suma de variables aleatorias independientes) con media 72×420 gramos y varianza 72×15^2 grs.; y por el Teorema del Límite Central,

$$y = \frac{S_n - 30.240}{\sqrt{16.200}} \sim N(0,1)$$

$$P(S_n \leq 30.000) = P\left[y \leq \frac{30.000 - 30.240}{\sqrt{16.200}}\right] = P(y \leq -1,88) = 0,0301$$

En el capítulo VII se verán aplicaciones de estos instrumentos a las muestras.

EJEMPLO 6.5.

Usar el Teorema del Límite Central para calcular n en el ejemplo 6.3.

Solución:

En este ejemplo se trata de obtener el número de habitantes que se deben preguntar, para que la probabilidad de que la proporción observada a favor del proyecto difiera de la verdadera proporción en menos del 5%, sea 0,90 ó más.

Llamemos $\bar{p}$ a la proporción observada, y p a la proporción verdadera. Tenemos que buscar un n tal que,

$$P\left[|\bar{p} - p| \leq 0,05\right] \geq 0,90$$

El resultado de cada persona encuestada puede representarse por una variable Bernoulli x_i con valor uno si la respuesta es favorable, y valor cero si es desfavorable. Cada x_i tiene valor esperado igual a p y varianza igual a $p(1-p)$, y son independientes. Consideremos su suma

$$S_n = x_1 + x_2 + \dots + x_n$$

$E(S_n) = np$; $\text{Var}(S_n) = np(1-p)$. Por el teorema del Límite Central,

$$y = \frac{S_n - np}{\sqrt{np(1-p)}} \sim N(0,1)$$

Por otro lado, $\bar{p} = S_n/n$

Entonces

$$P\left[|\bar{p} - p| \leq 0,05\right] = 0,90 \Rightarrow P\left[\left|\frac{S_n}{n} - p\right| \leq 0,05\right] = 0,90 \Rightarrow$$

$$\Rightarrow P\left[|S_n - np| \leq 0,05n\right] = 0,90$$

$$\text{Tipificando, } P\left[\left|\frac{S_n - np}{\sqrt{np(1-p)}}\right| \leq \frac{0,05n}{\sqrt{np(1-p)}}\right] = 0,90$$

$\frac{0,05n}{\sqrt{np(1-p)}}$ es el número tal que entre su negativo y él hay un área igual a 0,90

en la distribución normal (0,1), luego,

$$\frac{0,05n}{\sqrt{np(1-p)}} = 1,645$$

$$\text{Despejando } n, \text{ se obtiene } n = \frac{1,645^2 p(1-p)}{0,05^2}$$

El número de encuestados depende de la proporción verdadera " p " que no se conoce; sabiendo que $p(1-p) \leq 1/4$ se puede afirmar que

$$n \geq \frac{1,645^2}{4 \times 0,05^2}; \quad n \geq 271$$

Al sustituir en la fórmula $p(1-p)$ por $1/4$, el n hallado será en todo caso mayor o igual al que necesitamos.

EJERCICIOS RESUELTOS

- 6.1. Sean $x_1, x_2, \dots, x_{100}$ variables aleatorias independientes distribuidas según Poisson con $\mu=0,15$. Sea $S_{100} = x_1 + x_2 + \dots + x_{100}$. i) Calcular $P(S_n \geq 20)$ usando el Teorema del Límite Central; ii) Comparar el resultado con la probabilidad exacta.

Solución:

i) $S_n \sim N(15, 15)$

$$P(S_n \geq 20) = P\left(y \geq \frac{20-15}{\sqrt{15}}\right) = P(y \geq 1,29) = 0,0985$$

ii) S_n es Poisson con media 15.

$$P(S_n \geq 20) = 0,125$$

6.2. Una empresa firma un contrato para la entrega de 1.300 unidades de un producto en un mes. La empresa tiene 64 obreros, el número de unidades producidas por obrero por mes es una variable aleatoria con media de 20 unidades y $\sigma = 2$. ¿Cuál es la probabilidad de que el contrato sea cumplido?

Solución:

x_i es una variable aleatoria que representa la producción del obrero i ($i = 1, \dots, 64$) con media 20 y varianza 4.

$$S_n = x_1 + \dots + x_n \sim N(1.280, 256)$$

$$P(S_n \geq 1.300) = P\left(y \geq \frac{1.300 - 1.280}{\sqrt{256}}\right) = 0,1056$$

EJERCICIOS PROPUESTOS

- 6.3. Calcular el número de veces que debe lanzarse un dado no cargado para que la probabilidad de que la proporción de números pares que se obtengan esté entre 0,45 y 0,55 sea mayor o igual que 0,95.
- 6.4. ¿Cuántos intentos de un experimento con dos resultados A y B deben realizarse para que la probabilidad de que la frecuencia relativa de A difiera de la probabilidad "p" en no más de 0,02, sea al menos 0,90?
- 6.5. Si en el ejercicio anterior se sabe que la probabilidad de que se dé el resultado A en un intento es $p = 0,3$, calcular el número de intentos que debe realizarse, para que la probabilidad de que la frecuencia relativa de A difiera de "p" en no más de 0,02, sea al menos 0,90.

6.6. El número de clientes que llegan a una tienda en una hora es una variable aleatoria con media igual a 50 y desviación típica igual a 5. Usar la desigualdad de Chebychev para calcular un límite inferior a la probabilidad de que en una hora lleguen entre 40 y 60 clientes.

6.7. Una empresa encuestadora desea tomar una muestra de votantes, de forma que la probabilidad no sea mayor de 0,01 que la proporción en la muestra que favorece a un determinado candidato sea menor que 0,5 si la verdadera proporción es 0,52 o mayor. Use el teorema del Límite Central para calcular a cuántos votantes se debe preguntar.

6.8. Una variable aleatoria tiene media 20 y varianza 16. i) ¿Qué se puede decir acerca de la probabilidad que la variable esté entre 10 y 30? ii) Sabiendo que la probabilidad de que x sea menor que 10 es cero, ¿Qué se puede decir acerca de que x esté entre 10 y 30?

6.9. Supongamos que al lanzar un dado 5.424 veces, el número de unos que salieron fue de 708. Suponiendo que el dado no esté cargado, el valor esperado de unos obtenidos es 904. Calcular un límite superior a la probabilidad de que la diferencia entre el número de unos y su valor esperado fuera mayor que ± 196 .

6.10. Un productor de sílice empaca su producto por medio de una máquina automática que puede ser ajustada para envases de cualquier peso; la cantidad que realmente contiene cada envase es una variable aleatoria que tiene una varianza de cinco. Es decir, si la máquina se ajusta para llenar envases de "k" kgs., cada envase no tiene exactamente "k" kgs., sino que la cantidad en cada envase es una variable aleatoria con media "k" y varianza 5. Un fabricante de artículos de vidrio le compra 3.500 kgs. de sílice que deben ser enviados en envases de 100 kgs. cada uno; si la cantidad total recibida por el comprador es menor en un 1% ó más de la cantidad pedida, el comprador deducirá de la factura una cantidad de "a" bolívares; ¿Cuál es el nivel de peso más bajo en que el fabricante puede ajustar su máquina de envasado, y tener una probabilidad de 0,95 de que la factura será pagada en su totalidad?

6.11. Un cierto producto se vende en cajas de 100 unidades. Debido a la dificultad de contar el número de unidades de cada caja, éstas se van llenando hasta que el peso sea al menos de 15 gramos. Si el peso de cada unidad es una variable aleatoria con media de 0,15 gr. y varianza de 0,0004. ¿Cuál es la probabilidad de que una caja que contiene solamente 97 unidades se considere que tiene 100 unidades?

6.12. Un camión carga cajas de un cierto producto. Si el peso de cada caja es una variable aleatoria con media de 30 kgs. y desviación típica 3. ¿Cuántas cajas puede cargar el camión, de forma que la probabilidad de que el peso total sea mayor de 1 Tm. sea menor que 0,05?

33, =

6.13. En el ejercicio 6.2. ¿Cuántos obreros adicionales debe contratar si quiere que la probabilidad de cumplir el contrato sea mayor o igual a 0,95?

6.14. Determine razonadamente la veracidad o falsedad de la siguiente afirmación:

El Teorema del Límite Central dice que la suma de variables independientes e idénticamente distribuidas tiende a ser una variable normal con media cero y varianza uno cuando $n \rightarrow +\infty$.

CAPITULO VII

CONCEPTOS FUNDAMENTALES DE LA INFERENCIA ESTADISTICA

7.1. INTRODUCCION

Las preguntas que trata de contestar la Estadística, corresponden a dos tipos. El primer tipo lo constituyen aquellas que sólo tratan de obtener una descripción de un grupo de individuos que están siendo observados. Los datos obtenidos de esos individuos son reducidos a ciertos coeficientes como la media, desviación típica, percentiles, etc., que sirven para describir a ese particular grupo que ha sido observado, pero esos resultados no son utilizados para formalizar una teoría general aplicable a otros individuos similares a los anteriores, y que no han sido observados.

El segundo tipo de problemas que conciernen a la Estadística es más amplio. En estos problemas se trata de buscar conclusiones más generales. Se trata de inferir, partiendo de resultados particulares obtenidos mediante la observación de un grupo, conclusiones generales válidas para un conjunto más amplio, del cual el grupo observado es sólo una parte. Por eso, la parte de la Estadística que se ocupa de estos problemas se conoce como Inferencia Estadística.

Un ejemplo ayudará a clarificar la diferencia,

EJEMPLO 7.1.

Si queremos conocer el salario medio de los obreros de una industria, podemos proceder de 2 formas: observando el salario de todos y cada uno de los obreros de

la industria, y calculando a partir de todos los datos, la media de esos salarios. En este caso estamos simplemente describiendo una característica de un grupo en el cual hemos observado todos sus componentes. Pero podríamos solamente analizar una parte, no todos los obreros de la industria, y a partir de los datos de ese grupo escogido según una determinada técnica, inferir el salario medio para toda la industria.

La forma de llegar a esas conclusiones generales es el campo de estudio de la Inferencia Estadística.

7.2. POBLACION, MUESTRA Y MUESTRA ALEATORIA

DEFINICION 7.1.

El conjunto de elementos cuyas características tratamos de estudiar, y acerca del cual deseamos información, constituye lo que se conoce como "Población", "Universo" o "Colectivo".¹¹

DEFINICION 7.2.

El subconjunto de la población que elegimos para observar, y a partir del cual tratamos de conocer las características de la población, constituye una "muestra".

El objeto de la investigación estadística es conocer determinadas características de la población. Generalmente no es práctico, y muchas veces imposible, examinar todos los elementos de la población; por lo cual se examina una parte de esos elementos (la muestra), y a partir de la información limitada obtenida, se sacan conclusiones sobre la población.

Las poblaciones objetos de estudio pueden ser finitas o infinitas, según que el número de elementos que contienen sea finito o infinito. Los salarios de los obreros del ejemplo anterior constituyen una población finita. Un ejemplo de población infinita sería la representada por los diferentes valores que puede tener el peso de los productos obtenidos en un cierto proceso de producción.

Es obvio que en el caso de una población infinita o muy numerosa, cualquier característica tiene que ser estudiada a partir de una muestra, puesto que prácticamente es imposible o muy difícil examinar todos los elementos; pero en el caso de poblaciones

¹¹ No debe entenderse "población" como un conjunto de personas, sino como un conjunto de elementos, cualquiera que sea su naturaleza, sobre los que deseamos información, por ejemplo: productos, empresas, árboles, animales, etc.

finitas sería posible obtener la información completa mediante un censo; es decir, examinando todos los elementos de la población.

Las razones para hacer el estudio mediante una muestra que necesariamente nos provee información incompleta, son varias:

En primer lugar, porque el estudio de sólo una parte de una población resulta más económico, su costo es inferior al de hacer el estudio completo de toda la población.

En segundo lugar, los datos pueden ser obtenidos y elaborados con mayor rapidez; lo que a veces puede ser importante.

En tercer lugar, las conclusiones obtenidas a partir de una muestra, pueden ser más exactas que las obtenidas a partir de un censo. La causa de esta paradójica afirmación es sencilla de explicar. Para estudiar una muestra se necesita menos personal que cuando se desea realizar un censo; por lo tanto, puede escogerse personal más apto, así como ser entrenado más eficientemente. Además, es más fácil hacer una supervisión mejor cuando el volumen de trabajo a ser realizado es más reducido.

Por último, hay en ciertos casos una razón fundamental que impide la realización de un censo: cuando el examen de los elementos del colectivo supone su destrucción. Por ejemplo, si se quiere estimar la vida útil de los bombillos producidos en cierto proceso de producción.

Uno de los problemas más importantes que conlleva el estudio de una población por medio de muestras, es la selección apropiada de la muestra que se va a estudiar, y a partir de la cual se van a inferir las características de la población. La muestra debe ser representativa de la población de la cual se ha tomado; es decir, debe decidirse qué elementos de la población y cuántos formarán la muestra.

El estudio de las técnicas de escogencia de muestras es el objeto de la teoría del muestreo, un campo de la estadística con contenido teórico y práctico propio, cuyo estudio no es el objetivo de este texto.

Aquí se supondrá que las muestras son obtenidas a través de muestreo simple aleatorio, según el cual cada elemento de la población tiene idéntica probabilidad de ser escogido en una muestra; dicho de otro modo, cada una de las muestras diferentes de tamaño n que se pueden obtener de la población, tienen igual probabilidad de ser escogidas. Además se trabajará con la hipótesis de que las poblaciones estudiadas son infinitas o en el caso de ser finitas el muestreo se realiza con reemplazamiento.¹²

Bajo estas condiciones, los elementos de la muestra son variables aleatorias independientes, y las muestras reciben el nombre de "muestras aleatorias" cuya definición es la siguiente:

¹² El caso de poblaciones finitas y muestreo sin reemplazamiento se tratará someramente en el Capítulo IX.

DEFINICION 7.3.

Dada una población con función de densidad $f(x)$, si $x_1, x_2, \dots, x_n$, son n variables aleatorias independientes e idénticamente distribuidas cada una con función de densidad $f(x)$, entonces $x_1, x_2, \dots, x_n$ constituyen una muestra aleatoria de tamaño n de la población, cuya función de densidad es $f(x)$.

La definición anterior puede ser aclarada con un ejemplo: Supongamos que el valor de las compras por cliente en un establecimiento es una variable aleatoria exponencial con media θ . Si escogemos tres clientes al azar un determinado día, el valor de las compras de cada uno será una variable aleatoria exponencial con media θ e independiente del valor de las compras de los otros dos clientes; de forma que si x_i ($i = 1, 2, 3$) representa el valor de las compras del cliente i ; x_1, x_2 y x_3 , serán variables aleatorias independientes e idénticamente distribuidas, constituyendo una muestra aleatoria de la población que se trata de estudiar.

EJEMPLO 7.2.

Una población está compuesta de 10 elementos con los siguientes valores, 1, 3, 3, 5, 5, 5, 6, 6, 7, 7. Si x representa los valores de esa población, se podría considerar x como una variable aleatoria con la siguiente función de densidad:

x	1	3	5	6	7
$f(x)$	1/10	2/10	3/10	2/10	2/10

Tomemos una muestra aleatoria de dos elementos de esa población. Sea x_1 una variable aleatoria que representa el valor del primer elemento de la muestra. Los posibles valores de x_1 son 1, 3, 5, 6 y 7; estos valores se obtienen con probabilidades dadas por $f(x)$; es decir, la función de densidad de x_1 será idéntica a $f(x)$.

x_1	1	3	5	6	7
$f(x_1)$	1/10	2/10	3/10	2/10	2/10

Sea x_2 una variable que representa el valor del segundo elemento de la muestra. Como la muestra es aleatoria, los elementos de la misma se han tomado con reemplazamiento; luego x_2 tomará como posibles valores 1, 3, 5, 6 y 7 con idénticas probabilidades que x_1 ; es decir, la función de densidad de x_2 será también idéntica a $f(x)$.

x_2	1	3	5	6	7
$f(x_2)$	1/10	2/10	3/10	2/10	2/10

Nótese que el hecho de que las probabilidades de obtener los distintos valores de la variable sean diferentes, por ejemplo, $P(x_1 = 1) = 1/10$, $P(x_1 = 3) = 2/10$, no

contradice la característica de que todos los elementos de la población tienen la misma probabilidad de ser elegidos en la muestra, pues la población consiste de 10 elementos y cada uno tiene una probabilidad de 1/10 de ser elegido en la muestra. La aparente incongruencia se explica por el hecho de que algunos elementos de la población tienen el mismo valor.

Se deja como ejercicio al lector comprobar, con los datos del ejemplo, que las variables aleatorias representativas de los elementos de la muestra son independientes, calcular el valor esperado y la varianza poblacionales. Asimismo comprobar que si el muestreo se hace sin reemplazamiento los elementos son variables aleatorias idénticamente distribuidas, con la misma función de densidad, valor esperado y varianza de la población, pero dejan de ser independientes.

7.3. ESTADISTICO MUESTRAL

Hemos visto que la inferencia estadística trata de conocer alguna característica de la población, mediante el estudio de una muestra. La información contenida en la muestra puede ser (usualmente es conveniente y suficiente) condensada en una magnitud, en una sola variable aleatoria calculada como una función de las variables aleatorias que conforman la muestra.

DEFINICION 7.4.

Dada una muestra aleatoria: $x_1, x_2, \dots, x_n$, de tamaño n de una población con función de densidad $f(x)$, un estadístico es una función $g(x_1, x_2, \dots, x_n)$ de las variables aleatorias de la muestra que no contiene ningún parámetro desconocido.

Al ser una función de variables aleatorias, un estadístico es también una variable aleatoria.

Los estadísticos que utilizaremos más frecuentemente son la media muestral, la varianza muestral, la proporción muestral y la cuasivarianza muestral.

DEFINICION 7.5.

Sea $x_1, \dots, x_n$ una muestra aleatoria de tamaño n de una población con función de densidad $f(x)$ con media μ y varianza finita σ^2 . La media muestral representada por $\bar{x}$, es la media aritmética de los elementos de la muestra; es decir:

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$$

Al ser $\bar{x}$ una variable aleatoria, tiene un valor esperado y una varianza.

El valor esperado de la media muestral es la media de la población.

En efecto,

$$E(\bar{x}) = E\left[\frac{\sum_{i=1}^n x_i}{n}\right] = \frac{\sum_{i=1}^n E(x_i)}{n} = \frac{n\mu}{n} = \mu$$

$$E(\bar{x}) = \mu$$

La varianza de la media muestral $\sigma_{\bar{x}}^2$ es igual a la varianza de la población dividida por el tamaño de la muestra. En efecto,

$$\text{Var}(\bar{x}) = \sigma_{\bar{x}}^2 = \text{Var}\left(\frac{\sum_{i=1}^n x_i}{n}\right) = \text{Var}\left(\frac{x_1}{n} + \frac{x_2}{n} + \frac{x_3}{n} + \dots + \frac{x_n}{n}\right)$$

Sabemos que la varianza de la suma de variables aleatorias independientes, es igual a la suma de las varianzas (Ver 3.5). Además la varianza de una variable multiplicada por una constante es igual al cuadrado de la constante por la varianza de la variable (Ver 2.5). Luego:

$$\text{Var}(\bar{x}) = \frac{\sigma^2}{n^2} + \frac{\sigma^2}{n^2} + \dots + \frac{\sigma^2}{n^2} = \frac{\sigma^2}{n}$$

$$\text{Var}(\bar{x}) = \frac{\sigma^2}{n}$$

La importancia de estos resultados es obvia. Por un lado tenemos que el valor esperado de la media muestral es la media de la población; es decir, que si tomamos todas las muestras posibles de tamaño n de una población con media μ , la media de las medias muestrales es igual a la media de la población. Por otro lado sabemos que la varianza de una variable indica la dispersión de los valores de la variable respecto a su media; en este caso la varianza de la media muestral nos dice cuanto puede esperarse que las medias muestrales varíen de una muestra a otra, y el grado de dispersión de las medias muestrales respecto a la media de la población. Vemos que esa dispersión es tanto menor cuanto mayor sea el tamaño de la muestra; en otras palabras la distribución probabilística de la

media muestral se concentra alrededor de la media de la población cuanto mayor sea el tamaño de la muestra; es decir, cuando se aumenta el tamaño de la muestra, la media muestral tiende a acercarse a la media de la población. Si, como veremos más adelante, usamos la media muestral para estimar la media de la población, esa media muestral es tanto más confiable cuanto mayor sea el tamaño de la muestra.

DEFINICION 7.6.

Sea $x_1, x_2, \dots, x_n$, una muestra aleatoria de tamaño n de una población con función de densidad $f(x)$. La varianza muestral representada por s^2 , es el promedio del cuadrado de las desviaciones de los elementos de la muestra respecto a la media muestral; es decir:

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

La manera práctica y abreviada para calcular s^2 es (ver Ejercicio 7.1):

$$s^2 = \frac{\sum_{i=1}^n x_i^2}{n} - \bar{x}^2$$

No debe confundirse la varianza muestral (s^2) con la varianza de la media muestral ($\sigma_{\bar{x}}^2$). La primera se refiere a una muestra y mide la dispersión de los datos de esa muestra con respecto a su media. La segunda mide la dispersión de las medias de distintas muestras con respecto a la media de la población; por otro lado s^2 es un estadístico, mientras que $\sigma_{\bar{x}}^2$ no lo es pues contiene el parámetro desconocido σ^2 .

DEFINICION 7.7.

La cuasivarianza muestral está definida como:

$$s_c^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

El otro estadístico de mucha aplicación en la inferencia estadística es la proporción muestral.

DEFINICION 7.8.

Dada una muestra aleatoria de tamaño n de una población con parámetro p (proporción de elementos de la población que tienen una determinada característica), la proporción muestral representada por $\hat{p}$, se define como el número de elementos de la muestra que tienen esa característica, dividido por el tamaño de la muestra n . es decir:

$$\hat{p} = \frac{x}{n}$$

Siendo x el número de elementos en la muestra que presentan la característica en estudio.

7.4. REFORMULACION DE LA DESIGUALDAD DE CHEBYCHEV, LA LEY DE LOS GRANDES NUMEROS Y EL TEOREMA DEL LIMITE CENTRAL

En el Capítulo VI se estudiaron estas tres herramientas de la Estadística de una forma general, aplicadas a cualquier variable aleatoria. En esta sección se desarrolla su aplicación a los estadísticos muestrales, en particular a la media muestral.

* En la sección (6.2) se probó que:

$$P(|x - E(x)| \leq h) \geq 1 - \frac{\sigma^2}{h^2}$$

para cualquier variable aleatoria x .

Hemos visto en la sección anterior que dada una población con función de densidad $f(x)$ con media μ y varianza finita σ^2 , la media muestral $(\bar{x})$ de una muestra de tamaño n es una variable aleatoria con media μ y varianza σ^2/n , luego por la desigualdad de Chebychev, tenemos:

$$P(|\bar{x} - \mu| \leq h) \geq 1 - \frac{\sigma^2}{nh^2}$$

y haciendo $h = \frac{k\sigma}{\sqrt{n}}$

$$P\left(|\bar{x} - \mu| \leq \frac{k\sigma}{\sqrt{n}}\right) \geq 1 - \frac{1}{k^2}$$

o equivalentemente,

$$P\left(|\bar{x} - \mu| \geq \frac{k\sigma}{\sqrt{n}}\right) \leq 1 - \frac{1}{k^2}$$

EJEMPLO 7.3.

Se toma una muestra aleatoria de tamaño 10 de una población con media 2 y varianza 4. Se pide obtener, usando la desigualdad de Chebychev, un límite superior para la probabilidad de que la media muestral difiera de la media de la población en al menos 2.

En este ejemplo $\mu = 2$, $\sigma = 2$, $n = 10$, $\frac{k\sigma}{\sqrt{n}} = 2$

$$\frac{k\sigma}{\sqrt{n}} = 2 \quad k = \sqrt{10}$$

Luego :

$$P(|\bar{x} - 2| \geq 2) \leq \frac{1}{10} = 0,1$$

La Ley de los Grandes Números vista en la sección (6.3) se conoce como la Ley de los Grandes Números de Bernoulli, puesto que está aplicada a una variable aleatoria con dos posibles valores, cero y uno, (variable Bernoulli). En general, la Ley de los Grandes Números se puede aplicar a la media muestral de una muestra de tamaño n de una población con media μ .

- Reformulación de la Ley de Los Grandes Números -

Sean $x_1, x_2, \dots, x_n$ una muestra aleatoria de tamaño n de una población con media μ y varianza finita σ^2 . Entonces, para cualquier constante $\epsilon > 0$ se cumple que:

$$\lim_{n \rightarrow \infty} P(|\bar{x} - \mu| > \epsilon) = 0 \quad \text{o equivalentemente}$$

$$\lim_{n \rightarrow \infty} P(|\bar{x} - \mu| < \epsilon) = 1$$

En efecto, por la desigualdad de Chebychev,

$$P(|\bar{x} - \mu| \leq \epsilon) \geq 1 - \frac{\sigma^2}{n\epsilon^2}, \quad \text{cuando } n \rightarrow \infty, \frac{\sigma^2}{n\epsilon^2} \rightarrow 0$$

luego,

$$\lim_{n \rightarrow \infty} P(|\bar{x} - \mu| < \epsilon) = 1$$

En palabras, la Ley de los Grandes Números nos dice que a medida que el tamaño de la muestra aumenta la probabilidad de que la media muestral difiera de la media de la población en menos de un número $\varepsilon > 0$, tiende a uno; o sea, que a medida que aumenta el tamaño de la muestra, la media muestral tiende a ser igual a la media de la población.

Otra manera de formular la Ley de los Grandes Números es la siguiente: Si $x_1, x_2, \dots, x_n$, es una muestra aleatoria de tamaño n de una población con media μ y varianza finita σ^2 , dados dos números ε y α tan pequeños como se quiera tales que $\varepsilon > 0$ y $0 < \alpha < 1$

Si $n > \frac{\sigma^2}{\varepsilon^2(1-\alpha)}$, entonces:

$$P(|\bar{x} - \mu| < \varepsilon) \geq \alpha \quad (1)$$

En efecto, por la desigualdad de Chebychev

$$P\left(|\bar{x} - \mu| < \frac{k\sigma}{\sqrt{n}}\right) \geq 1 - \frac{1}{k^2}$$

haciendo $\frac{k\sigma}{\sqrt{n}} = \varepsilon \Rightarrow k^2 = \frac{\varepsilon^2 n}{\sigma^2}$, luego:

$$P(|\bar{x} - \mu| < \varepsilon) \geq 1 - \frac{\sigma^2}{\varepsilon^2 n} \quad (2)$$

Al cumplirse (2) se cumplirá (1) cuando $1 - \frac{\sigma^2}{\varepsilon^2 n} \geq \alpha$, lo que implica que n tiene que ser mayor que $\frac{\sigma^2}{\varepsilon^2(1-\alpha)}$

EJEMPLO 7.4.

Una máquina produce artículos con un peso medio de 20 kgs. y una desviación típica de uno, a un costo de Bs. 50 por unidad. Se propone la compra de una nueva máquina que produce artículos con una desviación típica en el peso de uno. El costo de los artículos producidos por la nueva máquina es menor que el de los producidos por la anterior. Sin embargo, es importante que el peso medio de los artículos no difiera de 20 kgs. en más de medio kilo, de forma que si esta condición no se cumple, la nueva máquina no será aceptada. Para decidir se toma una muestra aleatoria de la producción de la nueva máquina; si el peso medio muestral difiere de 20 en más de medio kilo, la máquina no se compra. ¿De que tamaño debe ser la muestra si se desea que la probabilidad de que no se compre la máquina sea menor que 0,05, cuando de hecho la máquina produce unidades con un peso medio de 20 kgs?

En este ejemplo $\varepsilon = 0,5$, $\alpha = 0,95$, $\sigma = 1$

Se desea que

$$P[|\bar{x} - 20| \geq 0,5] \leq 0,05 \text{ o sea } P[|\bar{x} - 20| \leq 0,5] \geq 1 - 0,05$$

Esta desigualdad se cumple cuando

$$n \geq \frac{\sigma^2}{\varepsilon^2(1-\alpha)} = \frac{1}{(0,5)^2 0,05} \Rightarrow n \geq 80 *$$

Por último, en esta sección se va a reformular el Teorema del Límite Central, aplicándolo a la media muestral:

Si $x_1, x_2, \dots, x_n$ es una muestra aleatoria de tamaño n de una población con función de densidad $f(x)$ con media μ y varianza finita σ^2 , entonces la media muestral $\bar{x}$ tiende a distribuirse normalmente con media μ y varianza σ^2/n , a medida que aumenta el tamaño de la muestra. Dicho de otra forma:

$$\frac{(\bar{x} - \mu)\sqrt{n}}{\sigma} \sim N(0,1)$$

La prueba del teorema enunciado de esta forma sigue los mismos pasos que la prueba de la sección 6.4, por lo cual se deja al lector a manera de ejercicio.

EJEMPLO 7.5.

Calcular el tamaño de la muestra en el ejemplo 7.4, usando el Teorema del Límite Central.

Por el Teorema del Límite Central $\bar{x}$ se distribuye aproximadamente con media μ y varianza $1/n$. Luego:

$$P(-0,5 \leq \bar{x} - \mu \leq 0,5) = 0,95; \quad P[-0,5\sqrt{n} \leq (\bar{x} - \mu)\sqrt{n} \leq 0,5\sqrt{n}] = 0,95$$

$$F(0,5\sqrt{n}) - F(-0,5\sqrt{n}) = 0,95$$

$$2F(0,5\sqrt{n}) = 1,95; \quad F(0,5\sqrt{n}) = 0,975$$

$$0,5\sqrt{n} = 1,96; \quad n \approx 16$$

EJEMPLO 7.6.

Un proceso de manufactura de alimentos para animales produce un alimento concentrado que se empaca en cajas de un kilogramo. El contenido medio de un determinado mineral es de 250 gr. por cada kilo de alimento con una desviación típica de 50 gr. Se ha propuesto un nuevo proceso que aparentemente aumenta el contenido medio de mineral. El economista de la empresa ha estimado, después de estudiar el costo de inversión en el nuevo proceso y el posible aumento de precio que se derivaría del mejoramiento en el producto, que es conveniente adoptar el nuevo proceso, si se puede aumentar el contenido medio en mineral en por lo menos un 10%. Se ha decidido tomar una muestra aleatoria de la producción del nuevo proceso, y aceptarlo si la media muestral es superior al 110% del contenido medio en el proceso actual. Si de hecho el nuevo proceso aumenta el contenido medio de mineral en un 15%. ¿Cuántas cajas deben ser examinadas, si se quiere que la probabilidad de no aceptarlo sea tan pequeña como 0,01? Se supone la misma desviación típica del proceso anterior.

La probabilidad de no adoptar el nuevo proceso es la probabilidad de que el contenido medio de la muestra ($\bar{x}$) sea menor que 275 gr., dado que el contenido medio de la población (μ) es de 287,5 gr.

$$P(\bar{x} \leq 275/\mu = 287,5) = 0,01$$

Por el Teorema del Límite Central $\bar{x} \sim N(\mu, \sigma^2/n)$, luego:

$$P\left[\frac{(\bar{x} - 287,5)\sqrt{n}}{50} \leq \frac{(275 - 287,5)\sqrt{n}}{50}\right] = 0,01$$

$$P\left(y \leq \frac{-12,5\sqrt{n}}{50}\right) = 0,01$$

$$\frac{-12,5\sqrt{n}}{50} = k \quad \text{donde } k \text{ es el número que tiene a su izquierda un área igual a } 0,01 \text{ en la distribución normal tipificada.}$$

$$\frac{-12,5\sqrt{n}}{50} = -2,326$$

$$n = 87$$

7.5. DISTRIBUCION DE PROBABILIDADES DE ALGUNOS ESTADISTICOS

Hemos visto en la sección 7.3 que los estadísticos muestrales son variables aleatorias. Como tales tendrán una determinada distribución de probabilidades, la cual es necesario conocer. Esta necesidad se basa en el hecho de que vamos a usar los valores de los estadísticos para hacer inferencias sobre los parámetros de la población; al hacer una conclusión sobre las características (parámetros) de una población hay que tener presente que el valor del estadístico en el cual se basa la decisión, es un valor de una variable aleatoria que se da con una determinada probabilidad, y que podría haberse dado otro valor que nos hubiera llevado a hacer otra conclusión diferente.

Por ejemplo, si se está interesado en determinar si los ingresos medios mensuales de una población son mayores de Bs. 1.000, se podría establecer la siguiente estrategia; se toma una muestra de esa población; si el ingreso medio en la muestra es mayor que Bs. 1.000, se concluye que los ingresos medios de la población son mayores que Bs. 1.000. Por el contrario, si los ingresos medios muestrales son menores que Bs. 1.000, se concluye que los de la población son también menores de Bs. 1.000. Con esta estrategia se puede llegar a diferentes conclusiones, dependiendo de los resultados de la muestra. Supongamos que la muestra tomada por un investigador A dio un ingreso medio $\bar{x} = 1.050$; según la estrategia establecida, la conclusión es que los ingresos medios de la población son superiores a Bs. 1.000. ¿Es la conclusión correcta? Obviamente hay dos situaciones alternativas: Los ingresos medios de la población pueden ser mayores o menores que Bs. 1.000; de ambas situaciones (poblaciones) puede haberse obtenido una media muestral de Bs. 1.050; luego la conclusión será o no será correcta, dependiendo de cuál es la verdadera situación. Si la población tiene una media superior a mil, la conclusión (basada en $\bar{x} = 1.050$) es correcta; pero si la población tiene media menor que 1.000, la conclusión es incorrecta.

En todo caso, al tomar nuestras decisiones con base en los resultados de la observación de sólo parte de los elementos de la población, por ser esos resultados aleatorios, estamos sujetos a cometer errores. El conocimiento de las distribuciones de probabilidades de los estadísticos muestrales nos permite conocer la probabilidad de cometer dichos errores, y en consecuencia nos permitirá tratar de minimizar en algún sentido esas probabilidades.

En esta sección se discutirán las distribuciones de probabilidades de los estadísticos estudiados en la sección 7.3.

7.5.1. DISTRIBUCION DE LA MEDIA MUESTRAL DE UNA POBLACION DISTRIBUIDA NORMALMENTE

Sea $x_1, x_2, \dots, x_n$ una muestra aleatoria de tamaño n de una población normalmente distribuida con media μ y varianza σ^2 . Estamos interesados en conocer la función de densidad de la media muestral.

Sabemos que $E(\bar{x}) = \mu$ y $\text{Var}(\bar{x}) = \sigma^2/n$. Quedaría sólo averiguar cómo se distribuye $\bar{x}$. Siendo la población normal, $\bar{x}$ es una función lineal de variables normales independientes, luego por el teorema visto en la sección 5.12. $\bar{x}$ es una variable normal. En definitiva, la media muestral de una muestra aleatoria de tamaño n tomada de una población normal, es una variable normalmente distribuida con media igual a la media de la población, y varianza igual a la varianza de la población dividida por el tamaño de la muestra.

$$\bar{x} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

7.5.2. DISTRIBUCION DE LA MEDIA MUESTRAL DE UNA POBLACION CON DISTRIBUCION DISTINTA DE LA NORMAL

Frecuentemente se da el caso de que la distribución de la población es desconocida o, aún siendo conocida, no es normal. En estos casos, el Teorema del Límite Central (sección 7.4.) es aplicable. Según el teorema, la media muestral de una población con cualquier distribución se distribuye aproximadamente como una variable normal para tamaños de muestras suficientemente grandes.

$$\bar{x} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

La bondad de esta aproximación, así como el tamaño de la muestra necesario para que la aproximación sea válida, no se puede determinar con precisión, y depende de la forma de la distribución de la población. A no ser que la distribución de la población tenga una forma muy rara, la aproximación es aceptable aún con un tamaño de la muestra relativamente pequeño.

7.5.3. DISTRIBUCION DE LA VARIANZA MUESTRAL

Se tiene una muestra aleatoria $x_1, x_2, \dots, x_n$ de tamaño n de una población normal con media μ y varianza σ^2 ; si bien no se puede determinar la distribución de probabilidades de la varianza muestral s^2 , es posible hacerlo para una función de s^2 .

En efecto, la variable ns^2/σ^2 se distribuye como una χ^2 con $n-1$ grados de libertad.

* Prueba:

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n} \quad ns^2 = \sum_{i=1}^n (x_i - \bar{x})^2$$

$$\begin{aligned} &= \sum_{i=1}^n (x_i - \bar{x} - \mu + \mu)^2 = \sum_{i=1}^n [(x_i - \mu) - (\bar{x} - \mu)]^2 = \\ &= \sum_{i=1}^n [(x_i - \mu)^2 + (\bar{x} - \mu)^2 - 2(x_i - \mu)(\bar{x} - \mu)] = \\ &= \sum_{i=1}^n (x_i - \mu)^2 + n(\bar{x} - \mu)^2 - 2(\bar{x} - \mu) \sum_{i=1}^n (x_i - \mu) = \\ &= \sum_{i=1}^n (x_i - \mu)^2 + n(\bar{x} - \mu)^2 - 2(\bar{x} - \mu) \sum_{i=1}^n \frac{(x_i - \mu)}{n} = \\ &= \sum_{i=1}^n (x_i - \mu)^2 + n(\bar{x} - \mu)^2 - 2n(\bar{x} - \mu)^2 = \sum_{i=1}^n (x_i - \mu)^2 - n(\bar{x} - \mu)^2 \end{aligned}$$

Dividiendo por σ^2 ambos miembros de la igualdad, se tiene:

$$\frac{ns^2}{\sigma^2} = \frac{\sum_{i=1}^n (x_i - \mu)^2}{\sigma^2} - \frac{n(\bar{x} - \mu)^2}{\sigma^2} \therefore$$

$$\frac{ns^2}{\sigma^2} + \frac{n(\bar{x} - \mu)^2}{\sigma^2} = \frac{\sum_{i=1}^n (x_i - \mu)^2}{\sigma^2}$$

Para simplificar la notación hagamos $\frac{ns^2}{\sigma^2} = Z$

$$\frac{n(\bar{x} - \mu)^2}{\sigma^2} = W \quad y \quad \sum_{i=1}^n \frac{(x_i - \mu)^2}{\sigma^2} = V$$

o sea, $Z + W = V$

la suma de las variables Z y W es igual a la variable V; luego, la función generatriz de momentos de Z + W es igual a la función generatriz de momentos de V,

$$m_{Z+W}(k) = m_V(k) \quad (3)$$

Utilizaremos ahora el siguiente teorema, el cual se enuncia sin prueba.¹³

Teorema: Dada una muestra aleatoria $x_1, x_2, \dots, x_n$ de una población normalmente distribuida, la varianza muestral (s^2) y la media muestral ($\bar{x}$) son variables aleatorias independientemente distribuidas.

Z es una función sólo de s^2 , y W es una función sólo de $\bar{x}$; luego, por el teorema anterior, Z y W son variables independientes y la función generatriz de su suma es igual al producto de sus funciones generatrices; (Sección 3.5); luego,

$$m_{Z+W}(k) = m_Z(k) \cdot m_W(k) \quad (4)$$

Uniendo (3) y (4) se tiene

$$m_Z(k) \cdot m_W(k) = m_V(k)$$

$$m_Z(k) = \frac{m_V(k)}{m_W(k)}$$

o sea, que la función generatriz de momentos de la variable Z es igual al cociente de las funciones generatrices de momentos de las variables V y W. La variable V es la suma de los cuadrados de n variables normales tipificadas independientes; luego, V se distribuye como χ^2 con n grados de libertad, y su función generatriz de momentos

es $m_V(k) = (1-2k)^{-n/2}$ (Ver sección 5.15). La variable $W = \left[\frac{(\bar{x} - \mu)\sqrt{n}}{\sigma} \right]^2$ es el cua-

drado de una variable normal tipificada; luego, se distribuye como una χ^2 con un grado de libertad, y su función generatriz de momentos es $m_W(k) = (1-2k)^{-1/2}$; luego:

$$m_Z(k) = \frac{(1-2k)^{-n/2}}{(1-2k)^{-1/2}} = (1-2k)^{-(n-1)/2}$$

¹³ Para una prueba del teorema, ver A. Mood y F. Graybill, op. cit. Cap. 10 o Paul G. Hoel, Introduction to Mathematical Statistics, John Wiley & Sons, Inc. New York, Apéndice 1.

esta es la función generatriz de momentos de una variable χ^2 con n-1 grados de libertad;

es decir, que $Z = \frac{ns^2}{\sigma^2}$ es una variable χ^2 con n-1 grados de libertad.*

NOTA SOBRE LOS GRADOS DE LIBERTAD

En el Capítulo V al introducir la variable χ^2 se especificó que los grados de libertad de la variable eran el número de variables independientes cuyos cuadrados se sumaban.

Hemos visto ahora que $\frac{ns^2}{\sigma^2}$ se distribuye como una χ^2 con n-1 grados de libertad.

Trataremos ahora de explicar en forma intuitiva porque son n-1 grados de libertad y al mismo tiempo se aclarará lo que implica el concepto de grados de libertad.

Recordemos que $s^2 = \frac{\sum (x_i - \bar{x})^2}{n}$ o sea, que para poder calcular la varianza

muestral es necesario calcular antes la media muestral con los datos disponibles de la muestra. Si al principio es cierto que disponíamos de n variables independientes, en el momento que calculamos la media muestral perdemos un grado de libertad; conocido el valor de la media muestral, sólo n-1 de las variables de la muestra permanecen independientes. Si tenemos una muestra de 4 elementos y la media muestral es 10, sólo 3 de las variables de la muestra pueden variar libremente puesto que la cuarta variable queda determinada. Por ejemplo, si $x_1 = 9$, $x_2 = 15$ y $x_3 = 10$, la cuarta variable debe ser 6 para que la media muestral pueda ser 10.

7.5.4. DISTRIBUCION DE LA MEDIA MUESTRAL CUANDO NO SE CONOCE LA VARIANZA DE LA POBLACION

En 7.5.1. y 7.5.2, Se vio que la media muestral se distribuye o tiende a distribuirse como una variable normal con media μ y varianza σ^2/n . Como se verá más adelante, cuando se quieren hacer inferencias acerca de la media de la población, este hecho no se puede utilizar si se desconoce la varianza de la población, pues la función de densidad contiene un parámetro desconocido σ^2 . Afortunadamente se puede utilizar la distribución t de Student, usando una función de $\bar{x}$ que contiene la varianza muestral en lugar de la varianza de la población.

Sabemos que $\bar{x} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$ y que $\frac{ns^2}{\sigma^2} \sim \chi^2(n-1)$ además $\bar{x}$ y s^2 son independientes; luego:

$$\frac{(\bar{x} - \mu)\sqrt{n}}{\sigma} \bigg/ \sqrt{\frac{ns^2}{\sigma^2(n-1)}} = \frac{(\bar{x} - \mu)\sqrt{n-1}}{s} \text{ se distribuye como una t de Student}$$

con n-1 grados de libertad (Ver sección 5.17).

7.5.5. DISTRIBUCION DE LA PROPORCION MUESTRAL

En una población binomial, dada una muestra aleatoria (con reemplazamiento), sabemos que la proporción muestral se define como el cociente del número de elementos de la muestra que tienen la característica deseada, entre el número total de elementos de la muestra, $\hat{p} = \frac{x}{n}$.

El estadístico $\hat{p}$ se distribuye binomialmente con media p y varianza pq/n , donde "p" es la proporción de elementos de la población que tienen la característica estudiada y $q = 1 - p$.

* En efecto, al tomar una muestra de tamaño n con reemplazamiento, x puede tomar los valores $1, 2, \dots, n$ y $\hat{p}$ los valores $0, 1/n, 2/n, \dots, 1$.

En el cuadro siguiente se presentan los posibles valores de p , con los correspondientes valores de x y sus probabilidades.

$\hat{p}$	0	1/n	2/n	 i/n	1
x	0	1	2	 i	n
f(x)	$\binom{n}{0} p^0 q^n$	$\binom{n}{1} p^1 q^{n-1}$	$\binom{n}{2} p^2 q^{n-2}$	... $\binom{n}{i} p^i q^{n-i}$	$\binom{n}{n} p^n q^0$

Es decir, $\hat{p}$ será igual a cero cuando el número de "éxitos" en la muestra es cero, y la probabilidad de que $\hat{p} = 0$ es $\binom{n}{0} p^0 q^n$ en general, $\hat{p}$ será igual a i/n cuando $x = i$ y esto se da con probabilidad $\binom{n}{i} p^i q^{n-i}$; luego, la función de densidad de $\hat{p}$ es:

$$f(\hat{p}) = \binom{n}{n\hat{p}} p^{n\hat{p}} q^{n-n\hat{p}} \quad \text{para } \hat{p} = 0, 1/n, 2/n, \dots, 1$$

El valor esperado de $\hat{p}$ es $E(\hat{p}) = E\left(\frac{x}{n}\right) = \frac{np}{n} = p$

La varianza es $\text{Var}(\hat{p}) = \text{Var}\left(\frac{x}{n}\right) = \frac{npq}{n^2} = \frac{pq}{n}$

$$E(\hat{p}) = p \quad \text{Var}(\hat{p}) = \frac{pq}{n}$$

En la práctica se usa la aproximación por la normal; tal aproximación se puede justificar de dos maneras. En primer lugar, al ser $\hat{p}$ una variable binomial se puede aproximar por la normal -ver sección 5.14-; en segundo lugar, $\hat{p}$ es la suma de variables independientes, pues x es la suma de variables Bernoulli -ver Ejemplo 6.5- luego por aplicación del Teorema del Límite Central tiende a distribuirse normalmente.

"La proporción de "éxitos" $\hat{p} = x/n$ en una muestra aleatoria tomada de una población punto-binomial se distribuye aproximadamente como una variable normal con media p y varianza pq/n ."

7.5.6. DISTRIBUCION DE LA DIFERENCIA DE LAS MEDIAS MUESTRALES

7.5.6.1. VARIANZAS POBLACIONALES CONOCIDAS

Sean dos poblaciones que se distribuyen normalmente con medias μ_x y μ_y respectivamente y varianzas σ_x^2 y σ_y^2 . Dada una muestra aleatoria de tamaño n_x de la primera población, y una de tamaño n_y de la segunda población, interesa conocer la distribución de la diferencia de las medias muestrales $\bar{x}$ e $\bar{y}$.

El valor esperado de $\bar{x} - \bar{y}$ es

$$E(\bar{x} - \bar{y}) = E(\bar{x}) - E(\bar{y}) = \mu_x - \mu_y$$

La varianza de $\bar{x} - \bar{y}$ es

$$\text{Var}(\bar{x} - \bar{y}) = \text{Var}(\bar{x}) + \text{Var}(\bar{y}) = \frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}$$

puesto que $\bar{x}$ e $\bar{y}$ son independientes.

Además $\bar{x} - \bar{y}$ es una función lineal de variables normales independientes; luego, es a su vez normal.

$$\bar{x} - \bar{y} \sim N\left(\mu_x - \mu_y, \frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}\right)$$

"Si $x_1, x_2, \dots, x_{n_x}$ es una muestra aleatoria de tamaño n_x de una población normal con media μ_x y varianza σ_x^2 e $y_1, y_2, \dots, y_{n_y}$ es una muestra aleatoria de tamaño n_y de otra población normal con media μ_y varianza σ_y^2 , la diferencia de medias muestrales $\bar{x} - \bar{y}$ se distribuye normalmente con media igual a la diferencia de las medias y varianza igual a la suma de las varianzas".

Este hecho es aplicable también a poblaciones que no son normales, cuando los tamaños de las muestras son suficientemente grandes para ser aplicable el Teorema del

Límite Central, pues en este caso, las medias muestrales $\bar{x}$ e $\bar{y}$ son aproximadamente normales.

7.5.6.2. VARIANZAS POBLACIONALES DESCONOCIDAS

Cuando no se conocen las varianzas poblacionales, como generalmente sucede, éstas se aproximan por las cuasivarianzas muestrales s_x^2 y s_y^2 , quedando la varianza de la diferencia de las medias muestrales.

$$\text{Var}(\bar{x} - \bar{y}) = \frac{s_x^2}{n_x} + \frac{s_y^2}{n_y}$$

La razón por la cual las varianzas poblacionales se aproximan por las cuasivarianzas muestrales y no por las varianzas muestrales se explicará en el Capítulo VIII.

Como $s_c^2 = \frac{ns^2}{n-1}$ queda:

$$\text{Var}(\bar{x} - \bar{y}) = \frac{s_x^2}{n_x - 1} + \frac{s_y^2}{n_y - 1}$$

siendo s_x^2 y s_y^2 las varianzas muestrales de la primera y segunda población respectivamente; es decir,

$$\bar{x} - \bar{y} \sim N\left(\mu_x - \mu_y, \frac{s_x^2}{n_x - 1} + \frac{s_y^2}{n_y - 1}\right)$$

A veces, aunque se desconoce el valor de las varianzas poblacionales, se sabe o se estima que son iguales $\sigma_x^2 = \sigma_y^2 = \sigma^2$. En estos casos se puede usar la distribución t de Student en la determinación de la distribución de las medias muestrales. En efecto,

$$\bar{x} - \bar{y} \sim N\left(\mu_x - \mu_y, \frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}\right)$$

como $\sigma_x^2 = \sigma_y^2 = \sigma^2$, se tiene

$$\bar{x} - \bar{y} \sim N\left(\mu_x - \mu_y, \sigma^2 \frac{n_x + n_y}{n_x n_y}\right)$$

por otro lado $\frac{n_x s_x^2}{\sigma^2}$ y $\frac{n_y s_y^2}{\sigma^2}$ se distribuyen independientemente como χ^2 con $n_x - 1$ y

$n_y - 1$ grados de libertad respectivamente; luego, su suma

$$\frac{n_x s_x^2}{\sigma^2} + \frac{n_y s_y^2}{\sigma^2}$$

se distribuye como una χ^2 con $n_x + n_y - 2$ grados de libertad (sección 5.15), y es independiente de $\bar{x} - \bar{y}$.

$$\frac{\bar{x} - \bar{y} - (\mu_x - \mu_y)}{\sigma \sqrt{\frac{n_x + n_y}{n_x n_y}}} \sim N(0,1)$$

dividiendo una normal (0,1) entre una χ^2 dividida por sus grados de libertad:

$$t = \frac{[(\bar{x} - \bar{y}) - (\mu_x - \mu_y)] / \sigma \sqrt{\frac{n_x + n_y}{n_x n_y}}}{\sqrt{\frac{n_x s_x^2 + n_y s_y^2}{\sigma^2 (n_x + n_y - 2)}}}$$

se obtiene una t de Student.

$$\frac{(\bar{x} - \bar{y}) - (\mu_x - \mu_y)}{\sqrt{\frac{n_x + n_y}{n_x n_y} \frac{n_x s_x^2 + n_y s_y^2}{n_x + n_y - 2}}} \sim t(n_x + n_y - 2)$$

7.5.7. DISTRIBUCION DE LA DIFERENCIA DE PROPORCIONES MUESTRALES

Sean dos poblaciones binomiales con parámetros p_x y p_y respectivamente. Tomamos una muestra aleatoria de tamaño n_x de la primera población, y una muestra de tamaño n_y de la segunda población, y estamos interesados en conocer la distribución de la diferencia de proporciones muestrales, $\hat{p}_x - \hat{p}_y$.

Siguiendo el mismo razonamiento de la sección anterior, siendo

$$\hat{p}_x \sim N(p_x, p_x q_x / n_x) \text{ y } \hat{p}_y \sim N(p_y, p_y q_y / n_y) \text{ se tiene que}$$

$$\hat{p}_x - \hat{p}_y \sim N\left(p_x - p_y, \frac{p_x q_x}{n_x} + \frac{p_y q_y}{n_y}\right)$$

o sea, que la diferencia de proporciones muestrales se distribuye aproximadamente como normal con media igual a la diferencia de medias y varianza igual a la suma de las varianzas.

EJERCICIOS RESUELTOS

7.1. Al tomar una muestra aleatoria de tamaño 6 de una población se obtuvieron los siguientes resultados:

$$x_1 = 3, \quad x_2 = 4, \quad x_3 = 5, \quad x_4 = 2, \quad x_5 = 6, \quad x_6 = 2.$$

Calcular; i) La media muestral; ii) La varianza muestral

Solución:

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n} = \frac{\sum_{i=1}^6 x_i}{6} = \frac{22}{6} = 3,66$$

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n} = \frac{\sum_{i=1}^n x_i^2 - 2\bar{x} \sum_{i=1}^n x_i + n\bar{x}^2}{n} = \frac{\sum_{i=1}^n x_i^2 - n\bar{x}^2}{n} =$$

$$= \frac{\sum_{i=1}^n x_i^2}{n} - \bar{x}^2 = \frac{94}{6} - \left(\frac{22}{6}\right)^2 = \frac{564 - 484}{36} = 2,22$$

7.2. Si $x_1, x_2, \dots, x_{10}$ es una muestra aleatoria de tamaño 10 de una población distribuida normalmente con media 8 y varianza 9, calcular la probabilidad de que la media muestral sea mayor que 10.

Solución:

$$\bar{x} \sim N(8, 9/10)$$

$$P(\bar{x} > 10) = P\left(\frac{(\bar{x} - 8)\sqrt{10}}{3} \geq \frac{(10 - 8)\sqrt{10}}{3}\right) = P(y \geq 2,11) = 1 - 0,9826 = 0,0174$$

7.3. Con los datos del problema anterior, calcular la probabilidad de que la varianza muestral sea mayor que 3,753.

Solución:

$$\text{Sabiendo que } \frac{ns^2}{\sigma^2} \sim \chi^2(n-1)$$

$$P(s^2 \geq 3,753) = P\left(\frac{ns^2}{\sigma^2} \geq \frac{10 \cdot 3,753}{9}\right) = P\left(\frac{ns^2}{\sigma^2} \geq 4,17\right) = 0,9$$

7.4. Si $x_1, x_2, \dots, x_{16}$ es una muestra aleatoria de tamaño 16 de una población binomial con $p = 0,7$. ¿Cuál es la probabilidad de que la proporción muestral sea menor que 0,5? (Use la aproximación normal).

Solución:

$$\hat{p} \sim N\left(p, \frac{pq}{n}\right)$$

Luego:

$$P(\hat{p} < 0,5) = P\left(\frac{\hat{p} - 0,7}{\sqrt{\frac{0,3 \cdot 0,7}{16}}} \leq \frac{-0,2 \cdot 4}{0,458}\right) = P(y \leq -1,75) = 1 - 0,9599 = 0,0401$$

7.5. Si $x_1, x_2, \dots, x_{10}$ es una muestra aleatoria de una población normal con media 8 y varianza 4 y $y_1, y_2, \dots, y_{15}$ es una muestra aleatoria de una población normal con media 12 y varianza 6. Calcular la probabilidad de que la diferencia de las medias muestrales esté entre -1 y 1.

Solución:

$$\bar{x} - \bar{y} \sim N\left(\mu_x - \mu_y, \left(\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}\right)\right)$$

$$P(-1 \leq \bar{x} - \bar{y} \leq 1) = P\left(\frac{-1 - (8 - 12)}{\sqrt{\frac{4}{10} + \frac{6}{15}}} \leq \frac{(\bar{x} - \bar{y}) - (\mu_x - \mu_y)}{\sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}}} \leq \frac{1 - (8 - 12)}{\sqrt{\frac{4}{10} + \frac{6}{15}}}\right) =$$

$$= F(5,59) - F(3,35) = 1 - 0,09996 = 0,004$$

7.6. Si se toma una muestra aleatoria de 36 elementos de una población con media m y desviación típica 4. i) Use la desigualdad de Chebychev para calcular la probabilidad de que la media muestral difiera en más de 3 de la media de la población; ii) Use el teorema del Límite Central para calcular esa probabilidad; iii) Si el tamaño de la muestra se duplica, cuál será la probabilidad calculada por la desigualdad de

Chebychev; iv) Use la Ley de los Grandes Números para calcular el tamaño de la muestra, si se quiere que la probabilidad sea menor que 0,02.

Solución:

i) Según la desigualdad de Chebychev

$$P\left(|\bar{x} - \mu| \geq \frac{k\sigma}{\sqrt{n}}\right) \leq \frac{1}{k^2}$$

$$P(|\bar{x} - \mu| \geq 3) < \frac{1}{k^2}$$

$$3 = \frac{k\sigma}{\sqrt{n}} \Rightarrow k = \frac{3 \cdot 6}{4} = 4,5 \Rightarrow$$

$$P(|\bar{x} - \mu| \geq 3) \leq \frac{1}{(4,5)^2} = 0,049$$

ii) Por el Teorema del límite Central,

$$\bar{x} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

$$P(|\bar{x} - \mu| \geq 3) = P(\bar{x} - \mu \leq -3) + P(\bar{x} - \mu \geq 3) =$$

$$= P\left(\frac{(\bar{x} - \mu)\sqrt{n}}{\sigma} \leq \frac{-3\sqrt{n}}{\sigma}\right) + P\left(\frac{(\bar{x} - \mu)\sqrt{n}}{\sigma} \geq \frac{3\sqrt{n}}{\sigma}\right) =$$

$$= F\left(\frac{-3\sqrt{n}}{\sigma}\right) + 1 - F\left(\frac{3\sqrt{n}}{\sigma}\right) = F(-4,5) + 1 - F(4,5) =$$

$$= 2 - 2F(4,5) = 2 - 2 = 0$$

iii) Si el tamaño de la muestra se duplica,

$$k = \frac{3\sqrt{72}}{4} = 6,36$$

$$P(|\bar{x} - \mu| \geq 3) \leq \frac{1}{(6,36)^2} = 0,0247$$

$$\text{iv) } P(|\bar{x} - \mu| > 3) \leq 0,02 \Rightarrow P(|\bar{x} - \mu| \leq 3) \geq 1 - 0,02$$

$$\text{en este caso } \varepsilon = 3 \quad \alpha = 0,98 \quad 1 - \alpha = 0,02$$

luego:

$$n \geq \frac{\sigma^2}{\varepsilon^2(1-\alpha)} \Rightarrow n \geq \frac{16}{9 \cdot 0,02}; \quad \boxed{n \geq 89}$$

EJERCICIOS PROPUESTOS

7.7 Si $x_1, x_2, x_3, \dots, x_{15}$ es una muestra aleatoria de tamaño 15 de una población distribuida normalmente con media μ y varianza σ^2 . Suponiendo que $\mu = 6$ y $\sigma^2 = 4$; calcular: i) $P(5 \leq \bar{x} \leq 8)$; ii) $P(1,2427 \leq s^2 \leq 2,0773)$.

Suponiendo que σ^2 es desconocida, y sabiendo que $s^2 = 6,25$; iii) Calcular $P(5,1014 \leq \bar{x} \leq 6,8986)$.

7.8. Si $x_1, x_2, \dots, x_{10}$ es una muestra aleatoria de una población normal con media 8 y varianza σ_x^2 , e $y_1, y_2, \dots, y_{15}$ es una muestra aleatoria de una población normal con media 12 y varianza σ_y^2 . Sabiendo que $\sigma_x^2 = \sigma_y^2$, y que $s_x^2 = 3,8$ y $s_y^2 = 5,7$; calcular $P(-5,69 \leq \bar{x} - \bar{y} \leq -2,31)$.

7.9. Este ejercicio está designado para comprobar cómo el valor de la media muestral varía de muestra a muestra, y que el valor esperado de la media muestral es igual a la media de la población.

Una población está compuesta por 4 elementos con valores 1, 3, 4, 6 que representan el peso en kgs. de los elementos de la población.

i) Enumerar todas las posibles muestras aleatorias de tamaño 2 (con reemplazamiento) de los elementos que se pueden obtener de esa población.

ii) Calcular los correspondientes valores de la media muestral.

iii) Calcular el valor esperado de la media muestral, y compararlo con la media de la población.

7.10. En el ejercicio anterior, calcular directamente la varianza de la media muestral, y comparar con el resultado dado por $\text{Var}(\bar{x}) = \sigma^2/n$.

7.11. En el ejercicio 7.9, calcular todos los valores de la varianza muestral (s_i^2) $i = 1, \dots, 16$ donde (s_i^2) es el valor de la varianza muestral de la muestra i .

- 7.12) Una población normal tiene media 3 y varianza 4. Una segunda población normal tiene media 5 y varianza 6. Se toman muestras aleatorias de ambas poblaciones de tamaño 40 y 36 respectivamente. Calcular la probabilidad de que la media muestral de la muestra de la segunda población exceda en 3 unidades o más a la media muestral de la muestra de la primera población.
- 7.13) Se toma una muestra aleatoria de tamaño 25 de una población con media μ_x y varianza 25, y una muestra aleatoria de tamaño 36 de una población con media μ_y y varianza 16. Calcular la probabilidad de que la diferencia de las medias muestrales se diferencie de la diferencia de las medias de la población en menos de 3.
- 7.14. En el problema anterior, ¿Qué relación debe haber entre los tamaños de las muestras de cada población para que la probabilidad de que la diferencia de las medias muestrales se diferencie de la diferencia de las medias de la población en menos de 3, sea igual a 0,95?
- 7.15. Dada una muestra aleatoria de tamaño 40 de una población binomial, donde $p = 0,25$ calcular la probabilidad de que la proporción muestral esté entre 0,20 y 0,30.
- 7.16. Usar la aproximación normal para calcular la probabilidad pedida en el ejercicio anterior.
- 7.17. Se toma una muestra de tamaño 20 de una población normal con media 15, y otra muestra de tamaño 12 de una población normal con media 10. Las varianzas muestrales son $s_x^2 = 4$ y $s_y^2 = 8$; calcular $P(\bar{x} - \bar{y} \leq 4)$.
- 7.18) Se toma una muestra de tamaño 20 de una población binomial con $p_x = 0,50$, y una muestra de tamaño 25 de una población binomial con $p_y = 0,45$. ¿Cuál es la probabilidad de que la proporción muestral de la primera población exceda en un 10% o más a la proporción muestral de la segunda población?
- 7.19) Un investigador desea tener alguna idea concreta sobre la media de una población, para lo cual decide tomar una muestra aleatoria de la población, y usar el valor de la media muestral como aproximación de la media de la población. Se sabe que la desviación típica es 0,05. ¿Cuál debe ser el tamaño de la muestra, para que la probabilidad de que la media muestral no difiera de la media de la población en más de 0,01, sea 0,95?
- 7.20) A un productor de transistores le interesa estimar cuanto duran en promedio sus transistores, sabiendo que la desviación típica es de 150 horas. Para hacerlo, toma una muestra aleatoria y estima la media por la duración promedio en la muestra. ¿Cuántos transistores debe tener la muestra para que la probabilidad de que la duración media en la muestra difiera de la duración media de la población en más de 10 horas, sea 0,1?

- 7.21) Se sabe que la resistencia a la tracción, de los cables producidos por un cierto fabricante es una variable aleatoria con media μ desconocida y desviación típica de 100 kgs. El valor de un cable es $0,1 \mu$ bolívares. Un cliente ofrece pagar al productor $0,1 \bar{x}$ bolívares por cada cable, siendo $\bar{x}$ la resistencia media en una muestra aleatoria que el cliente toma para examinar la producción. ¿De qué tamaño debe ser la muestra para que la probabilidad de que el comprador no sobrepague cada cable en más de Bs. 5, sea 0,95?
- 7.22. Un juego de azar se desarrolla de la siguiente forma: el apostador lanza un dado, y gana Bs. 2 si sale un número impar; y gana Bs. 6 si sale un seis. Si no se da ninguno de esos resultados, no gana nada. Supongamos que un apostador juega 10 veces. Sea $\bar{x}$ las ganancias medias; es decir, la décima parte de las ganancias totales (no se toma en cuenta lo que tiene que pagar para poder jugar). Usar la desigualdad de Chebychev para obtener un límite superior a la probabilidad de que las ganancias medias difieran de $E(\bar{x})$ en al menos Bs. 2.
- 7.23) Un investigador desea estimar la media de una población usando una muestra suficientemente grande, para que la probabilidad de que la media muestral no difiera de la media de la población en más del 25% de la desviación típica, sea 0,95. ¿De qué tamaño debe tomarse la muestra?
- 7.24. Dada una población con 3 elementos: 1, 2, 3. Se toman muestras de tamaño 2 de esa población.
- i) Si las muestras se toman con reemplazamiento, comprobar que los elementos que componen la muestra son variables aleatorias independientes, verificando que $f(x_1, x_2) = f(x_1) f(x_2)$, siendo x_1 y x_2 el primer y segundo elemento de la muestra respectivamente.
- ii) Comprobar que si el muestreo es sin reemplazamiento los elementos que componen la muestra no son variables independientes, verificando que $f(x_1, x_2) \neq f(x_1) f(x_2)$.
- 7.25. Determine razonadamente la veracidad o falsedad de las siguientes afirmaciones:
- a) A partir de una muestra aleatoria de una población con media μ y varianza σ^2 , se calculó el siguiente estadístico:
- $$\hat{x} = \frac{a_1 x_1 + a_2 x_2 + \dots + a_n x_n}{m} \quad \text{siendo } m = \sum_{i=1}^n a_i$$
- Se puede afirmar que $\hat{x}$ tiende a ser normal a medida que n aumenta.
- b) La media muestral de una muestra aleatoria tomada de una población normal es una variable aleatoria normal.

- c) El factor de corrección para poblaciones finitas y muestreo sin reemplazamiento afecta a la varianza muestral.

7.26. Determine razonadamente cuál de las respuestas es correcta en:

Cuando se toma una muestra sin reemplazamiento de una población finita se dice que no es una muestra aleatoria porque:

- a) Cada elemento de la población no tiene la misma probabilidad de salir en la muestra.
- b) Los elementos de la muestra no son variables aleatorias independientes.
- c) Los elementos de la muestra no son variables aleatorias idénticamente distribuidas.
- d) La afirmación es falsa y sí es una muestra aleatoria.
- e) Ninguna de las anteriores.

CAPITULO VIII

ESTIMACION POR PUNTOS

8.1. INTRODUCCION

Uno de los problemas más importantes que trata de resolver la inferencia estadística es el de la estimación de los "parámetros de una población", por medio de los datos contenidos en una muestra. Los parámetros de una población tales como la media, la varianza, la proporción, representan características importantes de la población que al investigador le interesa conocer.

Estos parámetros son generalmente desconocidos y es poco práctico o imposible analizar todos y cada uno de los elementos de la población, de manera de calcular los parámetros en forma exacta. Tenemos que contentarnos con hallar alguna magnitud a través de la información incompleta de una muestra, que nos sirva para aproximar el valor del parámetro desconocido. En esto consiste el problema de estimación en estadística. Esta estimación puede ser de dos clases: a) puede usarse una magnitud simple para estimar un parámetro; por ejemplo, usar la media muestral como estimador de la media de la población; en este caso estamos realizando una estimación por puntos o estimación puntual; b) se puede calcular un intervalo entre cuyos límites se espera que esté el parámetro con una razonable confianza; en este caso estamos realizando una estimación por intervalos.

En este capítulo estudiaremos el modo de calcular y las propiedades que deben tener los estimadores por puntos.

EJEMPLO 8.1.

En el ejemplo 7.1. si estamos interesados en conocer el salario medio de los obreros de una industria (media de la población: parámetro desconocido), podríamos estimarlo por el salario medio obtenido en una muestra (media muestral: estimador).

EJEMPLO 8.2.

Si queremos estimar la proporción de estudiantes de la Universidad que fuman (proporción de la población: parámetro desconocido), se puede hacer por medio de la proporción de fumadores en una muestra aleatoria (proporción muestral: estimador).

En general, los parámetros desconocidos de la población se estimarán a través de algún estadístico muestral, en consecuencia se puede definir un estimador puntual de la forma siguiente:

DEFINICION 8.1.

Un estimador puntual ($\hat{\theta}$) de un parámetro desconocido (θ) de una población es una función de las variables de una muestra aleatoria $\theta = g(x_1, \dots, x_n)$, que no contiene ningún parámetro desconocido, y que sirve como una aproximación del parámetro; o sea, es un estadístico que sirve como aproximación del parámetro.

Es preciso hacer una distinción entre “estimador” de un parámetro y “valor estimado” de un parámetro. Un estimador es una función de los valores de una muestra, y en consecuencia es una variable aleatoria que toma distintos valores dependiendo de los valores de las variables aleatorias de la muestra. Una vez obtenida una muestra concreta, y calculado el valor del estadístico muestral que usamos como estimador del parámetro, ese valor servirá como “valor estimado” del parámetro. Es decir, el “estimador” del parámetro es el estadístico muestral; el valor concreto del “estimador” obtenido en una muestra, es el “valor estimado” del parámetro.

EJEMPLO 8.3.

En el ejemplo 8.1, la media muestral ($\bar{x}$) es el estimador de la media de la población ($\hat{\theta} = \bar{x}$). Una vez obtenida la muestra, si $\bar{x} = \text{Bs. } 200$; Bs. 200 es el valor estimado de θ .

8.2. EL PROBLEMA DE LA ELECCION

Por ser el estimador del parámetro una función de las variables de una muestra, es evidente que podemos escoger distintos estimadores para un mismo parámetro, puesto que podemos elegir arbitrariamente la función que vamos a utilizar.

EJEMPLO 8.4.

Si deseamos estimar la media de la población, y tomamos una muestra aleatoria $x_1, x_2, \dots, x_n$, se puede elegir como estimador de la media, la media muestral

$\hat{\theta}_1 = \bar{x} = \frac{\sum x_i}{n}$; o decidir que el estimador es el primer valor de la muestra

$\hat{\theta}_2 = x_1$; o usar como estimador la varianza muestral $\hat{\theta}_3 = \frac{\sum (x_i - \bar{x})^2}{n}$,

o decidir que el estimador es la semisuma del primero y último valor de la muestra

$\hat{\theta}_4 = \frac{x_1 + x_n}{2}$, etc.

Es decir, para cada parámetro desconocido podemos elegir muchos, prácticamente infinitos, estimadores. Es evidente que se debería tener algún tipo de medida para juzgar si el estimador elegido, es un buen estimador; si uno es mejor que otro; es decir, alguna medida que nos indique la eficacia de nuestra elección.

Parecería obvio escoger un estimador tal que se acercara al valor del parámetro más que cualquier otro estimador; es decir un estimador $\hat{\theta}$ tal que,

$$P(\hat{\theta} - \epsilon \leq \theta \leq \hat{\theta} + \epsilon) \geq P(\bar{\theta} - \epsilon \leq \theta \leq \bar{\theta} + \epsilon) \quad (1)$$

para cualquier tamaño de muestra, representando $\bar{\theta}$ cualquier otro estimador alternativo.

La expresión (1) en palabras significa, que el mejor estimador sería aquel para el cual la probabilidad de que el parámetro esté en un entorno arbitrariamente pequeño del estimador $(\hat{\theta} - \epsilon, \hat{\theta} + \epsilon)$, es mayor que la probabilidad que el parámetro esté en el mismo entorno de otro estimador alternativo cualquiera.

La imposibilidad de encontrar estimador con esas características ha llevado a buscar otros criterios para escoger los estimadores.

La selección apropiada de un estimador depende de las consecuencias negativas o pérdidas que acarrea las decisiones equivocadas. Estas consecuencias negativas pueden representarse por lo que se conoce como “función de pérdida”

$L(\hat{\theta}, \theta) = L[g(x_1, \dots, x_n), \theta]$ que es una función no negativa del estimador y del parámetro

desconocido, que refleja la “pérdida” de escoger el estimador $\hat{\theta}$ cuando el parámetro es θ . Esta pérdida debe ser cero, cuando el estimador escogido es igual al verdadero valor del parámetro, $\hat{\theta} = \theta$; es decir, cuando se toma la decisión correcta, y debe ir creciendo a medida que la diferencia entre el estimador y el parámetro va siendo mayor.

El investigador debería entonces escoger un estimador tal que la pérdida fuera mínima para todos los posibles valores de θ . Ahora bien, siendo $\hat{\theta}$ una variable aleatoria, la función de pérdida es también una variable aleatoria, por lo cual no se puede minimizar la pérdida sino el valor esperado de la pérdida.

$$E[L(\hat{\theta}, \theta)] = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} L(\hat{\theta}, \theta) f(x_1, \dots, x_n) dx_1 \dots dx_n$$

donde $f(x_1, \dots, x_n)$ es la función de densidad conjunta de las variables aleatorias de la muestra.

El valor esperado de la función de pérdida es la función de riesgo. Una función de pérdida muy usada en los problemas de estimación es la llamada función de pérdida del error cuadrático:

$$L(\hat{\theta}, \theta) = (\hat{\theta} - \theta)^2$$

Esta función tiene la propiedad de que la pérdida es mayor, cuanto más se diferencia el estimador del parámetro; y la pérdida es cero, cuando $\hat{\theta} = \theta$.

La función de riesgo correspondiente a esta función de pérdida es

$$E[L(\hat{\theta}, \theta)] = E(\hat{\theta} - \theta)^2$$

que se conoce como “error cuadrático medio”.

Para ilustrar la idea de que la función de pérdida no se puede minimizar por ser una variable aleatoria, veamos un ejemplo.

EJEMPLO 8.5.

Supongamos que se desea estimar la media (μ) de una población con una varianza σ^2 , usando una muestra de tamaño 2. El investigador decide escoger entre dos estimadores, la media muestral ($\hat{\theta}_1 = \bar{x}$) y el primer valor de la muestra ($\hat{\theta}_2 = x_1$). La función de pérdida a usar es $L(\hat{\theta}, \theta) = (\hat{\theta} - \theta)^2$. Si el verdadero valor de la media es 4 y la muestra obtenida dio $x_1 = 2$, $x_2 = 4$, la pérdida, usando la media muestral como estimador, es:

$$L(\hat{\theta}_1, \theta) = (\hat{\theta}_1 - \theta)^2 = (\bar{x} - \theta)^2 = (3 - 4)^2 = 1$$

mientras que la pérdida, usando el segundo estimador, es:

$$L(\hat{\theta}_2, \theta) = (\hat{\theta}_2 - \theta)^2 = (x_1 - \theta)^2 = (2 - 4)^2 = 4$$

La pérdida es menor al usar $\hat{\theta}_1$ que cuando se usa $\hat{\theta}_2$.

Sin embargo, si los valores de la muestra hubieran sido $x_1 = 4$ y $x_2 = 8$ las pérdidas correspondientes serían:

$$L(\hat{\theta}_1, \theta) = 4 \quad \text{y} \quad L(\hat{\theta}_2, \theta) = 0$$

la pérdida con el primer estimador sería mayor que con el segundo.

Para comparar estimadores deben entonces compararse los riesgos. De dos estimadores será mejor, en términos de pérdida promedio, aquel cuyo riesgo sea menor para todos los posibles valores del parámetro, $\hat{\theta}_1$ será mejor estimador que $\hat{\theta}_2$ si

$$E(\hat{\theta}_1 - \theta)^2 < E(\hat{\theta}_2 - \theta)^2 \quad \forall \theta$$

EJEMPLO 8.6.

En el ejemplo 8.5, ¿Cuál de los estimadores tiene menor riesgo?

$$E[L(\hat{\theta}_1, \theta)] = E(\bar{x} - \mu)^2 = \text{Var}(\bar{x}) = \frac{\sigma^2}{n} = \frac{\sigma^2}{2}$$

$$E[L(\hat{\theta}_2, \theta)] = E(x_1 - \mu)^2 = \text{Var}(x_1) = \sigma^2$$

$$\frac{\sigma^2}{2} < \sigma^2 \quad \forall \mu$$

$$E[L(\hat{\theta}_1, \theta)] < E[L(\hat{\theta}_2, \theta)]$$

El riesgo para $\hat{\theta}_1$ es menor que para $\hat{\theta}_2$ para todo valor de μ , luego, en términos de riesgo, la media muestral es mejor estimador de la media de la población que el primer valor de la muestra.

El estimador ideal siguiendo este criterio, sería aquel cuyo riesgo fuera mínimo para todos los valores de θ ; en otras palabras el mejor estimador $\hat{\theta}$ sería aquel para el cual,

$$E(\hat{\theta} - \theta)^2 < E(\bar{\theta} - \theta)^2 \quad \forall \theta$$

siendo $\bar{\theta}$ un estimador alternativo cualquiera.

Desafortunadamente tales estimadores con mínimo riesgo para todos los posibles valores de θ no existen en la generalidad de los casos, por lo cual se han ideado otros criterios para juzgar los estimadores.

Se ha desarrollado así un conjunto de propiedades que parece conveniente tengan los estimadores. Debe estar claro que un estimador que posea todas o alguna de estas propiedades no necesariamente es mejor en términos de pérdida o riesgo que otro estimador que no las tenga o tenga menos.

Para cada una de ellas se debe saber en qué consiste la propiedad, por qué es conveniente que un estimador la posea y cómo se sabe si un estimador la tiene.

8.3. PROPIEDADES DE LOS ESTIMADORES

Casi todas las propiedades están relacionadas con la función de riesgo, por lo que es conveniente preparar esa función matemáticamente para definir las propiedades.

La función de riesgo que se ha considerado en el punto anterior es:

$$E[L(\hat{\theta}, \theta)] = E(\hat{\theta} - \theta)^2$$

Sumando y restando $E(\hat{\theta})$, queda:

$$\begin{aligned} E(\hat{\theta} - \theta)^2 &= E\{[\hat{\theta} - E(\hat{\theta})] - [\theta - E(\hat{\theta})]\}^2 = \\ &= E\{[\hat{\theta} - E(\hat{\theta})]^2 + [\theta - E(\hat{\theta})]^2 - 2[\hat{\theta} - E(\hat{\theta})][\theta - E(\hat{\theta})]\} = \\ &= E[\hat{\theta} - E(\hat{\theta})]^2 + E[\theta - E(\hat{\theta})]^2 - 2E\{[\hat{\theta} - E(\hat{\theta})][\theta - E(\hat{\theta})]\} \end{aligned}$$

Ahora bien,

$E[\hat{\theta} - E(\hat{\theta})]^2 = \text{Varianza de } \hat{\theta}$, además $\theta - E(\hat{\theta})$ es una constante, luego,

$$E(\hat{\theta} - \theta)^2 = \text{Var}(\hat{\theta}) + [\theta - E(\hat{\theta})]^2 \quad (2)$$

puesto que $E[\hat{\theta} - E(\hat{\theta})] = 0$; es decir, el "error cuadrático medio" es la suma de dos cantidades no negativas, la varianza del estimador y el cuadrado de la diferencia entre el parámetro y el valor esperado del estimador. Esta diferencia $[\theta - E(\hat{\theta})]$ se conoce como "sesgo" del estimador.

8.3.1. ESTIMADORES INSESGADOS

DEFINICION 8.2.

Un estimador $\hat{\theta}$ es "insesgado" cuando su sesgo es cero; es decir, cuando el valor esperado del estimador es igual al parámetro que está estimando.

$$E(\hat{\theta}) - \theta = 0$$

Parece obvio que una propiedad conveniente de los estimadores es que sean insesgados, puesto que uno de los términos no negativos que componen la función de riesgo se anula. Por otro lado, el hecho de ser insesgado significa que el estimador en promedio es igual al parámetro. De los estimadores con igual varianza, aquellos insesgados serán mejores estimadores.

Para saber si un estimador es insesgado basta verificar si su valor esperado es igual al parámetro que esté estimando.

EJEMPLO 8.7.

Si tomamos una muestra aleatoria de 4 elementos x_1, x_2, x_3, x_4 de una población, y queremos estimar la media poblacional μ , usamos como estimadores; a) la media muestral, b) la media de x_2 y x_3 . Ambos estimadores son insesgados. En efecto:

$$a) \hat{\theta}_1 = \bar{x} \quad E(\hat{\theta}_1) = E(\bar{x}) = \mu \quad (\text{Ver sección 7.3})$$

$$b) \hat{\theta}_2 = \frac{x_2 + x_3}{2}, \quad E(\hat{\theta}_2) = \frac{E(x_2) + E(x_3)}{2} = \frac{\mu + \mu}{2} = \mu$$

EJEMPLO 8.8.

Dada una población con media μ y varianza σ^2 , usamos como estimador de la varianza, la varianza muestral. Comprobar si es un estimador insesgado.

$$\hat{\theta} = s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

$$E(\hat{\theta}) = E(s^2) = E\left[\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}\right] = \frac{1}{n} \left[E \sum_{i=1}^n (x_i - \mu)^2 - n E(\bar{x} - \mu)^2 \right] =$$

$$= \frac{1}{n} \sum_{i=1}^n E(x_i - \mu)^2 - E(\bar{x} - \mu)^2$$

(Ver sección 7.5.3.)

Ahora bien,

$$E(x_i - \mu)^2 = \sigma^2 \Rightarrow \sum_{i=1}^n E(x_i - \mu)^2 = n\sigma^2$$

Además, $E(\bar{x} - \mu)^2 = \text{Var}(\bar{x}) = \frac{\sigma^2}{n}$

$$E(\hat{\theta}) = \frac{1}{n} n\sigma^2 - \frac{\sigma^2}{n} = \frac{(n-1)\sigma^2}{n}$$

$$E(s^2) \neq \sigma^2$$

Luego s^2 no es un estimador insesgado de σ^2 .

Un estimador insesgado de σ^2 sería la cuasivarianza muestral, puesto que

$$E\left[\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}\right] = E\left[\frac{ns^2}{n-1}\right] = \frac{n}{n-1} E(s^2) = \sigma^2$$

Al mismo resultado se llega si recordamos que en el caso de poblaciones normales ns^2/σ^2 es una variable χ^2 con $n-1$ grados de libertad, luego,

$$E\left[\frac{ns^2}{\sigma^2}\right] = n-1 \text{ (Ver sección 5.16)} \Rightarrow E(s^2) = \frac{n-1}{n} \sigma^2 \neq \sigma^2$$

8.3.2. ESTIMADORES EFICIENTES (RELATIVA EFICIENCIA)

DEFINICION 8.3.

Un estimador $\hat{\theta}_1$ es más eficiente que otro estimador $\hat{\theta}_2$ si

$$E(\hat{\theta}_1 - \theta)^2 < E(\hat{\theta}_2 - \theta)^2 \quad \forall \theta$$

es decir, si el riesgo del estimador $\hat{\theta}_1$ es menor que el riesgo del estimador $\hat{\theta}_2$, y el estimador eficiente será aquel de mínimo riesgo.

EJEMPLO 8.9.

En el ejemplo 8.7, la media muestral es un estimador más eficiente que la media de x_2 y x_3 . En efecto, siendo ambos insesgados, el riesgo depende únicamente de la varianza del estimador,

$$\text{Var}(\bar{x}) = \frac{\sigma^2}{4}; \quad \text{Var}\left[\frac{x_2 + x_3}{2}\right] = \frac{1}{4} \cdot 2\sigma^2 = \frac{\sigma^2}{2}$$

$$\frac{\sigma^2}{4} < \frac{\sigma^2}{2} \quad \forall \sigma^2$$

Resulta evidente la conveniencia de que un estimador sea eficiente, pues ese estimador tendrá mínimo riesgo.

Debido a la dificultad de conseguir estimadores con mínimo riesgo, el concepto de eficiencia se suele aplicar para comparar solamente estimadores insesgados. En este caso la comparación de riesgos se limita a la comparación de varianzas, puesto que el sesgo es cero; y surge así el concepto de "estimadores insesgados de mínima varianza", o estimadores insesgados eficientes, también conocidos como estimadores relativamente eficientes. Dados dos estimadores insesgados, será más eficiente aquel con menor varianza (Ver ejemplo anterior); y un estimador insesgado de mínima varianza será aquel cuya varianza sea menor entre la clase de los estimadores insesgados; en otras palabras, $\hat{\theta}$ será un estimador insesgado de mínima varianza, si y sólo si:

- 1) $E(\hat{\theta}) = \theta$
- 2) $\text{Var}(\hat{\theta}) < \text{Var}(\bar{\theta})$ donde $\bar{\theta}$ es cualquier estimador insesgado

Para saber si un estimador insesgado es de mínima varianza, es útil el teorema de Cramer-Rao, conocido como la desigualdad de Cramer-Rao que se enuncia a continuación

y que es válido bajo ciertas condiciones de regularidad que suelen darse en la práctica; la más importante es que los límites del campo de existencia de la variable no sean función del parámetro θ .

Teorema: Sea $x_1, x_2, \dots, x_n$ una muestra aleatoria de una población con función de densidad $f(x)$ con parámetro θ . Sea $\bar{\theta} = g(x_1, x_2, \dots, x_n)$ un estimador insesgado de θ . Entonces:

$$\text{Var}(\bar{\theta}) \geq \frac{1}{nE\left[\frac{\partial}{\partial\theta} \ln f(x)\right]^2}$$

Este teorema da un límite inferior para la varianza de cualquier estimador insesgado, por debajo del cual no puede caer la varianza; si se puede encontrar un estimador insesgado cuya varianza sea igual a ese límite inferior; ese estimador, evidentemente, será de mínima varianza. Se puede demostrar que ese estimador insesgado de mínima varianza es único¹⁴.

EJEMPLO 8.10.

Dada una población distribuida exponencialmente, calcular el límite inferior para la varianza de los estimadores insesgados del parámetro θ .

$$\ln f(x) = \ln\left(\frac{1}{\theta} e^{-x/\theta}\right) = -\ln\theta - \frac{x}{\theta}$$

$$\frac{\partial}{\partial\theta} \ln f(x) = -\frac{1}{\theta} + \frac{x}{\theta^2} = \frac{x - \theta}{\theta^2}$$

$$\left[\frac{\partial}{\partial\theta} \ln f(x)\right]^2 = \frac{(x - \theta)^2}{\theta^4}$$

$$E\left[\frac{\partial}{\partial\theta} \ln f(x)\right]^2 = \frac{E(x - \theta)^2}{\theta^4} = \frac{\text{Var}(x)}{\theta^4} = \frac{\theta^2}{\theta^4} = \frac{1}{\theta^2}$$

puesto que $E(x) = \theta$ y $\text{Var}(x) = \theta^2$ (Ver sección 5.5). Luego,

$$\text{Var}(\bar{\theta}) \geq \frac{1}{n \cdot 1/\theta^2} = \frac{\theta^2}{n}$$

¹⁴ Para una prueba del teorema, ver Paul G. Hoel, op. cit. Apéndice 1.

Ahora bien, puesto que la varianza de la media muestral es la varianza de la población dividida por el tamaño de la muestra, $\text{Var}(\bar{x}) = \frac{\sigma^2}{n} = \frac{\theta^2}{n}$, se tiene que la varianza de la media muestral corresponde al límite inferior dado por la desigualdad Cramer-Rao; luego, la media muestral es el estimador insesgado de mínima varianza de la media de una población exponencial.

8.3.3. ESTIMADORES CONSISTENTES

Como los estimadores puntuales son usados para aproximar los valores de los parámetros desconocidos de una población, es evidente que cuanto mayor sea el tamaño de la muestra, teniendo por consiguiente más información, el estimador debería acercarse más al verdadero valor del parámetro. En otras palabras, un estimador basado en una muestra de 25 observaciones debería estar más cerca del verdadero valor del parámetro, que el mismo estimador basado en una muestra de 10 observaciones. Esta propiedad se conoce como consistencia. Un estimador es consistente, si a medida que aumenta el tamaño de la muestra, se va aproximando al parámetro; dicho de otra forma, un estimador es consistente, si converge en probabilidad hacia el parámetro.

DEFINICION 8.4.

Sea $\hat{\theta}_n$ ($n = 1, 2, 3, \dots$), un estimador de θ , basado en una muestra de tamaño n . $\hat{\theta}_n$ es consistente si, para todo $\varepsilon > 0$ arbitrariamente pequeño, se cumple que

$$\lim_{n \rightarrow \infty} P\left[\theta - \varepsilon < \hat{\theta}_n < \theta + \varepsilon\right] = 1 \quad \forall \theta \quad (4)$$

En palabras, $\hat{\theta}_n$ será consistente si la probabilidad que $\hat{\theta}_n$ difiera de θ en menos de un número tan pequeño como se quiera tiende a uno cuando el tamaño de la muestra crece indefinidamente.

EJEMPLO 8.11.

Comprobar que $\bar{x}$ es un estimador consistente de la media de una población normal.

$$\bar{x} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

$$P[\mu - \varepsilon \leq \bar{x} \leq \mu + \varepsilon] = P\left[\frac{(\mu - \varepsilon - \mu)\sqrt{n}}{\sigma} \leq \frac{(\bar{x} - \mu)\sqrt{n}}{\sigma} \leq \frac{(\mu + \varepsilon - \mu)\sqrt{n}}{\sigma}\right] =$$

$$= P\left[\frac{-\varepsilon\sqrt{n}}{\sigma} \leq y \leq \frac{\varepsilon\sqrt{n}}{\sigma}\right]$$

$$\lim_{n \rightarrow \infty} P\left[\frac{-\varepsilon\sqrt{n}}{\sigma} \leq y \leq \frac{\varepsilon\sqrt{n}}{\sigma}\right] = P(-\infty < y < \infty) = 1$$

La condición de consistencia se puede expresar en términos del riesgo. Igual que es conveniente que el estimador se aproxime al parámetro a medida que aumenta el tamaño de la muestra, parece también lógico que a medida que disponemos de más observaciones, el riesgo de un estimador se haga cada vez menor, es decir:

$$\lim_{n \rightarrow \infty} E[L(\hat{\theta}_n, \theta)] = 0 \quad \forall \theta$$

Si usamos como función de riesgo el error cuadrático medio, la condición anterior, se convierte en:

$$\lim_{n \rightarrow \infty} \left\{ \text{Var}(\hat{\theta}) + [\theta - E(\hat{\theta}_n)]^2 \right\} = 0$$

lo que implica que tanto la varianza como el sesgo del estimador deben tender a cero.

$$\lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}_n) = 0 \quad \text{y} \quad \lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta$$

Si se cumplen estas dos condiciones, se cumple también la condición de consistencia dada en (4)

* En efecto, por la desigualdad de Chebychev sabemos que :

$$P\left[|\hat{\theta}_n - E(\hat{\theta}_n)| \leq \varepsilon\right] \geq 1 - \frac{\text{Var}(\hat{\theta}_n)}{\varepsilon^2}$$

$$\text{Ahora bien, si } \lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}_n) = 0 \quad \text{y} \quad \lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta$$

la anterior desigualdad se convierte en :

$$\lim_{n \rightarrow \infty} P\left[|\hat{\theta}_n - E(\hat{\theta}_n)| \leq \varepsilon\right] = \lim_{n \rightarrow \infty} P\left[|\hat{\theta}_n - \theta| \leq \varepsilon\right] = 1$$

puesto que,

$$\lim_{n \rightarrow \infty} \frac{\text{Var}(\hat{\theta}_n)}{\varepsilon^2} = 0 *$$

Para comprobar entonces la consistencia de un estimador en la práctica, se comprueba si la varianza y el sesgo del estimador tienden a cero.

EJEMPLO 8.12.

La media muestral es un estimador consistente de la media de la población exponencial.

En efecto,

$$E(\bar{x}) = \theta \quad \text{y} \quad \text{Var}(\bar{x}) = \frac{\theta^2}{n}$$

$$\lim_{n \rightarrow \infty} E(\bar{x}) - \theta = 0 \quad \text{y} \quad \lim_{n \rightarrow \infty} \text{Var}(\bar{x}) = 0$$

luego $\bar{x}$ es consistente.

EJEMPLO 8.13.

En el ejemplo 8.8. se demostró que s^2 no es estimador insesgado de σ^2 . Comprobar si en el caso de poblaciones normales, s^2 es un estimador consistente de σ^2 .

$$\text{Se sabe que } E(s^2) = \frac{(n-1)\sigma^2}{n} \quad (\text{ver ejemplo 8.8.})$$

$$\text{Por otro lado, } \text{Var}(s^2) = \frac{2(n-1)(\sigma^2)^2}{n^2}$$

$$\text{en efecto, } \frac{ns^2}{\sigma^2} \sim \chi^2(n-1) \quad (\text{Ver sección 7.5.3.}),$$

$$\text{luego } \text{Var}\left(\frac{ns^2}{\sigma^2}\right) = 2(n-1) \quad (\text{Ver sección 5.16})$$

$$\text{Var}\left(\frac{ns^2}{\sigma^2}\right) = \frac{n^2}{(\sigma^2)^2} \text{Var}(s^2) \Rightarrow \text{Var}(s^2) = \frac{2(n-1)(\sigma^2)^2}{n^2}$$

$$\lim_{n \rightarrow \infty} E(s^2) = \lim_{n \rightarrow \infty} \left(1 - \frac{1}{n}\right) \sigma^2 = \sigma^2$$

Además,

$$\lim_{n \rightarrow \infty} \text{Var}(s^2) = \lim_{n \rightarrow \infty} \left\{ 2 \left[\frac{1}{n} (\sigma^2)^2 - \frac{1}{n^2} (\sigma^2)^2 \right] \right\} = 0$$

Lucgo, s^2 es un estimador consistente de σ^2 para poblaciones normales.

EJEMPLO 8.14.

Si usamos como estimador de la media μ de una población, con varianza σ^2 la media del primer y último elemento de una muestra, cualquiera que sea su tamaño, ese estimador no será consistente.

En efecto,

$$\hat{\theta} = \frac{x_1 + x_n}{2} \quad E(\hat{\theta}) = \mu; \quad \text{pero } \text{Var}(\hat{\theta}) = \frac{2\sigma^2}{4} = \frac{\sigma^2}{2}$$

La varianza del estimador en este caso no depende de n ,

$$\lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}) = \frac{\sigma^2}{2} \neq 0$$

8.3.4. ESTIMADORES SUFICIENTES

Otra propiedad importante que es deseable que posean los estimadores es la "suficiencia". Esta propiedad se refiere a que los estimadores usen toda la información que sobre el parámetro a estimarse contenga la muestra. Cuando se desea estimar un parámetro θ desconocido de una población con función de densidad $f(x)$, a través de una muestra aleatoria, toda la información acerca de ese parámetro está contenida en la muestra. Se sabe que un estimador es una función de las variables aleatorias que componen la muestra. El estimador puede recoger toda la información que acerca del valor del parámetro contiene la muestra, o puede usar solamente parte de esa información. Por ejemplo, si se toma una muestra $x_1, x_2, \dots, x_n$ de una población para estimar la media,

y usamos como estimador la media de los dos primeros elementos de la muestra es obvio que no estamos utilizando toda la información que la muestra provee acerca del parámetro.

Un estimador se dice suficiente si recoge toda la información que la muestra provee; es decir, si ningún otro estimador basado en la misma muestra puede añadir información sobre el parámetro que se está estimando.

EJEMPLO 8.15.

Supongamos que se quiere estimar la proporción "p" de una población binomial, mediante una muestra aleatoria de 4 elementos. En la muestra se han dado 3 éxitos; luego la proporción muestral $\hat{p} = 3/4$. La probabilidad de obtener 3 éxitos en 4 intentos, dado p, es

$$P(x = 3) = \binom{4}{3} p^3 q$$

Supongamos que queremos ser más precisos en la estimación de "p" considerando no sólo el número de éxitos en la muestra, sino también el orden en que éstos se han dado. En una muestra de cuatro elementos, 3 éxitos se pueden dar de varias formas; (1, 1, 1, 0) (1, 0, 1, 1) (1, 1, 0, 1) (0, 1, 1, 1) donde los unos indican éxitos y los ceros fallas. La probabilidad de que los tres éxitos se den en determinada secuencia, por ejemplo: (1, 1, 1, 0), es:

$$P(1, 1, 1, 0) = p^3 q$$

Dado que se han obtenido tres éxitos, la probabilidad de que se den los tres éxitos primero y después la falla es:

$$P[(1, 1, 1, 0)/x = 3] = \frac{P(1, 1, 1, 0)}{P(x = 3)} = \frac{p^3 q}{\binom{4}{3} p^3 q} = \frac{1}{4}$$

En general, la probabilidad de que se den 3 éxitos en un orden determinado es $1/4$ y no depende del valor del parámetro desconocido p. Es decir que, después de conocer que se han obtenido tres éxitos en la muestra, el hecho de saber en que orden se han dado, no arroja ninguna información adicional sobre el valor de p, puesto que éste no influye en el orden en que se dieron los éxitos, sino solamente en el número de ellos. En este caso, si usamos como estimador de "p" la proporción de éxitos (número de éxitos), este estimador es suficiente, puesto que toda la información de la muestra está considerada en el estimador.

• La definición precisa de estimador suficiente es la siguiente:

*** DEFINICION 8.5.**

Dada una muestra aleatoria $x_1, \dots, x_n$ de una población con función de densidad $f(x)$ con parámetro desconocido θ , $\hat{\theta}$ será un estimador suficiente de θ , si la función de densidad condicional de cualquier otro estimador $\bar{\theta}$ obtenido de la misma muestra, dado $\hat{\theta}$ no depende del valor del parámetro θ ; es decir, si $f(\bar{\theta}/\hat{\theta})$ no contiene el parámetro desconocido θ .*

Para comprobar en la práctica si un estimador es suficiente, se puede usar el siguiente teorema, que se enuncia sin prueba, la prueba de este teorema va más allá de los alcances de este texto¹⁵.

Teorema de Fisher-Neyman:

Dada una muestra aleatoria $x_1, x_2, \dots, x_n$ de una población con función de densidad $f(x)$ con parámetro desconocido θ , $\hat{\theta}$ será un estimador suficiente de θ si y sólo si:

$$f(x_1, x_2, \dots, x_n) = g(\hat{\theta}, \theta) \cdot h(x_1, x_2, \dots, x_n)$$

es decir, si la función de densidad conjunta de las variables aleatorias de la muestra se puede descomponer en dos factores. Uno $g(\hat{\theta}, \theta)$ que depende sólo del estimador $\hat{\theta}$ y del parámetro θ , y el otro $h(x_1, \dots, x_n)$ que sea independiente de θ .

EJEMPLO 8.16.

En una muestra de tamaño n de una población Poisson con parámetro μ . ¿Es $\bar{x}$ un estimador suficiente de μ ?

$$f(x) = \frac{e^{-\mu} \mu^x}{x!} \quad \text{para } x = 0, 1, 2, 3, \dots$$

$$f(x_1, \dots, x_n) = f(x_1) f(x_2) \dots f(x_n)$$

$$= \frac{e^{-\mu} \mu^{x_1}}{x_1!} \frac{e^{-\mu} \mu^{x_2}}{x_2!} \dots \frac{e^{-\mu} \mu^{x_n}}{x_n!} \quad \text{para } x_i = 0, 1, 2, 3, \dots$$

$i = 1, \dots, n$

$$f(x_1, \dots, x_n) = \frac{e^{-\mu n} \mu^{\sum x_i}}{\prod_{i=1}^n x_i!} = e^{-\mu n} \mu^{n\bar{x}} \frac{1}{\prod_{i=1}^n x_i!}$$

¹⁵ Para una prueba del teorema ver S. D. Silvey, Statistical Inference, Penguin Books Ltd., págs. 27-28.

aquí,

$$g(\hat{\theta}, \theta) = g(\bar{x}, \mu) = e^{-\mu n} \mu^{n\bar{x}}$$

$$h(x_1, \dots, x_n) = \frac{1}{\prod_{i=1}^n x_i!} \quad \text{que no depende de } \mu$$

Luego $\bar{x}$ es un estimador suficiente de μ .

EJEMPLO 8.17.

Sea $x_1, x_2, \dots, x_n$ una muestra aleatoria de una población punto-binomial con $f(x) = p^x (1-p)^{1-x}$ para $x = 0, 1$. ¿Es la proporción muestral un estimador suficiente de "p"?

$f(x_1, \dots, x_n) = f(x_1) f(x_2) \dots f(x_n)$, por ser $x_1, \dots, x_n$ variables aleatorias independientes.

$$f(x_1, \dots, x_n) = p^{x_1} (1-p)^{1-x_1} \dots p^{x_n} (1-p)^{1-x_n} \quad \text{para } x_i = 0, 1$$

$i = 1, 2, \dots, n$

$$= p^{\sum x_i} (1-p)^{n - \sum x_i}$$

siendo $\hat{p} = \frac{\sum x_i}{n}$, queda:

$$f(x_1, \dots, x_n) = p^{n\hat{p}} (1-p)^{n(1-\hat{p})}$$

En este caso,

$$g(\hat{\theta}, \theta) = g(\hat{p}, p) = p^{n\hat{p}} (1-p)^{n(1-\hat{p})}; \quad h(x_1, \dots, x_n) = 1$$

Luego $\hat{p}$ es un estimador suficiente de "p".

EJEMPLO 8.18.

En una muestra aleatoria de tamaño n de una población exponencial con función de densidad $f(x) = \frac{1}{\theta} e^{-x/\theta}$ para $x > 0$. ¿Es x_1 un estimador suficiente de θ ?

$$f(x) = \frac{1}{\theta} e^{-x/\theta} \quad \text{para } x > 0$$

$$f(x_1, \dots, x_n) = \frac{1}{\theta^n} e^{-\frac{1}{\theta} \sum_{i=1}^n x_i} \quad \text{para } x_i > 0; \quad i = 1, \dots, n$$

Siendo $\hat{\theta} = x_1$

$$f(x_1, \dots, x_n) = \frac{1}{\theta^n} e^{-\frac{1}{\theta} x_1} e^{-\frac{1}{\theta} \sum_{i=2}^n x_i}$$

Evidentemente no se puede encontrar en este caso $h(x_1, \dots, x_n)$; luego x_1 no es un estimador suficiente de θ .

8.4. CALCULO DE ESTIMADORES (METODO DE MAXIMA VEROSIMILITUD)

En la sección anterior se han enumerado y discutido una serie de propiedades convenientes en los estimadores puntuales. Para el cálculo de éstos existe un procedimiento que, además de ser lógico en sí mismo, proporciona estimadores que generalmente poseen todas o algunas de las propiedades enunciadas. Tal procedimiento de cálculo de estimadores por puntos se conoce como el método de máxima verosimilitud.

Primero, se explicará de una forma intuitiva en qué consiste el método, para después formalizar el concepto.

Nuestro problema de estimación se reduce como se ha visto, a elegir, a partir de una muestra, un estimador del parámetro desconocido de una población. La idea básica del método de máxima verosimilitud es la siguiente: al tomar una muestra aleatoria de una población, sabemos que los elementos de esa muestra son variables aleatorias, y por consiguiente los valores de esas variables aleatorias se obtienen con una determinada probabilidad; esa probabilidad varía de acuerdo con el valor del parámetro poblacional desconocido; por ejemplo, es distinta la probabilidad de obtener un 4, al tomar un elemento de una población Poisson con media 3, que de obtenerlo si la media es 8.

El método de máxima verosimilitud trata de encontrar el valor del parámetro para el cual sea máxima la probabilidad de haber obtenido los valores muestrales encontrados. Para hacer más clara la idea, veamos un ejemplo simplificado de estimación.

EJEMPLO 8.19.

Supongamos que en un almacén hay unidades de mercancías de dos tipos: clase A y clase B. Se sabe que el 30% de las unidades pertenecen a una determinada clase,

pero no se sabe a cual de ellas. Si designamos por "p" la probabilidad de obtener una unidad de clase A al escogerla aleatoriamente del almacén, "p" puede ser igual a 0,3 o a 0,7. Se desea estimar "p" con base en una muestra aleatoria de cinco elementos, en este caso el valor estimado de "p" será $\hat{p} = 0,3$ o $\hat{p} = 0,7$ y la decisión se basará en los resultados concretos de la muestra,

La probabilidad de obtener x unidades de clase A en una muestra de 5 es $\binom{5}{x} p^x (1-p)^{5-x}$ siendo $p = 0,3$ o $p = 0,7$; por consiguiente, los resultados posibles de la muestra con sus respectivas probabilidades son:

x	p = 0,3	p = 0,7
0	0,16807	0,00243
1	0,36015	0,02835
2	0,30870	0,13230
3	0,13230	0,30870
4	0,02835	0,36015
5	0,00243	0,16807

Supongamos que en la muestra se han obtenido cero elementos de clase A; parece obvio que, ante este resultado, escojamos como valor estimado de "p", $\hat{p} = 0,3$, porque $0,16807 > 0,00243$; es decir, es más probable obtener cero elementos de clase A de una población donde la proporción de éstos sea 30%, que de una donde sea 70 %.

La misma decisión se tomaría si $x = 1, 2$; mientras que elegiríamos $\hat{p} = 0,7$, si $x = 3, 4, 5$; o sea, estamos eligiendo como valor estimado de "p", aquel que, de acuerdo con los resultados de la muestra, dé la mayor probabilidad de que esos resultados se hayan obtenido.

El principio o método de máxima verosimilitud indica, según el ejemplo anterior, elegir como estimador del parámetro desconocido, aquél que maximiza la probabilidad de haber obtenido los resultados muestrales.

Al seleccionar una muestra aleatoria de tamaño n $x_1, x_2, \dots, x_n$ de una población con parámetro desconocido θ , la probabilidad de que las variables $x_1, \dots, x_n$ tomen determinados valores, viene dada por la función de densidad conjunta, $f(x_1, \dots, x_n)$.

Ahora bien;

$$f(x_1, x_2, \dots, x_n; \theta) = f(x_1, \theta) f(x_2, \theta) \dots f(x_n, \theta)$$

por ser las variables independientes. Esta función de densidad es función de las variables $x_1, \dots, x_n$ y del parámetro fijo θ ; en ella los elementos de la muestra son variables aleatorias, y el parámetro θ es una constante dada.

Si tratamos ahora las variables aleatorias como fijas, (después de haber obtenido la muestra, estas variables tienen valores dados), y el parámetro desconocido θ como una variable que puede tener diferentes valores, tendremos tantas funciones de densidad conjunta como posibles valores del parámetro, y el problema es elegir aquella función de donde es más verosímil que provenga la muestra. A la función de densidad conjunta se le da una nueva interpretación, y se denomina como función de verosimilitud, para indicar el nuevo uso conceptual de la función.

Para variables aleatorias continuas, la función de densidad conjunta no da la probabilidad de que las variables aleatorias de la muestra tomen un valor determinado. Como se sabe, esta probabilidad es cero. Sin embargo el criterio de máxima verosimilitud es aplicable.

DEFINICION 8.6.

Dada una muestra aleatoria $x_1, \dots, x_n$ de una población con función de densidad $f(x)$, la función de verosimilitud es la función de densidad conjunta.

$$L(\theta) = f(x_1, x_2, \dots, x_n; \theta)$$

que es una función del parámetro desconocido θ .

DEFINICION 8.7.

Siendo $L(\theta) = f(x_1, x_2, \dots, x_n; \theta)$ la función de verosimilitud de $x_1, \dots, x_n$, el estimador de máxima verosimilitud o máximo verosímil de θ , es aquel valor de θ que maximiza la función de verosimilitud.

El estimador máximo verosímil se encuentra diferenciando la función de máxima verosimilitud, y hallando el valor de θ para el cual la derivada es igual a cero, teniendo en cuenta la condición de segundo orden; es decir, el estimador máximo verosímil de θ será aquel estimador $\hat{\theta}$ tal que

$$\left. \frac{dL(\theta)}{d\theta} \right|_{\theta = \hat{\theta}} = 0 \quad \text{y} \quad \left. \frac{d^2 L(\theta)}{d\theta^2} \right|_{\theta = \hat{\theta}} < 0$$

La función $\ln[L(\theta)]$ (logaritmo neperiano de $L(\theta)$) es una función monótonica de $L(\theta)$, y tiene el máximo para el mismo valor de θ , y en muchos casos es más fácil derivar

$\ln[L(\theta)]$ que $L(\theta)$; entonces, el estimador máximo verosímil se encontrará derivando $\ln[L(\theta)]$, e igualando a cero la derivada.

La condición de segundo orden se cumple para todos los casos de funciones de densidad utilizadas en la práctica, por lo que nosotros la omitiremos. Se deja como ejercicio al lector comprobar su cumplimiento.

EJEMPLO 8.20.

Hallar el estimador máximo verosímil de la proporción "p" en una distribución punto-binomial. Calcular el valor estimado de "p" si el número de éxitos en la muestra fue de 10, y el tamaño de la muestra 25.

$$f(x) = p^x (1-p)^{1-x} \quad x = 0, 1$$

$$L(p) = f(x_1, x_2, \dots, x_n, p) = p^{\sum x_i} (1-p)^{n - \sum x_i}$$

$$\ln[L(p)] = (\sum x_i) \ln p + (n - \sum x_i) \ln (1-p)$$

$$\frac{d \ln[L(p)]}{dp} = \frac{\sum x_i}{p} - \frac{n - \sum x_i}{1-p} = 0$$

$$(1-p) \sum x_i - np + p \sum x_i = 0 \Rightarrow \hat{p} = \frac{\sum x_i}{n}$$

o sea, que la proporción muestral es el estimador máximo verosímil de la proporción poblacional.

Si el número de éxitos en la muestra fue 10 y $n = 25$, el valor estimado es $\hat{p} = 10/25$.

EJEMPLO 8.21.

Hallar el estimador máximo verosímil de la media de la distribución de Poisson.

En este caso

$$f(x) = \frac{e^{-\mu} \mu^x}{x!} \quad \text{para } x = 0, 1, 2, \dots$$

$$L(\mu) = f(x_1, x_2, \dots, x_n; \mu) = \frac{e^{-n\mu} \mu^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!}$$

$$\ln [L(\mu)] = -n\mu + (\sum_{i=1}^n x_i) \ln \mu - \sum_{i=1}^n \ln(x_i!)$$

$$\frac{d \ln [L(\mu)]}{d\mu} = -n + \frac{\sum_{i=1}^n x_i}{\mu} = 0 \Rightarrow \hat{\mu} = \frac{\sum_{i=1}^n x_i}{n} = \bar{x}$$

Luego, el estimador máximo verosímil de la media de la distribución Poisson es la media muestral.

En el caso de que una población tenga más de un parámetro desconocido $\theta_1, \theta_2, \dots, \theta_k$, la función de verosimilitud será una función de los parámetros.

$$f(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k)$$

Para calcular los estimadores de máxima verosimilitud se deriva parcialmente con respecto a cada uno de los parámetros, se igualan las derivadas a cero, y se resuelve el sistema de ecuaciones resultante.

La condición de segundo orden se estudia en el determinante Hessiano, formado por las segundas derivadas. Si los menores principales alternan en signo empezando por negativo, se tiene un máximo. Condición que también omitiremos.

EJEMPLO 8.22.

Hallar los estimadores máximos verosímiles de la media y varianza de una población normal.

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-1/2 \left(\frac{x-\mu}{\sigma} \right)^2} \quad \text{para } -\infty < x < +\infty$$

$$L(\mu, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{n/2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2} \quad \text{para } -\infty < x_i < +\infty$$

$$\ln [L(\mu, \sigma^2)] = -\ln(2\pi)^{n/2} - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

$$\frac{\partial \ln [L(\mu, \sigma^2)]}{\partial \mu} = \frac{1}{2\sigma^2} 2 \sum_{i=1}^n (x_i - \mu) = 0 \quad (3)$$

$$\frac{\partial \ln [L(\mu, \sigma^2)]}{\partial \sigma^2} = \frac{-n}{2} \frac{1}{\sigma^2} + \frac{\sum_{i=1}^n (x_i - \mu)^2}{2(\sigma^2)^2} = 0 \quad (4)$$

de (3) se tiene $\sum_{i=1}^n (x_i - \mu) = 0$; $\sum_{i=1}^n x_i - n\mu = 0 \Rightarrow \hat{\mu} = \frac{\sum_{i=1}^n x_i}{n} = \bar{x}$

Sustituyendo en (4)

$$-n\sigma^2 + \sum_{i=1}^n (x_i - \bar{x})^2 = 0 \Rightarrow \hat{\sigma}^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n} = s^2$$

$$\ln [L(\mu, \sigma^2)] \text{ tiene un máximo para } \hat{\mu} = \bar{x} \text{ y } \hat{\sigma}^2 = s^2$$

Los estimadores máximo verosímiles de μ y σ^2 en la distribución normal son la media y varianzas muestrales respectivamente.

Los estimadores máximo verosímiles gozan de algunas de las propiedades consideradas convenientes:

Los estimadores máximo verosímiles son generalmente consistentes.

Para un tamaño grande de la muestra la varianza de los estimadores máximo verosímiles tiende al límite inferior dado por la desigualdad de Cramer-Rao; en este sentido se dice que son asintóticamente eficientes (de mínima varianza).

Los estimadores máximo verosímiles, por otro lado, tienden a distribuirse normalmente cuando n tiende a infinito.

Además, si existe un estimador suficiente de un parámetro, los estimadores máximo verosímiles son una función de ese estimador.

Por último, los estimadores de máxima verosimilitud gozan de una importante propiedad conocida como "invarianza".

Esta propiedad dice que si $\hat{\theta}$ es el estimador máximo verosímil de θ , entonces $g(\hat{\theta})$ es un estimador máximo verosímil de $g(\theta)$ siendo $g(\theta)$ una función de θ con una sola inversa. En otras palabras, dada una función con una sola inversa del parámetro desconocido, el estimador máximo verosímil de esa función es la misma función, sustituyendo θ por $\hat{\theta}$.

EJEMPLO 8.23.

Sabemos que $\bar{x}$ es el estimador máximo verosímil de μ en la distribución normal. El estimador máximo verosímil de

$$g(\mu) = 3\mu + 8 \text{ es } g(\hat{\mu}) = 3\bar{x} + 8$$

EJEMPLO 8.24.

El estimador máximo verosímil de la desviación típica es s , puesto que $\sigma = g(\sigma^2) = \sqrt{\sigma^2}$; función con una sola inversa, luego, $g(s^2) = \sqrt{s^2} = s$. El estimador de máxima verosimilitud de la desviación típica de una población normal es la desviación típica muestral.

EJERCICIOS RESUELTOS

- 8.1. i) Calcular el estimador máximo verosímil de θ en la distribución exponencial.
 ii) Calcular el valor estimado, si una muestra de 10 elementos dio los siguientes resultados: 1; 4; 7; 2; 3; 6; 12; 2,5; 3,5; 4,4.

Solución:

$$i) f(x) = \frac{1}{\theta} e^{-\frac{x}{\theta}} \text{ para } x > 0$$

$$L(\theta) = \frac{1}{\theta^n} e^{-\frac{\sum x_i}{\theta}}$$

$$\ln [L(\theta)] = -n \ln \theta - \frac{1}{\theta} \sum x_i$$

$$\frac{d}{d\theta} \ln [L(\theta)] = -\frac{n}{\theta} + \frac{\sum x_i}{\theta^2} = 0$$

$$-n\theta + \sum x_i = 0$$

$$\hat{\theta} = \frac{\sum x_i}{n} = \bar{x}$$

Luego, el estimador máximo verosímil de θ es la media muestral.

$$ii) \bar{x} = \frac{\sum x_i}{n} = \frac{45,4}{10} = 4,54$$

$$\hat{\theta} = 4,54$$

- 8.2. Comprobar si la media muestral es un estimador suficiente de μ en una población normal con σ^2 conocida.

Solución:

$$\begin{aligned} f(x_1, x_2, \dots, x_n) &= \left(\frac{1}{\sqrt{2\pi} \sigma} \right)^n e^{-\frac{1}{2\sigma^2} \sum (x_i - \mu)^2} \\ &= \left(\frac{1}{\sqrt{2\pi} \sigma} \right)^n e^{-\frac{1}{2\sigma^2} \sum [(x_i - \bar{x}) - (\mu - \bar{x})]^2} = \\ &= \left(\frac{1}{\sqrt{2\pi} \sigma} \right)^n e^{-\frac{1}{2\sigma^2} [\sum (x_i - \bar{x})^2 - 2(\mu - \bar{x}) \cdot \sum (x_i - \bar{x}) + n(\mu - \bar{x})^2]} = \\ &= \left(\frac{1}{\sqrt{2\pi} \sigma} \right)^n e^{-\frac{1}{2\sigma^2} \sum (x_i - \bar{x})^2} e^{-\frac{1}{2\sigma^2} n(\mu - \bar{x})^2} \end{aligned}$$

en este caso

$$g(\bar{x}, \mu) = \left(\frac{1}{\sqrt{2\pi} \sigma} \right)^n e^{-\frac{1}{2\sigma^2} n(\mu - \bar{x})^2}$$

$$h(x_1, \dots, x_n) = e^{-\frac{1}{2\sigma^2} \sum (x_i - \bar{x})^2}$$

Luego, $\bar{x}$ es un estimador suficiente de μ , conocido σ^2 .

8.3. Calcular el límite inferior para la varianza de los estimadores insesgados de σ^2 en una distribución normal con media conocida μ .

Solución:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

$$\ln f(x) = -\ln \sqrt{2\pi} - \frac{1}{2} \ln \sigma^2 - \frac{1}{2} \frac{(x-\mu)^2}{\sigma^2}$$

$$\frac{\partial \ln f(x)}{\partial \sigma^2} = \frac{-1}{2\sigma^2} + \frac{1}{2} \frac{(x-\mu)^2}{(\sigma^2)^2} = \frac{(x-\mu)^2 - \sigma^2}{2(\sigma^2)^2}$$

$$\left[\frac{\partial}{\partial \sigma^2} \ln f(x) \right]^2 = \left[\frac{(x-\mu)^2 - \sigma^2}{2(\sigma^2)^2} \right]^2 = \frac{(x-\mu)^4 - 2(x-\mu)^2\sigma^2 + (\sigma^2)^2}{4(\sigma^2)^4}$$

$$E \left[\frac{\partial}{\partial \sigma^2} \ln f(x) \right]^2 = \frac{E(x-\mu)^4 - 2(\sigma^2)^2 + (\sigma^2)^2}{4(\sigma^2)^4} = \frac{E(x-\mu)^4 - (\sigma^2)^2}{4(\sigma^2)^4}$$

$E(x-\mu)^4$ es el momento de 4º orden respecto a la media,

$$\begin{aligned} E(x-\mu)^4 &= E(x^4) - 4\mu E(x^3) + 6\mu^2 E(x^2) - 4\mu^3 E(x) + \mu^4 = \\ &= E(x^4) - 4\mu E(x^3) + 6\mu^2(\sigma^2 + \mu^2) - 4\mu^4 + \mu^4 = \\ &= E(x^4) - 4\mu E(x^3) + 6\mu^2\sigma^2 + 3\mu^4 \end{aligned}$$

$$E(x^3) = \left. \frac{d^3}{dk^3} m_x(k) \right|_{k=0} = 3\mu\sigma^2 + \mu^3$$

$$E(x^4) = \left. \frac{d^4}{dk^4} m_x(k) \right|_{k=0} = 3(\sigma^2)^2 + 6\mu^2\sigma^2 + \mu^4$$

(ver sección 5.11)

o sea,

$$E(x-\mu)^4 = 3(\sigma^2)^2 + 6\mu^2\sigma^2 + \mu^4 - 4\mu(3\mu\sigma^2 + \mu^3) + 6\mu^2\sigma^2 + 3\mu^4 = 3(\sigma^2)^2$$

Luego,

$$E \left[\frac{\partial}{\partial \sigma^2} \ln f(x) \right]^2 = \frac{3(\sigma^2)^2 - (\sigma^2)^2}{4(\sigma^2)^4} = \frac{1}{2(\sigma^2)^2}$$

En consecuencia, el límite inferior para la varianza de los estimadores de σ^2 es:

$$\text{Var}(\bar{\theta}) \geq \frac{1}{n/2(\sigma^2)^2} = \frac{2(\sigma^2)^2}{n}$$

8.4. Dada una muestra aleatoria de tamaño n de una población normal con media μ conocida. Consideren el siguiente estimador de σ^2 .

$$\bar{\theta} = \frac{\sum (x_i - \mu)^2}{n}$$

¿Es $\bar{\theta}$ i) Insesgado; ii) de mínima varianza, iii) consistente?

Solución:

i) Para que sea insesgado, $E(\bar{\theta}) = \sigma^2$

$$E(\bar{\theta}) = E \left[\frac{\sum (x_i - \mu)^2}{n} \right] = \frac{\sum E(x_i - \mu)^2}{n} = \frac{n\sigma^2}{n} = \sigma^2$$

Luego, es insesgado

ii) Por el problema anterior sabemos que el límite inferior de la varianza de los estimadores insesgados de σ^2 es $\frac{2(\sigma^2)^2}{n}$; si la varianza de $\bar{\theta}$ es $2(\sigma^2)^2/n$, $\bar{\theta}$ será un estimador insesgado de mínima varianza.

Sabemos que: $\frac{\sum (x_i - \mu)^2}{\sigma^2} \sim \chi^2(n)$

entonces, $\text{Var} \left[\frac{\sum (x_i - \mu)^2}{\sigma^2} \right] = 2n$ (ver sección 5.16)

$$\text{Var}(\bar{\theta}) = \text{Var} \left[\frac{\sum (x_i - \mu)^2 \sigma^2}{n \sigma^2} \right] = \frac{(\sigma^2)^2}{n^2} 2n = \frac{2(\sigma^2)^2}{n}$$

Luego, $\bar{\theta}$ es un estimador insesgado de mínima varianza.

iii) Para que sea consistente debe cumplirse $E(\bar{\theta}) = \sigma^2$ y $\lim_{n \rightarrow \infty} \text{Var}(\bar{\theta}) = 0$

En efecto, el estimador es insesgado, y además,

$$\lim_{n \rightarrow \infty} \text{Var}(\bar{\theta}) = \lim_{n \rightarrow \infty} \frac{2(\sigma^2)^2}{n} = 0$$

8.5. Dada una muestra aleatoria de tamaño 2 de una población normal con media μ y varianza conocida σ^2 , consideren la siguiente combinación lineal de los valores de la muestra

$$\alpha x_1 + (1 - \alpha) x_2 \quad \text{siendo } 0 \leq \alpha \leq 1$$

Sean:

$$\hat{\theta} = \alpha x_1 + (1 - \alpha) x_2 \quad 0 \leq \alpha \leq 1$$

estimadores de μ que dependen de α

i) ¿Para qué valor de α es $\hat{\theta}$ insesgado?

ii) ¿Para qué valor de α es $\hat{\theta}$ de mínimo riesgo?

Solución:

i) Para que $\hat{\theta}$ sea insesgado $E(\hat{\theta}) = \mu$

$$E(\hat{\theta}) = E[\alpha x_1 + (1 - \alpha) x_2] = \alpha \mu + (1 - \alpha) \mu = \mu$$

$\hat{\theta}$ es insesgado para todo valor de α

$$\text{ii) } E[L(\hat{\theta}, \mu)] = E(\hat{\theta} - \mu)^2 = \text{Var}(\hat{\theta}) + [E(\hat{\theta}) - \mu]^2 =$$

$$= \text{Var}(\hat{\theta}) = \text{Var}[\alpha x_1 + (1 - \alpha) x_2] =$$

$$= \alpha^2 \text{Var}(x_1) + (1 - \alpha)^2 \text{Var}(x_2) =$$

$$= \alpha^2 \sigma^2 + (1 - 2\alpha + \alpha^2) \sigma^2 = \sigma^2 (2\alpha^2 - 2\alpha + 1)$$

Para que el riesgo sea mínimo, $\frac{d}{d\alpha} E[L(\hat{\theta}, \mu)] = 0$

$$\frac{d}{d\alpha} E[L(\hat{\theta}, \mu)] = \sigma^2 (4\alpha - 2) = 0 \Rightarrow \alpha = \frac{1}{2}$$

8.6. Dada una muestra aleatoria de tamaño n de una población normal con media μ y varianza σ^2 . Hallar un estimador insesgado de $\mu^2 + 4\sigma^2$.

Solución:

Se sabe que, $E \left[\frac{\sum (x_i - \bar{x})^2}{n - 1} \right] = \sigma^2$ y $E(\bar{x}) = \mu$

Ahora bien,

$$E(\bar{x}^2) = \text{Var}(\bar{x}) + [E(\bar{x})]^2 = \frac{\sigma^2}{n} + \mu^2$$

Se quiere hallar un estimador insesgado de $\mu^2 + 4\sigma^2$

$$E \left[4 \frac{\sum (x_i - \bar{x})^2}{n - 1} \right] = 4\sigma^2$$

$$E \left[-\frac{1}{n} \frac{\sum (x_i - \bar{x})^2}{n - 1} \right] = -\frac{\sigma^2}{n}$$

luego,

$$E \left[\bar{x}^2 + 4 \frac{\sum (x_i - \bar{x})^2}{n - 1} - \frac{1}{n} \frac{\sum (x_i - \bar{x})^2}{n - 1} \right] = \frac{\sigma^2}{n} + \mu^2 + 4\sigma^2 - \frac{\sigma^2}{n} =$$

$$= \mu^2 + 4\sigma^2$$

Un estimador insesgado de $\mu^2 + 4\sigma^2$ será:

$$\begin{aligned} \bar{x}^2 + 4 \frac{\sum (x_i - \bar{x})^2}{n-1} - \frac{1}{n} \frac{\sum (x_i - \bar{x})^2}{n-1} &= \\ = \bar{x}^2 + \left(4 - \frac{1}{n}\right) \frac{\sum (x_i - \bar{x})^2}{n-1} &= \\ = \bar{x}^2 + \left(\frac{4n-1}{n}\right) \frac{\sum (x_i - \bar{x})^2}{n-1} \end{aligned}$$

EJERCICIOS PROPUESTOS

- 8.7. Comprobar si $\bar{x}$ es el estimador insesgado de mínima varianza de μ en una población normal.
- 8.8. En una población punto binomial comprobar si $\hat{p} = x/n$ es el estimador insesgado de mínima varianza de "p".
- 8.9. En una población binomial comprobar que $\hat{p} = x/n$ es un estimador consistente de "p".
- 8.10. Calcular i) el estimador máximo verosímil de la desviación típica de una población normal con media cero; ii) el valor del estimador, si en una muestra de 4 elementos los resultados fueron: -5, 3, 8, 12.
- 8.11. Calcular: i) el estimador máximo verosímil de θ en la función:

$$f(x) = \theta e^{-\theta x} \quad \text{para } x > 0$$

- ii) El valor estimado, si en una muestra de tamaño 5 los resultados fueron: 1,1; 1,2; 2,3; 1,4; 3,5.

8.12. Calcular el estimador máximo verosímil de "p" en la distribución geométrica.

8.13. Un fabricante de bombas hidroneumáticas desea estimar la probabilidad de que una bomba trabaje aceptablemente cuando se pone a funcionar. Para hacerlo, toma aleatoriamente 5 bombas de su producción, y cada una la enciende y apaga repetidamente hasta que la bomba falle en trabajar aceptablemente. El número de veces que se encendió y apagó cada bomba hasta que ocurrió la falla, fue de: 100; 75; 60; 85 y 95 respectivamente

- i) ¿Cuál es el valor del estimador máximo verosímil de la probabilidad de que la bomba trabaje aceptablemente?
- ii) ¿Cuál es el estimador máximo verosímil del número medio de veces que una bomba funcionará hasta que falla?

8.14. i) Hallar el estimador máximo verosímil de θ en una población con la siguiente función de densidad.

$$f(x) = (1 + \theta) x^\theta \quad 0 \leq x \leq 1 \quad \theta > 0$$

ii) Calcular el valor estimado del parámetro si los resultados de una muestra de tamaño 3 fueron: 0,75; 0,71; 0,70.

8.15. Calcular el valor estimado máximo verosímil en el problema anterior, si en una muestra de 4 elementos los valores fueron: 0,9; 0,8; 0,5; 1.

8.16. Dada una muestra de tamaño 3 de una población con media μ y varianza σ^2 , Se escogen dos estimadores de μ .

$$\hat{\theta}_1 = \bar{x} \quad \text{y} \quad \hat{\theta}_2 = \frac{x_1 + 3x_2 + x_3}{5}$$

En términos de riesgo, ¿Cuál de los dos estimadores es mejor?

8.17. Dada una población con la siguiente función de densidad

$$f(x) = \frac{2(\theta - x)}{\theta^2} \quad \text{para } 0 < x < \theta$$

Consideren los estimadores de θ de la forma $\hat{\theta} = c\bar{x}$, donde c es una constante.

- i) ¿Para qué valor de c es $\hat{\theta}$ insesgado?
- ii) ¿Para qué valor de c tiene $\hat{\theta}$ mínimo riesgo?
- iii) ¿Es el estimador hallado en (i) consistente?
- iv) ¿Es suficiente?

8.18. Dada una muestra aleatoria de tamaño 4 de una población con media μ y varianza 1. Sea un estimador de μ ,

$$\hat{\mu} = \lambda_1 x_1 + \lambda_2 x_2 + \lambda_3 x_3 + \lambda_4 x_4$$

i) ¿Para qué valores de λ_i $i = 1, 2, 3, 4$ es $\hat{\mu}$ insesgado?

ii) ¿Qué valores de λ_i entre los del punto (i) hacen $\hat{\mu}$ de mínimo riesgo?

8.19.i) Hallar el estimador de máxima verosimilitud de θ en una población con función de densidad:

$$f(x) = \theta x^{\theta-1} \quad \text{para } 0 < x < 1, \theta > 0$$

ii) Calcular el valor estimado de θ en una muestra de tamaño 2 con $x_1 = 0,5$, $x_2 = 0,6$.

8.20. Dada una población con función de densidad:

$$f(x) = \frac{1}{\theta} \left(1 - \frac{1}{\theta}\right)^{x-1} \quad \text{para } x = 1, 2, 3, \dots$$

i) Calcular el estimador máximo verosímil de θ con una muestra de tamaño n .

ii) ¿Cuál es el valor estimado de θ si en una muestra de 5, los resultados fueron 4; 5; 6; 10; 3?

8.21. ¿Es suficiente el estimador encontrado con el ejercicio anterior?

8.22. Hallar el límite Cramer-Rao para la varianza de los estimadores insesgados de θ en el problema 8.20.

8.23. Comprobar que el estimador hallado en 8.20 es el estimador insesgado de mínima varianza.

8.24. Dada una población con función de densidad gamma,

i) Calcular el estimador máximo verosímil de β , suponiendo α conocida.

ii) Si una muestra de tamaño 4 dio los resultados 5, 6, 7 y 6 siendo $\alpha = 2$, calcular el valor del estimador máximo verosímil de la media de la población.

8.25. Comprobar si el estimador hallado en el problema anterior es:

- i) Insesgado,
- ii) Suficiente
- iii) De mínima varianza
- iv) Consistente.

8.26. Dada una muestra aleatoria de tamaño n de una población normal con media μ y varianza σ^2 :

i) Calcular el estimador máximo verosímil de $3\mu + 4\sigma^2$

ii) ¿Es este estimador insesgado?

8.27. Dadas dos poblaciones normales con medias μ_1 y μ_2 y varianzas σ_1^2 y σ_2^2 , se toman dos muestras de tamaños n_1 y n_2 respectivamente;

i) ¿Cuál es el estimador máximo verosímil de $\mu_1 - \mu_2$?

ii) Suponiendo que $n_1 + n_2 = 90$, $\sigma_1^2 = 1$ y $\sigma_2^2 = 4$, calcular los tamaños de las muestras n_1 y n_2 para que la varianza del estimador sea mínima.

8.28. Supongamos que existen tres candidatos para un puesto público. Designemos por p_1 , p_2 y p_3 la proporción de votantes que son favorables a los candidatos A, B y C respectivamente. Al elegir una persona para preguntarle por cuál candidato votará, sean x , y , z , variables aleatorias que representan el resultado: Si la persona es favorable a A, $x = 1$, $y = 0$; $z = 0$; si es favorable a B, $x = 0$, $y = 1$, $z = 0$; y si favorece a C, $x = 0$, $y = 0$, $z = 1$. Si la persona no opina $x = 0$, $y = 0$, $z = 0$. Estas variables tienen función de densidad conjunta.

$$f(x, y, z) = p_1^x p_2^y p_3^z (1 - p_1 - p_2 - p_3)^{1-x-y-z}$$

$$\text{para } x, y, z = 0, 1$$

i) Tomando una muestra de n personas, ¿Cuáles son los estimadores máximo verosímiles de p_1 , p_2 y p_3 ?

ii) Si $n = 200$ y el número de votantes favorables a A, B, C fueron 70, 60 y 50 respectivamente, ¿Cuánto valen las proporciones estimadas?

8.29. Determine razonadamente la veracidad o falsedad de las siguientes afirmaciones:

- a) Si un estimador es una función del parámetro con una sola inversa, se dice que tiene la propiedad de la invarianza.
- b) Un estimador máximo verosímil maximiza la probabilidad de que el parámetro esté en un intervalo arbitrariamente pequeño del estimador.
- c) El error cuadrático medio de un estimador es una variable aleatoria.

8.30. Determine razonadamente cuál de las respuestas es correcta en:

El sesgo de un estimador es:

- (a) una constante; (b) una variable aleatoria; (c) ninguna de las anteriores.

Si $\hat{\theta}_1$ es un estimador insesgado de mínima varianza de θ y su riesgo es mayor que el riesgo de $\hat{\theta}_2$, se puede afirmar que:

- a) $\hat{\theta}_2$ es insesgado.
- b) $\hat{\theta}_2$ es sesgado.
- c) No puede saberse.
- d) El riesgo de $\hat{\theta}_1$ no puede ser mayor que el de $\hat{\theta}_2$.
- e) Ninguna de las anteriores.

Para que un estimador insesgado sea consistente, su varianza debe tender a:

- a) El límite dado por la desigualdad Cramer-Rao.
- b) Cero.
- d) Ambas respuestas son correctas.
- e) Ninguna de las anteriores.

CAPITULO IX

ESTIMACION POR INTERVALOS

9.1. INTRODUCCION

En el capítulo anterior se trató de la estimación puntual de los parámetros, y se mencionó la posibilidad de obtener estimaciones por intervalos.

La idea subyacente en la estimación por intervalos es complementar la estimación por puntos, de forma de tener alguna idea acerca de la precisión de los estimadores puntuales usados.

Como se vio anteriormente, un buen estimador puntual es aquel cuyo valor está cercano al valor del parámetro que se desea estimar. No se debe olvidar que los estimadores son estadísticos muestrales, y en consecuencia son variables aleatorias.

Al tomar una muestra de una población, el valor del estimador obtenido a través de esa muestra, o sea, el valor estimado del parámetro, es un número; pero la muestra concreta que se ha obtenido, es una de las muchas posibles muestras que se podrían haber obtenido. Si se hubiera obtenido otra muestra, el valor estimado hubiera sido posiblemente diferente; en consecuencia, no podemos ser tan optimistas como para pensar que el valor estimado a partir de una determinada muestra, es exactamente igual al valor real del parámetro de la población.

Lo anterior es razón suficiente para considerar que se necesita una cierta medida del posible error, que se comete al usar un estimador puntual del parámetro.

Si queremos estimar, por ejemplo, la media de una población mediante una muestra de tamaño "n", podemos obtener muchos diferentes valores de la media muestral, la mayoría de los cuales no son exactamente iguales a la media de la población. Es deseable entonces calcular algún intervalo alrededor del valor del estimador, acompañado de alguna medida que nos diga la confianza que se puede tener de que ese intervalo contenga el verdadero valor del parámetro.

DEFINICION 9.1.

Dada una muestra aleatoria $x_1, x_2, \dots, x_n$ de tamaño n de una población con función de densidad $f(x)$, un intervalo de confianza del 100 $(1 - \alpha)$ % para el parámetro desconocido θ , es un intervalo determinado por dos números $\hat{\theta} - \delta_1, \hat{\theta} + \delta_2$, calculado con base en los datos de la muestra, tales que, la probabilidad de que el intervalo contenga el verdadero valor del parámetro es igual a $1 - \alpha$.

$$P[\hat{\theta} - \delta_1 \leq \theta \leq \hat{\theta} + \delta_2] = 1 - \alpha$$

El valor 100 $(1 - \alpha)$ % se conoce como coeficiente de confianza. Se puede observar que los límites del intervalo son variables aleatorias, pues son funciones del estimador $\hat{\theta}$, y varían de una muestra a otra.

EJEMPLO 9.1.

Supongamos que la demanda diaria de un cierto bien es una variable aleatoria que se puede considerar aproximadamente como normal, con media μ desconocida y varianza 16. Para estimar la demanda media se toma una muestra de 25 días y se quiere obtener un intervalo de confianza del 95%.

Siendo la población (demanda diaria) distribuida normalmente, sabemos que $\bar{x} \sim N(\mu, \sigma^2/n)$.

$$y = (\bar{x} - \mu) \frac{\sqrt{n}}{\sigma} \sim N(0, 1)$$

La probabilidad de que y esté entre $-k_{\alpha/2}$ y $k_{\alpha/2}$, es $1 - \alpha$ luego:

$$P\left(-k_{0,025} \leq \frac{(\bar{x} - \mu)\sqrt{n}}{\sigma} \leq k_{0,025}\right) = 0,95$$

$$\Rightarrow P\left(-1,96 \leq \frac{(\bar{x} - \mu) 5}{4} \leq 1,96\right) = 0,95$$

$$\Rightarrow P(\bar{x} - 1,568 \leq \mu \leq \bar{x} + 1,568) = 0,95$$

Los límites del intervalo son $\bar{x} - 1,568$ y $\bar{x} + 1,568$, y la probabilidad de que el intervalo determinado por estos límites contenga el parámetro μ es 0,95.

Supongamos ahora que calculamos la media muestral, y ésta dio $\bar{x} = 25$. Los límites del intervalo para esta particular muestra son (23,432; 26,568). Entonces se puede afirmar que la demanda media diaria μ está entre 23,432 y 26,568; y esta afirmación se hace con un 95% de confianza.

Observen que en la última expresión no se habla de 95% de probabilidad sino de confianza. En efecto, una vez tomada la muestra, y calculados los límites del intervalo, no tiene sentido decir que la probabilidad de que μ esté entre 23,432 y 26,568 es 0,95; μ no es una variable aleatoria, y la probabilidad de que μ esté entre 23,432 y 26,568 es uno, o es cero, dependiendo de si está o no está entre esos dos números; por eso se habla de que μ está entre 23,432 y 26,568 con un 95% de confianza. La distinción puede parecer sutil, pero la razón es ésta: "Antes" de tomar la muestra, los límites del intervalo $\bar{x} \pm 1,568$ son variables aleatorias, y han sido determinados de tal forma que la probabilidad de que el intervalo contenga al parámetro es 0,95; "después" de tomada la muestra, y calculados los límites, hablamos de confianza, y no de probabilidad.

La interpretación dada al concepto de "confianza" es la siguiente. Si se toman repetidamente muestras de 25 elementos de la población dada en el ejemplo 9.1 y se calculan los intervalos $\bar{x} \pm 1,568$ para cada muestra, el 95% en promedio de los intervalos calculados contienen el verdadero valor del parámetro, mientras que el 5% no lo contienen; por eso, cuando tenemos un intervalo concreto tal como el del ejemplo, no sabemos si contiene o no el verdadero valor de μ ; sin embargo, como el 95% de los intervalos calculados en esa forma contienen μ , estamos 95% confiados de que el intervalo contiene el verdadero valor de μ .

Las figuras 9.1 y 9.2 representan gráficamente el razonamiento anterior.

FIGURA 9.1.





FIGURA 9.2.



En la figura 9.1. los puntos representan valores de medias muestrales ($\bar{x}$) para cada una de varias muestras. Sabemos que:

$$P\left(\mu - k_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \bar{x} \leq \mu + k_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

En el ejemplo, la probabilidad de que ($\bar{x}$) esté entre $\mu - 1,568$ y $\mu + 1,568$ es 0,95; o sea, se puede esperar que el 95% de las medias muestrales esté entre $\mu \mp k_{0,025} \frac{\sigma}{\sqrt{n}}$.

En el gráfico, 8 de las 11 medias muestrales está entre esos límites.

En el gráfico 9.2 se han construido los intervalos alrededor de la media muestral $\bar{x} \pm k_{\alpha/2} \frac{\sigma}{\sqrt{n}}$, $\bar{x} \pm 1,568$. Se puede observar que en aquellas medias muestrales que están entre $\mu \pm 1,568$, los intervalos de confianza construidos contienen el verdadero valor de μ ; no así los otros, por lo cual se puede afirmar que el 95% de los intervalos contienen μ y un intervalo en particular contiene el valor μ con un 95% de confianza.

Es evidente que en la práctica se pueden construir intervalos de confianza con coeficientes de confianza distintos de 95%, ya sea con confianza del 90%, 98%, 93%, etc.; es decir, con cualquier grado razonable de confianza excepto 100%. Un intervalo de confianza de 100% sería $(-\infty, +\infty)$, lo cual no tendría ninguna utilidad en la práctica.

EJEMPLO 9.2.

Construir un intervalo de confianza del 98% con los datos del ejemplo 9.1.

$$1 - \alpha = 0,98 \quad \alpha = 0,02 \quad \alpha/2 = 0,01$$

$$P\left(-k_{0,01} \leq \frac{(\bar{x} - \mu) 5}{4} \leq k_{0,01}\right) = 0,98$$

$$P\left(-2,326 \leq \frac{(\bar{x} - \mu) 5}{4} \leq 2,326\right) = 0,98$$

$$P\left(\bar{x} - 2,326 \frac{4}{5} \leq \mu \leq \bar{x} + 2,326 \frac{4}{5}\right) = 0,98$$

$$P(\bar{x} - 1,8608 \leq \mu \leq \bar{x} + 1,8608) = 0,98$$

Si $\bar{x} = 25$, un intervalo de confianza del 98% para μ será (23,1392; 26,8608). Se puede observar que este intervalo de confianza es más amplio que el del 95%; es lógico que cuanto mayor confianza queremos tener en que el parámetro esté entre los límites del intervalo, éste tiene que ser más amplio y por lo tanto menos preciso. Dado un tamaño de muestra, la alternativa está entre confianza y precisión, a mayor precisión menor confianza y viceversa.

Por otro lado, se debe notar que el tamaño de la muestra influye en la amplitud del intervalo, dado un coeficiente de confianza; "n" aparece como divisor en los límites del

intervalo, de forma que cuanto mayor sea el tamaño de la muestra, los intervalos con el mismo coeficiente de confianza serán de menor amplitud, es decir, más precisos.

Hay que notar que un intervalo con un coeficiente de confianza de $100(1-\alpha)\%$ no es único; cualesquiera dos límites tales que $P(a \leq \mu \leq b) = 1-\alpha$, siendo a y b funciones de los valores muestrales, constituyen un intervalo de confianza del $100(1-\alpha)\%$. Por ejemplo, en el caso anterior:

$$P\left(-1,65 \leq \frac{(\bar{x} - \mu)\sqrt{n}}{\sigma} \leq 3,32\right) = 0,95$$

$$\Rightarrow P\left(\bar{x} - 3,32 \frac{4}{5} \leq \mu \leq \bar{x} + 1,65 \frac{4}{5}\right) = 0,95$$

Para $\bar{x} = 25$, el intervalo será $(22,34; 26,32)$; también,

$$P\left(-1,70 \leq \frac{(\bar{x} - \mu)\sqrt{n}}{\sigma} \leq 2,55\right) = 0,95$$

$$\Rightarrow P\left(\bar{x} - 2,55 \frac{4}{5} \leq \mu \leq \bar{x} + 1,70 \frac{4}{5}\right) = 0,95$$


Para $\bar{x} = 25$, el intervalo será $(22,96; 26,36)$.

Sin embargo, se ve que los dos intervalos anteriores tienen una mayor amplitud que el intervalo hallado en el ejemplo 9.1. La amplitud del intervalo $(23,432; 26,568)$ es 3,136; en los dos últimos intervalos es 3,976 y 3,40 respectivamente. Esto quiere decir que con el mismo tamaño de muestra y el mismo coeficiente de confianza, el primer intervalo es más preciso que los otros.

En general, se puede afirmar que un intervalo, con un determinado coeficiente de confianza y un determinado tamaño de la muestra, construido de la forma del ejemplo 9.1, es decir simétrico alrededor del estimador, es más preciso que cualquier intervalo.

En la figura 9.3. se puede observar por qué esto es así:

FIGURA 9.3.



Sean y_0, y_1 dos números tales que $P\left(y_0 \leq \frac{(\bar{x} - \mu)\sqrt{n}}{\sigma} \leq y_1\right) = 1-\alpha$; el intervalo

de confianza para μ determinado por esos números será $(\bar{x} - y_1 \sigma/\sqrt{n}; \bar{x} - y_0 \sigma/\sqrt{n})$, su amplitud es $(y_1 - y_0) \sigma/\sqrt{n}$.

Esta amplitud será mínima cuando $y_1 = k_{\alpha/2}$ e $y_0 = -k_{\alpha/2}$.

En efecto, si se mueve y_1 hacia la derecha hasta y_1' , para mantener la misma área $(1-\alpha)$, y_0 debe moverse también hacia la derecha, pero una mayor distancia, digamos hasta y_0' , puesto que $f(y_1) > f(y_0)$. El intervalo determinado por y_0' e y_1' será de menor amplitud que el anterior: $y_0 y_1 > y_0' y_1'$. La amplitud del intervalo irá disminuyendo hasta que $f(y_1) = f(y_0)$; o sea, en los puntos y_0' e y_1' . A partir de esos puntos, si se sigue moviendo hacia la derecha y_1 para mantener la misma área, y_0 deberá moverse hacia la derecha una menor distancia; es decir, el intervalo empezará a tener mayor amplitud. Luego, la distancia mínima entre los límites se logra cuando $f(y_1) = f(y_0)$; y esto sucede cuando $y_0 = -y_1$; o sea, cuando $y_1 = k_{\alpha/2}$, por razón de que la curva $f(y)$ es simétrica alrededor de cero.

9.2. INTERVALOS DE CONFIANZA PARA LA MEDIA DE UNA POBLACION

9.2.1. POBLACIONES CON VARIANZA CONOCIDA

Se sabe que la media muestral de una muestra aleatoria es una variable que obedece exacta o aproximadamente a la distribución normal. Exactamente si la población es normal; si la población no es normal tiende a ser normal por aplicación del Teorema del Límite Central; es decir que a partir de una población con media μ y varianza σ^2 , se tiene,

$$\bar{x} \sim N\left(\mu, \frac{\sigma^2}{n}\right) \Rightarrow y = \frac{(\bar{x} - \mu)\sqrt{n}}{\sigma} \sim N(0, 1)$$

o sea,

$$P\left(-k_{\alpha/2} \leq \frac{(\bar{x} - \mu)\sqrt{n}}{\sigma} \leq k_{\alpha/2}\right) = 1 - \alpha \Rightarrow P\left(\bar{x} - k_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{x} + k_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

Un intervalo con un coeficiente de confianza de 100 (1 - α) % para la media de una población con varianza conocida será,

$$\bar{x} \pm k_{\alpha/2} \frac{\sigma}{\sqrt{n}}$$

EJEMPLO 9.3.

Encontrar un intervalo de confianza del 80% para la media de una población normal, sabiendo que $\sigma^2 = 4$, a partir de una muestra de 8 elementos que dio los siguientes resultados: 9, 14, 10, 12, 7, 13, 11 y 12.

$$\bar{x} = \frac{\sum x_i}{n} = 11 \quad k_{0,10} = 1,28$$

$$11 \pm 1,28 \frac{2}{\sqrt{8}} = 11 \pm 0,9065$$

$$(10,0935 ; 11,9065)$$

9.2.2. POBLACIONES CON VARIANZA DESCONOCIDA

En la mayoría de los casos prácticos se desconoce no sólo la media μ de la población, sino también la varianza σ^2 . En estos casos no se puede usar el intervalo obtenido en el caso anterior porque se desconoce el valor de σ^2 . En la sección 7.5.4. se vio que

$$t = \frac{(\bar{x} - \mu)\sqrt{n-1}}{s}$$

es una variable "t" de student, con $n - 1$ grados de libertad, luego :

$$P\left(-t_{\alpha/2} \leq \frac{(\bar{x} - \mu)\sqrt{n-1}}{s} \leq t_{\alpha/2}\right) = 1 - \alpha$$

$$P\left(\bar{x} - t_{\alpha/2} \frac{s}{\sqrt{n-1}} \leq \mu \leq \bar{x} + t_{\alpha/2} \frac{s}{\sqrt{n-1}}\right) = 1 - \alpha$$

Luego, un intervalo de confianza de 100 (1 - α) % para la media de una distribución con varianza desconocida es

$$\bar{x} \pm t_{\alpha/2} \frac{s}{\sqrt{n-1}}$$

EJEMPLO 9.4.

Encontrar un intervalo de confianza del 80% para la media de la población normal del ejemplo 9.3 siendo σ^2 desconocida.

$$\bar{x} = 11 \quad s^2 = \frac{\sum (x_i - \bar{x})^2}{n} = \frac{\sum x_i^2}{n} - \bar{x}^2 = \frac{1.004}{8} - 11^2 = 4,5$$

$$t_{0,10}(7) = 1,415$$

$$11 \pm 1,415 \frac{\sqrt{4,5}}{\sqrt{7}} = 11 \pm 1,1345$$

$$(9,865 ; 12,134)$$

Las tablas, usualmente disponibles, de la "t" de Student tienen hasta 30 grados de libertad, entonces cuando $n > 31$ no conocemos $t_{\alpha/2}$. Sin embargo, sabemos que para muestras grandes la distribución "t" tiende a la distribución normal, de forma tal que para muestras grandes, no conociendo la varianza de la población, $\frac{(\bar{x} - \mu)\sqrt{n-1}}{s}$ se dis-

tribuye aproximadamente como normal; luego un intervalo de confianza de 100 (1 - α) % es aproximadamente:

$$\bar{x} \pm k_{\alpha/2} \frac{s}{\sqrt{n-1}}$$

En otras palabras, para $n > 31$ en el intervalo se sustituye $t_{\alpha/2}$ por $k_{\alpha/2}$.

EJEMPLO 9.5.

Para estimar la media de una población normal se tomó una muestra de 65 elementos con los siguientes resultados $\bar{x} = 30$; $s^2 = 9$. Calcular un intervalo de confianza del 99% para μ .

$$\bar{x} = 30 \quad ; \quad s = 3 \quad n = 65 \quad k_{0,005} = 2,57$$

$$30 \pm 2,57 \frac{3}{\sqrt{64}} = 30 \pm 0,963$$

$$(29,037 \quad ; \quad 30,963)$$

EJEMPLO 9.6.

El diámetro de los tubos producidos por una máquina es una variable aleatoria con media μ y varianza σ^2 . Calcular un intervalo de confianza del 90% para μ , e interpretar el resultado, si:

- i) En una muestra aleatoria de 25 elementos $\bar{x} = 25$ mm, suponiendo $\sigma^2 = 2,1$.
- ii) σ^2 es desconocida y la varianza muestral es 2.
- iii) En una muestra de 101 elementos la media muestral resultó 25 mm y la varianza muestral 2.

$$i) \quad n = 25 \quad \bar{x} = 25 \quad \sigma^2 = 2,1 \quad k_{0,05} = 1,645$$

$$25 \pm 1,645 \frac{\sqrt{2,1}}{5} = 25 \pm 0,4767$$

$$(24,5233 \quad ; \quad 25,4767)$$

El diámetro de los tubos producidos por esa máquina tiene una longitud media que está entre 24,5233 milímetros y 25,4756 milímetros con una confianza del 90%.

$$ii) \quad n = 25 \quad \bar{x} = 25 \quad s^2 = 2 \quad t_{0,05} = 1,711$$

$$25 \pm 1,711 \frac{\sqrt{2}}{\sqrt{24}} = 25 \pm 0,4938$$

$$(24,5062 \quad ; \quad 25,4938)$$

$$iii) \quad n = 101 \quad \bar{x} = 25 \quad s^2 = 2 \quad k_{0,05} = 1,645$$

$$25 \pm 1,645 \frac{\sqrt{2}}{10} = 25 \pm 0,2326$$

$$(24,7674 \quad ; \quad 25,2326)$$

9.2.3. POBLACIONES FINITAS CON VARIANZA CONOCIDA

En los casos anteriores se ha trabajado con muestras aleatorias; o sea, que las variables que las componen son independientes. Este hecho se basa en el supuesto (sección 7.2) de que las poblaciones estudiadas eran infinitas, o que equivalentemente el muestreo en poblaciones finitas se hacía con reemplazamiento.

En el caso de poblaciones finitas y muestreo sin reemplazamiento, si bien los elementos de la población tienen también idéntica probabilidad de ser elegidos en la muestra, las variables que componen la muestra no siguen siendo independientes; al elegir el primer elemento de la muestra, la población queda modificada, y la probabilidad de elegir el segundo elemento no es la misma que la anterior.

EJEMPLO 9.7.

Supongamos que se quiere estimar el peso promedio de los sacos de harina envasados en un día según un determinado mecanismo. La producción del día fue de veinte sacos, y se va a usar una muestra de cuatro. Numeremos los sacos del 1 al 20; al tomar el primer saco para comprobar su peso, la probabilidad de escoger el saco i , ($i = 1, 2, \dots, 20$), es $1/20$; una vez elegido el primer saco, supongamos que fue el número dos, la probabilidad de obtener otro saco (digamos el 4) como segundo elemento de la muestra es $1/19$ y así sucesivamente.

El hecho de que las variables aleatorias de la muestra no sean independientes, implicaría que no puede aplicarse el Teorema del Límite Central para afirmar que $\bar{x}$ tiende a distribuirse normalmente; afortunadamente bajo ciertas condiciones¹⁶, generalmente dadas en la práctica, la aproximación por la normal es válida.

¹⁶ William C. Cochran, "Sampling Techniques". John Wiley e Sons. Ed. pp. 38.

Por otro lado, cuando las muestras se obtienen sin reemplazamiento, el número total de diferentes muestras (y en consecuencia de diferentes valores de la media muestral) que se pueden obtener, es distinto que cuando el muestreo es con reemplazamiento. En el caso "con reemplazamiento", las posibles muestras son $V'_{N,n} = N^n$, siendo N el número de elementos de la población, y n el número de elementos de la muestra; si el muestreo es sin reemplazamiento es $V_{N,n} = N(N-1) \dots (N-n+1)$; o sea, menor número de muestras.

EJEMPLO 9.8.

Si en el ejemplo 9.7. el muestreo es con reemplazamiento el número de muestras diferentes sería $V'_{20,4} = 20^4 = 160.000$; tales como:

(1, 1, 1, 1); (1, 1, 1, 2); (1, 1, 1, 3) (20, 20, 20, 20)

donde los números indican el saco escogido; es decir, (1, 1, 1, 1) indica que el saco escogido en cada elemento de la muestra fue el número uno.

Si el muestreo se realiza sin reemplazamiento, las posibles muestras son:

(1, 2, 3, 4), (1, 2, 3, 5) (17, 18, 19, 20), (20, 19, 18, 17) y su número es, $V_{20,4} = 116.280$

El efecto práctico de este hecho es que la varianza de la media muestral se modifica y se convierte en:

$$\text{Var}(\bar{x}) = \frac{\sigma^2}{n} \frac{N-n}{N-1}^{17}$$

o sea, que la varianza de la media muestral es menor que en el caso de muestreo con reemplazamiento, puesto que $(N-n) < (N-1)$. La razón conceptual de que sea menor la varianza de la media muestral en el caso de muestreo sin reemplazamiento es que se eliminan los valores de la media muestral correspondientes a muestras con valores extremos.

Supongan que el peso de los sacos de harina del ejemplo 9.7 es diferente para cada saco y va de un mínimo de 47 kg. a un máximo de 53 kg. En un muestreo de cuatro sacos sin reemplazamiento no se pueden obtener muestras como (47, 47, 47, 47) o (47, 47, 47, 48) o (53, 53, 53, 53), con lo cual se están eliminando valores extremos de la media muestral y, en consecuencia, $\text{Var}(\bar{x})$, que precisamente mide la dispersión de los valores de la media muestral, debe ser menor.

¹⁷ Para una prueba ver Harold Freeman, "Introducción a la Inferencia Estadística", Ed. Trillas, México, pp. 187 y sig.

Obsérvese que a medida que aumenta N , $\text{Var}(\bar{x})$ tiende a σ^2/n . El factor $(N-n)/(N-1)$ se conoce como factor de corrección para poblaciones finitas. En general, en el muestreo sin reemplazamiento en poblaciones finitas, el factor de corrección afecta a la varianza del estadístico muestral que se usa como estimador.

Los intervalos de confianza para $\bar{x}$ serán los mismos de la sección 9.2.1. con la diferencia de $\sigma_{\bar{x}}$.

Un intervalo de confianza del 100 $(1 - \alpha)$ % será

$$\bar{x} \pm k_{\alpha/2} \frac{\sigma}{\sqrt{n}} \sqrt{\frac{N-n}{N-1}}$$

EJEMPLO 9.9.

Calcular un intervalo de confianza del 95% para el peso medio de los sacos de harina del ejemplo 9.7, suponiendo que $\sigma^2 = 4$, y $\bar{x} = 50$

$\bar{x} = 50$; $\sigma = 2$; $n = 4$; $N = 20$; $k_{0,025} = 1,96$

$$50 \pm 1,96 \frac{2}{2} \sqrt{\frac{20-4}{20-1}} = 50 \pm 1,6507$$

(48,3493; 51,6507)

El peso medio de los sacos está entre 48,3493 kgs. y 51,6507 kgs. con una confianza del 95%.

9.2.4. POBLACIONES FINITAS CON VARIANZA DESCONOCIDA

Cuando la varianza es desconocida, se usa la "t" de Student para calcular los intervalos. Estos serán iguales a los de la sección 9.2.2. con la diferencia de $\sigma_{\bar{x}}$.

Un intervalo de confianza del 100 $(1 - \alpha)$ % será

si $n \leq 31$,

$$\bar{x} \pm t_{\alpha/2} \frac{s}{\sqrt{n-1}} \sqrt{\frac{N-n}{N-1}}$$

si $n > 31$,

$$\bar{x} \pm k_{\alpha/2} \frac{s}{\sqrt{n-1}} \sqrt{\frac{N-n}{N-1}}$$

Por otro lado, cuando las muestras se obtienen sin reemplazamiento, el número total de diferentes muestras (y en consecuencia de diferentes valores de la media muestral) que se pueden obtener, es distinto que cuando el muestreo es con reemplazamiento. En el caso "con reemplazamiento", las posibles muestras son $V_{N,n} = N^n$, siendo N el número de elementos de la población, y n el número de elementos de la muestra; si el muestreo es sin reemplazamiento es $V_{N,n} = N(N-1) \dots (N-n+1)$; o sea, menor número de muestras.

EJEMPLO 9.8.

Si en el ejemplo 9.7. el muestreo es con reemplazamiento el número de muestras diferentes sería $V_{20,4} = 20^4 = 160.000$; tales como:

(1, 1, 1, 1); (1, 1, 1, 2); (1, 1, 1, 3), (20, 20, 20, 20)

donde los números indican el saco escogido; es decir, (1, 1, 1, 1) indica que el saco escogido en cada elemento de la muestra fue el número uno.

Si el muestreo se realiza sin reemplazamiento, las posibles muestras son:

(1, 2, 3, 4), (1, 2, 3, 5) (17, 18, 19, 20), (20, 19, 18, 17) y su número es, $V_{20,4} = 116.280$

El efecto práctico de este hecho es que la varianza de la media muestral se modifica y se convierte en:

$$\text{Var}(\bar{x}) = \frac{\sigma^2}{n} \frac{N-n}{N-1} \quad 17$$

o sea, que la varianza de la media muestral es menor que en el caso de muestreo con reemplazamiento, puesto que $(N-n) < (N-1)$. La razón conceptual de que sea menor la varianza de la media muestral en el caso de muestreo sin reemplazamiento es que se eliminan los valores de la media muestral correspondientes a muestras con valores extremos.

Supongan que el peso de los sacos de harina del ejemplo 9.7 es diferente para cada saco y va de un mínimo de 47 kg. a un máximo de 53 kg. En un muestreo de cuatro sacos sin reemplazamiento no se pueden obtener muestras como (47, 47, 47, 47) o (47, 47, 47, 48) o (53, 53, 53, 53), con lo cual se están eliminando valores extremos de la media muestral y, en consecuencia, $\text{Var}(\bar{x})$, que precisamente mide la dispersión de los valores de la media muestral, debe ser menor.

¹⁷ Para una prueba ver Harold Freeman, "Introducción a la Inferencia Estadística", Ed. Trillas, México, pp. 187 y sig.

Obsérvese que a medida que aumenta N , $\text{Var}(\bar{x})$ tiende a σ^2/n . El factor $(N-n)/(N-1)$ se conoce como factor de corrección para poblaciones finitas. En general, en el muestreo sin reemplazamiento en poblaciones finitas, el factor de corrección afecta a la varianza del estadístico muestral que se usa como estimador.

Los intervalos de confianza para $\bar{x}$ serán los mismos de la sección 9.2.1. con la diferencia de $\sigma_{\bar{x}}$.

Un intervalo de confianza del 100(1 - α) % será

$$\bar{x} \pm k_{\alpha/2} \frac{\sigma}{\sqrt{n}} \sqrt{\frac{N-n}{N-1}}$$

EJEMPLO 9.9.

Calcular un intervalo de confianza del 95% para el peso medio de los sacos de harina del ejemplo 9.7, suponiendo que $\sigma^2 = 4$, y $\bar{x} = 50$

$\bar{x} = 50$; $\sigma = 2$; $n = 4$; $N = 20$; $k_{0,025} = 1,96$

$$50 \pm 1,96 \frac{2}{\sqrt{4}} \sqrt{\frac{20-4}{20-1}} = 50 \pm 1,6507$$

(48,3493; 51,6507)

El peso medio de los sacos está entre 48,3493 kgs. y 51,6507 kgs. con una confianza del 95%.

9.2.4. POBLACIONES FINITAS CON VARIANZA DESCONOCIDA

Cuando la varianza es desconocida, se usa la "t" de Student para calcular los intervalos. Estos serán iguales a los de la sección 9.2.2. con la diferencia de $\sigma_{\bar{x}}$.

Un intervalo de confianza del 100(1 - α) % será

si $n \leq 31$,

$$\bar{x} \pm t_{\alpha/2} \frac{s}{\sqrt{n-1}} \sqrt{\frac{N-n}{N-1}}$$

si $n > 31$,

$$\bar{x} \pm k_{\alpha/2} \frac{s}{\sqrt{n-1}} \sqrt{\frac{N-n}{N-1}}$$

Se deja al lector contestar la siguiente interrogante: Si la variable t de Student original es $t = \frac{(\bar{x} - \mu) \sqrt{n-1}}{s}$, en la cual aparentemente no interviene la varianza de la media muestral σ^2/n . ¿Por qué aparece el factor de corrección para poblaciones finitas en la t de Student que sirvió para calcular este intervalo?

EJEMPLO 9.10.

En el ejemplo 9.9. calcular un intervalo de confianza del 95% para μ , si $\bar{x} = 50$ y $s^2 = 4,41$

$$\bar{x} = 50; \quad s = 2,1; \quad t_{\alpha/2}(3) = 3,182; \quad N = 20; \quad n = 4$$

$$50 \pm 3,182 \frac{2,1}{\sqrt{3}} \sqrt{\frac{20-4}{20-1}} = 50 \pm 3,5404$$

$$(46,4596; 53,5404)$$

EJEMPLO 9.11.

Se trata de estimar el tiempo medio que 1000 lámparas fluorescentes producidas por una cierta empresa, se mantienen encendidas antes de echarse a perder. Para ello se toma una muestra de 101 y se dejan encendidas hasta que se apagan. El resultado de la muestra dio una duración media de 1500 horas con una desviación típica de 120 horas. Calcular un intervalo de confianza del 98% para la verdadera duración media.

$$\bar{x} = 1500; \quad s = 120; \quad N = 1000; \quad n = 101; \quad k_{0,01} = 2,326$$

$$1500 \pm 2,326 \frac{120}{\sqrt{100}} \sqrt{\frac{899}{999}} = 1500 \pm 26,4773$$

$$(1473,52; 1526,48)$$

La duración promedio de las lámparas producidas por esa empresa está entre 1473,52 horas y 1526,48 horas con una confianza del 98%.

9.2.5. DETERMINACION DEL TAMAÑO DE LA MUESTRA

Dado el coeficiente de confianza deseado para un intervalo, se puede determinar el tamaño (n) de la muestra necesario para tener un determinado grado de precisión en la estimación por intervalos.

Por ejemplo, en el caso de σ^2 conocida sabemos que la amplitud del intervalo es $2k_{\alpha/2} \sigma / \sqrt{n}$, en otras palabras, tenemos un $100(1-\alpha)\%$ de confianza que la media de la población está entre $\bar{x} - k_{\alpha/2} \sigma / \sqrt{n}$ y $\bar{x} + k_{\alpha/2} \sigma / \sqrt{n}$. La amplitud del intervalo depende del tamaño de la muestra, y en otro sentido se puede decir que el tamaño de la muestra está en función de la amplitud deseada del intervalo.

Si se quiere que la amplitud del intervalo sea h con una confianza del $100(1-\alpha)\%$, se debe buscar un valor de n tal que:

$$h = 2k_{\alpha/2} \sigma / \sqrt{n} \Rightarrow n = \left[\frac{2k_{\alpha/2} \sigma}{h} \right]^2$$

EJEMPLO 9.12.

Dada una población normal con media μ desconocida y con varianza $\sigma^2 = 9$, calcular el tamaño de muestra necesario para que un intervalo de confianza del 95% tenga una amplitud de 2 unidades,

$$n = \left(\frac{2 \times 1,96 \times 3}{2} \right)^2 = 34,57 \approx 35$$

En efecto, un intervalo de confianza para μ con $n = 35$ será:

$$\bar{x} \pm 1,96 \frac{3}{\sqrt{35}}$$

$$\text{y su amplitud } 2 \times 1,96 \frac{3}{\sqrt{35}} = 1,99 \approx 2$$

o sea, una muestra de 35 elementos será suficiente para obtener el grado de precisión deseado.

Desafortunadamente este cálculo del tamaño de la muestra es sólo posible, si se conoce el valor de la varianza poblacional σ^2 . En los casos en que σ^2 no se conozca puede ser útil una estimación de σ^2 , ya sea de previos estudios si se confía en que la varianza no ha cambiado, o un estimado calculado a partir de una pequeña muestra.

9.3. INTERVALOS DE CONFIANZA PARA LA PROPORCION DE UNA POBLACION

9.3.1. MUESTREO CON REEMPLAZAMIENTO

Para calcular intervalos de confianza para la proporción de elementos (p) que en una población tienen determinada característica, se usa el hecho de que la proporción

muestral ($\hat{p}$) para muestras grandes, es aproximadamente normalmente distribuida con parámetros p y $\frac{pq}{n}$ (Ver sección 7.5.5).

Entonces, si se quiere construir un intervalo de confianza del $100(1 - \alpha) \%$ para p , se tiene

$$P\left(-k_{\alpha/2} \leq \frac{(\hat{p} - p)\sqrt{n}}{\sqrt{p(1-p)}} \leq k_{\alpha/2}\right) = 1 - \alpha \quad (1)$$

El despeje de p en esta expresión para llegar a un intervalo es complejo y se puede omitir. En efecto:

$$* \Rightarrow P\left(\frac{|\hat{p} - p|\sqrt{n}}{\sqrt{p(1-p)}} \leq k_{\alpha/2}\right) = 1 - \alpha$$

La desigualdad $\frac{|\hat{p} - p|\sqrt{n}}{\sqrt{p(1-p)}} \leq k_{\alpha/2}$ equivale a:

$$\frac{(\hat{p} - p)^2 n}{p(1-p)} \leq (k_{\alpha/2})^2 \Rightarrow \quad (2)$$

$$\Rightarrow (\hat{p}^2 - 2\hat{p}p + p^2) n \leq (k_{\alpha/2})^2 p(1-p)$$

$$\Rightarrow (\hat{p}^2 - 2\hat{p}p + p^2) n - (k_{\alpha/2})^2 p(1-p) \leq 0$$

$$\Rightarrow n\hat{p}^2 - 2n\hat{p}p + np^2 - (k_{\alpha/2})^2 p + (k_{\alpha/2})^2 p^2 \leq 0$$

$$\Rightarrow p^2 \left[n + (k_{\alpha/2})^2 \right] - p \left[2n\hat{p} + (k_{\alpha/2})^2 \right] + n\hat{p}^2 \leq 0 \quad (3)$$

Si se cumple (3) se cumple (2), y en consecuencia se cumple (1), el primer miembro de (3) es una expresión menor o igual que cero. Si hallamos los valores de " p ", para los cuales es igual a cero (2 valores, puesto que es una ecuación de segundo grado), será menor que cero para los valores de p que estén entre las dos raíces. Luego,

$$p^2 \left[n + (k_{\alpha/2})^2 \right] - p \left[2n\hat{p} + (k_{\alpha/2})^2 \right] + n\hat{p}^2 = 0$$

$$p = \frac{2n\hat{p} + (k_{\alpha/2})^2 \pm \sqrt{\left[2n\hat{p} + (k_{\alpha/2})^2 \right]^2 - 4 \left[n + (k_{\alpha/2})^2 \right] n\hat{p}^2}}{2 \left[n + (k_{\alpha/2})^2 \right]}$$

Las dos raíces serán

$$p_1 = \frac{2n\hat{p} + (k_{\alpha/2})^2 - \sqrt{\left[2n\hat{p} + (k_{\alpha/2})^2 \right]^2 - 4 \left[n + (k_{\alpha/2})^2 \right] n\hat{p}^2}}{2 \left[n + (k_{\alpha/2})^2 \right]} \quad (4)$$

$$p_2 = \frac{2n\hat{p} + (k_{\alpha/2})^2 + \sqrt{\left[2n\hat{p} + (k_{\alpha/2})^2 \right]^2 - 4 \left[n + (k_{\alpha/2})^2 \right] n\hat{p}^2}}{2 \left[n + (k_{\alpha/2})^2 \right]} \quad (5)$$

Operando y simplificando en (4) se obtiene:

$$p_1 = \frac{2n\hat{p} + (k_{\alpha/2})^2 - \sqrt{4n^2\hat{p}^2 + 4n\hat{p}(k_{\alpha/2})^2 + (k_{\alpha/2})^4 - 4n^2\hat{p}^2 - 4n\hat{p}^2(k_{\alpha/2})^2}}{2 \left[n + (k_{\alpha/2})^2 \right]} =$$

$$= \frac{2n\hat{p} + (k_{\alpha/2})^2 - \sqrt{4n\hat{p}(k_{\alpha/2})^2 [1 - \hat{p}] + (k_{\alpha/2})^4}}{2 \left[n + (k_{\alpha/2})^2 \right]} =$$

$$= \frac{2n\hat{p} + (k_{\alpha/2})^2 - \sqrt{(k_{\alpha/2})^2 \left[4n\hat{p}(1 - \hat{p}) + (k_{\alpha/2})^2 \right]}}{2 \left[n + (k_{\alpha/2})^2 \right]} =$$

$$= \frac{2n\hat{p} + (k_{\alpha/2})^2 - k_{\alpha/2} \sqrt{4n\hat{p}(1 - \hat{p}) + (k_{\alpha/2})^2}}{2 \left[n + (k_{\alpha/2})^2 \right]} =$$

Dividiendo numerador y denominador por $2n$, queda:

$$p_1 = \frac{\hat{p} + (k_{\alpha/2})^2 / 2n - (k_{\alpha/2}) \sqrt{\hat{p}(1-\hat{p})/n + (k_{\alpha/2})^2 / 4n^2}}{1 + (k_{\alpha/2})^2 / n} \quad (6)$$

Similarmente,

$$p_2 = \frac{\hat{p} + (k_{\alpha/2})^2 / 2n + (k_{\alpha/2}) \sqrt{\hat{p}(1-\hat{p})/n + (k_{\alpha/2})^2 / 4n^2}}{1 + (k_{\alpha/2})^2 / n} \quad (7)$$

De forma tal que p_1 y p_2 son los valores de "p" entre los cuales se cumple (3); o sea, se cumple (1)

$$P\left(-k_{\alpha/2} \leq \frac{(\hat{p} - p)\sqrt{n}}{\sqrt{p(1-p)}} \leq k_{\alpha/2}\right) = 1 - \alpha$$

$$\Rightarrow P(p_1 \leq p \leq p_2) = 1 - \alpha$$

Luego, p_1 , p_2 son los límites del intervalo de confianza del $100(1 - \alpha)\%$ para "p".*

En la práctica, siendo n grande (éste es nuestro caso), los términos que contienen $(k_{\alpha/2}/n)$ se desprecian, quedando

$$p_1 = \hat{p} - k_{\alpha/2} \sqrt{\hat{p}(1-\hat{p})/n}$$

$$p_2 = \hat{p} + k_{\alpha/2} \sqrt{\hat{p}(1-\hat{p})/n}$$

O sea, los límites del intervalo aproximadamente son:

$$\hat{p} \mp k_{\alpha/2} \sqrt{\hat{p}(1-\hat{p})/n} \quad (8)$$

Observen que estos límites son los que se hubieran obtenido directamente a partir de (1), sustituyendo "p" por $\hat{p}$ en la raíz cuadrada del denominador.

EJEMPLO 9.13.

Se desea estimar la proporción de personas en una población, que gasta más del 30% de sus ingresos en alimentación. A tal efecto se escoge una muestra aleatoria de 1000 personas, siendo el 20% la proporción de la muestra que gasta más del 30% en alimentos. Calcular un intervalo de confianza del 95% para la proporción verdadera, i) usando los límites p_1 y p_2 hallados en (6) y (7), y ii) usando los límites aproximados dados en (8).

i) $\hat{p} = 0,2$; $k_{0,025} = 1,96$; $n = 1000$

$$p_2 = \frac{0,2 + 1,96^2 / 2000 + 1,96 \sqrt{0,2 \times 0,8 / 1000 + \frac{(1,96)^2}{4(1000)^2}}}{1 + (1,96)^2 / 1000} = 0,22486$$

$$p_1 = \frac{0,2 + 1,96^2 / 2000 - 1,96 \sqrt{0,2 \times 0,8 / 1000 + \frac{(1,96)^2}{4(1000)^2}}}{1 + (1,96)^2 / 1000} = 0,1770$$

(0,1770 ; 0,22486)

La proporción de personas que gastan más del 30% de sus ingresos en alimentación está entre 17,7% y 22,486%.

ii) $0,2 \mp 1,96 \sqrt{\frac{0,2 \times 0,8}{1000}}$

(0,1752 ; 0,2248)

Obsérvese que el error cometido al aproximar, es prácticamente nulo.

9.3.2. MUESTREO SIN REEMPLAZAMIENTO

Siguiendo el mismo razonamiento que en la sección 9.2.3., en el caso de muestreo sin reemplazamiento la proporción de elementos en la muestra que tienen una determinada característica $\hat{p}$, sigue teniendo como valor esperado "p", y su varianza es:

$$\text{Var}(\hat{p}) = \frac{p(1-p)}{n} \frac{N-n}{N-1}$$

En este caso, para calcular un intervalo de confianza del $100(1 - \alpha) \%$ para "p", se tiene:

$$P \left(-k_{\alpha/2} \leq \frac{(\hat{p} - p)}{\sqrt{\frac{p(1-p)}{n}} \sqrt{\frac{N-n}{N-1}}} \leq k_{\alpha/2} \right) = 1 - \alpha$$

* Siguiendo los lineamientos de la sección anterior, los límites de un intervalo de confianza resultan:

$$p_1 = \frac{\hat{p} + \frac{(k_{\alpha/2})^2}{2n} \frac{N-n}{N-1} - k_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n} \frac{N-n}{N-1} + \frac{(k_{\alpha/2})^2}{4n^2} \frac{(N-n)^2}{(N-1)^2}}}{1 + \frac{(k_{\alpha/2})^2}{n} \frac{N-n}{N-1}} \quad (9)$$

$$p_2 = \frac{\hat{p} + \frac{(k_{\alpha/2})^2}{2n} \frac{N-n}{N-1} + k_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n} \frac{N-n}{N-1} + \frac{(k_{\alpha/2})^2}{4n^2} \frac{(N-n)^2}{(N-1)^2}}}{1 + \frac{(k_{\alpha/2})^2}{n} \frac{N-n}{N-1}} \quad (10)$$

y despreciando los términos que contienen $\frac{k_{\alpha/2}}{n}$ tenemos*:

$$p_1 = \hat{p} - k_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n} \frac{N-n}{N-1}}$$

$$p_2 = \hat{p} + k_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n} \frac{N-n}{N-1}}$$

o sea, un intervalo de confianza para p será

$$\hat{p} \mp k_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n} \frac{N-n}{N-1}} \quad (11)$$

EJEMPLO 9.14.

En una población de 2.000 personas se desea estimar la proporción de personas que fuman, mediante una muestra de 200 personas. Si el 40% de las personas de la muestra fuma, calcular un intervalo de confianza del 95% para la verdadera proporción de fumadores.

$$\hat{p} = 0,4; \quad N = 2.000; \quad n = 200$$

$$0,4 \mp 1,96 \sqrt{\frac{0,4 \times 0,6}{200}} \sqrt{\frac{1.800}{1.999}} = 0,4 \mp 0,0644$$

$$(0,3356; 0,4644)$$

o sea, la proporción de fumadores está entre 33,56% y 46,44% con una confianza del 95%.

Para determinación de tamaños de la muestra en el caso de estimación de proporciones, ver ejercicios 9.13 y 9.44.

9.4. INTERVALOS DE CONFIANZA PARA LA VARIANZA DE UNA POBLACION NORMAL

Dada una población normal con media μ y varianza σ^2 sabemos que la variable $\frac{ns^2}{\sigma^2}$ se distribuye como una χ^2 con $n - 1$ grados de libertad (Ver sección 7.5.3.)

Para encontrar un intervalo de confianza del $100(1 - \alpha) \%$ para σ^2 , se tienen que encontrar dos números a y b tales que

$$P \left(a \leq \frac{ns^2}{\sigma^2} \leq b \right) = 1 - \alpha \quad (9)$$

$$\Rightarrow P \left(\frac{a}{ns^2} \leq \frac{1}{\sigma^2} \leq \frac{b}{ns^2} \right) = 1 - \alpha$$

$$\Rightarrow P \left(\frac{ns^2}{a} \geq \sigma^2 \geq \frac{ns^2}{b} \right) = 1 - \alpha$$


$$\Rightarrow P \left(\frac{ns^2}{b} \leq \sigma^2 \leq \frac{ns^2}{a} \right) = 1 - \alpha$$

Existen diferentes valores de a y b que cumplen (9), siendo ns^2/σ^2 una variable χ^2 ; pero estamos interesados en aquellos valores de a y b para los cuales la amplitud del intervalo es mínima. Como la χ^2 no es una distribución simétrica, no se puede aplicar el criterio general visto anteriormente (Sección 9.1.). Un intervalo aproximadamente mínimo para "n" no muy pequeña, se consigue escogiendo a y b tales que

$P\left(\frac{ns^2}{\sigma^2} \geq b\right) = \alpha/2$ y $P\left(\frac{ns^2}{\sigma^2} \leq a\right) = \alpha/2$, es decir, b es el número que tiene a su derecha un área igual a $\alpha/2$ y a el número que tiene a su izquierda un área igual a $\alpha/2$

$$(b = \chi^2_{\alpha/2}, \quad a = \chi^2_{1-\alpha/2}) \quad (\text{Ver figura 9.4.})$$

FIGURA 9.4



Luego, un intervalo de confianza del $100(1 - \alpha)\%$ para la varianza de una variable normal es:

$$\left(\frac{ns^2}{\chi^2_{\alpha/2}} ; \frac{ns^2}{\chi^2_{1-\alpha/2}} \right)$$

En la práctica, se usa este intervalo aunque la población no sea normal, aunque teóricamente se debería usar para muestras grandes el obtenido en la sección 9.5.

Equivalentemente, un intervalo de confianza para la desviación típica será:

$$\left(\sqrt{\frac{ns^2}{\chi^2_{\alpha/2}}} ; \sqrt{\frac{ns^2}{\chi^2_{1-\alpha/2}}} \right)$$

EJEMPLO 9.15.

Se desea estimar la varianza de una población normal mediante una muestra de 20 elementos que dio una varianza muestral de 15. Calcular un intervalo de confianza para σ^2 del 95%.

$$n = 20; \quad s^2 = 15; \quad \chi^2_{0,025}(19) = 32,9; \quad \chi^2_{0,975}(19) = 8,91$$

$$\frac{ns^2}{\chi^2_{\alpha/2}} = \frac{20 \times 15}{32,9} = 9,1185 \quad \frac{ns^2}{\chi^2_{1-\alpha/2}} = \frac{20 \times 15}{8,91} = 33,67$$

$$(9,1185 ; 33,67)$$

Para la desviación típica el intervalo será:

$$(3,02 ; 5,80)$$

* 9.5. INTERVALOS DE CONFIANZA PARA LA VARIANZA DE UNA POBLACION NO NORMAL

Si la población estudiada no es normal no se cumple que ns^2/σ^2 es una variable χ^2 . Sin embargo para muestras grandes, sabemos que s^2 (estimador máximo-verosímil de σ^2) tiende a distribuirse normalmente con media $\frac{(n-1)\sigma^2}{n}$ (Ver ejemplo 8.8) y varianza $\frac{2(n-1)(\sigma^2)^2}{n^2}$ (Ver ejemplo 8.13), luego, un intervalo de confianza del

$100(1 - \alpha)\%$ para σ^2 se construye a partir de:

$$P \left[-k_{\alpha/2} \leq \frac{s^2 - \frac{(n-1)\sigma^2}{n}}{\sqrt{\frac{2(n-1)(\sigma^2)^2}{n^2}}} \leq k_{\alpha/2} \right] = 1 - \alpha$$

$$\Rightarrow P \left(-k_{\alpha/2} \leq \frac{ns^2 - (n-1)\sigma^2}{\sigma^2 \frac{n}{\sqrt{2(n-1)}}} \leq k_{\alpha/2} \right) = 1 - \alpha$$

$$\Rightarrow P\left[-k_{\alpha/2} \leq \frac{ns^2/\sigma^2 - (n-1)}{\sqrt{2(n-1)}} \leq k_{\alpha/2}\right] = 1 - \alpha$$

$$\Rightarrow P\left[(n-1) - k_{\alpha/2} \sqrt{2(n-1)} \leq \frac{ns^2}{\sigma^2} \leq (n-1) + k_{\alpha/2} \sqrt{2(n-1)}\right] = 1 - \alpha$$

$$\Rightarrow P\left[\frac{1}{(n-1) + k_{\alpha/2} \sqrt{2(n-1)}} \leq \frac{\sigma^2}{ns^2} \leq \frac{1}{(n-1) - k_{\alpha/2} \sqrt{2(n-1)}}\right] = 1 - \alpha$$

$$\Rightarrow P\left[\frac{ns^2}{(n-1) + k_{\alpha/2} \sqrt{2(n-1)}} \leq \sigma^2 \leq \frac{ns^2}{(n-1) - k_{\alpha/2} \sqrt{2(n-1)}}\right] = 1 - \alpha$$

Luego, los límites aproximados de un intervalo de confianza de $100(1 - \alpha)\%$ para la varianza de una población, calculados a partir de una muestra grande son:

$$\frac{ns^2}{(n-1) + k_{\alpha/2} \sqrt{2(n-1)}} ; \frac{ns^2}{(n-1) - k_{\alpha/2} \sqrt{2(n-1)}}$$

EJEMPLO 9.16.

Calcular un intervalo de confianza del 90% para la varianza de una población, si en una muestra de 100 elementos, $s^2 = 9$.

$$n = 100; \quad s^2 = 9; \quad k_{\alpha/2} = 1,645$$

$$\frac{ns^2}{(n-1) + k_{\alpha/2} \sqrt{2(n-1)}} = \frac{100 \times 9}{99 + 1,645 \sqrt{2 \times 99}} = 7,368$$

$$\frac{ns^2}{(n-1) - k_{\alpha/2} \sqrt{2(n-1)}} = \frac{100 \times 9}{99 - 1,645 \sqrt{2 \times 99}} = 11,865$$

$$(7,368 ; 11,865)$$

Si usamos el intervalo definido en la sección anterior, éste sería (7,24 ; 11,55).

9.6. INTERVALOS DE CONFIANZA PARA LA DIFERENCIA DE MEDIAS

9.6.1. POBLACIONES CON VARIANZA CONOCIDA

Dadas dos poblaciones con medias desconocidas μ_x y μ_y respectivamente y varianzas conocidas σ_x^2 y σ_y^2 respectivamente, se trata de calcular intervalos de confianza para la diferencia de las medias de la población. Si $\bar{x}$ e $\bar{y}$ son las medias muestrales de muestras de ambas poblaciones de tamaño n_x y n_y respectivamente, sabemos que $\bar{x}$ e $\bar{y}$ son variables, exacta o aproximadamente, normales.

Entonces:

$$(\bar{x} - \bar{y}) \sim N\left[(\mu_x - \mu_y), \left(\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}\right)\right]$$

$$\frac{(\bar{x} - \bar{y}) - (\mu_x - \mu_y)}{\sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}}} \sim N(0, 1)$$

Luego

$$P\left[-k_{\alpha/2} \leq \frac{(\bar{x} - \bar{y}) - (\mu_x - \mu_y)}{\sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}}} \leq k_{\alpha/2}\right] = 1 - \alpha$$

$$P\left[(\bar{x} - \bar{y}) - k_{\alpha/2} \sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}} < \mu_x - \mu_y < (\bar{x} - \bar{y}) + k_{\alpha/2} \sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}}\right] = 1 - \alpha$$

Luego, un intervalo de confianza del $100(1 - \alpha)\%$ para la diferencia de las medias $\mu_x - \mu_y$ será :

$$(\bar{x} - \bar{y}) \mp k_{\alpha/2} \sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}}$$

EJEMPLO 9.17.

Un Banco de Caracas tiene una sucursal en el Centro, y otra en el Este. Se desea estimar la diferencia de depósitos medios mensuales por cliente entre ambas sucursales. Supongan que la varianza en los depósitos por cliente en el centro sea 100, y en el este 110. Una muestra de 100 clientes en el centro dio una media de Bs. 2.000. Una muestra de 120 clientes en el este dio una media de Bs. 1.800. Calcular un intervalo de confianza del 95% para la diferencia de depósitos medios por cliente.

$$\bar{x} = 2.000; \quad \bar{y} = 1.800; \quad \sigma_x^2 = 100; \quad \sigma_y^2 = 110; \quad n_x = 100; \quad n_y = 120$$

$$(\bar{x} - \bar{y}) \mp k_{\alpha/2} \sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}} = 200 \mp 1,96 \sqrt{\frac{100}{100} + \frac{110}{120}} = 200 \mp 2,71$$

$$(197,28 ; 202,71)$$

La diferencia de depósitos promedio entre las dos sucursales está entre Bs. 197,28 y Bs. 202,71 a favor de la Sucursal del Centro con un 95% de confianza.

9.6.2. POBLACIONES CON VARIANZA DESCONOCIDA

En la sección 7.5.6.2. se vio que en este caso $\bar{x} - \bar{y}$ era aproximadamente normal

con media $\mu_x - \mu_y$ y varianza $\frac{s_x^2}{n_x - 1} + \frac{s_y^2}{n_y - 1}$

Luego un intervalo aproximado de $100(1 - \alpha)\%$ será

$$(\bar{x} - \bar{y}) \mp k_{\alpha/2} \sqrt{\frac{s_x^2}{n_x - 1} + \frac{s_y^2}{n_y - 1}}$$

EJEMPLO 9.18.

Calcular el intervalo pedido en el ejemplo 9.17, si las varianzas son desconocidas y $s_x^2 = 90$, $s_y^2 = 130$.

$$\bar{x} = 2.000; \quad \bar{y} = 1.800$$

$$200 \mp 1,96 \sqrt{\frac{90}{99} + \frac{130}{119}} = 200 \mp 2,77$$

$$(197,22 ; 202,77)$$

Cuando se sabe que las varianzas son iguales, aunque desconocidas, se usa el hecho de que (Sección 7.5.6.2.).

$$\frac{(\bar{x} - \bar{y}) - (\mu_x - \mu_y)}{\sqrt{\frac{n_x + n_y}{n_x n_y} \frac{n_x s_x^2 + n_y s_y^2}{n_x + n_y - 2}}} \sim t(n_x + n_y - 2)$$

Un intervalo de confianza del $100(1 - \alpha)\%$ será:

$$(\bar{x} - \bar{y}) \mp t_{\alpha/2} \sqrt{\frac{n_x + n_y}{n_x n_y} \frac{n_x s_x^2 + n_y s_y^2}{n_x + n_y - 2}}$$

EJEMPLO 9.19.

Se desea estimar la diferencia del ingreso promedio de los habitantes de dos barrios caraqueños. Hay razones suficientes para pensar que las desviaciones típicas de la variable ingresos son iguales en ambos barrios. A partir de unas muestras de tamaño 15 con $\bar{x} = 450$ e $\bar{y} = 600$, $s_x^2 = 20$, $s_y^2 = 25$, calcular un intervalo de confianza del 95% para la diferencia de los ingresos medios.

$$n_x = n_y = 15; \quad \bar{x} = 450; \quad \bar{y} = 600; \quad s_x^2 = 20; \quad s_y^2 = 25;$$

$$t_{0,025}(28) = 2,048$$

$$(450 - 600) \mp 2,048 \sqrt{\frac{30}{15^2} \frac{15(20 + 25)}{28}} = -150 \mp 3,67$$

$$(-153,67 ; -146,33)$$

Los ingresos promedios de los dos barrios se diferencian en Bs. 146,33 y Bs. 153,67 a favor del segundo barrio con una confianza del 95%.

9.6.3. POBLACIONES FINITAS (MUESTREO SIN REEMPLAZAMIENTO)

El cálculo de intervalos de confianza para la diferencia de medias en los casos de varianzas conocidas y desconocidas de poblaciones finitas y muestreo sin reemplazamiento, se deja como ejercicio al lector.

(Ejercicios 9.28, 9.29 y 9.30).

9.7. INTERVALOS DE CONFIANZA PARA LA DIFERENCIA DE PROPORCIONES EN DOS POBLACIONES

9.7.1. MUESTREO CON REEMPLAZAMIENTO

Según hemos visto en la sección 7.5.7., la diferencia de proporciones muestrales $\hat{p}_x - \hat{p}_y$ se distribuye normalmente.

$$\hat{p}_x - \hat{p}_y \sim N \left[(p_x - p_y), \frac{p_x q_x}{n_x} + \frac{p_y q_y}{n_y} \right]$$

Luego,

$$\frac{(\hat{p}_x - \hat{p}_y) - (p_x - p_y)}{\sqrt{\frac{p_x q_x}{n_x} + \frac{p_y q_y}{n_y}}} \sim N(0, 1)$$

$$P \left[-k_{\alpha/2} \leq \frac{(\hat{p}_x - \hat{p}_y) - (p_x - p_y)}{\sqrt{\frac{p_x q_x}{n_x} + \frac{p_y q_y}{n_y}}} \leq k_{\alpha/2} \right] = 1 - \alpha$$

Siguiendo los lineamientos de la sección 9.3.1. un aproximado intervalo de confianza del 100 $(1 - \alpha)$ % para $p_x - p_y$ será:

$$(\hat{p}_x - \hat{p}_y) \pm k_{\alpha/2} \sqrt{\frac{\hat{p}_x (1 - \hat{p}_x)}{n_x} + \frac{\hat{p}_y (1 - \hat{p}_y)}{n_y}}$$

EJEMPLO 9.20.

Un proceso de producción produce artículos con un porcentaje de defectuosos del 100 p_x %. Un nuevo proceso produce los mismos artículos con un porcentaje de defectuosos del 100 p_y %. Para estimar la diferencia de proporciones de artículos defectuosos en cada proceso, se tomaron muestras aleatorias de 100 artículos de cada proceso, resultando el 20% defectuosos en el primer proceso, y el 15% defectuosos en el segundo; calcular un intervalo de confianza del 90% para la diferencia de las proporciones.

$$\hat{p}_x = 0,20; \quad \hat{p}_y = 0,15; \quad n_x = n_y = 100; \quad k_{0,05} = 1,645$$

$$(0,20 - 0,15) \pm 1,645 \sqrt{\frac{0,20 \times 0,80 + 0,15 \times 0,85}{100}} = 0,05 \pm 0,0887$$

$$(-0,0387 ; 0,1387)$$

La diferencia de proporciones está entre 3,87 % de más en el segundo proceso y 13,87% de más en el primer proceso.

9.7.2. MUESTREO SIN REEMPLAZAMIENTO

El cálculo de intervalos de confianza en este caso se deja como ejercicio al lector (Ejercicio 9.31)

EJERCICIOS RESUELTOS

9.1. Encuentre un intervalo de confianza del 90% para la media de una población normal con $\sigma = 3$, si una muestra de 4 elementos dio los siguientes resultados:

$$x_1 = 2,4; \quad x_2 = 3,1; \quad x_3 = -0,7; \quad x_4 = -0,6$$

Solución:

Aplicando el intervalo obtenido en la sección 9.2.1.

$$\bar{x} \pm k_{\alpha/2} \frac{\sigma}{\sqrt{n}}$$

$$\bar{x} = \frac{\sum x_i}{n} = 1,05; \quad k_{0,05} = 1,645; \quad \sigma = 3; \quad n = 4$$

$$1,05 \pm 1,645 \cdot \frac{3}{2} = (-1,42 ; 3,52)$$

9.2. En el ejercicio anterior, cuál sería el intervalo de confianza si σ^2 fuera desconocida.

Solución:

Aplicando el intervalo obtenido en la sección 9.2.2.

$$\bar{x} \mp t_{\alpha/2} \frac{s}{\sqrt{n-1}}$$

$$t_{0,05}(3) = 2,353; \quad s^2 = \frac{\sum x_i^2}{n} - (\bar{x})^2 = 2,95$$

$$1,05 \mp 2,353 \frac{\sqrt{2,95}}{\sqrt{3}}$$

$$(-1,28 ; 3,38)$$

9.3. Para estimar el precio medio de venta de un cierto bien, se tomaron al azar 101 automercados en el territorio de la República. El precio medio obtenido en la muestra fue de Bs. 20, con una desviación típica de Bs. 2. Calcular un intervalo de confianza del 95%.

Solución:

Caso de intervalos de confianza para la media con varianza desconocida y $n > 31$. Luego, se aplica el segundo intervalo obtenido en la sección 9.2.2.

$$\bar{x} \mp k_{\alpha/2} \frac{s}{\sqrt{n-1}}$$

$$\bar{x} = 20; \quad s = 2; \quad n = 101; \quad k_{0,025} = 1,96$$

$$20 \mp 1,96 \frac{2}{\sqrt{100}} = 20 \mp 0,392$$

$$(19,608 ; 20,392)$$

El precio promedio de ese producto está entre Bs. 19,608 y Bs. 20,392 con una confianza del 95%.

9.4. Una empresa industrial desea conocer la productividad media de sus 600 obreros, si utilizan un nuevo tipo de máquinas. Para hacerlo se escogen 20 obreros

convenientemente adiestrados para trabajar con el nuevo tipo de máquina por un día. La producción media por obrero fue de 35 unidades, con una desviación típica de dos unidades. Calcular un intervalo de confianza del 99%.

Solución:

Estimación de la media de poblaciones finitas, muestreo sin reemplazamiento, varianza desconocida, $n < 31$. Aplicamos el intervalo obtenido en la sección 9.2.4.

$$\bar{x} \mp t_{\alpha/2} \frac{s}{\sqrt{n-1}} \sqrt{\frac{N-n}{N-1}}$$

$$\bar{x} = 35; \quad t_{0,005}(19) = 2,861; \quad s = 2; \quad n = 20$$

$$35 \mp 2,861 \frac{2}{\sqrt{19}} \sqrt{\frac{580}{599}}$$

$$(33,7080 ; 36,2920)$$

La productividad media de los obreros con el nuevo tipo de máquinas está entre 33,708 unidades y 36,292 unidades producidas por día.

9.5. Para estimar el gasto medio diario en alimentación de las 4.000 familias residentes en un cierto barrio de Caracas, se tomó una muestra de 401 familias. Los gastos medios de las familias de la muestra fueron Bs. 200, con una varianza de 25. Calcular un intervalo de confianza del 90% para el gasto medio en alimentación.

Solución:

Caso de estimación de la media de poblaciones finitas, muestreo sin reemplazamiento, varianza desconocida, $n > 31$. Intervalo a aplicarse, sección 9.2.4.

$$\bar{x} \mp k_{\alpha/2} \frac{s}{\sqrt{n-1}} \sqrt{\frac{N-n}{N-1}}$$

$$\bar{x} = 200; \quad k_{0,05} = 1,645; \quad s = 5; \quad n = 401$$

$$200 \mp 1,645 \frac{5}{\sqrt{400}} \sqrt{\frac{4.000-401}{3.999}}$$

$$(199,6142 ; 200,3858)$$

El gasto diario medio en alimentación está entre Bs. 199,61 y Bs. 200,38 con una confianza del 90%.

- 9.6. Una empresa publicitaria desea estimar la proporción de la población que prefiere un producto cuya publicidad hace la empresa, con relación a otro producto similar. De una muestra de 50 personas, 20 prefirieron el otro producto. Calcular un intervalo de confianza del 95% para la proporción de la población que prefiere el producto patrocinado por la empresa publicitaria.

Solución:

Caso de estimación de proporciones en poblaciones prácticamente infinitas. Intervalo simplificado (8) de la sección 9.3.1.

$$\hat{p} \mp k_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

$$\hat{p} = 0,4; \quad k_{0,025} = 1,96; \quad n = 50$$

$$0,4 \mp 1,96 \sqrt{\frac{0,4 \times 0,6}{50}}$$

$$(0,4642; 0,7358)$$

La proporción de la población que prefiere el producto está entre 46,42% y 73,58%, con un 95% de confianza.

- 9.7. Se supone que el ingreso diario de los habitantes de Caracas es una variable aproximadamente normal. Para estimar la varianza del ingreso diario se tomó una muestra de 101 habitantes que dio un ingreso diario medio de Bs. 250, con una desviación típica de Bs. 10. Calcular un intervalo de confianza del 99% para σ .

Solución:

Caso de un intervalo de confianza para la varianza de una distribución normal. Intervalo obtenido en la sección 9.4.

$$\frac{ns^2}{\chi_{\alpha/2}^2}; \quad \frac{ns^2}{\chi_{1-\alpha/2}^2}$$

$$n = 101; \quad s^2 = 100; \quad \chi_{0,005}^2(100) = 140,2; \quad \chi_{0,995}^2(100) = 67,3$$

$$\frac{101 \times 100}{140,2} = 72,04 \quad \frac{101 \times 100}{67,3} = 150,07$$

Un intervalo de confianza del 99% para σ^2 es (72,04 ; 150,07) Como se pide un intervalo de confianza para σ , será

$$(\sqrt{72,04}; \sqrt{150,07}) \Rightarrow (8,49; 12,25)$$

- 9.8. Calcular el intervalo pedido en el ejercicio anterior, si no puede suponerse que la población es normal.

Solución:

Intervalo de confianza para σ en el caso de poblaciones no normales. Sección 9.5.

$$\frac{ns^2}{(n-1) + k_{\alpha/2} \sqrt{2(n-1)}}; \quad \frac{ns^2}{(n-1) - k_{\alpha/2} \sqrt{2(n-1)}}$$

$$k_{\alpha/2} = k_{0,005} = 2,57$$

$$\frac{101 \times 100}{100 + 2,57 \sqrt{200}} = 74,0767; \quad \sqrt{74,0767} = 8,6068$$

$$\frac{101 \times 100}{100 - 2,57 \sqrt{200}} = 158,6683; \quad \sqrt{158,6683} = 12,5964$$

$$(8,61; 12,60)$$

- 9.9. Se desea estimar la proporción de bombillos defectuosos en un lote de 100, mediante una muestra de 10. Si en la muestra, 3 bombillos resultaron defectuosos, calcular un intervalo de confianza del 90% para la proporción de defectuosos.

Solución:

Caso de estimación de proporciones en poblaciones finitas, muestreo sin reemplazamiento. Intervalo obtenido en la sección 9.3.2.

$$\hat{p} \mp k_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \sqrt{\frac{N-n}{N-1}}$$

$$\hat{p} = 0,3; \quad k_{0,05} = 1,645; \quad N = 100; \quad n = 10$$

$$0,3 \mp 1,645 \sqrt{\frac{0,3 \times 0,7}{10}} \sqrt{\frac{90}{99}}$$

$$(0,0727 ; 0,5273)$$

La proporción de bombillos defectuosos está entre 7,27% y 52,73%, con una confianza del 90%.

- 9.10. Se quiere estimar la demanda media por cliente de un cierto producto, con un intervalo de confianza del 95%. De qué tamaño debe ser la muestra para que la amplitud del intervalo no sea mayor de 5 unidades. Supongan $\sigma = 15$.

Solución:

Problema sobre el cálculo del tamaño de la muestra para estimación de la media. Tamaño obtenido en la sección 9.2.6.

$$n = \left[\frac{2k_{\alpha/2} \sigma}{h} \right]^2$$

$$k_{0,025} = 1,96; \quad \sigma = 15; \quad h = 5$$

$$n = \left(\frac{2 \times 1,96 \times 15}{5} \right)^2 = 139$$

- 9.11. Supongan que el ingreso mensual de las familias de una urbanización de Caracas es una variable aleatoria con media μ_x y varianza $\sigma_x^2 = 64$. El consumo mensual es una variable aleatoria con media μ_y y varianza $\sigma_y^2 = 36$. Se tomaron dos muestras aleatorias: la primera de 50 elementos dio unos ingresos medios de Bs. 3.000; la segunda de 35 elementos dio un consumo medio de Bs. 2.750. Calcular un intervalo de confianza del 95% para el ahorro medio de las familias de la urbanización.

Solución:

El ahorro medio = Ingreso Medio - Consumo Medio. Caso de intervalo de confianza para la diferencia de medias con varianzas conocidas. Intervalo obtenido en la sección 9.6.1.

$$(\bar{x} - \bar{y}) \mp k_{\alpha/2} \sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}}$$

$$\bar{x} = 3.000; \quad \bar{y} = 2.750; \quad k_{0,025} = 1,96; \quad \sigma_x^2 = 64; \quad \sigma_y^2 = 36; \quad n_x = 50; \quad n_y = 35$$

$$250 \mp 1,96 \sqrt{\frac{64}{50} + \frac{36}{35}}$$

$$(247,02 ; 252,98)$$

El ahorro mensual promedio está entre Bs. 247,02 y Bs. 252,98 con una confianza del 95%.

- 9.12. Calcular el intervalo pedido en el ejercicio anterior, si no se conocen las varianzas y $s_x^2 = 80$, $s_y^2 = 40$.

Solución:

En este caso se aplica la aproximación dada en la sección 9.6.2.

$$(\bar{x} - \bar{y}) \mp k_{\alpha/2} \sqrt{\frac{s_x^2}{n_x - 1} + \frac{s_y^2}{n_y - 1}}$$

$$250 \mp 1,96 \sqrt{\frac{80}{49} + \frac{40}{34}}$$

$$(246,71 ; 253,29)$$

- 9.13. Determinar el tamaño de la muestra necesario para estimar la proporción poblacional, con un intervalo de confianza del $100(1 - \alpha)\%$ de amplitud h , en el caso de muestreo con reemplazamiento o poblaciones prácticamente infinitas.

Solución:

Se sabe que para muestras grandes, $\hat{p}$ es aproximadamente normal.

$$\hat{p} \sim N\left(p, \frac{pq}{n}\right)$$

Luego:

$$P\left(-k_{\alpha/2} \leq \frac{\hat{p} - p}{\sqrt{\frac{pq}{n}}} \leq k_{\alpha/2}\right) = 1 - \alpha$$

$$\Rightarrow P\left(\hat{p} - k_{\alpha/2} \sqrt{\frac{pq}{n}} \leq p \leq \hat{p} + k_{\alpha/2} \sqrt{\frac{pq}{n}}\right) = 1 - \alpha$$

La amplitud del intervalo que contiene "p" con una confianza de $100(1 - \alpha)\%$ es

$$h = 2k_{\alpha/2} \sqrt{\frac{pq}{n}}$$

$$n = \left[\frac{2k_{\alpha/2}}{h} \right]^2 pq$$

Desafortunadamente, como en el caso de la media, el tamaño de la muestra está en función de "p" que es desconocido.

Ahora bien, pq es siempre menor o igual a 1/4; luego, si sustituimos pq por su valor máximo 1/4, se está estimando conservadoramente el valor de n; luego:

$$n = \left[\frac{2k_{\alpha/2}}{h} \right]^2 \frac{1}{4}$$

$$n = \left[\frac{k_{\alpha/2}}{h} \right]^2$$

Si se tiene alguna idea a priori sobre el valor de "p" se usará ese conocimiento para sustituir pq. Por ejemplo, si se sabe que $p \leq 0,2 \Rightarrow pq \leq 0,16$ y $0,16$, será el valor usado en la fórmula.

* 9.14. Calcular un intervalo de confianza del $100(1 - \alpha)\%$ para el parámetro θ de la distribución exponencial.

Solución:

Sea $x_1, x_2, \dots, x_n$ una muestra aleatoria de una variable exponencial x con parámetro desconocido θ .

Sabemos que $\bar{x}$ es el estimador máximo verosímil de θ . Vamos a buscar una función de $\bar{x}$ que tenga una distribución conocida e independiente θ .

$$\bar{x} = \frac{\sum x_i}{n} \Rightarrow n\bar{x} = \sum x_i$$

Llamando z a $n\bar{x}$, se tiene $z = \sum x_i$

Multiplicando por $\frac{2}{\theta}$ se tiene:

$$\frac{2}{\theta} z = \frac{2}{\theta} \sum x_i$$

La función generatriz de momentos de $\frac{2}{\theta} z$ es;

$$m_{\frac{2}{\theta} z}(k) = E\left(e^{\frac{2}{\theta} zk}\right) = E\left(e^{\frac{2}{\theta} k \sum x_i}\right)$$

Si hacemos $\frac{2}{\theta} k = 1$ obtenemos:

$$m_{\frac{2}{\theta} z}(k) = E\left(e^{\sum x_i}\right) = E\left(e^{x_1} \cdot e^{x_2} \dots e^{x_n}\right) =$$

y por ser independientes,

$$= E\left(e^{x_1}\right) \cdot E\left(e^{x_2}\right) \dots E\left(e^{x_n}\right)$$

o sea, la función generatriz de momentos de $\frac{2}{\theta} z$ es el producto de las funciones generatrices de momentos con parámetro 1 de las variables $x_1, \dots, x_n$

luego:

$$m_{\frac{2}{\theta} z}(1) = \left(\frac{1/\theta}{1/\theta - 1}\right) \left(\frac{1/\theta}{1/\theta - 1}\right) \dots \left(\frac{1/\theta}{1/\theta - 1}\right) = \left(\frac{1/\theta}{1/\theta - 1}\right)^n$$

Multiplicando numerador y denominador por θ , y sustituyendo 1 por $\frac{2}{\theta} k$, se tiene:

$$m_{\frac{2}{\theta} z}(1) = \left(\frac{1}{1 - \theta \frac{2}{\theta} k}\right)^n = \left(\frac{1}{1 - 2k}\right)^{\frac{2n}{\theta}}$$

Esta es la función generatriz de momentos de una variable χ^2 , con $2n$ grados de libertad (Ver sección 5.15); luego, $\frac{2}{\theta} z = \frac{2}{\theta} n\bar{x}$ es una χ^2 con $2n$ grados de libertad.

$$P\left(\chi^2_{1-\alpha/2} \leq \frac{2}{\theta} n\bar{x} \leq \chi^2_{\alpha/2}\right) = 1 - \alpha$$

Recordando,

$$P\left(\frac{\chi^2_{1-\alpha/2}}{2n\bar{x}} \leq \frac{1}{\theta} \leq \frac{\chi^2_{\alpha/2}}{2n\bar{x}}\right) = 1 - \alpha \Rightarrow$$

$$\Rightarrow P\left(\frac{2n\bar{x}}{\chi^2_{\alpha/2}} \leq \theta \leq \frac{2n\bar{x}}{\chi^2_{1-\alpha/2}}\right) = 1 - \alpha$$

Luego, un intervalo de confianza del $100(1 - \alpha) \%$ para el parámetro θ de la distribución exponencial es:

$$\left(\frac{2n\bar{x}}{\chi^2_{\alpha/2}} ; \frac{2n\bar{x}}{\chi^2_{1-\alpha/2}} \right)$$

- 9.15. Calcular un intervalo de confianza del $100(1 - \alpha) \%$ para el cociente de las varianzas de dos poblaciones normales.

Solución:

$$\text{Dadas } s_x^2 = \frac{\sum (x_i - \bar{x})^2}{n_x} \quad \text{y} \quad s_y^2 = \frac{\sum (y_i - \bar{y})^2}{n_y}$$

$$\text{Sabemos que } \frac{n_x s_x^2}{\sigma_x^2} \sim \chi^2(n_x - 1) \quad \text{y} \quad \frac{n_y s_y^2}{\sigma_y^2} \sim \chi^2(n_y - 1)$$

$$\frac{n_x s_x^2 / \sigma_x^2 (n_x - 1)}{n_y s_y^2 / \sigma_y^2 (n_y - 1)} \text{ es una variable F con } n_x - 1 \text{ y } n_y - 1 \text{ grados de libertad.}$$

$$P\left[F_{1-\alpha/2}(n_x - 1)(n_y - 1) \leq \frac{n_x s_x^2 / \sigma_x^2 (n_x - 1)}{n_y s_y^2 / \sigma_y^2 (n_y - 1)} \leq F_{\alpha/2}(n_x - 1)(n_y - 1)\right] = 1 - \alpha$$

$$P\left[F_{1-\alpha/2} \leq \frac{n_x s_x^2 \sigma_y^2 (n_y - 1)}{n_y s_y^2 \sigma_x^2 (n_x - 1)} \leq F_{\alpha/2}\right] = 1 - \alpha$$

$$P\left[F_{1-\alpha/2} \frac{n_y s_y^2 (n_x - 1)}{n_x s_x^2 (n_y - 1)} \leq \frac{\sigma_y^2}{\sigma_x^2} \leq F_{\alpha/2} \frac{n_y s_y^2 (n_x - 1)}{n_x s_x^2 (n_y - 1)}\right] = 1 - \alpha$$

$$P\left[\frac{1}{F_{\alpha/2}} \frac{n_x s_x^2 (n_y - 1)}{n_y s_y^2 (n_x - 1)} \leq \frac{\sigma_x^2}{\sigma_y^2} \leq \frac{1}{F_{1-\alpha/2}} \frac{n_x s_x^2 (n_y - 1)}{n_y s_y^2 (n_x - 1)}\right] = 1 - \alpha$$

Como,

$$\frac{1}{F_{1-\alpha/2}[(n_x - 1), (n_y - 1)]} = F_{\alpha/2}[(n_y - 1), (n_x - 1)]$$

los límites del intervalo son:

$\frac{1}{F_{\alpha/2}[(n_x - 1), (n_y - 1)]}$	$\frac{n_x s_x^2 (n_y - 1)}{n_y s_y^2 (n_x - 1)}$
$F_{\alpha/2}[(n_y - 1), (n_x - 1)]$	$\frac{n_x s_x^2 (n_y - 1)}{n_y s_y^2 (n_x - 1)}$

EJERCICIOS PROPUESTOS

9. Para estimar el alquiler medio pagado por viviendas de dos habitaciones en una urbanización de Caracas, se tomó una muestra aleatoria de 226 viviendas. La media muestral fue Bs. 300, y la desviación típica muestral de Bs. 64. Calcular un intervalo de confianza para el alquiler medio del i) 90%; ii) 95%; iii) 98%. Interpretar los resultados.

9. Un Banco desea estimar el valor medio de las deudas morosas de una empresa que está solicitando un préstamo. Una muestra aleatoria de 25 clientes morosos dio una media de Bs. 200, y una desviación típica de Bs. 20. Calcular un intervalo de confianza del 95% e interpretar el resultado.

- 9.18. Un productor de baterías para automóviles está interesado en estimar la vida útil media de sus baterías, así como la varianza del tiempo de duración. En una muestra de 50 clientes que han usado la batería en condiciones similares, la vida media fue de dos años, y una desviación típica de 1 mes. Calcular intervalos de confianza del 95% para la duración media y la varianza. Interpretar los resultados.

- 9.19. El peso medio de la carga de una muestra aleatoria de 100 camiones que viajan de Valencia a Caracas, fue de 20 Tm y la desviación típica de 2,1 Tm. Calcular un

intervalo de confianza del 95% para el peso medio de la carga de los camiones que van de Valencia a Caracas. Interpretar el resultado.

9.20. Una muestra aleatoria de 35 cauchos producidos por una empresa tuvo una duración media de 21.000 km. y una desviación típica de 1.500 km. i) Estimar la duración media con una confianza del 98%. ii) Estimar la desviación típica de la duración con una confianza del 98%. Interpretar los resultados.

9.21. Refiriéndose al ejercicio 9.10. ¿Cuál debe ser el tamaño de la muestra, si se desea una confianza del 99%?

9.22. En el ejercicio 9.19, el 60% de los camiones de la muestra tenían carga consistente en vegetales; y el resto, carga de otro tipo. Estimar la proporción de camiones que van de Valencia a Caracas con carga de vegetales con un 97% de confianza. Interpretar los resultados.

9.23. Para estimar la proporción de familias que en un barrio tienen ingresos medios diarios superiores a Bs. 300, se tomó una muestra aleatoria de 1.000 familias, 580 de las cuales tenían ingresos medios superiores a Bs. 300. Hacer la estimación con un intervalo de confianza del 95%, usando los intervalos (6) y (7) de la sección 9.3.1. Interpretar los resultados.

9.24. En el ejercicio anterior, hacer la estimación usando el intervalo (8) de la sección 9.3.1. Interpretar el resultado.

9.25. Supongamos que en el ejercicio 9.3. el número total de automercados en el territorio es de 1.000. Calcular un intervalo de confianza del 95%. Interpretar los resultados.

9.26. Supongamos que en el ejercicio 9.16. el número de viviendas de dos habitaciones en la urbanización es de 10.000. Calcular los intervalos de confianza del 90%, 95%, 99% e interpretar los resultados.

9.27. En el ejercicio 9.17. supongamos que el número de clientes morosos es de 250. Calcular el intervalo de confianza del 95%, e interpretar el resultado.

9.28. Calcular los límites de un intervalo de confianza del $100(1-\alpha)\%$ para la diferencia de medias de dos poblaciones finitas, con varianzas conocidas y muestreo sin reemplazamiento.

9.29. Calcular los límites de un intervalo de confianza del $100(1-\alpha)\%$ para la diferencia de medias de dos poblaciones finitas, con varianzas desconocidas y muestreo sin reemplazamiento.

9.30. Calcular los límites de un intervalo de confianza del $100(1-\alpha)\%$ para la diferencia de medias de dos poblaciones finitas, con varianzas desconocidas pero iguales y muestreo sin reemplazamiento.

9.31. Calcular los límites de un intervalo de confianza para la diferencia de proporciones de dos poblaciones finitas y muestreo sin reemplazamiento.

9.32. Un productor de marcadores pretende estimar el costo variable de producción por unidad de un cierto tipo de marcadores para decidir si los producirá o no. En una muestra de 150 unidades el costo variable medio fue de Bs. 3,71 siendo $s^2 = 0,263$. Estimar el costo variable medio con una confianza del 95%. Interpretar los resultados.

9.33. En el ejercicio anterior. ¿De qué tamaño debe ser la muestra, si se quiere que la amplitud del intervalo sea de Bs. 0,127. Suponga $\sigma^2 = 0,263$.

9.34. Supongamos que en el ejercicio 9.23, el número total de familias es de 5.000. Calcular un intervalo de confianza del 95%, para el número total de familias con ingresos superiores a Bs. 300.

i) Use intervalos (9) y (10) de la sección 9.3.2.

ii) Use intervalo (11) de la sección 9.3.2.

9.35. Determinar el tamaño de la muestra para la estimación de la media de la población, en el caso de poblaciones finitas. Nota: Seguir el razonamiento de la sección 9.2.5.

9.36. El precio a que una empresa puede comprar la materia prima de su proveedor, es una variable aleatoria que depende de la variación en el costo unitario de producción del proveedor. Para estimar el costo medio de la materia prima se ha utilizado una muestra de 28 unidades, facturadas a un precio medio de Bs. 30 y una desviación típica de Bs. 2. Calcular un intervalo de confianza del 80% para el costo medio. Interpretar el resultado.

9.37. Una gran empresa está pensando trasladar su fábrica para las afueras de la ciudad. A tal efecto se desea saber con una confianza del 95% la proporción de empleados que disponen de transporte propio. En una muestra aleatoria de 100 empleados, 80 tenían transporte propio. Haga la estimación e interprete el resultado.

9.38. Supongamos que en el ejercicio anterior el número total de empleados en la empresa es de 2.000. Estimar el número total de empleados con transporte propio. Usar un coeficiente de confianza del 95%. Interpretar el resultado.

9.39. El contenido en m^3 de los barriles de petróleo que se llenan de acuerdo con un cierto proceso automático es una variable aleatoria con media μ desconocida y desviación típica de $0,021 m^3$. Para estimar el número medio de m^3 por barril, se tomó una muestra aleatoria de 10 barriles y se obtuvieron los siguientes resultados:

$$\sum x_i = 1,7 m^3 \quad \sum x_i^2 = 0,298$$

Calcular un intervalo de confianza del 90%, para el número medio de m³ por barril. Interpretar el resultado.

9.40. Si en el ejercicio anterior no se conoce σ^2 . Calcular un intervalo de confianza del 90% e interpretar el resultado.

9.41. Para estimar el número de desempleados en Caracas, un economista selecciona aleatoriamente 1.000 familias. En esas familias un total de 1.521 personas pertenecían a la población activa y 284 estaban desempleados. Calcular un intervalo de confianza del 95% para la proporción de desempleados e interpretar el resultado.

9.42. Un Banco ha emitido 25.000 tarjetas de crédito. Se desea estimar con un 85% de confianza el número de poseedores de tarjetas de crédito que el mes pasado hicieron gastos (utilizando la tarjeta) inferiores a Bs. 10.000. De una muestra de 2.000 clientes, 1.300 gastaron menos de Bs. 10.000.

9.43. En el ejercicio anterior, suponiendo que $\sigma =$ Bs. 50. ¿De qué tamaño debe ser la muestra para que un intervalo de confianza del 85% para los gastos medios tenga una amplitud de Bs. 30? (Ver ejercicio 9.35).

9.44. Determinar el tamaño de la muestra necesario para estimar la proporción poblacional con un intervalo de confianza del 100 (1 - α) % de amplitud h en el caso de poblaciones finitas y muestreo sin reemplazamiento.
Nota: Siga el razonamiento del ejercicio 9.13.

9.45. Se desea estimar la proporción de estudiantes de la U.C.A.B. que desde la existencia de la Universidad no han tenido que reparar nunca. ¿De qué tamaño debe ser la muestra, si se quiere que un intervalo de confianza del 95% tenga una amplitud de 2%? (Ver ejercicio 9.13.).

9.46. Calcular el tamaño de la muestra en el ejercicio anterior, si por estudios anteriores se sabe que la proporción es menor del 30%. (Ver ejercicio 9.13.)

9.47. Se desea estimar con una precisión del 2% y una confianza del 98%, la proporción de clientes morosos de una gran empresa que tiene 5.000 clientes. ¿Qué tamaño de muestra debe usarse? (Ver ejercicio 9.44).

9.48. Calcular el tamaño de la muestra en el ejercicio anterior, si por estudios pasados se sabe que la proporción es $\leq 0,1$.

9.49. Químicamente se establece que el porcentaje de hierro en 5 muestras de mineral extraído en una cierta mina tiene una media de 22,3% y una desviación típica de 1,8%. En 6 muestras de mineral extraído de otra mina el contenido medio fue de 20% y la desviación típica de 1,3%. Se estima que las varianzas de los porcentajes

son las mismas. Establecer los límites de un intervalo de confianza del 95%, para la diferencia de contenidos medios de hierro de los minerales extraídos de las dos diferentes minas. Interpretar el resultado.

9.50. Para estimar el efecto de un programa de entrenamiento en los obreros de una fábrica, se tomaron muestras de obreros que no habían recibido el entrenamiento, y de obreros que habían recibido el entrenamiento, computándose las producciones medias diarias de ambos grupos. El número total de obreros que no recibieron el entrenamiento es de 500; y el número de obreros que lo recibieron es de 100. Los tamaños de las muestras fueron 50 y 10 respectivamente, y los resultados obtenidos fueron: Producción media diaria de los que recibieron entrenamiento: 25 unidades con varianza de 5; producción media diaria de los que no recibieron entrenamiento: 20 unidades con varianza de 2.

Calcular un intervalo de confianza del 95%, para la diferencia de producciones medias, e interpretar el resultado. (Ver ejercicio 9.29).

9.51. Una encuesta de 400 hombres y 400 mujeres de una cierta ciudad mostró que 270 hombres y 240 mujeres favorecerían una determinada proposición. Calcular un intervalo de confianza del 88%, para la diferencia de proporciones entre hombres y mujeres. Interpretar el resultado.

9.52. Se garantiza que un instrumento de medición mide con exactitud con una varianza máxima de 2 mm². Un mismo objeto de 354 mm. fue medido cuatro veces, y se obtuvo las siguientes lecturas en el instrumento: 353, 351, 351, 355. Calcular un intervalo de confianza del 95% para la varianza, e interpretar el resultado. Supóngase que la medida hecha por el instrumento es una variable aleatoria normal.

9.53. Para estimar la resistencia a la tracción de las cuerdas producidas en una fábrica, se tomó una muestra aleatoria de 5 cuerdas, sometiéndolas a pesos cada vez mayores hasta que se rompían. El peso máximo soportado por las cuerdas fue 660, 460, 540, 580 y 550 kilos respectivamente. Estimar con una confianza del 95%, el peso medio que soportan las cuerdas fabricadas, suponiendo que el peso soportado sea una variable aleatoria normal. Interpretar el resultado.

9.54. En el ejercicio anterior, estime la desviación típica de los pesos soportados con una confianza del 90%. Interpretar el resultado.

9.55. Para estimar la eficacia de un nuevo fertilizante una empresa agrícola seleccionó 8 parcelas. En una mitad de cada parcela usó el nuevo fertilizante, y en la otra el fertilizante usado anteriormente. La producción en Tm. por Ha. fue la siguiente:

Con nuevo fertilizante: 187, 159, 193, 184, 193, 175, 179, 186.

Con antiguo fertilizante: 179, 158, 192, 177, 182, 174, 166, 180.

Suponiendo que las producciones son independientes y normalmente distribuidas con la misma varianza, estimar la diferencia en la producción media, con un intervalo de confianza del 95% e interpretar el resultado.

- 9.56. Al lanzar una moneda 500 veces, se obtuvieron 300 caras. Hallar un intervalo de confianza del 90% para la probabilidad de obtener una cara al lanzar esa moneda una vez. ¿Opina Ud. que la moneda está bien balanceada?
- 9.57. El gobierno desea mejorar la comunicación terrestre que existe entre dos pueblos del interior, y se discute sobre la conveniencia de dos proyectos. El proyecto A es ampliar y mejorar la actual carretera; el proyecto B es construir una nueva carretera entre los dos pueblos. Uno de los pueblos tiene 25.000 habitantes, y el otro 20.000 habitantes. En una muestra de 2.500 habitantes del primer pueblo, 2.000 apoyan el proyecto B y 500 el proyecto A. En el segundo pueblo de una muestra de 2.000 habitantes, 1.500 favorecen el proyecto B y 500 el proyecto A. Estimar con una confianza del 95%, la diferencia de proporciones de la población en ambas ciudades que favorecen el proyecto B. Interpretar el resultado.
- 9.58. En el ejercicio anterior, calcular un intervalo de confianza para la diferencia de proporciones de la población que favorecen el proyecto A. Interpretar el resultado.
- 9.59. En el ejercicio 9.55, calcular el intervalo de confianza si no se sabe que las varianzas son iguales. Interpretar el resultado.
- 9.60. Se desea estimar si existe diferencia en el diámetro medio de las rolineras en un lote de 200 producidas por una máquina y las rolineras en un lote de 100 producidas por otra máquina. Se sabe que las varianzas en el diámetro son 1 y 0,8 respectivamente. Una muestra de 20 del primer lote dio un diámetro medio de 15 mm, y una muestra de 10 del segundo lote dio un diámetro medio de 13,5 mm. Usar un coeficiente de confianza del 98%, e interpretar el resultado.
- 9.61. En el ejercicio 9.60, supongan que las varianzas son desconocidas pero iguales, y las varianzas muestrales fueron 1,2 y 1,3 respectivamente. Calcular el intervalo de confianza.
- 9.62. Se desea estimar con un 95% de confianza, la diferencia en las proporciones de artículos defectuosos producidos por dos máquinas A y B. Se toman muestras aleatorias de 150 unidades de las producciones de ambas máquinas, resultando 30 defectuosas de las producidas por A, y 15 defectuosas de las producidas por B. Interpretar el resultado.
- *9.63. El tiempo de llegada entre clientes a una tienda, es una variable exponencial con parámetro s . Seleccionando al azar 15 clientes, el tiempo medio entre llegadas fue de 35 minutos; calcular un intervalo de confianza del 95%. (Ver ejercicio 9.14.)*

9.64. Supongamos que el tiempo de duración de las baterías del ejercicio 9.18 es exponencial. Calcular un intervalo de confianza del 95% para la duración media. (Ver ejercicio 9.14).

- 9.65. Una empresa ve con preocupación la poca estabilidad que los obreros muestran en la producción por hora. En ciertos días de la semana la producción por hora es muy alta; en otros, la producción por hora es baja. Se presume que acortando la jornada de trabajo en los días de baja producción, ésta tenderá a subir; y alargándola en los días de alta producción, ésta tenderá a bajar, manteniéndose el mismo nivel de producción media. Se experimenta el sistema con 61 obreros, y la varianza de la producción fue de 5; mientras que un grupo de 121 obreros que mantuvieron su jornada igual, la varianza fue de 10. Calcular un intervalo de confianza del 95% para el cociente de las varianzas. Interpretar el resultado.
- 9.66. Refiriéndose a la parte ii) del ejercicio 7.24, comprobar que $E(\bar{x}) = \mu$ y que
$$\text{Var}(\bar{x}) = \frac{\sigma^2}{n} \frac{N-n}{N-1}.$$
- 9.67. Determine razonadamente la veracidad o falsedad de las siguientes afirmaciones:
- La base teórica de un intervalo de confianza del 95% para un parámetro poblacional es que el 95% de los valores del estadístico muestral calculados a partir de todas las posibles muestras de un determinado tamaño están contenidos en el intervalo.
 - Para hacer una estimación por intervalos es necesario primero hacer una estimación puntual.
- 9.68. Determine razonadamente cuál de las respuestas es correcta en:
- Los intervalos de confianza calculados a partir de un muestreo con reemplazamiento en una población finita son, con respecto a los intervalos calculados a partir de una muestra sin reemplazamiento, "ceteris paribus":
- Más precisos.
 - Menos precisos.
 - La precisión no depende del tipo de muestreo.
 - Ninguna de las anteriores.
- Cuando se calcula un intervalo de confianza para la proporción, se puede afirmar que la proporción muestral cae en el intervalo:
- Con una probabilidad de 0,95.
 - Con un 95% de confianza.
 - Ninguna de las anteriores.

CAPITULO X

CONTRASTE DE HIPOTESIS

10.1. INTRODUCCION

Una de las áreas más importantes en el campo de la estadística aplicada es la que se conoce como “Contraste de Hipótesis”. La utilidad del contraste de hipótesis proviene del hecho de constituir uno de los instrumentos más apropiados para tomar decisiones en condiciones de incertidumbre.

En la toma de decisiones es útil hacer hipótesis sobre las poblaciones acerca de las cuales se va a tomar la decisión.

EJEMPLO 10.1.

Supongamos que una empresa está estudiando la posibilidad de implantar un nuevo sistema de propaganda para tratar de aumentar las ventas medias por cliente. Con el sistema de propaganda actual, las ventas medias por cliente son de Bs. 200. El nuevo sistema de propaganda supone un incremento en los costos, que se estima conveniente, si las ventas medias por cliente aumentan.

El problema de toma de decisiones a que se enfrenta la empresa es uno con dos posibles acciones: “Implantar el nuevo sistema de propaganda”, “No implantar el nuevo sistema de propaganda”.

Este problema se puede enfocar de la siguiente forma: Se hace la suposición de que las ventas medias con el nuevo sistema de propaganda son de Bs. 200. Esta suposición de que $\mu = 200$, es lo que se conoce como una hipótesis estadística. Después de formulada la hipótesis, se determina mediante los resultados de una muestra, si es o no una hipótesis razonable.

Es decir, a partir de los resultados de una muestra, decidimos si rechazar o aceptar la hipótesis establecida. La decisión de implantar o no el nuevo sistema, se reduce a decidir si se rechaza o no la hipótesis de que $\mu = 200$.

El procedimiento que nos lleva a aceptar o rechazar la hipótesis, es un contraste de hipótesis.

Generalizando el ejemplo, una hipótesis estadística se puede definir de la siguiente forma:

DEFINICION 10.1

Una hipótesis estadística es una suposición sobre la distribución de probabilidades de una variable aleatoria.

En la práctica se pueden presentar dos tipos de hipótesis. Uno, concerniente a la forma de la distribución de probabilidades de una determinada población; p. ej.: se plantea la hipótesis de que la demanda de un cierto bien es una variable aleatoria que obedece a la distribución exponencial. Un segundo tipo de hipótesis se refiere al valor del parámetro o de los parámetros desconocidos de la población; p. ej.: sabiendo que la demanda es exponencial, se plantea la hipótesis de que la demanda media es igual a 4 ($\theta = 4$). Las hipótesis de la primera clase se conocen como hipótesis no paramétricas; mientras que las de la segunda clase, como hipótesis paramétricas.

Este segundo tipo de hipótesis estadísticas paramétricas es el que se va a estudiar a continuación. El tratamiento de hipótesis estadísticas no paramétricas se verá en el Capítulo XII.

Los problemas de contraste de hipótesis sobre los parámetros de una población pueden enfocarse, como se vio en el ejemplo, como un problema de toma de decisiones.

DEFINICION 10.2.

El espacio del parámetro es el conjunto de posibles valores del parámetro desconocido θ sobre el cual vamos a plantear nuestra hipótesis, y lo representaremos por Ω ; es decir,

$$\Omega = \{\text{todos los posibles valores de } \theta\}$$

EJEMPLO 10.2.

En una distribución normal, el espacio del parámetro μ (media de la población) es:

$$\Omega = \{\mu / -\infty < \mu < \infty\}$$

EJEMPLO 10.3.

En una distribución binomial,

$$\Omega = \{p / 0 \leq p \leq 1\}$$

EJEMPLO 10.4.

En una distribución exponencial, el espacio del parámetro θ (media de la población) es:

$$\Omega = \{\theta / \theta > 0\}$$

Al plantear una hipótesis estadística sobre el parámetro de una población, lo que se hace es particionar el espacio Ω en dos subespacios Ω_0 y Ω_1 . Teóricamente, al particionar el espacio del parámetro en dos subespacios, se debe incluir en uno u otro subespacio todos los posibles valores del parámetro, es decir $\Omega_0 \cup \Omega_1 = \Omega$.

EJEMPLO 10.5.

Si en una población normal, hacemos la hipótesis que la media es igual a 20, estamos particionando Ω en dos subespacios:

$$\Omega_0 = \{\mu / \mu = 20\} \quad \Omega_1 = \{\mu / \mu \neq 20\}$$

EJEMPLO 10.6.

En una población binomial, si planteamos la hipótesis de que $p \leq 1/4$ estamos particionando Ω en dos subespacios:

$$\Omega_0 = \{p / p \leq 1/4\} \quad \Omega_1 = \{p / p > 1/4\}$$

Sin embargo, en la práctica no siempre ocurre así, puede suceder que algunos valores del parámetro no tengan importancia para el investigador. Por ejemplo, en el problema planteado sobre la implantación o no del nuevo sistema de propaganda, se está interesado en saber si el nuevo sistema aumenta o no las ventas medias; luego el espacio del parámetro podría reducirse a los valores de la media mayores o iguales a Bs. 200, eliminando por no ser procedentes o relevantes los valores menores a Bs. 200.

EJEMPLO 10.7.

En el ejemplo 10.1. particionamos el espacio Ω en dos subespacios:

$$\Omega_0 = \{\mu/\mu = 200\} \quad \Omega_1 = \{\mu/\mu > 200\}$$

EJEMPLO 10.8.

Si estamos interesados en decidir si la proporción de una población es 0,4 ó 0,6, se podría reducir el espacio del parámetro a $\Omega = \{p/p = 0,4 \text{ ó } p = 0,6\}$ y la partición en los dos subespacios sería:

$$\Omega_0 = \{p/p = 0,4\} \quad \Omega_1 = \{p/p = 0,6\}$$

Una vez particionado el espacio del parámetro, podemos tomar dos posibles acciones, llamémoslas a_0 y a_1 ; a_0 es la acción de decidir que $\theta \in \Omega_0$ y a_1 es decidir que $\theta \in \Omega_1$. En otras palabras, si tomamos la acción a_0 , estamos decidiendo que θ pertenece al subespacio Ω_0 ; si tomamos la acción a_1 , estamos decidiendo que θ es un elemento del espacio Ω_1 .

Es indudable que si $\theta \in \Omega_0$, la acción correcta sería a_0 ; por el contrario, si $\theta \in \Omega_1$, la acción correcta sería a_1 .

En el ejemplo 10.1. la acción a_0 es no implantar el nuevo sistema (suponer que las ventas medias siguen siendo Bs. 200); mientras que la acción a_1 es implantar el nuevo sistema (suponer que las ventas medias son superiores a Bs. 200).

Si $\mu = 200$ $\mu \in \Omega_0$, y la acción correcta es a_0

Si $\mu > 200$ $\mu \in \Omega_1$, y la acción correcta es a_1

El planteamiento de una hipótesis estadística supone de hecho la especificación de dos hipótesis. Una de ellas, conocida como "hipótesis nula" o "hipótesis original" (H_0), corresponde al subconjunto de valores del parámetro Ω_0 , o sea $H_0 : \theta \in \Omega_0$. La otra hipótesis, conocida como "hipótesis alternativa" (H_1), corresponde al subconjunto de valores del parámetro Ω_1 , es decir $H_1 : \theta \in \Omega_1$.

En el ejemplo 10.5 la hipótesis nula será $H_0 : \mu = 20$ y la alternativa $H_1 : \mu \neq 20$. En el ejemplo 10.6, $H_0 : p \leq 1/4$; $H_1 : p > 1/4$. En el ejemplo 10.7, $H_0 : \mu = 200$; $H_1 : \mu > 200$. En el ejemplo 10.8, $H_0 : p = 0,4$; $H_1 : p = 0,6$.

Se presenta entonces el problema de decidir cuál es la hipótesis nula y cuál la alternativa. El calificativo de nula proviene del hecho de que en esta hipótesis, en algún momento se hace cero la diferencia entre el valor del parámetro y el valor planteado en la hipótesis; por ejemplo, $H_0 : p \leq 1/4$, equivale a $H_0 : p - 1/4 \leq 0$ y en el límite de la hipótesis $p - 1/4 = 0$. Esto permite establecer la siguiente regla, que se justificará más adelante: "En la hipótesis nula siempre debe aparecer el signo de igualdad", por ejemplo, $\mu = 200$, $\mu \geq 400$ ó $p \leq 1/4$.

En la terminología estadística generalmente se toma la decisión con respecto a la hipótesis nula; es decir, los resultados muestrales llevan a rechazar o no la hipótesis nula. En este contexto la acción a_0 consiste en no rechazar la hipótesis nula H_0 , mientras que la acción a_1 consiste en rechazar H_0 .

En el ejemplo 10.1 Ω_0 contiene un solo punto ($\mu = 200$), mientras que Ω_1 tiene más de un punto ($\mu > 200$). En este caso $H_0 : \mu = 200$ se conoce como hipótesis simple; mientras que $H_1 : \mu > 200$, se conoce como hipótesis compuesta.

DEFINICION 10.3.

Una hipótesis estadística es una hipótesis simple, si el correspondiente subespacio del parámetro contiene un solo punto; es decir, si especifica un solo valor del parámetro.

Una hipótesis estadística es una hipótesis compuesta si el correspondiente subespacio del parámetro contiene más de un punto; es decir, si la hipótesis especifica más de un valor del parámetro.

De forma que las posibles situaciones de contraste de hipótesis que se pueden plantear son:

H_0 (Hipótesis Nula)	H_1 (Hipótesis Alternativa)
1) Simple	Simple
2) Simple	Compuesta
3) Compuesta	Compuesta
4) Compuesta	Simple

En la práctica, tal como se ha definido la hipótesis nula, el último caso no sucede puesto que ésta siempre lleva el signo igual.

Los tres casos anteriores son los siguientes:

	Hipótesis Nula	Hipótesis Alternativa
1) Simple	$H_0 : \theta = \theta_0$	Simple $H_1 : \theta = \theta_1$
2) Simple	$H_0 : \theta = \theta_0$	Compuesta: a) $H_1 : \theta \neq \theta_0$ b) $H_1 : \theta > \theta_0$ c) $H_1 : \theta < \theta_0$
3) Compuesta	a) $H_0 : \theta \geq \theta_0$ b) $H_0 : \theta \leq \theta_0$	Compuesta: a) $H_1 : \theta < \theta_0$ b) $H_1 : \theta > \theta_0$

Cabe la posibilidad que H_0 sea $\theta_0 \leq \theta \leq \theta_1$ y la alternativa $\theta < \theta_0$ ó $\theta > \theta_1$. Este caso no será tratado en el texto.

EJEMPLO 10.9.

Como ejemplo del primer caso supongamos que sabemos que una determinada población es normal, y tenemos la información que la media es 20 ó 30. En este caso podemos plantear la hipótesis nula $H_0 : \mu = 20$, y la hipótesis alternativa $H_1 : \mu = 30$.

Como ejemplo del caso 2-a.

Supongamos que la productividad media de los trabajadores de una industria es de 400 unidades diarias. Se cambia el proceso de producción y se desea saber si la productividad ha cambiado.

En este caso $H_0 : \mu = 400$; $H_1 : \mu \neq 400$ siendo μ la productividad media con el nuevo proceso.

Caso 2-b.

El ejemplo 10.1 cae dentro de este caso

$$H_0 : \mu = 200 \quad H_1 : \mu > 200$$

Caso 2-c.

El censo de 1961 muestra que la proporción de desempleo en el estado Aragua era 14,2%. Se afirma que debido al desarrollo de la región, ese porcentaje es menor en 1972.

En este caso $H_0 : p = 14,2\%$; $H_1 : p < 14,2\%$

Caso 3-a.

Se desea saber si la proporción de votantes de una población que favorece un determinado proyecto, es el 50% ó más.

$$H_0 : p \geq 0,5 \quad H_1 : p < 0,5$$

Caso 3-b.

Una empresa solicita un crédito a un Banco, y en su solicitud afirma que el porcentaje de cuentas morosas no es mayor que el 10%. El Banco para verificar esa información, hace un estudio estadístico para contrastar la hipótesis de que $p \leq 0,10$.

$$H_0 : p \leq 0,10 \quad H_1 : p > 0,10$$

10.2. CONTRASTE DE HIPOTESIS

Una vez que se han planteado las hipótesis nula y alternativa, se debe decidir de acuerdo con los resultados de una muestra, que acción se va a tomar: a_0 ó a_1 .

Los resultados muestrales obviamente están relacionados con el valor del parámetro sobre el cual se plantean las hipótesis. Puede suceder que los resultados muestrales obtenidos hagan pensar que la hipótesis nula es falsa y en consecuencia, llevan a rechazarla; también puede que los resultados muestrales hagan pensar que la hipótesis nula es verdadera y, por consiguiente, no se pueda rechazar la hipótesis nula.

En este texto, se usarán indistintamente los términos “no se puede rechazar” y “aceptar”, aunque se ha planteado en la teoría estadística que el hecho de que los resultados muestrales no permitan rechazar H_0 , no implica que aceptemos que es verdadera.

Se debe elegir una estrategia o función de decisión que lleve a rechazar o no rechazar la hipótesis nula; es decir, antes de tomar la muestra debe decidirse cuando la hipótesis nula será rechazada y cuando no. Por ejemplo, se puede decidir en el ejemplo 10.1 que se rechazará la hipótesis nula $\mu = 200$, si las ventas medias en una muestra, después de experimentar durante cierto tiempo con el nuevo sistema de propaganda, son mayores que Bs. 205, (si $\bar{x} > 205$).

Al tomar una muestra aleatoria, se está realizando un experimento aleatorio; el espacio muestral de este experimento es el conjunto de todos los posibles puntos muestrales (Ver sección 1.4. Cap. I), siendo cada punto muestral el n-ple formado por los elementos de la muestra. Si $x_1, x_2, \dots, x_n$ son los elementos de una muestra aleatoria de tamaño n , el punto $(x_1, x_2, \dots, x_n)$ es un punto muestral del espacio muestral

n-dimensional de ese experimento. En la práctica, como se dijo antes, las variables aleatorias de la muestra se resumen en un estadístico; en consecuencia, se podría decir que el espacio muestral es el conjunto de posibles valores del estadístico utilizado como estimador. En el ejemplo, el espacio muestral "S" es el conjunto de posibles valores de $\bar{x}$.

La función de decisión o estrategia divide el espacio muestral "S" en dos subconjuntos S_0 y S_1 ; siendo S_0 el conjunto de puntos del espacio muestral que lleva a aceptar la hipótesis H_0 y S_1 el conjunto de puntos muestrales que lleva a rechazar la hipótesis H_0 ; es decir, si el estadístico muestral obtenido $\hat{\theta}$ pertenece a S_0 ($\hat{\theta} \in S_0$), se acepta la hipótesis nula ($H_0: \theta \in \Omega_0$), si $\hat{\theta} \in S_1$, se rechaza la hipótesis nula.

En el ejemplo de las ventas podemos fijar arbitrariamente las siguientes regiones: $S_0 = \{\bar{x}/\bar{x} \leq 205\}$, $S_1 = \{\bar{x}/\bar{x} > 205\}$.

Si las ventas medias de la muestra son menores o iguales a Bs. 205 ($\bar{x} \in S_0$), no rechazamos H_0 ($\mu = 200$), y en consecuencia no se introduce el nuevo sistema de propaganda. Si las ventas medias son mayores que Bs. 205 ($\bar{x} \in S_1$) se rechaza H_0 (se acepta $H_1: \mu > 200$), y se introduce el nuevo sistema de propaganda.

Al seleccionar una función de decisión para decidir si se rechaza o no una hipótesis, se está realizando un contraste de hipótesis.

DEFINICION 10.4.

Un contraste de hipótesis es una función de decisión o estrategia que lleva a aceptar o rechazar la hipótesis nula H_0 .

El subconjunto de puntos del espacio muestral que hacen rechazar la hipótesis nula (S_1) se conoce como "región crítica" o región de rechazo; mientras que el subconjunto de puntos del espacio muestral que conduce a aceptar la hipótesis nula (S_0), se conoce como región de aceptación, y los límites que separan la región crítica y la región de aceptación, se conocen como valores críticos. En el ejemplo, el valor crítico es 205, y la región crítica está formada por los valores de $\bar{x}$ mayores que 205.

Realizar un contraste de hipótesis es equivalente a seleccionar una región crítica. Una vez seleccionada la región crítica, la región de aceptación queda determinada puesto que $S_0 = \bar{S}_1$.

EJEMPLO 10.10.

Según el censo de 1961, el alquiler promedio mensual pagado en Venezuela por viviendas familiares (de menos de Bs. 1.000 mensuales) fue de Bs. 313. Se desea

saber si el alquiler aumentó entre 1961 y 1972. Para ello se tomó la siguiente decisión: Si el alquiler medio resultante de una muestra era mayor de Bs. 315, se acepta que el alquiler se ha incrementado significativamente. Definir el espacio de los parámetros, la hipótesis nula y la alternativa, el espacio muestral, la región crítica y la región de aceptación.

En este ejemplo, el espacio del parámetro es el conjunto de posibles valores del alquiler medio.

$$\Omega = \{\mu/313 \leq \mu \leq 1000\}$$

(Nota: Se está excluyendo por inverosímil la posibilidad de que el alquiler medio haya disminuido).

Los dos subespacios son $\Omega_0 = \{\mu = 313\}$; $\Omega_1 = \{\mu/313 < \mu < 1000\}$. La hipótesis nula a contrastar será:

$$H_0: \mu \in \Omega_0 \text{ o sea } H_0: \mu = 313$$

La hipótesis alternativa

$$H_1: \mu \in \Omega_1 \text{ o sea } H_1: \mu > 313$$

El espacio muestral será el conjunto de todos los posibles valores de $\bar{x}$, siendo $\bar{x}$ el alquiler medio obtenido en la muestra.

$$S = \{\bar{x}/0 \leq \bar{x} \leq 1000\}$$

La región crítica es el conjunto de valores posibles de $\bar{x}$ que nos llevan a rechazar H_0 .

$$S_1 = \{\bar{x}/\bar{x} > 315\}$$

La región de aceptación será:

$$S_0 = \{\bar{x}/\bar{x} \leq 315\}$$

Debe ser obvio que la estrategia establecida en este ejemplo es arbitraria; podría también haberse fijado otra de las infinitas posibles estrategias, por ejemplo si $\bar{x} > 320$ se rechaza H_0 .

10.3. ERRORES TIPO I Y TIPO II

Cuando una hipótesis estadística es rechazada o aceptada con base en los resultados de una muestra, siempre existe la posibilidad de tomar una decisión equivocada. Hay dos

tipos de error que se pueden cometer. Uno es rechazar la hipótesis nula siendo verdadera; otro es aceptar la hipótesis nula siendo falsa. Estos errores reciben el nombre de errores Tipo I y Tipo II respectivamente. Un error Tipo I es el error de rechazar la hipótesis siendo verdadera. Un error Tipo II es aceptar la hipótesis siendo falsa.

EJEMPLO 10.11.

En la continuación del ejemplo 10.1, se ha utilizado la siguiente función de decisión:

Si $\bar{x} > 205$, rechazamos la hipótesis que $\mu = 200$

Si $\bar{x} \leq 205$, aceptamos la hipótesis que $\mu = 200$

Es obvio que $\bar{x}$ puede ser mayor que 205, siendo $\mu = 200$; luego, con esta función de decisión, cabe la posibilidad de rechazar H_0 ($\mu = 200$), cuando en realidad es verdadera. Si $\mu = 200$ y $\bar{x} > 205$, rechazamos H_0 ; es decir, estamos rechazando la hipótesis siendo verdadera, estamos cometiendo un error Tipo I. Por otro lado, también es obvio que $\bar{x}$ puede ser menor o igual que 205 siendo $\mu > 200$; luego, cabe la posibilidad de aceptar H_0 ($\mu = 200$), cuando en realidad es falsa, en este caso cometemos un error Tipo II.

EJEMPLO 10.12.

En el ejemplo 10.10.

$$H_0 : \mu = 313 \quad H_1 : \mu > 313$$

La función de decisión es:

Si $\bar{x} > 315$, rechazamos H_0

Si $\bar{x} \leq 315$, aceptamos H_0

Hay una probabilidad positiva de que $\bar{x} > 315$, siendo $\mu = 313$; luego, hay una probabilidad positiva de rechazar H_0 siendo verdadera, o sea de cometer el error Tipo I. Además hay una probabilidad positiva de que $\bar{x} \leq 315$, siendo $\mu > 313$; es decir, hay una probabilidad positiva de aceptar H_0 , siendo falsa, o sea de cometer el error Tipo II.

Los errores que se pueden cometer, así como las acciones correctas se resumen en la tabla dada a continuación:

Hipótesis \ Decisión	Aceptar H_0 (tomar acción a_0)	Rechazar H_0 (tomar acción a_1)
$H_0 : \theta \in \Omega_0$ Verdadera	Acción Correcta	Error Tipo I
$H_0 : \theta \in \Omega_0$ Falsa	Error Tipo II	Acción Correcta

En el ejemplo 10.11 el cuadro anterior sería:

Hipótesis \ Decisión	Aceptar H_0 Aceptar que $\mu = 200$	Rechazar H_0 Rechazar que $\mu = 200$ (Aceptar que $\mu > 200$)
$H_0 : \mu = 200$ Verdadera	Acción Correcta	Error Tipo I
$H_0 : \mu = 200$ Falsa	Error Tipo II	Acción Correcta

La acción a tomar de aceptar o rechazar la hipótesis nula H_0 , depende de los valores de la muestra aleatoria, de forma que la acción es en sí aleatoria. ¿Con qué probabilidad cometeremos el error Tipo I? es decir, ¿Con qué probabilidad rechazaremos H_0 , siendo verdadera?

Se dijo anteriormente que la función de decisión (contraste de hipótesis) particionaba el espacio muestral en dos subconjuntos, la región crítica y la región de aceptación. Si el estadístico muestral " $\hat{\theta}$ " caía en la región crítica (S_1), se rechazaba H_0 ; luego, la probabilidad de cometer un error Tipo I es:

$$P(I) = P[\hat{\theta} \in S_1 / H_0 \text{ es verdadera}] = P[\hat{\theta} \in S_1 / \theta \in \Omega_0]$$

es decir, la probabilidad de cometer un error Tipo I [representado por $P(I)$] es la probabilidad de que el estadístico muestral caiga en la región crítica, dado que la hipótesis nula es verdadera.

Igualmente, la hipótesis nula se aceptaba si el punto muestral " $\hat{\theta}$ " caía en la región de aceptación (S_0); luego, la probabilidad de cometer un error Tipo II es:

$$P(II) = P[\hat{\theta} \in S_0 / H_0 \text{ es falsa}] = P[\hat{\theta} \in S_0 / \theta \in \Omega_1]$$

es decir, la probabilidad de cometer un error Tipo II [representada por $P(II)$] es la probabilidad de que el estadístico muestral caiga en la región de aceptación, dado que la hipótesis nula es falsa.

Generalmente las probabilidades de errores se representan por $\alpha = P(I)$ y $\beta = P(II)$.

EJEMPLO 10.13.

En el ejemplo que estamos tratando de la implantación del nuevo sistema de propaganda tenemos:

$$H_0: \mu = 200; \quad H_1: \mu > 200$$

La hipótesis nula dice que con el nuevo sistema las ventas medias siguen siendo iguales a Bs. 200. La hipótesis alternativa dice que con el nuevo sistema las ventas medias son mayores que antes.

La función de decisión elegida fue la siguiente: Si las ventas medias de una muestra aleatoria son mayores que Bs. 205, rechazamos H_0 ; si son menores, aceptamos H_0 ; de forma que la región crítica o de rechazo es $S_1 = \{\bar{x}/\bar{x} > 205\}$. Supongamos que conocemos la varianza de la población ($\sigma^2 = 81$), y que la muestra que usamos es de 25 elementos ($n = 25$).

Vamos a calcular las probabilidades de cometer ambos tipos de errores en este contraste de hipótesis.

La probabilidad de cometer un error Tipo I es la probabilidad de rechazar H_0 , siendo verdadera; en este caso, es la probabilidad de que $\bar{x}$ sea mayor que Bs. 205, siendo $\mu = 200$.

$$\alpha = P(I) = P(\bar{x} \in S_1 / \mu = 200) = P(\bar{x} > 205 / \mu = 200)$$

Por el Teorema del Límite Central $\bar{x} \sim N(\mu, \sigma^2/n)$ luego si H_0 es verdadera ($\mu = 200$), $\bar{x} \sim N(200, 81/25)$, en consecuencia,

$$\begin{aligned} \alpha &= P(\bar{x} > 205) = P\left(y \geq \frac{205 - 200}{9/5}\right) = \\ &= P(y \geq 2,78) = 0,0027 \end{aligned}$$

β , o sea la probabilidad de cometer el error Tipo II, aceptar H_0 cuando es falsa dependerá del valor de μ ; si H_0 es falsa, sólo sabemos que $\mu > 200$, pero el cálculo de β exige un valor concreto de μ para poder hallar la probabilidad de que $\bar{x} < 205$. Supongamos que $\mu = 208$. Si $\mu = 208$

$$\begin{aligned} \beta &= P(II) = P(\bar{x} \in S_0 / \mu = 208) = P(\bar{x} \leq 205 / \mu = 208) = \\ &= P\left(y \leq \frac{205 - 208}{9/5}\right) = P(y \leq -1,67) = 0,0475 \end{aligned}$$

Si la media μ es 206, β es mayor

$$\beta = P(\bar{x} \leq 205 / \mu = 206) = P\left(y \leq \frac{205 - 206}{9/5}\right) = P(y \leq -0,56) = 0,2877$$

Consideremos en este ejemplo otro contraste de hipótesis, otra función de decisión: Si las ventas medias son menores que Bs. 203, aceptamos H_0 ; si son mayores que Bs. 203, rechazamos H_0 . En este caso la región crítica es:

$$S_1 = \{\bar{x}/\bar{x} > 203\}$$

y la probabilidad de cometer los errores cambia.

$$\alpha = P(\bar{x} > 203 / \mu = 200) = P(y > 1,66) = 0,0485$$

Si $\mu = 208$,

$$\beta = P(\bar{x} < 203 / \mu = 208) = P(y \leq -2,78) = 0,0027$$

Si $\mu = 206$,

$$\beta = P(\bar{x} < 203 / \mu = 206) = P(y \leq -1,66) = 0,0485$$

Observen que α y β son distintos con este contraste de hipótesis: con el primer contraste, $\alpha = 0,0027$, con el segundo, α es mayor 0,0485; por el contrario β disminuyó: 0,0475 y 0,2877 contra 0,0027 y 0,0485.

EJEMPLO 10.14.

Calcular la probabilidad de cometer los errores tipo I y II en el ejemplo 10.12, sabiendo que $\sigma^2 = 100$, y usando una muestra de tamaño 49.

$$\alpha = P(\bar{x} > 315 / \mu = 313) = P(y > 1,4) = 0,0808$$

Para el cálculo de β , supongamos que $\mu = 318$.

$$\beta = P(\bar{x} < 315 / \mu = 318) = P(y < -2,1) = 0,0179$$

Si usáramos la siguiente función de decisión: se rechaza H_0 cuando $\bar{x} > 317$ y se acepta cuando $\bar{x} < 317$ las probabilidades de cometer los errores serían:

$$\alpha = P(\bar{x} > 317/\mu = 313) = P(y > 2,8) = 0,0026$$

$$\beta = P(\bar{x} < 317/\mu = 318) = P(y < 0,7) = 0,2420$$

α es mayor en el primer caso; pero β es mayor en el segundo caso.

EJEMPLO 10.15.

Se desea contrastar la hipótesis nula de que la media de una población normal es 20, sabiendo que $\sigma = 4$ y empleando una muestra de 9 elementos. Se ha adoptado la siguiente función de decisión. Si la media muestral está entre 18 y 22, se acepta la hipótesis nula; si la media muestral es menor que 18 o mayor que 22, se rechaza la hipótesis nula. Calcular las probabilidades de cometer los errores tipo I y II. (Para calcular este último, supongamos que $\mu = 23$).

$$\text{En este ejemplo } H_0: \mu = 20 \quad H_1: \mu \neq 20$$

La región crítica es:

$$S_1 = \{\bar{x}/\bar{x} < 18 \text{ ó } \bar{x} > 22\}$$

mientras que la región de aceptación es:

$$S_0 = \{\bar{x}/18 \leq \bar{x} \leq 22\}$$

$$\text{Si } H_0 \text{ es verdadera, } \bar{x} \sim N\left(20, \frac{16}{9}\right)$$

$$\alpha = P(I) = P(\bar{x} < 18 \cup \bar{x} > 22/\mu = 20) = P(\bar{x} < 18/\mu = 20) +$$

$$+ P(\bar{x} \geq 22/\mu = 20) = P(y < -1,5) + P(y > 1,5) = 0,1336$$

$$\beta = P(II) = P(18 \leq \bar{x} \leq 22/\mu = 23) = P(-3,75 \leq y \leq -0,75) = 0,2266$$

Consideremos que adoptamos otra función de decisión: Si la media muestral está en 17 y 21, aceptamos H_0 ; si la media muestral es menor que 17 ó mayor que 21, rechazamos H_0 .

Con esta función de decisión los valores críticos son 17 y 21, y la región crítica es $S_1 = \{\bar{x}/\bar{x} < 17 \text{ ó } \bar{x} > 21\}$

$$\alpha = P(\bar{x} < 17 \cup \bar{x} > 21/\mu = 20) = P(y \leq -2,25) + P(y \geq 0,75) = 0,2388$$

$$\beta = P(17 \leq \bar{x} \leq 21/\mu = 23) = P(-4,5 \leq y \leq -1,5) = 0,0668$$

α es mayor mientras que β es menor.

EJEMPLO 10.16.

Un estudio sobre la vivienda en Caracas dio como resultado que el 40% de las viviendas no tienen agua corriente. Sin embargo, otro estudio realizado simultáneamente afirma que es el 25% el porcentaje de viviendas sin agua corriente.

Se desea contrastar la hipótesis nula $H_0: p = 0,4$ contra la hipótesis alternativa $H_1: p = 0,25$. Se adopta la siguiente función de decisión: si la proporción de viviendas que no tienen agua corriente en una muestra aleatoria es menor que 0,30, se rechaza H_0 (se acepta H_1); si es mayor o igual que 0,30, se acepta H_0 . Calcular las probabilidades de cometer los errores, si $n = 100$.

$$S_1 = \{\hat{p}/\hat{p} < 0,3\}$$

Si H_0 es verdadera, $\hat{p}$ es aproximadamente normal, con media $p = 0,4$ y varianza $pq/n = 0,4 \times 0,6/100$.

$$\alpha = P(\hat{p} < 0,3/p = 0,4) = P(y < -2,04) = 0,0207$$

Si H_1 es verdadera, $\hat{p}$ es aproximadamente normal, con media $p = 0,25$ y varianza $pq/n = 0,25 \times 0,75/100$.

$$\beta = P(\hat{p} > 0,3/p = 0,25) = P(y > 1,15) = 0,1251$$

Los ejemplos vistos anteriormente ilustran dos hechos: En primer lugar si comparamos dos contrastes de hipótesis distintos (dos estrategias distintas), el que tiene menor α , tiene mayor β . En segundo lugar, si la hipótesis alternativa es compuesta, el valor de β depende del valor del parámetro.

Estas observaciones se profundizarán en las siguientes secciones; antes de hacerlo, se resumen en una tabla los conceptos hasta ahora vistos.

(1)	(2)	(3)	(4)	(5)
Planteamiento de Hipótesis	Contraste de Hipótesis	Regla de Decisión	Probabilidades	Probabilidad de Errores
$H_0 : \theta \in \Omega_0$	S_0 (Región de Aceptación)	Si $\hat{\theta} \in S_0$ (Aceptamos H_0)	De aceptación $P(\hat{\theta} \in S_0 / \theta)$	$P(\hat{\theta} \in S_0 / \theta \in \Omega_0) = 1 - \alpha$ $P(\hat{\theta} \in S_0 / \theta \in \Omega_1) = \beta$
$H_1 : \theta \in \Omega_1$	S_1 (Región Crítica)	Si $\hat{\theta} \in S_1$ (Rechazamos H_0)	De rechazo $P(\hat{\theta} \in S_1 / \theta)$	$P(\hat{\theta} \in S_1 / \theta \in \Omega_0) = \alpha$ $P(\hat{\theta} \in S_1 / \theta \in \Omega_1) = 1 - \beta$

Primero se plantean las hipótesis nula y alternativa; luego se formula el contraste de hipótesis; es decir, se define la región crítica [Columnas (2) y (3)]. Una vez definida la región crítica, quedan especificadas las probabilidades de aceptación y rechazo de la hipótesis nula. (Columna 4). La probabilidad de aceptación se puede diferenciar en dos casos: 1) probabilidad de aceptar la hipótesis nula, siendo verdadera (probabilidad de tomar la acción correcta); o sea, la probabilidad de que el punto muestral caiga en la región de aceptación ($\hat{\theta} \in S_0$), siendo verdadera la hipótesis nula ($\theta \in \Omega_0$); 2) la probabilidad de aceptar la hipótesis nula, siendo falsa (probabilidad de cometer un error Tipo II), o sea, la probabilidad de que el punto muestral caiga en la región de aceptación ($\hat{\theta} \in S_0$) siendo la hipótesis nula falsa ($\theta \in \Omega_1$).

Similarmente la probabilidad de rechazar la hipótesis nula se diferencia en dos situaciones: 1) la probabilidad de rechazarla, siendo verdadera (error Tipo I) o sea la probabilidad de que el punto muestral caiga en la región crítica ($\hat{\theta} \in S_1$), siendo la hipótesis nula verdadera ($\theta \in \Omega_0$); 2) la probabilidad de rechazarla, siendo falsa (acción correcta); o sea, la probabilidad de que el punto muestral caiga en la región crítica ($\hat{\theta} \in S_1$) siendo la hipótesis falsa ($\theta \in \Omega_1$).

10.4. NIVEL DE SIGNIFICACION, FUNCION CARACTERISTICA DE OPERACION Y FUNCION DE POTENCIA DE UN CONTRASTE.

La probabilidad de cometer el error tipo I (α) se conoce también como "nivel de significación" del contraste. El uso de este término se explica porque en definitiva la hipótesis nula es rechazada, cuando se considera que los resultados obtenidos en la muestra son significativamente diferentes de los resultados que esperaríamos obtener, si la hipótesis fuera verdadera.

El hecho de que los resultados muestrales caigan en la región crítica puede deberse a dos razones: a) que la hipótesis sea falsa, con lo que a priori se espera que el resultado de la muestra nos lleve a rechazarla, b) que siendo la hipótesis verdadera eventualmente los resultados de la muestra nos inclinan a pensar que es falsa. Esto sucede con una probabilidad igual a α . Es decir, la diferencia de los resultados muestrales obtenidos y los esperados si la hipótesis es verdadera es significativa con probabilidad igual a α .

Por ejemplo, si contrastamos la hipótesis de que la media de una población es μ_0 ($H_0 : \mu = \mu_0$), esperaríamos que, si la hipótesis es verdadera, la media muestral esté en las cercanías de μ_0 ; en otras palabras, los valores más probables de la media muestral, son los valores cercanos a μ_0 . Si la media muestral está alejada de esos valores probables, consideramos que la diferencia es suficientemente significativa para determinar que la media de la población no es μ_0 . Esa diferencia significativa sucede con una probabilidad de α , si la hipótesis es verdadera.

En el ejemplo 10.13. se observó que β (la probabilidad de cometer error tipo II) variaba dependiendo del valor alternativo del parámetro. En general, cuando la hipótesis alternativa es compuesta, el valor de β dependerá del valor del parámetro desconocido.

DEFINICION 10.5.

Al contrastar hipótesis sobre el parámetro de una población, la probabilidad de aceptar la hipótesis nula siendo falsa es una función del parámetro. Esta función del parámetro se conoce como Función Característica de Operación del Contraste, y su representación gráfica es la Curva Característica de Operación (Curva OC).

EJEMPLO 10.17.

En el ejemplo 10.13.

$$\beta = P(\bar{x} \leq 205 / \mu > 200) = P\left(y \leq \frac{205 - \mu}{9/5}\right) = F\left[\frac{(205 - \mu) 5}{9}\right]$$

La función característica de operación es $\beta = F\left[\frac{(205 - \mu) 5}{9}\right]$


A continuación se enumeran valores de β para ciertos valores de μ .

μ	$\frac{(205-\mu) 5}{9}$	β
201	2,22	0,9868
202	1,67	0,9525
203	1,11	0,8665
204	0,56	0,7123
205	0	0,5000
206	- 0,56	0,2877
207	- 1,11	0,1335
208	- 1,67	0,0475

Se puede observar que la función característica de operación se va haciendo menor a medida que la media se aleja del valor establecido en la hipótesis nula. Esto es lógico puesto que siendo β la probabilidad de aceptar la hipótesis nula siendo falsa, cuanto "más" falsa sea la hipótesis nula, en este caso cuanto más alejada esté la media de 200, la probabilidad de cometer el error de aceptarla debería ser menor.

En la figura 10.1 está representada gráficamente la función característica de operación de este caso.

FIGURA 10.1



EJEMPLO 10.18.

En el ejemplo 10.14. con la primera función de decisión usada,

$$\beta = P(\bar{x} < 315/\mu > 313) = P\left[y < \frac{(315-\mu) 7}{10}\right] = F\left[\frac{(315-\mu) 7}{10}\right]$$


La función característica de operación es:

$$\beta = F\left[\frac{(315-\mu) 7}{10}\right]$$

cuyos valores para distintos valores de la hipótesis alternativa son:

μ	$\frac{(315-\mu) 7}{10}$	β
314	0,7	0,7580
315	0	0,5000
316	- 0,7	0,2420
317	- 1,4	0,0808
318	- 2,1	0,0179
319	- 2,8	0,0026
320	- 3,5	0,0001
321	- 4,2	0,000

FIGURA 10.2



EJEMPLO 10.19.

En el ejemplo 10.15,


$$\begin{aligned}\beta &= P[18 \leq \bar{x} \leq 22/\mu \neq 20] = \\ &= P\left[\frac{(18 - \mu) 3}{4} \leq y \leq \frac{(22 - \mu) 3}{4}\right] \\ &= F\left[\frac{(22 - \mu) 3}{4}\right] - F\left[\frac{(18 - \mu) 3}{4}\right]\end{aligned}$$

Luego, la función característica de operación es:

$$\beta = F\left[\frac{(22 - \mu) 3}{4}\right] - F\left[\frac{(18 - \mu) 3}{4}\right]$$

μ	16	17	18	19	21	22	23	24	25
β	0,0668	0,2266	0,4987	0,7612	0,7612	0,4987	0,2266	0,0668	0,0122

FIGURA 10.3



La función característica de operación de un contraste (β) trabaja con la región de aceptación, puesto que da la probabilidad de que el punto muestral caiga en la región de aceptación, cuando la hipótesis nula es falsa. El deseo de trabajar únicamente con una región (región crítica) para analizar los contrastes de hipótesis, ha llevado a los estadísticos a trabajar con la cantidad $1 - \beta$ en lugar de β . $1 - \beta$ es la probabilidad de rechazar la hipótesis nula, cuando es falsa; la cantidad $1 - \beta$ es conocida como la "potencia del contraste" y es, por supuesto, una función del parámetro.

DEFINICION 10.6.

Al contrastar una hipótesis sobre el parámetro de una población, la probabilidad de rechazar la hipótesis siendo falsa es una función del parámetro. Esta función $P(\theta)$ se conoce como "Función de Potencia" del contraste.

$$P(\theta) = 1 - \beta = P[\hat{\theta} \in S_1/\theta \in \Omega_1]$$

En palabras, la "función potencia" de un contraste, es la probabilidad de rechazar la hipótesis nula ($\hat{\theta} \in S_1$), cuando es falsa ($\theta \in \Omega_1$).

EJEMPLO 10.20.


La función de potencia correspondiente al ejemplo 10.17 será:

$$P(\mu) = 1 - \beta = 1 - F\left[\frac{(205 - \mu) 5}{9}\right]$$

μ	201	202	203	204	205	206	207	208
$P(\mu)$	0,0132	0,0475	0,1335	0,2877	0,5000	0,7123	0,8665	0,9525

La representación gráfica será :

FIGURA 10.4



Es evidente que la altura de la curva $P(\theta)$ es uno menos la altura de la curva OC.


Se deja como ejercicio para el lector el cálculo y representación gráfica de las funciones de potencia correspondientes a los ejemplos 10.18 y 10.19.

10.5. ELECCION DEL CONTRASTE

Hemos visto que para contrastar una hipótesis nula (H_0), se pueden escoger muchas, en la práctica infinitas, funciones de decisión o contrastes. Indudablemente sería conveniente escoger un contraste que fuera mejor que los otros. El mejor contraste se podría definir como aquel que minimiza las probabilidades de cometer los dos tipos de errores posibles; es decir, el contraste que minimiza simultáneamente α y β .

Los ejemplos 10.13 y 10.14 ilustraron el hecho de que, dado un tamaño de muestra, la relación entre α y β es inversa; si se quiere disminuir la probabilidad de cometer el error Tipo I, necesariamente aumenta la probabilidad de cometer el error Tipo II. Este es así porque α y β dicen relación con la región crítica definida en el contraste; disminuir α equivale a hacer la región crítica más pequeña, y en consecuencia mayor será la región de aceptación por lo que β aumentará. La figura 10.5 muestra gráficamente las afirmaciones anteriores.

FIGURA 10.5.



Queremos contrastar la hipótesis de que la media de una población normal es μ_0 ($H_0: \mu = \mu_0$) contra la hipótesis alternativa que la media es μ_1 , siendo $\mu_1 > \mu_0$ ($H_1: \mu = \mu_1$) y elegimos la siguiente estrategia: Si $\bar{x} > h$, rechazamos H_0 , si $\bar{x} < h$, aceptamos H_0 .

En la figura 10.5 las curvas identificadas como (1) y (2) son las funciones de densidad de $\bar{x}$, cuando $\mu = \mu_0$ y $\mu = \mu_1$ respectivamente; o sea, cuando H_0 es verdadera [curva (1)], y cuando H_0 es falsa [curva (2)].

α será el área de la derecha de h debajo de la curva (1) en la figura 10.5 (área rayada horizontalmente), puesto que esa área representa la probabilidad de que $\bar{x} > h$ siendo μ_0 la media de la población. Por otro lado, β será el área a la izquierda de h debajo de la curva (2) (área rayada verticalmente), ya que esa área representa la probabilidad de que $\bar{x} < h$, siendo μ_1 la media de la población.

Si se quiere hacer α menor, deberemos mover h hacia la derecha (el área rayada horizontalmente se hace menor), con lo cual β se hace mayor.


La imposibilidad de que un contraste minimice simultáneamente α y β , dado el tamaño de la muestra¹⁸, ha hecho acudir a otro principio para elegir el contraste de hipótesis adecuado. Se fija a priori el valor de α ; es decir, se fija la probabilidad máxima de cometer el error Tipo I que se esté dispuesto a aceptar, y entre todos los contrastes que tengan ese valor de α se elige aquel que minimice el valor de β ; o lo que es lo mismo, que maximice $1 - \beta$, para todos los posibles valores alternativos del parámetro. Fijada la probabilidad de cometer un tipo de error, se elige el contraste que minimice, para todos los posibles valores del parámetro, la probabilidad de cometer el otro tipo de error. Los valores de α más usualmente usados en contraste de hipótesis son 0,1 y 0,05, aunque otros valores pueden usarse.

Al fijar el valor de α , automáticamente se está fijando el tamaño de la región crítica, quedando por especificar la situación de esa región crítica. En general pueden darse tres casos: a) que toda la región crítica quede en la parte derecha del espacio muestral; es decir, la región crítica corresponde a valores mayores que un valor dado, b) que toda la región crítica esté situada en la parte izquierda del espacio muestral; es decir, que la región crítica corresponda a valores menores que un valor dado. c) que la región crítica esté parte a la derecha y parte a la izquierda del espacio muestral; es decir, que esté formada por valores mayores que uno dado y menores que otro valor dado. Los tres casos corresponden a tres tipos de contraste de hipótesis conocidos como: a) contraste de una cola por la derecha; b) contraste de una cola por la izquierda y c) contraste de dos colas. En los dos primeros casos las regiones crítica y de aceptación están separadas por un solo valor crítico; mientras que en el tercero, existen dos valores críticos.

En la figura 10.6 están representados los tres tipos de contraste.

¹⁸ α y β podrían hacerse menores simultáneamente incrementando el tamaño de la muestra, lo que normalmente acarrearía mayores costos de muestreo.

FIGURA 10.6



Las curvas en la figura 10.6 representan la función de densidad del estadístico usado como estimador.

El espacio muestral o sea el conjunto de posibles valores del estadístico utilizado, está representado por el eje de abscisas. En la figura (a) dividimos el espacio muestral en dos regiones separadas por el valor "h"; la región crítica a la derecha de h , la región de aceptación a la izquierda de "h", este contraste es un contraste de una cola por la derecha. El contraste de una cola por la izquierda está representado en la figura (b), en la cual la región crítica está situada a la izquierda de "h". El contraste de dos colas se representa en la figura (c) en la que la región crítica está dividida en 2 partes. En los tres casos la probabilidad que el estadístico caiga en la región crítica es α . En el último caso se fijan los valores críticos simétricos por razones similares a las esgrimidas al explicar los intervalos de confianza.

EJEMPLO 10.21.

Si se quiere contrastar la hipótesis de que la media de una población normal es 20, siendo $\sigma = 4$, con una muestra de 9 elementos y un nivel de significación $\alpha = 0,05$, se pueden elegir tres contrastes.

- Rechazar H_0 si $\bar{x} > 22,193$
- Rechazar H_0 si $\bar{x} < 17,807$
- Rechazar H_0 si $\bar{x} > 22,613$ ó $\bar{x} < 17,387$

En los tres contrastes, la probabilidad de rechazar la hipótesis siendo verdadera es $\alpha = 0,05$. En efecto, si H_0 es verdadera,

$$a) P(\bar{x} > 22,193) = P\left[y \geq \frac{(22,193 - 20) \cdot 3}{4}\right] = P(y \geq 1,645) = 0,05$$

$$b) P(\bar{x} < 17,807) = P(y \leq -1,645) = 0,05$$

$$b) P(\bar{x} < 17,387 \text{ ó } \bar{x} > 22,613) = P(y < -1,96) + P(y > 1,96) = 0,05$$

De estos tres tipos de contraste, será mejor, según el principio antes enunciado, aquel que minimice β para todos los valores alternativos de μ , en otras palabras, aquel que maximice la potencia del contraste.

El contraste apropiado para cada caso, depende de cual sea la hipótesis alternativa. Como regla general se puede enunciar la siguiente:

Para contrastar la hipótesis $H_0: \theta = \theta_0$

Si la hipótesis alternativa es $H_1: \theta > \theta_0$, el mejor contraste es el de una cola por la derecha.

Si la hipótesis alternativa es $H_1: \theta < \theta_0$, el mejor contraste es el de una cola por la izquierda.

Si la hipótesis alternativa es $H_1: \theta \neq \theta_0$, el mejor contraste es el de dos colas.

Vamos a comprobar esa regla calculando las potencias de los contrastes del ejemplo 10.21 para cada una de las posibles hipótesis alternativas.

EJEMPLO 10. 22.

Supongamos que en el ejemplo 10.21 la hipótesis alternativa es $\mu > 20$; tenemos:

$$H_0: \mu = 20; \quad H_1: \mu > 20; \quad \alpha = 0,05; \quad n = 9; \quad \sigma = 4$$

a) Si usamos el contraste de una cola por la derecha, el valor crítico es $\bar{x} = 22,193$.

$$\beta = P(\bar{x} < 22,193/\mu > 20) = P\left[y < \frac{(22,193 - \mu) \cdot 3}{4} / \mu > 20\right]$$

$$P(\mu) = 1 - \beta = 1 - P\left[y < \frac{(22,193 - \mu) \cdot 3}{4} / \mu > 20\right] = P\left[y > \frac{(22,193 - \mu) \cdot 3}{4} / \mu > 20\right]$$

μ	21	22	23	24	25	26
$1 - \beta$	0,1867	0,4443	0,7291	0,9131	0,9826	0,9979

b) Si usamos el contraste de una cola por la izquierda, el valor crítico es 17,807.

$$\beta = P(\bar{x} > 17,807/\mu > 20) = P\left[y > \frac{(17,807 - \mu) \cdot 3}{4} / \mu > 20\right]$$

$$P(\mu) = 1 - \beta = 1 - P\left[y > \frac{(17,807 - \mu) \cdot 3}{4} / \mu > 20\right] = P\left[y < \frac{(17,807 - \mu) \cdot 3}{4} / \mu > 20\right]$$

μ	21	22	23	24	25	26
$1 - \beta$	0,0084	0,0008	0	0	0	0

c) Si usamos el contraste de dos colas, los valores críticos son $\bar{x} = 17,387$ y $\bar{x} = 22,613$

$$\beta = P(17,387 < \bar{x} < 22,613/\mu > 20) = P\left[\frac{(17,387 - \mu) \cdot 3}{4} < y < \frac{(22,613 - \mu) \cdot 3}{4} / \mu > 20\right]$$

$$P(\mu) = 1 - \beta = 1 - P\left[\frac{(17,387 - \mu) \cdot 3}{4} < y < \frac{(22,613 - \mu) \cdot 3}{4} / \mu > 20\right]$$


μ	21	22	23	24	25	26
$1 - \beta$	0,1165	0,3231	0,6141	0,8508	0,9633	0,9945

Se observará que la función de potencia es uniformemente mayor con el contraste de una cola por la derecha que con los otros dos.

En la figura 10.7 se representan las funciones de potencia de los 3 tipos de contraste usados para contrastar la hipótesis $H_0: \mu = 20$, contra la hipótesis alternativa $H_1: \mu > 20$.

La curva identificada como A corresponde a la función de potencia del contraste de una cola por la derecha, la B a la función de potencia del contraste de una cola por la izquierda, y la C a la función de potencia del contraste de dos colas.

FIGURA 10.7.



Se observa que la curva A está uniformemente por encima de las otras dos; luego, se ha comprobado en el ejemplo que cuando la hipótesis alternativa es $H_1: \theta > \theta_0$, el mejor contraste, el que maximiza la potencia (minimiza la probabilidad de cometer error Tipo II) es el contraste de una cola por la derecha.

DEFINICION 10.7.

Un contraste que maximiza la función de potencia para todo valor del parámetro se conoce como "uniformemente más potente".

EJEMPLO 10.23.

Supongamos ahora que en el ejemplo 10.21 la hipótesis alternativa es $\mu < 20$; tenemos:

$$H_0: \mu = 20; \quad H_1: \mu < 20; \quad \alpha = 0,05; \quad n = 9; \quad \sigma = 4$$

- a) Si usamos el contraste de una cola por la derecha, el valor crítico es $\bar{x} = 22,193$, la región crítica formada por los valores de $\bar{x}$ mayores que 22,193.

$$\beta = P(\bar{x} < 22,193 / \mu < 20) = P\left[y < \frac{(22,193 - \mu) 3}{4} / \mu < 20\right]$$

$$P(\mu) = 1 - \beta = 1 - P\left[y < \frac{(22,193 - \mu) 3}{4} / \mu < 20\right] = P\left[y > \frac{(22,193 - \mu) 3}{4} / \mu < 20\right]$$

μ	14	15	16	17	18	19
$1 - \beta$	0	0	0	0	0,0008	0,0084

- b) Si usamos el contraste de una cola por la izquierda, el valor crítico es $\bar{x} = 17,807$, la región crítica está formada por los valores de $\bar{x}$ menores que 17,807.

$$\beta = P(\bar{x} > 17,807 / \mu < 20) = P\left[y > \frac{(17,807 - \mu) 3}{4} / \mu < 20\right]$$

$$P(\mu) = 1 - \beta = 1 - P\left[y > \frac{(17,807 - \mu) 3}{4} / \mu < 20\right] = P\left[y < \frac{(17,807 - \mu) 3}{4} / \mu < 20\right]$$

μ	14	15	16	17	18	19
$1 - \beta$	0,9979	0,9826	0,9131	0,7291	0,4443	0,1867

- c) Si usamos el contraste de 2 colas, los valores críticos son $\bar{x} = 17,387$ y $\bar{x} = 22,613$. La región crítica está formada por los valores de $\bar{x}$ mayores que 22,613 y menores que 17,387.


$$\beta = P(17,387 < \bar{x} < 22,613 / \mu < 20) = P\left[\frac{(17,387 - \mu) 3}{4} < y < \frac{(22,613 - \mu) 3}{4} / \mu < 20\right]$$

$$P(\mu) = 1 - \beta = 1 - P\left[\frac{(17,387 - \mu) 3}{4} < y < \frac{(22,613 - \mu) 3}{4} / \mu < 20\right]$$

μ	14	15	16	17	18	19
$1 - \beta$	0,9945	0,9633	0,8508	0,6141	0,3231	0,1165

La representación gráfica de las funciones de potencia, figura 10.8, comprueba que si la hipótesis alternativa es de la forma $H_1: \mu < 20$, el contraste uniformemente más potente es el de una cola por la izquierda. (Curva B.)

FIGURA 10.8.



Veamos ahora el caso cuando la hipótesis alternativa es de la forma: $H_1: \theta \neq \theta_0$, sin especificar si θ es mayor o menor que θ_0 .

EJEMPLO 10.24.

En el ejemplo 10.21 la hipótesis alternativa es ahora $\mu \neq 20$.

$$H_0: \mu = 20; H_1: \mu \neq 20; \alpha = 0,05; n = 9; \sigma = 4$$

- a) Contraste de una cola por la derecha. Valor crítico $\bar{x} = 22,193$.

$$\beta = P(\bar{x} < 22,193 / \mu \neq 20) = P\left[y < \frac{(22,193 - \mu) 3}{4} / \mu \neq 20\right]$$

$$P(\mu) = 1 - \beta = P\left[y > \frac{(22,193 - \mu) 3}{4} / \mu \neq 20\right]$$

μ	14	15	16	17	18	19	21	22	23	24	25	26
$1 - \beta$	0	0	0	0	0,0008	0,0082	0,1867	0,4443	0,7291	0,9131	0,9826	0,9979

- b) Contraste de una cola por la izquierda. Valor crítico $\bar{x} = 17,807$.

$$P(\mu) = 1 - \beta = P\left[y < \frac{(17,807 - \mu) 3}{4} / \mu \neq 20\right]$$

μ	14	15	16	17	18	19	21	22	23	24	25	26
$1 - \beta$	0,9979	0,9826	0,9131	0,7291	0,4443	0,1867	0,0082	0,0008	0	0	0	0


- c) Contraste de dos colas. Valores Críticos $\bar{x} = 17,387$ y $\bar{x} = 22,613$.

$$P(\mu) = 1 - \beta = 1 - P\left[\frac{(17,387 - \mu) 3}{4} < y < \frac{(22,613 - \mu) 3}{4} / \mu \neq 20\right]$$

μ	14	15	16	17	18	19
$1 - \beta$	0,9945	0,9633	0,8508	0,6141	0,3231	0,1165

μ	21	22	23	24	25	26
$1 - \beta$	0,1165	0,3231	0,6141	0,8508	0,9633	0,9945

FIGURA 10.9.



En este caso, cuando la hipótesis alternativa es $H_1: \theta \neq \theta_0$, ninguno de los tres contrastes es uniformemente más potente. A la izquierda de θ_0 , $B > C > A$; mientras que a la derecha, $A > C > B$. En este caso se escoge como contraste más conveniente el contraste de dos colas, porque no sería lógico usar cualquiera de los dos contrastes de una cola cuando no se sabe si θ es mayor o menor que θ_0 , puesto que los valores de θ a la derecha e izquierda de θ_0 llevan a probabilidades muy grandes de cometer el error Tipo II, usando cualquiera de los dos contrastes de una cola. Obsérvese que para valores de μ menores que 20, el contraste de una cola por la derecha haría β muy cercana a uno, lo mismo que el contraste de una cola por la izquierda para valores de μ mayores que 20.

Pareciera entonces más seguro usar el contraste de dos colas de forma de evitar esas grandes probabilidades de cometer el error Tipo II que ofrecen los otros contrastes.

En resumen, para contrastar la hipótesis nula $H_0: \theta = \theta_0$, si la hipótesis alternativa es $H_1: \theta > \theta_0$, se usa el contraste de una cola por la derecha. Si la hipótesis alternativa

es $H_1: \theta < \theta_0$, se usa el contraste de una cola por la izquierda. Si la hipótesis alternativa es $H_1: \theta \neq \theta_0$, se usa el contraste de dos colas.

El mismo criterio se puede aplicar si la hipótesis alternativa es simple. Si $H_1: \theta = \theta_1$ y $\theta_1 > \theta_0$ se usa el contraste de una cola por la derecha, si $\theta_1 < \theta_0$ se usa el contraste de una cola por la izquierda.

Por otro lado, si la hipótesis nula es compuesta de la forma $\theta \leq \theta_0$ ó $\theta \geq \theta_0$, también se usan los contrastes de una cola por la derecha o por la izquierda. En estos casos el nivel de significación (α) está definido como la probabilidad máxima de cometer error Tipo I; y es la probabilidad de que el punto muestral caiga en la región crítica siendo $\theta = \theta_0$. O sea, si se trata de contrastar la hipótesis

$$H_0: \theta \leq \theta_0 \text{ contra } H_1: \theta > \theta_0$$

se usa el contraste de una cola por la derecha como si la hipótesis nula fuera $H_0: \theta = \theta_0$.

Si se trata de contrastar la hipótesis:

$$H_0: \theta \geq \theta_0 \text{ contra } H_1: \theta < \theta_0$$

se usa el contraste de una cola por la izquierda como si la hipótesis nula fuera $H_0: \theta = \theta_0$.

Cuando la hipótesis nula es compuesta la probabilidad de cometer el error Tipo I, dado el valor crítico, es una función del parámetro; en efecto, en un contraste de una cola por la derecha.


$$P(I) = P(\hat{\theta} > h / \mu \leq \mu_0)$$

Esta probabilidad cambia dependiendo del valor de μ ; de todos los valores posibles de esta probabilidad se elige como nivel de significación del contraste, es decir α , aquel para el cual $\mu = \mu_0$; es decir:

$$\alpha = P(\hat{\theta} > h / \mu = \mu_0)$$

Esto implica que α se define ahora como el mayor valor de la probabilidad de cometer el error Tipo I. En efecto, esto se puede observar en la figura 10.10.

FIGURA 10.10



El valor de h se eligió de tal manera que,

$$P(\hat{\theta} > h / \mu = \mu_0) = \alpha$$

Obviamente si μ es menor que μ_0 , la probabilidad de cometer el error Tipo I sería menor que α , puesto que la función de densidad del estadístico se desplazaría hacia la izquierda.

Debe estar claro también que si el valor de α y en consecuencia el valor crítico se relacionan con un valor de μ , digamos μ_1 , menor que μ_0 , la probabilidad de cometer el error Tipo I sería para los valores de μ comprendidos entre μ_1 y μ_0 mayor que el α establecido.

En la tabla dada a continuación se presenta un resumen de los contrastes apropiados para cada tipo de hipótesis nula y alternativa.

H_0	H_1	Tipo de Contraste	Valores Críticos	Región Crítica
1) $\theta = \theta_0$	$\theta > \theta_0$	Una cola por la derecha	h	Valores del estadístico mayores que h .
2) $\theta = \theta_0$	$\theta < \theta_0$	Una cola por la izquierda	h	Valores del estadístico menores que h .
3) $\theta = \theta_0$	$\theta \neq \theta_0$	Dos colas	h_1 h_2	Valores del estadístico menores que h_1 y mayores que h_2 .
4) $\theta = \theta_0$	$\theta = \theta_1$ siendo $\theta_1 > \theta_0$	Igual que el caso 1		
5) $\theta = \theta_0$	$\theta = \theta_1$ siendo $\theta_1 < \theta_0$	Igual que el caso 2		
6) $\theta \leq \theta_0$	$\theta > \theta_0$	Igual que el caso 1		
7) $\theta \geq \theta_0$	$\theta < \theta_0$	Igual que el caso 2		

En todos los casos los valores críticos son escogidos de tal forma que la probabilidad de que el estadístico caiga en la región crítica, siendo la hipótesis nula verdadera, es igual a α .

EJERCICIOS PROPUESTOS

10.1. Determine razonadamente la veracidad o falsedad de las siguientes afirmaciones:

a) Para hacer un contraste de hipótesis sobre un parámetro poblacional, el estadístico utilizado deberá ser un estimador insesgado del parámetro, pues así se conoce la media del estadístico y las correspondientes probabilidades de rechazo y aceptación.

b) La región crítica en un contraste de hipótesis es el conjunto de valores del parámetro que llevan a rechazar la hipótesis nula.

c) En un contraste de una cola por la derecha, la probabilidad de cometer el error Tipo II es la probabilidad de que el estadístico sea menor que el valor crítico siendo la hipótesis alternativa verdadera.

10.2. Determine razonadamente cuál de las respuestas es correcta en:

En un contraste de hipótesis $1 - \alpha$ es la probabilidad de que el estadístico caiga:

- a) En la región crítica siendo H_1 verdadera.
- b) En la región crítica siendo H_1 falsa.
- c) En la región de aceptación siendo H_1 verdadera.
- d) En la región de aceptación siendo H_1 falsa.

Al hacer un contraste de hipótesis se fija como nivel de significación $\alpha = 0,05$. Si H_0 es una hipótesis compuesta, la probabilidad de cometer el error Tipo I es, en todo caso:

- a) $\geq 0,05$
- b) $\leq 0,05$
- c) $= 0,05$
- d) No puede saberse.
- e) Ninguna de las anteriores.

10.3. En el ejercicio 11.15 plantear las hipótesis apropiadas, definiendo con precisión el o los parámetros correspondientes.

10.4. En el ejercicio 11.19 plantear las hipótesis apropiadas, definiendo con precisión el o los parámetros correspondientes.

10.5. En el ejercicio 11.29 plantear las hipótesis apropiadas, definiendo con precisión el o los parámetros correspondientes.

10.6. En el ejercicio 11.30 plantear las hipótesis apropiadas, definiendo con precisión el o los parámetros correspondientes.

- 10.7. En el ejercicio 11.32 plantear las hipótesis apropiadas, definiendo con precisión el o los parámetros correspondientes.
- 10.8. En el ejercicio 11.33 plantear las hipótesis apropiadas, definiendo con precisión el o los parámetros correspondientes.
- 10.9. En el ejercicio 11.37 plantear las hipótesis apropiadas, definiendo con precisión el o los parámetros correspondientes.
- 10.10. En el ejercicio 11.39 plantear las hipótesis apropiadas, definiendo con precisión el o los parámetros correspondientes.
- 10.11. En el ejercicio 11.48 plantear las hipótesis apropiadas, definiendo con precisión el o los parámetros correspondientes.
- 10.12. En el ejercicio 11.51 plantear las hipótesis apropiadas, definiendo con precisión el o los parámetros correspondientes.
- 10.13. Si en el ejercicio 10.8 se establece como valor crítico una proporción del 4 %, calcular la probabilidad de cometer el error Tipo I y 3 valores de la probabilidad de cometer el error Tipo II.
- 10.14. Si en el ejercicio 10.3 se establece como valor crítico un alquiler medio de 307, calcular la probabilidad de cometer el error Tipo I y 3 valores de la probabilidad de cometer el error Tipo II.
- 10.15. Calcular la probabilidad de cometer el error Tipo I y 3 valores de la probabilidad de cometer el error Tipo II en el ejercicio 10.12, si 1,75 es el valor crítico de la diferencia de ventas medias.
- 10.16. Calcular la probabilidad de cometer el error Tipo I y 3 valores de la función de potencia, en el ejercicio 10.4, si los valores críticos de la diferencia de ingresos medios son $\pm 10,28$.

CAPITULO XI

CONTRASTE DE HIPOTESIS


(CONTINUACION)

11.1. CONTRASTE DE HIPOTESIS SOBRE LA MEDIA DE UNA POBLACION

11.1.1. HIPOTESIS NULA $H_0 : \mu \leq \mu_0$ ó $\mu = \mu_0$

HIPOTESIS ALTERNATIVA $H_1 : \mu > \mu_0$ ó $\mu = \mu_1$ SIENDO $\mu_1 > \mu_0$

En este caso sabemos que el contraste más potente es de una cola por la derecha, situando la región crítica en el lado derecho del espacio muestral.



Si la varianza σ^2 de la población es conocida, sabemos que $\bar{x}$ es exacta o aproximadamente normal con media μ y varianza σ^2/n .

Si la hipótesis nula H_0 es verdadera,

$$\bar{x} \sim N\left(\mu_0, \frac{\sigma^2}{n}\right) \text{ y } \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1)$$

Queremos hallar el valor crítico h tal que la probabilidad de que $\bar{x} > h$, siendo H_0 verdadera, sea igual a α .

Tenemos:

$$P\left[\frac{(\bar{x} - \mu_0)\sqrt{n}}{\sigma} > k_\alpha\right] = \alpha$$

$$P\left[\bar{x} > \mu_0 + k_\alpha \frac{\sigma}{\sqrt{n}}\right] = \alpha$$

Luego, el valor crítico h es: $h = \mu_0 + k_\alpha \frac{\sigma}{\sqrt{n}}$; si la media muestral $\bar{x}$ es mayor que h , se rechaza la hipótesis; si $\bar{x}$ es menor, se acepta la hipótesis.

Noten que la probabilidad de rechazar la hipótesis siendo verdadera ($\mu = \mu_0$) (Error Tipo I), es α .

Por otro lado, la probabilidad de aceptar la hipótesis, siendo falsa, es:

$$\beta = P(\bar{x} < h / \mu > \mu_0) = P\left(y < \frac{(h - \mu)\sqrt{n}}{\sigma} / \mu > \mu_0\right)$$

En la práctica se calcula la cantidad $h = \mu_0 + k_\alpha \frac{\sigma}{\sqrt{n}}$. Si la media muestral $\bar{x}$ es mayor que esa cantidad, se rechaza H_0 , si es menor, se acepta H_0 .

Alternativamente, también se puede calcular la cantidad $\frac{(\bar{x} - \mu_0)\sqrt{n}}{\sigma}$. Si esa cantidad es mayor que k_α se rechaza la hipótesis H_0 ; si es menor, se acepta.

EJEMPLO 11.1.

La empresa mencionada en el ejemplo 10.1 decide tomar una muestra aleatoria de las ventas a 100 clientes después de un período de prueba del nuevo sistema de propaganda. Se sabe que la desviación típica de las ventas por cliente es de Bs. 40. Usando un nivel de significación del 5%. ¿Adoptaría Ud. el nuevo sistema de propaganda, si la media de la muestra fue de Bs. 210?

Se trata de determinar si el nuevo sistema de propaganda aumenta las ventas medias por cliente por encima de Bs. 200.

Con $\alpha = 0,05$, hay que contrastar la hipótesis;

$$H_0: \mu = 200 \text{ contra la alternativa } H_1: \mu > 200$$

$$k_\alpha = k_{0,05} = 1,645$$

$$\text{Calculamos } \mu_0 + k_\alpha \frac{\sigma}{\sqrt{n}} = 200 + 1,645 \frac{40}{10} = 206,58$$

$$\bar{x} = 210; \quad h = 206,58; \quad \bar{x} > h$$

Cae en la región crítica, se rechaza H_0 ; en otras palabras, se adopta el nuevo sistema de propaganda.

La probabilidad de cometer el error Tipo II sería:

$$P(\bar{x} < 206,58 / \mu > 200) = P\left(y < \frac{(206,58 - \mu) 10}{40} / \mu > 200\right)$$

$$\text{Si } \mu = 204 \quad \beta = P(y < 0,64) = 0,7389$$

EJEMPLO 11.2.

Se desea contrastar la hipótesis de que la media de una población normal con $\sigma = 2$ es igual a 7, contra la hipótesis alternativa de que es igual a 9, con una muestra de tamaño 25 y un nivel de significación del 1%. Determinar la región crítica y la probabilidad de cometer un error Tipo II.

$$\text{En este caso, } H_0: \mu = 7, \quad H_1: \mu = 9$$

Usamos contraste de una cola por la derecha

$$k_\alpha = k_{0,01} = 2,326$$

$$\text{Calculamos } \mu_0 + k_\alpha \frac{\sigma}{\sqrt{n}} = 7 + 2,326 \frac{2}{5} = 7,9304$$

La región crítica estará formada por los valores de $\bar{x} > 7,9304$. Si la media muestral es mayor que 7,9304, se rechaza la hipótesis.

La probabilidad de cometer un error Tipo II, es la probabilidad de aceptar H_0 siendo falsa; o sea,

$$\beta = P\left(\bar{x} < 7,9304 / \mu = 9\right) = P\left(y < \frac{(7,9304 - 9) 5}{2}\right) =$$

$$= P[y < -2,67] = 0,0038$$

Si no se conoce la varianza de la población, se sabe que, si la hipótesis H_0 es verdadera,

$$\frac{(\bar{x} - \mu_0) \sqrt{n-1}}{s} \sim t(n-1)$$

De donde:

$$P\left[\frac{(\bar{x} - \mu_0) \sqrt{n-1}}{s} > t_\alpha\right] = \alpha$$

$$P\left[\bar{x} > \mu_0 + t_\alpha \frac{s}{\sqrt{n-1}}\right] = \alpha$$

Luego, el valor crítico es $h = \mu_0 + t_\alpha \frac{s}{\sqrt{n-1}}$

Si el tamaño de la muestra es mayor que 31, será:

$$h = \mu_0 + k_\alpha \frac{s}{\sqrt{n-1}}$$

EJEMPLO 11.3.

La política crediticia de un Banco exige que las empresas que solicitan créditos al Banco tengan un promedio de deudas morosas por cliente moroso no mayor de Bs. 500. Para determinar si una empresa cumple con el requisito, se selecciona una muestra aleatoria de 25 clientes morosos. La media de la muestra fue de Bs. 510, con una desviación típica de Bs. 45. ¿Cree Ud. que la empresa cumple el requisito? Use un nivel de significación del 10%.

En este problema se va a contrastar:

$$H_0 : \mu \leq 500 \text{ contra } H_1 : \mu > 500$$

Usaremos el contraste de una cola por la derecha.

$$\mu_0 = 500; s = 45; n = 25; t_\alpha = t_{0,1}(24) = 1,318$$

$$h = \mu_0 + t_\alpha \frac{s}{\sqrt{n-1}} = 500 + 1,318 \frac{45}{\sqrt{24}} = 512,11$$

$\bar{x} = 510$ es menor que el valor crítico 512,11. Luego, no se puede rechazar la hipótesis de que las deudas medias son menores o iguales que Bs. 500. Se acepta que la empresa cumple el requisito.

EJEMPLO 11.4.

Se ha propuesto a una industria un nuevo proceso de producción, que según el oferente hará aumentar la producción media diaria. Para decidir la instalación o no del nuevo proceso, se pone éste a prueba durante un período de 60 días.

La producción media diaria en el período fue de 15 unidades, con una desviación típica de 3 unidades. En el pasado la producción diaria era de 12 unidades promedio. ¿Usando un nivel de significación del 5%. Aceptaría Ud. la afirmación del oferente de que el nuevo proceso representa un mejoramiento en la producción?

$$H_0 : \mu = 12 \quad H_1 : \mu > 12$$

Como no se conoce σ , se usa la t de Student. Sin embargo, en este caso $n = 60$, por lo cual se usa el valor crítico:


$$h = \mu_0 + k_\alpha \frac{s}{\sqrt{n-1}} = 12 + 1,645 \frac{3}{\sqrt{59}} = 12,64$$

La producción media (15) es mayor que el valor crítico 12,64; luego se rechaza H_0 ; se acepta la afirmación de que el nuevo proceso representa un mejoramiento en la producción.

11.1.2. HIPOTESIS NULA $H_0 : \mu \geq \mu_0$ ó $\mu = \mu_0$

HIPOTESIS ALTERNATIVA $H_1 : \mu < \mu_0$ ó $\mu = \mu_1$ siendo $\mu_1 < \mu_0$

En este caso el contraste más potente es el de una cola por la izquierda.



Queremos hallar el valor crítico tal que la probabilidad de que $\bar{x} < h$, siendo H_0 verdadera, sea α .

$$P\left[\frac{(\bar{x} - \mu_0)\sqrt{n}}{\sigma} < -k_\alpha\right] = \alpha \Rightarrow P\left[\bar{x} < \mu_0 - k_\alpha \frac{\sigma}{\sqrt{n}}\right] = \alpha$$

Luego el valor crítico es $h = \mu_0 - k_\alpha \frac{\sigma}{\sqrt{n}}$

Si $\bar{x}$ es menor que $\mu_0 - k_\alpha \frac{\sigma}{\sqrt{n}}$, rechazamos H_0 .

EJEMPLO 11.5.

Un productor de cauchos afirma que sus cauchos duran en promedio 20.000 km. o más. Un distribuidor potencial de los cauchos quiere verificar la afirmación del productor, para lo cual somete 100 cauchos a un experimento. La duración media de los cauchos de la muestra fue de 19.320 km.

Se conoce por experiencia pasada que la desviación típica de la duración de los cauchos producidos en la empresa es de 2.000 km. Contrastar la hipótesis de que la duración promedio es de 20.000 km. o más con un nivel de significación del 2,5%.

$$H_0 : \mu \geq 20.000 \quad H_1 : \mu < 20.000$$

$$k_\alpha = k_{0,025} = 1,96$$

$$h = 20.000 - 1,96 \frac{2.000}{\sqrt{100}} = 19.608$$

$\bar{x} = 19.320$ es menor que $h = 19.608$, luego se rechaza H_0 .

Si la varianza de la población es desconocida, el valor crítico h será aquel para el cual se cumple:

$$P[\bar{x} < h] = \alpha; \text{ o sea,}$$

$$P\left[\frac{(\bar{x} - \mu_0)\sqrt{n-1}}{s} < -t_\alpha\right] = \alpha$$

$$h = \mu_0 - t_\alpha \frac{s}{\sqrt{n-1}}$$

Si $n > 31$

$$h = \mu_0 - k_\alpha \frac{s}{\sqrt{n-1}}$$

EJEMPLO 11.6.

Si en el ejemplo 11.5. no se conoce σ y la desviación típica muestral de los 100 cauchos fue 4.000 km. Contrastar la hipótesis con un nivel de significación del 2,5%.

$$H_0 : \mu \geq 20.000 \quad H_1 : \mu < 20.000$$


$$h = 20.000 - 1,96 \frac{4.000}{\sqrt{99}} = 19.212$$

$\bar{x} > 19.212$ luego no se rechaza H_0 .

11.1.3. HIPOTESIS NULA $H_0 : \mu = \mu_0$

HIPOTESIS ALTERNATIVA $H_1 : \mu \neq \mu_0$

En este caso usaremos el contraste de hipótesis de dos colas; la región crítica estará situada a ambos lados del espacio muestral.



Tenemos que buscar dos números h_1 y h_2 tales que la probabilidad de que $\bar{x}$ sea mayor que h_2 , ó que $\bar{x}$ sea menor que h_1 sea igual a α , o alternativamente, h_1 y h_2 , tales que:

$$P[h_1 \leq \bar{x} \leq h_2 / \mu = \mu_0] = 1 - \alpha$$

Cuando σ^2 es conocida y H_0 es verdadera, tenemos

$$P \left[-k_{\alpha/2} \leq \frac{(\bar{x} - \mu_0) \sqrt{n}}{\sigma} \leq k_{\alpha/2} \right] = 1 - \alpha \Rightarrow$$

$$\Rightarrow P \left[\mu_0 - k_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \bar{x} \leq \mu_0 + k_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right] = 1 - \alpha$$

Luego, los valores críticos son:

$$h_1 = \mu_0 - k_{\alpha/2} \frac{\sigma}{\sqrt{n}} \quad y \quad h_2 = \mu_0 + k_{\alpha/2} \frac{\sigma}{\sqrt{n}}$$

Si $\bar{x} < h_1$ ó $\bar{x} > h_2$, se rechaza la hipótesis H_0 ; si $h_1 < \bar{x} < h_2$, se acepta la hipótesis.

En este caso la probabilidad de aceptar la hipótesis siendo falsa será:

$$\beta = P [h_1 < \bar{x} < h_2 / \mu \neq \mu_0]$$

EJEMPLO 11.7.

Si una máquina está perfectamente ajustada produce repuestos que tienen un diámetro medio de 0,6 cm., con una desviación típica de 0,012 cm. Para comprobar si la máquina sigue ajustada, se toma una muestra aleatoria de 25 repuestos producidos por la máquina, obteniéndose un diámetro medio en la muestra de 0,594 cm. ¿Todavía está la máquina perfectamente ajustada? $\alpha = 0,05$.

$$H_0 : \mu = 0,6 \quad H_1 : \mu \neq 0,6$$

Contraste de dos colas $k_{\alpha/2} = k_{0,025} = 1,96$

$$h_1 = 0,6 - 1,96 \frac{0,012}{5} = 0,5952 \quad h_2 = 0,6 + 1,96 \frac{0,012}{5} = 0,6047$$

$\bar{x} = 0,594$ es menor que h_1 ; luego cae en la región de rechazo. Rechazamos H_0 . Los resultados muestrales nos llevan a rechazar la hipótesis de que la máquina está ajustada.

En el caso de que la varianza de la población es desconocida; si H_0 es verdadera,

$$\frac{(\bar{x} - \mu_0) \sqrt{n-1}}{s} \sim t(n-1)$$

$$P \left[-t_{\alpha/2} \leq \frac{(\bar{x} - \mu_0) \sqrt{n-1}}{s} \leq t_{\alpha/2} \right] = 1 - \alpha$$

$$\Rightarrow P \left[\mu_0 - t_{\alpha/2} \frac{s}{\sqrt{n-1}} \leq \bar{x} \leq \mu_0 + t_{\alpha/2} \frac{s}{\sqrt{n-1}} \right] = 1 - \alpha$$

$$h_1 = \mu_0 - t_{\alpha/2} \frac{s}{\sqrt{n-1}} \quad h_2 = \mu_0 + t_{\alpha/2} \frac{s}{\sqrt{n-1}}$$

Si $\bar{x} < h_1$ ó $\bar{x} > h_2$, rechazamos H_0 ; si $h_1 < \bar{x} < h_2$ aceptamos H_0 .

Cuando la varianza es desconocida, pero los grados de libertad mayores de 30, se usa:

$$h_1 = \mu_0 - k_{\alpha/2} \frac{s}{\sqrt{n-1}} \quad h_2 = \mu_0 + k_{\alpha/2} \frac{s}{\sqrt{n-1}}$$

EJEMPLO 11.8.

Un Instituto dedicado a la financiación de construcción de casas para familias afirma que el precio promedio de las viviendas construidas en Caracas el año 1971 fue de Bs. 70.000. Para contrastar esta afirmación se tomó una muestra aleatoria de 20 contratos de venta en los cuales el precio promedio fue de Bs. 56.000, con una desviación típica de Bs. 9.700. Contrastar con un nivel de significación del 10% si parece razonable la afirmación de que el precio promedio fue de Bs. 70.000.

$$H_0 : \mu = 70.000 \quad H_1 : \mu \neq 70.000$$

$$t_{\alpha/2} = t_{0,05}(19) = 1,729$$

$$h_1 = 70.000 - 1,729 \frac{9.700}{\sqrt{19}} = 66.152,29; \quad h_2 = 70.000 + 1,729 \frac{9.700}{\sqrt{19}} = 73.847,6$$

$\bar{x} = 56.000 < h_1$. Luego se rechaza H_0 . La afirmación de que el precio promedio es Bs. 70.000, no parece razonable.

11.1.4. DETERMINACION DEL TAMAÑO DE LA MUESTRA

Hasta ahora hemos supuesto que conocíamos el tamaño de la muestra en cada contraste de hipótesis.

Un problema interesante en el contraste de hipótesis es la determinación del tamaño de muestra mínimo necesario para contrastar una hipótesis, dados α y β .

Como se mencionó anteriormente, cuando se aumenta el tamaño de la muestra, dado α , β disminuye, es decir, β es una función del tamaño de la muestra. Si bien aumentando el tamaño de la muestra, se logra disminuir la probabilidad de cometer error Tipo II, por otro lado muestras más grandes suponen generalmente mayores costos.


Si determinamos de antemano los valores máximos de α y β , habrá distintos tamaños de muestra que cumplen con esos valores de α y β ; pero deseamos hallar el menor tamaño de la muestra (que supone el menor costo de muestreo) tal que cumpla con las especificaciones dadas de α y β .

Supongamos que queremos contrastar la hipótesis

$$H_0 : \mu \leq \mu_0 \quad H_1 : \mu > \mu_0$$

con un nivel de significación de α , y establecemos que para un valor alternativo de μ , digamos $\mu_1 > \mu_0$ es aceptable cometer un error tipo II con probabilidad igual a β .

Sabemos que en este caso se usa un contraste de una cola por la derecha y que el valor crítico es $h = \mu_0 + k_\alpha \frac{\sigma}{\sqrt{n}}$.



Similarmente, si $\mu = \mu_1$ (H_1 verdadera).

$$\beta = P[\bar{x} < h / \mu = \mu_1] = P\left[\frac{(\bar{x} - \mu_1) \sqrt{n}}{\sigma} < \frac{(h - \mu_1) \sqrt{n}}{\sigma}\right]$$

siendo $\frac{(h - \mu_1) \sqrt{n}}{\sigma} = k_{1-\beta}$ el número que tiene a su izquierda un área igual a β , o sea

$$\text{que } h = \mu_1 + k_{1-\beta} \frac{\sigma}{\sqrt{n}}.$$

luego,

$$\mu_0 + k_\alpha \frac{\sigma}{\sqrt{n}} = \mu_1 + k_{1-\beta} \frac{\sigma}{\sqrt{n}}$$

de donde,

$$n = \left[\frac{(k_\alpha - k_{1-\beta}) \sigma}{\mu_1 - \mu_0} \right]^2$$

EJEMPLO 11.9.

Determinar el tamaño de la muestra en el ejemplo 11.1, si se considera aceptable que $\beta = 0,166$ cuando $\mu = 205$.


En este caso $k_\alpha = k_{0,05} = 1,645$, $k_{1-\beta} = k_{0,834} = -0,97$, $\sigma = 40$, $\mu_0 = 200$, $\mu_1 = 205$.

$$n = \left[\frac{(1,645 + 0,97) 40}{205 - 200} \right]^2 \approx 438$$

Si quisiéramos $\beta = 0,3669$, entonces $k_{1-\beta} = k_{0,6331} = -0,34$, $n \approx 253$.

La misma expresión se aplica si el contraste es de una cola por la izquierda.

$$H_0 : \mu \geq \mu_0 \quad H_1 : \mu < \mu_0$$



Sabemos que $h = \mu_0 - k_\alpha \frac{\sigma}{\sqrt{n}}$

Por otro lado,

$$\beta = P[\bar{x} > h / \mu = \mu_1] = P\left[\frac{(\bar{x} - \mu_1)\sqrt{n}}{\sigma} > \frac{(h - \mu_1)\sqrt{n}}{\sigma}\right]$$

$$\frac{(h - \mu_1)\sqrt{n}}{\sigma} = k_\beta \Rightarrow h = \mu_1 + k_\beta \frac{\sigma}{\sqrt{n}}$$

$$\mu_0 - k_\alpha \frac{\sigma}{\sqrt{n}} = \mu_1 + k_\beta \frac{\sigma}{\sqrt{n}}$$

$$n = \left[\frac{(k_\alpha + k_\beta) \sigma}{(\mu_1 - \mu_0)} \right]^2$$

como $k_\beta = -k_{1-\beta}$, se tiene:

$$n = \left[\frac{(k_\alpha - k_{1-\beta}) \sigma}{\mu_1 - \mu_0} \right]^2$$


Si la hipótesis alternativa es $H_1 : \mu \neq \mu_0$, el tamaño de la muestra se calcula de la forma siguiente:

Determinemos dos valores alternativos de μ , μ_1 y μ_2 , tales que $\mu_1 = \mu_0 - b$ y $\mu_2 = \mu_0 + b$. Es decir, μ_1 y μ_2 se desvían de μ en una misma cantidad b ; y se considera aceptable que si $\mu = \mu_1$ ó $\mu = \mu_2$ la probabilidad de cometer error Tipo II sea β .

Se sabe que $h_1 = \mu_0 - k_{\alpha/2} \frac{\sigma}{\sqrt{n}}$ y $h_2 = \mu_0 + k_{\alpha/2} \frac{\sigma}{\sqrt{n}}$

Supongamos que el valor alternativo de μ es μ_2 .

FIGURA 11.1.



$$h_1 = \mu_0 - k_{\alpha/2} \frac{\sigma}{\sqrt{n}} \quad (3) \quad h_2 = \mu_0 + k_{\alpha/2} \frac{\sigma}{\sqrt{n}} \quad (4)$$

Si la hipótesis alternativa es verdadera, siendo $\mu = \mu_2$.

$$\beta = P[h_1 \leq \bar{x} \leq h_2 / \mu = \mu_2]$$

La probabilidad de que $\bar{x} < h_1$, siendo $\mu = \mu_2$ es, en todos los casos prácticamente cero. [En la figura 11.1 $P(\bar{x} < h_1 / \mu = \mu_2)$ será el área debajo de la curva de la derecha, a la izquierda de h_1] luego, β se puede aproximar por:

$$\beta = P[\bar{x} \leq h_2 / \mu = \mu_2]$$

$$= P\left[\frac{(\bar{x} - \mu_2)\sqrt{n}}{\sigma} < \frac{(h_2 - \mu_2)\sqrt{n}}{\sigma}\right]$$

$$\text{siendo } \frac{(h_2 - \mu_2)\sqrt{n}}{\sigma} = k_{1-\beta} \Rightarrow h_2 = \mu_2 + k_{1-\beta} \frac{\sigma}{\sqrt{n}} \quad (5)$$


De (4) y (5) tenemos:

$$\mu_0 + k_{\alpha/2} \frac{\sigma}{\sqrt{n}} = \mu_2 + k_{1-\beta} \frac{\sigma}{\sqrt{n}}$$

$$n = \left[\frac{(k_{\alpha/2} - k_{1-\beta}) \sigma}{\mu_2 - \mu_0} \right]^2$$

Similarmente, si el valor alternativo de μ es μ_1 .

FIGURA 11.2.



Se deja como ejercicio al lector, comprobar que la expresión para n es la misma.

En definitiva, en el caso de un contraste de hipótesis de dos colas, dados α y β , el menor tamaño de la muestra es:

$$n = \left[\frac{(k_{\alpha/2} + k_{\beta}) \sigma}{\mu_1 - \mu_0} \right]^2$$

EJEMPLO 11.10.

Calcular el tamaño de la muestra necesario en el ejemplo 11.7., si se considera aceptable que $\beta = 0,1251$, cuando el diámetro verdadero de los repuestos es $0,6 \pm 0,007$.

En este caso, $\mu_1 = 0,593$ y $\mu_2 = 0,607$

$$\alpha = 0,05 \quad k_{\alpha/2} = k_{0,025} = 1,96 \quad \beta = 0,1251$$

$$k_{\beta} = k_{0,1251} = 1,15 \quad \sigma = 0,012$$

$$n = \left[\frac{(1,96 + 1,15) 0,012}{0,007} \right]^2 = 29$$

Desafortunadamente, estas fórmulas del tamaño de la muestra exigen el conocimiento de la varianza de la población.

Cuando ésta se desconoce, se puede tomar una pequeña muestra antes del experimento general para estimar σ^2 .

11.2. CONTRASTE DE HIPOTESIS SOBRE LA PROPORCION DE UNA POBLACION

Para contrastar hipótesis sobre la proporción "p" de una población, usamos el hecho de que la proporción muestral $\hat{p}$ es aproximadamente normal con media "p" y varianza $p(1-p)/n$.

11.2.1. HIPOTESIS NULA $H_0 : p \leq p_0$ ó $p = p_0$

HIPOTESIS ALTERNATIVA $H_1 : p > p_0$ ó $p = p_1$, siendo $p_1 > p_0$

Si siguiendo el mismo razonamiento que en la sección 11.1.1., si H_0 es verdadera,

$$\hat{p} \sim N \left[p_0, \frac{p_0(1-p_0)}{n} \right], \text{ luego,}$$

$$\alpha = P \left[\frac{(\hat{p} - p_0)}{\sqrt{p_0(1-p_0)/n}} > k_{\alpha} \right] \Rightarrow$$

$$P \left[\hat{p} > p_0 + k_{\alpha} \sqrt{\frac{p_0(1-p_0)}{n}} \right] = \alpha$$

$$\text{Luego el valor crítico es } h = p_0 + k_{\alpha} \sqrt{\frac{p_0(1-p_0)}{n}}$$

si $\hat{p} > h$, se rechaza H_0 , si $\hat{p} < h$ no se rechaza H_0 .

EJEMPLO 11.11.

Una investigación llevada a cabo por un organismo oficial determinó que el 70% de las personas que estaban sujetos a Impuesto Sobre la Renta, declaraba sus rentas anualmente. Contrastar esta afirmación contra la hipótesis de que la proporción es mayor del 70%, usando un nivel de significación del 5%. En una muestra aleatoria de 100 personas habían declarado el 75%.

$$H_0 : p = 0,7 \quad H_1 : p > 0,7$$

$$k_{0,05} = 1,645$$

$$h = 0,7 + 1,645 \sqrt{\frac{0,7 \cdot 0,3}{100}} = 0,7753$$

$$\hat{p} = 0,75 < h$$

No se puede rechazar la hipótesis de que la proporción de personas que declaran es el 70%.

11.2.2. HIPOTESIS NULA $H_0 : p \geq p_0$ ó $H_0 : p = p_0$

HIPOTESIS ALTERNATIVA $H_1 : p < p_0$ ó $H_1 : p = p_1$, siendo $p_1 < p_0$

Se deja al lector la deducción de que el valor crítico en este contraste es:

$$h = p_0 - k_{\alpha} \sqrt{\frac{p_0(1-p_0)}{n}}$$

Si $\hat{p} < h$, se rechaza H_0 , si $\hat{p} > h$ no se rechaza H_0 .

EJEMPLO 11.12.

Se ha pensado realizar un plebiscito entre los habitantes de una ciudad, para decidir la construcción de una autopista. Si el 60% ó más de la población apoya el proyecto, se construirá la autopista. Si el porcentaje de apoyo es menor del 60%, no se construirá.

Ud. tiene la oportunidad de comprar ahora unos terrenos que se revalorizarán, si la autopista es construida. Para decidir la compra o no de los terrenos se busca información adicional encuestando a 50 personas aleatoriamente. Con un nivel de significación del 5%, ¿compraría Ud. los terrenos, si 23 de las 50 personas encuestadas son partidarias de la construcción de la autopista?

$$H_0 : p \geq 0,6 \quad H_1 : p < 0,6$$

$$k_{\alpha} = k_{0,05} = 1,645$$

$$h = 0,6 - 1,645 \sqrt{\frac{0,6 \cdot 0,4}{50}} = 0,486$$

$$\hat{p} = 23/50 = 0,46 < h, \text{ luego rechazamos } H_0.$$

No se comprarían los terrenos.

11.2.3 HIPOTESIS NULA $H_0 : p = p_0$

HIPOTESIS ALTERNATIVA $H_1 : p \neq p_0$

En este caso los valores críticos serán:

$$h_1 = p_0 - k_{\alpha/2} \sqrt{\frac{p_0(1-p_0)}{n}} \quad \text{y} \quad h_2 = p_0 + k_{\alpha/2} \sqrt{\frac{p_0(1-p_0)}{n}}$$

Se deja como ejercicio al lector la deducción de estos valores críticos.

Si $\hat{p}$ es menor que h_1 ó $\hat{p}$ es mayor que h_2 , se rechaza H_0 ; si $\hat{p}$ está entre h_1 y h_2 , no se rechaza H_0 .

EJEMPLO 11.13.

El porcentaje de desempleados en Venezuela según el censo de 1970 era de 8%. Si una muestra de 2.000 personas en 1971 dio un porcentaje de desempleados del 9%, ¿afirmaría Ud. que el porcentaje de desempleo ha variado de un año a otro? Use un nivel de significación del 5%.

$$H_0 : p = 0,08 \quad H_1 : p \neq 0,08$$

$$k_{\alpha/2} = k_{0,025} = 1,96$$

$$h_1 = 0,08 - 1,96 \sqrt{\frac{0,08 \cdot 0,92}{2.000}} = 0,0681$$

$$h_2 = 0,08 + 1,96 \sqrt{\frac{0,08 \cdot 0,92}{2.000}} = 0,0919$$

$\hat{p} = 9\%$ está entre 6,81% y 9,11%, luego aceptamos H_0 . La proporción de desempleados aparentemente no ha variado.

11.2.4. DETERMINACIÓN DEL TAMAÑO DE LA MUESTRA

Los cálculos de las expresiones para el tamaño de la muestra en los contrastes de proporciones, se dejan como ejercicio al lector.

(Ver Ejercicios 11.1. y 11.14.)

11.3. CONTRASTE DE HIPÓTESIS SOBRE LA DIFERENCIA DE MEDIAS DE DOS POBLACIONES

Uno de los contrastes más usados y de mayor utilidad práctica es el que se realiza sobre la diferencia de las medias de dos poblaciones. Por ejemplo: Se desea verificar estadísticamente si los ingresos medios de los habitantes de Caracas son iguales a los ingresos medios de los habitantes de Maracaibo. En este caso los ingresos de los habitantes de Caracas se pueden considerar como una población estadística, y similarmente los ingresos de los habitantes de Maracaibo.

Para hacer el contraste de la igualdad de los ingresos medios se tomarían dos muestras aleatorias, una de cada población, y con base en la comparación de las medias muestrales decidir sobre las medias de la población.

Al hacer este contraste, estamos decidiendo si los datos de las muestras provienen de poblaciones con la misma media o de poblaciones con distinta media.

11.3.1. HIPOTESIS NULA $H_0: \mu_x = \mu_y$

HIPOTESIS ALTERNATIVA $H_1: \mu_x \neq \mu_y$

Si conocemos las varianzas de las poblaciones, sabemos que:

$$(\bar{x} - \bar{y}) \sim N\left(\mu_x - \mu_y, \frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}\right)$$

Si la hipótesis nula es verdadera $\mu_x - \mu_y = 0$, o sea:

$$(\bar{x} - \bar{y}) \sim N\left(0, \frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}\right)$$

Entonces,

$$P\left[-k_{\alpha/2} \leq \frac{\bar{x} - \bar{y}}{\sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}}} \leq k_{\alpha/2}\right] = 1 - \alpha$$

$$\Rightarrow P\left[-k_{\alpha/2} \sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}} \leq \bar{x} - \bar{y} \leq k_{\alpha/2} \sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}}\right] = 1 - \alpha$$

Los valores críticos serán:

$$h_1 = -k_{\alpha/2} \sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}} \quad \text{y} \quad h_2 = k_{\alpha/2} \sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}}$$

Si $h_1 < \bar{x} - \bar{y} < h_2$, aceptamos H_0 , si $\bar{x} - \bar{y} < h_1$ ó $\bar{x} - \bar{y} > h_2$, rechazamos H_0 .

EJEMPLO 11.14.

Se quiere determinar si los estudiantes diurnos y nocturnos de la Facultad de Ciencias Económicas y Sociales dedican el mismo tiempo a sus estudios. Por

estimaciones anteriores se supone que las varianzas en el tiempo de estudios semanales son 8 y 5 horas respectivamente. Una muestra aleatoria de 100 estudiantes diurnos dio un promedio de 12 horas semanales; mientras que una muestra de 80 estudiantes nocturnos dio un promedio de 9 horas semanales. ¿Con un nivel de significación del 5%, hay una diferencia significativa en las horas estudiadas por cada grupo?

$$H_0: \mu_x = \mu_y \quad H_1: \mu_x \neq \mu_y$$

$$\bar{x} = 12; \quad \bar{y} = 9; \quad \sigma_x^2 = 8; \quad \sigma_y^2 = 5; \quad n_x = 100; \quad n_y = 80$$

$$k_{\alpha/2} = k_{0.025} = 1.96$$

$$h_1 = -1.96 \sqrt{\frac{8}{100} + \frac{5}{80}} = -0.74 \quad h_2 = 1.96 \sqrt{\frac{8}{100} + \frac{5}{80}} = 0.74$$

$\bar{x} - \bar{y} = 3 > h_2$, luego se rechaza H_0 . Hay una diferencia significativa en las horas estudiadas.

Si las varianzas poblacionales son desconocidas, usamos el hecho (Ver Sección 7.5.6.2.) de que $\bar{x} - \bar{y}$ es aproximadamente normal con media $\mu_x - \mu_y$ y varianza $\frac{s_x^2}{n_x - 1} + \frac{s_y^2}{n_y - 1}$.

Los valores críticos serán en este caso:

$$h_1 = -k_{\alpha/2} \sqrt{\frac{s_x^2}{n_x - 1} + \frac{s_y^2}{n_y - 1}} \quad \text{y} \quad h_2 = k_{\alpha/2} \sqrt{\frac{s_x^2}{n_x - 1} + \frac{s_y^2}{n_y - 1}}$$

EJEMPLO 11.15.

Si en el ejemplo anterior, σ_x^2 y σ_y^2 son desconocidas, y los resultados muestrales fueron $s_x^2 = 10$ y $s_y^2 = 4$, determinar si existe diferencia significativa.

$$h_1 = -1.96 \sqrt{\frac{10}{99} + \frac{4}{79}} = -0.7632$$

$$h_2 = 1,96 \sqrt{\frac{10}{99} + \frac{4}{79}} = 0,7632$$

$\bar{x} - \bar{y} = 3 > 0,7632$, luego se rechaza H_0 .

Si las varianzas son desconocidas pero iguales, se sabe que:

$$\frac{(\bar{x} - \bar{y}) - (\mu_x - \mu_y)}{\sqrt{\frac{n_x + n_y}{n_x n_y} \frac{n_x s_x^2 + n_y s_y^2}{n_x + n_y - 2}}} \sim t(n_x + n_y - 2)$$

y si H_0 es verdadera:

$$\frac{(\bar{x} - \bar{y})}{\sqrt{\frac{n_x + n_y}{n_x n_y} \frac{n_x s_x^2 + n_y s_y^2}{n_x + n_y - 2}}} \sim t(n_x + n_y - 2)$$

Los valores críticos serán:

$$h_1 = -t_{\alpha/2} \sqrt{\frac{n_x + n_y}{n_x n_y} \frac{n_x s_x^2 + n_y s_y^2}{n_x + n_y - 2}}$$

$$h_2 = t_{\alpha/2} \sqrt{\frac{n_x + n_y}{n_x n_y} \frac{n_x s_x^2 + n_y s_y^2}{n_x + n_y - 2}}$$

EJEMPLO 11.16.

Dos empresas han hecho ofertas para el suministro de materia prima a una industria. La variable importante técnicamente en cuanto a la calidad de la materia prima es el porcentaje medio que de un cierto elemento contiene la materia prima. Se sabe que la varianza del porcentaje contenido en ambas materias primas es la misma. Se tomaron 15 muestras de cada materia prima con los siguientes resultados porcentuales:

Materia Prima A: % 20, 22, 28, 17, 16, 12, 21, 20, 19, 13, 12, 17, 15, 25, 19.

Materia Prima B: % 26, 25, 15, 18, 22, 20, 19, 22, 23, 25, 24, 23, 18, 21, 13.

¿Hay diferencia significativa en el contenido medio de mineral en las materias primas de ambas empresas? Use un nivel de significación del 10%.

$$H_0 : \mu_x = \mu_y; \quad H_1 : \mu_x \neq \mu_y$$

$$t_{\alpha/2}(28) = t_{0,05}(28) = 1,701; \quad \bar{x} = \frac{\sum x_i}{n_x} = \frac{276}{15} = 18,4; \quad \bar{y} = \frac{\sum y_i}{n_y} = \frac{314}{15} = 20,93$$

$$s_x^2 = \frac{\sum (x_i - \bar{x})^2}{n_x} = \frac{\sum x_i^2}{n_x} - \bar{x}^2 = \frac{5.372}{15} - 338,56 = 19,573$$

$$s_y^2 = \frac{\sum (y_i - \bar{y})^2}{n_y} = \frac{\sum y_i^2}{n_y} - \bar{y}^2 = \frac{6.772}{15} - 438,06 = 13,41$$

$$h_1 = -1,701 \sqrt{\frac{15+15}{15^2} \frac{15 \cdot 19,57 + 15 \cdot 13,41}{28}} = -2,61$$

$$h_2 = 1,701 \sqrt{\frac{15+15}{15^2} \frac{15 \cdot 19,57 + 15 \cdot 13,41}{28}} = 2,61$$

$\bar{x} - \bar{y} = -2,53$; $-2,61 < -2,53$; luego, no se rechaza H_0 , el contenido medio es aparentemente el mismo.

11.3.2. HIPOTESIS NULA $H_0 : \mu_x \leq \mu_y$ ó $\mu_x = \mu_y$ HIPOTESIS ALTERNATIVA $H_1 : \mu_x > \mu_y$

Hay casos en el contraste de hipótesis sobre la igualdad de medias de dos poblaciones, en que la hipótesis alternativa es que una media es mayor que la otra (no solamente diferente). Por ejemplo, si se quiere comprobar que una determinada política económica conlleva un mejoramiento de los ingresos medios de los trabajadores de un sector industrial. En este caso se trata de contrastar la hipótesis $H_0 : \mu_x = \mu_y$ contra la hipótesis $\mu_x > \mu_y$, siendo μ_x los ingresos medios después de la implantación de la política, y μ_y los ingresos medios antes de la implantación de la política.

En este caso se aplicará el contraste de una cola por la derecha, y el valor crítico h será obtenido de la siguiente forma en el caso de que las varianzas sean conocidas.

Si H_0 es verdadera,

$$(\bar{x} - \bar{y}) \sim N\left(0, \frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}\right)$$

luego,

$$P\left[\frac{\bar{x} - \bar{y}}{\sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}}} > k_\alpha\right] = \alpha \Rightarrow$$

$$P\left[\bar{x} - \bar{y} > k_\alpha \sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}}\right] = \alpha$$

Si $\bar{x} - \bar{y}$ es mayor que h , se rechaza H_0 ; si es menor, se acepta.

Se deducen fácilmente los valores críticos de los casos en que las varianzas sean desconocidas; o que sean desconocidas, pero iguales. Los valores críticos serán para estos casos:

$$h = k_\alpha \sqrt{\frac{s_x^2}{n_x - 1} + \frac{s_y^2}{n_y - 1}}$$

y

$$h = t_\alpha \sqrt{\frac{n_x + n_y}{n_x n_y} \frac{n_x s_x^2 + n_y s_y^2}{n_x + n_y - 2}}$$

EJEMPLO 11.17.

Ha sido propuesto un nuevo método para producir cierto artículo. Para comprobar si el nuevo proceso aumenta la duración de los productos, se toma una muestra de 5 unidades de cada método con los siguientes resultados de tiempo de vida útil.

Método Nuevo: 154, 132, 139, 147, 143 días

Método Tradicional: 131, 134, 126, 155, 144 días

Con un nivel de significación del 5%. ¿Hay diferencia significativa en ambos métodos bajo los siguientes supuestos?

- Las varianzas son $\sigma_x^2 = 70$ y $\sigma_y^2 = 95$
- No se conocen las varianzas
- Se estima que las varianzas son iguales

$$H_0 : \mu_x = \mu_y ; H_1 : \mu_x > \mu_y$$

siendo μ_x y μ_y , las duraciones con los métodos nuevo y tradicional respectivamente.

$$\bar{x} = 143; \quad \bar{y} = 138; \quad s_x^2 = 54,8; \quad s_y^2 = 106,8$$

$$k_{0,05} = 1,645$$

$$i) \quad h = 1,645 \sqrt{\frac{70}{5} + \frac{95}{5}} = 9,45$$

$$ii) \quad h = 1,645 \sqrt{\frac{54,8}{4} + \frac{106,8}{4}} = 10,46$$

$$iii) \quad t_{0,05} = 1,860$$

$$h = 1,860 \sqrt{\frac{10}{25} \frac{274 + 534}{8}} = 11,82$$

Bajo los tres supuestos, $\bar{x} - \bar{y} = 5$ es menor que el valor crítico; luego, se acepta la hipótesis H_0 . El nuevo método aparentemente no incrementa la duración media.

Es evidente que el mismo contraste de hipótesis sirve, cuando la hipótesis alternativa es que una media es menor que la otra; es decir, cuando se quiere contrastar: $H_0 : \mu_x \geq \mu_y$ ó $\mu_x = \mu_y$ contra $H_1 : \mu_x < \mu_y$, pues en este caso basta enfocar en forma distinta el contraste. Considerar la población "y" como la población "x" y viceversa. En otras palabras, es indiferente contrastar

$$H_0 : \mu_x \geq \mu_y \text{ contra } H_1 : \mu_x < \mu_y$$

que

$$H_0 : \mu_x \leq \mu_y \text{ contra } H_1 : \mu_x > \mu_y$$

Debe estar claro que este tipo de contraste es válido no sólo cuando en la hipótesis nula se afirma que la diferencia de medias en el límite de la hipótesis es cero, sino también puede aplicarse cuando la diferencia es un número diferente de cero, digamos μ_0 .

En estos casos los valores críticos serían similares tomando en cuenta que el valor de la hipótesis nula que se usa cuando es verdadera no es cero sino μ_0 .

Por ejemplo, si $H_0 : \mu_x - \mu_y \leq \mu_0$ y $H_1 : \mu_x - \mu_y > \mu_0$ el valor crítico será:

$$h = \mu_0 + k_{\alpha} \sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}}$$

De igual forma se podrían deducir los valores críticos para las diferentes situaciones. (Ver ejercicios 11.64 y 11.65).

11.4. CONTRASTE DE HIPOTESIS SOBRE LA DIFERENCIA DE PROPORCIONES DE DOS POBLACIONES

Similarmemente al contraste de hipótesis sobre la diferencia de dos medias poblacionales, pueden realizarse contrastes de hipótesis sobre la igualdad de las proporciones de elementos, que en dos poblaciones tienen determinada característica. Por ejemplo, se puede desear comprobar si la proporción de viviendas que tienen agua corriente en dos barrios son iguales o no. Las técnicas para realizar este tipo de contraste son similares a las de la sección anterior.

11.4.1. HIPOTESIS NULA $H_0 : p_x = p_y$ HIPOTESIS ALTERNATIVA $H_1 : p_x \neq p_y$

Sabemos que si H_0 es verdadera,

$$\hat{p}_x - \hat{p}_y \sim N \left[0, \frac{p_x(1-p_x)}{n_x} + \frac{p_y(1-p_y)}{n_y} \right]$$

luego,

$$P \left[-k_{\alpha/2} < \frac{\hat{p}_x - \hat{p}_y}{\sqrt{\frac{p_x(1-p_x)}{n_x} + \frac{p_y(1-p_y)}{n_y}}} < k_{\alpha/2} \right] = 1 - \alpha$$

$$P \left[-k_{\alpha/2} \sqrt{\frac{p_x(1-p_x)}{n_x} + \frac{p_y(1-p_y)}{n_y}} < \hat{p}_x - \hat{p}_y < k_{\alpha/2} \sqrt{\frac{p_x(1-p_x)}{n_x} + \frac{p_y(1-p_y)}{n_y}} \right] = 1 - \alpha$$

En este caso los valores críticos están en función de p_x y p_y , que son desconocidos. Para resolver este problema se sustituyen en los valores críticos p_x y p_y , por

$$\tilde{p} = \frac{x+y}{n_x + n_y}$$

siendo $\frac{x}{n_x}$ y $\frac{y}{n_y}$ las proporciones muestrales, o sea que $\tilde{p}$ es la proporción de

elementos que en las dos muestras conjuntamente tienen la característica estudiada. Este planteamiento se justifica porque, si la hipótesis nula es verdadera, $p_x = p_y$, y es más razonable usar un único estimador para ambas proporciones que estamos suponiendo son iguales. Los valores críticos serán:

$$h_1 = -k_{\alpha/2} \sqrt{\tilde{p}(1-\tilde{p}) \left(\frac{1}{n_x} + \frac{1}{n_y} \right)}$$

$$h_2 = k_{\alpha/2} \sqrt{\tilde{p}(1-\tilde{p}) \left(\frac{1}{n_x} + \frac{1}{n_y} \right)}$$

EJEMPLO 11.18.

Una muestra aleatoria de 5.000 personas tomada en áreas urbanas, dio una proporción de desempleados del 10%; mientras que una muestra de 3.000 en áreas rurales, dio una proporción de desempleados de 12%. ¿Hay diferencia significativa en la proporción de desempleados en las áreas urbana y rural? Usar un nivel de significación del 1%.

$$H_0 : p_x = p_y \quad H_1 : p_x \neq p_y$$

$$\hat{p}_x = 0,10; \quad \hat{p}_y = 0,12; \quad \tilde{p} = \frac{500 + 360}{8.000} = \frac{860}{8.000} = 0,1075$$

$$k_{0,005} = 2,576$$

$$h_1 = -2,576 \sqrt{0,1075 \cdot 0,8925 \left(\frac{1}{5.000} + \frac{1}{3.000} \right)} = -0,0184$$

$$h_2 = 2,576 \sqrt{0,1075 \cdot 0,8925 \left(\frac{1}{5.000} + \frac{1}{3.000} \right)} = 0,0184$$

$$\hat{p}_x - \hat{p}_y = -0,02 \quad -0,02 < -0,0184$$

Se rechaza H_0 , la proporción de desempleados no es la misma aparentemente.

11.4.2. HIPOTESIS NULA $H_0 : p_x \leq p_y$ ó $p_x = p_y$
HIPOTESIS ALTERNATIVA $H_1 : p_x > p_y$

En el caso de que la hipótesis alternativa sea que la proporción en una población es mayor que en la otra, se usa el contraste de una cola por la derecha.

$$P \left[\frac{\hat{p}_x - \hat{p}_y}{\sqrt{\tilde{p}(1-\tilde{p}) \left(\frac{1}{n_x} + \frac{1}{n_y} \right)}} > k_\alpha \right] = \alpha$$

$$P \left[\hat{p}_x - \hat{p}_y > k_\alpha \sqrt{\tilde{p}(1-\tilde{p}) \left(\frac{1}{n_x} + \frac{1}{n_y} \right)} \right] = \alpha$$

Valor crítico

$$h = k_\alpha \sqrt{\tilde{p}(1-\tilde{p}) \left(\frac{1}{n_x} + \frac{1}{n_y} \right)}$$

EJEMPLO 11.19.

Una empresa de consultoría económica fue encargada de determinar los efectos que sobre la estabilidad en el trabajo de los habitantes de un barrio podría tener un programa de educación de adultos. Un programa piloto fue aplicado. Una muestra de 100 tomada antes del programa dio como resultado que un 60% de los

habitantes cambiaron de empleo en un año. Después del programa, una muestra de 100 dio una proporción de 53%. El informe preparado por la empresa afirma que el programa tiene un efecto beneficioso en la estabilidad del trabajo, y que con el programa se rebajará la inestabilidad. ¿Parece justificable el informe? $\alpha = 0,05$.

Si designamos por p_x la proporción de cambios de empleo después del programa piloto, y p_y la proporción antes,

$$H_0 : p_x = p_y \quad H_1 : p_x < p_y$$

o equivalentemente,

$$H_0 : p_y = p_x \quad H_1 : p_y > p_x$$

$$\hat{p}_y = 0,60 \quad \hat{p}_x = 0,53$$

$$k_{0,05} = 1,645 \quad \tilde{p} = \frac{60+53}{200} = 0,565$$

$$h = 1,645 \sqrt{0,565 \cdot 0,435 \left(\frac{2}{100} \right)} = 0,1153$$

$\hat{p}_y - \hat{p}_x = 0,07 < 0,1153$; luego, aceptamos H_0 . No hay diferencia significativa en los porcentajes.

Podría también plantearse la hipótesis de que la diferencia de proporciones es igual a un valor p_0 . En este caso, la deducción de los valores críticos sería similar al caso de la diferencia de medias que se mencionó antes. Sin embargo, hay que notar que al no ser $p_x = p_y$ en la hipótesis nula no se debe usar $\tilde{p}$ como estimador de p_x y de p_y , sino que se usarán los estimadores $\hat{p}_x$ y $\hat{p}_y$ (ver ejercicio 11.66).

11.5. CONTRASTE DE HIPOTESIS SOBRE LA VARIANZA DE UNA POBLACION NORMAL

Cuando se quiere contrastar hipótesis sobre la varianza de una población normal, se usa el hecho de que:

$$\frac{ns^2}{\sigma^2} \sim \chi^2(n-1)$$

$$11.5.1 \quad H_0 : \sigma^2 = \sigma_0^2 \quad H_1 : \sigma^2 \neq \sigma_0^2$$

Si H_0 es verdadera $ns^2/\sigma_0^2 \sim \chi^2(n-1)$, luego la probabilidad de que ns^2/σ_0^2 esté entre $\chi_{1-\alpha/2}^2$ y $\chi_{\alpha/2}^2$ es $1-\alpha$.

$$P\left[\chi_{1-\alpha/2}^2 < \frac{ns^2}{\sigma_0^2} < \chi_{\alpha/2}^2\right] = 1-\alpha$$

$$P\left[\chi_{1-\alpha/2}^2 \frac{\sigma_0^2}{n} < s^2 < \chi_{\alpha/2}^2 \frac{\sigma_0^2}{n}\right] = 1-\alpha$$

Los valores críticos serán $h_1 = \chi_{1-\alpha/2}^2 \frac{\sigma_0^2}{n}$, $h_2 = \chi_{\alpha/2}^2 \frac{\sigma_0^2}{n}$.

Con un nivel de significación de α , si la varianza muestral s^2 , está entre h_1 y h_2 , se acepta la hipótesis, si no se rechaza.

Similarmente, se puede calcular la cantidad ns^2/σ_0^2 y comprobar si está o no entre $\chi_{1-\alpha/2}^2$ y $\chi_{\alpha/2}^2$.

EJEMPLO 11.20.

Contrastar la hipótesis de que la varianza de una población normal es 2, si en una muestra de 15 elementos la varianza muestral fue 3. $\alpha = 0,05$.

$$\chi_{0,975}^2(14) = 5,63 \quad \chi_{0,025}^2(14) = 26,1$$

$$h_1 = 5,63 \cdot \frac{2}{15} = 0,75 \quad h_2 = 26,1 \cdot \frac{2}{15} = 3,48$$

$s^2 = 3$ está entre h_1 y h_2 luego no se rechaza H_0 .

$$11.5.2. \text{ HIPOTESIS NULA } H_0 : \sigma^2 \leq \sigma_0^2 \quad \text{ó} \quad \sigma^2 = \sigma_0^2$$

$$\text{HIPOTESIS ALTERNATIVA } H_1 : \sigma^2 > \sigma_0^2$$

Si la hipótesis alternativa es $\sigma^2 > \sigma_0^2$, usaremos el contraste de una cola por la derecha.

$$P\left[\frac{ns^2}{\sigma_0^2} > \chi_{\alpha}^2\right] = \alpha \Rightarrow P\left[s^2 > \chi_{\alpha}^2 \frac{\sigma_0^2}{n}\right] = \alpha$$

El valor crítico será $h = \chi_{\alpha}^2 \frac{\sigma_0^2}{n}$. Si s^2 es mayor que h , se rechaza H_0 con un nivel de significación de α .

$$11.5.3. \text{ HIPOTESIS NULA } H_0 : \sigma^2 \geq \sigma_0^2 \quad \text{ó} \quad \sigma^2 = \sigma_0^2$$

$$\text{HIPOTESIS ALTERNATIVA } H_1 : \sigma^2 < \sigma_0^2$$

En este caso,

$$P\left[\frac{ns^2}{\sigma_0^2} < \chi_{1-\alpha}^2\right] = \alpha \Rightarrow P\left[s^2 < \chi_{1-\alpha}^2 \frac{\sigma_0^2}{n}\right] = \alpha$$

El valor crítico es: $h = \chi_{1-\alpha}^2 \frac{\sigma_0^2}{n}$

Si s^2 es menor que h , se rechaza H_0 .

EJEMPLO 11.21.

Contrastar la hipótesis $H_0 : \sigma^2 = 8$ contra la hipótesis $H_1 : s^2 > 8$, si en una muestra de 20 elementos $s^2 = 11$; $\alpha = 0,10$.

Contraste de una cola por la derecha $\chi_{0,1}^2(19) = 27,2$.

$$h = \chi_{\alpha}^2 \frac{\sigma_0^2}{n} = \frac{27,2 \cdot 8}{20} = 10,88$$

$s^2 > 10,88$; se rechaza H_0 .

11.6. CONTRASTE DE HIPOTESIS SOBRE LA IGUALDAD DE VARIANZAS DE DOS POBLACIONES NORMALES.

Dadas dos poblaciones normales, si se quiere contrastar si las varianzas son iguales, sabemos que $\frac{ns^2}{\sigma^2} \sim \chi^2(n-1)$, luego, en la primera población $\frac{n_x s_x^2}{\sigma_x^2} \sim \chi^2(n_x - 1)$;

y en la segunda población $\frac{n_y s_y^2}{\sigma_y^2} \sim \chi^2(n_y - 1)$, siendo s_x^2 y s_y^2 independientes.

En la sección 5.18 vimos que el cociente de χ^2 independientes divididas por sus grados de libertad se distribuía según la distribución F de Snedecor. En consecuencia,

$$\frac{n_x s_x^2 / \sigma_x^2 (n_x - 1)}{n_y s_y^2 / \sigma_y^2 (n_y - 1)} \sim F(n_x - 1) \text{ y } (n_y - 1)$$

Si se contrasta $H_0: \sigma_x^2 = \sigma_y^2$, $H_1: \sigma_x^2 \neq \sigma_y^2$; siendo H_0 verdadera, puesto que $\sigma_x^2 = \sigma_y^2$, se tiene:

$$\frac{n_x s_x^2 (n_y - 1)}{n_y s_y^2 (n_x - 1)} \sim F(n_x - 1) \text{ y } (n_y - 1)$$

Si queremos una probabilidad de rechazarla (siendo verdadera) igual a α , tenemos:

$$P \left[F_{1-\alpha/2} < \frac{n_x s_x^2 (n_y - 1)}{n_y s_y^2 (n_x - 1)} < F_{\alpha/2} \right] = 1 - \alpha$$

Se calcula $\frac{n_x s_x^2 (n_y - 1)}{n_y s_y^2 (n_x - 1)}$; si esa cantidad está entre $F_{1-\alpha/2}$ y $F_{\alpha/2}$ se acepta H_0 ,

si no, se rechaza H_0 .

EJEMPLO 11.22.

En una población se tomó una muestra aleatoria de 21 elementos, siendo $\bar{x} = 200$ y $s_x^2 = 40$. En otra población una muestra aleatoria de 31 elementos dio $\bar{y} = 180$ y $s_y^2 = 30$. ¿Hay una diferencia significativa en las varianzas? $\alpha = 0,05$.

$$H_0: \sigma_x^2 = \sigma_y^2 \quad H_1: \sigma_x^2 \neq \sigma_y^2$$

$$n_x = 21; \quad n_y = 31; \quad s_x^2 = 40; \quad s_y^2 = 30;$$

$$F_{1-\alpha/2} = F_{0,975}(20, 30) = \frac{1}{F_{0,025}(30, 20)} = \frac{1}{2,35} = 0,425$$

$$F_{\alpha/2} = F_{0,025}(20, 30) = 2,20$$

$$\frac{21 \cdot 40 \cdot 30}{31 \cdot 30 \cdot 20} = 1,354$$

$$0,425 < 1,354 < 2,20; \text{ se acepta } H_0.$$

Si se trata de contrastar $H_0: \sigma_x^2 \leq \sigma_y^2$ ó $\sigma_x^2 = \sigma_y^2$ contra $H_1: \sigma_x^2 > \sigma_y^2$.

El contraste se hace de una cola por la derecha.

$$P \left[\frac{n_x s_x^2 (n_y - 1)}{n_y s_y^2 (n_x - 1)} > F_{\alpha} \right] = \alpha$$

Si $\frac{n_x s_x^2 (n_y - 1)}{n_y s_y^2 (n_x - 1)} > F_{\alpha}$, se rechaza H_0 ; si es menor, se acepta.

Si se trata de contrastar $H_0: \sigma_x^2 \geq \sigma_y^2$ ó $\sigma_x^2 = \sigma_y^2$ contra $H_1: \sigma_x^2 < \sigma_y^2$.

Una cola por la izquierda.

$$P \left[\frac{n_x s_x^2 (n_y - 1)}{n_y s_y^2 (n_x - 1)} < F_{1-\alpha} \right] = \alpha$$

Si $\frac{n_x s_x^2 (n_y - 1)}{n_y s_y^2 (n_x - 1)} < F_{1-\alpha}$ se rechaza H_0 ; si es mayor, se acepta H_0 .

EJEMPLO 11.23.

Refiriéndonos al ejercicio 9.65. del Capítulo IX, ¿evidencian los resultados muestrales mejoramiento significativo en la estabilidad de la producción por hora?

$$H_0: \sigma_x^2 = \sigma_y^2 \quad H_1: \sigma_x^2 < \sigma_y^2$$

Donde σ_x^2 es la varianza en la producción del grupo de obreros después de cambiar la jornada, y σ_y^2 es la varianza en el grupo de obreros que no cambió la jornada de trabajo.

$$n_x = 61; \quad n_y = 121; \quad s_x^2 = 5; \quad s_y^2 = 10$$

$$F_{1-\alpha} = F_{0,95}(60, 120) = \frac{1}{F_{0,05}(120, 60)} = \frac{1}{1,47} = 0,6802$$

$$\frac{61 \cdot 5 \cdot 120}{121 \cdot 10 \cdot 60} = 0,504$$

$$0,504 < 0,6802$$

Se rechaza H_0 , hay un mejoramiento significativo en la varianza.

Los contrastes desarrollados en las secciones 11.5, 11.6 son utilizados en la práctica también en los casos en que no sean poblaciones normales.

Es obvio que en el caso de poblaciones finitas y muestreo sin reemplazamiento los valores críticos en todos los casos anteriores son los mismos modificados por el factor de corrección que afecta a la varianza del estadístico muestral usado, como se vio en el Capítulo IX.

Se deja como un importante ejercicio al lector la deducción de los valores críticos en todos los casos anteriores cuando la población es finita y el muestreo es sin reemplazamiento. (Ver ejercicios 11.67, 11.68, 11.69 y 11.70).

EJERCICIOS RESUELTOS

- 11.1 Determinar el tamaño de la muestra para contrastar la hipótesis $p = p_0$ contra la hipótesis alternativa $p > p_0$, si se considera aceptable un error tipo II igual a β , cuando $p = p_1$, $p_1 > p_0$.

Solución:

$$H_0 : p = p_0 \quad H_1 : p > p_0$$

Se trata de un contraste de una cola por la derecha; luego,

$$\alpha = P[\hat{p} > h/p = p_0] = P\left[\frac{\hat{p} - p_0}{\sqrt{\frac{p_0 q_0}{n}}} > \frac{h - p_0}{\sqrt{\frac{p_0 q_0}{n}}}\right]$$

$$\text{Siendo } \frac{h - p_0}{\sqrt{\frac{p_0 q_0}{n}}} = k_\alpha \quad ; \quad h = p_0 + k_\alpha \sqrt{\frac{p_0 q_0}{n}}$$

Por otro lado, cometeremos un error tipo II, cuando $\hat{p}$ sea menor que el valor crítico "h", siendo $p = p_1$.

$$\beta = P[\hat{p} < h/p = p_1] = P\left[\frac{\hat{p} - p_1}{\sqrt{\frac{p_1 q_1}{n}}} < \frac{h - p_1}{\sqrt{\frac{p_1 q_1}{n}}}\right]$$

$$\text{Siendo } \frac{h - p_1}{\sqrt{\frac{p_1 q_1}{n}}} = k_{1-\beta} \quad , \quad h = p_1 + k_{1-\beta} \sqrt{\frac{p_1 q_1}{n}}$$

$$\text{Igualando queda } p_0 + k_\alpha \sqrt{\frac{p_0 q_0}{n}} = p_1 + k_{1-\beta} \sqrt{\frac{p_1 q_1}{n}}$$

$$\text{Despejando: } n = \left[\frac{k_\alpha \sqrt{p_0 q_0} - k_{1-\beta} \sqrt{p_1 q_1}}{p_1 - p_0} \right]^2$$

- 11.2. Se afirma que el precio medio de venta de un cierto artículo no es superior a Bs. 18. El precio medio obtenido en una muestra de 26 automercados fue de Bs. 20, con una desviación típica de Bs. 4. Usando un nivel de significación del 5%, ¿Parece razonable la afirmación?

Solución:

Se trata de contrastar la hipótesis de que el precio es inferior o igual a Bs. 18. Esta será la hipótesis nula; la hipótesis alternativa será que el precio es mayor de Bs. 18.

$$H_0 : \mu \leq 18 \quad ; \quad H_1 : \mu > 18$$

$$n = 26 \quad s = 4$$

$$\text{Si } H_0 \text{ es verdadera } \frac{(\bar{x} - \mu) \sqrt{n-1}}{s} \sim t(n-1)$$

Luego la probabilidad de rechazarla será :

$$\alpha = P \left[\frac{(\bar{x} - \mu_0) \sqrt{n-1}}{s} > t_{\alpha} \right]$$

$$\begin{aligned} \text{El valor crítico será } h &= \mu_0 + t_{\alpha} \frac{s}{\sqrt{n-1}} = 18 + t_{0,05} (25) \frac{4}{5} = \\ &= 18 + 1,708 \frac{4}{5} = 19,36 \end{aligned}$$

$$\text{Siendo } \bar{x} = 20 > 19,36 = h$$

Se rechaza H_0 : la afirmación de que el precio no es superior a Bs. 18 no parece razonable.

- 11.3. Un supermercado tiene ventas promedio diarias por cliente de Bs. 10, con una desviación típica de Bs. 2,50. Después de un proceso especial de propaganda, una muestra aleatoria de 65 clientes reveló que el promedio de ventas diarias por cliente fue Bs. 11,50. Usando un nivel de significación de $\alpha = 0,05$. ¿Es el cambio significativo?

Solución:

Se trata de contrastar la hipótesis de que el promedio de ventas permaneció igual contra la hipótesis alternativa de que aumentó.

$$H_0 : \mu = 10 \quad H_1 : \mu > 10$$

$$\text{Si } H_0 \text{ es verdadera } \frac{(\bar{x} - \mu_0) \sqrt{n}}{\sigma} \sim N(0,1)$$

$$\alpha = P \left[\frac{(\bar{x} - \mu_0) \sqrt{n}}{\sigma} > k_{\alpha} \right]$$

$$\text{El valor crítico es } h = \mu_0 + k_{\alpha} \frac{\sigma}{\sqrt{n}} = 10 + 1,645 \frac{2,5}{\sqrt{65}} = 10,51$$

$$\text{Siendo } \bar{x} = 11,50 > 10,51 = h$$

Se rechaza H_0 . El cambio en las ventas medias es significativo.

- 11.4. Un fabricante de lámparas fluorescentes afirma que sus lámparas duran en promedio por lo menos 1.750 horas. Si en una muestra de 101 lámparas, la duración media fue de 1.618 horas con una desviación típica de 400 horas. ¿Es razonable la afirmación del productor? Use un nivel de significación del 1%.

Solución:

Se trata de contrastar la hipótesis de que la duración promedio es mayor o igual a 1.750 contra la hipótesis alternativa de que la media es menor que 1.750. Contraste de una cola por la izquierda.

$$H_0 : \mu \geq 1.750 \quad H_1 : \mu < 1.750$$

$$n = 101; \quad \bar{x} = 1.618; \quad s = 400$$

$$\text{Si } H_0 \text{ es verdadera, } \frac{(\bar{x} - \mu_0) \sqrt{n-1}}{s} \sim t(n-1)$$

$$P \left[\frac{(\bar{x} - \mu_0) \sqrt{n-1}}{s} < -t_{\alpha} \right] = \alpha$$

$$\text{El valor crítico es } h = \mu_0 - t_{\alpha} \frac{s}{\sqrt{n-1}}$$

Como $n > 30$, aproximamos t_{α} por $k_{\alpha} = k_{0,01} = 2,326$, luego

$$h = 1.750 - 2,326 \frac{400}{\sqrt{100}} = 1.656,96$$

Como $\bar{x} = 1.618$ es menor que $h = 1.656,96$, se rechaza H_0 .

La afirmación del productor no parece razonable.

- 11.5. El incremento medio en un año en el salario de los obreros de una cierta empresa fue de Bs. 0,50 por hora. Una muestra aleatoria de 26 obreros de otra empresa competidora mostró un incremento medio en el mismo año de Bs. 0,45 por hora, con una desviación típica de Bs. 0,10 por hora. ¿Es el incremento medio en la segunda empresa significativamente diferente del de la primera? Use $\alpha = 0,10$.

Solución:

Se trata de contrastar que la media en la segunda población es de Bs. 0,50, contra la hipótesis de que es diferente de Bs. 0,50. Contraste de hipótesis de dos colas.

$$H_0: \mu = 0,50 \quad H_1: \mu \neq 0,50$$

$$n = 26; \quad s = 0,10; \quad \bar{x} = 0,45; \quad t_{0,05}(25) = 1,708$$

$$\text{Si } H_0 \text{ es verdadera } \frac{(\bar{x} - \mu_0) \sqrt{n-1}}{s} \sim t(n-1)$$

$$P \left[-t_{\alpha/2} \leq \frac{(\bar{x} - \mu_0) \sqrt{n-1}}{s} \leq t_{\alpha/2} \right] = 1 - \alpha$$

Los valores críticos son:

$$h_1 = \mu_0 - t_{\alpha/2} \frac{s}{\sqrt{n-1}} = 0,50 - 1,708 \frac{0,10}{5} = 0,4658$$

$$h_2 = \mu_0 + t_{\alpha/2} \frac{s}{\sqrt{n-1}} = 0,50 + 1,708 \frac{0,10}{5} = 0,5341$$

Región crítica $\bar{x} < 0,4658$ ó $\bar{x} > 0,5341$

$\bar{x} = 0,45$ cae en la región crítica; luego, se rechaza H_0 . El incremento medio en los salarios ha sido significativamente diferente en la segunda industria.

- 11.6. La hipótesis $\mu \leq 16$ va a ser contrastada con un nivel de significación de 0,05. ¿Qué tamaño debe tener la muestra para que $\beta = 0,02$, si la muestra está tomada de una población con $\mu = 18$, siendo $\sigma = 2$?

Solución:

$$H_0: \mu \leq 16 \quad H_1: \mu > 16$$

$$\mu_1 = 18 \quad k_{1-\beta} = k_{0,98} = -2,05$$

$$n = \left[\frac{(k_{\alpha} - k_{1-\beta}) \sigma}{\mu_1 - \mu_0} \right]^2 = \left[\frac{(1,645 + 2,05) 2}{2} \right]^2 = 14$$

- 11.7. Una empresa publicitaria afirma que con la publicidad hecha a un cierto producto, la proporción de personas que compra el artículo ha aumentado. Si la proporción de personas que antes compraba el artículo era 32%, y si en una muestra de 50 personas, 20 prefirieron el producto. ¿Es aceptable la afirmación de la empresa?

Use $\alpha = 0,05$. Calcular la probabilidad de cometer el error tipo II, cuando la verdadera proporción difiere en 10 puntos del valor de la hipótesis nula.

Solución:

$$H_0: p = 0,32; \quad H_1: p > 0,32$$

$$\text{Si } H_0 \text{ es verdadera, } \hat{p} \sim N \left(p, \frac{p_0 q_0}{n} \right)$$

$$P \left[\frac{\hat{p} - p_0}{\sqrt{p_0 q_0 / n}} > k_{\alpha} \right] = \alpha$$

El valor crítico es:

$$h = p_0 + k_{0,05} \sqrt{\frac{p_0 q_0}{n}} = 0,32 + 1,645 \sqrt{\frac{0,32 \cdot 0,68}{50}} = 0,4285$$

La región crítica es $\hat{p} > 0,4285$; puesto que $\hat{p} = 0,40$ no se rechaza la hipótesis nula de que la proporción de personas que prefieren el producto no ha cambiado.

La probabilidad de cometer el error de aceptar H_0 , siendo falsa, es:

$$\beta = P[\hat{p} < h/p = 0,42] = P \left[y < \frac{0,4285 - 0,42}{\sqrt{\frac{0,42 \cdot 0,58}{50}}} \right] = 0,5478$$

- 11.8. Una gran empresa está pensando trasladar su fábrica para las afueras de la ciudad. El sindicato aprobará el traslado, si el 90% ó más de los empleados tienen transporte propio. En una muestra de 100 empleados, 80 tenían transporte propio. ¿Aconsejaría Ud. al sindicato aprobar el traslado? Se quiere tener una probabilidad de 0,05 de no aprobar el traslado, cuando de hecho 90% ó más de los empleados tienen transporte propio.

Solución:

$$H_0: p \geq 0,90 \quad H_1: p < 0,90$$

$$\text{Valor crítico } h = p_0 - k_{\alpha} \sqrt{\frac{p_0 q_0}{n}} = 0,90 - 1,645 \sqrt{\frac{0,9 \cdot 0,1}{100}} = 0,8506$$

La región crítica es $\hat{p} < 0,8506$, como $\hat{p} = 0,80$ cae en la región crítica, se rechaza H_0 . El sindicato no debe aprobar el traslado.

- 11.9. Un estudio económico estimó que el 22% de las familias gastaban más del 30% de sus ingresos en alimentación. Para verificar las cifras del estudio, se tomó una muestra aleatoria de 1.000 familias resultando que el 20% de las familias gastaba más del 30% en alimentación. ¿Confirman significativamente los resultados del muestreo la afirmación hecha en el estudio? Use $\alpha = 0,05$.

Solución:

$$H_0 : p = 0,22 \quad H_1 : p \neq 0,22$$

Valores críticos:

$$h_1 = p_0 - k_{\alpha/2} \sqrt{\frac{p_0 q_0}{n}} = 0,22 - 1,96 \sqrt{\frac{0,22 \cdot 0,78}{1.000}} = 0,1943$$

$$h_2 = p_0 + k_{\alpha/2} \sqrt{\frac{p_0 q_0}{n}} = 0,22 + 1,96 \sqrt{\frac{0,22 \cdot 0,78}{1.000}} = 0,2457$$

La región crítica es $\hat{p} < 0,1943$ ó $\hat{p} > 0,2457$. Como $\hat{p} = 0,20$, no se rechaza la hipótesis H_0 . Los datos de la muestra confirman aparentemente los resultados del estudio.

- 11.10. Se desea conocer si existe diferencia en el diámetro medio de las rolineras producidas por una máquina, y en el de las producidas por otra máquina. Se sabe que las varianzas en los diámetros son 1 y 0,8 respectivamente. Una muestra de 20 elementos de la primera máquina dio un diámetro medio de 15 mm., y una muestra de 10 elementos de la segunda máquina dio un diámetro medio de 13,5 mm. Use un nivel de significación del 5%.

Solución:

Si designamos por x e y las variables aleatorias que representan la longitud de los diámetros de las rolineras producidas por la primera y segunda máquina respectivamente, se trata de contrastar.

$$H_0 : \mu_x = \mu_y \quad , \quad H_1 : \mu_x \neq \mu_y$$

Si H_0 es verdadera se tiene que

$$\bar{x} - \bar{y} \sim N\left(0, \frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}\right)$$

$$P\left[-k_{\alpha/2} \leq \frac{\bar{x} - \bar{y}}{\sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}}} \leq k_{\alpha/2}\right] = 1 - \alpha$$

Los valores críticos serán:

$$h_1 = -k_{\alpha/2} \sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}} = -1,96 \sqrt{\frac{1}{20} + \frac{0,8}{10}} = -0,7066$$

$$h_2 = 0,7066$$

La región crítica es $\bar{x} - \bar{y} < -0,7066$ ó $\bar{x} - \bar{y} > 0,7066$; puesto que $\bar{x} - \bar{y} = 15 - 13,5 = 1,5$, se rechaza H_0 , los diámetros medios son significativamente diferentes.

- 11.11. Con los datos del ejercicio 9.55 se desea saber si los resultados de las muestras confirman el hecho de que el nuevo fertilizante es más eficaz que el anterior. Se desea tener una probabilidad de sólo 0,05 de cometer el error de considerar el nuevo fertilizante más eficaz, si de hecho no lo es.

Solución:

Sea μ_x y μ_y los promedios en Tm. por H_a , obtenidos con el nuevo fertilizante y el anterior fertilizante respectivamente.

$$H_0 : \mu_x \leq \mu_y \quad H_1 : \mu_x > \mu_y$$

$$\bar{x} = 182; \quad \bar{y} = 176; \quad s_x^2 = 109,25; \quad s_y^2 = 93,25; \quad \alpha = 0,05$$

$$\begin{aligned} \text{Valor crítico} \quad h &= t_{\alpha} \sqrt{\frac{n_x + n_y}{n_x n_y} \frac{n_x s_x^2 + n_y s_y^2}{n_x + n_y - 2}} \\ &= 1,761 \sqrt{\frac{16 \cdot 8 \cdot 109,25 + 8 \cdot 93,25}{14}} = 9,4715 \end{aligned}$$

La región crítica es $\bar{x} - \bar{y} > 9,4715$

Como $\bar{x} - \bar{y} = 6$ no se rechaza H_0 . Se acepta que el nuevo fertilizante no mejora la producción media.

- 11.12. Un productor de hojillas de afeitar seleccionó aleatoriamente 1.000 personas para usar sus hojillas durante 2 meses, y otras 1.000 personas para usar una marca competidora por el mismo período de tiempo. El promedio de afeitadas por unidad con su marca fue de 2,7, con desviación típica de 1,2. Con la marca competidora fue de 2,1, con desviación típica de 2. De acuerdo con los resultados de la muestra se inició una campaña de propaganda, afirmando que su marca aumentaba el número de afeitadas por hojilla. ¿Opina Ud. que la propaganda era razonable? Use $\alpha = 0,05$

Solución:

$$H_0 : \mu_x = \mu_y \quad H_1 : \mu_x > \mu_y$$

$$\text{Valor crítico } h = k_\alpha \sqrt{\frac{s_x^2}{n_x - 1} + \frac{s_y^2}{n_y - 1}} = 1,645 \sqrt{\frac{1,2^2 + 2^2}{999}} = 0,1214$$

Región crítica $\bar{x} - \bar{y} > 0,1214$, siendo $\bar{x} - \bar{y} = 2,7 - 2,1 = 0,6$ se rechaza H_0 , la campaña de propaganda era razonable.

- 11.13. Un proceso de manufactura produce artículos con un porcentaje de defectuosos de 100 $p_x\%$. Se propone un nuevo proceso para producir los mismos artículos, afirmándose que el porcentaje de defectuosos disminuirá. Si en una muestra de 100 artículos tomados del primer proceso, 20 resultaron defectuosos; y en una muestra de 100 tomados del segundo, 15 resultaron defectuosos. ¿Es correcta la afirmación de que el segundo proceso disminuye el % de defectuosos? Se quiere tener una probabilidad no mayor de 0,10 de aprobar la afirmación, no siendo correcta.

Solución:

Sean 100 $p_x\%$ y 100 $p_y\%$ los porcentajes de defectuosos con el nuevo y antiguo proceso respectivamente. Se quiere tener una probabilidad de 0,10 de rechazar la hipótesis $p_x \geq p_y$ si es verdadera; luego, el contraste es:

El valor crítico será

$$H_0 : p_x \geq p_y \quad H_1 : p_x < p_y$$

$$\hat{p}_x = 0,15; \quad \hat{p}_y = 0,20; \quad \tilde{p} = \frac{20 + 15}{200} = \frac{35}{200}$$

El valor crítico será

$$h = -k_\alpha \sqrt{\tilde{p}(1-\tilde{p}) \left(\frac{1}{n_x} + \frac{1}{n_y} \right)} = -1,28 \sqrt{\frac{35}{200} \frac{165}{200} \frac{2}{100}} = -0,0690$$

La región crítica es $\hat{p}_x - \hat{p}_y = -0,0690$

Como $\hat{p}_x - \hat{p}_y = -0,05 > -0,0690$ no se rechaza H_0 . Los resultados muestrales no permiten afirmar que el nuevo proceso disminuye el porcentaje de defectuosos.

EJERCICIOS PROPUESTOS

- 11.14. Determinar el tamaño de la muestra para contrastar la hipótesis $p = p_0$ contra la hipótesis alternativa $p < p_0$, si se considera aceptable un error tipo II igual a β cuando $p = p_1$, siendo $p_1 < p_0$.
- 11.15. El alquiler medio pagado por vivienda de dos habitaciones en una urbanización de Caracas, era de Bs. 300 en 1965. Una muestra de 226 viviendas en 1972 dio una media de Bs. 315, con una desviación típica de Bs. 64. Usando un nivel de significación de 0,05, ¿Ha aumentado significativamente el alquiler medio en esa urbanización?
- 11.16. Determinar y representar la función de potencia del ejercicio anterior, usando algunos valores de μ correspondientes a la hipótesis alternativa.
- 11.17. Con los datos del ejemplo 9.17. ¿Hay diferencia significativa en los depósitos medios de ambas sucursales? $\alpha = 0,10$.
- 11.18. Determinar y representar la función de potencia del ejercicio anterior, usando algunos valores de $\mu_x - \mu_y$ correspondientes a la hipótesis alternativa.
- 11.19. Una muestra de 150 habitantes de un barrio de Caracas dio unos ingresos medios diarios de Bs. 450, con una desviación típica de Bs. 40. Una muestra de 150 habitantes de otro barrio dio una media de Bs. 443, con una desviación típica de Bs. 50. Con un nivel de significación del 5%. ¿Son los ingresos medios en ambos barrios diferentes?
- 11.20. Una empresa solicita un préstamo a un Banco, y en su solicitud afirma que el promedio por cliente de deudas morosas es de Bs. 200. El Banco considera que si las deudas medias morosas son mayores de Bs. 200, no es conveniente otorgar el

préstamo. Para verificar la afirmación de la empresa, se toman aleatoriamente 25 clientes morosos, dando una media de Bs. 210, con una desviación típica de Bs. 40. Usando un nivel de significación del 5%. ¿Aconsejaría Ud. conceder el préstamo?

11.21. Con los datos del ejercicio 9.32. El empresario decide producir los marcadores, si el costo variable medio de producción es menor o igual a Bs. 3,65. Con $\alpha = 0,05$. ¿Aconsejaría Ud. la producción?

11.22. La empresa del ejercicio 9.36 decide que comprará la materia prima al proveedor, si el precio medio es menor o igual a Bs. 28. ¿Cuál debe ser la decisión? $\alpha = 0,05$

11.23. En el ejercicio 9.39 se considera aceptable que la varianza en el contenido de petróleo de cada barril no sea superior a 0,0004. ¿Opina Ud. que los resultados de la muestra permiten creer que se cumple la condición? $\alpha = 0,05$.

11.24. En el ejercicio 9.52, con un nivel de significación de 0,05. ¿Se puede aceptar que la varianza máxima es 2?

11.25. *Se acepta el rechazo.*

Al lanzar una moneda 500 veces se obtuvieron 300 caras. ¿Opina Ud. que la moneda está bien balanceada? $\alpha = 0,10$.

11.26. Determinar y representar la función de potencia del ejercicio anterior, usando algunos valores de "p" correspondientes a la hipótesis alternativa.

11.27. En el ejercicio 11.10, considere que no se conocen σ_x^2 y σ_y^2 ; pero se supone que son iguales. $s_x^2 = 1,2$ y $s_y^2 = 1,3$.

11.28. Según un contrato un cierto repuesto debe tener un diámetro con una varianza máxima de 15. Se inspecciona una muestra de 20 repuestos, y dio una varianza de 20. ¿Diría Ud. que el repuesto cumple con las especificaciones del contrato? $\alpha = 0,05$.

11.29. En una fábrica de artículos de vidrio las máquinas pueden producir un promedio de 100 artículos por minuto. Se pretende hacer una innovación que aparentemente permitirá mejorar el rendimiento de las máquinas. Se introduce la innovación en 15 máquinas escogidas aleatoriamente, y éstas produjeron un promedio de 110 artículos por minuto, con una desviación típica de 5. ¿Ha aumentado significativamente el rendimiento? Se desea tener una probabilidad de 0,01 de afirmar que ha mejorado el rendimiento, si de hecho no ha mejorado.

11.30. Un organismo afirma que la proporción de agricultores propietarios, ha pasado del 20% existente antes de la Reforma Agraria a un 25%. En una muestra de 400

agricultores, 90 era propietarios. Se desea tener una probabilidad máxima de 0,05 de rechazar la afirmación del organismo, si ésta es verdadera. ¿Considera razonable la afirmación? Calcule la probabilidad de cometer un error tipo II.

11.31. Un productor de boquillas de cigarrillos tiene una propaganda en la que afirma que las boquillas son eficientes en la retención de alquitrán y nicotina para un promedio de 55 cigarrillos. Para confirmar esta propaganda se toma una muestra de 101 boquillas, y dio como resultado que el promedio de cigarrillos en que resultaron eficientes fue de 52, con una desviación típica de 5. ¿Está la compañía usando una propaganda que no se ajusta a la realidad? $\alpha = 0,05$.

11.32. Se desea contrastar la hipótesis de que la proporción de la población activa desocupada es 10%, contra la hipótesis alternativa de que es mayor que 10%. Se desea que la probabilidad de cometer un error tipo I sea de 0,01, y la probabilidad aceptable de cometer un error tipo II es 0,0322, si la verdadera proporción es 0,5. Determinar el tamaño de la muestra.

11.33. Un fabricante de inyectoras desechables debe hacer una negociación con la Cámara de Farmacéuticos. Esta le ha presentado un contrato para la compra de inyectoras en el que se especifica que no se pagará el valor de las inyectoras, si el 15% o más son defectuosas. El fabricante desea que la probabilidad de que no se le pague el contrato sea muy pequeña, digamos 0,001. Para decidir si firma o no el contrato, el fabricante toma una muestra de 100, de las cuales 6 fueron defectuosas. ¿Debe firmar el contrato el fabricante?

11.34. Un técnico de control de calidad está chequeando el peso de cierto producto que debe pesar 30 kgs. Toma una muestra de 11 unidades y las pesa, obteniendo un peso total de 322,3 kgs. con una desviación típica de 1,5 kgs. Con un nivel de significación del 5%. ¿Tiene el producto el peso especificado?

11.35. Una empresa compra ropa de trabajo para sus obreros a una fábrica A; la duración promedio de la ropa es de 6 meses. Otra fábrica B afirma que sus ropas duran más de 6 meses. Suponiendo una desviación típica en la duración de la ropa producida por ambas fábricas de 2,5 meses, establezca una regla de decisión con una muestra de tamaño 25 y $\alpha = 0,05$. Encuentre los valores de β si $\mu = 8$ y $\mu = 7$.

11.36. ¿Una proporción muestral de 0,30 de una muestra de tamaño 900 caerá en la región crítica de un contraste de dos colas de la hipótesis $p = 1/3$, con un nivel de significación del 5%?

11.37. Un industrial afirma que por lo menos el 20% de los consumidores prefieren su producto en lugar de productos competidores. Una muestra de 100 consumidores es tomada aleatoriamente para verificar dicho planteamiento. Con un nivel de

significación del 5%. ¿Qué valor debe tener la proporción muestral para que la afirmación se acepte como correcta? Calcular la probabilidad de cometer error tipo II para la alternativa $p = 0,15$.

- 11.38. Una máquina automática expendedora de refrescos está diseñada para despachar vasos con un contenido promedio de 0,25 litros. Si el contenido promedio es mayor, la empresa pierde; si es menor, puede ser multada. Para verificar que la máquina trabaja correctamente, se obtienen aleatoriamente 10 vasos, dando un promedio de 0,26 litros, con una desviación típica de 0,0012 litros. ¿Hay evidencia suficiente para indicar que la máquina trabaja defectuosamente? $\alpha = 0,05$.
- 11.39. Se está tratando de determinar la conveniencia de la construcción de un hotel en un lugar muy concurrido por turistas. La justificación del proyecto es que se afirma que el 70% ó más de los turistas, pasarían más tiempo en el lugar, si existiera un hotel de categoría. En una muestra de 100 turistas, 62 contestaron afirmativamente al preguntárseles si la existencia de un hotel como el proyectado les haría quedarse más tiempo. Se desea que la probabilidad de no construir el hotel, si en realidad fuese conveniente, sea 0,05. ¿Qué aconsejaría Ud?
- 11.40. Un productor afirma que sus nuevos automóviles recorren en promedio 12 km. o más por litro de gasolina. 28 carros escogidos aleatoriamente promediaron 11 km. por litro, con una desviación típica de 2 km. ¿Es correcta la afirmación del productor? $\alpha = 0,05$.
- 11.41. Se quiere contrastar la hipótesis $\mu = 40$ contra $\mu \neq 40$. Se desea una probabilidad de cometer error tipo I de 0,05; y si la media poblacional difiere en 5 unidades de 40, se considera aceptable una probabilidad de cometer error Tipo II igual 0,0985. Determinar el tamaño de la muestra, si por experiencia pasada se sabe que $\sigma = 15$.
- 11.42. Un estudio de mercado reveló que de 200 hombres 30 fumaban una determinada marca de cigarrillos; y de 200 mujeres 35 fumaban esa marca. ¿Hay diferencia significativa en la proporción de mujeres y hombres que prefieren esa marca? $\alpha = 0,05$.
- 11.43. Un estudio de mercados reveló que 100 personas de Maracaibo gastaban en gasolina en promedio Bs. 3 diarios. En Caracas el consumo promedio de 100 personas fue de Bs. 5 diarios. Las desviaciones típicas muestrales fueron Bs. 1 y Bs. 1,50 respectivamente. ¿Son diferentes los mercados de Maracaibo y Caracas en cuanto al consumo de gasolina? $\alpha = 0,05$.
- 11.44. Se afirma que el 40% de todos los estudiantes que se inscriben en la Universidad, abandona sus estudios antes de terminar su carrera. Contraste esta hipótesis contra la alternativa de que el porcentaje es mayor del 40%. De una muestra aleatoria de 300 estudiantes inscritos en la Universidad, 130 abandonaron sus estudios. Use un nivel de significación del 5%.

11.45. En un Banco se obtuvieron los siguientes datos: en una muestra de 500 cuenta correntistas que habían declarado ingresos mensuales superiores a Bs. 3.000, 50 se sobregiraron durante el año. En una muestra de 400 con ingresos mensuales menores de Bs. 3.000, 45 se sobregiraron en el mismo período. Use $\alpha = 0,05$ para verificar si hay diferencia significativa en la proporción de sobregirados de uno y otro tipo.

11.46. Los envases de cierto alimento tienen una etiqueta "Peso Neto 500 gr.". Una muestra aleatoria de 26 latas dio un peso medio de 495 gr., con una desviación típica de 10 gr. ¿Permite esta información afirmar que las latas no cumplen la especificación? $\alpha = 0,01$.

11.47. Se sabe que los automóviles usados por los vendedores de una compañía de seguros recorren en promedio anualmente μ km., con una desviación típica de 5.000 km. Contraste la hipótesis $\mu = 20.000$ con un nivel de significación de 0,05, si una muestra aleatoria de 50 automóviles dio un recorrido medio de 21.500 km.

11.48. Una fábrica produce piezas diseñadas para durar por lo menos 18 meses bajo condiciones normales de uso. La variación en la duración, medida por la desviación típica, es estable; y en base a miles de piezas se ha establecido que es 3,6 meses. Una muestra de 400 piezas tomadas aleatoriamente de la producción, fue sometida a un experimento en condiciones tales, que un día de duración en el experimento equivale a un mes de duración en condiciones normales. La duración media fue de 16,5 días. ¿Están produciéndose las piezas de acuerdo con los requerimientos de duración? $\alpha = 0,10$.

11.49. Se ha afirmado que debido a la política proteccionista los precios de un determinado artefacto eléctrico han tenido un incremento medio del 20%. Una muestra de 45 marcas y modelos del artefacto dio un incremento del precio del 21%, con una desviación típica del 3%. Use un contraste de dos colas para contrastar la hipótesis que el incremento medio es del 20%. Use $\alpha = 0,05$ y $\alpha = 0,01$. ¿Las conclusiones en ambos contrastes son iguales? Explique el significado.

11.50. En el examen de admisión de la Escuela de Economía los resultados de una muestra aleatoria fueron los siguientes:

	Nota Promedio	s	n
Bachilleres en Ciencias	13	1,5	15
Bachilleres en Letras	11	1,7	13

Suponiendo que $\sigma_x^2 = \sigma_y^2 = \sigma^2$. ¿Hay diferencia significativa en los resultados del examen en uno y otro tipo de bachiller? $\alpha = 0,05$.

11.51. La gerencia de una cadena de supermercados se ha propuesto elevar el consumo promedio semanal por cliente en sus automercados. Para hacerlo se considera que una política de rebajas en ciertos artículos incrementarán el consumo total medio. Para experimentar el método se escogen dos automercados en los cuales las ventas por cliente en el pasado, eran prácticamente iguales, con una desviación típica de Bs. 15. En uno de ellos no se experimenta el método y en una muestra de 400 clientes las ventas medias fueron de Bs. 125. En el otro, donde se experimentó el método, en una muestra de 400 clientes las ventas medias fueron de Bs. 130. ¿Opina Ud. que el método es eficiente? $\alpha = 0,05$

11.52. Para experimentar un nuevo fertilizante se divide una parcela en 50 secciones iguales. Aleatoriamente se usó el nuevo fertilizante en 25 secciones, dando un resultado de 500 kgs. de producto en promedio, con una desviación típica de 40 kg. En las otras 25 secciones se usó el antiguo fertilizante con un resultado promedio de 485 kgs., y una desviación típica de 45 kgs. ¿Representa el nuevo fertilizante una mejora en el rendimiento? $\alpha = 0,05$

11.53. En un estudio económico se trata de determinar si los proyectos industriales textiles generan un mayor empleo que los proyectos en industrias de manufactura de muebles.

Una muestra tomada de 16 industrias textiles, indicó que los nuevos empleos por cada millón de bolívares de inversión fueron 400, con desviación típica de 20. En una muestra de 14 industrias de muebles se generaron 380 empleos por cada millón de bolívares invertidos, con desviación típica de 18. Suponiendo $\sigma_x^2 = \sigma_y^2 = \sigma^2$ el estudio concluyó que los proyectos textiles generaban un 6% más de empleos que los otros. ¿Se justifica la conclusión? ¿Podría ser rechazada la hipótesis de igualdad de la creación media de empleos con $\alpha = 0,05$?

11.54. Determinar el tamaño de la muestra y el valor crítico que debe usarse en el ejercicio 11.15, si se introduce la hipótesis alternativa $\mu = 310$, y se desea $\beta = 0,10$. Suponga que $\sigma = 64$.

11.55. Determinar el tamaño de la muestra y el valor crítico en el ejercicio 11.4, si se introduce la hipótesis alternativa $\mu = 1.700$, y se desea $\beta = 0,0119$. Suponga $\sigma = 400$.

11.56. Determinar el tamaño de la muestra y el valor crítico en el ejercicio 11.7, si se desea $\beta = 0,3669$.

11.57. Determinar el tamaño de la muestra y el valor crítico en el ejercicio 11.20, si se introduce la alternativa $\mu = 220$, y se desea $\beta = 0,0287$. Suponga $\sigma = 40$.

11.58. Determinar el tamaño de la muestra en el ejercicio 11.8, si se introduce la alternativa $p = 0,8$, y se desea i) $\beta = 0,0043$ ii) $\beta = 0,025$.

11.59. Se desea saber si los mercados de Maracaibo y Caracas son iguales respecto al precio que los consumidores están dispuestos a pagar por un cierto producto. Suponga las varianzas iguales. Una muestra de 10 consumidores en Maracaibo dio un precio medio de Bs. 5, con una desviación típica de Bs. 2; en Caracas una muestra de 15 consumidores dio un precio medio de Bs. 5,50, con una desviación típica de Bs. 2,10. $\alpha = 0,05$.

11.60. Una máquina produce tornillos cuya longitud es una variable aleatoria normal. Una muestra al azar de 15 tornillos dio una longitud media de 3 cm. con una desviación típica de 0,0479; con un nivel de significación del 1%, contraste la hipótesis que $\sigma^2 \leq 0,0025$.

11.61. Se determinó que el ingreso medio anual de 101 obreros tomados al azar en una industria fue de Bs. 2.700, con una desviación típica de Bs. 37. Con un nivel de significación de 0,05 contraste la hipótesis que $\sigma^2 = 2.025$. Se suponen los ingresos normalmente distribuidos.

11.62. En una ciudad se escogió una muestra aleatoria de 121 personas para preguntarle el precio que estarían dispuestas a pagar por un determinado artículo, dando una media de Bs. 5,50, con una desviación típica de Bs. 0,50. En otra ciudad una muestra de 61 personas dio una media de Bs. 5, con una desviación típica de Bs. 0,37. ¿Hay diferencia significativa en las varianzas de los precios? $\alpha = 0,05$.

11.63. Los gastos medios en viviendas en una muestra de 21 familias de cierta población fueron de Bs. 400 mensuales, con una desviación típica de Bs. 30. En una muestra de 31 familias de otra población los gastos fueron de Bs. 405, con una desviación típica de Bs. 35. ¿Hay más variación en los gastos de la segunda población? $\alpha = 0,05$.

11.64. Deducir el valor crítico para contrastar la hipótesis $\mu_x - \mu_y = \mu_0$ ó $\mu_x - \mu_y \leq \mu_0$ contra la hipótesis $\mu_x - \mu_y > \mu_0$ suponiendo que: i) Se conocen las varianzas poblacionales; ii) No se conocen las varianzas poblacionales; iii) No se conocen, pero se supone que son iguales.

11.65. Deducir los valores críticos para contrastar la hipótesis $\mu_x - \mu_y = \mu_0$ contra la hipótesis $\mu_x - \mu_y \neq \mu_0$ bajo los mismos supuestos del ejercicio anterior.

11.66. Deducir los valores críticos para contrastar la hipótesis $p_x - p_y = p_0$ contra las distintas alternativas.

- 11.67. Deducir los valores críticos para los contrastes sobre la media de una población en las distintas situaciones, si se supone que la población es finita y el muestreo se hace sin reemplazamiento.
- 11.68. Lo mismo que el ejercicio anterior para la proporción.
- 11.69. Lo mismo para el caso de diferencia de medias.
- 11.70. Lo mismo para el caso de diferencia de proporciones.

CAPITULO XII

CONTRASTE DE HIPOTESIS

(CONTINUACION)

12.1. INTRODUCCION

En el capítulo X se mencionó la existencia de hipótesis estadísticas no paramétricas, entendiéndose por tales aquellas referidas a la forma de la distribución de probabilidades de una población.

Cuando se usa alguna función de densidad para definir una población, surge de inmediato la pregunta de si la función teórica usada es apropiada; en otras palabras, si la función de densidad de la población en estudio tiene la forma especificada. Una forma simple de analizar la verosimilitud de que una población obedezca a una determinada función de densidad, es obtener una muestra aleatoria de la población en estudio, representar gráficamente los resultados obtenidos en la muestra con sus respectivas frecuencias, y comparar el gráfico de la muestra con el gráfico de la función de densidad supuesta; de una forma visual se puede afirmar si la función de frecuencias es similar a la función de densidad. Indudablemente que muy frecuentemente este método no permitirá identificar objetivamente la distribución de probabilidades de la población, en el sentido de que la diferencia entre el gráfico de las frecuencias muestrales y el gráfico de la distribución teórica puede deberse a casualidad, o a que la distribución teórica que se supone tiene la población, no es correcta.

EJEMPLO 12.1.


Se supone que la demanda de un cierto bien es una variable aleatoria exponencial con media igual a 25 unidades.

Una muestra aleatoria de 100 elementos dio los siguientes resultados:

Demanda	0-10	10-20	20-30	30-40	40-50	50-60	60-70
Frecuencia	20	30	25	10	5	3	7

Representemos los resultados de la muestra en un histograma o polígono de frecuencias en la Fig. 12.1.

FIGURA 12.1.



La altura de cada polígono ha sido determinada de tal forma que el área del polígono es igual a la frecuencia relativa con que la variable cae en el correspondiente intervalo. La altura del primer polígono, por ejemplo, es 20/1000, puesto que el área debe ser 20/100.

La curva punteada corresponde a la función de densidad exponencial con media 25; las frecuencias relativas teóricas para cada intervalo, si la distribución de probabilidad es la especificada, vienen dadas por las áreas debajo de la curva entre los límites del correspondiente intervalo.

Determinar si las diferencias entre las frecuencias observadas en la muestra y las frecuencias teóricas se deben a que la distribución hipotética no corresponde a la realidad o simplemente a la aleatoriedad de los resultados muestrales, es el objeto del contraste de hipótesis sobre la bondad del ajuste de distribuciones teóricas. Existen dos contrastes generalmente usados en este tipo de problema: El contraste χ^2 de Bondad del ajuste y el Contraste de Kolmogorov - Smirnov.

12.2. CONTRASTE χ^2 DE BONDAD DEL AJUSTE

El contraste χ^2 de Bondad del ajuste fue diseñado por Pearson en 1.900. Originalmente el contraste fue diseñado para su aplicación a poblaciones discretas, extendiéndose luego su aplicación a poblaciones continuas.

Supongamos un experimento aleatorio con r posibles resultados cada uno con probabilidades $p_1, p_2, \dots, p_r$. Las variables aleatorias $x_1, x_2, \dots, x_r$ representan el número de veces que se da el resultado i ($i = 1, \dots, r$) al realizar el experimento n veces; sabemos que la función de densidad conjunta de las x es multinomial.

Planteamos la hipótesis $H_0: p_1 = p_1^0; p_2 = p_2^0; \dots; p_r = p_r^0$; es decir, la hipótesis de que las probabilidades con que se den los distintos resultados (p_i) son iguales a ciertos valores (p_i^0). Al hacer esta hipótesis, estamos suponiendo que la función de densidad multinomial es una distribución particular caracterizada por las probabilidades específicas (p_i^0).

Para proceder a contrastar esta hipótesis, se toma una muestra aleatoria de tamaño n (se realiza el experimento n veces en forma independiente), y se calculan las frecuencias de cada uno de los posibles resultados a las que designamos $f_1, f_2, \dots, f_r$, siendo f_i la frecuencia del resultado i , $\left(\sum_{i=1}^r f_i = n\right)$. Las frecuencias teóricas o esperadas, si H_0 es verdadera, vendrán dadas por $f_i^0 = np_i^0$; es decir, f_i^0 es la frecuencia con que esperaríamos se diera el resultado i , si p_i^0 fuese la probabilidad de que se diese ese resultado en un intento. Se procede entonces a calcular la cantidad,

$$\chi^2 = \sum_{i=1}^r \frac{(f_i - f_i^0)^2}{f_i^0} \quad (1)$$

Es indudable que si la hipótesis H_0 es verdadera, esta cantidad tiende a ser pequeña, puesto que $f_i - f_i^0$ serán pequeñas, las frecuencias observadas y las frecuencias teóricas tenderán a ser iguales; por el contrario, si la hipótesis es falsa, estas diferencias tenderán a ser grandes, y la cantidad será grande. La expresión (1) es una variable aleatoria, puesto que f_i ($i = 1 \dots r$) viene siendo la variable que representa el número de veces que se da el resultado i en el experimento aleatorio. La distribución de esta variable cuando n es finita, no es fácil calcularla, y depende de los valores de p_i^0 . Sin embargo, se ha demostrado que cuando $n \rightarrow \infty$, si H_0 es verdadera, la expresión (1) tiende a distribuirse como una variable χ^2 con $r - 1$ grados de libertad y para n grande se puede usar esta aproximación sin riesgo de cometer errores abultados.

Para saber si las frecuencias observadas difieren significativamente de las frecuencias esperadas; en otras palabras, para contrastar la hipótesis $H_0 : p_1 = p_1^0 ; p_2 = p_2^0 ; \dots ; p_r = p_r^0$ contra la hipótesis alternativa H_1 de que los valores asignados a p_i no son correctos con un nivel de significación de α , se usa la siguiente regla de decisión:

Si $\chi^2 = \sum_{i=1}^r (f_i - f_i^0)^2 / f_i^0$, es mayor que χ_{α}^2 , se rechaza H_0 . Si $\chi^2 < \chi_{\alpha}^2$, no se rechaza H_0 .

EJEMPLO 12.2.

Se desea saber si un dado está bien balanceado, y se lanza 180 veces, obteniéndose los siguientes resultados; 23 veces el uno, 35 veces el dos, 27 veces el tres, 40 veces el cuatro, 15 veces el cinco y 40 veces el seis.

El hecho de que el dado esté bien balanceado equivale a la hipótesis de que $p_i = 1/6$ ($i = 1 \dots 6$), siendo p_i la probabilidad de que aparezca el resultado i al lanzar el dado una vez. Si el dado está bien balanceado; o sea, si H_0 es verdadera, las frecuencias esperadas de los seis posibles resultados son $180 \cdot \frac{1}{6} = 30$.

Luego,

Resultado	1	2	3	4	5	6
f_i	23	35	27	40	15	40
f_i^0	30	30	30	30	30	30

$$\chi^2 = \frac{49}{30} + \frac{25}{30} + \frac{9}{30} + \frac{100}{30} + \frac{225}{30} + \frac{100}{30} = \frac{508}{30} = 16,9$$

Con un nivel de significación de 5%, $\chi_{0,05}^2 (5) = 11,07$.

Como $16,9 > 11,07$, se rechaza la hipótesis de que los resultados son igualmente probables.

EJEMPLO 12.3.

Se afirma que la distribución de la población caraqueña de acuerdo con el nivel de ingresos, es la siguiente:

Nivel de Ingresos Mensuales	Proporción de la Población
Entre 0 y 15.000	38%
Entre 15.001 y 30.000	25%
Entre 30.001 y 45.000	12%
Entre 45.001 y 60.000	8%
Más de 60.000	17%

Para verificar la hipótesis, se toma una muestra aleatoria de 2.000 personas con los siguientes resultados:

Ingresos Bs.	0-15.000	15.001-30.000	30.001-45.000	45.001-60.000	Más de 60.000
Nº de personas	800	475	300	155	270

Con un nivel de significación del 10% verificar si las proporciones dadas se ajustan razonablemente a la realidad.

Resultado	f_i	f_i^0
0 - 15.000	800	760
15.001 - 30.000	475	500
30.001 - 45.000	255	240
45.001 - 60.000	155	160
Más de 60.000	315	340
	2.000	2.000

$$\chi^2 = \frac{40^2}{760} + \frac{25^2}{500} + \frac{15^2}{240} + \frac{5^2}{160} + \frac{25^2}{340} = 6,26$$

$$\chi_{0,10}^2 (4) = 7,78 \quad \text{Como } 6,26 < 7,78 \text{ se acepta } H_0.$$

Las proporciones que se presentan en la tabla son aparentemente adecuadas.

Se observará que el contraste χ^2 ha sido usado realmente en los ejemplos anteriores para contrastar valores de p, no para contrastar la forma de la distribución teórica de probabilidades de una población.

Veamos con otro ejemplo como se hace este contraste en poblaciones discretas.

EJEMPLO 12.4.

La demanda diaria de un determinado artículo es una variable aleatoria con media igual a 4. Una muestra aleatoria de 400 días dio los siguientes resultados:

x	0	1	2	3	4	5	6	7	8	9 ó más
f_i	10	25	45	52	65	70	60	35	23	15

Se desea saber si los datos se ajustan bien a una distribución de Poisson.

En este caso nuestra hipótesis nula H_0 es que las ventas diarias obedecen a una distribución de Poisson con media igual a 4.

El procedimiento para el contraste es el mismo descrito anteriormente. Calculemos las frecuencias esperadas con que obtendríamos los resultados, si la hipótesis H_0 fuese verdadera, en el ejemplo si la distribución es Poisson con media 4. Las frecuencias esperadas vienen dadas a continuación.

x	0	1	2	3	4	5	6	7	8	9 ó más
f_i^0	7,32	29,32	58,60	78,16	78,16	62,52	41,68	23,80	11,92	8,52

Estas frecuencias esperadas fueron calculadas multiplicando 400 por las probabilidades correspondientes a una Poisson con media 4; p. ej., la primera frecuencia $0,0183 \times 400 = 7,32$.

$$\chi^2 = \frac{2,68^2}{7,32} + \frac{4,32^2}{29,32} + \frac{13,60^2}{58,60} + \frac{26,16^2}{78,16} + \frac{13,16^2}{78,16} + \frac{7,48^2}{62,52} + \frac{18,32^2}{41,68} + \frac{11,20^2}{23,80} + \frac{11,08^2}{11,92} + \frac{6,48^2}{8,52} = 45,214$$

Comparemos χ^2 con $\chi_{\alpha}^2 (r - 1)$. Si usamos un nivel de significación del 5%, $\chi_{\alpha}^2 (r - 1)$ es $\chi_{0,05}^2 (9) = 16,92$. Como $45,214 > 16,92$ rechazamos H_0 , es decir los datos nos llevan a rechazar la hipótesis de que la distribución de la población es Poisson con media 4.¹⁹

Para usar el contraste χ^2 en poblaciones continuas se presenta la dificultad de que las probabilidades de que la variable tome un valor determinado, son cero; por eso los resultados muestrales deben agruparse en intervalos, y se comparan entonces las frecuencias observadas con que los valores muestrales caen en esos intervalos y las frecuencias teóricas.

Se agrupan los resultados muestrales en r intervalos de clase. Las frecuencias muestrales f_i corresponden al número de veces que los resultados muestrales caen en el

¹⁹ Se debe observar que r en este caso es el número de diferentes resultados.

correspondiente intervalo. Las frecuencias teóricas se calculan multiplicando la probabilidad de que la variable caiga en el intervalo bajo la hipótesis de que la función de densidad es $f_0(x)$ por el tamaño de la muestra. Por ejemplo, si la hipótesis es que la función de densidad normal y los límites de un intervalo son (a_{i-1}, a_i) , p_i^0 será :

$$p_i^0 = P(a_{i-1} \leq x \leq a_i) = F(a_i) - F(a_{i-1})$$

el área debajo de la curva normal entre a_{i-1} y a_i .

La frecuencia esperada de ese intervalo será $f_i^0 = p_i^0 n$.

No hay regla fija para determinar r ; es decir, el número de intervalos que se van a usar, pero es práctica común que r sea tal que ningún intervalo tenga una frecuencia teórica menor que 5.²⁰ La razón de esto es lo siguiente: El estadístico χ^2 que se usa para hacer el contraste no está definido si algún f_i^0 es cero; por otro lado, si algún f_i^0 es muy pequeño, el término correspondiente en χ^2 es grande, surgiendo la posibilidad de rechazar la hipótesis ($\chi^2 > \chi_\alpha^2$), no porque las frecuencias observadas difieren de las teóricas, (lo que afecta a los numeradores) sino porque estas últimas son pequeñas.

EJEMPLO 12.5.

Se sabe que la cantidad de gas contenida en las bombonas es una variable con media 40 m³ y desviación típica de 5 m³. Los contenidos de 100 bombonas escogidas aleatoriamente fueron medidos con los siguientes resultados:

x	m ³	< 30	30-33	33-36	36-39	39-42	42-45	45-48	> 48
f_i	Número de bombonas	4	5	10	22	18	24	12	5

A la luz de estos resultados ¿se puede rechazar la hipótesis de normalidad?

Se trata de contrastar $H_0: f(x)$ es normal

$H_1: f(x)$ no es normal

²⁰ El mismo criterio de una frecuencia esperada mayor o igual a 5 es válido para el caso de distribuciones discretas. (Ver ejemplo 12.7).

x	f_i	p_i^0	$f_i^0 = n p_i^0$
< 30	4	0,0228	2,28
30 - 33	5	0,0580	5,80
33 - 36	10	0,1311	13,11
36 - 39	22	0,2088	20,88
39 - 42	18	0,2347	23,47
42 - 45	24	0,1859	18,59
45 - 48	12	0,1039	10,39
> 48	5	0,0548	5,48

En la tercera columna de la tabla se presentan las probabilidades de que una variable normal con media 40 y $\sigma = 5$, caiga en el intervalo correspondiente indicado en la primera columna. Como el primer intervalo tiene una frecuencia esperada menor que 5 (2,28), se agrupa con el segundo para que ningún intervalo tenga una frecuencia menor que 5. Luego,

$$\chi^2 = \frac{(9 - 8,08)^2}{8,08} + \frac{(10 - 13,11)^2}{13,11} + \frac{(22 - 20,88)^2}{20,88} + \frac{(18 - 23,47)^2}{23,47} + \frac{(24 - 18,59)^2}{18,59} + \frac{(12 - 10,39)^2}{10,39} + \frac{(5 - 5,48)^2}{5,48} = 4$$

$\chi_{0,05}^2(6) = 12,59$; como $4 < 12,59$ se acepta H_0 . Obsérvese que r es 7, número de intervalos usados después del agrupamiento

EJEMPLO 12.6.

Consideren los datos del ejemplo 12.1. ¿Se justifica la hipótesis de que la distribución es exponencial?

x	f _i	p _i ⁰	f _i ⁰ = n p _i ⁰
0 - 10	20	0,3297	32,97
10 - 20	30	0,2210	22,10
20 - 30	25	0,1432	14,32
30 - 40	10	0,0992	9,92
40 - 50	5	0,0716	7,16
50 - 60	3	0,0397	3,97
> 60	7	0,0956	9,56

$$p_i^0 = P(a_{i-1} < x < a_i) = \int_{a_{i-1}}^{a_i} \frac{1}{25} e^{-x/25} dx = -e^{-x/25} \Big|_{a_{i-1}}^{a_i} = -e^{-\frac{a_i}{25}} + e^{-\frac{a_{i-1}}{25}}$$

Para el primer intervalo: $p_1^0 = -e^{-10/25} + e^0 = 1 - 0,6703 = 0,3297$; el mismo procedimiento se sigue para los otros intervalos. Como antes, se agrupan los dos últimos intervalos para que $f_i^0 > 5$.

$$\chi^2 = \frac{(20 - 32,97)^2}{32,97} + \frac{(30 - 22,10)^2}{22,10} + \frac{(25 - 14,32)^2}{14,32} + \frac{(10 - 9,92)^2}{9,92} + \frac{(5 - 7,16)^2}{7,16} + \frac{(10 - 13,53)^2}{13,53} = 17,4668$$

$17,4668 > 9,24 = \chi_{0,10}^2(5)$. Con un nivel de significación del 10% rechazamos H_0 .

Hasta ahora se han visto casos en que al hacer la hipótesis sobre la función de densidad de una población se especificaba el valor de los parámetros de la función. En el ejemplo 12.3 se hablaba de una Poisson con media 4; en el ejemplo 12.4 se mencionaba una normal con media 40 y $\sigma = 5$, etc.; es muy frecuente tratar de determinar si la función de densidad se ajusta a unos datos, pero sin tener conocimiento "a priori" y, en

consecuencia, sin poder especificar los parámetros de la función de densidad. Recordemos que el estadístico χ^2 es una función de las p_i^0 ; y éstas a su vez sólo se pueden determinar, cuando H_0 es verdadera, si se conocen los parámetros de la función de densidad. Afortunadamente el contraste χ^2 es aplicable generalmente cuando los parámetros son desconocidos, si se sustituyen éstos por los valores de sus estimadores máximo verosímiles obtenidos a partir de la muestra.

La corrección fundamental que es necesario realizar, es disminuir los grados de libertad de la χ^2 en el número de parámetros que se estiman; los grados de libertad serán entonces $r - 1 - k$, siendo k el número de parámetros estimados con los datos de la muestra. Si por ejemplo, se quiere saber si los datos son consistentes con una distribución normal, como tenemos que estimar μ y σ^2 (los estimadores serán $\bar{x}$ y s^2), los grados de libertad de la χ^2 serán $r - 3$.

EJEMPLO 12.7.

Los precios de un cierto artículo en 110 diferentes establecimientos de Caracas vienen dados en la tabla que se da a continuación, aproximándolos a bolívares enteros; es decir, por ejemplo, los precios entre 234,5 y 235,4 se tomaron como 235, etc.

213	196	161	195	164	173	201	200	185	176
205	153	184	196	233	227	239	186	185	197
199	237	180	230	231	240	191	173	253	255
201	197	196	176	228	249	202	171	252	206
177	176	231	187	178	197	238	205	235	183
231	214	152	171	244	201	210	191	206	236
243	245	244	204	224	206	222	190	227	177
210	229	157	195	196	153	164	215	216	157
203	244	221	260	245	241	199	204	186	223
190	243	147	208	242	177	217	192	238	212
179	230	198	187	207	207	218	189	189	218

Comprobar si los datos se ajustan a una distribución normal.

Primero se procede a calcular la media y varianza muestrales.

$$\bar{x} = \frac{\sum x_i}{n} = \frac{22,587}{110} = 205,33 \quad s^2 = \frac{\sum (x_i - \bar{x})^2}{n} = 243,05 \quad s = 15,59$$

Agrupamos los datos en intervalos. Los datos extremos son 147 y 260; dividimos el rango en 10 intervalos cada uno de amplitud 12.

	f_i	$p_i^{0.21}$	$f_i^0 = n p_i^0$	
146,5 - 158,5	6	0,0013	0,143	} 7,931
158,5 - 170,5	3	0,0116	1,276	
170,5 - 182,5	13	0,0592	6,512	
182,5 - 194,5	15	0,1730	19,030	
194,5 - 206,5	25	0,2868	31,548	} 5,907
206,5 - 218,5	13	0,2676	29,436	
218,5 - 230,5	10	0,1468	16,148	
230,5 - 242,5	13	0,0450	4,950	
242,5 - 254,5	10	0,0079	0,869	
254,5 - 266,5	2	0,0008	0,088	
	110	1,0000		

Como límite inferior del primer intervalo se escogió 146,5 para que los límites de los intervalos no coincidan con los datos, de forma de evitar la indecisión de ubicar un dato particular en uno u otro intervalo.

²¹ Probabilidades calculadas a partir de una normal con media 205,33 y $\sigma^2 = 243,05$.

Agrupemos los tres primeros intervalos y los tres últimos, de forma que las frecuencias esperadas no sean inferiores a 5.

Los grados de libertad serán $r - 3 = 3$, puesto que hemos estimado dos parámetros μ y σ .

$$\chi^2 = 100,399 \quad \chi_{0,95}^2(3) = 7,81 \quad 100,399 > 7,81$$

Se rechaza la hipótesis de que los datos provienen de una distribución normal.

EJEMPLO 12.8.

Los datos que aparecen a continuación corresponden al número de personas que han acudido a la caja de un Banco en un periodo de 60 horas escogidas aleatoriamente. Verificar la bondad del ajuste de los datos a una distribución de Poisson.

8	1	2	4	5	6	5	8	4	5
7	9	6	8	9	6	8	11	7	6
3	6	3	4	3	5	10	8	11	9
7	2	5	6	2	4	5	10	6	7
8	2	7	12	7	8	9	9	4	10
5	3	10	7	4	5	4	6	6	5

$$\bar{x} = \frac{372}{60} = 6,2$$

	f_i	f_i^0	
0	0	0,120	} 8,052
1	1	0,756	
2	4	2,340	
3	4	4,836	
4	7	7,494	
5	9	9,294	} 5,910
6	9	9,606	
7	7	8,508	
8	7	6,594	
9	5	4,542	
10	4	2,814	
11	2	1,590	
12 ó más	1	1,506	
	60	60,000	

$r - 1 - k = 8 - 1 - 1 = 6$ grados de libertad

$\chi^2 = 0,729 \quad \chi^2_{0,05}(6) = 12,59$

El ajuste es bueno, $0,729 < 12,59$

No se rechaza la hipótesis de que el número de personas que acude a la caja del Banco en una hora obedece a la distribución Poisson.

12.3. CONTRASTE DE KOLMOGOROV - SMIRNOV

El contraste de Kolmogorov-Smirnov sirve al igual que el χ^2 para estudiar si un conjunto de datos muestrales proviene de una población con una función de distribución determinada. Este contraste se puede usar sólo para variables continuas, y cuando la función de distribución que se quiere contrastar está completamente especificada, en el sentido de que se dan tanto la forma como los parámetros de la distribución.

Si tenemos una muestra aleatoria de tamaño n , queremos contrastar la hipótesis de que la función de distribución de la población de la cual proviene la muestra es $F_0(x)$ contra la hipótesis alternativa de que no es $F_0(x)$.

H_0 : La función de distribución es $F_0(x)$

H_1 : La función de distribución no es $F_0(x)$

El contraste de Kolmogorov-Smirnov procede a comparar la función de distribución muestral $F_n(x)$ con la función distribución teórica $F_0(x)$. Si la muestra proviene de una población con función de distribución $F_0(x)$, entonces $F_n(x)$ debería parecerse a $F_0(x)$, y la hipótesis H_0 se rechaza cuando para algún valor de x la diferencia entre $F_n(x)$ y $F_0(x)$ es significativamente grande.

El contraste procede de la siguiente forma:

1. Se ordenan los datos muestrales de menor a mayor. Designemos los datos muestrales ordenados como $(x_1, x_2, \dots, x_n)$.
2. Se calcula la función de distribución muestral $F_n(x)$. El cálculo de $F_n(x)$ es muy simple.

Para $x < x_1$ $F_n(x) = 0$

Para $x_k \leq x \leq x_{k+1}$ $F_n(x) = \frac{k}{n}$ siendo k el número de elementos de la muestra

menores o iguales a x ($k = 1, \dots, n-1$).

Para $x \geq x_n$ $F_n(x) = 1$

EJEMPLO 12.9.

La función de distribución muestral del ejemplo 12.1. es:

x	10	20	30	40	50	60	70
$F_n(x)$	20/100	50/100	75/100	85/100	90/100	93/100	100/100

Siendo n el número de observaciones muestrales, en este ejemplo, $n = 100$. Hay 20 observaciones menores o iguales que 10, $F_n(10) = 20/100$. Hay 50 observaciones menores o iguales que 20, $F_n(20) = 50/100$, etc.

- Se calcula $F_0(x)$ para cada dato. $F_0(h)$ es la probabilidad de que la variable sea menor o igual que h bajo la hipótesis H_0 ; es decir, si la distribución de la población es $F_0(x)$.
- Se calcula el estadístico

$$D_n = \max |F_n(x) - F_0(x)| \quad \forall x$$

es decir, la desviación máxima en valor absoluto entre la función de distribución muestral y la función de distribución teórica.

La región crítica del contraste es de la forma $D_n > D_{n,\alpha}$; es un contraste de una cola por la derecha. Si el estadístico D_n es mayor que la constante $D_{n,\alpha}$, se rechaza la hipótesis con un nivel de significación de α . Los valores de $D_{n,\alpha}$ son dados en la tabla V, y han sido calculados con base en la función de probabilidades del estadístico D_n ; en otras palabras, $D_{n,\alpha}$ es aquel número tal que la probabilidad que D_n sea mayor que él cuando H_0 es verdadera, es α ; o sea,

$$P[D_n > D_{n,\alpha} / H_0 \text{ es verdadera}] = \alpha$$

EJEMPLO 12.10.

Usar el contraste de Kolmogorov-Smirnov para resolver el ejemplo 12.5.
 H_0 : $F(x)$ es normal (40,25).

x	$F_n(x)$	$F_0(x)$	$ F_n(x) - F_0(x) $
30	0,04	0,0228	0,0172
33	0,09	0,0808	0,0092
36	0,19	0,2119	0,0219
39	0,41	0,4207	0,0107
42	0,59	0,6554	0,0654
45	0,83	0,8413	0,0113
48	0,95	0,9452	0,0048
51	1,00	0,9861	0,0139

$$D_n = \max |F_n(x) - F_0(x)| = 0,0654$$

$$D_{100;0,05} = 0,14 \quad 0,0219 < 0,14 \quad \text{Se acepta } H_0$$

EJEMPLO 12.11.

Usar el contraste de Kolmogorov-Smirnov para resolver el ejemplo 12.6.
 H_0 : $F(x)$ es exponencial con media 25.

x	$F_n(x)$	$F_0(x)$	$ F_n(x) - F_0(x) $
10	0,20	0,3297	0,1297
20	0,50	0,5507	0,0507
30	0,75	0,6939	0,0561
40	0,85	0,7931	0,0569
50	0,90	0,8647	0,0353
60	0,93	0,9043	0,0257
70	1,00	0,9392	0,0608

$$D_n = \max |F_n(x) - F_0(x)| = 0,1297$$

$$D_{100;0,10} = \frac{1,22}{\sqrt{100}} = 0,122 \quad 0,1297 > 0,122. \quad \text{Rechazamos } H_0.$$

12.4. CONTRASTE DE INDEPENDENCIA: TABLAS DE CONTINGENCIA

Un contraste muy útil en la práctica es el que se refiere a la independencia de variables aleatorias que representan conjuntos de atributos o características de tipo cualitativo de una población determinada. Por ejemplo, un investigador de mercados puede estar interesado en saber si existe relación entre el sexo, el nivel de ingresos, y la preferencia por una determinada marca de un producto; o puede estar interesado en conocer si existe interrelación entre el grado de educación de los obreros de una industria y su productividad, etc.

Los casos mencionados se pueden enfocar en forma general como problemas en los cuales se puede subdividir una población en distintas categorías de acuerdo con ciertos criterios, e investigar si existe alguna asociación entre ellos. Nosotros nos limitaremos a tratar el caso de dos criterios tal como el segundo ejemplo mencionado. En el ejemplo, el investigador podría establecer 4 categorías de nivel educacional: ninguna educación formal, primaria, secundaria, técnica y 3 categorías de productividad: baja, media, alta. Se trata entonces de establecer si el hecho de tener educación primaria, por ejemplo, está relacionado con un nivel de productividad bajo; en general, si el grado de educación afecta el nivel de rendimiento.

Una población se puede clasificar de acuerdo con un criterio A en h categorías distintas mutuamente excluyentes: $A_1, A_2, A_3, \dots, A_h$, y de acuerdo con un criterio B en c categorías distintas $B_1, B_2, \dots, B_c$. Al tomar una muestra aleatoria de tamaño n de esa población, cada elemento u observación de la muestra queda clasificado en una de las categorías de cada criterio. Sea n_{ij} el número de elementos muestrales que pertenecen simultáneamente a la categoría A_i y a la categoría B_j ; las observaciones muestrales se pueden presentar en un cuadro de doble entrada (Tabla 12.1).

TABLA 12.1.

	Criterio de Clasificación B			
	B ₁	B ₂	B ₃ B _c	Totales Filas
A ₁	n ₁₁	n ₁₂	n ₁₃ n _{1c}	n _{1.}
A ₂	n ₂₁	n ₂₂	n ₂₃ n _{2c}	n _{2.}
A ₃	n ₃₁	n ₃₂	n ₃₃ n _{3c}	n _{3.}
⋮	⋮	⋮	⋮	⋮
A _h	n _{h1}	n _{h2}	n _{h3} n _{hc}	n _{h.}
Totales Columnas	n _{.1}	n _{.2}	n _{.3} n _{.c}	n

Estas tablas se conocen como tablas de contingencia de doble entrada (2 criterios de clasificación), h x c, (h filas y c columnas).

Los elementos de la última columna de la tabla $n_{i.}$ son simplemente las sumas de los valores de las filas; es decir, $n_{i.} = \sum_{j=1}^c n_{ij}$ (en particular el primer elemento $n_{1.} = \sum_{j=1}^c n_{1j}$, etc.). Similarmente, los elementos de la última fila $n_{.j}$ son las sumas de los valores de las columnas, $n_{.j} = \sum_{i=1}^h n_{ij}$.

Como se dijo anteriormente, se trata de contrastar la independencia o no relación de las variables aleatorias o criterios de clasificación A y B. Si A y B son independientes, debe cumplirse, como se vio en el Cap. I, que:

$$P(A_i \cap B_j) = P(A_i) P(B_j) \quad \forall i, j$$

en otras palabras, la probabilidad que se dé el suceso de que un elemento de la población pertenezca simultáneamente a la categoría A_i y a la categoría B_j es igual al producto de la probabilidad de que se dé el suceso de pertenecer a A_i por la probabilidad de que se dé el suceso de pertenecer a B_j . Designemos como p_i la probabilidad de que un elemento pertenezca a la categoría A_i , como p_j la probabilidad de que pertenezca a B_j y como p_{ij} la probabilidad de que pertenezca simultáneamente a A_i y B_j . En esta terminología la hipótesis nula será:

$$H_0 : p_{ij} = p_i \cdot p_j$$

es decir, el suceso de que un elemento pertenezca a la categoría A_i es independiente de que pertenezca a la categoría B_j .

Contra la hipótesis alternativa,

$$H_1 : p_{ij} \neq p_i \cdot p_j$$

Las probabilidades marginales p_i y p_j no se conocen, pero pueden ser estimadas a partir de los datos muestrales. Los estimadores máximo verosímiles de p_i y p_j son: (Ver ejercicio 8.28).

$$\hat{p}_{i.} = \frac{n_{i.}}{n}, \quad \hat{p}_{.j} = \frac{n_{.j}}{n}$$

El estimador máximo verosímil de la probabilidad que un elemento pertenezca a la categoría A_i es igual al número de elementos de la muestra que pertenecen a esa categoría ($n_{i.}$) dividido por el número total de elementos de la muestra (n), etc.

Si la hipótesis H_0 es verdadera (si los criterios de clasificación son independientes), las probabilidades conjuntas p_{ij} se pueden estimar por el producto de $\hat{p}_{i.}$ y $\hat{p}_{.j}$

$$\hat{p}_{ij} = \hat{p}_{i.} \cdot \hat{p}_{.j}$$

Una vez estimadas las probabilidades conjuntas, se puede calcular la frecuencia esperada en cada "celda" o casilla de la tabla de contingencia; entendiéndose por frecuencia esperada de la celda (i, j), el número esperado de elementos que teóricamente esperaríamos pertencieran simultáneamente a la categoría A_i y B_j , este número es:

$$f_{ij} = n \cdot \hat{p}_{ij}$$

Comparando estas frecuencias esperadas con las frecuencias muestrales (n_{ij}), se puede contrastar la hipótesis H_0 . En efecto, si la hipótesis es verdadera podemos esperar que las frecuencias muestrales no difieran significativamente de las frecuencias esperadas; por lo tanto, si las diferencias son significativas, rechazaremos la hipótesis de independencia; si no, la aceptaremos. El estadístico y contraste usado para determinar si las diferencias son o no significativas, es el mismo de la sección 12.2. El estadístico

$$\chi^2 = \sum_i \sum_j \frac{(n_{ij} - f_{ij})^2}{f_{ij}}$$

tiende a distribuirse como una variable χ^2 con $[(h-1)(c-1)]$ grados de libertad.

El número de grados de libertad $(h-1)(c-1)$ se explica por lo siguiente. La variable χ^2 en la sección 12.2 tenía $r-1-k$ grados de libertad, siendo r el número de posibles resultados y k el número de parámetros que se estimaban a partir de los datos muestrales. En este caso $r = h \times c$, número de distintas clasificaciones y el número de parámetros estimados es $(h-1) + (c-1)$, puesto que tenemos que estimar $h p_i$ y $c p_j$ parámetros, pero $\sum_i p_i = 1$, uno de las p_i queda determinada al estimar las otras; luego en verdad se estiman en forma independiente únicamente $(h-1) p_i$; similar razonamiento en el caso de p_j ; luego, los grados de libertad serán:

$$hc - 1 - [(h-1) + (c-1)] = hc - h - c + 1 = (h-1)(c-1)$$

En resumen, si χ^2 es mayor que $\chi^2_{\alpha} [(h-1)(c-1)]$ se rechaza la hipótesis de independencia; si χ^2 es menor que $\chi^2_{\alpha} [(h-1)(c-1)]$, se acepta.

EJEMPLO 12.12.

Se está interesado en determinar si existe relación entre el grado de educación y el nivel de rendimiento de la mano de obra en una industria. A tal efecto se clasificaron 400 obreros tomados aleatoriamente, con los siguientes resultados:

Grado de Educación \ Nivel de Rendimiento	Ninguna Educación	Primaria	Secundaria	Técnica	Total
Bajo	40	80	10	10	140
Medio	10	40	10	70	130
Alto	10	20	20	80	130
Total	60	140	40	160	400

$$H_0: p_{ij} = p_i \cdot p_j \quad i = 1, 2, 3; \quad j = 1, 2, 3, 4$$

$$H_1: p_{ij} \neq p_i \cdot p_j$$

Se calculan los estimadores de p_i y p_j .

$$\hat{p}_1 = \frac{140}{400}; \quad \hat{p}_2 = \frac{130}{400}; \quad \hat{p}_3 = \frac{130}{400}$$

$$\hat{p}_{.1} = \frac{60}{400}; \quad \hat{p}_{.2} = \frac{140}{400}; \quad \hat{p}_{.3} = \frac{40}{400}; \quad \hat{p}_{.4} = \frac{160}{400}$$

$$\hat{p}_{11} = \frac{140 \times 60}{400^2}; \quad \hat{p}_{12} = \frac{140^2}{400^2}; \quad \hat{p}_{13} = \frac{140 \times 40}{400^2}; \quad \hat{p}_{14} = \frac{140 \times 160}{400^2}$$

$$\hat{p}_{21} = \frac{130 \times 60}{400^2}; \quad \hat{p}_{22} = \frac{130 \times 140}{400^2}; \quad \hat{p}_{23} = \frac{130 \times 40}{400^2}; \quad \hat{p}_{24} = \frac{130 \times 160}{400^2}$$

$$\hat{p}_{31} = \frac{130 \times 60}{400^2}; \quad \hat{p}_{32} = \frac{130 \times 140}{400^2}; \quad \hat{p}_{33} = \frac{130 \times 40}{400^2}; \quad \hat{p}_{34} = \frac{130 \times 160}{400^2}$$

Calculamos las frecuencias esperadas, mostradas a continuación

					Total
	21,0	49,0	14	56	140
	19,5	45,5	13	52	130
	19,5	45,5	13	52	130
Total	60	140	40	160	400

$$\begin{aligned} \chi^2 = & \frac{(40-21)^2}{21} + \frac{(80-49)^2}{49} + \frac{(10-14)^2}{14} + \frac{(10-56)^2}{56} + \frac{(10-19,5)^2}{19,5} + \\ & + \frac{(40-45,5)^2}{45,5} + \frac{(10-13)^2}{13} + \frac{(70-52)^2}{52} + \frac{(10-19,5)^2}{19,5} + \frac{(20-45,5)^2}{45,5} + \\ & + \frac{(20-13)^2}{13} + \frac{(80-52)^2}{52} = 470,33 \end{aligned}$$

$$\chi^2_{0,05}(6) = 12,59 \quad \chi^2 > \chi^2_{0,05}(6)$$

Rechazamos con un nivel de significación del 5% la hipótesis de que no existe relación entre el grado de educación y el nivel de rendimiento.

EJEMPLO 12.13.

Un investigador desea estimar la relación que existe entre el sexo y la preferencia por dos marcas de un mismo producto; se tomó una muestra aleatoria de 200 personas y se obtuvieron los siguientes resultados:

Sexo \ Marca	A	B	Total
F	58	22	80
M	72	48	120
Total	130	70	200

$$H_0: p_{ij} = p_{i.} p_{.j}; \quad H_1: p_{ij} \neq p_{i.} p_{.j}$$

$$\hat{p}_{1.} = \frac{80}{200}; \quad \hat{p}_{2.} = \frac{120}{200}; \quad \hat{p}_{.1} = \frac{130}{200}; \quad \hat{p}_{.2} = \frac{70}{200};$$

$$\hat{p}_{11} = \frac{80 \times 130}{200^2}; \quad \hat{p}_{12} = \frac{80 \times 70}{200^2}; \quad \hat{p}_{21} = \frac{120 \times 130}{200^2}; \quad \hat{p}_{22} = \frac{120 \times 70}{200^2}$$

Frecuencias esperadas:

			Total
	52	28	80
	78	42	120
Total	130	70	200

$$\chi^2 = \frac{(58-52)^2}{52} + \frac{(22-28)^2}{28} + \frac{(72-70)^2}{70} + \frac{(48-42)^2}{42} = 3,35$$

$$\chi^2_{0,05}(1) = 3,84 \quad \chi^2 < \chi^2_{0,05}(1)$$

Se acepta H_0 ; es decir, se acepta la hipótesis de independencia, de que no existe relación entre el sexo y la preferencia por una determinada marca.

12.5. COEFICIENTE DE CONTINGENCIA

En la sección anterior se estudió un procedimiento para contrastar la independencia de dos variables aleatorias de tipocualitativo. El contraste nos dice si existe aparentemente relación o no entre las variables, parece conveniente tener alguna medida que indique la fuerza de relación entre las variables; esta medida es el coeficiente de contingencia que viene a ser para datos cualitativos lo que es el coeficiente de correlación para datos cuantitativos.

En el ejemplo 12.12 se estableció la existencia de una relación entre el grado de educación y el nivel de rendimiento en una industria, se trata de investigar ahora si esa correlación es alta o baja.

El coeficiente de contingencia es:

$$c = \sqrt{\frac{\chi^2}{\chi^2 + n}}$$

Este coeficiente se acerca a cero cuando χ^2 es pequeño; o sea, cuando se acepta la hipótesis de no relación; y se acerca a 1, cuando existe correlación (χ^2 grande).

Hay que hacer notar que este coeficiente nunca llega a ser uno, por lo cual no se pueden comparar sino coeficientes de contingencia de tablas similares en cuanto al número de categorías en cada criterio de clasificación.

A continuación se presentan los valores máximos de c para distinto número de categorías ²².

²² K. A. Yeomans, Applied Statistics. Statistics for the Social Scientist. Volume Two. Penguin Books, 1968

Tabla	2x2	3x3	4x4	5x5	6x6	7x7	8x8	9x9	10x10
Máximo c	0,707	0,816	0,866	0,894	0,913	0,926	0,935	0,943	0,949

EJEMPLO 12.14.

El coeficiente de contingencia en el ejemplo 12.12 es:

$$c = \sqrt{\frac{470,33}{470,33 + 400}} = 0,73$$

EJEMPLO 12.15.

En el ejemplo 12.13.

$$c = \sqrt{\frac{3,35}{3,35 + 200}} = 0,129$$

EJERCICIOS RESUELTOS

12.1. Una muestra de 100 familias con 5 hijos dio los siguientes resultados en cuanto al número de hijos varones:

Nº de Varones	Nº de Familias
0	3
1	26
2	34
3	24
4	6
5	2
	100

Según los resultados de la muestra. ¿Se podría afirmar que el número de hijos varones en familias con 5 hijos es una variable aleatoria binomial? Use $\alpha = 0,05$

Solución:

Se trata de aplicar el contraste χ^2 de bondad del ajuste. H_0 : Número de hijos varones en familia de 5 hijos obedece a una distribución binomial.

Primero se debe estimar el parámetro desconocido p . Se sabe que el estimador máximo verosímil de " p " en una población binomial, es la proporción muestral $\hat{p}$.

$$\hat{p} = \frac{\text{Número de varones de la muestra}}{\text{Número total de hijos}} = \frac{200}{500} = 0,4$$

Otra forma de estimar " p " es estimando primero la media

$$\bar{x} = \frac{\sum xf(x)}{F} = \frac{200}{100} = 2$$

Como en la binomial $E(x) = np$; $2 = 5\hat{p}$; $\hat{p} = 0,4$. Una vez estimado p , usemos el estimador para calcular las probabilidades de que haya x varones ($x = 0, 1, \dots, 5$), y la frecuencia teórica f_i^0 .

x	f_i	$p_i^0 = \binom{5}{i} p^i (1-p)^{5-i}$	f_i^0	$(f_i - f_i^0)^2$
0	8	$\binom{5}{0} 0,4^0 0,6^5 = 0,0778$	7,78	0,0484
1	26	$\binom{5}{1} 0,4 0,6^4 = 0,2592$	25,92	0,0064
2	34	$\binom{5}{2} 0,4^2 0,6^3 = 0,3456$	34,56	0,3136
3	24	$\binom{5}{3} 0,4^3 0,6^2 = 0,2304$	23,04	0,9216
4	6	$\binom{5}{4} 0,4^4 0,6 = 0,0768$	7,68	0,4900
5	2	$\binom{5}{5} 0,4^5 0,6^0 = 0,0102$	1,02	

$$\chi^2 = \frac{0,0484}{7,78} + \frac{0,0064}{25,92} + \frac{0,3136}{34,56} + \frac{0,9216}{23,64} + \frac{0,4900}{8,70} = 0,1108$$

grados de libertad $r - 1 - k = 5 - 1 - 1 = 3$

$$\chi_{0,05}^2 (3) = 7,81 \quad 0,1108 < 7,81$$

El ajuste de los datos muestrales a una binomial es bueno; se acepta H_0 .

- 12.2. El número de defectos menores que tienen 100 artículos de vidrio producidos por una fábrica fueron los siguientes:

N° de Defectos	x	0	1	2	3	4	5
N° de Artículos	f_i	50	20	10	10	5	5

Verificar si el número de defectos es una variable aleatoria que obedece a la distribución de Poisson, con media igual a 1. $\alpha = 0,05$.

Solución:

H_0 : x es una variable Poisson con media 1; $n = 100$

x	0	1	2	3	4	5
f_i	50	20	10	10	5	5
p_i^0	0,3679	0,3679	0,1839	0,0613	0,0153	0,0037
f_i^0	36,79	36,79	18,39	6,13	1,53	0,37

8,03

Se agrupan los 3 últimos datos para que $f_i^0 > 5$

$$\chi^2 = \frac{(50 - 36,79)^2}{36,79} + \frac{(20 - 36,79)^2}{36,79} + \frac{(10 - 18,39)^2}{18,39} + \frac{(20 - 8,03)^2}{8,03} = 34,06$$

Grados de libertad: $r - 1 = 3$

$$\chi_{0,05}^2 (3) = 7,81 \quad 34,06 > 7,81$$

Los datos no se ajustan bien a una Poisson con media uno; se rechaza H_0 .

- 12.3. El costo por unidad de la materia prima de una fábrica es una variable aleatoria que depende del costo de producción del proveedor. Una muestra aleatoria de 500 unidades facturadas por el proveedor dio los siguientes resultados:

Precio Bs.	2,7-3,1	3,1-3,5	3,5-3,9	3,9-4,3	4,3-4,7	4,7-5,1
Cantidad	19	67	141	157	94	22

Verificar si los datos de costo se ajustan a una distribución normal. $\alpha = 0,10$.

Solución:

H_0 : Costo es una variable normal.

Se procede a calcular $\bar{x}$ y s^2

x	Marca de Clase x_i	f_i	$x_i f_i$	x_i^2	$x_i^2 f_i$
2,7 - 3,1	2,9	19	55,10	8,41	159,79
3,1 - 3,5	3,3	67	221,10	10,89	729,63
3,5 - 3,9	3,7	141	521,70	13,69	1.930,29
3,9 - 4,3	4,1	157	643,70	16,81	2.639,17
4,3 - 4,7	4,5	94	423,00	20,25	1.903,50
4,7 - 5,1	4,9	22	107,80	24,01	528,22
		500	1.972,40		7.890,60

$$\bar{x} = \frac{\sum x_i f_i}{F} = \frac{1.972,40}{500} = 3,945$$

$$s^2 = \frac{\sum (x_i - \bar{x})^2 f_i}{F} = \frac{\sum x_i^2 f_i}{F} - \bar{x}^2 = \frac{7.890,60}{500} - 3,945^2 = 0,2182$$

$$s = \sqrt{0,2182} = 0,4671$$

Calculemos ahora las probabilidades de que una variable normal (3,945 ; 0,2132) caiga en los respectivos intervalos.

x	f _i	$\frac{x - \mu}{\sigma}$	p _i ⁰	f _i ⁰ = np _i ⁰	$(f_i - f_i^0)^2 / f_i^0$
< 3,1	19	-1,81	0,0351	17,55	0,1198
3,1 - 3,5	67	-0,95	0,1360	68,00	0,0147
3,5 - 3,9	141	-0,10	0,2891	144,55	0,0872
3,9 - 4,3	157	0,76	0,3162	158,10	0,0077
4,3 - 4,7	94	1,62	0,1710	85,50	0,8450
> 4,7	22	2,47	0,0526	26,30	0,7030
	500		1,0000	500,00	1,7774

En la tercera columna se enumeran los valores de la variable tipificada.

$$\chi^2 = 1,7774 \quad \text{Grados de libertad} = 6 - 1 - 2 = 3$$

$$\chi_{0,10}^2 = 6,25 \quad 1,7774 < 6,25$$

Los datos se ajustan bien a una normal; se acepta H₀.

- 12.4. Supongamos que por experiencia pasada se sabe que el costo medio es 4, con una desviación típica de 0,5. Usar el contraste de Kolmogorov - Smirnov para verificar que es una variable normal; $\alpha = 0,10$.

Solución:

H₀ : F(x) es una distribución Normal $\mu = 4$, $\sigma = 0,5$. Debemos comparar las frecuencias relativas muestrales acumuladas [F_n(x)] con las frecuencias relativas teóricas acumuladas dadas por la función de distribución teórica F₀(x).

x	F _n (x)	$\frac{x - \mu}{\sigma}$	F ₀ (x)	F _n (x) - F ₀ (x)
3,1	0,0380	-1,8	0,0359	0,0021
3,5	0,1720	-1,0	0,1587	0,0133
3,9	0,4540	-0,2	0,4207	0,0333
4,3	0,7680	0,6	0,7257	0,0423
4,7	0,9560	1,4	0,9192	0,0368
> 4,7	1,0000		1,0000	

$$D_n = \max |F_n(x) - F_0(x)| = 0,0423$$

$$D_{100,0,10} = \frac{1,22}{\sqrt{500}} = 0,0546 \quad 0,0423 < 0,0546$$

Se acepta H₀.

- 12.5. Una muestra aleatoria de 150 aparatos eléctricos domésticos dio los siguientes resultados, acerca de la vida útil de los mismos.

Tiempo en años	< 1	1-2	2-3	3-4	4-5	5-6
Nº de Aparatos	40	28	23	19	15	25

Usando esta información contraste la hipótesis de que el tiempo de vida útil es exponencialmente distribuido, con media 3. $\alpha = 0,10$.

Solución:

x	f _i	p _i ⁰	f _i ⁰	$(f_i - f_i^0)^2 / f_i^0$
0 - 1	40	0,2811	42,17	0,1117
1 - 2	28	0,2072	31,09	0,3072
2 - 3	23	0,1438	21,56	0,0964
3 - 4	19	0,0985	14,78	1,2052
4 - 5	15	0,0743	11,15	1,3298
5 ó más	25	0,1951	29,25	0,6176
				3,6679

$$p_i^0 = \int_{a_{i-1}}^{a_i} \frac{1}{3} e^{-x/3} dx = -c \frac{-a_i}{3} + c \frac{-a_{i-1}}{3}$$

$$\text{En particular } p_1^0 = -c^{-1/3} + c^0 = 1 - 0,7189 = 0,2811$$

$$\chi^2 = 3,6679 \quad \text{Grados de libertad} = 6 - 1 = 5$$

$$\chi^2_{0,10}(5) = 9,24 \quad 3,6679 < 9,24$$

El ajuste de los datos a la distribución exponencial es bueno; se acepta H_0 .

12.6. Usar el contraste de Kolmogorov - Smirnov para verificar la bondad del ajuste del ejercicio anterior.

Solución:

H_0 : $F(x)$ es exponencial con media 3.

x	$F_n(x)$	$F_0(x)$	$ F_n(x) - F_0(x) $
1	0,2666	0,2811	0,0145
2	0,4533	0,4833	0,0350
3	0,6066	0,6321	0,0255
4	0,7333	0,7306	0,0027
5	0,8333	0,8049	0,0284
>5	1,0000	1,0000	

$$D_n = \max |F_n(x) - F_0(x)| = 0,0350$$

$$D_{150; 0,10} = \frac{1,22}{\sqrt{150}} = 0,0996$$

Se acepta H_0 .

12.7. En un estudio sobre desarrollo turístico se escogió una muestra aleatoria de personas del Oriente, Centro y Occidente de Venezuela, y se les preguntó acerca de sus preferencias vacacionales hacia Margarita u otras zonas del país, con los siguientes resultados:

Región Preferencia	Zona de Procedencia			
	Oriente	Centro	Occidente	Total
Margarita	40	35	30	105
Otras Zonas	30	40	40	110
Indiferentes	10	15	15	40
Total	80	90	85	255

i) ¿Reflejan los datos de que la preferencia por Margarita está regionalmente afectada? $\alpha = 0,05$.

ii) Calcular el coeficiente de contingencia.

Solución:

Se trata de establecer la independencia de la preferencia por zona turística, y la procedencia de las personas.

$$H_0: p_{ij} = p_{i.} \cdot p_{.j} \quad \forall i, j$$

$$H_1: p_{ij} \neq p_{i.} \cdot p_{.j}$$

Calculemos los estimadores de las probabilidades marginales

$$\hat{p}_{1.} = 105/255; \quad \hat{p}_{2.} = 110/255; \quad \hat{p}_{3.} = 40/255$$

$$\hat{p}_{.1} = 80/255; \quad \hat{p}_{.2} = 90/255; \quad \hat{p}_{.3} = 85/255$$

Los estimadores de las probabilidades conjuntas p_{ij} , si la hipótesis H_0 es verdadera (independencia), son: $\hat{p}_{ij} = \hat{p}_{i.} \cdot \hat{p}_{.j}$

$$\hat{p}_{11} = \frac{105 \times 80}{255^2}; \quad \hat{p}_{12} = \frac{105 \times 90}{255^2}; \quad \hat{p}_{13} = \frac{105 \times 85}{255^2}$$

$$\hat{p}_{21} = \frac{110 \times 80}{255^2}; \quad \hat{p}_{22} = \frac{110 \times 90}{255^2}; \quad \hat{p}_{23} = \frac{110 \times 85}{255^2}$$

$$\hat{p}_{31} = \frac{40 \times 80}{255^2}; \quad \hat{p}_{32} = \frac{40 \times 90}{255^2}; \quad \hat{p}_{33} = \frac{40 \times 85}{255^2}$$

Las frecuencias esperadas, si H_0 es verdadera, son: $f_{ij} = n\hat{p}_{ij}$

	Zona de Procedencia			Total
Región Preferencia	Oriente	Centro	Occidente	Total
	32,94	37,06	35,00	105
	34,51	38,82	36,67	110
Indiferentes	12,55	14,12	13,33	40
	80	90	85	255

$$\chi^2 = \frac{(40 - 32,94)^2}{32,94} + \frac{(35 - 37,06)^2}{37,06} + \dots + \frac{(15 - 13,33)^2}{13,33} = 4,0518$$

Grados de libertad: $(r - 1)(c - 1) = 2 \times 2 = 4$; $\chi^2_{0,05}(4) = 9,49$

$$4,0518 < 9,49$$

Se acepta H_0 . Se acepta la independencia de las dos variables o criterios.

$$ii) \quad c = \sqrt{\frac{\chi^2}{\chi^2 + n}} = \sqrt{\frac{4,0518}{259,0518}} = 0,1249$$

12.8. En un estudio socioeconómico se pretende analizar la influencia del origen socioeconómico de los estudiantes con relación a la preferencia por colegios públicos o privados. Una muestra aleatoria de 1.095 estudiantes dio los siguientes resultados:

Categoría Socio-Económica del padre medida por su profesión	Tipo de Colegio		Total
	Privado	Público	
Profesionales Universitarios	250	75	325
Comerciantes e Industriales	175	92	267
Empleados (no universitarios)	125	138	263
Obreros	90	150	240
Total	640	455	1.095

i) ¿Está el tipo de colegio influenciado por la clase socioeconómica de las familias?
 $\alpha = 0,10$. ii) Calcular el coeficiente de contingencia.

Solución:

$$H_0 : p_{ij} = p_{i.} p_{.j}$$

$$H_1 : p_{ij} \neq p_{i.} p_{.j}$$

$$\hat{p}_{1.} = 325/1.095; \quad \hat{p}_{2.} = 267/1.095; \quad \hat{p}_{3.} = 263/1.095; \quad \hat{p}_{4.} = 240/1.095$$

$$\hat{p}_{.1} = 640/1.095; \quad \hat{p}_{.2} = 455/1.095$$

$$\hat{p}_{11} = \frac{325 \times 640}{1.095^2}; \quad \hat{p}_{12} = \frac{325 \times 455}{1.095^2}; \quad \hat{p}_{21} = \frac{267 \times 640}{1.095^2}; \quad \hat{p}_{22} = \frac{267 \times 455}{1.095^2}$$

$$\hat{p}_{31} = \frac{263 \times 640}{1.095^2}; \quad \hat{p}_{32} = \frac{263 \times 455}{1.095^2}; \quad \hat{p}_{41} = \frac{240 \times 640}{1.095^2}; \quad \hat{p}_{42} = \frac{240 \times 455}{1.095^2}$$

Frecuencias esperadas siendo verdadera H_0 :

	Total	
Profesionales Universitarios	189,95	135,05
Comerciantes e Industriales	156,05	110,95
Empleados (no universitarios)	153,73	109,27
Obreros	140,27	99,73
Total	640,00	455,00

$$\chi^2 = \frac{(250 - 189,95)^2}{189,95} + \dots + \frac{(150 - 99,73)^2}{99,73} = 107,50$$

Grados de libertad: $(r - 1)(c - 1) = 3 \times 1 = 3$; $\chi^2_{0,10}(3) = 2,71$

$107,50 > 2,71$. Se rechaza H_0 . No son independientes. El tipo de colegio está influenciado por el nivel socioeconómico.

$$ii) \quad c = \sqrt{\frac{\chi^2}{\chi^2 + n}} = \sqrt{\frac{107,5}{107,5 + 1.095}} = 0,2989$$

EJERCICIOS PROPUESTOS

12.9. El departamento de control de calidad de una empresa inspeccionó aleatoriamente 400 cajas de bombillos con 4 bombillos cada una. El número de bombillos defectuosos en cada caja fue:

Nº de bombillos defectuosos	Nº de cajas
0	312
1	72
2	9
3	6
4	1

Comprobar si los datos muestrales se ajustan a una distribución binomial, $\alpha=0,05$.

- 12.10. En una tienda de ropa para hombres se ha hallado que de las personas que entran a la tienda, el 30% no compran trajes, el 40% compran trajes de precio bajo, el 10% trajes de precio medio, y el 20% trajes de precio alto. Una muestra de 200 personas dio los siguientes resultados:

	Nº de personas
No compraron trajes	57
Traje de precio bajo	75
Traje de precio medio	25
Traje de precio alto	43
	200

Con un nivel de significación del 5%. ¿Se rechazaría la hipótesis de que los porcentajes dados son correctos?

- 12.11. El número de accidentes ocurridos en una autopista durante 267 días escogidos aleatoriamente fueron:

Accidentes	x	0-3	4	5	6	7	8	9	10	11	12	13	14	15
Días	f_i	6	11	14	22	43	31	40	35	20	18	12	7	8

¿Se ajustan los datos a una distribución de Poisson? $\alpha = 0,05$

- 12.12. En un viaje de Caracas a Maiquetía, 250 personas tardaron :

Tiempo	Nº de personas
40' - 45'	49
45' - 50'	52
50' - 55'	55
55' - 60'	54

¿Es el tiempo de viaje de Caracas a Maiquetía una variable uniforme entre 40' y 60'? $\alpha = 0,05$

- 12.13. Usar el contraste de Kolmogorov - Smirnov para verificar la hipótesis de uniformidad en el ejercicio anterior.

- 12.14. La demanda diaria de un cierto bien se considera que obedece a una distribución normal. Se observó la demanda en 100 días, con los siguientes resultados:

Demanda	0-20	20-40	40-60	60-80	80-100	100-120	120-140	140-160	160-180
Días	5	13	13	14	17	12	15	7	4

¿Se ajustan los datos a una distribución normal? $\alpha = 0,05$

- 12.15. Por experiencia pasada se sabe que las ventas medias del ejercicio anterior son 80, con una desviación típica de 40. Usar el contraste de Kolmogorov - Smirnov para verificar la hipótesis de normalidad.

- 12.16. Los ingresos diarios de 80 familias de una urbanización de Caracas fueron:

Ingresos	Familias
500 - 999	6
1000 - 1499	12
1500 - 1999	19
2000 - 2499	20
2500 - 2999	13
3000 - 3499	8
3500 - 3999	2

Contrastar con un nivel de significación del 5%, la hipótesis de que el ingreso es una variable normal.

- 12.17. Por estudios anteriores se sabe que los ingresos medios de las familias de la urbanización del ejercicio anterior son de Bs. 2.100, con una desviación típica de 750. Usar el contraste de Kolmogorov - Smirnov para verificar la hipótesis de normalidad. $\alpha = 0,05$

- 12.18. El tiempo que dura una persona desempleada al entrar por primera vez en el mercado de trabajo, se considera una variable exponencialmente distribuida. Una muestra de 250 personas arrojó los siguientes resultados:

Tiempo (días)	Personas
0 - 100	131
100 - 200	68
200 - 300	62
300 - 400	14
> 400	5

Por otro lado, los datos de la muestra dieron una media de 120 días. Con un nivel de significación del 10%, verificar si los datos se ajustan a una distribución exponencial.

- 12.19. Usar el contraste de Kolmogorov-Smirnov para verificar la hipótesis de que el tiempo es exponencial, con media 120.

- 12.20. Se va a experimentar un nuevo tipo de pintura de carros. El estado de la pintura de 135 carros se examinó después de haberlos sometido a un procedimiento cuyos efectos eran equivalentes al uso normal de un carro por un año, con los siguientes resultados:

Tipo de Pintura	Estado del Carro			Total
	Buena	Regular	Mala	
Nueva	45	25	15	85
Antigua	15	25	10	50
Total	60	50	25	135

- i) ¿Es el tipo de pintura factor importante en el estado de los carros? $\alpha = 0,10$.
ii) Calcular el coeficiente de contingencia.

- 12.21. Los siguientes datos corresponden a la clasificación de empresas vendedoras de un mismo producto según dos criterios: El área de la zona metropolitana en que están ubicadas, y el volumen de ventas con relación al promedio de éstas:

	Sabana Grande	Centro	Otras zonas	Total
Ventas menores que el promedio	58	46	38	142
Ventas en el promedio	102	160	84	346
Ventas mayores que el promedio	34	51	60	145
Total	194	257	182	633

- i) ¿Según esos datos se podría decir que la ubicación influye en el volumen de ventas? $\alpha = 0,05$. ii) Calcular el coeficiente de contingencia.

- 12.22. Los datos que se presentan en la tabla corresponden a 476 familias clasificadas según dos criterios: El área en que habitan, y el nivel de educación de los hijos mayores de 16 años;

Área	Nivel de Educación			Total
	Secundaria	Primaria	Ninguna	
Urbana > 50.000 h.	75	58	11	144
Urbana < 50.000 h.	53	101	22	176
Rural	33	85	38	156
Total	161	244	71	476

- i) ¿Evidencian los datos influencia del área sobre el nivel de educación alcanzado? $\alpha = 0,01$. ii) Calcular el coeficiente de contingencia.

- 12.23. Una encuesta de 100 personas de las áreas urbanas y rural sobre la preferencia por candidatos a presidente, dio los siguientes resultados:

Candidato	Area		Total
	Urbana	Rural	
A	10	20	30
B	20	10	30
C	30	10	40
Total	60	40	100

i) ¿Hay diferencia en las preferencias debido a las áreas? $\alpha = 0,05$. ii) Calcular el coeficiente de contingencia.

12.24. Los datos siguientes pertenecen a un estudio sobre la preferencia de las personas por programas de T.V. sobre problemas sociales. Las personas están clasificadas por edad y preferencia o no de programas de tipo social.

Respuesta	Edad			Total
	Menores de 20 años	Entre 20 y 45	Mayores de 45	
Favorable	375	339	144	858
Desfavorable	164	138	58	360
Indiferentes	46	32	22	100

i) Verificar la hipótesis de independencia entre la edad y la preferencia por esos programas. $\alpha = 0,10$; ii) Calcular el coeficiente de contingencia.

12.25. Un estudio sobre la posible implantación de subsidio familiar dio los siguientes datos de 139 familias, clasificadas de acuerdo con el número de hijos y a su preferencia por dos proyectos de subsidio.

Nº de Hijos	Proyecto			Total
	A	B	Indiferentes	
Ninguno	11	12	6	29
0 - 3	18	20	11	49
4 - 5	12	19	9	40
Más de 5	5	12	4	21
Total	46	63	30	139

i) Contrastar la hipótesis de independencia entre el número de hijos y la preferencia por alguno de los dos proyectos. $\alpha = 0,05$.

ii) Calcular el coeficiente de contingencia.

CAPITULO XIII

ANALISIS DE VARIANZA

13.1. INTRODUCCION

El problema que se va a tratar en este capítulo es el de la igualdad de medias de más de dos poblaciones. En el Capítulo XI se estudiaron los contrastes sobre igualdad de medias de dos poblaciones, ahora generalizamos el problema para cubrir simultáneamente más de dos poblaciones. Por ejemplo, se puede estar interesado en averiguar si distintos métodos de entrenamiento aplicados a un grupo de trabajadores en una industria, producen iguales o diferentes efectos sobre la productividad; en este caso, la igualdad o diferencia de las productividades medias representarían la igualdad o diferencia de los efectos de distintos tratamientos aplicados a una población.

Un segundo ejemplo podría ser, analizar la influencia del nivel de educación en el ingreso, medido por los ingresos medios obtenidos en distintos niveles de educación.

En todo caso, el problema se puede generalizar de la siguiente forma: se tienen k poblaciones con medias $\mu_1, \mu_2, \dots, \mu_k$, y se trata de contrastar la hipótesis nula $\mu_1 = \mu_2 = \dots = \mu_k = \mu$.

Se podría pensar en la posibilidad o conveniencia de resolver el problema, utilizando repetidas veces el contraste sobre igualdad de dos medias explicado en el Capítulo XI, aplicado sucesivamente a todos los posibles pares de poblaciones que se pueden combinar con k poblaciones. Tal procedimiento, además de laborioso, adolece del defecto de presentar una probabilidad de error demasiado alta para ser aceptable. En efecto,

supongamos que en el ejemplo anterior hay 5 métodos diferentes de entrenamiento, lo que implica que tenemos 5 medias cuya igualdad deseamos contrastar. ($k = 5$). Supongamos que los métodos tienen el mismo efecto en la productividad; es decir, que la hipótesis de igualdad de medias es verdadera.

Necesitaríamos 10 contrastes de medias tomadas dos a dos; si el nivel de significación de cada contraste se fija en $\alpha = 0,05$, la probabilidad de rechazar la hipótesis verdadera $\mu_1 = \mu_j$ en cada contraste, es 0,05; y la probabilidad de llegar a una conclusión correcta (aceptar la hipótesis), es 0,95. Como tenemos 10 contrastes la probabilidad de llegar a una conclusión correcta conjuntamente es $0,95^{10}$, lo que implica que la probabilidad de cometer error, rechazar la igualdad de medias es $1 - 0,95^{10} \approx 0,40$, demasiado alta para ser aceptable.

Afortunadamente existe un método aplicable bajo ciertas condiciones, para realizar este tipo de contraste. El método se conoce como "Análisis de Varianza", que consiste en descomponer la dispersión de los datos muestrales alrededor de la media en dos componentes: uno aleatorio debido al proceso muestral, y otro debido a la posible desigualdad de las medias poblacionales; la magnitud relativa de este componente constituye la base para la toma de decisiones sobre la igualdad o desigualdad de las medias poblacionales.

13.2. CLASIFICACION SIMPLE

El primer caso que estudiaremos es el que se conoce como "Clasificación simple" o "Un solo criterio de clasificación", al cual pertenecen los ejemplos de la sección anterior.

13.2.1. PLANTEAMIENTO DEL PROBLEMA Y NOMENCLATURA

Se tienen k poblaciones con medias $\mu_1, \mu_2, \mu_3, \dots, \mu_k$, y se trata de contrastar la hipótesis nula

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_k = \mu$$

de igualdad de medias, contra la hipótesis alternativa.

$$H_1 : \text{por lo menos dos medias son diferentes.}$$

Se toma de cada población una muestra aleatoria cuyo tamaño puede ser igual o diferente, con lo que se tienen k muestras independientes con un determinado número de observaciones cada una. Sea n_j el número de elementos de la muestra j ($j = 1, 2, \dots, k$); o sea, n_1 es el número de elementos de la muestra tomada de la población uno, n_2 el número de elementos de la muestra tomada de la población dos, etc. En el caso de iguales tamaños de muestra $n_1 = n_2 = \dots = n_k = n$.

Para simplificar la exposición del procedimiento, se hará el análisis suponiendo el mismo número de elementos (n) en cada muestra. (Con distintos tamaños de muestra el procedimiento sufre ligeras modificaciones de forma, y no de fondo).

Las observaciones individuales de las muestras se representarán por x_{ij} ; el primer subíndice indica el número de la observación dentro de la muestra a , mientras que el segundo indica el número de la muestra; p. ej. x_{12} representa el elemento 1 de la muestra 2; x_{34} el elemento 3 de la muestra 4, y en general x_{ij} el elemento i de la muestra j , en consecuencia el subíndice i toma valores de 1 hasta n ($i = 1, 2, \dots, n$) y el subíndice j de 1 hasta k ($j = 1, 2, \dots, k$).

La tabla 13.1 presenta en forma general las observaciones muestrales

TABLA 13.1.

	Muestra 1	Muestra 2	Muestra k
	x_{11}	x_{12}	x_{1k}
	x_{21}	x_{22}	x_{2k}
	x_{31}	x_{32}	x_{3k}
	$\vdots$	$\vdots$	$\vdots$
	x_{n1}	x_{n2}	x_{nk}
Sumas	$\sum_{i=1}^n x_{i1}$	$\sum_{i=1}^n x_{i2}$	$\sum_{i=1}^n x_{ik}$
Medias muestrales	$\bar{x}_1$	$\bar{x}_2$	$\bar{x}_k$
Varianzas muestrales	S_1^2	S_2^2	S_k^2

En la penúltima fila de la tabla están las medias muestrales de cada muestra; $\bar{x}_j$ es la media muestral de la muestra j .

$$\bar{X}_j = \frac{\sum_{i=1}^n X_{ij}}{n}$$

En la última fila aparecen las varianzas muestrales de cada muestra; S_j^2 es la varianza muestral de la muestra j .

$$S_j^2 = \frac{\sum_{i=1}^n (X_{ij} - \bar{X}_j)^2}{n}$$

Definimos la "gran media" como la media de todas las observaciones.

$$\bar{X} = \frac{\sum_{j=1}^k \sum_{i=1}^n X_{ij}}{kn}$$

El símbolo de doble sumatoria del numerador, que puede confundir al lector, implica simplemente que deben sumarse todas las observaciones; o sea, que el numerador es la suma de las sumas parciales que aparecen en la antepenúltima fila de la tabla 13.1. [Prime-

ro se suman las observaciones verticalmente $\left(\sum_{i=1}^n X_{ij} \right)$, y esas sumas parciales se suman

horizontalmente $\left(\sum_{j=1}^k \sum_{i=1}^n X_{ij} \right)$; como tenemos k muestras cada una de n elementos, el

número total de elementos es $k.n$, que aparece como denominador en la gran media.

Es fácil ver que, en este caso, la gran media es también igual al promedio de las medias muestrales,

$$\bar{X} = \frac{\sum_{j=1}^k \bar{X}_j}{k}$$

Antes de continuar la exposición, veamos un ejemplo numérico con el fin de visualizar el cálculo de las magnitudes anteriores,

EJEMPLO 13.1.

En una industria se escogen 3 grupos de 5 obreros cada uno, y se les da entrenamiento con base en 3 diferentes métodos. Las productividades de los obreros después del entrenamiento fueron las siguientes:

Método 1	Método 2	Método 3
20	25	16
25	26	18
23	20	15
18	29	20
19	30	21

Las magnitudes definidas anteriormente son en el ejemplo

Medias Muestrales

$$\bar{X}_1 = \frac{\sum_{i=1}^5 X_{i1}}{5} = \frac{20 + 25 + 23 + 18 + 19}{5} = 21$$

$$\bar{X}_2 = \frac{\sum_{i=1}^5 X_{i2}}{5} = \frac{25 + 26 + 20 + 29 + 30}{5} = 26$$

$$\bar{X}_3 = \frac{\sum_{i=1}^5 X_{i3}}{5} = \frac{16 + 18 + 15 + 20 + 21}{5} = 18$$

Varianzas Muestrales

$$S_1^2 = \frac{\sum_{i=1}^5 (X_{i1} - \bar{X}_1)^2}{5} =$$

$$= \frac{(20 - 21)^2 + (25 - 21)^2 + (23 - 21)^2 + (18 - 21)^2 + (19 - 21)^2}{5} = \frac{34}{5}$$

$$S_2^2 = \frac{\sum_{i=1}^5 (X_{i2} - \bar{X}_2)^2}{5} =$$

$$= \frac{(25-26)^2 + (26-26)^2 + (20-26)^2 + (29-26)^2 + (30-26)^2}{5} = \frac{62}{5}$$

$$S_3^2 = \frac{\sum_{i=1}^5 (X_{i3} - \bar{X}_3)^2}{5} =$$

$$= \frac{(16-18)^2 + (18-18)^2 + (15-18)^2 + (20-18)^2 + (21-18)^2}{5} = \frac{26}{5}$$

Las varianzas muestrales también se pueden calcular con la expresión abreviada que se vio en el Capítulo VII.

Gran Media

$$\bar{X} = \frac{\sum_{j=1}^k \sum_{i=1}^n X_{ij}}{kn} =$$

$$= \frac{(20+25+23+18+19) + (25+26+20+29+20) + (16+18+15+20+21)}{15} = \frac{65}{3}$$

$$\text{o } \bar{X} = \frac{\sum_{j=1}^k \bar{X}_j}{k} = \frac{21+26+18}{3} = \frac{65}{3}$$

13.2.2. DESCOMPOSICION DE LA SUMA DE CUADRADOS

Consideremos la variable

$$STC = \sum_{j=1}^k \sum_{i=1}^n (X_{ij} - \bar{X})^2$$

suma de los cuadrados de las diferencias entre todos los elementos de la muestra y la gran media, STC es una medida de la dispersión de todas las observaciones respecto a $\bar{X}$.

Operando convenientemente, se puede descomponer la variación total medida por la suma total de los cuadrados (STC) en dos componentes; esta separación de STC en dos partes es la relación básica en el método de análisis de varianza.

$$\begin{aligned} STC &= \sum_{j=1}^k \sum_{i=1}^n (X_{ij} - \bar{X})^2 = \sum_{j=1}^k \sum_{i=1}^n [(X_{ij} - \bar{X}_j) + (\bar{X}_j - \bar{X})]^2 = \\ &= \sum_{j=1}^k \sum_{i=1}^n [(X_{ij} - \bar{X}_j)^2 + (\bar{X}_j - \bar{X})^2 + 2(X_{ij} - \bar{X}_j)(\bar{X}_j - \bar{X})] = \\ &= \sum_{j=1}^k \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2 + \sum_{j=1}^k \sum_{i=1}^n (\bar{X}_j - \bar{X})^2 + 2 \sum_{j=1}^k \sum_{i=1}^n (X_{ij} - \bar{X}_j)(\bar{X}_j - \bar{X}) = \\ &= \sum_{j=1}^k \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2 + \sum_{j=1}^k (\bar{X}_j - \bar{X})^2 \sum_{i=1}^n 1 + 2 \sum_{j=1}^k (\bar{X}_j - \bar{X}) \sum_{i=1}^n (X_{ij} - \bar{X}_j) \end{aligned}$$

En el paso anterior, en el segundo y tercer términos se ha sacado $(\bar{X}_j - \bar{X})^2$ factor común en la sumatoria sobre las i s.

$$\sum_{i=1}^n 1 = n \quad \text{y} \quad \sum_{i=1}^n (X_{ij} - \bar{X}_j) = 0$$

porque es la suma de las desviaciones de una variable con respecto a su media; luego en definitiva,

$$STC = \sum_{j=1}^k \sum_{i=1}^n (X_{ij} - \bar{X})^2 = \sum_{j=1}^k \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2 + n \sum_{j=1}^k (\bar{X}_j - \bar{X})^2$$

La variación o dispersión total de los datos se ha dividido en dos componentes, cada uno de los cuales refleja la variación debida a diferentes causas. En efecto, consideremos el primer término del segundo miembro de la relación anterior.

$$SCD = \sum_{j=1}^k \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2$$

Esta variable es una medida de la dispersión de las observaciones dentro de cada muestra alrededor de la media correspondiente. Su magnitud no está influida por la igualdad o desigualdad de las medias; es mayor a medida que las observaciones en cada grupo o muestra estén más dispersas; y sería cero si todas las observaciones correspondientes a una muestra tuvieran el mismo valor. Esta magnitud se suele conocer como la suma de cuadrados dentro de las muestras.

Observen que, puesto que:
$$S_j^2 = \frac{\sum_{i=1}^n (X_{ij} - \bar{X}_j)^2}{n},$$

$$SCD = \sum_{j=1}^k n S_j^2$$

En el ejemplo,

$$SCD = 34 + 62 + 26 = 122$$

El segundo término de la relación:

$$SCE = n \sum_{j=1}^k (\bar{X}_j - \bar{X})^2$$

es una medida de la dispersión de las medias muestrales con respecto a la gran media. Su magnitud está influida directamente por la diferencia entre las medias. Cuanto menos difieran las medias muestrales una de otra y de la gran media, SCE será menor; en el caso de que todas las medias muestrales fuesen iguales será cero. Esta magnitud se conoce como la suma de cuadrados entre muestras.

En el ejemplo,

$$SCE = 5 \left[\left(21 - \frac{65}{3} \right)^2 + \left(26 - \frac{65}{3} \right)^2 + \left(18 - \frac{65}{3} \right)^2 \right] = \frac{490}{3}$$

Además,

$$STC = 122 + \frac{490}{3} = \frac{856}{3}$$

En efecto,

$$STC = \sum_{j=1}^k \sum_{i=1}^n (X_{ij} - \bar{X})^2 = \left(20 - \frac{65}{3} \right)^2 + \left(25 - \frac{65}{3} \right)^2 + \dots + \left(21 - \frac{65}{3} \right)^2 = \frac{856}{3}$$

13.2.3. PROCEDIMIENTO DEL CONTRASTE

Un supuesto básico para la aplicabilidad del método de análisis de varianza es el de que las poblaciones cuyas medias se están contrastando son poblaciones normales con varianza común σ^2 . Evidentemente esto supone una limitación en el campo de aplicación del análisis de varianza; pero no es menos cierto que en la práctica en un porcentaje elevado de casos, los supuestos de normalidad y varianza común pueden ser razonablemente aceptados. En cada caso concreto el supuesto de normalidad se puede contrastar usando los métodos del capítulo anterior; y en el apéndice de este capítulo se dará un método para contrastar el supuesto de varianzas iguales.

El método de análisis de la varianza se basa en la comparación de dos estimadores de σ^2 obtenidos en forma diferente de los datos de las muestras.

Consideremos la suma de los cuadrados dentro de las muestras $SCD = \sum_{j=1}^k n S_j^2$

Sabemos que $\frac{n S_j^2}{\sigma^2}$ es una variable χ^2 con $n-1$ grados de libertad (Ver Sección 7.5.3.). Luego SCD, que es la suma de k variables χ^2 independientes, cada una con $n-1$ grados de libertad, es a su vez una variable χ^2 con $k(n-1)$ grados de libertad.

Además $\sum_{i=1}^n (X_{ij} - \bar{X}_j)^2 / (n-1)$ es un estimador insesgado de la varianza poblacional σ^2 (Ver Sección 8.3.1.). Tenemos k estimadores insesgados de σ^2 , uno por cada muestra, el promedio de éstos será:

$$\frac{\sum_{j=1}^k \left[\sum_{i=1}^n (X_{ij} - \bar{X}_j)^2 / (n-1) \right]}{k} = \frac{SCD}{k(n-1)} \quad (1)$$

que es a su vez un estimador insesgado de σ^2 .

Tenemos así un estimador insesgado de la varianza poblacional, basado la dispersión de los datos dentro de las muestras, cuyo valor no depende la verdad o falsedad de la hipótesis de igualdad de medias poblacionales

Por otro lado, si la hipótesis nula

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_k = \mu$$

es verdadera, y bajo los supuestos de normalidad y varianza común, las k poblaciones pueden considerarse como una sola población normal con media μ y varianza σ^2 ; entonces, al tomar una muestra aleatoria de n elementos sabemos que la media muestral es normal con media μ y varianza σ^2/n . Las medias muestrales de las k muestras $\bar{X}_1, \bar{X}_2, \dots, \bar{X}_k$ se pueden considerar como una muestra aleatoria de k elementos de una población normal $(\mu, \sigma^2/n)$.

La varianza muestral de esa muestra es:

$$S_{\bar{x}}^2 = \frac{\sum_{j=1}^k (\bar{X}_j - \bar{X})^2}{k}$$

y $\frac{kS_{\bar{x}}^2}{\sigma^2}$ es una variable χ^2 con $k - 1$ grados de libertad.

Además, la cuasivarianza muestral $\sum_{j=1}^k (\bar{X}_j - \bar{X})^2 / (k - 1)$ es un estimador insesgado de la varianza σ^2/n ; en consecuencia,

$$\frac{n \sum_{j=1}^k (\bar{X}_j - \bar{X})^2}{k - 1} = \frac{\text{SCE}}{k - 1} \quad (2)$$

es un estimador insesgado de σ^2 .

Hemos obtenido otro estimador insesgado de σ^2 independiente del anterior basado en la dispersión de las medias muestrales; el valor de este estimador sí está influenciado por la verdad o falsedad de la hipótesis nula.

Si obtenemos el cociente de los dos estimadores, tenemos:

$$\frac{\text{SCE}/k - 1}{\text{SCD}/k(n - 1)} = \frac{n \sum_{j=1}^k (\bar{X}_j - \bar{X})^2 / (k - 1)}{\sum_{j=1}^k \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2 / k(n - 1)} \quad (3)$$

Si H_0 es verdadera, el numerador y denominador de la relación anterior son ambos estimadores insesgados del mismo parámetro σ^2 ; deberíamos esperar que sus valores fueran similares y en consecuencia que su cociente fuese cercano a la unidad.

Si esto es así, la dispersión entre las medias muestrales medida por el numerador es de una magnitud que razonablemente puede esperarse aún siendo H_0 verdadera, por lo cual nos inclinamos a aceptar H_0 .

Por el contrario, si H_0 es falsa (las poblaciones tienen diferentes medias), el numerador tenderá a ser mayor (las medias muestrales tienden a diferir al provenir de poblaciones con distintas medias); mientras que el denominador no se verá afectado, en consecuencia el cociente tenderá a ser grande (mayor que la unidad).

Un cociente suficientemente grande arroja evidencia de falsedad de la hipótesis, y nos inclina a rechazarla.

Faltaría determinar cuan grande debe ser el cociente para que la dispersión de las medias muestrales sea significativa de diferencia de medias poblacionales.

La relación (3) es el cociente de dos variables χ^2 independientes divididas por sus grados de libertad; luego, es una variable F con $(k - 1)$ y $k(n - 1)$ grados de libertad.

Fijado un nivel de significación de α , el valor crítico tal que la probabilidad de rechazar la hipótesis siendo verdadera sea α es F_{α} ; luego, si

$$F = \frac{n \sum_{j=1}^k (\bar{X}_j - \bar{X})^2 / (k - 1)}{\sum_{j=1}^k \sum_{i=1}^n (X_{ij} - \bar{X}_j)^2 / k(n - 1)} = \frac{\text{SCE}/k - 1}{\text{SCD}/k(n - 1)}$$

es mayor que F_{α} , se rechaza la hipótesis; si es menor, se acepta.

Se observará que el contraste es de una cola por la derecha. La explicación es la siguiente: si H_0 es falsa, el numerador del cociente nunca será menor que si es verdadera; más bien deberá ser mayor, valores elevados de F arrojan duda sobre la verdad de la hipótesis, valores pequeños de F no. En consecuencia, la región crítica del contraste debe

estar situada a la derecha. Más aún, si el numerador es menor que el denominador ($F < 1$), se acepta la hipótesis sin realizar el contraste pues las diferencias de las medias muestrales no serán significativas.

EJEMPLO 13.2.

En el ejemplo 13.1

$$SCE = 490/3; \quad SCD = 122; \quad k = 3; \quad n = 5;$$

$$F = \frac{490/3 \cdot 2}{122/12} = 8,03 \quad F_{0,05}(2, 12) = 3,89$$

$F > F_{0,05}$. Luego, con un nivel de significación del 5% se rechaza la hipótesis de igualdad de medias poblacionales. Los distintos métodos de entrenamiento afectan en forma diferente las productividades.

13.2.4. FORMULAS PRACTICAS PARA SIMPLIFICACION DE CALCULOS

Las cantidades necesarias para realizar el análisis de varianza se pueden obtener de forma más simple, desarrollando las sumas de cuadrados.

$$STC = \sum_{j=1}^k \sum_{i=1}^n (X_{ij} - \bar{X})^2 = \sum_{j=1}^k \sum_{i=1}^n (X_{ij})^2 + \sum_{j=1}^k \sum_{i=1}^n \bar{X}^2 - 2 \sum_{j=1}^k \sum_{i=1}^n (X_{ij} \cdot \bar{X}) =$$

$$= \sum_{j=1}^k \sum_{i=1}^n (X_{ij})^2 + \sum_{j=1}^k n \bar{X}^2 - 2 \bar{X} \sum_{j=1}^k \sum_{i=1}^n X_{ij} =$$

$$= \sum_{j=1}^k \sum_{i=1}^n (X_{ij})^2 + kn \bar{X}^2 - 2 \bar{X} \cdot kn \bar{X} =$$

$$= \sum_{j=1}^k \sum_{i=1}^n (X_{ij})^2 - kn \bar{X}^2 = \sum_{j=1}^k \sum_{i=1}^n (X_{ij})^2 - kn \left[\frac{\sum_{j=1}^k \sum_{i=1}^n X_{ij}}{kn} \right]^2$$

En definitiva,

$$STC = \sum_{j=1}^k \sum_{i=1}^n X_{ij}^2 - \frac{1}{kn} \left(\sum_{j=1}^k \sum_{i=1}^n X_{ij} \right)^2$$

STC es entonces igual a la suma de los cuadrados de todas las observaciones, menos el cuadrado de la suma dividido por el número de observaciones.

$$SCD = \sum_{j=1}^k \sum_{i=1}^n X_{ij}^2 - \frac{1}{n} \sum_{j=1}^k \left(\sum_{i=1}^n X_{ij} \right)^2$$

$$SCE = \frac{1}{n} \sum_{j=1}^k \left(\sum_{i=1}^n X_{ij} \right)^2 - \frac{1}{kn} \left(\sum_{j=1}^k \sum_{i=1}^n X_{ij} \right)^2$$

Las pruebas de las dos últimas relaciones siguen los mismos pasos que la primera, y se dejan como ejercicio al lector.

EJEMPLO 13.3.

Aplicación al ejemplo 13.1. de las fórmulas anteriores

Cuadrado de las Observaciones

	400	625	256	
	625	676	324	
	529	400	225	
	324	841	400	
	361	900	441	
Totales	2.239	3.442	1.646	7.327

$$STC = 7.327 - \frac{325^2}{15} = \frac{856}{3}$$

$$SCD = 7.327 - \frac{1}{5}(105^2 + 130^2 + 90^2) = 122$$

$$SCE = \frac{1}{5}(105^2 + 130^2 + 90^2) - \frac{325^2}{15} = 490/3$$

Los resultados del análisis de la varianza se suelen presentar en una tabla.

TABLA 13.2.

Análisis de Varianza

(1) Fuente de Variación	(2) Suma de Cuadrados	(3) Grados de Libertad	(4) (2)/(3)	F
Entre Muestras	SCE	k - 1	SCE/(k - 1)	$\frac{SCE/(k - 1)}{SCD/k (n - 1)}$
Dentro de Muestras	SCD	k (n - 1)	SCD/k (n - 1)	
Total	STC	kn - 1		

EJEMPLO 13.4.

La tabla del ejemplo 13.1.

Análisis de Varianza

Fuente de Variación	Suma de Cuadrados	Grados de Libertad		
Entre Muestras	490/3	2	490/3.2	$\frac{490/6}{122/12} = 8,03$
Dentro Muestras	122	12	122/12	
Total	856/3	14		

13.2.5. DISTINTOS TAMAÑOS DE MUESTRAS

Cuando el número de elementos en cada muestra es diferente (n_j), la lógica del procedimiento es idéntica a la anterior. Las únicas modificaciones están en las expresiones utilizadas.

La media muestral de la muestra j será:

$$\bar{X}_j = \frac{\sum_{i=1}^{n_j} X_{ij}}{n_j}$$

La varianza muestral de la muestra j

$$S_j^2 = \frac{\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_j)^2}{n_j}$$

La gran media

$$\bar{X} = \frac{\sum_{j=1}^k \sum_{i=1}^{n_j} X_{ij}}{N} = \frac{\sum_{j=1}^k n_j \bar{X}_j}{N}$$

siendo N el número total de observaciones $N = \sum_{j=1}^k n_j$; se observará que es una media

ponderada de las medias muestrales, siendo las ponderaciones el número de elementos en cada muestra.

La suma total de los cuadrados:

$$STC = \sum_{j=1}^k \sum_{i=1}^{n_j} (X_{ij} - \bar{X})^2$$

Descomposición de la STC:

$$STC = \sum_{j=1}^k \sum_{i=1}^{n_j} (X_{ij} - \bar{X})^2 = \sum_{j=1}^k \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_j)^2 + \sum_{j=1}^k n_j (\bar{X}_j - \bar{X})^2$$

Suma de los cuadrados dentro de las muestras:

$$SCD = \sum_{j=1}^k \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_j)^2$$

Suma de los cuadrados entre muestras:

$$SCE = \sum_{j=1}^k n_j (\bar{X}_j - \bar{X})^2$$

Los grados de libertad de la χ^2 de SCD serán ahora

$$n_1 + n_2 + \dots + n_k - k = N - k$$

puesto que es la suma de k variables χ^2 con $(n_1 - 1)$, $(n_2 - 1)$, ..., $(n_k - 1)$ grados de libertad respectivamente.

La variable F será:

$$F = \frac{\sum_{j=1}^k n_j (\bar{X}_j - \bar{X})^2 / (k - 1)}{\sum_{j=1}^k \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_j)^2 / (N - k)} = \frac{SCE / (k - 1)}{SCD / (N - k)}$$

Las expresiones para el cálculo práctico de las sumas de los cuadrados serán:

$$STC = \sum_{j=1}^k \sum_{i=1}^{n_j} X_{ij}^2 - \frac{1}{N} \left(\sum_{j=1}^k \sum_{i=1}^{n_j} X_{ij} \right)^2$$

$$SCD = \sum_{j=1}^k \sum_{i=1}^{n_j} X_{ij}^2 - \sum_{j=1}^k \frac{1}{n_j} \left(\sum_{i=1}^{n_j} X_{ij} \right)^2$$

$$SCE = \sum_{j=1}^k \frac{1}{n_j} \left(\sum_{i=1}^{n_j} X_{ij} \right)^2 - \frac{1}{N} \left(\sum_{j=1}^k \sum_{i=1}^{n_j} X_{ij} \right)^2$$

EJEMPLO 13.5.

Se desea comparar los ingresos medios diarios de la población de 4 parroquias de Caracas, para lo cual se toman muestras aleatorias de 10, 6, 9 y 9 elementos respectivamente. Los resultados fueron los siguientes:

PARROQUIAS

A $X_{i1} (X_{i1}^2)$	B $X_{i2} (X_{i2}^2)$	C $X_{i3} (X_{i3}^2)$	D $X_{i4} (X_{i4}^2)$
12 (144)	15 (225)	15 (225)	10 (100)
15 (225)	8 (64)	17 (289)	5 (25)
8 (64)	16 (256)	5 (25)	12 (144)
10 (100)	13 (169)	13 (169)	14 (196)
9 (81)	14 (196)	14 (196)	16 (256)
11 (121)	12 (144)	8 (64)	13 (169)
12 (144)		10 (100)	12 (144)
14 (196)		10 (100)	8 (64)
13 (169)		12 (144)	12 (144)
10 (100)			

$$\begin{array}{cccccc} \sum_{i=1}^{n_j} X_{ij} & 114 & 78 & 104 & 102 & 398 = \sum_{j=1}^4 \sum_{i=1}^{n_j} X_{ij} \\ \sum_{i=1}^{n_j} X_{ij}^2 & 1.344 & 1.054 & 1.312 & 1.242 & 4.952 = \sum_{j=1}^4 \sum_{i=1}^{n_j} X_{ij}^2 \end{array}$$

$$STC = \sum_{j=1}^4 \sum_{i=1}^{n_j} X_{ij}^2 - \frac{1}{N} \left(\sum_{j=1}^4 \sum_{i=1}^{n_j} X_{ij} \right)^2 = 4.952 - \frac{398^2}{34} = 293,059$$

$$SCD = \sum_{j=1}^4 \sum_{i=1}^{n_j} X_{ij}^2 - \sum_{j=1}^4 \frac{1}{n_j} \left(\sum_{i=1}^{n_j} X_{ij} \right)^2 =$$

$$= 4.952 - \left(\frac{114^2}{10} + \frac{78^2}{6} + \frac{104^2}{9} + \frac{102^2}{9} \right) = 280,622$$

$$SCE = STC - SCD = 293,059 - 280,622 = 12,437$$

ANÁLISIS DE LA VARIANZA

Fuente de Variación	Suma de Cuadrados	Grados de Libertad	
Entre Muestras	12,437	4 - 1 = 3	12,437/3 = 4,15
Dentro Muestras	280,622	34 - 4 = 30	280,622/30 = 9,35
Total	293,059	33	

El cociente 4,15/9,35 es menor que la unidad; luego, se acepta la hipótesis sin necesidad de comparar con F_{α} .

Los pasos a seguir para el análisis de varianza son:

1. Cálculo de la suma total de los cuadrados STC.
2. Cálculo de la suma de los cuadrados dentro de las muestras SCD.
3. Cálculo de la suma de los cuadrados entre muestras: STC - SCD.
4. Cálculo de $F = \frac{SCE/(k-1)}{SCD/k(n-1) \text{ ó } (N-k)}$
5. Comparación con $F_{\alpha} [(k-1), k(n-1) \text{ ó } (N-k)]$

Si $F < F_{\alpha}$, se acepta H_0 ; si $F > F_{\alpha}$ se rechaza H_0 con un nivel de significación de α .

13.3. CLASIFICACION DOBLE

Al lector seguramente se le ha planteado una duda respecto a la validez de los experimentos presentados en los ejemplos de la sección anterior. Es indudable que la productividad de los obreros después de aplicados los diferentes métodos de entrenamiento, no está sólo afectada por este factor, sino también por otros tales como la distinta habilidad de los trabajadores, o el previo entrenamiento de los mismos. El experimento tal como está diseñado en la sección anterior, no toma en cuenta este hecho.

En esta sección ampliamos la visión de la sección anterior, para dar cabida a un segundo factor de influencia en las variables que queremos estudiar; en esto consiste el análisis de varianza con clasificación doble.

Suponemos que tenemos "p" niveles distintos del factor B, en el caso del ejemplo, 3 distintos métodos de entrenamiento; y "q" niveles distintos del factor A, en el ejemplo podríamos especificar 4 diferentes grados de habilidad de los obreros, y clasificar éstos según estos grados de habilidad. Tenemos entonces pq distintas combinaciones de los dos factores. Ejemplo de tales combinaciones sería: Método de entrenamiento 1 aplicado a obreros con grado de habilidad 1, etc.; en total pq distintas combinaciones.

Primero enfocaremos el problema más simple, cuando se dispone de una sola observación muestral para cada posible combinación.

13.3.1. CASO DE UNA OBSERVACION MUESTRAL EN CADA CELDA

Supongamos que tenemos 12 obreros a los que se van a aplicar los 3 métodos de entrenamiento, y agrupamos a los 12 obreros de acuerdo a 4 distintos niveles de habilidad: (3 en cada nivel) Superior, Buena, Media y Deficiente; es decir, dentro de cada grupo los obreros tienen una productividad similar con base en su habilidad.

Procedemos a asignar aleatoriamente los métodos de entrenamiento a los obreros en cada grupo; es decir, en el grupo de 3 obreros de habilidad superior, a uno de ellos se le da el entrenamiento por el método 1; a otro por el método 2; y al otro por el método 3; y lo mismo en los restantes grupos.

Sea X_{ij} la observación correspondiente al nivel i del factor A y al nivel j del factor B. (i = 1, 2, ..., p; j = 1, 2, ..., q).

En el ejemplo X_{11} representará la productividad del obrero en nivel de habilidad superior al que se le ha dado entrenamiento por el método 1, etc., en general X_{ij} representará la productividad del obrero de nivel de habilidad i con entrenamiento j.

TABLA 13.3.

FACTOR B

	1	2	3		q	
1	X_{11}	X_{12}	X_{13}		X_{1q}	$\bar{X}_{1.}$
2	X_{21}	X_{22}	X_{23}		X_{2q}	$\bar{X}_{2.}$
3	X_{31}	X_{32}	X_{33}		X_{3q}	$\bar{X}_{3.}$
.	.	.	.		.	.
.	.	.	.	X_{ij}	.	.
.	.	.	.		.	.
p	X_{p1}	X_{p2}	X_{p3}		X_{pq}	$\bar{X}_{p.}$
	$\bar{X}_{.1}$	$\bar{X}_{.2}$	$\bar{X}_{.3}$		$\bar{X}_{.q}$	$\bar{X}$

En la tabla 13.3. se presentan las observaciones en una tabla de doble entrada.

En la última fila de la tabla aparecen los símbolos $\bar{X}_{.1}$, $\bar{X}_{.2}$, ..., $\bar{X}_{.q}$; estos símbolos corresponden a las medias de las observaciones de los niveles 1, 2, ..., q respectivamente del factor B; es decir,

$$\bar{X}_{.j} = \frac{\sum_{i=1}^p X_{ij}}{p}$$

$\bar{X}_{.1}$ es el promedio de las observaciones de la primera columna (nivel 1 del factor B), etc.

En la última columna tenemos similarmente los símbolos $\bar{X}_{1.}$, $\bar{X}_{2.}$, ..., $\bar{X}_{p.}$ que corresponde a las medias de las observaciones de los niveles 1, 2, ..., p respectivamente del factor A.

$$\bar{X}_{.j} = \frac{\sum_{i=1}^p X_{ij}}{p}$$

Por último, $\bar{X}$ es la media de todas las observaciones

$$\bar{X} = \frac{\sum_{i=1}^p \sum_{j=1}^q X_{ij}}{p \cdot q} = \frac{\sum_{i=1}^p \bar{X}_{i.}}{p} = \frac{\sum_{j=1}^q \bar{X}_{.j}}{q}$$

Paralelamente a estos estadísticos muestrales se pueden definir los correspondientes parámetros $\mu_{.j}$, $\mu_{i.}$ y μ .

$\mu_{.j}$ representa la media poblacional del nivel j del factor B; $\mu_{i.}$ la media poblacional del nivel i del factor A; μ la gran media poblacional.

El problema se resume a verificar si los factores en estudio influyen o no en la variable de interés; en otras palabras, queremos contrastar dos hipótesis. Una si el factor A influye en la variable; otra, si el factor B influye en la variable. Si el factor A tiene influencia importante, esta influencia se puede representar por la existencia de medias poblacionales diferentes en los distintos niveles del factor A; es decir, contrastaremos la hipótesis nula de que las medias poblacionales de los distintos niveles del factor A son iguales ($H_0: \mu_{1.} = \mu_{2.} = \dots = \mu_{p.}$), contra la hipótesis alternativa (H_1 : no todas las $\mu_{i.}$ son iguales).

Por otro lado, la influencia o no del factor B viene dada por la desigualdad o igualdad de las medias poblacionales de los distintos niveles del factor B. $H_0: \mu_{.1} = \mu_{.2} = \dots = \mu_{.q}$. (El factor B no tiene influencia) contra H_1 : no todas las $\mu_{.j}$ son iguales (El factor B tiene influencia).

13.3.1.1. DESCOMPOSICION DE LA SUMA DE CUADRADOS

Tenemos como antes:

$$STC = \sum_{i=1}^p \sum_{j=1}^q (X_{ij} - \bar{X})^2$$

que es la media de la dispersión de todas las observaciones respecto a la gran media $\bar{X}$.

Procedemos a descomponer esta suma de cuadrados en tres componentes.

$$STC = \sum_{i=1}^p \sum_{j=1}^q (X_{ij} - \bar{X})^2 = \sum_{i=1}^p \sum_{j=1}^q (X_{ij} - \bar{X}_i - \bar{X}_j + \bar{X})^2 + \sum_{i=1}^p \sum_{j=1}^q (\bar{X}_i - \bar{X})^2 + \sum_{i=1}^p \sum_{j=1}^q (\bar{X}_j - \bar{X})^2$$

En efecto, sumando y restando $(\bar{X}_i - \bar{X})$ y $(\bar{X}_j - \bar{X})$

$$\begin{aligned} \sum_{i=1}^p \sum_{j=1}^q (X_{ij} - \bar{X})^2 &= \sum_{i=1}^p \sum_{j=1}^q \{X_{ij} + (\bar{X}_i - \bar{X}) + (\bar{X}_j - \bar{X}) - (\bar{X}_i - \bar{X}) - (\bar{X}_j - \bar{X}) - \bar{X}\}^2 = \\ &= \sum_{i=1}^p \sum_{j=1}^q \{X_{ij} - (\bar{X}_i - \bar{X}) - (\bar{X}_j - \bar{X}) - \bar{X} + (\bar{X}_i - \bar{X}) + (\bar{X}_j - \bar{X})\}^2 = \\ &= \sum_{i=1}^p \sum_{j=1}^q [X_{ij} - (\bar{X}_i - \bar{X}) - (\bar{X}_j - \bar{X}) - \bar{X}]^2 + \sum_{i=1}^p \sum_{j=1}^q (\bar{X}_i - \bar{X})^2 + \\ &+ \sum_{i=1}^p \sum_{j=1}^q (\bar{X}_j - \bar{X})^2 + 2 \sum_{i=1}^p \sum_{j=1}^q [X_{ij} - (\bar{X}_i - \bar{X}) - (\bar{X}_j - \bar{X}) - \bar{X}](\bar{X}_i - \bar{X}) + \\ &+ 2 \sum_{i=1}^p \sum_{j=1}^q [X_{ij} - (\bar{X}_i - \bar{X}) - (\bar{X}_j - \bar{X}) - \bar{X}](\bar{X}_j - \bar{X}) + \\ &+ 2 \sum_{i=1}^p \sum_{j=1}^q (\bar{X}_i - \bar{X})(\bar{X}_j - \bar{X}) \end{aligned}$$

Los tres últimos términos son todos cero. En efecto,

$$\begin{aligned} \sum_{i=1}^p \sum_{j=1}^q [X_{ij} - \bar{X}_i - \bar{X}_j + \bar{X}](\bar{X}_i - \bar{X}) &= \sum_{i=1}^p \left\{ (\bar{X}_i - \bar{X}) \sum_{j=1}^q (X_{ij} - \bar{X}_i - \bar{X}_j + \bar{X}) \right\} = \\ &= \sum_{i=1}^p \left\{ (\bar{X}_i - \bar{X}) \left[\sum_{j=1}^q X_{ij} - q \bar{X}_i - \sum_{j=1}^q \bar{X}_j + q \bar{X} \right] \right\} = \\ &= \sum_{i=1}^p (\bar{X}_i - \bar{X}) [q \bar{X}_i - q \bar{X}_i - q \bar{X} + q \bar{X}] = 0 \end{aligned}$$

Similantemente, los dos últimos términos.

En definitiva, la suma total de cuadrados se divide en componentes, cada uno de los cuales representa la variación debida a diferentes causas.

$$\text{El segundo término, } SCA = \sum_{i=1}^p \sum_{j=1}^q (\bar{X}_i - \bar{X})^2 = q \sum_{i=1}^p (\bar{X}_i - \bar{X})^2$$

representa la dispersión de las medias muestrales del factor A respecto a la gran media; y su magnitud depende de la diferencia de las medias poblacionales μ_i . Si las medias μ_i son iguales, SCA tenderá a ser menor.

$$\text{El tercer término, } SCB = \sum_{i=1}^p \sum_{j=1}^q (\bar{X}_j - \bar{X})^2 = p \sum_{j=1}^q (\bar{X}_j - \bar{X})^2$$

es una medida de la dispersión de las medias muestrales del factor B alrededor de la gran media y su valor está influido por las medias poblacionales μ_j .

$$\text{El primer término, } SCR = \sum_{i=1}^p \sum_{j=1}^q (X_{ij} - \bar{X}_i - \bar{X}_j + \bar{X})^2 \text{ que se podría llamar suma}$$

residual de cuadrados, mide la variación de las variables X_{ij} respecto a $\bar{X}$ después de que los efectos de los factores A y B han sido eliminados, y representa las variaciones no explicadas por los factores A y B.

EJEMPLO 13.6.

Supongamos que los resultados de los métodos de entrenamiento en los obreros han sido los siguientes:

		FACTOR B - MÉTODO DE ENTRENAMIENTO					
			Método 1	Método 2	Método 3	$\sum_{j=1}^3 X_{ij}$	$\bar{X}_i$
FACTOR A - HABILIDAD	Superior	1	20	18	15	53	53/3
	Buena	2	16	18	13	47	47/3
	Media	3	12	13	17	42	14
	Deficiente	4	8	8	10	26	26/3
	$\sum_{i=1}^4 X_{ij}$		56	57	55	168	14
			14	57/4	55/4	14	$\bar{X}$

$$\begin{aligned}
 \text{STC} &= \sum_{i=1}^4 \sum_{j=1}^3 (X_{ij} - \bar{X})^2 = (23-14)^2 + (18-14)^2 + \dots + (8-14)^2 = 176 \\
 \text{SCA} &= q \sum_{i=1}^4 (\bar{X}_i - \bar{X})^2 = 3 \left[\left(\frac{53}{3} - 14 \right)^2 + \left(\frac{47}{3} - 14 \right)^2 + (14-14)^2 + \left(\frac{26}{3} - 14 \right)^2 \right] = 134 \\
 \text{SCB} &= p \sum_{j=1}^3 (\bar{X}_j - \bar{X})^2 = 4 \left[(14-14)^2 + \left(\frac{57}{4} - 14 \right)^2 + \left(\frac{55}{4} - 14 \right)^2 \right] = 0,5 \\
 \text{SCR} &= 176 - 134 - 0,5 = 41,5
 \end{aligned}$$

13.3.1.2. PROCEDIMIENTO DEL CONTRASTE

Como antes, un supuesto básico es que las variables X_{ij} son normales con la misma varianza σ^2 .

Si la hipótesis:

$$H_0: \mu_{1.} = \mu_{2.} = \dots = \mu_{p.} = \mu$$

es verdadera,

$$\frac{\text{SCA}}{\sigma^2} = \frac{q \sum_{i=1}^p (\bar{X}_i - \bar{X})^2}{\sigma^2} \text{ es una variable } \chi^2 \text{ con } p-1 \text{ grados de libertad.}$$

En efecto $\bar{X}_i$ es una variable normal puesto que es una combinación lineal de las variables X_{ij} , que por hipótesis son normales. Su valor esperado es $\mu_{i.}$ y si H_0 es verdadera, su valor esperado es μ . La varianza de $\bar{X}_i$ es σ^2/q puesto que $\bar{X}_i$ es la media muestral de una muestra de tamaño q de una población con varianza σ^2 . Las varianzas $\bar{X}_i$ son entonces variables normales independientes, con media μ y varianza σ^2/q ; luego, por sección 7.5.3,

$$q \frac{\sum_{i=1}^p (\bar{X}_i - \bar{X})^2}{\sigma^2} \sim \chi^2(p-1)$$

Por otro lado, SCR/σ^2 es una variable χ^2 con $(p-1)(q-1)$ grados de libertad, y es independiente de SCA/σ^2 . (La prueba de esta afirmación está más allá de los alcances de este libro).

Dijimos que SCA representa la dispersión de las medias muestrales del factor A, y será mayor si las medias poblacionales $\mu_{i.}$ son diferentes; la comparación de SCA con SCR nos dará una medida para determinar si el factor A es influyente, y nos servirá para contrastar la hipótesis de no influencia del factor A; es decir, la hipótesis nula de igualdad de las medias $\mu_{i.}$

Si dividimos $\frac{\text{SCA}/\sigma^2 (p-1)}{\text{SCR}/\sigma^2 (p-1)(q-1)}$ obtenemos una variable F con $(p-1)$ y $(p-1)(q-1)$ grados de libertad.

$$F = \frac{\text{SCA}}{\text{SCR}} = \frac{(p-1)(q-1)}{(p-1)} = \frac{\text{SCA}}{\text{SCR}} (q-1)$$

Establecido el nivel de significación α , si $F > F_{\alpha}$, se rechaza la hipótesis $H_0: \mu_{1.} = \mu_{2.} = \dots = \mu_{p.}$ de que el factor A no tiene influencia. Si $F < F_{\alpha}$, se acepta la hipótesis H_0 .

EJEMPLO 13.7.

En el ejemplo anterior $\text{SCA} = 134$; $\text{SCR} = 41,5$; $p = 4$; $q = 3$

$$F = \frac{134 \cdot 2}{41,5} = \frac{268}{41,5} = 6,457$$

$F_{0,05}(3,6) = 4,76$. $F > F_{\alpha}$; luego, se rechaza la hipótesis nula con un nivel de significación del 5%. El factor A (habilidad) aparentemente sí influye en la productividad media.

Similarmemente, para contrastar la influencia del factor B, tenemos que si la hipótesis $H_0: \mu_{.1} = \mu_{.2} = \dots = \mu_{.q} = \mu$ es verdadera

$$\frac{\text{SCB}}{\sigma^2} = \frac{p \sum_{j=1}^q (\bar{X}_j - \bar{X})^2}{\sigma^2} \text{ es una variable } \chi^2 \text{ con } (q-1) \text{ grados de libertad.}$$

$$\text{El cociente } F = \frac{\text{SCB}/\sigma^2 (q-1)}{\text{SCR}/\sigma^2 (p-1)(q-1)} = \frac{\text{SCB}}{\text{SCR}} (p-1)$$

se distribuye como una variable F con $(q-1)$ y $(p-1)(q-1)$ grados de libertad. Si $F > F_{\alpha}$, se rechaza H_0 , es decir el factor B sí tiene influencia. Si $F < F_{\alpha}$, se acepta H_0 .

EJEMPLO 13.8.

En el ejemplo anterior SCB = 0,5

$$F = \frac{0,5 \cdot 3}{41,5} = 0,0361$$

$F_{0,05}(2,6) = 5,14$ $F < F_{\alpha}$, se acepta H_0 ; los métodos de entrenamiento no influyen aparentemente en la productividad de los obreros.

13.3.1.3. FORMULAS PRACTICAS PARA SIMPLIFICACION DE CALCULOS

Siguiendo el procedimiento de la sección 13.2.4. para el cálculo de STC, se tiene:

$$STC = \sum_{i=1}^p \sum_{j=1}^q (X_{ij} - \bar{X})^2 = \sum_{i=1}^p \sum_{j=1}^q X_{ij}^2 - \frac{1}{pq} \left(\sum_{i=1}^p \sum_{j=1}^q X_{ij} \right)^2$$

Siguiendo el procedimiento para el cálculo de SCE, se tiene:

$$SCA = q \sum_{i=1}^p (\bar{X}_{i.} - \bar{X})^2 = \frac{1}{q} \sum_{i=1}^p \left[\sum_{j=1}^q X_{ij} \right]^2 - \frac{1}{pq} \left[\sum_{i=1}^p \sum_{j=1}^q X_{ij} \right]^2$$

$$SCB = p \sum_{j=1}^q (\bar{X}_{.j} - \bar{X})^2 = \frac{1}{p} \sum_{j=1}^q \left[\sum_{i=1}^p X_{ij} \right]^2 - \frac{1}{pq} \left[\sum_{i=1}^p \sum_{j=1}^q X_{ij} \right]^2$$

SCR es calculado por diferencia $SCR = STC - SCA - SCB$

EJEMPLO 13.9.

Aplicación de las fórmulas anteriores al ejemplo

$$STC = \sum_{i=1}^4 \sum_{j=1}^3 (X_{ij})^2 - \frac{1}{4 \cdot 3} \left(\sum_{i=1}^4 \sum_{j=1}^3 X_{ij} \right)^2 =$$

$$= 20^2 + 16^2 + 12^2 + 8^2 + 18^2 + \dots + 10^2 -$$

$$- \frac{1}{12} (20 + 16 + 12 + \dots + 10)^2 = 2.528 - \frac{28.224}{12} = 176$$

$$SCA = \frac{1}{3} \sum_{i=1}^4 \left[\sum_{j=1}^3 X_{ij} \right]^2 - \frac{1}{4 \cdot 3} \left[\sum_{i=1}^4 \sum_{j=1}^3 X_{ij} \right]^2 =$$

$$= \frac{1}{3} (53^2 + 47^2 + 42^2 + 26^2) - \frac{28.224}{12} = \frac{7.458}{3} - \frac{28.224}{12} = 134$$

$$SCB = \frac{1}{4} \sum_{j=1}^3 \left[\sum_{i=1}^4 X_{ij} \right]^2 - \frac{1}{4 \cdot 3} \left[\sum_{i=1}^4 \sum_{j=1}^3 X_{ij} \right]^2 =$$

$$= \frac{1}{4} (56^2 + 57^2 + 55^2) - \frac{28.224}{12} = \frac{9.410}{4} - 2.352 = 0,5$$

$$SCR = 176 - 134 - 0,5 = 41,5$$

TABLA 13.3
ANALISIS DE VARIANZA
(Clasificación Doble) ($n = 1$)

(1) Fuente de Variación	(2) Suma de Cuadrados	(3) Grados de Libertad	(4) (2) / (3)	F
FACTOR A	SCA	$p - 1$	$SCA/(p - 1)$	$\frac{SCA/(p - 1)}{SCR/(p - 1)(q - 1)}$
FACTOR B	SCB	$q - 1$	$SCB/(q - 1)$	$\frac{SCB/(q - 1)}{SCR/(p - 1)(q - 1)}$
Residuo	SCR	$(p - 1)(q - 1)$	$SCR/(p - 1)(q - 1)$	
Total	STC	$pq - 1$		

EJEMPLO 13.10.

Los datos de la tabla siguiente se refieren a ingresos medios diarios de personas habitantes de 4 regiones de Venezuela, y trabajadores en 4 sectores económicos.

Sector \ Región	Centro	Oriente	Occidente	Sur
Agricultura	700	500	750	600
Manufactura	1.300	800	1.000	1.050
Comercio	1.600	1.000	1.100	1.200
Público	900	1.000	850	700

Con un nivel de significación del 5%.

- ¿Hay diferencia significativa en los ingresos medios respecto a la región en que habitan?
- ¿Hay diferencia significativa en los 4 sectores respecto al ingreso medio?

$$STC = \sum_{i=1}^4 \sum_{j=1}^4 (X_{ij})^2 - \frac{1}{4 \cdot 4} \left(\sum_{i=1}^4 \sum_{j=1}^4 X_{ij} \right)^2 =$$

$$= (700^2 + 500^2 + \dots + 700^2) - \frac{1}{16} (700 + 500 + \dots + 700)^2 =$$

$$= 15.327.500 - 14.156.406,25 = 1.171.093,75$$

$$SCA = \frac{1}{4} \sum_{i=1}^4 \left[\sum_{j=1}^4 X_{ij} \right]^2 - \frac{1}{16} \left(\sum_{i=1}^4 \sum_{j=1}^4 X_{ij} \right)^2 = \frac{1}{4} (2.550^2 + 4.150^2 + 4.900^2 + 3.450^2) -$$

$$- 14.156.406,25 = 14.909.375 - 14.156.406,25 = 752.968,75$$

$$SCB = \frac{1}{4} \sum_{j=1}^4 \left[\sum_{i=1}^4 X_{ij} \right]^2 - \frac{1}{16} \left(\sum_{i=1}^4 \sum_{j=1}^4 X_{ij} \right)^2 = \frac{1}{4} (4.500^2 + 3.300^2 + 3.700^2 + 3.550^2) -$$

$$- 14.156.406,25 = 14.270.000 - 14.156.406,25 = 113.593,75$$

$$SCR = 304.531,25$$

ANALISIS DE VARIANZA

Fuente de Variación	Suma de Cuadrados	Grados de Libertad	(2)/(3)	F
Sector	752.968,75	3	250.989,58	7,42
Región	113.593,75	3	37.864,58	1,12
Residuo	304.531,25	9	33.836,81	
Total	1.171.093,75	15		

$$F_{0,05}(3,9) = 3,86$$

FACTOR A(Sector): $7,42 > 3,86$, se rechaza la hipótesis de igualdad de medias. Hay diferencia significativa en los 4 sectores con respecto al ingreso medio.

FACTOR B(Región): $1,12 < 3,86$, se acepta la hipótesis de igualdad de medias. No hay diferencia significativa en las 4 regiones respecto al ingreso medio.

13.3.2. CASO DE VARIAS OBSERVACIONES MUESTRALES EN CADA CELDA

El caso que nos ocupa ahora es el mismo de clasificación doble (influencia de dos factores), pero con n observaciones para cada una de las posibles combinaciones de los dos factores.

Generalizando el ejemplo de la sección 13.3.1., supongamos que tenemos los cuatro niveles del factor A (Habilidad), los tres niveles del factor B (Método de entrenamiento); y tenemos 3 observaciones para cada combinación; es decir, 3 obreros de habilidad superior a los cuales se aplica el método de entrenamiento 1, etc.

Las observaciones muestrales serán representadas ahora por el símbolo X_{ijk} . Los dos primeros subíndices tienen el mismo significado anterior, mientras que el subíndice k ($k = 1, \dots, n$) nos indica el elemento correspondiente de la muestra. Por ejemplo, X_{122} representa el resultado de la segunda observación de la celda correspondiente a la combinación formada por el nivel 1 del factor A y el nivel 2 del factor B. En el ejemplo, X_{122} es la productividad del segundo obrero de habilidad superior, al que se le ha aplicado el método de entrenamiento 2.

Tendremos entonces npq observaciones muestrales.

Además de los estadísticos usados anteriormente $\bar{X}_{i.}$, $\bar{X}_{.j}$ y $\bar{X}$, usaremos en este caso el estadístico $\bar{X}_{ij}$ que representa la media muestral de la celda (i, j) .

$$\bar{X}_{ij} = \frac{\sum_{k=1}^n X_{ijk}}{n}$$

$$\bar{X}_{i.} = \frac{\sum_{j=1}^q \sum_{k=1}^n X_{ijk}}{nq}$$

$$\bar{X}_{.j} = \frac{\sum_{i=1}^p \sum_{k=1}^n X_{ijk}}{np}$$

$$\bar{X} = \frac{\sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n X_{ijk}}{npq}$$

Los correspondientes parámetros son $\mu_{i.}$, $\mu_{.j}$ y μ_{ij} , siendo μ_{ij} la media poblacional del colectivo "combinación del nivel i del factor A y nivel j del factor B".

Las hipótesis a contrastar son como antes:

- 1) $H_0: \mu_{1.} = \mu_{2.} = \dots = \mu_{p.}$ (El factor A no tiene influencia diferente en los distintos niveles).
- 2) $H_0: \mu_{.1} = \mu_{.2} = \dots = \mu_{.q}$ (El factor B no tiene influencia diferente en los distintos niveles).

Además tenemos una tercera hipótesis que contrastar: la ausencia de interacción entre los factores A y B. Esta hipótesis, en términos de parámetros es:

$$3) H_0: \mu_{ij} = \mu + (\mu_{i.} - \mu) + (\mu_{.j} - \mu)$$

o equivalentemente

$$H_0: \mu_{ij} - \mu_{i.} - \mu_{.j} + \mu = 0$$

Es conveniente aclarar el significado de esta hipótesis. Al hablar de interacción entre los factores A y B, se quiere decir que existe la posibilidad de que los factores A y B actúen en forma conjunta influenciando la variable. Si no existe interacción, quiere decir que la influencia de un nivel cualquiera del factor A es la misma, sin ser afectada por el nivel del factor B con que se combine. En términos del ejemplo, la no existencia de interacción implica que la efectividad del método de entrenamiento no está influenciada por el nivel de habilidad de las personas a las que se aplica ese método de entrenamiento; o la influencia del nivel de habilidad es la misma cualquiera que sea el método de entrenamiento que se use.

Si no existieran diferencias de efectividad entre los distintos métodos de entrenamiento y/o entre los distintos niveles de actividad, las observaciones muestrales vendrían todas de la misma población con una productividad media igual a μ ; y las medias de cada celda μ_{ij} serían iguales a μ .

Consideremos concretamente la población formada por los obreros de habilidad superior a los que se aplica el método de entrenamiento uno. Su media es $\mu_{1.}$. Si los factores en estudio no afectan en forma diferente según su nivel a la productividad, $\mu_{1.}$ debería ser igual a μ (media de la población formada por todos los obreros a los que aplican cualquier método de entrenamiento). Si los factores son influyentes, $\mu_{1.}$ será diferente de μ , y esta diferencia puede ser explicada a través de una triple causa: 1º) Puede ser que el nivel de habilidad superior aisladamente considerado, tenga un efecto en la productividad; este efecto vendría dado por la diferencia $(\mu_{1.} - \mu)$; es decir, la diferencia entre la media de la población formada por los obreros de habilidad superior cualquiera que sea el método de entrenamiento aplicado y la media poblacional global. 2º) Puede ser que el método de entrenamiento 1 tomado aisladamente, tenga un efecto en la productividad; este efecto viene dado por la diferencia entre la media de la población formada por los obreros a los que se aplica el método de entrenamiento 1, y la media poblacional global $(\mu_{.1} - \mu)$. 3º) Además de los efectos aislados del método de entrenamiento 1 y nivel de habilidad superior, puede ser que el método de entrenamiento 1 tenga un efecto mayor al combinarlo con el nivel de habilidad superior y viceversa; vamos a representar este efecto por γ_{11} .

Entonces,

$$\mu_{11} - \mu = (\mu_{1.} - \mu) + (\mu_{.1} - \mu) + \gamma_{11}$$

La diferencia entre la media de la población formada por los obreros con habilidad superior a los que se aplica el método de entrenamiento 1 (μ_{11}) y la media global (μ), consta de tres componentes: el efecto del método de entrenamiento 1, el efecto del nivel de habilidad superior y el efecto conjunto de ambos (interacción). Si este último efecto es cero (la efectividad del método de entrenamiento 1 es la misma, cualquiera que sea el nivel de habilidad; o similarmente la efectividad del nivel de habilidad superior es la misma, cualquiera que sea el método aplicado), γ_{11} será igual a cero y la diferencia $\mu_{11} - \mu$ se explica

sumando simplemente los efectos aislados del método de entrenamiento 1 y el nivel de habilidad superior. Si $\gamma_{11} \neq 0$, se dice que la interacción de los niveles produce efectos que no pueden ser explicados solamente con la suma de los efectos aislados de los dos factores.

En general,

$$\mu_{ij} - \mu = (\mu_{i.} - \mu) + (\mu_{.j} - \mu) + \gamma_{ij}$$

La hipótesis de no interacción implica $\gamma_{ij} = 0$; o sea que:

$$\mu_{ij} = (\mu_{i.} - \mu) + (\mu_{.j} - \mu) + \mu$$

ó

$$\mu_{ij} = \mu_{i.} - \mu_{.j} + \mu = 0$$

Hay que notar que el efecto de interacción también puede darse en el caso de una observación en cada celda; pero en esta situación es imposible contrastar este efecto, por lo que se supone es cero.

13.3.2.1. DESCOMPOSICION DE LA SUMA DE CUADRADOS

La suma total de los cuadrados de las desviaciones de las observaciones con respecto a la gran media $\bar{X}$ es:

$$STC = \sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n (X_{ijk} - \bar{X})^2$$

Esta suma se puede descomponer en 4 términos

$$(I) \quad STC = \sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n (X_{ijk} - \bar{X})^2 = nq \sum_{i=1}^p (\bar{X}_{i.} - \bar{X})^2 + np \sum_{j=1}^q (\bar{X}_{.j} - \bar{X})^2 + n \sum_{i=1}^p \sum_{j=1}^q (\bar{X}_{ij} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X})^2 + \sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n (X_{ijk} - \bar{X}_{ij})^2$$

En efecto, sumando y restando $(\bar{X}_{i.} - \bar{X})$, $(\bar{X}_{.j} - \bar{X})$ y $(X_{ijk} - \bar{X}_{ij})$ tenemos:

$$STC = \sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n [(X_{ijk} - \bar{X}) + (\bar{X}_{i.} - \bar{X}) - (\bar{X}_{i.} - \bar{X}) + (\bar{X}_{.j} - \bar{X}) - (\bar{X}_{.j} - \bar{X}) + (X_{ijk} - \bar{X}_{ij}) - (X_{ijk} - \bar{X}_{ij})]^2$$

Agrupando términos queda:

$$STC = \sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n [(\bar{X}_{i.} - \bar{X}) + (\bar{X}_{.j} - \bar{X}) + (X_{ijk} - \bar{X}_{ij}) + (X_{ijk} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X})]^2$$

$$STC = \sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n (\bar{X}_{i.} - \bar{X})^2 + \sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n (\bar{X}_{.j} - \bar{X})^2 + \sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n (X_{ijk} - \bar{X}_{ij})^2 + \sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n (X_{ijk} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X})^2 + 6 \text{ productos cruzados}$$

Los 6 productos cruzados son cero, y en definitiva queda la expresión (I). La suma total de los cuadrados representativa de las variaciones de los datos con respecto a la media, se divide en 4 componentes, representando las posibles causas de variación.

El primer término

$$SCA = \sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n (\bar{X}_{i.} - \bar{X})^2 = nq \sum_{i=1}^p (\bar{X}_{i.} - \bar{X})^2$$

representa la dispersión de las medias muestrales de los distintos niveles del factor A respecto a la gran media; y su magnitud depende de la diferencia entre las medias poblacionales $\mu_{i.}$

El segundo término:

$$SCB = \sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n (\bar{X}_{.j} - \bar{X})^2 = np \sum_{j=1}^q (\bar{X}_{.j} - \bar{X})^2$$

representa la dispersión de las medias muestrales de los diferentes niveles del factor B respecto a la gran media; y su magnitud está influida por la igualdad o no de las medias poblacionales $\mu_{.j}$.

El tercer término:

$$SCI = \sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n (\bar{X}_{ij} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X})^2 = n \sum_{i=1}^p \sum_{j=1}^q (\bar{X}_{ij} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X})^2$$

representa la variación debida al efecto de interacción entre los distintos niveles de ambos factores. Obsérvese que el paréntesis $(\bar{X}_{ij} - \bar{X}_i - \bar{X}_j + \bar{X})$ representa la diferencia entre la media muestral de la celda (i, j) y la gran media una vez han sido eliminados los efectos aislados del factor A y del factor B.

El efecto individual del factor A viene estimado por $(\bar{X}_i - \bar{X})$; el factor B por $(\bar{X}_j - \bar{X})$. Si a $\bar{X}_{ij} - \bar{X}$ le restamos ambos efectos, nos queda:

$$\bar{X}_{ij} - \bar{X} - (\bar{X}_i - \bar{X}) - (\bar{X}_j - \bar{X}) = (\bar{X}_{ij} - \bar{X}_i - \bar{X}_j + \bar{X})$$

La magnitud de este término SCI depende de la importancia de la interacción; si ésta es muy importante, este término tenderá a ser elevado; y al contrario, si es poco importante este término tenderá a ser pequeño.

Por último, el cuarto término:

$$SCR = \sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n (X_{ijk} - \bar{X}_{ij})^2$$

es una medida de la dispersión de los datos de cada celda con respecto a su media; o sea es una magnitud residual, de error muestral o aleatoria.

EJEMPLO 13.11.

La productividad de 26 obreros de distintos niveles de habilidad a los cuales se aplicaron 3 métodos diferentes de entrenamiento (3 obreros por combinación) fueron los siguientes:

	FACTOR B - Método de Entrenamiento			$\sum_{j=1}^3 \sum_{k=1}^3 X_{ijk}$	$\bar{X}_i$
	Método 1	Método 2	Método 3		
Superior 1	24 21 18 $\sum_{k=1}^3 X_{11k} = 63$ $\bar{X}_{11} = 21$	17 18 20 $\sum_{k=1}^3 X_{12k} = 55$ $\bar{X}_{12} = 18,33$	13 12 16 $\sum_{k=1}^3 X_{13k} = 41$ $\bar{X}_{13} = 13,67$	159	17,66
Buena 2	18 15 16 $\sum_{k=1}^3 X_{21k} = 49$ $\bar{X}_{21} = 16,33$	18 20 15 $\sum_{k=1}^3 X_{22k} = 53$ $\bar{X}_{22} = 17,67$	14 10 12 $\sum_{k=1}^3 X_{23k} = 36$ $\bar{X}_{23} = 12$	138	15,33
Media 3	10 13 11 $\sum_{k=1}^3 X_{31k} = 34$ $\bar{X}_{31} = 11,33$	11 14 12 $\sum_{k=1}^3 X_{32k} = 37$ $\bar{X}_{32} = 12,33$	17 13 20 $\sum_{k=1}^3 X_{33k} = 50$ $\bar{X}_{33} = 16,67$	121	13,44
Deficiente 4	10 5 12 $\sum_{k=1}^3 X_{41k} = 27$ $\bar{X}_{41} = 9$	6 9 13 $\sum_{k=1}^3 X_{42k} = 28$ $\bar{X}_{42} = 9,33$	11 10 9 $\sum_{k=1}^3 X_{43k} = 30$ $\bar{X}_{43} = 10$	85	9,44
$\sum_{i=1}^4 \sum_{j=1}^3 X_{ijk}$	173	173	157	$\sum_{i=1}^4 \sum_{j=1}^3 \sum_{k=1}^3 X_{ijk} = 503$	
$\bar{X}_j$	14,41	14,41	13,09		$\bar{X} = 13,97$

$$\begin{aligned}
STC &= \sum_{i=1}^4 \sum_{j=1}^3 \sum_{k=1}^3 (X_{ijk} - \bar{X})^2 = \\
&= (24-13,97)^2 + (21-13,97)^2 + \dots + (9-13,97)^2 = 654,97 \\
SCA &= 3 \cdot 3 \sum_{i=1}^4 (\bar{X}_i - \bar{X})^2 = 9 [(17,66-13,97)^2 + (15,33-13,97)^2 + \\
&\quad + (13,44-13,97)^2 + (9,44-13,97)^2] = 326,53 \\
SCB &= 3 \cdot 4 \sum_{j=1}^3 (\bar{X}_j - \bar{X})^2 = 12 [(14,41-13,97)^2 + \\
&\quad + (14,41-13,97)^2 + (13,09-13,97)^2] = 14,22 \\
SCI &= 3 \sum_{i=1}^4 \sum_{j=1}^3 (\bar{X}_{ij} - \bar{X}_i - \bar{X}_j + \bar{X})^2 = 3 [(21-17,66-14,41+13,97)^2 + \\
&\quad + (18,33-17,66-14,41+13,97)^2 + (13,67-17,66-13,09+13,97)^2 + \\
&\quad + (16,33-15,33-14,41+13,97)^2 + \dots + (10-9,44-13,09+13,97)^2] = 170,89 \\
SCR &= \sum_{i=1}^4 \sum_{j=1}^3 \sum_{k=1}^3 (X_{ijk} - \bar{X}_{ij})^2 = (24-21)^2 + (21-21)^2 + (18-21)^2 + (17-18,33)^2 + \\
&\quad + (18-18,33)^2 + \dots + (11-10)^2 + (10-10)^2 + (9-10)^2 = 143,33
\end{aligned}$$

13.3.2.2. PROCEDIMIENTO DE CONTRASTE

Bajo los supuestos de variables X_{ijk} normales, con común varianza σ^2 , se cumple lo siguiente:

$$\frac{SCR}{\sigma^2} \sim \chi^2 [pq(n-1)]$$

SCR es un estimador de la dispersión residual o aleatoria de los datos.

1) Además si $H_0: \mu_{1.} = \mu_{2.} = \dots = \mu_{p.}$ es verdadera; entonces:

$$\frac{SCA}{\sigma^2} \sim \chi^2 (p-1)$$

La comparación de SCA (Variación debida a diferencias en las medias poblacionales del factor A) con SCR nos dirá la importancia relativa de la influencia del factor A.

$$\frac{SCA/\sigma^2 (p-1)}{SCR/\sigma^2 pq (n-1)} \sim F [(p-1), pq (n-1)]$$

Si $F > F_{\alpha}$, se rechaza H_0 ; si $F < F_{\alpha}$, se acepta H_0 .

2) Si $H_0: \mu_{.1} = \mu_{.2} = \dots = \mu_{.q}$ es verdadera; entonces,

$$\frac{SCB}{\sigma^2} \sim \chi^2 (q-1)$$

Como antes, la comparación de SCB con SCR indicará la importancia de la influencia del factor B.

$$\frac{SCB/\sigma^2 (q-1)}{SCR/\sigma^2 pq (n-1)} \sim F [(q-1), pq (n-1)]$$

Si $F > F_{\alpha}$, se rechaza la hipótesis; si $F < F_{\alpha}$, se acepta la hipótesis.

3) Si $H_0: \mu_{ij} - \mu_{i.} - \mu_{.j} + \mu = 0$ es verdadera; entonces:

$$\frac{SCI}{\sigma^2} \sim \chi^2 [(p-1)(q-1)]$$

SCI es una medida de la dispersión de los datos debido a la interacción.

$$\frac{SCI/\sigma^2 (p-1)(q-1)}{SCR/\sigma^2 pq (n-1)} \sim F [(p-1)(q-1), pq (n-1)]$$

Si $F > F_{\alpha}$, se rechaza H_0

Si $F < F_{\alpha}$, se acepta H_0

EJEMPLO 13.12.

En el ejemplo 13.11. usando un nivel de significación del 5%

$$F = \frac{SCA/(p-1)}{SCR/pq(n-1)} = \frac{326,53/3}{143,33/4 \cdot 3 \cdot 2} = 18,23$$

$$F_{0,05}(3,24) = 3,05 \quad F > F_{\alpha} \quad \text{se rechaza } H_0.$$

Los niveles de habilidad aparentemente tienen diferente influencia en la productividad.

$$F = \frac{SCB/(q-1)}{SCR/pq(n-1)} = \frac{14,22/2}{143,33/4 \cdot 3 \cdot 2} = 1,19$$

$$F_{0,05}(2,24) = 3,40 \quad F < F_{\alpha} \quad \text{se acepta } H_0.$$

Los métodos de entrenamiento aparentemente son similares en cuanto a su influencia en la productividad.

$$F = \frac{SCI/(p-1)(q-1)}{SCR/pq(n-1)} = \frac{170,89/3 \cdot 2}{143,33/4 \cdot 3 \cdot 2} = 4,77$$

$$F_{0,05}(6,24) = 2,51 \quad F > F_{\alpha} \quad \text{Se rechaza } H_0.$$

Aparentemente existe interacción entre los distintos niveles de los factores.

13.3.2.3. FORMULAS PRACTICAS PARA SIMPLIFICACION DE CALCULOS

Por el mismo razonamiento de la sección 13.2.4. las distintas sumas son:

$$STC = \sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n (X_{ijk} - \bar{X})^2 = \sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n X_{ijk}^2 - \frac{\left(\sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n X_{ijk} \right)^2}{npq}$$

$$SCA = nq \sum_{i=1}^p (\bar{X}_{i.} - \bar{X})^2 = \frac{1}{nq} \sum_{i=1}^p \left(\sum_{j=1}^q \sum_{k=1}^n X_{ijk} \right)^2 - \frac{\left(\sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n X_{ijk} \right)^2}{npq}$$

$$SCB = np \sum_{j=1}^q (\bar{X}_{.j} - \bar{X})^2 = \frac{1}{np} \sum_{j=1}^q \left(\sum_{i=1}^p \sum_{k=1}^n X_{ijk} \right)^2 - \frac{\left(\sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n X_{ijk} \right)^2}{npq}$$

$$SCR = \sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n (X_{ijk} - \bar{X}_{ij})^2 = \sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n X_{ijk}^2 - \frac{1}{n} \sum_{i=1}^p \sum_{j=1}^q \left(\sum_{k=1}^n X_{ijk} \right)^2$$

$$SCI = STC - SCA - SCB - SCR$$

EJEMPLO 13.13.

Aplicación de las fórmulas anteriores al ejemplo 13.11.

$$STC = \sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n X_{ijk}^2 - \frac{\left(\sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n X_{ijk} \right)^2}{npq} =$$

$$= (24^2 + 21^2 + 18^2 + \dots + 9^2) - \frac{1}{4 \cdot 3 \cdot 3} (24 + 21 + 18 + \dots + 9)^2 = 7.683 - 7.028,03 = 654,97$$

$$SCA = \frac{1}{nq} \sum_{i=1}^p \left(\sum_{j=1}^q \sum_{k=1}^n X_{ijk} \right)^2 - \frac{\left(\sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n X_{ijk} \right)^2}{npq} =$$

$$= \frac{1}{9} (159^2 + 138^2 + 121^2 + 85^2) - 7.028,03 = 7.354,55 - 7.028,03 = 326,53$$

$$SCB = \frac{1}{np} \sum_{j=1}^q \left(\sum_{i=1}^p \sum_{k=1}^n X_{ijk} \right)^2 - \frac{\left(\sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n X_{ijk} \right)^2}{npq} =$$

$$= \frac{1}{12} (173^2 + 173^2 + 157^2) - 7.028,03 = 7.042,25 - 7.028,03 = 14,22$$

$$SCR = \sum_{i=1}^p \sum_{j=1}^q \sum_{k=1}^n X_{ijk}^2 - \frac{1}{n} \sum_{i=1}^p \sum_{j=1}^q \left(\sum_{k=1}^n X_{ijk} \right)^2 =$$

$$= (24^2 + 21^2 + \dots + 9^2) - \frac{1}{3} (63^2 + 55^2 + 41^2 + \dots + 30^2) = 7.683 - 7.539,67 = 143,33$$

$$SCI = STC - SCA - SCB - SCR = 170,89$$

TABLA 13.4.
ANALISIS DE VARIANZA
(Clasificación Doble) (n > 1)

(1) Fuente de Variación	(2) Suma de Cuadrados	(3) Grados de Libertad	(4) (2) / (3)	F
Factor A	SCA	(p - 1)	SCA/(p - 1)	$\frac{SCA/(p-1)}{SCR/pq(n-1)}$
Factor B	SCB	(q - 1)	SCB/(q - 1)	$\frac{SCB/(q-1)}{SCR/pq(n-1)}$
Interacción	SCI	(p - 1)(q - 1)	SCI/(p - 1)(q - 1)	$\frac{SCI/(p-1)(q-1)}{SCR/pq(n-1)}$
Residuo	SCR	pq(n - 1)	SCR/pq(n - 1)	
TOTAL	STC	pqn - 1		

APENDICE

13.4. COMPARACION DE VARIANZAS DE VARIAS POBLACIONES

Uno de los supuestos del análisis de varianza es la igualdad de varianzas de las variables estudiadas. En este Anexo se dará sin prueba un método para contrastar igualdad de varianzas de más poblaciones. Este método se debe a M. S. Bartlett²³, y procede de la siguiente forma:

Dadas k poblaciones con varianzas $\sigma_1^2, \sigma_2^2, \dots, \sigma_k^2$, se toman muestras aleatorias de cada población de tamaños $n_1, n_2, \dots, n_k$. Designemos por X_{ij} el elemento j de la muestra i; es decir, X_{12} será el elemento 2 de la muestra aleatoria de la población 1, etc. Sea $\bar{X}_i$ la media muestral de la muestra i,

$$\bar{X}_i = \frac{\sum_{j=1}^{n_i} X_{ij}}{n_i}$$

Sea s_i^2 la varianza muestral de la muestra i,

$$s_i^2 = \frac{\sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2}{n_i}$$

²³ M. S. Bartlett. "Properties of Sufficiency and Statistical Tests", Supplement to the Journal of the Royal Statistical Society (1937).

Se quiere contrastar la hipótesis nula;

$$H_0 : \sigma_1^2 = \sigma_2^2 = \dots = \sigma_k^2 = \sigma^2$$

Si H_0 es verdadera, la magnitud $s_i^2 = \frac{n_1 s_1^2 + n_2 s_2^2 + \dots + n_k s_k^2}{(n_1 - 1) + (n_2 - 1) + \dots + (n_k - 1)}$

es un estimador insesgado de σ^2 .

Se calcula el estadístico:

$$A = 2,3026 \left\{ \left[\sum_{i=1}^k (n_i - 1) \right] \log s^2 - \sum_{i=1}^k (n_i - 1) \log \frac{n_i s_i^2}{n_i - 1} \right\}$$

Se divide el estadístico A por el factor de corrección

$$C = 1 + \frac{1}{3(k-1)} \left(\sum_{i=1}^k \frac{1}{n_i - 1} - \frac{1}{\sum_{i=1}^k [n_i - 1]} \right)$$

El estadístico A/C es una variable χ^2 con $k - 1$ grados de libertad.

Si A/C es mayor que $\chi_{\alpha}^2 (k-1)$, se rechaza la hipótesis con un nivel de significación de α ; si A/C es menor se acepta la hipótesis.

TABLA 13.5
CALCULOS PARA EL CONTRASTE DE IGUALDAD DE VARIANZAS

(1) Muestra Nº	(2) $n_i s_i^2$	(3) $n_i - 1$	(4) $1/(n_i - 1)$	(5) $n_i s_i^2 / (n_i - 1)$	(6) $\log \frac{n_i s_i^2}{n_i - 1}$	(7) $(n_i - 1) \log \frac{n_i s_i^2}{n_i - 1}$
1	$\sum_{j=1}^{n_1} (X_{1j} - \bar{X}_1)^2$	$n_1 - 1$	$1/(n_1 - 1)$	(2) x (4)	log (5)	(3) x (6)
2	$\sum_{j=1}^{n_2} (X_{2j} - \bar{X}_2)^2$	$n_2 - 1$	$1/(n_2 - 1)$	(2) x (4)	log (5)	(3) x (6)
.	.	.	.	.	.	.
.	.	.	.	.	.	.
.	.	.	.	.	.	.
k	$\sum_{j=1}^{n_k} (X_{kj} - \bar{X}_k)^2$	$n_k - 1$	$1/(n_k - 1)$	(2) x (4)	log (5)	(3) x (6)
Sumas	$\sum_{i=1}^k n_i s_i^2$	$\sum_{i=1}^k (n_i - 1)$	$\sum_{i=1}^k \frac{1}{(n_i - 1)}$			$\sum_{i=1}^k (n_i - 1) \log \frac{n_i s_i^2}{n_i - 1}$

$$s_*^2 = \frac{\text{Suma de Columna 2}}{\text{Suma de Columna 3}}$$

EJEMPLO 13.14.

Con los datos del ejemplo 13.1., contrastar la hipótesis de que las varianzas de las 3 poblaciones (cada población representa un método de entrenamiento) son iguales.

Muestra	$n_i s_i^2$	$n_i - 1$	$1/(n_i - 1)$	$n_i s_i^2 / (n_i - 1)$	$\log \frac{n_i s_i^2}{n_i - 1}$	$(n_i - 1) \log \frac{n_i s_i^2}{n_i - 1}$
1	34	4	0,25	8,5	0,929419	3,717676
2	62	4	0,25	15,5	1,190332	4,761328
3	26	4	0,25	6,5	0,812913	3,251652
Sumas	122	12	0,75			11,730656

$$s_*^2 = \frac{122}{12} = 10,17 \quad \log 10,17 = 1,007321$$

$$A = 2,3026 (12 \times 1,007321 - 11,730656) = 0,82248$$

$$\text{Factor de Corrección } C = 1 + \frac{1}{3 \times 2} \left(0,75 - \frac{1}{12} \right) = 1,111$$

$$\frac{A}{C} = \frac{0,82248}{1,111} = 0,7402$$

$$\chi_{0,05}^2 (2) = 5,99 \quad \frac{A}{C} < 5,99$$

Se acepta la hipótesis de igualdad de varianzas.

EJEMPLO 13.15.

Con los datos del ejemplo 13.5., contrastar la hipótesis de que las varianzas de las 4 poblaciones son iguales.

Muestra	$n_i s_i^2$	$n_i - 1$	$1/(n_i - 1)$	$n_i s_i^2 / (n_i - 1)$	$\log \frac{n_i s_i^2}{n_i - 1}$	$(n_i - 1) \log \frac{n_i s_i^2}{n_i - 1}$
1	44,40	9	0,1111	4,933	0,693111	6,237999
2	40,00	5	0,2000	8,000	0,903090	4,515450
3	110,22	8	0,1250	13,790	1,139564	9,116512
4	86,00	8	0,1250	10,750	1,031408	8,251264
	280,62	30	0,5611			28,121225

$$s_*^2 = \frac{280,62}{30} = 9,354 \quad \log s_*^2 = 0,970997$$

$$A = 2,3026 (30 \cdot 0,970997 - 28,121225) = 2,322598$$

$$C = 1 + \frac{1}{3 \times 3} \left(0,5611 - \frac{1}{30} \right) = 1,058641$$

$$A/C = 2,193943 \quad \chi_{0,05}^2 (3) = 7,81 \quad A/C < 7,81$$

Se acepta la hipótesis de igualdad de varianzas.

EJERCICIOS RESUELTOS

- 13.1. Un investigador está interesado en saber si los ingresos medios semanales de los habitantes de 3 barrios de Caracas son significativamente diferentes. Se tomaron muestras aleatorias de 5 elementos en cada uno de los barrios con los siguientes resultados.

Barrio A	Barrio B	Barrio C
135	130	125
130	135	130
126	120	120
100	120	130
120	125	135

A la luz de estos resultados ¿Se puede afirmar que los ingresos medios son diferentes? $\alpha = 0,05$.

Solución:

Se trata de contrastar la hipótesis nula.

$$H_0 : \mu_1 = \mu_2 = \mu_3$$

A		B		C	
X_{i1}	X_{i1}^2	X_{i2}	X_{i2}^2	X_{i3}	X_{i3}^2
135	18.225	130	16.900	125	15.625
130	16.900	135	18.225	130	16.900
126	15.876	120	14.400	120	14.400
100	10.000	120	14.400	130	16.900
120	14.400	125	15.625	135	18.225
611	75.401	630	79.550	640	82.050

$$STC = \sum_{j=1}^3 \sum_{i=1}^4 X_{ij}^2 - \frac{1}{12} \left(\sum_{j=1}^3 \sum_{i=1}^4 X_{ij} \right)^2 =$$

$$= (75.401 + 79.550 + 82.050) - \frac{(611 + 630 + 640)^2}{12} = 1.123,60$$

$$SCD = \sum_{j=1}^3 \sum_{i=1}^4 X_{ij}^2 - \frac{1}{4} \sum_{j=1}^3 \left(\sum_{i=1}^4 X_{ij} \right)^2 = 237.001 - \frac{611^2 + 630^2 + 640^2}{4} = 1.036,80$$

$$SCE = \frac{1}{4} \sum_{j=1}^3 \left(\sum_{i=1}^4 X_{ij} \right)^2 - \frac{1}{12} \left(\sum_{j=1}^3 \sum_{i=1}^4 X_{ij} \right)^2 = 235.964,20 - 235.877,40 = 86,80$$

TABLA DE ANALISIS DE VARIANZA

(1) Fuente de Variación	(2) Suma de Cuadrados	(3) Grados de Libertad	(4) (2)/(3)	(5) F
Entre Muestras	86,80	2	43,40	0,5
Dentro de Muestras	1.036,80	12	86,40	
Total	1.123,60	14		

$$F_{0,05}(2,12) = 3,89 ; \quad F = 0,5 < 3,89$$

Se acepta H_0 . Las medias son aparentemente iguales.

- 13.2. Se desea saber si existe diferencia significativa en el diámetro medio de las rolineras producidas por 3 máquinas. Se tomaron muestras de 5, 7 y 4 elementos respectivamente, y dieron los siguientes diámetros en mm.

Máquina 1	Máquina 2	Máquina 3
8	8,5	10
9	9,5	9
10	9,0	9
9	10,0	11
11	10,0	
	9,0	
	10,0	

Con un nivel de significación del 5%. ¿Se podría, con base en esos resultados, rechazar la hipótesis de que los diámetros medios son iguales? $\alpha = 0,05$

Solución:

Se trata de contrastar la hipótesis nula.

$$H_0 : \mu_1 = \mu_2 = \mu_3$$

Máquina 1		Máquina 2		Máquina 3	
X_{i1}	X_{i1}^2	X_{i2}	X_{i2}^2	X_{i3}	X_{i3}^2
8	64	8,5	72,25	10	100
9	81	9,5	90,25	9	81
10	100	9,0	81,00	9	81
9	81	10,0	100,00	11	121
11	121	10,0	100,00		
		9,0	81,00		
		10,0	100,00		
47	447	66,0	624,50	39	383

$$STC = \sum_{j=1}^3 \sum_{i=1}^{n_j} X_{ij}^2 - \frac{1}{16} \left(\sum_{j=1}^3 \sum_{i=1}^{n_j} X_{ij} \right)^2 =$$

$$= (447 + 624,50 + 383) - \frac{(47 + 66 + 39)^2}{16} = 10,50$$

$$SCD = \sum_{j=1}^3 \sum_{i=1}^{n_j} X_{ij}^2 - \sum_{j=1}^3 \frac{1}{n_j} \left(\sum_{i=1}^{n_j} X_{ij} \right)^2 = 1.454,50 - \left(\frac{47^2}{5} + \frac{66^2}{7} + \frac{39^2}{4} \right) = 10,17$$

$$SCE = \sum_{j=1}^3 \frac{1}{n_j} \left(\sum_{i=1}^{n_j} X_{ij} \right)^2 - \frac{1}{16} \left(\sum_{j=1}^3 \sum_{i=1}^{n_j} X_{ij} \right)^2 = 1.444,33 - 1.444 = 0,33$$

TABLA DE ANALISIS DE VARIANZA

(1) Fuente de Variación	(2) Suma de Cuadrados	(3) Grados de Libertad	(4) (2)/(3)	(5) F
Entre Muestras	0,33	2	0,165	0,210
Dentro de Muestras	10,17	13	0,782	
Total	10,50	15		

$F < 1$ Se acepta H_0 .

13.3. Los siguientes datos representan el número de unidades diarias producidas por seis diferentes trabajadores, usando cuatro diferentes máquinas.

- Verificar si la productividad media diaria es la misma para los 6 trabajadores.
- Verificar si la productividad media diaria es la misma para las cuatro máquinas.

		MAQUINAS			
		1	2	3	4
O B R E R O S	1	24	18	27	16
	2	26	20	22	23
	3	14	16	24	12
	4	23	18	26	13
	5	18	22	29	19
	6	27	22	24	26

Solución:

Se trata de un análisis de varianza con doble clasificación y tamaño de la muestra igual a uno. Hay que contrastar dos hipótesis:

1º) No hay diferencia en la productividad media de los obreros.

$$H_0 : \mu_1 = \mu_2 = \mu_3 = \mu_4 = \mu_5 = \mu_6$$

2º) No hay diferencia en la productividad media de las máquinas.

$$H_0 : \mu_{.1} = \mu_{.2} = \mu_{.3} = \mu_{.4}$$

MAQUINAS												
1		2		3		4		$\sum_{j=1}^4 X_{ij}$	$\left(\sum_{j=1}^4 X_{ij}\right)^2$	$\sum_{j=1}^4 X_{ij}^2$		
X_{i1}	X_{i1}^2	X_{i2}	X_{i2}^2	X_{i3}	X_{i3}^2	X_{i4}	X_{i4}^2					
1	24	576	18	324	27	729	16	256	85	7.225	1.885	
2	26	676	20	400	22	484	23	529	91	8.281	2.089	
3	14	196	16	256	24	576	12	144	66	4.356	1.172	
4	23	529	18	324	26	676	13	169	80	6.400	1.698	
5	18	324	22	484	29	841	19	361	88	7.744	2.010	
6	27	729	22	484	24	576	26	676	99	9.801	2.465	
132		116		152		109		509	43.807			
17.429		13.456		23.104		11.881		2.135	65.870	11.319		
$\left(\sum_{i=1}^6 X_{ij}\right)^2$												
$\sum_{i=1}^6 X_{ij}^2$												

Verificar

- i) Si los salarios medios son iguales para hombres y mujeres.
- ii) Si los salarios medios son iguales en las cuatro industrias.
- iii) Si existe interacción entre los dos factores (Industria y Sexo).

Solución:

Se trata de aplicar análisis de varianza con clasificación doble, y tamaño de la muestra mayor que uno.

Hay que contrastar las hipótesis:

1º) No hay diferencia en el salario medio de los hombres y mujeres.

$$H_0 : \mu_1 = \mu_2$$

2º) No hay diferencia en el salario medio en las industrias.

$$H_0 : \mu_1 = \mu_2 = \mu_3 = \mu_4$$

3º) No existe interacción entre las categorías del factor A (sexo) y el factor B (industria), en cuanto al salario medio.

$$H_0 : \mu_{ij} - \mu_{i.} - \mu_{.j} + \mu = 0$$

		INDUSTRIA				$\sum_{j=1}^4 \sum_{k=1}^3 x_{ijk}$
		1	2	3	4	
Hombres	11 (121)	18 (324)	10 (100)	13 (169)	132 (17.424)	
	9 (81)	12 (144)	9 (81)	8 (64)		
	7 (49)	15 (225)	11 (121)	9 (81)		
	27 (729)	45 (2.025)	30 (900)	30 (900)		
Mujeres	12 (144)	13 (169)	10 (100)	12 (144)	144 (20.736)	
	14 (196)	16 (256)	7 (49)	11 (121)		
	13 (169)	16 (256)	10 (100)	10 (100)		
	39 (1.521)	45 (2.025)	27 (729)	33 (1.089)		
		66 (4.356)	90 (8.100)	57 (3.249)	63 (3.969)	276

$$\sum_{i=1}^2 \sum_{k=1}^3 X_{ijk}$$

Los números entre paréntesis son los cuadrados de los números que aparecen a la izquierda de cada paréntesis.

$$p = 2 \quad q = 4 \quad n = 3$$

$$STC = \sum_{i=1}^2 \sum_{j=1}^4 \sum_{k=1}^3 X_{ijk}^2 - \frac{\left(\sum_{i=1}^2 \sum_{j=1}^4 \sum_{k=1}^3 X_{ijk} \right)^2}{24} =$$

$$= (121 + 81 + \dots + 121 + 100) - \frac{276^2}{24} = 3.364 - 3.174 = 190$$

$$SCA = \frac{1}{3 \times 4} \sum_{i=1}^2 \left(\sum_{j=1}^4 \sum_{k=1}^3 X_{ijk} \right)^2 - \frac{\left(\sum_{i=1}^2 \sum_{j=1}^4 \sum_{k=1}^3 X_{ijk} \right)^2}{24} =$$

$$= \frac{17.424 + 20.736}{12} - 3.174 = 3.180 - 3.174 = 6$$

$$SCB = \frac{1}{3 \times 2} \sum_{j=1}^4 \left(\sum_{i=1}^2 \sum_{k=1}^3 X_{ijk} \right)^2 - \frac{\left(\sum_{i=1}^2 \sum_{j=1}^4 \sum_{k=1}^3 X_{ijk} \right)^2}{24} =$$

$$= \frac{4.356 + 8.100 + 3.249 + 3.969}{6} - 3.174 = 3.279 - 3.174 = 105$$

$$SCR = \sum_{i=1}^2 \sum_{j=1}^4 \sum_{k=1}^3 X_{ijk}^2 - \frac{1}{n} \sum_{i=1}^2 \sum_{j=1}^4 \left(\sum_{k=1}^3 X_{ijk} \right)^2 =$$

$$= 3.364 - \frac{729 + 2.025 + \dots + 1.089}{3} = 3.364 - 3.306 = 58$$

$$SCI = STC - SCA - SCB - SCR = 21$$

- i) ¿Existe diferencia en los rendimientos de las distintas variedades de maíz independientemente del fertilizante utilizado?
- ii) ¿Existe diferencia en los rendimientos debido al tipo de fertilizante independientemente de la variedad de maíz? $\alpha = 0,05$.

13.11. La siguiente tabla presenta las estimaciones de un índice del costo de la vida en cuatro zonas de Caracas hechas por cinco investigadores.

Investigador	Zonas			
	1	2	3	4
1	106	110	107	109
2	107	111	110	112
3	105	109	108	108
4	104	108	104	114
5	109	105	109	111

- i) ¿Existe diferencia en los índices de costo de la vida en cuanto a cada investigador independientemente de la zona?
- ii) ¿Existe diferencia en los índices de cada zona independientemente del investigador que lo realiza? $\alpha = 0,05$.

13.12. Los datos siguientes se refieren a cuatro diferentes tipos de alimento "C" y 2 diferentes tipos de alimento "D" para ganado vacuno. 24 vacas fueron escogidas aleatoriamente, y el aumento de peso en libras fue:

C \ D	1	2	3	4
1	133 144 134	162 148 152	210 233 220	195 184 200
2	149 143 149	146 156 160	227 229 225	187 193 184

- i) ¿Hay diferencia significativa en el aumento de peso debido a los distintos tipos de Alimento "D", independientemente del tipo de Alimento "C" ?

- ii) ¿Hay diferencia significativa en el aumento de peso debido a los distintos tipos de Alimento "C", independientemente del tipo de Alimento "D"?
- iii) ¿Hay influencia significativa por las distintas combinaciones de alimentos?

13.13. Los datos siguientes corresponden al gasto porcentual en alimentación de 32 familias clasificadas según su nivel de ingresos diarios y su lugar de residencia.

	< 500	500 - 1000	1000 - 2000	> 2000
Caracas	60 55 58 62	55 54 58 50	42 46 50 48	42 50 38 35
Maracaibo	59 56 50 58	54 56 55 53	45 46 40 48	35 32 36 40

- i) ¿Hay diferencia significativa en el gasto medio en los distintos niveles de ingreso, independientemente del lugar de residencia?
- ii) ¿Hay diferencia significativa en el gasto medio de los habitantes de Caracas y Maracaibo, independientemente del nivel de ingresos?
- iii) ¿Existe interacción entre los distintos niveles de ingresos y el lugar de residencia? $\alpha = 0,05$.

13.14. Los datos de la tabla se refieren al sueldo diario de 36 profesionales, agrupados según su profesión y según el sector económico en que prestan sus servicios.

	Abogados	Economistas	Contadores
Gobierno	4.000 3.750	3.700 3.600	3.500 4.000
Industria	3.500 4.400	4.000 4.500	4.250 3.850
Banca	4.200 3.950	3.800 3.750	4.000 4.100
	3.700 4.400	4.200 4.600	4.500 3.900
	4.100 4.700	4.300 3.900	4.400 4.200
	3.700 4.500	4.000 4.600	3.950 4.000

- i) Contrastar la hipótesis de igualdad en los sueldos medios de las distintas profesiones.

ii) Contrastar la hipótesis de igualdad de los sueldos medios en los distintos sectores.

iii) Contrastar la hipótesis de no interacción.

13.15. En el ejercicio 13.2., contrastar la hipótesis de igualdad de varianzas. $\alpha = 0,05$.

13.16. En el ejercicio 13.7., contrastar la hipótesis de igualdad de varianzas. $\alpha = 0,05$.

13.17. En el ejercicio 13.9., contrastar la hipótesis de igualdad de varianzas. $\alpha = 0,05$.

13.18. En el ejercicio 13.4., contrastar la hipótesis de igualdad de varianzas. $\alpha = 0,05$.

13.19. En el ejercicio 13.14., contrastar la hipótesis de igualdad de varianzas. $\alpha = 0,05$.

CAPITULO XIV

CONCEPTOS BASICOS DE ECONOMETRIA

14.1. INTRODUCCION

Econometría, literalmente, significa "medición de la economía". Esta interpretación literal es demasiado amplia, en el sentido de que no toda medición de fenómenos económicos se puede incluir dentro de un concepto preciso de Econometría. Por ejemplo, la determinación estadística del "Índice del Costo de la Vida en Caracas" constituye un importantísimo trabajo de medición económica, pero no es Econometría.

La Econometría podría ser definida como "una rama de la Ciencia Económica en la cual los elementos de la Teoría Económica, las Matemáticas y la Inferencia Estadística son aplicados al análisis económico mediante el establecimiento, estimación y verificación empírica de relaciones cuantitativas entre variables económicas".

En la definición se destaca el hecho de que la Econometría conjuga el uso de los conocimientos, métodos y técnicas de otras disciplinas perfectamente identificables.

Cabría preguntarse por qué se ha desarrollado independientemente de la Teoría Económica, de la Economía Matemática, de la Estadística Económica Descriptiva o de la Estadística Matemática. La clave de esta separación se encuentra en la segunda parte de la definición.

La Teoría Económica postula hipótesis de comportamiento generalmente en términos cualitativos. Cuando se afirma que el consumo aumenta al aumentar el ingreso, no proporciona una medida numérica de la relación entre ambos.

La Economía Matemática consiste fundamentalmente en la aplicación de los instrumentos matemáticos a los aspectos puramente teóricos del análisis económico, expresa la teoría económica en términos matemáticos, estudia relaciones teóricas entre variables económicas, pero no presta atención a la medición o verificación empírica de la teoría económica.

La Estadística Económica centra su atención en la recolección, procesamiento y presentación de cifras económicas; es decir, aplica mediciones cuantitativas a variables económicas pero no intenta establecer relaciones entre ellas.

La Estadística Matemática estudia relaciones entre variables y proporciona una gran parte de las herramientas de la Econometría; ésta usa profusamente los métodos de la teoría estadística; los procedimientos inductivos de la Estadística clásica permiten contrastar hipótesis y estimar parámetros. Estos métodos usados en Econometría, en principio son comunes con los usados en otros campos de la ciencia, pero se han tenido que desarrollar técnicas propias por los rasgos particulares de los fenómenos y de las variables económicas, entre los que destacan: 1) los datos representativos de relaciones económicas, rara vez pueden obtenerse mediante experimentos controlados, 2) la conducta económica está respaldada por un abundante cuerpo de teoría cuyos principios deben aprovecharse con métodos propios.

Es así como la Econometría se ha desarrollado en forma separada, aunque no independiente del progreso de las otras disciplinas mencionadas, perfeccionando una serie de nuevos métodos y técnicas de análisis.

Esta rama de la ciencia económica, con características propias, es conocida como Econometría desde 1930, año en que se fundó la "Econometric Society" como una "sociedad internacional para el avance de la Teoría Económica en su relación con la Estadística y las Matemáticas".

Podría resumirse el objetivo de la Econometría en proporcionar contenido empírico a la Teoría Económica. El análisis econométrico complementa la teoría usando datos empíricos conseguidos en la observación de la realidad económica para verificar la plausibilidad de las relaciones entre variables económicas postuladas por la teoría, conseguir estimaciones numéricas de las relaciones, proyectar y, de alguna forma, controlar el curso futuro de las variables como auxiliar de la política económica.

14.2. MODELOS ECONOMICOS

La Teoría Económica fundamentalmente trata de estudiar las relaciones existentes entre variables económicas. Así, la teoría simple Keynesiana nos dice que el consumo es función del ingreso; la teoría del consumidor nos dice que éste reacciona ante cambios en los precios y en consecuencia la demanda de un bien es una función del precio; profundizando más, la teoría afirma que la demanda de un bien no sólo es función de su precio, sino también del precio de otros bienes, del ingreso, etc.


En estos análisis de la teoría económica las variables son, en general, cuantificables y planteando hipótesis sobre el comportamiento de alguna de ellas se puede determinar el comportamiento de otras relacionadas con las primeras.

Las relaciones entre las variables suelen expresarse en forma de un modelo.

Un modelo económico se puede definir como "una expresión lógica, verbal, gráfica o matemática de las relaciones entre variables económicas".

Si bien la costumbre ha identificado el concepto de modelo con el concepto matemático, de hecho cualquier forma de expresión de esas relaciones constituye un modelo.

Por ejemplo, cuando se dice "La cantidad demandada de un bien varía en forma inversa, ceteris paribus, con las variaciones de los precios" se ha determinado un modelo verbal de la conducta del consumidor. La misma relación se puede expresar en forma gráfica en los ejes de coordenadas, con lo que se tiene un modelo gráfico:



También la relación entre cantidades demandadas y precios se puede expresar algebraicamente en un modelo matemático:

$$(1) \quad Q = f(P) \quad ; \quad (2) \quad \frac{dQ}{dP} < 0$$

siendo, Q = Cantidades demandadas y P = Precio

La expresión (1) indica que las cantidades demandadas varían con los precios y la (2) indica que la relación es inversa al ser la derivada negativa.

Un modelo económico es una representación abstracta y simplificada de la realidad; en él se tratan de poner de relieve aquellos aspectos que se consideran fundamentales para

el análisis de un problema económico en particular y dejar de lado aquellos otros aspectos de la realidad que pueden oscurecer el análisis y que no se consideran relevantes.

“Un modelo económico matemático es un conjunto de relaciones que representan un proceso económico, expresadas en forma matemática”; o sea, es una representación matemática y simplificada de un fenómeno económico.

Un modelo matemático es, entonces, un sistema de ecuaciones en el que se expresa el conocimiento que “a priori” se posee sobre el comportamiento de las variables que conforman un determinado problema económico.

La construcción de un modelo es un proceso creativo, en el que se pretende deliberadamente simplificar la realidad con toda su complejidad y diversidad, reduciendo el problema a expresiones manejables y útiles, para lo cual se debe eliminar lo supuestamente superfluo, y captar las características cruciales del fenómeno económico en estudio.

No se debe creer que el uso de modelos es exclusivo de la Ciencia Económica; se puede afirmar que todas las ciencias trabajan con modelos; quizá, el punto de partida del método científico es aislar los fenómenos y establecer representaciones abstractas de ellos, simplificando situaciones reales complejas para estudiar sus leyes básicas.

Es cierto que en las ciencias exactas y físicas los modelos, por lo general, son representaciones exactas y fieles del fenómeno real estudiado; esto es debido, por un lado, a la constancia de las leyes que rigen estas ciencias y, por otro, a la posibilidad de experimentación controlada de los fenómenos.

En las Ciencias Sociales, en general, y en la economía, en particular, el uso adecuado de modelos, es mucho más difícil y complicado. La realidad económica es cambiante, el comportamiento de las variables económicas se basa en el comportamiento del hombre y la sociedad, cuyas reacciones no son de naturaleza permanente; la experimentación es generalmente imposible; el estudio de los fenómenos rara vez se puede hacer en condiciones invariables, es decir el “ceteris paribus” no es muy frecuente en la realidad. Los modelos económicos simplifican la realidad en mayor grado que los modelos en otras ciencias, por lo cual el economista debe ser más riguroso en el tratamiento y en las conclusiones de sus análisis.

“Los modelos económicos tienen ciertas características comunes básicas:

1°. Se supone que la conducta de las variables económicas está determinada por la operación simultánea y conjunta de algunas relaciones económicas.

2°. Se supone que el modelo, a pesar de ser una simplificación de las complejidades de la realidad, captará los rasgos esenciales del sector o sistema económico estudiado.

3° Se espera que con el conocimiento del sistema proporcionado por el modelo se puedan predecir los futuros movimientos del sistema y posiblemente controlarlos para mejorar el bienestar económico”.²⁴

14.3. EJEMPLOS DE MODELOS

EJEMPLO 14.1. MODELO MACROECONOMICO: Modelo de Ingreso Nacional.

Una versión de la teoría Keynesiana de determinación de la renta podría ser la siguiente:

1° Se define el Consumo (C) como los gastos que las unidades del sector privado dedican a la compra de bienes y servicios que no se utilizarán posteriormente en la producción.

Se define Inversión (I) como los gastos realizados por las unidades productoras privadas en bienes que se utilizarán posteriormente en la producción.

Los Gastos del Gobierno (G) son aquellos realizados por el Gobierno Central, los Estados y las Municipalidades.

2° Por la identidad de la renta como ingreso, producto y gasto, se tiene $Y = C + I + G$, siendo $Y =$ Ingreso Nacional.

3° El Consumo depende del Ingreso Disponible (Y_d) definido como el Ingreso Nacional menos impuestos (T); o sea,

$$C = f(Y_d) \quad (3)$$

se puede especificar además que $0 < \frac{dC}{dY_d} < 1$; es decir, que la propensión

marginal a consumir es positiva pero menor que la unidad. Se puede especificar también la forma de la ecuación (3); su forma más simple sería que la relación es lineal

$$C = a + bY_d$$

²⁴ Johnston, J., “Econometric Methods”, International Student Edition, Mc Graw-Hill, New York, 1972, pp. 2. (Traducción del autor).

4° Tanto la Inversión como los Gastos del Gobierno son autónomos, o sea determinados por factores que no están explícitamente incorporados en la teoría; es decir, $I = I_0$ y $G = G_0$.

5° El monto de los Impuestos es proporcional al Ingreso Nacional, es decir

$$T = c Y$$

El modelo matemático representativo de esta teoría sería,

$$Y = C + I_0 + G_0$$

$$C = a + b Y_d$$

$$Y_d = Y - T$$

$$T = c Y$$

Este modelo es obviamente muy simple y no representa ni aproximadamente la compleja realidad económica. Sin embargo, se pueden construir y se han construido otros modelos de determinación del ingreso nacional, con diferentes grados de complejidad y sofisticación. A pesar de su simplicidad muestra cómo se determinarían los niveles de equilibrio del Ingreso y del Consumo, si se conocen los valores de a , b y c , para determinados niveles de inversión y del Gasto del Gobierno. Si, por ejemplo, $I_0 = 100$, $G_0 = 200$, $a = 40$, $b = 0,80$ y $c = 0,10$; se tiene, sustituyendo en la segunda ecuación del modelo;

$$Y - 300 = 40 + 0,80 (Y - 0,10Y)$$

$$(1 - 0,8 + 0,08) Y = 340$$

$$Y = 1.214,30$$

Según la cuarta ecuación:

$$T = 0,10 \times 1.214,30 = 121,43$$

Según la tercera:

$$Y_d = 1.092,87$$

Según la segunda:

$$C = 914,30$$

Un incremento del 50% en los gastos del Gobierno ($G_0 = 300$) traería como consecuencia una variación en el Ingreso, el Ingreso Disponible, el Consumo y los Impuestos cuyos nuevos niveles serían

$$Y = 1.571,43 ; T = 157,14 ; Y_d = 1.414,29 ; C = 1.171,43$$

EJEMPLO 14.2. MODELO MICROECONOMICO: Modelo de la Telaraña

El modelo de la telaraña es un modelo de mercado en el que se supone que las decisiones de producción tienen que ser adoptadas en forma anticipada debido a que el proceso de producción no es instantáneo sino que consume tiempo, tal como sucede con la mayoría de los productos agrícolas.

El ajuste del mercado sólo se realiza después de un período de tiempo; así, mientras que la demanda en un período depende del precio de ese período, la oferta depende del precio del período anterior. Por otro lado, se supone que el precio en un período se fija de tal forma que se consigue la igualdad de la demanda y oferta en el período, lo que implica, a su vez, que ningún productor queda con inventarios no vendidos y ningún consumidor queda con demanda insatisfecha. El modelo matemático representativo de este mercado será:

$$D_t = a P_t + b$$

$$S_t = A P_{t-1} + B$$

$$D_t = S_t$$

siento, D_t = Demanda en el período t ; S_t = Oferta del período t ; P_t = Precio en el período t y P_{t-1} = Precio en el período $t-1$.

A través de la técnica de ecuaciones en diferencia finita, se pueden determinar las condiciones de la oferta y la demanda de manera de llegar al equilibrio del mercado.²⁵

²⁵ Véase Alpha C. Chiang, Métodos Fundamentales de Economía Matemática. Ed. Amorrortu, pp. 521 y siguientes.

14.4. CLASIFICACION Y COMPONENTES DE LOS MODELOS ECONOMICOS MATEMATICOS

Los modelos económicos pueden ser clasificados en distintas categorías :

a) Modelos **Macroeconómicos y Microeconómicos** según que representen fenómenos económicos correspondientes a un nivel total de agregación o no.

b) Modelos **Uniecuacionales y Multiecuacionales** según contengan una o varias ecuaciones.

c) Modelos **Lineales y No-lineales**; los primeros sólo contienen ecuaciones de primer grado, los segundos contienen una o más ecuaciones de otro grado.

Los elementos de un modelo son las variables, los parámetros y las ecuaciones.

Las variables son aquellas magnitudes que en el modelo se suponen sujetas a cambio. Variables **endógenas o dependientes** son aquellas cuyos valores se determinan dentro del modelo por la interrelación simultánea de las relaciones del modelo. Variables **exógenas o independientes** son aquellas cuyos valores se determinan fuera del modelo, sus valores influyen en el modelo pero no son influidos por él.

Variables **retardadas o desfasadas** son aquellas que entran en el modelo con valores correspondientes a periodos precedentes. De especial importancia son las variables endógenas retardadas, es decir aquellas que, siendo endógenas, toman, en algunas relaciones, valores correspondientes a periodos anteriores. Tomando en cuenta este desfase en el tiempo, se pueden agrupar en una sola categoría las variables endógenas retardadas y las variables exógenas (retardadas o no). Esta nueva categoría es la de las variables predeterminadas.²⁶

En el ejemplo 14.1. son variables endógenas: Y = Ingreso Nacional, Y_d = Ingreso disponible, C = Consumo, T = Impuestos; son variables exógenas (predeterminadas) I = Inversión, G = Gastos del Gobierno.

En el ejemplo 14.2. son endógenas: D_t = Demanda en el período t , S_t = Oferta en el período t , P_t = Precio en el período t . La variable P_{t-1} = Precio en el período $t-1$ es una variable predeterminada por ser endógena desfasada.

Algunos autores llaman a las variables endógenas, variables explicadas y a las variables exógenas o predeterminadas, variables explicativas. Tal calificación no parece

²⁶ En el texto se usarán indistintamente los términos exógenas, independientes y predeterminadas.

totalmente correcta. La categoría de explicada o explicativa de una variable debe referirse al papel que juega la variable en alguna ecuación del modelo. En el ejemplo 14.1. la variable Ingreso Disponible a pesar de ser endógena es una variable explicativa en la función de consumo. Se podría generalizar afirmando que todas las variables exógenas son explicativas, mientras que las endógenas pueden ser explicativas en una ecuación o más ecuaciones y explicadas en otras.

Los **parámetros**, también llamados coeficientes, son las constantes del modelo. Estas constantes caracterizan la estructura económica del fenómeno estudiado. Aunque no siempre son conocidos, se presume que toman valores numéricos fijos en una situación observada.

En el ejemplo 14.1. los parámetros son a , b y c ; En particular b representa la conocida propensión marginal al consumo. En el ejemplo 14.2. los parámetros son a , b , A y B .

La estimación y análisis estadístico de los parámetros del modelo es el objetivo primordial del análisis econométrico.

Las **ecuaciones del modelo** son las expresiones matemáticas de las distintas relaciones entre las variables y reflejan relaciones de diferente naturaleza. La sistematización de estas relaciones ha llevado a la siguiente clasificación:

Ecuaciones de Comportamiento son aquellas que representan la conducta de los sujetos económicos. En el ejemplo 14.1. se tiene la función de consumo, $C = a + b Y_d$. En el modelo de la telaraña tanto la función de Oferta como la de Demanda son ecuaciones de comportamiento.

Ecuaciones Técnicas representan las relaciones técnicas de producción. Por ejemplo; $P = f(T, K)$, es decir la producción como función del Trabajo y del Capital; también, $C = f(Q)$, el costo como función de la cantidad producida.

Ecuaciones de Definición son una forma matemática de las definiciones que se emplean en el modelo. Por ejemplo, $Y_d = Y - T$ del ejemplo 14.1.

Ecuaciones Contables, de Balance o Identidades representan la identidad que hay entre una magnitud global y sus componentes (entre el todo y sus partes), tal sería $Y = C + I_o + G_o$.

Ecuaciones de Equilibrio reflejan las condiciones de equilibrio del modelo, tal como $D_t = S_t$ en el modelo 14.2.

Ecuaciones Institucionales suelen representar las relaciones impuestas por la ley u organismos reguladores. Como ejemplo se tiene en el modelo de determinación de la renta, la ecuación, $T = cY$.

Antes se clasificaron los modelos en lineales y no lineales dependiendo del grado de las ecuaciones que lo integraban. Es importante mencionar que la linealidad de las ecuaciones puede referirse a las variables o a los parámetros. La ecuación $Y = a + bX_1 + cX_2$ es lineal en las variables y los parámetros; la ecuación $Y = a + bX^2$ es no lineal en las variables, mientras que en la ecuación $Y = aX^b$ la no linealidad envuelve al parámetro b . Esta distinción es importante para la estimación de modelos no lineales.

Se habrá podido observar que en los ejemplos de modelos presentados, el número de variables endógenas era igual al número de ecuaciones. Si hay G variables endógenas debe haber G ecuaciones para explicar esas variables. Un modelo es **completo** cuando tiene tantas ecuaciones como variables endógenas y los valores de éstas pueden ser determinados en forma única en términos de las variables predeterminadas. Esto nos conduce a considerar los conceptos de forma estructural y forma reducida de un modelo.

14.5. FORMA ESTRUCTURAL Y FORMA REDUCIDA

Los modelos de Ingreso Nacional y de la telaraña han sido presentados en lo que se conoce como **forma estructural** del modelo. El término estructural se justifica porque es natural considerar un fenómeno económico como una estructura. Cada ecuación de la forma estructural intenta representar la conducta de algún sujeto económico, la reacción de una variable ante cambios de otras variables o alguna definición o condición de equilibrio tales como son postulados por la teoría económica sin manipulaciones algebraicas. Los efectos de un cambio en una variable predeterminada se pueden seguir a través del sistema de ecuaciones que, haciendo el papel de vasos comunicantes, llevan a determinar el efecto sobre las variables endógenas. En el modelo 14.1. al variar la inversión, varía el Ingreso Nacional, esta variación afecta a los Impuestos, y a su vez, se modifica el Ingreso Disponible y, en consecuencia el Consumo.

Las ecuaciones de la forma estructural se conocen como **ecuaciones estructurales** y los parámetros como **parámetros o coeficientes estructurales**.

Estos efectos de las variables predeterminadas sobre las endógenas se pueden precisar en forma explícita usando simplificaciones algebraicas de manera de consolidar las ecuaciones de la forma estructural en lo que se conoce como **forma reducida** del modelo que se puede definir como un conjunto de ecuaciones, obtenido de la forma estructural, tal que las variables endógenas están en función únicamente de las variables predeterminadas. Cada ecuación de la forma reducida contiene una y sólo una variable endógena y muestra explícitamente como la variable endógena correspondiente es dependiente de las variables predeterminadas.

EJEMPLO 14.3.

A partir del modelo 14.1.

$$Y = C + I_o + G_o \quad (1)$$

$$C = a + bY_d \quad (2)$$

$$Y_d = Y - T \quad (3)$$

$$T = cY \quad (4)$$

se puede obtener la forma reducida. Sustituyendo (4) en (3) se obtiene:

$$Y_d = (1 - c) Y \quad (5)$$

Sustituyendo (5) en (2), se obtiene:

$$C = a + b(1 - c) Y \quad (6)$$

Sustituyendo (6) en (1), se obtiene:

$$Y = a + b(1 - c) Y + I_o + G_o \Rightarrow$$

$$\Rightarrow Y = \frac{a}{1 - b(1 - c)} + \frac{1}{1 - b(1 - c)} I_o + \frac{1}{1 - b(1 - c)} G_o \quad (7)$$

Sustituyendo (7) en (5):

$$Y_d = \frac{a(1 - c)}{1 - b(1 - c)} + \frac{1 - c}{1 - b(1 - c)} I_o + \frac{1 - c}{1 - b(1 - c)} G_o \quad (8)$$

Sustituyendo (7) en (6):

$$C = \frac{a}{1 - b(1 - c)} + \frac{b(1 - c)}{1 - b(1 - c)} I_o + \frac{b(1 - c)}{1 - b(1 - c)} G_o \quad (9)$$

Sustituyendo (7) en (4):

$$T = \frac{ca}{1-b(1-c)} + \frac{c}{1-b(1-c)} I_o + \frac{c}{1-b(1-c)} G_o \quad (10)$$

Las ecuaciones (7) a (10) son las ecuaciones de la forma reducida.

Con los valores supuestos en el ejemplo 14.1. $I_o = 100$; $G_o = 200$; $a = 40$; $b = 0,80$; $c = 0,10$, se pueden obtener directamente los valores de las variables endógenas;

$$Y = \frac{40}{0,28} + \frac{1}{0,28} 100 + \frac{1}{0,28} 200 = 1.214,30$$

$$Y_d = \frac{36}{0,28} + \frac{0,90}{0,28} 100 + \frac{0,90}{0,28} 200 = 1.092,87$$

$$C = \frac{40}{0,28} + \frac{0,72}{0,28} 100 + \frac{0,72}{0,28} 200 = 914,30$$

$$T = \frac{4}{0,28} + \frac{0,10}{0,28} 100 + \frac{0,10}{0,28} 200 = 121,43$$

EJEMPLO 14.4.

En el modelo de la teleraña

$$D_t = a P_t + b \quad (1)$$

$$S_t = A P_{t-1} + B \quad (2)$$

$$D_t = S_t \quad (3)$$

De acuerdo a (3), se pueden igualar (1) y (2) y se tiene,

$$P_t = \frac{A}{a} P_{t-1} + \frac{B-b}{a} \quad (4)$$

Sustituyendo (4) en (1):

$$D_t = A P_{t-1} + B \quad (5)$$

Por último (2) ya está en forma reducida,

$$S_t = A P_{t-1} + B \quad (6)$$

Se puede observar que las ecuaciones de la forma reducida de la demanda y de la oferta son idénticas; esto ilustra el hecho de que las ecuaciones de la forma reducida, por ser resultado de simplificaciones algebraicas, no tienen, en general, una precisa y única interpretación económica; la forma reducida indica en forma explícita lo que le pasa a las variables endógenas cuando cambian las variables predeterminadas pero no explica el por qué de esos cambios.

Los parámetros o coeficientes de la forma reducida se conocen en la terminología económica como **multiplicadores de impacto** o simplemente **multiplicadores** porque muestran el efecto en cada variable endógena del cambio en cualquier variable predeterminada.


14.6. MODELOS ECONOMETRICOS

Los modelos económicos planteados especifican relaciones funcionales exactas entre las variables. Desde el punto de vista del análisis teórico esta supuesta exactitud es una simplificación útil. Sin embargo, cuando se trata de la verificación empírica de una hipótesis teórica para proyectar situaciones del mundo real económico o para efectos de política económica el supuesto de exactitud en las relaciones deja de ser válido. La observación más superficial de cualquier fenómeno real, macro o microeconómico, demuestra que las relaciones entre variables económicas son inexactas. Por ejemplo, no todos los individuos con un mismo nivel de ingreso, tienen el mismo consumo; dado un precio no siempre las cantidades demandadas de un bien son idénticas.

Las relaciones exactas postuladas por la teoría se mantienen en términos de promedios, pero los comportamientos individuales observados en la vida real se desvían de esos promedios. El punto de partida del análisis econométrico es precisamente tomar en cuenta este hecho introduciendo en los modelos matemáticos elementos probabilísticos.


Según este punto de vista, en las relaciones entre las variables económicas se pueden distinguir dos partes o componentes: Una sistemática que expresa la relación exacta y es susceptible de ser manejada teóricamente en forma sencilla. Otra parte no sistemática, aleatoria, que proporciona un vínculo entre lo que afirma la teoría y lo que sucede en la realidad.

Una relación entre el precio y la cantidad demandada, gráficamente se podría representar así:



Según estos datos a cada nivel de precios corresponde una cantidad demandada única, la naturaleza de la relación entre el precio y la cantidad demandada se determina fácilmente y la expresión analítica de la función es precisa.

Esta situación es excepcional en el estudio de los fenómenos económicos; los datos aparecerán en el gráfico en un diagrama disperso que aunque hace presumir la existencia de una relación, no permite visualizarla claramente, tal como se muestra en el gráfico.



Estas observaciones muestran la existencia de una relación entre el precio y las cantidades, pero obviamente no es una relación determinística o exacta sino una relación estocástica (probabilística); es decir, para cada valor del precio hay un conjunto de valores de la demanda que obedecen a una determinada distribución de probabilidades.

La existencia de estas relaciones inexactas se puede justificar por varias causas. En primer lugar la falta de precisión de las estadísticas económicas; aunque la relación exacta existiese en la realidad, los datos reales usados para medir las variables no representan exactamente a las mismas. En segundo lugar, la teoría económica no incluye, ni puede incluir, todos y cada uno de los factores que pueden influir en un fenómeno económico. Si todas las variables fuesen incluidas la relación sería exacta. Sin embargo, la inclusión de todos los factores es imposible no sólo por la complejidad de la relación que le quitaría cualquier utilidad, sino también porque en algunos casos, incluso los factores no son cuantitativos, no son mensurables; además, la dificultad de experimentación en economía, mencionada anteriormente, no permite considerar aisladamente el efecto de uno o algunos factores. En tercer lugar, aun suponiendo que se incluyen todas las variables explicativas relevantes, la intrínseca indeterminación y libertad del comportamiento humano establece necesariamente diferencias individuales en la conducta de los sujetos económicos.

Los modelos econométricos se caracterizan por la introducción de elementos probabilísticos para tomar en cuenta los factores que se suponen pequeños o accidentales que no se han incluido explícitamente en los modelos matemáticos.

Se podría definir un modelo econométrico como un modelo económico matemático en el que se introducen variables aleatorias.

Los términos aleatorios introducidos en las ecuaciones de un modelo econométrico se conocen como **términos de perturbación o error**.

El modelo matemático 14.1. se convierte en econométrico así:

$$Y = C + I_o + G_o$$

$$C = a + b Y_d + u_1$$

$$Y_d = Y - T$$

$$T = cY + u_2$$

siendo u_1 y u_2 los términos de perturbación de la función de consumo y de la función de impuestos respectivamente.

Una explicación más profunda de la naturaleza y características de los términos de perturbación se verá en la sección 14.9.

14.7. UTILIDAD DE LOS MODELOS

En la sección anterior se destacó el hecho de la inexactitud de las relaciones entre variables económicas. Las razones de esta situación, ya mencionadas, podrían llevar a la

posición extrema de descartar el uso de los modelos como instrumentos de análisis en la Ciencia Económica. Los modelos económicos, en general, y econométricos, en particular, han sido criticados frecuentemente como no realísticos. Esta crítica ha recaído hacia el uso de cualquier instrumento matemático en el estudio de los fenómenos económicos y se ha basado en la aparente imposibilidad de representar reacciones humanas en un sistema de ecuaciones.

Si bien es cierto que la Economía es una ciencia social y, por lo tanto, sujeta a la indeterminación de la conducta humana, también lo es, que una parte importante de los fenómenos económicos son de naturaleza cuantitativa; precios, costos, ingresos, liquidez monetaria, tipo de cambio, importaciones, exportaciones, impuestos, etc. son magnitudes cuantitativas perfecta o imperfectamente mensurables y sujetas a relaciones contrastables empíricamente.

Por otro lado, el objeto del estudio de la economía, no es la determinación exacta del comportamiento de un individuo en particular, sino la conducta general de las comunidades la cual, en principio, es predecible. Como ilustración, al subir el precio de un bien normal, puede haber personas que demanden más cantidad, pero el comportamiento general será racional y la demanda de ese bien, disminuirá en términos globales.

Más aún, la crítica en esa dirección, si se acepta, no debería particularizarse a los modelos matemáticos o econométricos, sino que, si se quiere ser consistente, debería estar dirigida a la economía como ciencia. La Teoría Económica, expresión de la ciencia económica, y base de la política económica, es, por su propia naturaleza, una abstracción del mundo real. Por ejemplo, la teoría de la empresa en el mercado de competencia imperfecta, no es realística, ya sea expresada en términos verbales o mediante un modelo matemático.

Todo modelo, por definición, es irreal, porque su propósito no es describir la realidad con todos sus detalles; tal descripción sería inmanejable e inoperante. Su misión es reducir los aspectos más relevantes de esa realidad a expresiones manejables y suficientemente simples con el objetivo de tomar decisiones y controlarlas. Los modelos constituyen marcos útiles con los que el economista puede, en muchos casos, analizar, comprender y proyectar más eficientemente los fenómenos económicos.

Hablando en términos estadísticos, no se ha podido establecer una correlación entre la complejidad de un modelo y su utilidad. Toda teoría, todo modelo, deja de tomar en cuenta ciertos aspectos reales del fenómeno en estudio. Para juzgar si un modelo es bueno o malo, el criterio adecuado no es determinar si es realístico en todos sus supuestos o detalles, sino analizar el grado en que sirve como instrumento para alcanzar el objetivo para lo cual ha sido construido. Un modelo no necesita ser realístico en todos sus supuestos, lo que importa es que lo sea razonablemente en sus supuestos básicos o cruciales, es decir aquellos a los cuales son muy sensitivas las conclusiones que se derivan del modelo.

La simplificación es necesaria en la construcción de cualquier teoría o modelo representativo de la misma. "Los modelos de una u otra forma son deficientes, con simplificaciones estratégicas. No es importante preguntarse si los supuestos son simplificaciones, lo que hay que preguntar es si estas simplificaciones son útiles o seriamente desorientadoras".²⁷

Por último cabe mencionar el hecho de que ciencias más sociales y menos cuantitativas que la economía, como la Psicología y la Sociología, están usando con éxito mediante la Psicometría y la Sociometría, modelos matemáticos y estadísticos en el análisis de la conducta general de las sociedades, grupos e individuos.

Lo que sí se debe criticar es la tendencia a considerar las matemáticas y estadística como un fin y no como un medio, lo que puede llevar a adoptar supuestos económicos inadecuados en función de conveniencias estadísticas o matemáticas y también a la construcción y desarrollo de modelos econométricos como un juego que proporciona un puro placer intelectual.

14.8. LA ECONOMETRIA EN ACCION

La relevancia o validez de las hipótesis de conducta reflejadas en los modelos económicos debe ser contrastada con evidencia empírica mediante rigurosas pruebas estadísticas aplicadas a los modelos econométricos. Con esta confrontación de la teoría con el mundo real la econometría puede, en principio, determinar el éxito de un modelo, la relevancia de una teoría y ayudar a formular teorías y modelos mejores.

La ciencia económica progresa a través del desarrollo de teorías susceptibles de verificación empírica, el contraste de teorías existentes para determinar su relevancia y la sustitución de teorías existentes inadecuadas por otras mejores.

Las técnicas econométricas sirven para confrontar modelos económicos con datos del mundo real; el objetivo esencial de la econometría es la estimación y contraste de los modelos económicos. Con su ayuda, determinada teoría económica puede considerarse como inadecuada o inaplicable en una situación particular. Si bien la econometría no puede probar la veracidad o falsedad de una teoría, puede mostrarla como consistente o inconsistente con la realidad y darle mayor profundidad y utilidad consiguiendo valores numéricos para los parámetros del modelo que permitan la mejor proyección y control de las variables económicas y hagan más eficaz la política económica.

Un estudio econométrico se desarrolla en una secuencia de pasos concretos:

²⁷ Kane, Edward J.; "Economic Statistics & Econometrics", Harper & Row, Publishers. N. Y. 1968. pp. 35 (Traducción del autor).

1° Determinación de los objetivos del estudio

Se deben establecer claramente los objetivos del estudio, revisar la teoría relevante para concretar el marco teórico apropiado que conduzca a la formulación de hipótesis sobre las relaciones de las variables importantes en el estudio.

2° Especificación del modelo

Las hipótesis de conducta determinadas en el paso anterior deben encontrar una precisa formulación en términos matemáticos. Se escogerá la forma funcional de las ecuaciones a usarse y las características del término de perturbación o error en las ecuaciones. Estas deben ser en primer lugar suficientemente simples para que se entienda su significado y puedan, al mismo tiempo, manejarse con relativa facilidad; en segundo lugar, deben ser consistentes con la teoría económica y las hipótesis que tratan de representar.

3° Recolección de Información

Se deben buscar y analizar los datos disponibles de las variables, revisar si corresponden a las variables definidas y determinar la necesidad o no de recolectar directamente información adicional.

Los datos usados en los estudios econométricos se suelen clasificar en dos tipos: (a) **Series cronológicas**, basados en datos provenientes de la misma unidad económica para distintos períodos de tiempo; generalmente están asociadas a la medición de variables macroeconómicas usando datos publicados de estadísticas económicas; (b) **Series de corte transversal (cross-section)**, basadas en datos provenientes de diferentes entidades económicas en el mismo período de tiempo; generalmente son resultado de encuestas que proporcionan información directa de las características económicas de unidades microeconómicas.

4° Identificación del modelo

En los modelos multiccuacionales hay que determinar, como un paso previo a la estimación de los parámetros de una ecuación dada, si es posible estimarla. Es frecuente que en un modelo en forma estructural algunas ecuaciones sean estadísticamente idénticas y al proceder a la estimación no se sepa cual de ellas se está estimando. Si una ecuación está identificada se puede proceder a su estimación con la seguridad de que se está estimando esa y no otra o una combinación híbrida derivada de dos o más ecuaciones de la forma estructural. El problema de identificación es un problema econométrico muy importante que debe ser estudiado en conexión con los modelos multiccuacionales.

5° Estimación

El siguiente paso es usar los datos de las variables para estimar los parámetros del modelo mediante métodos estadísticos apropiados. Como se verá más adelante, el método

de mínimos cuadrados es ampliamente usado en la estimación de los modelos econométricos; sin embargo, los problemas característicos de los modelos económicos han llevado al desarrollo y aplicación de otros métodos de estimación.

6° Evaluación del modelo

Una vez estimados los parámetros del modelo, hay que verificar si las hipótesis teóricas postuladas por el mismo son respaldadas por la evidencia empírica disponible. Criterios tales como la consistencia de los signos y magnitudes de los estimadores, la bondad del ajuste de las ecuaciones, la habilidad de proyección, etc. son utilizables para determinar si el modelo constituye un retrato suficientemente aceptable del fenómeno estudiado o si una diferente especificación debe ser formulada. En este último caso, se debe proceder a la

7° Reformulación del modelo

A la luz de los resultados proporcionados por la evidencia empírica es posible que sea necesaria la reformulación de las hipótesis teóricas. Existe, en la práctica, una realimentación entre la teoría económica y la econometría. Esta le da contenido empírico a la primera y ha tenido un papel importante en la construcción de la teoría económica.

14.9. EL MODELO DE REGRESIÓN SIMPLE

Se mencionó anteriormente que la característica diferencial de los modelos econométricos es la introducción de los términos de perturbación.

En la sección 14.6. se justificó la introducción del término de perturbación; en esta sección se pretende, con la ayuda del modelo lineal de dos variables analizar la especificación de las características del término de perturbación.

El modelo de dos variables tiene la importancia fundamental de que puede ser ilustrado gráficamente en dos dimensiones lo que es de gran ayuda para visualizar la naturaleza del término de perturbación.

Supongamos que estamos interesados en estudiar la relación entre los gastos de consumo y el ingreso disponible en una determinada población. Supongamos también que la relación es lineal y más aún que conocemos los datos de las variables para toda la población.

Si la relación fuese exacta o determinística, a cada valor de la variable independiente, ingreso disponible (X), correspondería un único valor de la variable dependiente, consumo (Y) y la relación entre ellas estaría representada por la ecuación

$$Y_i = a + bX_i$$

siendo a y b los parámetros de la relación poblacional.


Los datos de la tabla proveen un ejemplo de tal relación exacta.

Ingreso Disponible (X)	Consumo (Y)	Número de familias
100	80	5
140	108	8
180	136	7
200	150	3
220	164	4
260	192	3

Los datos corresponden a una población hipotética de 30 familias, en la cual todas las familias con el mismo ingreso tienen el mismo consumo. El valor de los parámetros a y b es fácilmente obtenido con las técnicas de la geometría analítica


$$Y_i = 10 + 0,70X_i$$

La ilustración gráfica de esta situación se presenta en el gráfico.



Como se dijo anteriormente esta relación exacta no se da en la realidad; lo lógico es que no todas las familias con el mismo ingreso tengan idéntico consumo. Más plausible sería una situación como la reflejada en la tabla y el gráfico que siguen, según los cuales familias con el mismo ingreso tienen distintos niveles de consumo.

Ingreso Disponible (X)	Consumo (Y)								E (Y)
100	80	85	75	95	65				80
140	103	106	108	110	113	100	116	108	108
180	132	136	140	115	157	135	137		136
200	148	150	152						150
220	164	162	164	166					164
260	184	192	200						192



Los datos anteriores muestran que aún existiendo una relación exacta entre el ingreso disponible y el consumo promedio, los valores individuales de la variable dependiente difieren del valor promedio, dado en la última columna de la tabla.

Los valores promedios de la variable Y aparecen en el gráfico sobre una línea recta con pendiente positiva indicando que los valores esperados de Y aumentan al aumentar X. Esta línea, recta en este hipotético ejemplo, pero con otras posibles formas analíticas, se conoce como **curva de regresión**, que es simplemente el lugar geométrico de los valores esperados de la variable dependiente para los valores fijos de la variable independiente. El término regresión se debe a Francis Galton y el análisis de regresión trata de estimar el valor esperado poblacional de una variable dependiente dados valores de una o más variables explicativas del comportamiento de la primera.

La expresión analítica de esta curva de regresión poblacional, en el ejemplo, es,

$$E(Y_i/X_i) = a + b X_i$$

siendo $E(Y_i/X_i)$ el valor esperado condicional de Y dado X_i ; en forma más simple, siendo X dada, se tiene,

$$E(Y_i) = a + b X_i \quad (1)$$

Obviamente, si se conocen todos los valores poblacionales, como en el ejemplo, es fácil, como antes, determinar los valores de a y b que en este caso son los mismos, $a = 10$, $b = 0,70$.

Las diferencias individuales con respecto al comportamiento promedio son tomadas en cuenta por el término de perturbación, que sería simplemente igual al valor observado de la variable (Y_i) menos el valor hipotético (promedio) que vendría dado por la relación (1).

El modelo econométrico representativo de la relación entre las dos variables sería entonces,

$$Y_i = a + b X_i + u_i$$

El subíndice i se refiere al i-ésimo elemento de la población.

El término de perturbación u_i es una variable aleatoria que toma valores de acuerdo a una determinada distribución de probabilidades y que representa todos aquellos factores no tomados en cuenta explícitamente en el componente sistemático de la ecuación.

Es preciso notar que la aleatoriedad del término de perturbación implica, a su vez, la naturaleza estocástica de la variable dependiente; esto significa simplemente que, dado un valor de la variable o variables explicativas, la variable dependiente no toma un valor fijo sino valores diferentes con ciertas probabilidades.

Es evidente que en la realidad no se conocen todos los elementos poblacionales por lo que los parámetros poblacionales a y b no pueden ser determinados exactamente como

se hizo antes, sino estimados según alguna técnica estadística por medio de muestras. Es decir, no es posible obtener la línea de regresión poblacional sino estimarla con una línea de regresión muestral.

Para que el modelo econométrico sea operativo, puesto el término de perturbación (u_i) no es observable y puesto que la variable dependiente es una función de la variable explicativa y del término de perturbación, es necesario especificar las características de la variable explicativa y de la distribución de probabilidades de la variable u_i . Esta especificación está contenida en lo que se conoce como *supuestos básicos* del modelo de regresión lineal.

Supuesto 1

La variable explicativa es fija o determinística. El concepto determinístico se usa aquí en contraste directo con el término aleatorio para indicar que los valores de la variable independiente son fijos, conocidos o controlables, que no cambian de muestra a muestra, es decir que son independientes del muestreo, lo que equivale a suponer que unos valores de C, previamente elegidos (en nuestro ejemplo ciertos niveles de ingreso) se dejan invariables en el muestreo.

Además se requiere que $\frac{\sum (X_i - \bar{X})^2}{n}$ sea un número finito diferente de cero,

siendo $\bar{X}$ la media de los valores de X y n el número de observaciones, lo que implica que los valores de X en la muestra no sean todos iguales. La razón de esto es obvia: si los valores de X fueran todos iguales a un mismo número no se podría determinar la variación en la variable dependiente relacionada con *variaciones* en la variable independiente X.

Supuesto 2

El término de perturbación u_i es una variable aleatoria normalmente distribuida. El supuesto de normalidad se justifica en el sentido de que u_i representa la suma de un gran número de pequeños e independientes factores, por lo que parece apropiada la aplicación del Teorema del Límite Central. Este supuesto implica a su vez que la variable dependiente Y_i es también normal por ser una función lineal de u_i .

Supuesto 3

El valor esperado del término de perturbación es cero:

$$E(u_i) = 0 \quad \forall i$$

Según este supuesto la variable u_i puede tomar valores positivos o negativos pero en promedio es cero para cada observación, lo que implica una relación exacta en términos de promedio entre "Y" y "X", puesto que

$$(1) E(Y_i) = E[a + bX_i + u_i] = a + bX_i + E(u_i) = a + bX_i$$

en otras palabras, para cada valor de X , los valores de Y están distribuidos normalmente alrededor de su valor medio que sería un punto en la recta de regresión poblacional.

Supuesto 4


$$\text{Var}(u_i) = E[u_i - E(u_i)]^2 = E(u_i)^2 = \sigma^2 \quad \forall i$$

Es decir la varianza de los términos de perturbación es finita e igual para todas las observaciones. Este supuesto, conocido como **homocedasticidad**, significa que cualquiera que sea el valor de X , la dispersión de los posibles valores del término de perturbación, alrededor de su media cero, es la misma. Se puede observar que la varianza de Y_i también es σ^2 .

En efecto,

$$\text{Var}(Y_i) = E[Y_i - E(Y_i)]^2 = E[a + bX_i + u_i - (a + bX_i)]^2 = E(u_i)^2 = \sigma^2$$

Gráficamente, el supuesto de homocedasticidad se puede presentar tal como se observa en el gráfico.




En el ejemplo este supuesto significa que la variabilidad del consumo es igual para todos los niveles de ingreso.

Hay casos en los que este supuesto no es aceptable, es decir, la varianza de u_i es diferente para distintos valores de X ; por ejemplo, aumenta al aumentar X ; el caso de varianza distinta se conoce como **heterocedasticidad**,

$$\text{Var}(u_i) = \sigma_i^2$$

Gráficamente, la situación de mayor varianza para valores mayores de X , se representaría así:



Supuesto 5

Los términos de perturbación no están correlacionados entre sí, es decir

$$\text{Cov}(u_i, u_j) = E\{[u_i - E(u_i)][u_j - E(u_j)]\} = E(u_i \cdot u_j) = 0 \quad \text{para } i \neq j$$

El supuesto de no correlación significa que un valor grande (pequeño) de una perturbación i no conlleva un valor grande (pequeño) de otra perturbación j .

Haciendo uso del supuesto de normalidad, la no correlación de los términos de perturbación, implica también que son variables aleatorias independientes.

En términos de la variable dependiente, se puede expresar este supuesto así:

$$\text{Cov}(Y_i, Y_j) = 0 \text{ para } i \neq j$$

Supuesto 6

$$\text{Cov}(u_i, X_i) = 0 \quad \forall i$$

Según este supuesto, el término de perturbación u y la variable explicativa X no están correlacionadas, es decir que los valores de u son independientes de los valores de X .

El modelo de regresión simple se podría resumir así:

$$Y_i = a + bX_i + u_i$$

$$E(u_i) = 0 \quad E(u_i \cdot u_j) = \begin{cases} \sigma^2 & i = j \\ 0 & i \neq j \end{cases}$$

El objetivo será estimar, a partir de n observaciones o datos muestrales de las variables X e Y , los parámetros poblacionales a , b y σ^2 , en otras palabras, estimar la línea de regresión poblacional desconocida.

Con técnicas estadísticas apropiadas se obtiene una **línea de regresión estimada**, llamada también **línea de regresión muestral**,

$$\hat{Y}_i = \hat{a} + \hat{b}X_i$$

siendo $\hat{a}$, $\hat{b}$ los estimadores de a y b ; $\hat{Y}_i$ el valor estimado o ajustado de Y_i .

La diferencia entre el valor real Y_i y el valor estimado $\hat{Y}_i$ se conoce como residuo (e_i).


$$e_i = Y_i - \hat{Y}_i$$

y no debe confundirse con u_i . El término de perturbación u_i es la diferencia entre el valor real Y_i y el valor medio o teórico $E(Y_i)$ que nos daría la relación exacta.

$$u_i = Y_i - E(Y_i)$$

Mientras que e_i es la diferencia entre el valor real (Y_i) y el valor estimado ($\hat{Y}_i$).

La diferencia puede ilustrarse gráficamente:



Si la relación entre X e Y fuese exacta, si no existiesen otros factores influyendo en la variable dependiente, dado un valor de X , X_i , el valor correspondiente de Y , sería el dado por la línea teórica de regresión $E(Y_i)$. El valor observado, real de Y es Y_i , y la diferencia la llamamos perturbación (u_i). Al hacer la estimación no se obtiene la recta de regresión poblacional sino una recta estimada, y el valor estimado de Y para X_i está dado por $\hat{Y}_i$. La diferencia entre el valor real y el valor estimado es el residuo e_i .

En el siguiente capítulo se desarrollarán los métodos de estimación bajo los supuestos mencionados.

EJERCICIOS PROPUESTOS

14.1 Determinar razonadamente la veracidad o falsedad de las siguientes afirmaciones:

- Con un modelo econométrico se puede probar que una teoría económica es verdadera.
- Un modelo económico es completo si contiene por lo menos una ecuación de cada clase.
- El supuesto de homocedasticidad implica que los factores no especificados explícitamente en la ecuación y que influyen en la variable dependiente son los mismos para cada conjunto de observaciones.

- (e) Un modelo econométrico debe contener tantas ecuaciones como variables endógenas,
- (f) Una variable explicada en una ecuación puede ser explicativa en otra.
- (g) El supuesto de que el valor esperado del término de perturbación es cero, se puede expresar así $\sum_{i=1}^n u_i / n = 0$ siendo n el número de datos.

14.2. En los siguientes modelos, determine cuáles son las variables endógenas y las predeterminadas, el tipo de ecuación y halle la forma reducida.

(a) $C = a + b Y$

$$I = d + c r$$

$$Y = C + I + G$$

siendo C = Consumo, Y = Ingreso, I = Inversión, r = Tipo de interés, G = Gastos del Gobierno.

(b) $C = \alpha_1 + \alpha_2 Y_d + u_1$

$$I = \beta_1 + \beta_2 Y + u_2$$

$$M = \delta_1 + \delta_2 Y + u_3$$

$$Y_d = Y - T + R$$

$$Y = C + I + G + X - M$$

siendo C = Consumo; Y_d = Ingreso Disponible; I = Inversión; Y = Ingreso Nacional; M = Importaciones; R = Subsidios; G = Gastos del Gobierno; X = Exportaciones, T = Impuestos.

(c) $C_t = \alpha_1 + \alpha_2 D_t + u_{1t}$

$$I_t = \beta_1 + \beta_2 Y_t + \beta_3 Y_{t-1} + u_{2t}$$

$$Y_t = D_t - T_t$$

$$Y_t = C_t + I_t + G_t$$

siendo C_t = Consumo en el período t; D_t = Producto nacional a precios de mercado en el período t; Y_t = Producto Nacional a costo de factores en el

período t; Y_{t-1} = Producto Nacional a costo de factores en el período t - 1;
 I_t = Inversión en el período t; G_t = Gastos del Gobierno en el período t;
 T_t = impuestos Indirectos.

14.3. Hallar la forma reducida en los siguientes modelos:

(a) $Y_{1i} = \beta_{12} Y_{2i} + \gamma_{11} + u_{1i}$

$$Y_{2i} = \gamma_{21} + \gamma_{22} X_i + u_{2i}$$

Variables endógenas, Y_1, Y_2 ; Variable exógena, X.

(b) $Y_{1i} + \beta_{12} Y_{2i} + \gamma_{11} X_i = u_{1i}$

$$\beta_{21} Y_{1i} + Y_{2i} + \gamma_{22} X_i = u_{2i}$$

Variables endógenas, Y_1, Y_2 ; Variables exógenas, X_1, X_2 .

CAPITULO XV

MODELO LINEAL GENERAL

15.1. INTRODUCCION

Aparentemente el paso lógico siguiente sería exponer las técnicas de estimación del modelo con que se concluyó el capítulo anterior; es decir, el modelo lineal de dos variables; la mayoría de los textos de Econometría así lo hacen. Sin embargo, en este texto se procederá de inmediato al análisis del modelo uniecuacional lineal con cualquier número de variables exógenas, conocido en la literatura estadística y econométrica como “Modelo Lineal General” o “Modelo de Regresión Múltiple”.

Dos razones justifican este camino; en primer lugar, los resultados del modelo general son perfectamente aplicables al modelo de dos variables; en segundo lugar, el uso del álgebra matricial simplifica sustancialmente las demostraciones matemáticas necesarias que en el modelo de dos variables, sin la notación matricial, son sumamente engorrosas y obstaculizan una clara visión del objetivo que se persigue.

A medida que se obtengan los resultados del modelo general se hará referencia a los resultados similares del modelo de dos variables. Asimismo cuando se requiera visualizar gráficamente alguno de los conceptos expuestos se acudirá al modelo de dos variables.

15.2. EL MODELO DE REGRESION

En el modelo clásico de regresión lineal el valor de una variable aleatoria observable Y se hace depender linealmente de $k-1$ variables no aleatorias observables y de una variable aleatoria no observable.

El modelo es:

$$(1) \quad Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + \dots + \beta_k X_{ki} + u_i; \quad i = 1, 2, \dots, n$$

en el cual la variable endógena o dependiente Y es explicada como una función lineal de $k-1$ variables exógenas o predeterminadas $X_2, X_3, \dots, X_k$ y del término de perturbación u_i .

Se mantienen los supuestos básicos del modelo lineal; es decir, las variables explicativas son determinísticas, el término de perturbación es una variable aleatoria normal con media cero y varianza finita e igual para cada observación, los términos de perturbación no están correlacionados entre sí, ni con las variables explicativas.

Como antes, se tiene:

$$E(Y_i) = \beta_1 + \beta_2 X_{2i} + \dots + \beta_k X_{ki}$$

Parece conveniente interpretar los coeficientes de la regresión:

β_1 es la ordenada en el origen, es decir el valor esperado de Y_i cuando todas las variables explicativas son iguales a cero.

Cada coeficiente β_j ($j = 2, \dots, k$) representa el cambio esperado en la variable dependiente debido a un cambio unitario en la variable explicativa X_j , permaneciendo constantes todas las demás variables explicativas.

Por ejemplo, en una ecuación de demanda si se hace depender la cantidad demandada (Y_i) del precio (X_{2i}) y del ingreso per cápita (X_{3i}), el modelo sería

$$Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + u_i$$

β_2 representa la variación esperada en la cantidad demandada ante una variación unitaria del precio permaneciendo constante el ingreso per cápita.

(Se deja al lector la interpretación del coeficiente β_3).

Además es necesario especificar dos supuestos o condiciones adicionales: El número de observaciones debe ser mayor que el número de parámetros a estimar ($n > k$)

y no debe existir ninguna relación lineal exacta entre las variables explicativas. La necesidad de estos supuestos se verá más adelante.

Se dispone de n datos u observaciones de cada una de variables:

$$\begin{array}{ccccccc} Y_1 & X_{21} & X_{31} & \dots & X_{k1} \\ Y_2 & X_{22} & X_{32} & \dots & X_{k2} \\ \vdots & \vdots & \vdots & \dots & \vdots \\ Y_n & X_{2n} & X_{3n} & \dots & X_{kn} \end{array}$$

que se usarán para la estimación de los coeficientes β_j ($j = 1, \dots, k$) y σ^2 (varianza del término de perturbación).

La expresión (1) representa n ecuaciones (una para cada conjunto de observaciones); es decir:

$$Y_1 = \beta_1 + \beta_2 X_{21} + \beta_3 X_{31} + \dots + \beta_k X_{k1} + u_1$$

$$Y_2 = \beta_1 + \beta_2 X_{22} + \beta_3 X_{32} + \dots + \beta_k X_{k2} + u_2$$

$$\vdots$$

$$Y_n = \beta_1 + \beta_2 X_{2n} + \beta_3 X_{3n} + \dots + \beta_k X_{kn} + u_n$$

Estas n ecuaciones se pueden expresar en forma matricial así:

$$Y = X\beta + u$$

Siendo,

$$Y = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix} \quad X = \begin{pmatrix} 1 & X_{21} & X_{31} & \dots & X_{k1} \\ 1 & X_{22} & X_{32} & \dots & X_{k2} \\ \vdots & \vdots & \vdots & \dots & \vdots \\ 1 & X_{2n} & X_{3n} & \dots & X_{kn} \end{pmatrix}$$

$$\beta = \begin{pmatrix} \beta_1 \\ \beta_2 \\ . \\ . \\ . \\ \beta_n \end{pmatrix} \quad u = \begin{pmatrix} u_1 \\ u_2 \\ . \\ . \\ . \\ u_n \end{pmatrix}$$

o sea, Y es un vector columna ($n \times 1$) cuyos elementos son las observaciones de la variable dependiente; X es una matriz ($n \times k$) con la primera columna de unos y las otras columnas con las observaciones de cada una de las $k - 1$ variables exógenas; β es un vector columna ($k \times 1$) cuyos elementos son los coeficientes o parámetros del modelo y u es un vector columna ($n \times 1$) cuyos elementos son los términos de perturbación.

Para poder expresar los supuestos del modelo, se define $E(A)$, (siendo A una matriz), como una matriz cuyos elementos son los valores esperados de los elementos de A . En consecuencia los supuestos del modelo expresados en notación matricial serían:

$$E(u) = 0 \quad E(u u') = \sigma^2 I$$

siendo I la matriz identidad de orden n .

en efecto, $E(u) = 0 \Rightarrow E(u_i) = 0 \quad \forall i$, porque

$$E(u) = E \begin{pmatrix} u_1 \\ u_2 \\ . \\ . \\ . \\ u_n \end{pmatrix} = \begin{pmatrix} E(u_1) \\ E(u_2) \\ . \\ . \\ . \\ E(u_n) \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ . \\ . \\ . \\ 0 \end{pmatrix}$$

$$\text{Por otro lado, } E(u u') = \sigma^2 I \Rightarrow E(u_i u_j) = \begin{cases} \sigma^2 & i = j \\ 0 & i \neq j \end{cases}$$

en efecto,

$$E(u u') = E \begin{pmatrix} u_1 \\ u_2 \\ . \\ . \\ . \\ u_n \end{pmatrix} (u_1 \ u_2 \ \dots \ u_n) = E \begin{pmatrix} u_1^2 & u_1 u_2 & \dots & u_1 u_n \\ u_2 u_1 & u_2^2 & \dots & u_2 u_n \\ . & . & \dots & . \\ . & . & \dots & . \\ . & . & \dots & . \\ u_n u_1 & u_n u_2 & \dots & u_n^2 \end{pmatrix}$$

En esta matriz los elementos de la diagonal principal son las varianzas de los términos de perturbación y el resto de los elementos son las covarianzas.

Además,

$$\sigma^2 I = \begin{pmatrix} \sigma^2 & 0 & \dots & 0 \\ 0 & \sigma^2 & \dots & 0 \\ . & . & \dots & . \\ . & . & \dots & . \\ 0 & 0 & \dots & \sigma^2 \end{pmatrix}$$

y al afirmar que $E(u u') = \sigma^2 I$, se está afirmando que

$$\text{Var}(u_i) = E(u_i^2) = \sigma^2 \quad \forall i \text{ y que } \text{Cov}(u_i u_j) = E(u_i u_j) = 0$$

La matriz $E(u u')$ se conoce como matriz de varianzas y covarianzas del término de perturbación y se suele expresar con la notación $\text{Var}(u)$. En general, cualquier matriz en la cual los elementos de la diagonal principal son las varianzas de una serie de variables y el resto de los elementos son las covarianzas, se denomina matriz de varianzas y covarianzas.

Nótese que es una matriz simétrica puesto que $\text{Cov}(X_i, X_j) = \text{Cov}(X_j, X_i)$.

En resumen, el modelo general en notación matricial es:

$$(2) \quad Y = X\beta + u$$

$$(3) \quad E(u) = 0$$

$$(4) \quad \text{Var}(u) = \sigma^2 I$$

15.3. ESTIMACION DEL MODELO

Nos enfrentamos al problema de estimar los parámetros desconocidos del modelo, que son los coeficientes $\beta_1, \beta_2, \dots, \beta_k$ y σ^2 . Se utilizará el método de "mínimos cuadrados directos u ordinarios". El calificativo de directos u ordinarios se agrega para diferenciarlo de otros métodos de mínimos cuadrados que se usan para estimar los parámetros de los sistemas multiecuacionales. Como se sabe, los estimadores mínimo-cuadráticos son aquellos que minimizan la suma de los cuadrados de las diferencias entre los valores reales y los valores estimados de la variable dependiente.

Si se designa el estimador de β_j (para $j = 1, 2, \dots, k$) como $\hat{\beta}_j$, los valores estimados de la variable Y serán:

$$\hat{Y}_i = \hat{\beta}_1 + \hat{\beta}_2 X_{2i} + \dots + \hat{\beta}_k X_{ki}$$

y en notación matricial,

$$(5) \quad \hat{Y} = X\hat{\beta}$$

siendo,

$\hat{Y}$ un vector columna ($n \times 1$) cuyos elementos son los valores estimados de la variable dependiente, y $\hat{\beta}$ un vector columna ($k \times 1$) cuyos elementos son los estimadores de los coeficientes del modelo; es decir,

$$\hat{Y} = \begin{pmatrix} \hat{Y}_1 \\ \hat{Y}_2 \\ \vdots \\ \hat{Y}_n \end{pmatrix} \quad \hat{\beta} = \begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \\ \vdots \\ \hat{\beta}_k \end{pmatrix}$$

Definamos e como un vector columna ($n \times 1$) cuyos elementos son los residuos, es decir las diferencias entre los valores reales y estimados de la variable Y .

$$e = \begin{pmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{pmatrix} = \begin{pmatrix} Y_1 - \hat{Y}_1 \\ Y_2 - \hat{Y}_2 \\ \vdots \\ Y_n - \hat{Y}_n \end{pmatrix} = Y - \hat{Y}$$

Se trata de minimizar la suma de los cuadrados de los residuos, o sea de minimizar $e'e$. En efecto,

$$e'e = (e_1 e_2 \dots e_n) \begin{pmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{pmatrix} = e_1^2 + e_2^2 + \dots + e_n^2$$

Desarrollando $e'e$ se tiene

$$\begin{aligned} e'e &= (Y' - Y')'(Y - \hat{Y}) = (Y - X\hat{\beta})'(Y - X\hat{\beta}) = \\ &= (Y' - \hat{\beta}'X') (Y - X\hat{\beta}) = Y'Y - Y'X\hat{\beta} - \hat{\beta}'X'Y + \hat{\beta}'X'X\hat{\beta} \end{aligned}$$

El segundo y el tercer término son iguales puesto que $Y'X\hat{\beta}$ es de orden 1×1 y $\hat{\beta}'X'Y$ es su traspuesta; o sea,

$$e'e = Y'Y - 2Y'X\hat{\beta} + \hat{\beta}'X'X\hat{\beta}$$

Para minimizar una función de varias variables, en este caso $e'e$ función de $\hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_k$ la condición de primer orden es que las derivadas parciales sean iguales a cero. En forma matricial,

$$\frac{\partial e'e}{\partial \hat{\beta}} = 2X'Y + 2X'X\hat{\beta} = 0 \Rightarrow$$

$$(6) \Rightarrow X'X\hat{\beta} = X'Y$$

Premultiplicando por la inversa de $X'X$ se tiene

$$(7) \quad \hat{\beta} = (X'X)^{-1} X'Y$$

Se comprende ahora la necesidad de los supuestos adicionales mencionados anteriormente: para hallar los estimadores mínimo cuadráticos es necesario hallar la inversa de la matriz $X'X$, esta matriz cuadrada de orden k debe ser no singular, o sea su rango debe ser k . Para que se cumpla esta condición, el rango de la matriz X debe ser k . Al ser k el número de columnas de la matriz X , para que su rango sea k deben darse dos condiciones: en primer lugar, el número de filas de la matriz (n) no puede ser menor que el número de columnas (k); en segundo lugar las columnas deben ser linealmente independientes. Si el número de filas es menor que el número de columnas o si existiese alguna combinación lineal entre las columnas de X , su rango sería menor que k , puesto que el rango de una matriz es igual al máximo número de filas o columnas linealmente independientes. Recordando que las columnas de X son los valores de las variables explicativas se justifica el supuesto de que no exista relación lineal exacta entre ellas.

Como se dijo antes, los coeficientes del modelo representan los efectos en la variable dependiente causados por variaciones de la correspondiente variable independiente permaneciendo las otras constantes. Si existe una dependencia lineal entre las variables explicativas, la condición de permanencia de las otras variables no se puede cumplir y será imposible aislar los efectos individuales de cada una; en otras palabras, no se podrán estimar los parámetros de la ecuación.

Es de hacer notar que para efectos de la posible inversión de la matriz $X'X$ es necesario que el número de observaciones sea mayor o igual al número de parámetros a estimar ($n \geq k$). Sin embargo, la condición establecida es más restrictiva ($n > k$). La necesidad de esta condición guarda relación con los "grados de libertad" del modelo como se verá posteriormente.

La expresión (6), derivada de la condición de primer orden para la minimización de $e'e$, representa en forma matricial un sistema de k ecuaciones con k incógnitas. Este sistema se conoce como "sistema de ecuaciones normales".

Veamos este sistema en el caso de regresión simple, o sea el modelo con una sola variable independiente.

$$X'X = \begin{pmatrix} 1 & 1 & 1 & \dots & 1 \\ X_{21} & X_{22} & X_{23} & \dots & X_{2n} \end{pmatrix} = \begin{pmatrix} n & \sum X_{2i} \\ \sum X_{2i} & \sum X_{2i}^2 \end{pmatrix}$$

$$X'Y = \begin{pmatrix} 1 & 1 & 1 & \dots & 1 \\ X_{21} & X_{22} & X_{23} & \dots & X_{2n} \end{pmatrix} \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix} = \begin{pmatrix} \sum Y_i \\ \sum Y_i X_{2i} \end{pmatrix}$$

Luego,

$$\begin{pmatrix} n & \sum X_{2i} \\ \sum X_{2i} & \sum X_{2i}^2 \end{pmatrix} \begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} = \begin{pmatrix} \sum Y_i \\ \sum Y_i X_{2i} \end{pmatrix}$$

$$\Rightarrow \begin{cases} n\hat{\beta}_1 + \hat{\beta}_2 \sum X_{2i} = \sum Y_i \\ \hat{\beta}_1 \sum X_{2i} + \hat{\beta}_2 \sum X_{2i}^2 = \sum Y_i X_{2i} \end{cases}$$

obteniéndose el conocido sistema de dos ecuaciones para el ajuste de una recta.

Para el caso de k variables véase ejercicio 15.3.

Se puede demostrar ²⁸ que se cumple la condición de segundo orden para la existencia de un mínimo.

EJEMPLO 15.1.

El objetivo de este ejemplo es ilustrar el método y los cálculos necesarios para estimar un modelo lineal. Para la aplicación práctica de la estimación, los parámetros, así como en el cálculo de otros estadísticos que se mencionarán posteriormente, existen programas estadísticos de computación tales como el TSP, SPSS y otros. Al final de este capítulo se presenta una hoja con los resultados de la estimación de este mismo ejemplo usando el programa E Views, Micro TSP. Supongan que se hace depender la demanda de un bien de tres variables: gastos de propaganda, ingreso per cápita y precio del bien. El modelo será:

$$Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + \beta_4 X_{4i} + u_i$$

siendo Y_i = Número de unidades vendidas en el período i ; X_{2i} = Gastos de propaganda, en miles de bolívares; X_{3i} = Ingreso per cápita en miles de bolívares y X_{4i} = Precio del bien, en bolívares. Los datos hipotéticos de las variables aparecen en la siguiente tabla.

Cantidades Demandadas (Unidades) Y_i	Gastos de Propaganda (Miles de Bs.) X_{2i}	Ingreso per Cápita (Miles de Bs.) X_{3i}	Precio del bien (Bolívares) X_{4i}
1	0	1	8
2	1	2	5
4	3	3	6
3	2	4	7
5	1	6	3
7	4	8	4
6	3	7	2
8	2	7	2
9	1	8	1
8	0	9	1

²⁸ Véase Goldberger, Arthur S.; "Econometric Theory", Wiley & Sons Inc., New York, 1964, pp. 158.

Los cálculos básicos son los siguientes:

a) Matriz $X'X$

$$X'X = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 0 & 1 & 3 & 2 & 1 & 4 & 3 & 2 & 1 & 0 \\ 1 & 2 & 3 & 4 & 6 & 8 & 7 & 7 & 8 & 9 \\ 8 & 5 & 6 & 7 & 3 & 4 & 2 & 2 & 1 & 1 \end{pmatrix} = \begin{pmatrix} 10 & 17 & 55 & 39 \\ 17 & 45 & 100 & 67 \\ 55 & 100 & 373 & 159 \\ 39 & 67 & 159 & 209 \end{pmatrix}$$

b) Determinante de la matriz $X'X$

$$|X'X| = 120.487$$

c) Inversa de la matriz $X'X$

$$(X'X)^{-1} = \frac{1}{120.487} \begin{pmatrix} 736.623 & 22.642 & -78.436 & -85.043 \\ 22.642 & 9.312 & -4.087 & -4.101 \\ -78.436 & -4.087 & 9.156 & 8.981 \\ -85.043 & -4.101 & 8.981 & 10.928 \end{pmatrix} = \begin{pmatrix} 6,1137 & 0,1879 & -0,6510 & -0,7058 \\ 0,0773 & -0,0339 & -0,0340 & \\ & 0,0760 & 0,0745 & \\ & & 0,0907 & \end{pmatrix}$$

d) Se obtiene $X'Y$

$$X'Y = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 0 & 1 & 3 & 2 & 1 & 4 & 3 & 2 & 1 & 0 \\ 1 & 2 & 3 & 4 & 6 & 8 & 7 & 7 & 8 & 9 \\ 8 & 5 & 6 & 7 & 3 & 4 & 2 & 2 & 1 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \\ 4 \\ 3 \\ 5 \\ 7 \\ 6 \\ 8 \\ 9 \\ 8 \end{pmatrix} = \begin{pmatrix} 53 \\ 96 \\ 357 \\ 151 \end{pmatrix}$$

e) $\hat{\beta} = (X'X)^{-1} X'Y$

$$\hat{\beta} = \begin{pmatrix} 6,1137 & 0,1879 & -0,6510 & -0,7058 \\ & 0,0773 & -0,0339 & -0,0340 \\ & & 0,0760 & 0,0745 \\ & & & 0,0907 \end{pmatrix} \begin{pmatrix} 53 \\ 96 \\ 357 \\ 151 \end{pmatrix} = \begin{pmatrix} 3,834 \\ 0,13 \\ 0,6255 \\ -0,3704 \end{pmatrix}$$

f) Modelo ajustado

$$\hat{Y}_i = 3,0834 + 0,13 X_{2i} + 0,6255 X_{3i} - 0,3704 X_{4i}$$

15.4. PROPIEDADES DE LOS ESTIMADORES MINIMO CUADRATICOS

Ya se ha mencionado el fundamento conceptual de los estimadores obtenidos por el método de mínimos cuadrados; tienen la conveniente característica de minimizar la suma de los cuadrados de las diferencias entre los valores reales y estimados de la variable dependiente.

Estos estimadores tienen, además, otras propiedades y características que los hacen muy apropiados para la estimación bajo los supuestos del modelo.

En primer lugar, si el supuesto de normalidad de los términos de perturbación es válido; los estimadores máximo verosímiles coinciden con los estimadores mínimo cuadráticos²⁹.

En segundo lugar los estimadores mínimo cuadráticos son insesgados y eficientes, según lo enuncia el teorema de Gauss-Markov.

Teorema de Gauss-Markov

Los estimadores mínimo cuadráticos son los mejores estimadores lineales insesgados, o sea son los estimadores lineales insesgados de mínima varianza.

Prueba:

El calificativo lineal quiere decir que son funciones lineales de la variable dependiente (véase la expresión (7)) y, en consecuencia, de los términos de perturbación.

Para que sean insesgados debe cumplirse que $E(\hat{\beta}) = \beta$

Desarrollando (7) se tiene, utilizando (2)

$$\begin{aligned} \hat{\beta} &= (X'X)^{-1} X'Y = (X'X)^{-1} X'(X\beta + u) = \\ (8) \quad &= (X'X)^{-1} (X'X)\beta + (X'X)^{-1} X'u = \beta + (X'X)^{-1} X'u \end{aligned}$$

puesto que $(X'X)^{-1}(X'X) = I$

Tomando valores esperados

$$E(\hat{\beta}) = \beta + (X'X)^{-1} X'E(u) = \beta$$

ya que $E(u) = 0$

Para demostrar que es de mínima varianza primero calcularemos las varianzas de los estimadores, expresándolas en términos de la matriz de varianzas y covarianzas (ver sección 15.2).

²⁹ Para una prueba véase Goldberger, A.; Op. Cit. pp. 179 y siguientes.

Por definición,

$$\text{Var}(\hat{\beta}_i) = E(\hat{\beta}_i - \beta_i)^2$$

$$\text{Cov}(\hat{\beta}_i, \hat{\beta}_j) = E[(\hat{\beta}_i - \beta_i)(\hat{\beta}_j - \beta_j)]$$

las k varianzas y $C_{k,2}$ covarianzas se pueden agrupar en una matriz cuadrada y simétrica de orden k , en la cual los elementos de la diagonal principal son las varianzas y los otros elementos las covarianzas; esta matriz, simbólicamente, se representa $\text{Var}(\hat{\beta})$.

$$\text{Var}(\hat{\beta}) = E[(\hat{\beta} - \beta)(\hat{\beta} - \beta)']$$

En efecto,

$$E[(\hat{\beta} - \beta)(\hat{\beta} - \beta)'] = E \begin{pmatrix} \hat{\beta}_1 - \beta_1 \\ \hat{\beta}_2 - \beta_2 \\ \vdots \\ \hat{\beta}_k - \beta_k \end{pmatrix} (\hat{\beta}_1 - \beta_1, \hat{\beta}_2 - \beta_2, \dots, \hat{\beta}_k - \beta_k) =$$

$$= E \begin{pmatrix} (\hat{\beta}_1 - \beta_1)^2 & (\hat{\beta}_1 - \beta_1)(\hat{\beta}_2 - \beta_2) & \dots & (\hat{\beta}_1 - \beta_1)(\hat{\beta}_k - \beta_k) \\ (\hat{\beta}_2 - \beta_2)(\hat{\beta}_1 - \beta_1) & (\hat{\beta}_2 - \beta_2)^2 & \dots & (\hat{\beta}_2 - \beta_2)(\hat{\beta}_k - \beta_k) \\ \vdots & \vdots & \ddots & \vdots \\ (\hat{\beta}_k - \beta_k)(\hat{\beta}_1 - \beta_1) & \dots & \dots & (\hat{\beta}_k - \beta_k)^2 \end{pmatrix} =$$

$$= \begin{pmatrix} \text{Var}(\hat{\beta}_1) & \text{Cov}(\hat{\beta}_1, \hat{\beta}_2) & \dots & \text{Cov}(\hat{\beta}_1, \hat{\beta}_k) \\ \text{Cov}(\hat{\beta}_2, \hat{\beta}_1) & \text{Var}(\hat{\beta}_2) & \dots & \text{Cov}(\hat{\beta}_2, \hat{\beta}_k) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(\hat{\beta}_k, \hat{\beta}_1) & \dots & \dots & \text{Var}(\hat{\beta}_k) \end{pmatrix}$$

Veamos a que es igual $\text{Var}(\hat{\beta})$. Según (8) $\hat{\beta} - \beta = (X'X)^{-1}X'u$, luego

$$\text{Var}(\hat{\beta}) = E[(X'X)^{-1}X'uu'X(X'X)^{-1}]$$

puesto que la traspuesta de un producto es el producto de las traspuestas con el orden cambiado y además $(X'X)^{-1}$ es una matriz simétrica.

$$\begin{aligned} \text{Var}(\hat{\beta}) &= (X'X)^{-1}X'E(uu')X(X'X)^{-1} = \\ &= (X'X)^{-1}X'\sigma^2 IX(X'X)^{-1} = \quad [\text{por (4)}] \\ &= \sigma^2 (X'X)^{-1} \end{aligned}$$

puesto que σ^2 es un escalar que está multiplicando y la matriz identidad desaparece como multiplicador.

$$\boxed{\text{Var}(\hat{\beta}) = \sigma^2 (X'X)^{-1}}$$

Es decir que la varianza del estimador $\hat{\beta}_j$ ($j = 1, 2, \dots, k$), es igual a la varianza de los términos de perturbación multiplicada por el elemento a_{jj} de la matriz $(X'X)^{-1}$, y la covarianza de los estimadores $\hat{\beta}_j, \hat{\beta}_s$ es igual a la varianza de los términos de perturbación multiplicada por el elemento a_{js} de la matriz $(X'X)^{-1}$.

EJEMPLO 15.2.

Siguiendo con los datos del ejemplo 15.1. se tiene,

$$\text{Var}(\hat{\beta}_1) = \sigma^2 \cdot 6,1137$$

$$\text{Var}(\hat{\beta}_2) = \sigma^2 \cdot 0,0773$$

$$\text{Var}(\hat{\beta}_3) = \sigma^2 \cdot 0,0760$$

$$\text{Var}(\hat{\beta}_4) = \sigma^2 \cdot 0,0907$$

$$\text{Cov}(\hat{\beta}_1, \hat{\beta}_2) = \sigma^2 \cdot 0,1879$$

etc.

En el caso de dos variables, si no se usa notación matricial, las correspondientes expresiones son,³⁰

$$\text{Var}(\hat{\beta}_1) = \sigma^2 \frac{\sum X_{2i}^2}{n \sum (X_{2i} - \bar{X})^2}$$

$$\text{Var}(\hat{\beta}_2) = \sigma^2 \frac{1}{\sum (X_{2i} - \bar{X})^2}$$

$$\text{Cov}(\hat{\beta}_1, \hat{\beta}_2) = -\sigma^2 \frac{\bar{X}}{\sum (X_{2i} - \bar{X})^2}$$

Se demostrará ahora que cualquier otro estimador lineal insesgado de β tiene una mayor varianza que $\hat{\beta}$.

En efecto, consideremos otro estimador lineal de β , digamos $b = CY$, siendo C una matriz de números de orden $k \times n$.

³⁰ Véase Johnston J.; Op. cit. pág. 20 y 21.

Para que b sea un estimador insesgado de β , se debe cumplir que,

$$E(b) = \beta$$

Como $b = CX\beta + u = CX\beta + Cu$, se tiene

$$E(b) = CX\beta + C E(u) = CX\beta \Rightarrow CX = I$$

para que b sea insesgado CX debe ser igual a la matriz identidad. Según esto,

$$b = \beta + Cu \Rightarrow b - \beta = Cu$$

Calcularemos ahora la matriz de varianzas y covarianzas de b .

$$\text{Var}(b) = E[(b - \beta)(b - \beta)'] = E[Cuu'C'] =$$

$$= CE(uu')C' = C\sigma^2 IC' = \sigma^2 CC'$$

Luego la matriz de varianzas y covarianzas de cualquier estimador lineal insesgado de β es:

$$\text{Var}(b) = \sigma^2 CC'$$

o sea que las varianzas son iguales a σ^2 multiplicado por los elementos correspondientes de la diagonal principal de CC' , por lo que se deberá demostrar que esos elementos son mayores o iguales que los elementos de la diagonal principal de $(X'X)^{-1}$. Para relacionar CC' con $(X'X)^{-1}$ se usa un artificio matemático:

$$CC' = (X'X)^{-1} + (X'X)^{-1} - (X'X)^{-1} - (X'X)^{-1} + CC'$$

Se ha sumado y restado dos veces la misma cantidad; premultiplicando el segundo término por $(X'X)^{-1}X'X$, el tercero por CX y posmultiplicando el cuarto por $X'C'$, la expresión no varía puesto que en todos los casos se está multiplicando por la matriz identidad, luego

$$CC' = (X'X)^{-1} + (X'X)^{-1}(X'X)(X'X)^{-1} - CX(X'X)^{-1} - (X'X)^{-1}X'C' + CC'$$

factorizando los cuatro últimos términos,

$$CC' = (X'X)^{-1} + [(X'X)^{-1}X' - C][[(X'X)^{-1}X' - C]']$$

Si se desarrolla el producto en esta expresión se obtiene la expresión anterior, Para simplificar la expresión, llamemos;

$$A = [(X'X)^{-1}X' - C]$$

queda entonces,

$$\text{Var}(b) = \sigma^2 CC' = \sigma^2 [(X'X)^{-1} + AA'] = \sigma^2 (X'X)^{-1} + \sigma^2 AA' =$$

$$= \text{Var}(\hat{\beta}) + \sigma^2 AA'$$

El segundo término del segundo miembro de la igualdad anterior es σ^2 por el producto de una matriz por su traspuesta, en consecuencia los elementos de la diagonal principal de ese producto son cantidades no negativas por ser sumas de cuadrados; esto quiere decir que la varianza de b_j , estimador lineal insesgado, es igual a la varianza del estimado mínimo-cuadrático $\hat{\beta}_j$ más un término no negativo $[\text{Var}(b_j) = \text{Var}(\hat{\beta}_j) + \text{término no negativo}]$; o sea, cualquier estimador lineal insesgado tiene una varianza mayor o igual a la del estimador obtenido por el método de mínimos cuadrados:

$$\text{Var}(b_j) \geq \text{Var}(\hat{\beta}_j)$$

de forma que los estimadores mínimo-cuadráticos son los estimadores lineales insesgados de mínima varianza, conocidos en la literatura econométrica como estimadores BLUE (Best Linear Unbiased Estimators).

Se puede observar que los elementos de la diagonal principal de AA' son cero cuando $(X'X)^{-1}X' = C$, o sea cuando el vector b es el propio vector $\hat{\beta}$, que es precisamente el vector de los estimadores mínimo-cuadráticos. Se debe recordar que los estimadores insesgados de mínima varianza son únicos.

15.5. ESTIMADOR DE LA VARIANZA DE LAS PERTURBACIONES

El otro parámetro del modelo que se debe estimar es σ^2 .

Por ser σ^2 una medida de las desviaciones de los términos de perturbación con respecto a su media cero, parecería lógico que un estimador de σ^2 se base en los residuos

del modelo, puesto que éstos pueden considerarse como representativos de los términos de perturbación.

Un estimador insesgado de σ^2 es

$$s^2 = \frac{e'e}{n-k}$$

En efecto, se tiene

$$e = Y - X\hat{\beta} = X\beta + u - X(X'X)^{-1}X'(X\beta + u) \text{ por (2) y (7)}$$

$$= X\beta + u - X(X'X)^{-1}(X'X)\beta - X(X'X)^{-1}X'u =$$

$$= u - X(X'X)^{-1}X'u = [I - X(X'X)^{-1}X']u = Mu$$

siendo $M = [I - X(X'X)^{-1}X']$. Entonces la suma de los cuadrados de los residuos es

$$e'e = u'M'Mu = u'Mu$$

puesto que M es una matriz simétrica e idempotente.

Tomando valores esperados,

$$E(e'e) = E(u'Mu) =$$

$$= E \begin{pmatrix} u_1 & u_2 & \dots & u_n \end{pmatrix} \begin{pmatrix} b_{11} & b_{12} & \dots & b_{1n} \\ b_{21} & b_{22} & \dots & b_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ b_{n1} & b_{n2} & \dots & b_{nn} \end{pmatrix} \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{pmatrix} =$$

$$= E \left(u_1 b_{11} + \dots + u_n b_{n1}, u_1 b_{12} + \dots + u_n b_{n2}, \dots, u_1 b_{1n} + \dots + u_n b_{nn} \right) \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{pmatrix} =$$

$$= E \left(u_1^2 b_{11} + \dots + u_1 u_n b_{n1} + u_1 u_2 b_{12} + u_2^2 b_{22} + \dots + u_n^2 b_{nn} \right) =$$

$= b_{11} \sigma^2 + b_{22} \sigma^2 + \dots + b_{nn} \sigma^2 +$ términos que contienen las covarianzas de los términos de perturbación que son cero;

$$E(e'e) = \sigma^2 (b_{11} + b_{22} + \dots + b_{nn}) = \sigma^2 \text{tr} M =$$

$$= \sigma^2 \text{tr} [I - X(X'X)^{-1}X'] =$$

$$= \sigma^2 [\text{tr} I_n - \text{tr} X(X'X)^{-1}X'] =$$

$$= \sigma^2 [\text{tr} I_n - \text{tr} (X'X)(X'X)^{-1}] =$$

$$= \sigma^2 [\text{tr} I_n - \text{tr} I_k] = \sigma^2 (n - k)$$

luego

$$E(s^2) = \frac{E(e'e)}{n - k} = \frac{\sigma^2 (n - k)}{n - k} = \sigma^2$$

La forma más práctica de calcular la suma de los cuadrados de los residuos es la siguiente;

Se sabe que,

$$\begin{aligned} e'e &= Y'Y - 2\hat{\beta}'X'Y + \hat{\beta}'X'X\hat{\beta} = \\ &= Y'Y - 2\hat{\beta}'X'Y + \hat{\beta}'X'Y \quad \text{por (6)} \end{aligned}$$

$$(9) \quad e'e = Y'Y - \hat{\beta}'X'Y \quad ^{31}$$

EJEMPLO 15.3.

Siguiendo con el ejemplo 15.1.

$$Y'Y = \sum Y_i^2 = 349$$

$$\hat{\beta}'X'Y = (3,0834 \quad 0,13 \quad 0,6255 - 0,3704) \begin{pmatrix} 53 \\ 96 \\ 357 \\ 151 \end{pmatrix} = 343,2733$$

$$e'e = 349 - 343,2733 = 5,7267$$

El estimador de σ^2 será,

$$s^2 = \frac{5,7267}{6} = 0,9545$$

A la raíz cuadrada (positiva) de s^2 (s) se le conoce como "error standard de la estimación".

En la ecuación (4) se determinó que la matriz de varianzas y covarianzas de $\hat{\beta}$ es,

$$\text{Var}(\hat{\beta}) = \sigma^2 (X'X)^{-1}$$

Los estimadores de las varianzas y covarianzas de los estimadores de los coeficientes se obtendrán sustituyendo σ^2 por s^2 , de forma que

$$\text{Var}(\hat{\beta}) = s^2 (X'X)^{-1}$$

³¹ En el caso de un pequeño número de observaciones, no es demasiado difícil calcular $e'e$ simplemente hallando las diferencias entre los valores reales y estimados, elevando al cuadrado y sumando.

en particular

$$\text{Var}(\hat{\beta}_j) = s^2 a_{jj}$$

siendo a_{jj} el elemento j de la diagonal principal de la matriz $(X'X)^{-1}$.

La raíz cuadrada (positiva) de la varianza se conoce como "error standard del estimador".

$$\hat{\sigma}_{\hat{\beta}_j} = \sqrt{s^2 a_{jj}}$$

EJEMPLO 15.4.

Los valores estimados de las varianzas y los errores standard de los estimadores en el ejemplo 15.1. son:

$$\text{Var}(\hat{\beta}_1) = 0,9545 \times 6,1137 = 5,84 \Rightarrow \hat{\sigma}_{\hat{\beta}_1} = \sqrt{5,84} = 2,4166$$

$$\text{Var}(\hat{\beta}_2) = 0,9545 \times 0,0773 = 0,0738 \Rightarrow \hat{\sigma}_{\hat{\beta}_2} = \sqrt{0,0738} = 0,2717$$

$$\text{Var}(\hat{\beta}_3) = 0,9545 \times 0,0760 = 0,0725 \Rightarrow \hat{\sigma}_{\hat{\beta}_3} = \sqrt{0,0725} = 0,2693$$

$$\text{Var}(\hat{\beta}_4) = 0,9545 \times 0,0907 = 0,0866 \Rightarrow \hat{\sigma}_{\hat{\beta}_4} = \sqrt{0,0866} = 0,2949$$

15.6. BONDAD DEL AJUSTE. COEFICIENTE DE DETERMINACION R^2 .

15.6.1. EL COEFICIENTE DE DETERMINACION

La varianza de los términos de perturbación, σ^2 , es una medida de la importancia que tienen los factores no considerados en el modelo, en las variaciones de la variable dependiente. Un valor alto de la varianza indicaría que los valores poblacionales de la variable dependiente están alejados de los valores teóricos que supuestamente debería tener, como consecuencia de la influencia de las variables explicativas incluidas en el modelo. Esta situación se refleja en los valores muestrales lo que ocasiona que los datos muestrales no se ajusten bien al modelo teórico, los residuos serán grandes y s^2 (estimador de σ^2) también será grande.

La magnitud de σ^2 como medida de la habilidad del modelo para explicar el comportamiento de la variable dependiente y, por ende, la de s^2 como medida de la "bondad del ajuste" no son completamente adecuadas. Cuando se califica s^2 como grande o pequeña, cabría preguntarse con respecto a que es grande o pequeña. Los valores de σ^2 y s^2 están afectados por la unidad de medida de la variable dependiente. Además, si se quiere comparar el grado de variación o la bondad del ajuste en distintos modelos se necesita tener una medida standard que pueda usarse como indicador relativo de comparación.

Esta medida, para los datos poblacionales, la constituye el coeficiente de correlación múltiple (P) o su cuadrado el "Coeficiente de determinación múltiple (P^2)".

P^2 está definido como el porcentaje de variación de la variable dependiente explicado por la influencia lineal de las variables independientes.

Este coeficiente es un parámetro poblacional desconocido. Para determinar la "bondad del ajuste" a partir de los datos muestrales se utiliza un estimador de P^2 ; al considerar el modelo ajustado como un estimador de la verdadera influencia que las variables explicativas tienen en la variable dependiente, el estimador que se usa es R^2 , conocido como "Coeficiente de determinación múltiple muestral".

$$R^2 = 1 - \frac{\text{SCR}}{\text{STC}}$$

siendo:

SCR = Suma de los cuadrados de los residuos o suma de los cuadrados no explicada


por el modelo = $e'e = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$

STC = Suma total de los cuadrados = $\sum_{i=1}^n (Y_i - \bar{Y})^2$, en donde $\bar{Y}$ es la media de


la variable dependiente.

R^2 es un número comprendido entre cero y uno; un R^2 igual a uno implicaría un ajuste perfecto de los datos al modelo, mientras que, en el extremo opuesto, un R^2 igual a cero mostraría que no hay ninguna relación aparente entre la variable dependiente y las variables independientes; valores intermedios de R^2 indican una mayor o menor relación aparente entre la variable explicada y las variables explicativas.

En efecto, si el ajuste es perfecto, los valores reales y estimados de la variable dependiente son iguales $Y_i = \hat{Y}_i \Rightarrow \text{SCR} = 0 \Rightarrow R^2 = 1$. Véase el gráfico para el caso de dos variables.



Por otro lado, si las variaciones de Y no están relacionadas con los valores de X, cada valor $\hat{Y}_i$ sería igual a $\bar{Y}$ y $SCR = STC \Rightarrow R^2 = 0$. Si la relación entre la variable dependiente e independiente es nula, cada uno de los estimadores $\hat{\beta}_2, \dots, \hat{\beta}_k$ serían iguales a cero y en consecuencia cada valor estimado sería igual a una constante e igual a la media de variable dependiente ($\bar{Y}$) puesto que el plano de regresión estimado por el método de mínimos-cuadrados para por el punto $(\bar{X}, \bar{Y})$ ³². En el gráfico siguiente se presenta esta situación extrema para el caso del modelo de dos variables.




³² En el caso del modelo simple, una de las ecuaciones para el ajuste de la recta es $\sum Y_i = n\hat{\beta}_1 + \hat{\beta}_2 \sum X_{2i}$. Si se divide por n se tiene $\bar{Y} = \hat{\beta}_1 + \hat{\beta}_2 \bar{X}_2$.

Vamos a profundizar un poco más en el significado que tienen las sumas de los cuadrados que se utilizan para calcular R^2 . Si no existiera ningún factor que influyera en la variable Y, ésta no variaría, sería constante, cada Y_i sería igual a $\bar{Y}$. Cuando Y varía, sus variaciones podemos medirlas como desviaciones con respecto a la media $Y_i - \bar{Y}$. Cabe preguntarse por qué varía Y, por qué los valores de Y difieren de una observación a otra. Según el modelo que hemos especificado estas variaciones en Y se deben en parte, la cual pretendemos que sea importante, a los cambios en las variables explicativas, y en parte, la que queremos sea poco relevante, a las perturbaciones aleatorias.

Las desviaciones de Y con respecto a $\bar{Y}$ se pueden descomponer en dos partes: $Y_i - \bar{Y}_i$ y $\hat{Y}_i - \bar{Y}$, es decir

$$Y_i - \bar{Y} = (Y_i - \hat{Y}_i) + (\hat{Y}_i - \bar{Y})$$

como se muestra en el gráfico.



Si elevamos al cuadrado estas desviaciones y las sumamos se obtiene

$$(10) \sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 + \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$$

$$STC = SCR + SEC$$

siendo SEC la suma explicada de los cuadrados por el modelo

Para demostrar (10), se desarrollan cada uno de los términos de la expresión.

$$(11) \text{STC} = \sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n Y_i^2 - 2\bar{Y} \sum_{i=1}^n Y_i + n\bar{Y}^2 = Y'Y - n\bar{Y}^2$$

$$(12) \text{SCR} = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = e'e = Y'Y - \hat{\beta}'X'Y \text{ por (9)}$$

$$(13) \text{SEC} = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 = \sum_{i=1}^n Y_i^2 - 2\bar{Y} \sum_{i=1}^n \hat{Y}_i + n\bar{Y}^2 = Y'Y - n\bar{Y}^2$$

puesto que $\frac{\sum \hat{Y}_i}{n} = \bar{Y}$, es decir la media de los valores estimados y de los valores reales es igual; este hecho se desprende del propio método de mínimos cuadrados ³³. Además,

$$\hat{Y} = X\hat{\beta} \quad \text{por (5)}$$

$$\text{y} \quad X'X\hat{\beta} = X'Y \quad \text{por (6)}$$

se tiene

$$(14) \text{SEC} = \hat{\beta}'X'X\hat{\beta} - n\bar{Y}^2 = \hat{\beta}'X'Y - n\bar{Y}^2$$

Si se suma SCR y SEC se tiene STC:

$$Y'Y - \hat{\beta}'X'Y + \hat{\beta}'X'Y - n\bar{Y}^2 = Y'Y - n\bar{Y}^2$$

es decir que la suma total de los cuadrados se puede separar en dos componentes, uno que representa la variación atribuible a las variables explicativas usadas en el modelo (SEC) y otra atribuible a otros factores no incluidos explícitamente en él (reunidos en el término de perturbación) (SCR). Cuanto mayor sea la primera en relación con la segunda el modelo se ajusta mejor y el coeficiente de determinación R^2 tiende a ser mayor.

Haciendo uso de la descomposición anterior, se tiene

³³ En el caso de dos variables al derivar con respecto a $\hat{\beta}_1$ la suma de los cuadrados de los residuos se obtiene:

$$\frac{\partial}{\partial \hat{\beta}_1} \sum (Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_{2i})^2 = -2 \sum (Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_{2i}) = 0 \Rightarrow \sum Y_i = \sum \hat{Y}_i$$

$$R^2 = 1 - \frac{\text{SCR}}{\text{STC}} = \frac{\text{STC} - \text{SCR}}{\text{STC}} = \frac{\text{SEC}}{\text{STC}}$$

que es otra forma de definir el coeficiente de determinación.

Para los cálculos prácticos se puede usar cualquiera de las siguientes expresiones:

$$R^2 = \frac{\hat{\beta}'X'Y - n\bar{Y}^2}{Y'Y - n\bar{Y}^2} \quad \text{por (11) y (14)}$$

ó

$$R^2 = 1 - \frac{Y'Y - \hat{\beta}'X'Y}{Y'Y - n\bar{Y}^2} \quad \text{por (11) y (12)}$$

también, puesto que $\bar{Y} = \frac{\sum Y_i}{n}$, se puede escribir:

$$R^2 = \frac{\hat{\beta}'X'Y - (\sum Y_i)^2/n}{Y'Y - (\sum Y_i)^2/n} \quad \text{ó} \quad R^2 = 1 - \frac{Y'Y - \hat{\beta}'X'Y}{Y'Y - (\sum Y_i)^2/n}$$

EJEMPLO 15.5.

Siguiendo con nuestro ejemplo,

$$R^2 = 1 - \frac{5,7267}{349 - 53^2/10} = 0,9159$$


15.6.2. INTERPRETACION DE R^2

Tanto R^2 como R , coeficiente de correlación múltiple, son ampliamente usados en el análisis de los modelos de regresión. El coeficiente de correlación R no tiene una interpretación numérica precisa, cuando se acerca a uno indica alta correlación y si se acerca a cero baja correlación entre la variable dependiente y las independientes. El hecho de que $R = 0,9$ en una regresión y $R = 0,45$ en otra no indica que la primera sea dos veces mejor o más útil que la segunda. Es una medida de asociación lineal que tampoco implica relación causa-efecto.


En el contexto de la regresión, el coeficiente de determinación R^2 , es una medida más significativa cuantitativamente. R^2 mide el porcentaje de variación de la variable dependiente atribuible a las variables explicativas. Si $R^2 = 0,84$ se puede decir que el 84% de la variación de Y está explicada de alguna forma por la influencia lineal de las variables explicativas.

Sin embargo la interpretación de R^2 debe hacerse con precaución; un coeficiente de determinación alto, incluso igual a uno, no implica necesariamente que exista una relación teórica íntima entre las variables. Si existe una perfecta correlación entre la demanda y el precio de un bien podemos creer que se debe a la íntima relación que la teoría económica indica entre esas dos variables; pero si se halla un R^2 igual a uno entre la lluvia caída en Caracas y la demanda de televisores a color en Maracaibo, esto se debe a la casualidad y no podemos pretender presentar o defender una teoría de la demanda basada en esta magnitud estadística. Si la alta correlación se debe a que exista una relación teórica o a la casualidad debe determinarse a priori desde un punto de vista teórico; esto implica que antes de intentar medir la relación entre variables económicas se debe analizar, comprender y racionalizar las hipótesis teóricas sobre esas relaciones; no se debe hacer análisis estadísticos de medición de relaciones entre variables económicas sin que exista una base teórica lógica que justifique esa medición. Dicho en otras palabras la teoría es anterior y más importante que las técnicas estadísticas.


Por otro lado, un R^2 muy pequeño no implica necesariamente la inexistencia de relación entre la variable dependiente e independientes. Un R^2 cercano a cero, indica que la función utilizada se ajusta mal a los datos reales de las variables. Una posible explicación es que las variables explicativas utilizadas son deficientes en el sentido de que sus variaciones no afectan a la variable que tratamos de explicar. Tal situación gráficamente sería así, en el caso de dos variables.



Otra posibilidad es que aunque las variables explicativas usadas en el modelo sí afectan a la variable dependiente, su influencia es relativamente poco importante comparada con la de los factores incluidos en el término de perturbación. Gráficamente se tiene:



También un R^2 pequeño podría explicarse por una incorrecta especificación del modelo. Si la relación entre X e Y existe pero es altamente no lineal, la relación lineal se ajustaría mal.



15.6.3. COEFICIENTE DE DETERMINACION MODIFICADO ($\bar{R}^2$)

El valor de R^2 es una medida aceptable para la comparación de la bondad del ajuste entre dos o más modelos que traten de explicar el comportamiento de una variable. Sin embargo, tiene algunas deficiencias que conviene mencionar. En primer lugar R^2 es una función no decreciente del número de variables explicativas que se utilizan en el modelo, es decir que si en un modelo, cuyo coeficiente de determinación es R_1^2 , se agregan variables explicativas y se vuelve a estimar, el coeficiente de determinación del segundo modelo R_2^2 es mayor o igual que el del primero. En otras palabras, el coeficiente de determinación tiende a aumentar al agregar variables aunque éstas no expliquen nada desde el punto de vista teórico, y el investigador puede sentirse tentado a agregar variables con el objetivo de conseguir un R^2 elevado.

En segundo lugar R^2 es un estimador sesgado de P^2 ³⁴. El sesgo es negativo y se mantiene aún para muestras grandes.

Suele usarse en lugar de R^2 un coeficiente de determinación corregido por los grados de libertad ($\bar{R}^2$).

$$\bar{R}^2 = 1 - \frac{n-1}{n-k} (1 - R^2)$$

lo que equivale a

$$\bar{R}^2 = 1 - \frac{SCR/(n-k)}{STC/(n-1)}$$

o sea que se ponderan las sumas totales y no explicadas por sus grados de libertad respectivos.

Obsérvese que el numerador es un estimador insesgado de la varianza de los términos de perturbación mientras que el denominador es un estimador insesgado de la varianza de la variable Y_i .

Se puede observar también que $\bar{R}^2$ puede disminuir si la variable o variables adicionales producen solamente un pequeño aumento en R^2 .

³⁴ Barten A.P.; "Note on Unbiased Estimation of the Squared Multiple Correlation Coefficient". Statistics Neerlandia, 16, pp. 151-163.

Este coeficiente de determinación modificado es también sesgado pero su sesgo es menor que el de R^2 .

En el ejemplo el coeficiente de determinación modificado es

$$\bar{R}^2 = 1 - \frac{9}{6} (1 - 0,9159) = 0,8739$$

Los errores standard de los estimadores y el coeficiente de determinación son magnitudes importantes para la evaluación de los modelos por lo que es necesario especificar sus valores en la presentación de los resultados de la estimación de un modelo, tal como se muestra a continuación con los datos del ejemplo:

$$\hat{Y}_i = 3,0834 + 0,13 X_{2i} + 0,6255 X_{3i} - 0,3704 X_{4i} \quad R^2 = 0,9159$$

$$(0,2717) \quad (0,2693) \quad (0,2949)$$

Los números entre paréntesis debajo de cada coeficiente estimado son los correspondientes errores standard.

15.7. OTROS RESULTADOS ESTADISTICOS DEL MODELO

Intervalos de Confianza y Contrastes de Hipótesis

Para poder hacer contrastes de hipótesis y calcular intervalos de confianza para los coeficientes del modelo, es necesario usar el supuesto de normalidad de los términos de perturbación.

Como los estimadores mínimo-cuadráticos son funciones lineales de los términos de perturbación, son también normales.

$$\hat{\beta}_j \sim N(\beta_j, \sigma^2 a_{jj})$$

Como σ^2 es desconocida no se puede utilizar la distribución normal para hacer los contrastes o calcular los intervalos.

Se usará el hecho de que $\frac{(n-k)s^2}{\sigma^2} = \frac{e'e}{\sigma^2}$ es una variable χ^2 con $(n-k)$ grados de libertad e independiente de $\hat{\beta}_j$,³⁵

³⁵ Para una demostración, véase Johnston J. Op. Cit. pp. 144.

Según esto,

$$t = \frac{\hat{\beta}_j - \beta_j}{\sqrt{s^2 a_{jj}}}$$

obedece a una distribución "t" de Student con n-k grados de libertad. Un intervalo de confianza de 100 (1 - α)% para β_j será:

$$\hat{\beta}_j \pm t_{\alpha/2} s \sqrt{a_{jj}}$$

Para contrastar la hipótesis $H_0: \beta_j = \beta_{j0}$ contra la hipótesis alternativa $H_1: \beta_j \neq \beta_{j0}$ con un nivel de significación de α , los valores críticos son:

$$h_1 = \beta_{j0} - t_{\alpha/2} s \sqrt{a_{jj}}$$

$$h_2 = \beta_{j0} + t_{\alpha/2} s \sqrt{a_{jj}}$$

o, alternatively, se calcula el valor de

$$t = \frac{\hat{\beta}_j - \beta_{j0}}{\sqrt{s^2 a_{jj}}}$$

Si t está entre $-t_{\alpha/2}$ y $t_{\alpha/2}$ se acepta la hipótesis, si no se rechaza.

Se deja como ejercicio al lector la derivación de los límites del intervalo y de los valores críticos.

EJEMPLO 15.6.

En el modelo desarrollado en este capítulo un intervalo de confianza para β_2 del 90% es,

$$0,13 \mp 1,943 \times 0,2717 \Rightarrow (-0,40 ; 0,66)$$

Si se quiere contrastar la hipótesis nula $H_0: \beta_3 = 0$ contra $H_1: \beta_3 \neq 0$, con un nivel de significación del 10%.

$$\frac{\hat{\beta}_3}{\sqrt{s^2 a_{33}}} = 2,3227 > 1,943; \quad \text{se rechaza } H_0.$$

Se deja como ejercicio calcular intervalos de confianza para β_3 y β_4 y hacer los contrastes para β_2 y β_4 .

Son particularmente importantes estos contrastes en los cuales la hipótesis nula es $\beta_j = 0$, puesto que con ellos se puede determinar si alguna variable en particular tiene o no influencia significativa en la variable dependiente, es decir, si la variable en cuestión es relevante en la explicación de la variable dependiente.

Por otro lado, es útil verificar si las variables explicativas, tomadas en conjunto, explican satisfactoriamente los cambios de la variable dependiente. Esto se hace mediante un contraste de hipótesis en el cual la hipótesis nula es $H_0: P^2 = 0$; si al hacer este contraste no se puede rechazar la hipótesis nula, estamos afirmando que el modelo tal como está formulado, no explica satisfactoriamente las variaciones de la variable dependiente. El estadístico apropiado para hacer este contraste es el coeficiente de determinación múltiple muestral R^2 .

La técnica para hacer este contraste sobre el coeficiente de determinación se deriva del contraste conjunto sobre los coeficientes del modelo que se explicará a continuación.

Contraste de Hipótesis Conjunto sobre los coeficientes β_j

En este contraste se trata de verificar la hipótesis nula de que un subgrupo de los coeficientes del modelo son iguales a cero conjuntamente considerados.

Supongamos que se tiene un modelo con tres variables explicativas,

$$Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + \beta_4 X_{4i} + u_i$$

y estamos interesados en saber si ese modelo puede ser sustituido por el modelo,

$$Y_i = \beta_1 + \beta_2 X_{2i} + u_i$$

con una sola variable explicativa; es decir, queremos saber si el modelo simplificado explica las variaciones de Y_i tan eficientemente como el modelo original.

Con este contraste se puede verificar si un subgrupo de variables tomadas conjuntamente no ejercen influencia significativa en la variable dependiente.

En el caso que nos ocupa, se deberá contrastar la hipótesis conjunta:

$$H_0: \beta_3 = \beta_4 = 0$$

En general, si se tiene el modelo:

$$Y_i = \beta_1 + \beta_2 X_{2i} + \dots + \beta_k X_{ki} + u_i$$

se puede contrastar la hipótesis:

$$H_0 : \beta_{r+1} = \beta_{r+2} = \dots = \beta_k = 0$$

es decir, la hipótesis de que $k-r$ coeficientes del modelo son, conjuntamente considerados, iguales a cero.

Debe hacerse notar que este tipo de contraste no puede hacerse contrastando individualmente cada uno de los coeficientes; es decir, no es equivalente un contraste conjunto

$$H_0 : \beta_3 = \beta_4 = 0$$

a dos contrastes individuales,

$$H_0 : \beta_3 = 3; \quad H_0 : \beta_4 = 0$$

en este último caso se utilizarían las técnicas explicadas en el capítulo anterior.

Es posible, por ejemplo, aceptar la hipótesis de que β_3 es igual a cero y también aceptar la hipótesis de que β_4 es igual a cero y sin embargo rechazar la hipótesis de que β_3 y β_4 son iguales a cero, conjuntamente considerados.

La razón de esta aparente contradicción es la siguiente: Si existe una alta correlación lineal entre las variables X_3 y X_4 , no se pueden separar los efectos de las variables correlacionadas sobre la variable dependiente, lo que hace que el método de estimación no pueda asignar la variación de la variable dependiente entre las variables explicativas individuales; esto da lugar, entre otras cosas, a que al hacer los contrastes individuales de los coeficientes, para verificar la significación individual de las variables explicativas, los coeficientes pueden resultar no significativamente diferentes de cero, no debido a que las variables no tengan importancia en la explicación de la variable dependiente, sino debido a un alto error standard del estimador, provocado por la alta correlación de las variables explicativas; si la correlación es alta, aunque no perfecta, el determinante de $X'X$ está cercano a cero, con lo que la matriz $(X'X)^{-1}$ tiene algunos elementos extremadamente grandes; si recordamos que los elementos de la diagonal principal de esa matriz forman parte, como factores, de las varianzas de los estimadores, estas y los correspondientes errores standard pueden ser anormalmente grandes lo que traerá como consecuencia intervalos de confianza poco precisos, regiones de aceptación amplias y no podrá rechazarse la hipótesis $\beta_j = 0$.

Estas altas varianzas surgen porque no existe suficiente variación independiente en una variable explicativa para poder calcular con confianza el efecto que ella tiene en la variable explicada.

Esta es en pocas palabras, la esencia del importantísimo problema de la "multicolinealidad" que ha sido objeto de amplios y rigurosos estudios por los econométricos.

Primero se explicará como se hace el contraste y después se justificará el procedimiento del mismo.

a) Procedimiento del contraste

1° Sin pérdida de generalidad se puede considerar que los coeficientes que se quieren contrastar son los últimos $k-r$ coeficientes; es decir, en el modelo:

$$Y_i = \beta_1 + \beta_2 X_{2i} + \dots + \beta_r X_{ri} + \beta_{r+1} X_{r+1,i} + \dots + \beta_k X_{ki} + u_i$$

que, en forma matricial, es:

$$Y = X\beta + u$$

se contrastará la hipótesis nula:

$$H_0 : \beta_{r+1} = \beta_{r+2} = \dots = \beta_k = 0$$

Se particiona la matriz X en dos submatrices X_1 y X_2 . Los elementos de X_1 son los datos de las variables X_2 hasta X_r con la primera columna de unos, y los de la matriz X_2 son los datos de las variables X_{r+1} hasta X_k :

$$X = [X_1 : X_2]$$

siendo:

$$X_1 = \begin{bmatrix} 1 & X_{21} & \dots & X_{r1} \\ 1 & X_{22} & \dots & X_{r2} \\ \dots & \dots & \dots & \dots \\ 1 & X_{2n} & \dots & X_{rn} \end{bmatrix} \quad \text{y} \quad X_2 = \begin{bmatrix} X_{r+1,1} & X_{r+2,1} & \dots & X_{k1} \\ X_{r+1,2} & X_{r+2,2} & \dots & X_{k2} \\ \dots & \dots & \dots & \dots \\ X_{r+1,n} & X_{r+2,n} & \dots & X_{kn} \end{bmatrix}$$

Se particiona el vector β en dos vectores γ_1 y γ_2 .

$$\beta = \begin{bmatrix} \gamma_1 \\ \dots \\ \gamma_2 \end{bmatrix}$$

siendo,

$$\gamma_1 = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_r \end{bmatrix} \quad y \quad \gamma_2 = \begin{bmatrix} \beta_{r+1} \\ \beta_{r+2} \\ \vdots \\ \beta_k \end{bmatrix}$$

en consecuencia, el modelo original se puede expresar así:

$$Y = [X_1 \vdots X_2] \begin{bmatrix} \gamma_1 \\ \vdots \\ \gamma_2 \end{bmatrix} + u = X_1 \gamma_1 + X_2 \gamma_2 + u$$

y la hipótesis nula se puede reformular así:

$$H_0: \gamma_2 = 0$$

2° Se ajustan los dos modelos, el original y el simplificado,

$$Y = X\beta + u; \quad Y = X_1 \gamma_1 + u$$

obteniéndose los estimadores:

$$\hat{\beta} = (X'X)^{-1} X'Y; \quad \hat{\gamma}_1 = (X_1'X_1)^{-1} X_1'Y$$

y se calculan las cantidades:

$$\hat{\beta}'X'Y \quad y \quad \hat{\gamma}_1'X_1'Y$$

3° Si la hipótesis nula es verdadera, se tiene que el cociente:

$$(15) \quad \frac{\hat{\beta}'X'Y - \hat{\gamma}_1'X_1'Y}{e'e} \frac{n-k}{k-r}$$

es una variable aleatoria que obedece a la distribución F de Snedecor con (k-r) y (n-k) grados de libertad.

4° Si el valor de esta variable F es mayor que F_{α} , se rechaza la hipótesis nula con un nivel de significación de α ; si $F < F_{\alpha}$ no se puede rechazar la hipótesis nula.

b) Justificación del contraste ³⁶

Se tratará ahora de justificar el procedimiento del contraste descrito anteriormente.

La variación explicada por el modelo completo es, según sabemos

$$SEC = \hat{\beta}'X'Y - n\bar{Y}^2 \quad (\text{ver pag. 536})$$

Al estimar el modelo con las variables X_2 hasta X_k , la variación explicada es:

$$SEC_1 = \hat{\gamma}_1'X_1'Y - n\bar{Y}^2$$

luego el numerador del cociente utilizado en el contraste es:

$$(16) \quad SEC - SEC_1 = \hat{\beta}'X'Y - \hat{\gamma}_1'X_1'Y$$


y representa la contribución de las variables omitidas X_{r+1} hasta X_k a la explicación de la variación de Y.

El valor de esta diferencia depende de la veracidad o falsedad de la hipótesis nula; en efecto, la hipótesis planteada es que un subgrupo de los coeficientes tomados conjuntamente son iguales a cero, y se puede interpretar como que las variables explicativas correspondientes no tienen influencia significativa en la variable dependiente. Si H_0 es verdadera la diferencia (16) tenderá a ser cero, o, lo que es lo mismo, la variación no explicada por el modelo simplificado será prácticamente igual a la variación no explicada por el modelo completo.

Si $e_1'e_1$ representa la suma de los cuadrados de los residuos en el modelo simplificado se tiene:

$$(17) \quad e_1'e_1 = e'e + (SEC - SEC_1)$$

³⁶ Para una prueba completa, ver J. Johnston, op. cit. p. 146 a 154.



Por otro lado, se sabe que $e'e/\sigma^2$ y $e'e_1/\sigma^2$ son variables que obedecen a la distribución χ^2 con $(n-k)$ y $(n-r)$ grados de libertad respectivamente (ver sección 15.7).

Dividiendo (17) por σ^2 se tiene:

$$\frac{e'e_1}{\sigma^2} = \frac{e'e}{\sigma^2} + \frac{(SEC - SEC_1)}{\sigma^2}$$

de tal forma que $(SEC - SEC_1)/\sigma^2$ es una variable χ^2 con $(k-r)$ grados de libertad, puesto que la suma de variables χ^2 independientes es una variable χ^2 con un número de grados de libertad igual a la suma de grados de libertad de los sumandos. Según esto, la variable utilizada en el contraste (15) es el cociente de dos χ^2 independientes divididas por sus grados de libertad, luego es una variable F.

Además, el valor de $e'e$ (suma de los cuadrados de los residuos del modelo completo) no depende de la veracidad o falsedad de la hipótesis nula. En efecto, la variación explicada conjuntamente por todas las variables incluidas originalmente no se ve afectada por el hecho de que una o más de las variables en forma individual no tengan influencia en la variable dependiente. En términos de la hipótesis que se está contrastando, la magnitud relativa de la variable F depende sólo del numerador, si éste es relativamente grande comparado con el denominador nos inclinaríamos a rechazar la hipótesis nula; si, por el contrario, es relativamente pequeño tenderíamos a aceptarla; en otras palabras el contraste debe ser de una cola por la derecha, es decir, la región crítica está constituida por valores del estadístico mayores al valor crítico. Con un nivel de significación de α , este valor crítico es F_α .

EJEMPLO 15.7

Siguiendo con los datos de nuestro ejemplo, supongamos que queremos contrastar la hipótesis:

$$H_0 : \beta_2 = \beta_4 = 0$$

El modelo simplificado para contrastar la hipótesis nula es:

$$Y_1 = \beta_1 + \beta_3 X_{31} + u_1$$

Se ajusta el modelo simplificando para obtener $\hat{\gamma}_1$.

$$X_1'X_1 = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 6 & 8 & 7 & 7 & 8 & 9 \end{bmatrix} \quad \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 6 \\ 1 & 8 \\ 1 & 7 \\ 1 & 7 \\ 1 & 8 \\ 1 & 9 \end{bmatrix} = \begin{bmatrix} 10 & 55 \\ 55 & 373 \end{bmatrix}$$

$$[X_1'X_1]^{-1} = \frac{1}{705} \begin{bmatrix} 373 & -55 \\ -55 & 10 \end{bmatrix}; \quad X_1'Y = \begin{bmatrix} 53 \\ 357 \end{bmatrix}$$

$$\hat{\gamma}_1 = \frac{1}{705} \begin{bmatrix} 373 & -55 \\ -55 & 10 \end{bmatrix} \begin{bmatrix} 53 \\ 357 \end{bmatrix} = \begin{bmatrix} 0,19 \\ 0,929 \end{bmatrix}$$

$$\hat{\gamma}_1'X_1'Y = \begin{bmatrix} 0,19 & 0,929 \end{bmatrix} \begin{bmatrix} 53 \\ 357 \end{bmatrix} = 341,723$$

$$F = \frac{343,2733 - 341,723}{5,7267} \frac{6}{2} = 0,8121$$

$$F_{0,05}(2,6) = 5,14$$

como $F < F_\alpha$ no se puede rechazar H_0 .

Este contraste se suele presentar en una tabla de Análisis de Varianza.

ANALISIS DE VARIANZA

Fuente de Variación	Suma de los Cuadrados	Grados de Libertad
Total	$Y'Y - n\bar{Y}^2$	
$X_2 \dots \dots X_k$	$\hat{\beta}'X'Y - n\bar{Y}^2$	
$X_2 \dots \dots X_r$	$\hat{\gamma}'X_1'Y - n\bar{Y}^2$	
$X_{r+1} \dots \dots X_k$	$\hat{\beta}'X'Y - \hat{\gamma}'X_1'Y$	$k - r$
No Explicada	$e'e$	$n - k$

La tabla correspondiente al ejemplo es:

Fuente de Variación	Suma de los Cuadrados	Grados de Libertad
Total	$Y'Y = 349$	
X_2, X_3, X_4	$\hat{\beta}'X'Y = 343,2733 \quad (1)$	
X_3	$\hat{\gamma}'X_1'Y = 341,723 \quad (2)$	
X_2, X_4	$(1) - (2) = 1,55$	$k - r = 2$
No Explicada	$e'e = 5,7267$	$n - k = 6$

Obsérvese que en las sumas de los cuadrados no se toma en consideración la cantidad $n\bar{Y}^2$ puesto que aparece en todas las sumas y desaparece al calcular las diferencias.

Contraste de hipótesis sobre el Coeficiente de Determinación

Como se dijo anteriormente, este contraste se basa en el explicado en el punto anterior. En efecto, contrastar la hipótesis nula: $P^2 = 0$, equivale a contrastar la hipótesis de que toda las variables explicativas incluidas en la ecuación, consideradas en forma conjunta, no tienen influencia significativa en variable dependiente; en otras palabras, la hipótesis $P^2 = 0$, expresada en términos de los coeficientes del modelo, es:

$$H_0: \beta_2 = \beta_3 = \dots = \beta_k = 0$$

Consideremos el estadístico usado en el contraste explicado anteriormente:

$$F = \frac{\text{Suma explicada por las variables omitidas}}{\text{Suma no explicada por el modelo}} \frac{n - k}{k - r}$$

Al aplicarlo al caso que nos ocupa, las variables omitidas son todas las originalmente incluidas en el modelo, luego el numerador de la fracción es la suma explicada por el modelo (SEC) y r es uno, es decir,

$$F = \frac{SEC}{e'e} \frac{n - k}{k - 1}$$

Dividiendo numerador y denominador por la suma total de los cuadrados (STC), se tiene,

$$F = \frac{R^2}{1 - R^2} \frac{n - k}{k - 1} \quad (\text{Ver sección 2.6.1})$$

Si la variable F es mayor que $F_\alpha(k - 1, n - k)$ se rechaza la hipótesis nula $P^2 = 0$, con un nivel de significación de α .

EJEMPLO 15.8

Siguiendo con el ejemplo de la demanda,

$$F = \frac{0,9159}{1 - 0,9159} \frac{10 - 4}{4 - 1} = 21,78 \quad F_\alpha(3,6) = 4,76$$

Se rechaza la hipótesis nula, $P^2 = 0$.

El modelo, en forma conjunta explica suficientemente bien las variaciones de la variable.

Aunque al hacer este contraste se rechace la hipótesis nula, el R^2 puede ser demasiado pequeño y hacer el modelo poco útil. La magnitud relativa del coeficiente de determinación muestral para considerar aceptable un modelo queda a juicio del investigador o del usuario de la investigación; es decir, un $R^2 = 0,80$, por ejemplo, puede ser suficiente para unos y no para otros.

EJERCICIOS PROPUESTOS

15.1. Determine razonadamente la veracidad o falsedad de las siguientes afirmaciones:

- Si $\bar{R}^2$ aumenta al agregar una variable explicativa en un modelo, ésta influye en forma directa en la variable dependiente.
- Si todos los estimadores β_j son negativos en un modelo, el coeficiente de determinación será negativo.
- Las unidades en que se miden la variable dependiente y las independientes deben ser las mismas.
- Si el supuesto E (u_j) = 0 no se cumple, implica que los estimadores mínimo-cuadráticos no serán insesgados.

15.2. Determine razonadamente cuál de las respuestas es correcta en:

- En un modelo uniecuacional con una sola variable explicativa la Y está medida en millones de Bolívares y la X en miles de Bolívares. Entonces β_2 está medido en:

- (1) Miles de Bolívares;
- (2) Millones de Bolívares;
- (3) Millones de Bolívares por cada mil Bolívares;
- (4) Miles de Bolívares por cada millón;
- (5) En ninguna unidad concreta porque es un parámetro;
- (6) Ninguna de las anteriores.

- La condición $n \geq k$ es condición:

- (1) Necesaria;
 - (2) Suficiente;
 - (3) Necesaria y suficiente;
 - (4) Ni necesaria ni suficiente;
- para que el rango de $(X'X)$ sea igual a k.

- Cuanto en un modelo no se cumple el supuesto de homocedasticidad, $\text{Var}(u) = \Omega$. La matriz Ω :

- (1) Tendrá diferentes los elementos de la diagonal principal
- (2) Tendrá diferentes de cero los elementos fuera de la diagonal principal
- (3) Ambas afirmaciones (1), (2) son correctas
- (4) No será una matriz simétrica
- (5) Ninguna de las anteriores

15.3. Desarrolle las ecuaciones normales para el caso de k-1 variables explicativas en la expresión (6).

15.4. Derive los valores críticos y límites de los intervalos de confianza presentados en la página 542.

15.5. Usando las expresiones de las varianzas y covarianzas de los estimadores en el caso de dos variables (véase pág. 526), determine los límites de un intervalo de confianza del 100 $(1-\alpha)\%$ para β_2 y los valores críticos para contrastar la hipótesis $\beta_2 = 0$.

15.6. Dados los siguientes datos de tres variables:

Y	0	2	1	2	-1	1
X_2	-1	0	1	2	0	0
X_3	0	1	0	1	-1	0

- Calcular los estimadores.
- Calcular los errores standard de los estimadores.
- Calcular R^2 y $\bar{R}^2$.
- Presentar el modelo ajustado.
- Calcular intervalos de confianza del 95% para los coeficientes β_2 y β_3 .
- Contrastar las hipótesis $\beta_2 = 0$ y $\beta_3 = 0$ con $\alpha = 0,05$.
- Contrastar la hipótesis $\beta_3 \leq 1$ con $\alpha = 0,05$.

15.7. En el siguiente modelo uniecuacional

$$Y = X\beta + u$$

Y de orden 10×1 ; X de orden 10×5
se obtuvieron los siguientes resultados:
Suma de los cuadrados de los residuos: 40
 $\hat{\beta}_3 = 1$; $\hat{\beta}_5 = 6$; $\text{Var}(\hat{\beta}_5) = 3$

Se pide:

- ¿De qué orden es β ?
- ¿De qué orden es u ?
- Completar la matriz

$$(X'X)^{-1} \begin{pmatrix} 9 & 8 & 5 & 4 & 2 \\ & 5 & 3 & 1 & 6 \\ & & 0,2 & 2 & 7 \\ & & & 4 & 3 \end{pmatrix}$$

- iv) Calcular el estimador de la varianza de los términos de perturbación.
- v) Calcular el error standard de $\hat{\beta}_3$.
- vi) ¿Es la variable X_3 importante en la explicación de Y ?
- vii) ¿Es la variable X_4 importante en la explicación de Y ?

15.8. Se pretende describir en un modelo el comportamiento del producto interno real en Venezuela (YNR); el cual se hace depender de las siguientes variables: Gasto Fiscal interno real del período anterior (GFR); Liquidez monetaria en términos reales (LMR); exportaciones reales de petróleo e hierro (XTP) y Tasa de inflación (VCOV)³⁷. Las variables YNR, GFR, LMR, XTP están medidas en millones de bolívares. Los datos trimestrales de las variables son los siguientes:

Trimestre	YNR	LMR	GFR	XTP	VCOV
1974-01	11.840	19.146	5.165	3.050	0,055
1974-02	11.980	19.224	6.787	2.858	0,056
1974-03	12.290	18.952	3.670	2.950	0,112
1974-04	13.400	21.266	4.839	3.249	0,119
1975-01	12.990	22.770	7.029	2.317	0,121
1975-02	13.480	24.570	6.017	1.905	0,132
1975-03	14.300	25.363	3.676	1.845	0,079
1975-04	13.810	29.019	2.114	1.729	0,071
1976-01	13.930	28.614	7.779	1.343	0,069
1976-02	14.340	29.620	4.198	1.584	0,076
1976-03	15.240	29.655	4.640	1.704	0,082
1976-04	15.970	33.327	7.543	1.675	0,076
1977-01	16.360	33.804	4.220	2.362	0,084
1977-02	16.060	36.933	7.617	1.636	0,078
1977-03	15.680	35.666	5.170	1.802	0,075
1977-04	16.250	41.367	5.860	1.636	0,076
1978-01	16.410	38.098	4.139	1.943	0,075
1978-02	16.070	34.488	6.195	1.636	0,068
1978-03	17.420	39.250	5.141	1.595	0,070
1978-04	18.560	44.271	4.754	1.836	0,071
1979-01	16.760	39.751	6.236	2.514	0,076
1979-02	16.900	38.881	2.740	1.729	0,099
1979-03	16.560	38.796	4.088	1.846	0,126
1979-04	18.060	39.867	6.107	2.177	0,190
1980-01	16.840	37.898	3.435	2.102	0,218
1980-02	16.170	39.152	4.096	1.631	0,227
1980-03	17.110	39.019	4.020	1.513	0,217

Fuente: Banco de Datos del BCMOD

³⁷ León Sandoval, Inirida; La Interdependencia entre la Política Fiscal y la Política Monetaria en Venezuela. Memoria de Grado. Universidad Católica Andrés Bello. Caracas, 1981.

- i) Determinar la ecuación que relaciona el producto interno real con las variables explicativas.
- ii) Calcular el estimador de la varianza de los términos de perturbación.
- iii) Calcular los errores standard de los estimadores.
- iv) Calcular R^2 y $\bar{R}^2$.
- v) Construir intervalos de confianza para los coeficientes.
- vi) ¿Cuál es el significado de los coeficientes y en qué unidades están medidos?

15.9. Usando datos de Consumo e Ingreso en Venezuela para el período 1970-1990 estimar la función de consumo

$$C_i = \alpha + \beta Y_i + u_i$$

Hacer la estimación usando matrices y sin el uso de matrices.

15.10. En un modelo econométrico se hizo depender la demanda monetaria (Y_i) de tres variables explicativas: nivel de ingreso privado (X_{2i}), exportaciones (X_{3i}) y gasto público (X_{4i}); los resultados fueron los siguientes:

$$\hat{Y}_i = -1,029 + 0,785X_{2i} + 0,2703X_{3i} + 0,2638X_{4i}$$

$$(0,1641) \quad (0,5281) \quad (0,2301)$$

$$R^2 = 0,495; s = 0,6604; F(3,31) = 10,13$$

Cuando se hizo depender la demanda monetaria sólo del nivel de ingreso privado, se obtuvieron los siguientes resultados:

$$Y_i = 1,839 + 0,8298X_{2i}$$

$$(0,2503)$$

$$R^2 = 0,4725; s = 0,6543; F(1,33) = 29,56$$

- i) Considerando los resultados del primer modelo. ¿Qué opina Ud. de la siguiente afirmación?: El nivel de ingreso privado tiene influencia significativa en la demanda monetaria. $\alpha = 0,05$.
- ii) Comparando los resultados de los dos modelos, ¿Qué opina Ud. de la siguiente afirmación?: El segundo modelo es tan eficiente como el primero en la explicación de las variables de la demanda monetaria. $\alpha = 0,05$.

15.11. En una función de producción Cobb-Douglas, después de convertirla en lineal, se obtuvieron los siguientes resultados a partir de 15 observaciones de las variables:

$$\hat{Y}_i = 2,3542 + 0,9576 X_{2i} + 0,8242 X_{3i} \quad R^2 = 0,842$$

(0,3022) (0,3571)

donde las variables son los logaritmos neperianos de las variable originales, producto, trabajo y capital.

i) ¿Cree Ud. que el modelo explica satisfactoriamente las variaciones de la producción? ii) Contraste la hipótesis de que la elasticidad del producto del trabajo y capital individualmente consideradas son unitarias.

15.12. En un modelo se analizó una función de demanda de un bien:

$$D = \beta_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + u$$

siendo D = Cantidades demandadas en miles de unidades; X_2 = Ingreso per capita en miles de Bolívars; X_3 = Índice de precios del bien (1.973 = 100); X_4 = Índice de precios de un bien substitutivo (1973 = 100). Se ajustó el modelo a las observaciones anuales de las variables desde 1.973 a 1.992 y se obtuvieron los siguientes resultados:

$$\hat{D} = 1,46 + 0,18X_2 - 0,37X_3 + 0,12X_4$$

(0,13) (0,16) (0,16)

$$R^2 = 0,69; \quad s = 0,159; \quad F = 11,87; \quad Y'Y = 40$$

Dé su opinión acerca de las siguientes afirmaciones: i) Un incremento unitario en el índice de precios del bien provoca, ceteris paribus, una disminución en la cantidad demandada de por lo menos 500 unidades. ii) Los precios del bien substitutivo no tienen influencia significativa en la demanda. $\alpha = 0,05$.


15.13. Para explicar el comportamiento de la demanda en el caso anterior, otro investigador utilizó sólo como variable explicativa el índice de precios del bien y obtuvo los siguientes resultados:

$$\hat{D} = 2,3 - 0,40X_3 \quad s = 0,22$$

¿Cree Ud. que este modelo explica las variaciones de la demanda tan eficientemente como el anterior? $\alpha = 0,05$.

RESULTADOS DEL EJEMPLO OBTENIDOS EN EL PROGRAMA EVIEWS

LS // Dependent Variable is Y				
Date: 04/24/96 Time: 10:57				
Sample: 1 10				
Included observations: 10				
Variable	Coefficient	Std. Error	T-Statistic	Prob.
X2	0.130039	0.271710	0.478595	0.6492
X3	0.625487	0.269424	2.321568	0.0593
X4	-0.370413	0.294343	-1.258441	0.2550
C	3.083370	2.416608	1.275908	0.2492
R-squared	0.915839	Mean dependent var	5.300000	
Adjusted R-squared	0.873758	S.D. dependent var	2.750757	
S.E. of regression	0.977358	Akaike info criterion	0.243370	
Sum squared resid	5.731374	Schwartz criterion	0.364404	
Log likelihood	-11.40624	F-statistic	21.76394	
Durbin-Watson stat	2.247110	Prob(F-statistic)	0.001262	




APENDICE A

TABLAS


- I.- DISTRIBUCION NORMAL
- II.- DISTRIBUCION χ^2
- III.- DISTRIBUCION t
- IV.- DISTRIBUCION F
- V.- CONTRASTE KOLMOGOROV-SMIRNOV

TABLA I
AREAS BAJO LA CURVA DE LA DISTRIBUCION NORMAL CON $\mu = 0$ y $\sigma^2 = 1$



z_0	.00	.01	.02	.03	.04	.05	.06	.07	.08	.09
.0	.5000	.5040	.5080	.5120	.5160	.5199	.5239	.5279	.5319	.5359
.1	.5398	.5438	.5478	.5517	.5557	.5596	.5636	.5675	.5714	.5753
.2	.5793	.5832	.5871	.5910	.5948	.5987	.6026	.6064	.6103	.6141
.3	.6179	.6217	.6255	.6293	.6331	.6368	.6406	.6443	.6480	.6517
.4	.6554	.6591	.6628	.6664	.6700	.6736	.6772	.6808	.6844	.6879
.5	.6915	.6950	.6985	.7019	.7054	.7088	.7123	.7157	.7190	.7224
.6	.7257	.7291	.7324	.7357	.7389	.7422	.7454	.7486	.7517	.7549
.7	.7580	.7611	.7642	.7673	.7704	.7734	.7764	.7794	.7823	.7852
.8	.7881	.7910	.7939	.7967	.7995	.8023	.8051	.8078	.8106	.8133
.9	.8159	.8186	.8212	.8238	.8264	.8289	.8315	.8340	.8365	.8389
1.0	.8413	.8438	.8461	.8485	.8508	.8531	.8554	.8577	.8599	.8621
1.1	.8643	.8665	.8686	.8708	.8729	.8749	.8770	.8790	.8810	.8830
1.2	.8849	.8869	.8888	.8907	.8925	.8944	.8962	.8980	.8997	.9015
1.3	.9032	.9049	.9066	.9082	.9099	.9115	.9131	.9147	.9162	.9177
1.4	.9192	.9207	.9222	.9236	.9251	.9265	.9279	.9292	.9306	.9319
1.5	.9332	.9345	.9357	.9370	.9382	.9394	.9406	.9418	.9429	.9441
1.6	.9452	.9463	.9474	.9484	.9495	.9505	.9515	.9525	.9535	.9545
1.7	.9554	.9564	.9573	.9582	.9591	.9599	.9608	.9616	.9625	.9633
1.8	.9641	.9649	.9656	.9664	.9671	.9678	.9686	.9693	.9699	.9706
1.9	.9713	.9719	.9726	.9732	.9738	.9744	.9750	.9756	.9761	.9767
2.0	.9772	.9778	.9783	.9788	.9793	.9798	.9803	.9808	.9812	.9817
2.1	.9821	.9826	.9830	.9834	.9838	.9842	.9846	.9850	.9854	.9857
2.2	.9861	.9864	.9868	.9871	.9875	.9878	.9881	.9884	.9887	.9890
2.3	.9893	.9896	.9898	.9901	.9904	.9906	.9909	.9911	.9913	.9916
2.4	.9918	.9920	.9922	.9925	.9927	.9929	.9931	.9932	.9934	.9936
2.5	.9938	.9940	.9941	.9943	.9945	.9946	.9948	.9949	.9951	.9952
2.6	.9953	.9955	.9956	.9957	.9959	.9960	.9961	.9962	.9963	.9964
2.7	.9965	.9966	.9967	.9968	.9969	.9970	.9971	.9972	.9973	.9974
2.8	.9974	.9975	.9976	.9977	.9977	.9978	.9979	.9979	.9980	.9981
2.9	.9981	.9982	.9982	.9983	.9984	.9984	.9985	.9985	.9986	.9986
3.0	.9987	.9987	.9987	.9988	.9988	.9989	.9989	.9989	.9990	.9990
3.1	.9990	.9991	.9991	.9991	.9992	.9992	.9992	.9992	.9993	.9993
3.2	.9993	.9993	.9994	.9994	.9994	.9994	.9994	.9995	.9995	.9995
3.3	.9995	.9995	.9995	.9996	.9996	.9996	.9996	.9996	.9996	.9997
3.4	.9997	.9997	.9997	.9997	.9997	.9997	.9997	.9997	.9997	.9998

$> 3.49 = 1$



$\begin{matrix} F(x_0^2) \\ n \end{matrix}$	.005	.010	.025	.050	.100	.250	.500	.750	.900	.950	.975	.990	.995
1	.00393	.00757	.01582	.03083	.0540	.102	.455	1.32	2.71	3.84	5.02	6.63	7.88
2	.0100	.0201	.0406	.0738	.103	.211	.575	1.39	2.77	4.61	5.99	7.38	10.6
3	.0157	.0311	.0616	.1013	.148	.271	.584	1.21	2.37	4.11	5.49	6.94	12.84
4	.0207	.0410	.0821	.1358	.193	.284	.594	1.06	2.20	3.75	5.19	6.75	14.86
5	.0256	.0507	.1013	.1675	.236	.300	.604	1.00	2.10	3.64	5.02	6.63	16.75
6	.0299	.0599	.1199	.1928	.269	.327	.614	.935	2.00	3.54	4.90	6.58	18.55
7	.0344	.0687	.1393	.2237	.308	.371	.624	.879	1.92	3.43	4.78	6.45	20.3
8	.0389	.0778	.1585	.2518	.340	.408	.634	.833	1.85	3.36	4.67	6.33	22.0
9	.0435	.0871	.1774	.2799	.372	.445	.644	.797	1.78	3.29	4.57	6.21	23.6
10	.0479	.0963	.1961	.3083	.394	.473	.654	.759	1.71	3.22	4.48	6.10	25.2
11	.0524	.1056	.2146	.3370	.426	.509	.664	.723	1.64	3.15	4.39	5.99	26.8
12	.0569	.1149	.2330	.3658	.458	.545	.674	.693	1.57	3.08	4.30	5.88	28.3
13	.0614	.1242	.2515	.3946	.490	.581	.684	.663	1.50	3.01	4.21	5.77	29.8
14	.0659	.1335	.2700	.4234	.522	.616	.694	.643	1.43	2.94	4.12	5.66	31.3
15	.0704	.1428	.2885	.4522	.554	.649	.704	.613	1.36	2.87	4.03	5.55	32.8
16	.0749	.1521	.3070	.4810	.586	.685	.724	.583	1.29	2.80	3.94	5.44	34.3
17	.0794	.1614	.3255	.5098	.618	.719	.744	.553	1.22	2.73	3.85	5.33	35.7

$\begin{matrix} F(x_0^2) \\ n \end{matrix}$	.005	.010	.025	.050	.100	.250	.500	.750	.900	.950	.975	.990	.995
18	6.26	7.01	8.23	9.39	10.86	13.68	17.34	21.6	26.0	28.9	31.5	34.8	37.2
19	6.84	7.63	8.91	10.12	11.65	14.56	18.34	22.7	27.2	30.1	32.9	36.2	38.6
20	7.43	8.26	9.59	10.85	12.44	15.45	19.34	23.8	28.4	31.4	34.2	37.6	40.0
21	8.03	8.90	10.28	11.59	13.24	16.34	20.3	24.9	29.6	32.7	35.5	38.9	41.4
22	8.64	9.54	10.98	12.34	14.04	17.24	21.3	26.0	30.8	33.9	36.8	40.3	42.8
23	9.26	10.20	11.69	13.09	14.85	18.14	22.3	27.1	32.0	35.2	38.1	41.6	44.2
24	9.89	10.86	12.40	13.85	15.66	19.04	23.3	28.2	33.2	36.4	39.4	43.0	45.6
25	10.52	11.52	13.12	14.61	16.47	19.94	24.3	29.3	34.4	37.7	40.6	44.3	46.9
26	11.16	12.20	13.84	15.38	17.29	20.8	25.3	30.4	35.6	38.9	41.9	45.6	48.3
27	11.81	12.88	14.57	16.15	18.11	21.7	26.3	31.5	36.7	40.1	43.2	47.0	49.6
28	12.46	13.56	15.31	16.93	18.94	22.7	27.3	32.6	37.9	41.3	44.5	48.3	51.0
29	13.12	14.26	16.05	17.71	19.77	23.6	28.3	33.7	39.1	42.6	45.7	49.6	52.3
30	13.79	14.95	16.79	18.49	20.6	24.5	29.3	34.8	40.3	43.8	47.0	50.9	53.7
40	20.7	22.2	24.4	26.5	29.1	33.7	39.3	45.6	51.8	55.8	59.3	63.7	66.8
50	28.0	29.7	32.4	34.8	37.7	42.9	49.3	56.3	63.2	67.5	71.4	76.2	79.5
60	35.5	37.5	40.5	43.2	46.5	52.3	59.3	67.0	74.4	79.1	83.3	88.4	92.0
70	43.3	45.4	48.8	51.7	55.3	61.7	69.3	77.6	85.5	90.5	95.0	100.4	104.2
80	51.2	53.5	57.2	60.4	64.3	71.1	79.3	88.1	96.6	101.9	106.6	112.3	116.3
90	59.2	61.8	65.6	69.1	73.3	80.6	89.3	98.6	107.6	113.1	118.1	124.1	128.3
100	67.3	70.1	74.2	77.9	82.4	90.1	99.3	109.1	118.5	124.3	129.6	135.8	140.2


TABLA III
AREAS DEBAJO DE LA CURVA DE LA DISTRIBUCION "t"
DE STUDENT CON n GRADOS DE LIBERTAD



$F(t_0)$ n	.75	.90	.95	.975	.99	.995	.9995
1	1.000	3.078	6.314	12.706	31.821	63.657	636.619
2	.816	1.886	2.920	4.303	6.965	9.925	31.598
3	.765	1.638	2.353	3.182	4.541	5.841	12.941
4	.741	1.533	2.132	2.776	3.747	4.604	8.610
5	.727	1.476	2.015	2.571	3.365	4.032	6.859
6	.718	1.440	1.943	2.447	3.143	3.707	5.959
7	.711	1.415	1.895	2.365	2.998	3.499	5.405
8	.706	1.397	1.860	2.306	2.896	3.355	5.041
9	.703	1.383	1.833	2.262	2.821	3.250	4.781
10	.700	1.372	1.812	2.228	2.764	3.169	4.587
11	.697	1.363	1.796	2.201	2.718	3.106	4.437
12	.695	1.356	1.782	2.179	2.681	3.055	4.318
13	.694	1.350	1.771	2.160	2.650	3.012	4.221
14	.692	1.345	1.761	2.145	2.624	2.977	4.140
15	.691	1.341	1.753	2.131	2.602	2.947	4.073
16	.690	1.337	1.746	2.120	2.583	2.921	4.015
17	.689	1.333	1.740	2.110	2.567	2.898	3.965
18	.688	1.330	1.734	2.101	2.552	2.878	3.922
19	.688	1.328	1.729	2.093	2.539	2.861	3.883
20	.687	1.325	1.725	2.086	2.528	2.845	3.850
21	.686	1.323	1.721	2.080	2.518	2.831	3.819
22	.686	1.321	1.717	2.074	2.508	2.819	3.792
23	.685	1.319	1.714	2.069	2.500	2.807	3.767
24	.685	1.318	1.711	2.064	2.492	2.797	3.745
25	.684	1.316	1.708	2.060	2.485	2.787	3.725
26	.684	1.315	1.706	2.056	2.479	2.779	3.707
27	.684	1.314	1.703	2.052	2.473	2.771	3.690
28	.683	1.313	1.701	2.048	2.467	2.763	3.674
29	.683	1.311	1.699	2.045	2.462	2.756	3.659
30	.683	1.310	1.697	2.042	2.457	2.750	3.646
40	.681	1.303	1.684	2.021	2.423	2.704	3.551
60	.679	1.296	1.671	2.000	2.390	2.660	3.460
120	.677	1.289	1.658	1.980	2.358	2.617	3.373
∞	.674	1.282	1.645	1.960	2.326	2.576	3.291

TABLA IV

AREAS A LA IZQUIERDA, DEBAJO DE LA CURVA F CON m GRADOS DE
LIBERTAD EN EL NUMERADOR Y n GRADOS DE LIBERTAD
EN EL DENOMINADOR



Area	n m	1	2	3	4	5	6	7	8	9	10	12	15	20	30	60	120	∞
0.90	1	39.9	49.5	53.6	55.8	57.2	58.2	58.9	59.4	59.9	60.2	60.7	61.2	61.7	62.3	62.8	63.1	63.3
0.95		161	200	216	225	230	234	237	239	241	242	244	246	248	250	252	253	254
0.975		648	800	864	900	922	937	948	957	963	969	977	985	993	1000	1010	1010	1020
0.99		4050	5000	5400	5620	5760	5860	5930	5980	6020	6060	6110	6160	6210	6260	6310	6340	6370
0.995		16200	20000	21600	22500	23100	23400	23700	23900	24100	24200	24400	24600	24800	25000	25200	25400	25500
0.90	2	8.53	9.00	9.16	9.24	9.29	9.33	9.35	9.37	9.38	9.39	9.41	9.42	9.44	9.46	9.47	9.48	9.49
0.95		18.5	19.0	19.2	19.2	19.3	19.3	19.4	19.4	19.4	19.4	19.4	19.4	19.5	19.5	19.5	19.5	19.5
0.975		38.5	39.0	39.2	39.2	39.3	39.3	39.4	39.4	39.4	39.4	39.4	39.4	39.4	39.5	39.5	39.5	39.5
0.99		98.5	99.0	99.2	99.2	99.3	99.3	99.4	99.4	99.4	99.4	99.4	99.4	99.4	99.5	99.5	99.5	99.5
0.995		199	199	199	199	199	199	199	199	199	199	199	199	199	199	199	199	199
0.90	3	5.54	5.46	5.39	5.34	5.31	5.28	5.27	5.25	5.24	5.23	5.22	5.20	5.18	5.17	5.15	5.14	5.13
0.95		10.1	9.55	9.28	9.12	9.01	8.94	8.89	8.85	8.81	8.79	8.74	8.70	8.66	8.62	8.57	8.55	8.53
0.975		17.4	16.0	15.4	15.1	14.9	14.7	14.6	14.5	14.5	14.4	14.3	14.3	14.2	14.1	14.0	13.9	13.9
0.99		34.1	30.8	29.5	28.7	28.2	27.9	27.7	27.5	27.3	27.2	27.1	26.9	26.7	26.5	26.3	26.2	26.1
0.995		55.6	49.8	47.5	46.2	45.4	44.8	44.4	44.1	43.9	43.7	43.4	43.1	42.8	42.5	42.1	42.0	41.8
0.90	4	4.54	4.32	4.19	4.11	4.05	4.01	3.98	3.95	3.93	3.92	3.90	3.87	3.84	3.82	3.79	3.78	3.76
0.95		7.71	6.94	6.59	6.39	6.26	6.16	6.09	6.04	6.00	5.96	5.91	5.86	5.80	5.75	5.69	5.66	5.63
0.975		12.2	10.6	9.98	9.60	9.36	9.20	9.07	8.98	8.90	8.84	8.75	8.66	8.56	8.46	8.36	8.31	8.26
0.99		21.2	18.0	16.7	16.0	15.5	15.2	15.0	14.8	14.7	14.5	14.4	14.2	14.0	13.8	13.7	13.6	13.5
0.995		31.3	26.3	24.3	23.2	22.5	22.0	21.6	21.4	21.1	21.0	20.7	20.4	20.2	19.9	19.6	19.5	19.3
0.90	5	4.06	3.78	3.62	3.52	3.45	3.40	3.37	3.34	3.32	3.30	3.27	3.24	3.21	3.17	3.14	3.12	3.11
0.95		6.61	5.79	5.41	5.19	5.05	4.95	4.88	4.82	4.77	4.74	4.68	4.62	4.56	4.50	4.43	4.40	4.37
0.975		10.0	8.43	7.76	7.39	7.15	6.98	6.85	6.76	6.68	6.62	6.52	6.43	6.33	6.23	6.12	6.07	6.02
0.99		16.3	13.3	12.1	11.4	11.0	10.7	10.5	10.3	10.2	10.1	9.89	9.72	9.55	9.38	9.20	9.11	9.02
0.995		22.8	18.3	16.5	15.6	14.9	14.5	14.2	14.0	13.8	13.6	13.4	13.1	12.9	12.7	12.4	12.3	12.1
0.90	6	3.78	3.46	3.29	3.18	3.11	3.05	3.01	2.98	2.96	2.94	2.90	2.87	2.84	2.80	2.76	2.74	2.72
0.95		5.99	5.14	4.76	4.53	4.39	4.28	4.21	4.15	4.10	4.06	4.00	3.94	3.87	3.81	3.74	3.70	3.67
0.975		8.81	7.26	6.60	6.23	5.99	5.82	5.70	5.60	5.52	5.46	5.37	5.27	5.17	5.07	4.96	4.90	4.85
0.99		13.7	10.9	9.78	9.15	8.75	8.47	8.26	8.10	7.98	7.87	7.72	7.56	7.40	7.23	7.06	6.97	6.88
0.995		18.6	14.5	12.9	12.0	11.5	11.1	10.8	10.6	10.4	10.2	10.0	9.81	9.59	9.36	9.12	9.00	8.88

Area	n m	1	2	3	4	5	6	7	8	9	10	12	15	20	30	60	120	∞
0.90	7	3.59	3.26	3.07	2.96	2.88	2.83	2.78	2.75	2.72	2.70	2.67	2.63	2.59	2.56	2.51	2.49	2.47
0.95		5.59	4.74	4.35	4.12	3.97	3.87	3.79	3.73	3.68	3.64	3.57	3.51	3.44	3.38	3.30	3.27	3.23
0.975		8.07	6.54	5.89	5.52	5.29	5.12	4.99	4.90	4.82	4.76	4.67	4.57	4.47	4.36	4.25	4.20	4.14
0.99		12.2	9.55	8.45	7.85	7.46	7.19	6.99	6.84	6.72	6.62	6.47	6.31	6.16	5.99	5.82	5.74	5.65
0.995		16.2	12.4	10.9	10.1	9.52	9.16	8.89	8.68	8.51	8.38	8.18	7.97	7.75	7.53	7.31	7.19	7.08
0.90	8	3.46	3.11	2.92	2.81	2.73	2.67	2.62	2.59	2.56	2.54	2.50	2.46	2.42	2.38	2.34	2.31	2.29
0.95		5.32	4.46	4.07	3.84	3.69	3.58	3.50	3.44	3.39	3.35	3.28	3.22	3.15	3.08	3.01	2.97	2.93
0.975		7.57	6.06	5.42	5.05	4.82	4.65	4.53	4.43	4.36	4.30	4.20	4.10	4.00	3.89	3.78	3.73	3.67
0.99		11.3	8.65	7.59	7.01	6.63	6.37	6.18	6.03	5.91	5.81	5.67	5.52	5.36	5.20	5.03	4.95	4.86
0.995		14.7	11.0	9.60	8.81	8.30	7.95	7.69	7.50	7.34	7.21	7.01	6.81	6.61	6.40	6.18	6.06	5.95
0.90	9	3.36	3.01	2.81	2.69	2.61	2.55	2.51	2.47	2.44	2.42	2.38	2.34	2.30	2.25	2.21	2.18	2.16
0.95		5.12	4.26	3.86	3.63	3.48	3.37	3.29	3.23	3.18	3.14	3.07	3.01	2.94	2.86	2.79	2.75	2.71
0.975		7.21	5.71	5.08	4.72	4.48	4.32	4.20	4.10	4.03	3.96	3.87	3.77	3.67	3.56	3.45	3.39	3.33
0.99		10.6	8.02	6.99	6.42	6.06	5.80	5.61	5.47	5.35	5.26	5.11	4.96	4.81	4.65	4.48	4.40	4.31
0.995		13.6	10.1	8.72	7.96	7.47	7.13	6.88	6.69	6.54	6.42	6.23	6.03	5.83	5.62	5.41	5.30	5.19
0.90	10	3.29	2.92	2.73	2.61	2.52	2.46	2.41	2.38	2.35	2.32	2.28	2.24	2.20	2.15	2.11	2.08	2.06
0.95		4.96	4.10	3.71	3.48	3.33	3.22	3.14	3.07	3.02	2.98	2.91	2.84	2.77	2.70	2.62	2.58	2.54
0.975		6.94	5.46	4.83	4.47	4.24	4.07	3.95	3.85	3.78	3.72	3.62	3.52	3.42	3.31	3.20	3.14	3.08
0.99		10.0	7.56	6.55	5.99	5.64	5.39	5.20	5.06	4.94	4.85	4.71	4.56	4.41	4.25	4.08	4.00	3.91
0.995		12.8	9.43	8.08	7.34	6.87	6.54	6.30	6.12	5.97	5.85	5.66	5.47	5.27	5.07	4.86	4.75	4.64
0.90	12	3.18	2.81	2.61	2.48	2.39	2.33	2.28	2.24	2.21	2.19	2.15	2.10	2.06	2.01	1.96	1.93	1.90
0.95		4.75	3.89	3.49	3.26	3.11	3.00	2.91	2.85	2.80	2.75	2.69	2.62	2.54	2.47	2.38	2.34	2.30
0.975		6.55	5.10	4.47	4.12	3.89	3.73	3.61	3.51	3.44	3.37	3.28	3.18	3.07	2.96	2.85	2.79	2.72
0.99		9.33	6.93	5.95	5.41	5.06	4.82	4.64	4.50	4.39	4.30	4.16	4.01	3.86	3.70	3.54	3.45	3.36
0.995		11.8	8.51	7.23	6.52	6.07	5.76	5.52	5.35	5.20	5.09	4.91	4.72	4.53	4.33	4.12	4.01	3.90
0.90	15	3.07	2.70	2.49	2.36	2.27	2.21	2.16	2.12	2.09	2.06	2.02	1.97	1.92	1.87	1.82	1.79	1.76
0.95		4.54	3.68	3.29	3.06	2.90	2.79	2.71	2.64	2.59	2.54	2.48	2.40	2.33	2.25	2.16	2.11	2.07
0.975		6.20	4.77	4.15	3.80	3.58	3.41	3.29	3.20	3.12	3.06	2.96	2.86	2.76	2.64	2.52	2.46	2.40
0.99		8.68	6.36	5.42	4.89	4.56	4.32	4.14	4.00	3.89	3.80	3.67	3.52	3.37	3.21	3.05	2.96	2.87
0.995		10.8	7.70	6.48	5.80	5.37	5.07	4.85	4.67	4.54	4.42	4.25	4.07	3.88	3.69	3.48	3.37	3.26

Area	n m	1	2	3	4	5	6	7	8	9	10	12	15	20	30	60	120	∞
0.90	20	2.97	2.59	2.38	2.25	2.16	2.09	2.04	2.00	1.96	1.94	1.89	1.84	1.79	1.74	1.68	1.64	1.61
0.95		4.35	3.49	3.10	2.87	2.71	2.60	2.51	2.45	2.39	2.35	2.28	2.20	2.12	2.04	1.95	1.90	1.84
0.975		5.87	4.46	3.86	3.51	3.29	3.13	3.01	2.91	2.84	2.77	2.68	2.57	2.46	2.35	2.22	2.16	2.09
0.99		8.10	5.85	4.94	4.43	4.10	3.87	3.70	3.56	3.46	3.37	3.23	3.09	2.94	2.78	2.61	2.52	2.42
0.995		9.94	6.99	5.82	5.17	4.76	4.47	4.26	4.09	3.96	3.85	3.68	3.50	3.32	3.12	2.92	2.81	2.69
0.90	30	2.88	2.49	2.28	2.14	2.05	1.98	1.93	1.88	1.85	1.82	1.77	1.72	1.67	1.61	1.54	1.50	1.46
0.95		4.17	3.32	2.92	2.69	2.53	2.42	2.33	2.27	2.21	2.16	2.09	2.01	1.93	1.84	1.74	1.68	1.62
0.975		5.57	4.18	3.59	3.25	3.03	2.87	2.75	2.65	2.57	2.51	2.41	2.31	2.20	2.07	1.94	1.87	1.79
0.99		7.56	5.39	4.51	4.02	3.70	3.47	3.30	3.17	3.07	2.98	2.84	2.70	2.55	2.39	2.21	2.11	2.01
0.995		9.18	6.35	5.24	4.62	4.23	3.95	3.74	3.58	3.45	3.34	3.18	3.01	2.82	2.63	2.42	2.30	2.18
0.90	60	2.79	2.39	2.18	2.04	1.95	1.87	1.82	1.77	1.74	1.71	1.66	1.60	1.54	1.48	1.40	1.35	1.29
0.95		4.00	3.15	2.76	2.53	2.37	2.25	2.17	2.10	2.04	1.99	1.92	1.84	1.75	1.65	1.53	1.47	1.39
0.975		5.29	3.93	3.34	3.01	2.79	2.63	2.51	2.41	2.33	2.27	2.17	2.06	1.94	1.82	1.67	1.58	1.58
0.99		7.08	4.98	4.13	3.65	3.34	3.12	2.95	2.82	2.72	2.63	2.50	2.35	2.20	2.03	1.84	1.74	1.60
0.975		8.49	5.80	4.73	4.14	3.76	3.49	3.29	3.13	3.01	2.90	2.74	2.57	2.39	2.19	1.96	1.83	1.69
0.90	120	2.75	2.35	2.13	1.99	1.90	1.82	1.77	1.72	1.68	1.65	1.60	1.54	1.48	1.41	1.32	1.26	1.19
0.95		3.92	3.07	2.68	2.45	2.29	2.18	2.09	2.02	1.96	1.91	1.83	1.75	1.66	1.55	1.43	1.35	1.25
0.975		5.15	3.80	3.23	2.89	2.67	2.52	2.39	2.30	2.22	2.16	2.05	1.94	1.82	1.69	1.53	1.43	1.31
0.99		6.85	4.79	3.95	3.48	3.17	2.96	2.79	2.66	2.56	2.47	2.34	2.19	2.03	1.86	1.66	1.53	1.38
0.995		8.18	5.54	4.50	3.92	3.55	3.28	3.09	2.93	2.81	2.71	2.54	2.37	2.19	1.98	1.75	1.61	1.43
0.90	∞	2.71	2.30	2.08	1.94	1.85	1.77	1.72	1.67	1.63	1.60	1.55	1.49	1.42	1.34	1.24	1.17	1.00
0.95		3.84	3.00	2.60	2.37	2.21	2.10	2.01	1.94	1.88	1.83	1.75	1.67	1.57	1.46	1.32	1.22	1.00
0.975		5.02	3.69	3.12	2.79	2.57	2.41	2.29	2.19	2.11	2.05	1.94	1.83	1.71	1.57	1.39	1.27	1.00
0.99		6.63	4.61	3.78	3.32	3.02	2.80	2.64	2.51	2.41	2.32	2.18	2.04	1.88	1.70	1.47	1.32	1.00
0.995		7.88	5.30	4.28	3.72	3.35	3.09	2.90	2.74	2.62	2.52	2.36	2.19	2.00	1.79	1.53	1.36	1.00

TABLA V
VALORES CRITICOS (D_n) PARA EL CONTRASTE
KOLMOGOROV-SMIRNOV

n/α	0.20	0.10	0.05	0.01
1	0.90	0.95	0.98	1.00
2	0.68	0.78	0.84	0.93
3	0.57	0.64	0.71	0.83
4	0.49	0.56	0.62	0.73
5	0.45	0.51	0.56	0.67
6	0.41	0.47	0.52	0.62
7	0.38	0.44	0.49	0.58
8	0.36	0.41	0.46	0.54
9	0.34	0.39	0.43	0.51
10	0.32	0.37	0.41	0.49
11	0.31	0.35	0.39	0.47
12	0.30	0.34	0.38	0.45
13	0.28	0.33	0.36	0.43
14	0.27	0.31	0.35	0.42
15	0.27	0.30	0.34	0.40
16	0.26	0.30	0.33	0.39
17	0.25	0.29	0.32	0.38
18	0.24	0.28	0.31	0.37
19	0.24	0.27	0.30	0.36
20	0.23	0.26	0.29	0.35
25	0.21	0.24	0.26	0.32
30	0.19	0.22	0.24	0.29
35	0.18	0.21	0.23	0.27
40	0.17	0.19	0.21	0.25
45	0.16	0.18	0.20	0.24
50	0.15	0.17	0.19	0.23
60		0.17	0.17	0.21
70			0.16	0.19
80			0.15	
90			0.14	0.18
100			0.14	

Valores grandes de n

$\frac{1.07}{\sqrt{n}}$ $\frac{1.22}{\sqrt{n}}$ $\frac{1.36}{\sqrt{n}}$ $\frac{1.63}{\sqrt{n}}$

RESPUESTAS DE LOS EJERCICIOS PROPUESTOS

CAPITULO I

- 1.8. $P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) - P(B \cap C) + P(A \cap B \cap C)$
- 1.9. i) 9/50; ii) 6/25; iii) 14/25; iv) 1/50
- 1.10. i) 1; ii) 41/50; iii) 29/50; iv) 1/50
- 1.11. i) 9/50; ii) 21/50; iii) 49/50; iv) 1
- 1.12. 1/6
- 1.13. 5/6
- 1.14. 2/3
- 1.15. i) 19/21; ii) 6/7; iii) 21/42; iv) 11/42; v) 19/21; vi) 1/7
- 1.16. i) 1/6; ii) 2/3
- 1.17. 0,11
- 1.18. i) 1/2; ii) 11/12
- 1.19. i) 1/9; ii) 37/108
- 1.20. i) 2/9; ii) 2/15; iii) 1/9.
- 1.21. i) 1/6; ii) 2/9; iii) 0; iv) 1/5
- 1.22. i) 32/371; 15/371; ii) 59/371; 60/371; iii) 16/41, 23/70.
- 1.23. 1/16; 2/16; 3/16; 4/16; 3/16; 2/16; 1/16.
- 1.24. 5/13
- 1.25. 2/1.001
- 1.26. 707/1.001
- 1.27. i) 0,094; ii) 0,333; iii) 0,385

- 1.28. 0,183
 1.29. i) 1/1.184.040; ii) 0,0394; iii) 0,2687
 1.30. 0,25
 1.31. i) 1/216; ii) 5/18
 1.32. 2/105
 1.33. 0,5
 1.34. 0,84
 1.35. Si
 1.36. No
 1.37. i) 9/20; ii, iii) 0,75
 1.38. i) 3/8; ii) 0,3415; iii) 2/7; iv) 0,3137; v) No
 1.39. 0,53
 1.40. i) 1/2 ó 1/3; ii) 1/3 ó 1/2
 1.41. i) 0,5; ii) 1/3
 1.42. 0,33; 0,6255; 0,044
 1.43. 1/720

CAPITULO II

- 2.8. i) $f(x) = 1/10$ para $x = 7, 8, 12, 13$
 $= 2/10$ para $x = 9, 10, 11$
 iv) 10; v) 3
 2.9. 3/4
 2.10. i) $3/4 - e^k$; ii) 1/3, 4/9
 2.11. i) 3/256; ii) 63/64; iii) 1/4.096; iv) 15/65.536
 2.12. 800.000
 2.13. i) 6; ii) $F(x) = 0$ para $x < 0$
 $= 3x^2 - 2x^3$ para $x \leq x \leq 1$
 $= 1$ para $x > 1$
 2.14. i) 0,5; ii) 1/20; iii) 0; iv) 0,5; v, vi) 0,15625
 2.15. i) 3/8; ii) $F(x) = 0$ para $x < 0$
 $= \frac{3}{4}x^2 - \frac{1}{4}x^3$ para $0 \leq x \leq 2$
 $= 1$ para $x > 2$
 iv) 1, 1/5

- 2.16. 9
 2.17. i) 37/8; ii) 71/4; iii) 45/8
 2.18. i) 1/25; ii) $F(x) = 0$ para $x < 0$
 $= x^2/50$ para $0 < x < 5$
 $= -\frac{x^2}{50} + \frac{2}{5}x - 1$ para $5 < x < 10$
 $= 1$ para $x > 10$
 iv) 5, 25/6
 2.19. i) 1/8; ii) $F(x) = 0$ para $x < 0$
 $= \frac{1}{2}x - \frac{1}{16}x^2$ para $0 < x < 4$
 $= 1$ para $x > 4$
 iv) 4/3, 8/9

- 2.20. 3/8, 1/8
 2.21. i) 1/100; ii) $F(x) = 0$ para $x < -100$
 $= \frac{x^2}{20.000} + \frac{x}{100} + \frac{1}{2}$ para $-100 < x < 0$
 $= -\frac{x^2}{20.000} + \frac{x}{100} + \frac{1}{2}$ para $0 < x < 100$
 $= 1$ para $x > 100$
 iv) 0, 5.000/3
 2.22. i) 1; ii) $F(x) = 0$ para $x < 0$
 $= x$ para $0 < x < 1$
 $= 1$ para $x > 1$
 iv) 1/2; 1/12

$$\begin{aligned}
 2.23. \text{ i) } F(x) &= 0 && \text{para } x < 0 \\
 &= x^2/2 && \text{para } 0 < x < 1 \\
 &= -x^2/2 + 2x - 1 && \text{para } 1 < x < 2 \\
 &= 1 && \text{para } x > 2
 \end{aligned}$$

iv) 1, 1/6

$$\begin{aligned}
 2.24. f(x) &= 2x && \text{para } 0 < x < 1 \\
 &= 0 && \text{para cualquier otro valor de } x
 \end{aligned}$$

$$2.25. \text{ i) } f(x) = \frac{1}{2}x^2 \quad \text{para } 0 < x < 1$$

$$= -x^2 + 3x - \frac{3}{2} \quad \text{para } 1 < x < 2$$

$$= \frac{1}{2}x^2 - 3x + \frac{9}{2} \quad \text{para } 2 < x < 3$$

$$= 0 \quad \text{para cualquier otro valor de } x$$

$$2.26. c = 6; a = 1$$

$$2.27. c = 5; a = 1$$

$$2.28. \text{ i) } 1/2.500; \text{ ii) } F(x) = 0 \quad \text{para } x < 1$$

$$= \frac{(1+x)x}{5.000} \quad \text{para } x = 1, 2, \dots, 50$$

$$= \frac{2.550 + (149-x)(x-50)}{5.000} \quad \text{para } x = 51, 52, \dots, 100$$

$$= 1 \quad \text{para } x > 100$$

iv) 50

$$2.29. \sqrt{2}$$

$$2.30. 54,13$$

$$2.31. \text{ Bs. } 13.376,66$$

CAPÍTULO III

$$3.6. \text{ i) } -3/4; \text{ ii) } 3/7; \text{ iii) } 5/6; \text{ iv) No}$$

$$\begin{aligned}
 3.8. \text{ i) } f(x/y = 4) &= 0 && \text{para } x = 2, 3, 4, 11, 12 \\
 &= 1/16 && \text{para } x = 5, 6, 7, 8, 9, 10
 \end{aligned}$$

$$\text{ii) } 21/2; \text{ iii) } 987/36; \text{ iv) } 105/36$$

$$3.9. \text{ i) } 0,94; \text{ ii) } 0,08; \text{ iii) } 0,44$$

$$3.10. \text{ i) } f(x) = e^{-x} \text{ para } x > 0; f(y) = ye^{-y} \text{ para } y > 0$$

$$f(z) = \frac{1}{2}z^2e^{-z} \quad \text{para } z > 0$$

$$\text{ii) } 0,00188; \text{ iii) } 0,04979$$

$$3.11. \text{ i) Valores esperados: } 1.000; 2.000; 3.000$$

$$\text{Varianzas: } 1.000; 2.000; 3.000$$

$$\text{ii) } 6.000; 6.000$$

$$3.12. \text{ i) } 0; \text{ ii) } 7/8; \text{ iii) } 6/8; \text{ iv) } 0$$

$$3.13. f(x/y) = 2y \text{ para } 0 \leq y \leq 1$$

$$3.15. \text{ i) No; ii) } -0,09$$

$$3.16. \text{ i) } 2.770.000; \text{ ii) } 2.666.666; \text{ iii) } 1/3$$

$$3.17. \text{ i) No; ii) } 571,4 \text{ m}^3$$

$$3.18. \text{ i) } 0,607; \text{ ii) } 0,6773; \text{ iii) } 1.167; \text{ iv) } -3/144; -0,3488$$

$$3.19. \text{ i) No; ii) } 0$$

$$3.20. \text{ i) } \frac{e^{-\lambda}\lambda^x}{x!} \quad \text{para } x = 0, 1, 2, \dots$$

$$\text{ii) } \frac{n!}{(n-y)!y!} \lambda^y (1-\lambda)^{n-y} \quad \text{para } y = 0, 1, 2, \dots, n$$

$$3.21. \text{ Bs. } 229.970$$

CAPÍTULO IV

$$4.16. 0,193$$

$$4.17. \text{ i) } 0,00640; \text{ ii) } 0,00672$$

$$4.18. 0,9606$$

19. i, ii) 0,125; iii) 0,375; iv) 0,25
- 4.20. 5 ó más
- 4.21. i) 0,16; ii) 0,64; iii) 0,3684
- 4.22. i) 0,08192; ii) 0,0746
- 4.23. $3/2$, $3/4$
- 4.24. 0,6630
- 4.25. 0,21; 0,296; 0,274; 0,22
- 4.26. 0,2241
- 4.27. 0,807
- 4.28. 0,801
- 4.29. 1,83%
- 4.30. 0,6065
- 4.31. 0,5908
- 4.32. 0,632
- 4.33. 0,8754
- 4.34. i) 0,128; ii) 0,0655; iii) 0,128
- 4.35. i) 0,2013; ii) 0,01225; iii) 0,034
- 4.36. $P(\text{Categoría A}) = 0,1075$; $P(\text{Categoría B}) = 0,5713$; $P(\text{Categoría C}) = 0,3212$
- 4.37. 0,0965
- 4.38. i) 0,147; ii) 0,343; iii) 0,657
- 4.39. 0,133
- 4.40. 0,0881
- 4.41. i) 0,605; ii) 0,6065
- 4.42. 0,3616
- 4.43. 0,0956
- 4.44. 0,0015
- 4.45. 0,0016
- 4.46. i) 0,1353; ii) 0,2707; iii) 0,0526
- 4.47. 15
- 4.48. 0,4752
- 4.49. 0,98
- 4.50. 0,9949
- 4.51. p, p (1-p)

CAPÍTULO V

- 5.6. Siete y cinco o antes
- 5.7. 0,4
- 5.8. 0,1
- 5.9. 2 meses, 14 días.
- 5.10. i) 0,01832; ii) 99,75%
- 5.11. 0,1353
- 5.12. 0,1353
- 5.13. 0,5438
- 5.14. 0,848
- 5.15. i) 0,6915; ii) 0,0668; iii) 0,8185 iv) 6,08; v) 2,68; vi) 0,1574
- 5.16. 9
- 5.17. i) 0,3849; ii) 0,2517; iii) 0,6636
iv) 0,1828; v) 0,2742; vi) 0,8997; vii) 0,0951
- 5.18. i) 16,64; ii) 16,36; iii) 6,60; iv) 5,24; v) No existe
- 5.19. 0,2676
- 5.20. 0,0026
- 5.21. 0,8106
- 5.22. 0,0985
- 5.23. 0,001
- 5.24. 0,444
- 5.25. 0,9597
- 5.26. 0,5117
- 5.27. 12,084 cm. y 11,916 cm.
- 5.28. 15,87%
- 5.29. i) 0,25; ii) 0,995; iii) 0,49
- 5.30. 0,75
- 5.31. i) 0,05; ii) 0,99; iii) 0,245
- 5.32. i) 0,1; ii) 0,99; iii) 0,2; iv) 0,97
- 5.33. i) 0,975; ii) 0,005; iii) 0,09
- 5.34. i) 2,9; ii) 0,333
- 5.35. 0,5767
- 5.36. i) 0,3192; ii) 0,7794; iii) Bs. 17.047,71; iv) 0,881

CAPITULO VI

- 6.3. 2.000
 6.4. 6.250
 6.5. 5.250
 6.6. 0,75
 6.7. 3.364
 6.8. 0,84
 6.9. 0,0196
 6.10. 99,621 kgs.
 6.11. 0,0113
 6.12. 32
 6.13. 3

CAPITULO VII

- 7.7. i) 0,9738; ii) 0,09; iii) 0,8
 7.8. 0,9
 7.9. iii) $\sqrt{2}$
 7.10. 13/8
 7.11. $s_i^2 = 1$ para $i = 2, 5, 12, 15$
 $= 0,25$ para $i = 7, 10$
 $= 2,25$ para $i = 3, 8, 9, 14$
 $= 6,25$ para $i = 4, 13$
 $= 0$ para $i = 1, 6, 11, 16$
 7.12. 0,027
 7.13. 0,9876
 7.14. $n_x = -\frac{96,04 n_y}{61,47 - 9n_y}$ para $n_y > 7$ y $n_x > 11$
 7.15. 0,6424
 7.16. 0,5346
 7.17. 0,1515
 7.18. 0,3707
 7.19. 97

7.20. 609

7.21. 11

7.22. 0,1

7.23. 62

CAPITULO VIII

- 8.10. i) $\sqrt{\sum x_i^2/n}$; ii) 7,778
 8.11. $n/\sum x_i$; ii) 0,526
 8.12. $n/\sum x_i$
 8.13. i) 0,988; ii) 83
 8.14. i) $\frac{-n - \ln \prod x_i}{\ln \prod x_i}$; ii) 2,04
 8.15. 2,915
 8.16. $\hat{\theta}_1$
 8.17. i) 3; ii) $6n/(1+2n)$; iii) Si; iv) No
 8.18. i) $\sum \lambda_i = 1$; ii) $\lambda_i = 1/4$
 8.19. i) $-\frac{n}{\ln \prod x_i}$; ii) 1,66
 8.20. i) $\bar{x}$; ii) 5,6
 8.21. Si
 8.22. $(\theta - 1) \theta/n$
 8.24. i) $\bar{x}/\alpha$; ii) 6
 8.25. Si
 8.26. i) $3\bar{x} + 4s^2$; ii) No

8.27. i) $\bar{x}_1 - \bar{x}_2$; ii) $n_1 = 30$; $n_2 = 60$

8.28. i) $\hat{p}_1 = \frac{\sum x_i}{n}$; $\hat{p}_2 = \frac{\sum y_i}{n}$; $\hat{p}_3 = \frac{\sum z_i}{n}$

ii) 33,3%; 30%; 25%

CAPITULO IX

9.16. i) (292,98; 307,02); ii) (291,64; 308,36); iii) (290,08; 309,92)

9.17. (191,57; 208,43)

9.18. (23 meses, 21 días; 24 meses, 9 días)

(0,7310; 1,6893)

9.19. (19,59; 20,41)

9.20. i) (20.402,32; 21.597,68); ii) (1.202,18; 2.414,31)

9.21. 238

9.22. (49,37%; 70,63%)

9.23. (55,22%; 60,72%)

9.24. (54,94%; 61,06%)

9.25. (19,63; 20,37)

9.26. (293,06; 306,94); (291,73; 308,27); (289,16; 310,84)

9.27. (191,99; 208 01)

9.28. $\bar{x} - \bar{y} \pm k_{\alpha/2} \sqrt{\frac{\sigma_x^2}{n_x} \frac{N_x - n_x}{N_x - 1} + \frac{\sigma_y^2}{n_y} \frac{N_y - n_y}{N_y - 1}}$

9.29. $\bar{x} - \bar{y} \pm k_{\alpha/2} \sqrt{\frac{s_x^2}{n_x - 1} \frac{N_x - n_x}{N_x - 1} + \frac{s_y^2}{n_y - 1} \frac{N_y - n_y}{N_y - 1}}$

9.30. $\bar{x} - \bar{y} \pm t_{\alpha/2} \sqrt{\frac{N_x - n_x}{n_x(N_x - 1)} + \frac{N_y - n_y}{n_y(N_y - 1)}} \sqrt{\frac{n_x s_x^2 + n_y s_y^2}{n_x + n_y - 2}}$

9.31. $\hat{p}_x - \hat{p}_y \pm k_{\alpha/2} \sqrt{\frac{\hat{p}_x(1 - \hat{p}_x)}{n_x} \frac{N_x - n_x}{N_x - 1} + \frac{\hat{p}_y(1 - \hat{p}_y)}{n_y} \frac{N_y - n_y}{N_y - 1}}$

9.32 (3,63; 3,79)

9.33. 281

9.34. i) (2.760; 3.036); ii) (2.762; 3.038)

9.35. $\frac{(2 k_{\alpha/2} \sigma)^2 N}{(2 k_{\alpha/2} \sigma)^2 + h^2 (N - 1)}$

9.36. (29,49; 30,51)

9.37. (72,16%; 87,84%)

9.38. (1.448; 1.752)

9.39. (0,1591; 0,1809)

9.40. (0,1517; 0, 1883)

9.41. (16,71%; 20,63%)

9.42. (15.890; 16.610)

9.43. 24

9.44. $\frac{pqN/(N-1)}{(h/2 k_{\alpha/2})^2 + pq/(N-1)}; \frac{N/(N-1)}{(h/k_{\alpha/2})^2 + 1/(N-1)}$

9.45. 9.604

9.46. 8.068

9.47. 3.646

9.48. 2.468

9.49. (-0,04%; 4,64%)

9.50. (3,56; 6,44)

9.51. (2,25%; 12,75%)

9.52. (1,18; 50,93)

9.53. (468,34; 647,66)

9.54. (46,91; 171,37)

- 9.55. (-5,54; 17,54)
 9.56. (0,56; 0,64)
 9.57. (2,66%; 7,34%)
 9.58. (-7,34%; -2,66%)
 9.59. (-4,54; 16,54)
 9.60. (0,70; 2,30)
 9.61. (0,45; 2,55)
 9.62. (1,92%; 18,08%)
 9.63. (22,34; 62,54)
 9.64. (18 meses, 15 días; 32 meses, 10 días)
 9.65. (0,33; 0,80)
 9.66. 2.823
 9.67. (-0,0629; 0,0629)
 9.68. i) (97,17; 102,82); ii) (98,01; 101,98)

CAPÍTULO X

- 10.9. $H_0: p \geq 0,20$; $H_1: p < 0,20$
 10.10. $H_0: p \geq 0,70$; $H_1: p < 0,70$
 10.11. $H_0: \mu \geq 18$; $H_1: \mu < 18$
 10.12. $H_0: \mu_X = \mu_Y$; $H_1: \mu_X > \mu_Y$
- | | |
|---|-----------------|
| 10.13. $\alpha = 0,001$, $\beta = 0,998$ | para $p = 0,14$ |
| $\beta = 0,9599$ | para $p = 0,09$ |
| $\beta = 0,6772$ | para $p = 0,05$ |
-
- | | |
|---|------------------|
| 10.14. $\alpha = 0,05$, $\beta = 0,6808$ | para $\mu = 305$ |
| $\beta = 0,7580$ | para $\mu = 304$ |
| $\beta = 0,8264$ | para $\mu = 303$ |
-
- | | |
|---|----------------------------|
| 10.15. $\alpha = 0,05$, $\beta = 0,2389$ | para $\mu_X - \mu_Y = 1$ |
| $\beta = 0,5948$ | para $\mu_X - \mu_Y = 2$ |
| $\beta = 0,8264$ | para $\mu_X - \mu_Y = 2,5$ |
-
- | | |
|---|--------------------------|
| 10.16. $\alpha = 0,05$, $\beta = 0,9471$ | para $\mu_X - \mu_Y = 1$ |
| $\beta = 0,9335$ | para $\mu_X - \mu_Y = 2$ |
| $\beta = 0,0122$ | para $\mu_X - \mu_Y = 3$ |

CAPÍTULO XI

$$11.14. \left(\frac{k_{\alpha} \sqrt{p_0 q_0} - k_{1-\beta} \sqrt{p_1 q_1}}{p_1 - p_0} \right)^2$$

- 11.15. $h = 307,01$. Se rechaza H_0
 11.17. $h_1 = -2,28$; $h_2 = 2,28$. Se rechaza H_0
 11.19. $h_1 = -10,28$; $h_2 = 10,28$. No se rechaza H_0
 11.20. $h = 213,97$. No se rechaza H_0
 11.21. $h = 3,7191$. No se rechaza H_0
 11.22. $h = 28,655$. Se rechaza H_0
 11.23. $h = 0,0007$. Se rechaza H_0
 11.24. $h = 3,905$. No se rechaza H_0
 11.25. $h_1 = 0,4632$; $h_2 = 0,5367$. Se rechaza H_0
 11.27. $h_1 = -0,9118$; $h_2 = 0,9118$. Se rechaza H_0
 11.28. $h = 22,575$. No se rechaza H_0
 11.29. $h = 103,50$. Se rechaza H_0
 11.30. $h = 0,2143$. No se rechaza H_0 ; 0,2358
 11.31. $h = 54,177$. Se rechaza H_0
 11.32. 17
 11.33. $h = 0,0393$. No se rechaza H_0
 11.34. $h_1 = 28,9432$; $h_2 = 31,0568$. No se rechaza H_0
 11.35. $h = 6,8225$; 0,0091; 0,3594
 11.36. $h_1 = 0,3025$; $h_2 = 0,3641$. Si
 11.37. 0,1342 ó más
 11.38. $h_1 = 0,2491$; $h_2 = 0,2509$. Se rechaza H_0
 11.39. $h = 0,6246$. Se rechaza H_0
 11.40. $h = 11,3445$. Se rechaza H_0
 11.41. 96
 11.42. $h_1 = -0,0723$; $h_2 = 0,0723$. No se rechaza H_0
 11.43. $h_1 = -0,3551$; $h_2 = 0,3551$. Se rechaza H_0
 11.44. $h = 0,4466$. No se rechaza H_0
 11.45. $h_1 = -0,0404$; $h_2 = 0,0404$. No se rechaza H_0
 11.46. $h = 495,03$. Se rechaza H_0

11.47. $h_1 = 18.614,08$; $h_2 = 21.385,92$. Se rechaza H_0

11.48. $h = 17,77$. Se rechaza H_0

11.49. $h_1 = 19,11$; $h_2 = 20,88$. $h_1 = 18,83$; $h_2 = 21,16$

11.50. $h_1 = -1,2903$; $h_2 = 1,2903$. Se rechaza H_0

11.51. $h = 1,7448$. Se rechaza H_0

11.52. $h = 20,22$. No se rechaza H_0

11.53. $h = 12,30$. Se rechaza H_0

11.54. 353; $h = 305,60$

11.55. 1.346; $h = 1.724,63$

11.56. 88; $h = 0,4018$

11.57. 51; $h = 209,21$

11.58. i) 239; ii) 164

11.59. $h_1 = -1,8145$; $h_2 = 1,8145$. No se rechaza H_0

11.60. $h = 0,00485$. No se rechaza H_0

11.61. $h_1 = 1.487,67$; $h_2 = 2.598,41$. Se rechaza H_0

11.62. $h_1 = 0,65$; $h_2 = 1,58$. Se rechaza H_0

11.63. $F = 1,3395$. No se rechaza H_0

$$11.64. \text{ i) } h = \mu_0 + k_\alpha \sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}}; \quad \text{ ii) } h = \mu_0 + k_\alpha \sqrt{\frac{s_x^2}{n_x - 1} + \frac{s_y^2}{n_y - 1}}$$

$$\text{ iii) } h = \mu_0 + t_\alpha \sqrt{\frac{n_x + n_y}{n_x n_y} + \frac{n_x s_x^2 + n_y s_y^2}{n_x + n_y - 2}}$$

$$11.65. \text{ i) } h = \mu_0 \mp k_{\alpha/2} \sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}}; \quad \text{ ii) } h = \mu_0 \mp k_{\alpha/2} \sqrt{\frac{s_x^2}{n_x - 1} + \frac{s_y^2}{n_y - 1}}$$

$$\text{ iii) } h = \mu_0 \mp t_{\alpha/2} \sqrt{\frac{n_x + n_y}{n_x n_y} + \frac{n_x s_x^2 + n_y s_y^2}{n_x + n_y - 2}}$$

$$11.66. \text{ i) } p_0 + k_\alpha \sqrt{\frac{\hat{p}_x (1 - \hat{p}_x)}{n_x} + \frac{\hat{p}_y (1 - \hat{p}_y)}{n_y}}; \quad \text{ ii) } p_0 - k_\alpha \sqrt{\frac{\hat{p}_x (1 - \hat{p}_x)}{n_x} + \frac{\hat{p}_y (1 - \hat{p}_y)}{n_y}}$$

$$\text{ iii) } p_0 \mp k_{\alpha/2} \sqrt{\frac{\hat{p}_x (1 - \hat{p}_x)}{n_x} + \frac{\hat{p}_y (1 - \hat{p}_y)}{n_y}}$$

$$11.67. \mu_0 + k_\alpha \frac{\sigma}{\sqrt{n}} \sqrt{\frac{N-n}{N-1}}; \quad \mu_0 - k_\alpha \frac{\sigma}{\sqrt{n}} \sqrt{\frac{N-n}{N-1}}; \quad \mu_0 \mp k_{\alpha/2} \frac{\sigma}{\sqrt{n}} \sqrt{\frac{N-n}{N-1}}$$

$$\mu_0 + t_\alpha \frac{s}{\sqrt{n-1}} \sqrt{\frac{N-n}{N-1}}; \quad \mu_0 - t_\alpha \frac{s}{\sqrt{n-1}} \sqrt{\frac{N-n}{N-1}}; \quad \mu_0 \mp t_{\alpha/2} \frac{s}{\sqrt{n-1}} \sqrt{\frac{N-n}{N-1}}$$

$$11.68. p_0 + k_\alpha \sqrt{\frac{p_0(1-p_0)}{n} \frac{N-n}{N-1}}; \quad p_0 - k_\alpha \sqrt{\frac{p_0(1-p_0)}{n} \frac{N-n}{N-1}};$$

$$p_0 \mp k_{\alpha/2} \sqrt{\frac{p_0(1-p_0)}{n} \frac{N-n}{N-1}}$$

$$11.69. \mu_0 + k_\alpha \sqrt{\frac{\sigma_x^2}{n_x} \frac{N_x - n_x}{N_x - 1} + \frac{\sigma_y^2}{n_y} \frac{N_y - n_y}{N_y - 1}};$$

$$\mu_0 - k_\alpha \sqrt{\frac{\sigma_x^2}{n_x} \frac{N_x - n_x}{N_x - 1} + \frac{\sigma_y^2}{n_y} \frac{N_y - n_y}{N_y - 1}};$$

$$\mu_0 \mp k_\alpha \sqrt{\frac{\sigma_x^2}{n_x} \frac{N_x - n_x}{N_x - 1} + \frac{\sigma_y^2}{n_y} \frac{N_y - n_y}{N_y - 1}};$$

$$11.70. p_o + k_\alpha \sqrt{\frac{\hat{p}_x(1-\hat{p}_x)}{n_x} \frac{N_x - n_x}{N_x - 1} + \frac{\hat{p}_y(1-\hat{p}_y)}{n_y} \frac{N_y - n_y}{N_y - 1}}$$

$$p_o - k_\alpha \sqrt{\frac{\hat{p}_x(1-\hat{p}_x)}{n_x} \frac{N_x - n_x}{N_x - 1} + \frac{\hat{p}_y(1-\hat{p}_y)}{n_y} \frac{N_y - n_y}{N_y - 1}}$$

$$p_o \mp k_\alpha \sqrt{\frac{\hat{p}_x(1-\hat{p}_x)}{n_x} \frac{N_x - n_x}{N_x - 1} + \frac{\hat{p}_y(1-\hat{p}_y)}{n_y} \frac{N_y - n_y}{N_y - 1}}$$

CAPITULO XII

- 12.9. $\chi^2 = 6,8159$. Se rechaza H_0
 12.10. $\chi^2 = 1,9375$. No se rechaza H_0
 12.11. $\chi^2 = 7,863$. No se rechaza H_0
 12.12. $\chi^2 = 1,32$. No se rechaza H_0
 12.13. $D_n = 0,03$. No se rechaza H_0
 12.14. $\chi^2 = 6,6842$. No se rechaza H_0
 12.15. $D_n = 0,0759$. No se rechaza H_0
 12.16. $\chi^2 = 0,4393$. No se rechaza H_0
 12.17. $D_n = 0,0142$. No se rechaza H_0
 12.18. $\chi^2 = 4,6817$. No se rechaza H_0
 12.19. $D_n = 0,04$. No se rechaza H_0
 12.20. i) $\chi^2 = 7,42$. Se rechaza H_0 ; ii) 0,2283
 12.21. i) $\chi^2 = 24,1895$. Se rechaza H_0 ; ii) 0,191
 12.22. i) $\chi^2 = 42,4226$. Se rechaza H_0 ; ii) 0,2860
 12.23. i) $\chi^2 = 13,1944$. Se rechaza H_0 ; ii) 0,3415
 12.24. i) $\chi^2 = 3,2368$. No se rechaza H_0 ; ii) 0,049
 12.25. i) $\chi^2 = 6,0256$. No se rechaza H_0 ; ii) 0,2037

CAPITULO XIII

- 13.6. $F = 1,18$. No se rechaza H_0
 13.7. $F = 7,52$. Se rechaza H_0
 13.8. $F = 2,51$. No se rechaza H_0
 13.9. $F = 3,72$. Se rechaza H_0
 13.10. i) $F = 1,67$. No se rechaza H_0 ; ii) $F = 2,03$. No se rechaza H_0
 13.11. i) $F = 0,82$. No se rechaza H_0 ; ii) $F = 3,58$. Se rechaza H_0
 13.12. i) $F = 0,61$. No se rechaza H_0 ; ii) $F = 116,02$. Se rechaza H_0
 iii) $F = 0,88$. No se rechaza H_0
 13.13. i) $F = 3,58$. No se rechaza H_0 ; ii) $F = 41,75$. Se rechaza H_0
 iii) $F = 1,01$. No se rechaza H_0
 13.14. i) $F = 1,95$. No se rechaza H_0 ; ii) $F = 1,01$. No se rechaza H_0
 iii) $F = 0,07$. No se rechaza H_0
 13.15. $A/C = 0,7823$. No se rechaza H_0
 13.16. $A/C = 2,9326$. No se rechaza H_0
 13.17. $A/C = 6,356$. No se rechaza H_0
 13.18. $A/C = 4,338$. No se rechaza H_0
 13.19. $A/C = 2,264$. No se rechaza H_0

CAPITULO XIV

$$14.2. i) Y = \frac{a+d}{1-b} + \frac{c}{1-b} r + \frac{1}{1-b} G$$

$$C = \frac{a+bd}{1-b} + \frac{bc}{1-b} r + \frac{b}{1-b} G$$

$$I = d + cr$$

$$ii) Y = \frac{\alpha_1 - \beta_1 - \delta_1}{\Delta} - \frac{\alpha_2}{\Delta} T + \frac{\alpha_2}{\Delta} R + \frac{1}{\Delta} G + \frac{1}{\Delta} X + \frac{u_1 + u_2 - u_3}{\Delta}$$

$$C = \frac{\alpha_1 (1 - \beta_2 + \delta_2) + \alpha_2 (\beta_1 - \delta_1)}{\Delta} - \frac{\alpha_2 (1 - \beta_2 + \delta_2)}{\Delta} T +$$

$$+ \frac{\alpha_2 (1 - \beta_2 + \delta_2)}{\Delta} R + \frac{\alpha_2}{\Delta} G + \frac{\alpha_2}{\Delta} X + \frac{\alpha_2 (u_2 - u_3) + u_1 (1 - \beta_2 - \delta_2)}{\Delta}$$

$$I = \frac{\beta_1 (1 - \alpha_2 + \delta_2) + \beta_2 (\alpha_1 - \delta_1)}{\Delta} - \frac{\beta_2 \alpha_2}{\Delta} T + \frac{\beta_2 \alpha_2}{\Delta} R + \frac{\beta_2}{\Delta} G + \frac{\beta_2}{\Delta} X +$$

$$+ \frac{\beta_2 (u_1 - u_3) + u_2 (1 - \alpha_2 + \delta_2)}{\Delta}$$

$$M = \frac{\delta_1 (1 - \alpha_2 - \beta_2) + \delta_2 (\alpha_1 + \beta_1)}{\Delta} - \frac{\delta_2 \alpha_2}{\Delta} T + \frac{\delta_2 \alpha_2}{\Delta} R + \frac{\delta_2}{\Delta} G + \frac{\delta_2}{\Delta} X +$$

$$+ \frac{\delta_2 (u_1 + u_2) + u_3 (1 - \alpha_2 - \beta_2)}{\Delta}$$

$$Y_d = \frac{\alpha_1 + \beta_1 - \delta_1}{\Delta} - \frac{1 - \beta_2 + \delta_2}{\Delta} + \frac{1 - \beta_2 + \delta_2}{\Delta} R + \frac{1}{\Delta} G + \frac{1}{\Delta} X + \frac{u_1 + u_2 - u_3}{\Delta}$$

$$\text{siendo } \Delta = 1 - \alpha_2 - \beta_2 + \delta_2$$

$$\text{iii) } Y_t = \frac{\alpha_1 + \beta_1}{\Delta} + \frac{\alpha_2}{\Delta} T_t + \frac{1}{\Delta} G_t + \frac{\beta_3}{\Delta} y_{t-1} + \frac{u_{1t} + u_{2t}}{\Delta}$$

$$D_t = \frac{\alpha_1 + \beta_1}{\Delta} + \frac{1 - \beta_2}{\Delta} T_t + \frac{1}{\Delta} G_t + \frac{\beta_3}{\Delta} y_{t-1} + \frac{u_{1t} + u_{2t}}{\Delta}$$

$$I_t = \frac{\beta_1 (1 - \alpha_2) + \beta_2 (\alpha_1 + \beta_1)}{\Delta} + \frac{\beta_2 \alpha_2}{\Delta} T_t + \frac{\beta_2}{\Delta} G_t + \frac{(1 - \alpha_2) \beta_3}{\Delta} y_{t-1} +$$

$$+ \frac{\beta_2 u_{1t} + (1 - \alpha_2) u_{2t}}{\Delta}$$

$$C_t = \frac{\alpha_1 (1 - \beta_2) + \alpha_2 \beta_1}{\Delta} + \frac{\alpha_1 (1 - \beta_2)}{\Delta} T_t + \frac{\alpha_2}{\Delta} G_t + \frac{\alpha_2 \beta_3}{\Delta} y_{t-1} +$$

$$+ \frac{\alpha_2 u_{2t} + (1 - \beta_2) u_{1t}}{\Delta}$$

$$\text{siendo } \Delta = 1 - \alpha_2 - \beta_2$$

$$14.3. \text{ i) } Y_{1i} = (\gamma_{11} + \beta_{12} \gamma_{21}) + \beta_{12} \gamma_{22} X_i + (u_{1i} + \beta_{12} u_{2i})$$

$$Y_{2i} = \gamma_{21} + \gamma_{22} X_i + u_{2i}$$

$$\text{ii) } Y_{1i} = \frac{-\gamma_{11}}{\Delta} X_{1i} + \frac{\beta_{12} \gamma_{22}}{\Delta} X_{2i} - \frac{\beta_{12} u_{2i} + u_{1i}}{\Delta}$$

$$Y_{2i} = \frac{\beta_{21} \gamma_{11}}{\Delta} X_{1i} - \frac{\gamma_{22}}{\Delta} X_{2i} + \frac{u_{2i} - \beta_{21} u_{1i}}{\Delta}$$

$$\text{siendo } \Delta = 1 - \beta_{21} \beta_{12}$$

CAPITULO XV

$$15.3. \quad n \hat{\beta}_1 + \hat{\beta}_2 \sum X_{2i} + \hat{\beta}_3 \sum X_{3i} + \dots + \hat{\beta}_k \sum X_{ki} = \sum y_i$$

$$\hat{\beta}_1 \sum X_{2i} + \hat{\beta}_2 \sum X_{2i}^2 + \hat{\beta}_3 \sum X_{2i} X_{3i} + \dots + \hat{\beta}_k \sum X_{2i} X_{ki} = \sum X_{2i} y_i$$

$$\dots \dots \dots$$

$$\dots \dots \dots$$

$$\hat{\beta}_1 \sum X_{ki} + \hat{\beta}_2 \sum X_{ki} X_{2i} + \hat{\beta}_3 \sum X_{ki} X_{3i} + \dots + \hat{\beta}_k \sum X_{ki}^2 = \sum X_{ki} y_i$$

$$15.5. \quad \hat{\beta}_2 \mp t_{\alpha/2} \frac{s}{\sqrt{\sum (X_{2i} - \bar{X})^2}}$$

- 15.6. i) 20/37, 15/74, 50/37; ii) 0,2009; 0,2756; iii) 0,9229; 0,8715
 iv) (-0,4366; 0,8420); (0,4744; 2,2284); v) $t = 1,01$. No se rechaza H_0
 $t = 4,90$. Se rechaza H_0
 vi) $h = 1,6485$. No se rechaza H_0
- 15.7. i) 5×1 ; ii) 10×1 ; iv) 8; v) 0,5657
- 15.10. i) $t = 4,78$; ii) $F = 0,696$
- 15.11. i) $F = 31,97$; ii) $h_1 = 0,3415$; $h_2 = 1,6585$. No se rechaza H_0
 $h_1 = 0,2219$; $h_2 = 1,7781$. No se rechaza H_0
- 15.12. i) $h = -0,22$; ii) $t = 0,75$
- 15.13. $F = 3,73$

BIBLIOGRAFIA

INFERENCIA ESTADISTICA

- COCHRAN, W., "Sampling Techniques". John Wiley & Sons, 1963.
- CRAMER, H., "Mathematical Methods of Statistics". Princenton University Press, 1946.
- CHERNOFF, H. AND MOSES L. E., "Elementary Decision Theory". John Wiley & Sons, 1959.
- DYCKMAN, T. R., SMIDT S., Mc. ADAMS A. K., "Management Decision Making under Uncertainty". McMillan Co., 1969.
- FELLER, W., "An Introduction to Probability Theory and its Applications". John Wiley & Sons, 1950.
- FREUND, J., WILLIAMS, F., "Modern Business Statistics". Prentice Hall, 1960.
- GRAYBILL, F., "An Introduction to Linear Statistical Models". McGraw Hill, 1961.
- HADLEY, G., "Introduction to Business Statistics". Holden Day, 1968
- HOEL, P., "Introduction to Mathematical Statistics". John Wiley & Sons, 1962.
- KENDALL, M. G., "The Advanced Theory of Statistics". Charles Griffin & Co., 1948.
- KOLMOGOROV, A. N., "Foundations of the Theory of Probability". Chelsea Publishing Co., 1950.
- LINDGREN, B. W., "Elements of Decision Theory". McMillan Co., 1971.
- LINDGREN, B. W., Mc. ELRATH, G. W., "Introduction to Probability and Statistics". McMillan Co., 1966.

MOOD A., GRAYBILL, F., "Introduction to the Theory of Statistics". McGraw Hill, 1963.

PARZEN, E., "Modern Probability Theory and its Applications". John Wiley & Sons, 1960.

SASAKI, K., "Statistics for Modern Business Decision Making". Wadsworth Publishing Co., 1968.

SNEDECOR, G. W., "Statistical Methods". Iowa State College Press, 1956.

ECONOMETRIA

ALLAN, PH., "Applied Econometrics". Camelot Press, 1976.

BERNDT, E. R., "The Practice of Econometrics - Classic and Contemporary". Addison-Wesley Publishing Co., 1991.

CHATERJEE, S., PRICE, B., "Regression Analysis by Example". John Wiley & Sons, 1977.

CHRIST, C. F., "Econometric Models and Methods". John Wiley & Sons, 1966.

DRAPER, N., SMITH, H., "Applied Regression Analysis". John Wiley & Sons, 1966.

GOLDBERGER, A., "Econometric Theory". John Wiley & Sons, 1964.

GUJARATI, D., "Econometría". McGraw Hill, 1990.

HUANG, D., "Regression and Econometric Methods". John Wiley & Sons, 1970.

JOHNSTON, J., "Métodos de Econometría". Ed. Vicens-Vives, 1977.

KANE, E. J., "Economic Statistics and Econometrics". Harper & Row, 1968.

KMENTA, J., "Elementos de Econometría". Ed. Vicens-Vives, 1977.

LOPEZ CASUSO, R., "La Función de Consumo: Caso de Venezuela". U.C.A.B., 1970.

MADDALA, G. S., "Econometría". McGraw Hill, 1985.

MALINVAUD, E., "Statistical Methods of Econometrics". Rand McNally, 1966.

NOVALES, A., "Econometría". McGraw Hill, 1993.

INDICE DE MATERIAS

Aceptación, Región de, 304

Aleatorio (a),

Experimento, 7

Fenómeno, 3

Muestra, 192

Suceso, 7, 11

Variable, 37, 38

Conjuntamente distribuidas, 71

Continua, 38

Discreta, 38

Función de Probabilidades de, 38

Independientes, 81-95

No Correlacionadas, 90

Tipificada, 152

Bayes, Teorema de, 20

Bernoulli, Variable, 108

Beta, Distribución, 146, 147

Binomial, Distribución, 108-113

Aproximación

Por la Normal, 159

Por Poisson, 120

Bondad del Ajuste, Contraste de, 524

Cálculo de Probabilidades, 17

Clasificación, Análisis de Varianza, 577

Doble, 601

Simple, 578

Cramer - Rao, Teorema de, 225-227

Combinación Lineal de Variables, 150

Complemento, Suceso, 13

Condicional,

Función de Densidad, 77

Probabilidad, 14

y Sucesos independientes, 17

Valor Esperado, 80

Confianza, Intervalo de, 251 (Véase Intervalo de Confianza)

Coefficiente de, 252

Coefficiente de Determinación Múltiple, 533

Modificado, 540

Conjunto, 10, 11

Conjunta, Función de Densidad, 71 (Véase Función de Densidad)

Consistencia de un Estimador, 227

Contingencia, Tablas de, 397

Contraste de Independencia en, 397-402

Continua, Variable, 38

Contraste de Hipótesis,

Bondad del Ajuste, 383 - 394

Coefficiente de Contingencia, 403

Coefficientes del modelo, 541

Cola por la Derecha, 320

Cola por la Izquierda, 320

Dos Colas, 320

Errores Tipo I y Tipo II, 305-307

Estrategia, 303

Función Característica de Operación, 312-317

Función de Potencia, 317-328

Igualdad de Medias, 349-355

Igualdad de Proporciones, 356-359

Igualdad de Varianzas, 361-364

Independencia, 397
 Ji - Cuadrado, 383-394
 Kolmogorov - Smirnov, 395
 Media, 333-346
 Nivel de Significación, 312
 Proporción, 346-349
 Región Crítica, 304
 Región de Aceptación, 304
 Tablas de Contingencia, 397
 Tamaño de la Muestra, 342-346, 349
 Uniformemente más Potente, 324
 Varianza, 359, 361
 Valores Críticos, 304
 Correlación, Coeficiente de, 91
 Múltiple, 533
 Covarianza, 90
 Cramer - Rao, Teorema de, 225-227
 Crítica, Región, 304
 Cuasivarianza Muestral, 195
 Chebychev, Desigualdad de, 175-178, 196
 Decisiones, Teoría de, 297
 Densidad, Función de, 38-40
 Beta, 146-147
 Binominal, 108-113 (Véase Binominal, Distribución)
 Condicional, 72
 Conjunta, 71-73
 Exponencial, 139-143
 F de Snedecor, 165-168 (Véase F, Distribución)
 Gamma, 143-146
 Geométrica, 113-114
 Hipergeométrica, 115-116
 Ji-Cuadrado, 160-162 (Véase Ji-Cuadrado Distribución)
 Marginal, 74
 Multinomial, 116-117
 Normal, 147-158 (Véase Normal, Distribución)
 Poisson, 118-120 (Véase Poisson, Distribución)
 t de Student 163-165 (Véase t, Distribución)
 Uniforme, 136-137
 Desigualdad de Chebychev, 175-178, 196
 Diferencia de,
 Medias Muestrales, 207-208
 Proporciones Muestrales, 209
 Discreta, Variable, 38
 Distribución, Función de, 40
 De Estadísticos Muestrales, 201-209
 Econometría, 38-40, 481
 Ecuaciones
 Contables, Identidades, 489
 de Comportamiento, 489
 de Definición, 489
 de Equilibrio, 489
 Institucionales, 490
 Técnicas, 489
 Eficiencia, 225-226
 Error
 Cuadrático, 220
 Tipo I y Tipo II, 305-312
 Espacio
 del Parámetro 298
 Muestral, 11, 303
 Probabilidad del, 13
 Esperanza Matemática, (Véase Valor Esperado)
 Estadística, 1
 Descriptiva, 11
 Estimativa, 1
 Estadístico, 193
 Estimador,
 Consistente, 227-230
 De Máxima Verosimilitud, 234-240
 (Máximo Verosímil)
 Eficiente, 225-226
 Inssegado, 223-224
 Inssegado de Mínima Varianza, 225-226
 (Relativamente Eficiente)
 Por Intervalos, 217, 340
 Puntual, 217
 Suficiente, 230-233
 Estrategia, 303
 Exhaustivos, Sucesos, 31
 Experimento Aleatorio, 7
 Exponencial, Distribución, 139-143
 Factor de Corrección 262
 F de Snedecor, Distribución, 165-168
 Tablas, 565-568
 Fenómeno Aleatorio, 7
 Modalidad de un, 28
 Finita, Población, (Véase Población)
 Fisher-Neyman, Teorema de, 232-233
 Frecuencia Relativa, 10
 Función Característica de Operación, 312-317, 427
 Función de Densidad, 38, 40
 Condicional, 77
 Conjunta, 71-73
 Marginal, 74

Función de Distribución, 40
 Función de Pérdida, 219-220
 Función de Potencia, 317-328
 Función de Probabilidad, 38
 Masa, 38
 Función de Riesgo, 220-221
 Función de Verosimilitud, 236
 Función Generatriz de Momentos, 52, 96
 Gamma, Distribución, 143-146
 Gauss, Distribución de, (Véase Normal, Distribución)
 Gauss-Markov, Teorema, 523
 Geométrica, Distribución, 113-114
 Grados de Libertad, 160, 163, 165, 518
 Hipergeométrica, Distribución, 115-116
 Hipótesis, (Véase Contraste de Hipótesis)
 Alternativa, 300
 Compuesta, 301
 No Paramétrica, 298
 Nula, 300
 Original, 300
 Paramétrica, 298
 Simple, 301
 Identificación, 498
 Igualmente Posibles, Resultados, 8, 9, 11
 Independencia,
 Condiciones para, 18
 De la Media y Varianza Muestral, 204
 De Sucesos, 17, 18
 De Variables, 81, 83, 85, 90, 92, 95-96
 En Probabilidad, 17
 Inferencia Estadística, 1, 189
 Inssegado, Estimador, 223-224
 Interacción en Análisis de Varianza, 618
 Intersección de Sucesos, 7, 12
 Probabilidad de, 12, 17
 Intervalos de Confianza, 251-279, 541
 Coeficiente de Confianza, 252
 Definición, 252
 Diferencia de Medias, 275-277
 Diferencia de Proporciones, 278-279
 Media, 257-264
 Proporción, 265-271
 Tamaño de la Muestra, 264-265, 271
 Invarianza, 240
 Ji-Cuadrado, Distribución, 160-162
 Contraste de Bondad del Ajuste, 383 - 394
 Tablas, 562-563

Kolmogorov - Smirnov, Contraste, 395
 Tablas, 569
 Ley de Los Grandes Números, 178-180, 197
 Límite Central, Teorema del, 181-185, 199
 Marginal, Función de Densidad, 74
 Masa, Función de Probabilidad, 38
 Matriz de Varianzas y Covarianzas, 515
 Máxima Verosimilitud, Estimador de, 236
 Propiedades, 239
 Media, (Véase también Valor Esperado)
 de la Población, 193
 Contraste de Hipótesis sobre, 333-346
 Intervalos de Confianza para, 257-264
 Muestral, 193, 201-202, 205
 Distribución de Probabilidades, 201-202
 Varianza de la, 194
 Mínima Varianza, Estimador Inssegado de, 225-226
 Mínimos Cuadrados, 516
 Modalidad en Fenómenos Aleatorios, 8
 Modelos Económicos, 482
 Clasificación, 488
 Conceptos, 483
 Económicos, 493-497
 Ejemplos, 485-487
 Forma Estructural, 490
 Forma Reducida, 490
 Lineales, 488
 Macroeconómicos, 488
 Microeconómicos, 488
 Multiecuacionales, 488
 No lineales, 488
 Uniecuacionales, 488
 Modelo Lineal General, 511
 Momentos de una Variable, 52
 Función Generatriz de, 52
 Suma de Variables, 96
 Muestra, 190-192
 Aleatoria, 192
 De una Población Finita, 262
 Muestral
 Cuasivarianza, 195
 Espacio, 11, 413
 Estadístico, 193
 Media, 193, 201-202, 205
 Proporción, 196, 206
 Punto, 11
 Varianza, 195, 202-204
 Muestreo, 258
 Con Reemplazamiento, 191
 Simple Aleatorio, 191

Sin Reemplazamiento, 191
 Factor de Corrección, 262
 Multinomial, Distribución, 116-117
 Mutuamente Excluyentes, Sucesos, 12-13

Nivel de Significación, 312-313
 No Correlacionadas, Variables, 90
 No Paramétricas, Hipótesis, 298
 Normal, Distribución, 147-158
 Cálculo de Probabilidades en, 152-158
 Propiedades, 150-152
 Tablas, 561
 Nula, Hipótesis, 300

Parámetro, Espacio del, 298
 Parámetros, 489
 Pearson, (Véase Ji-Cuadrado, Distribución)
 Pérdida, Función de, 219-220
 Población, 190
 Finita, 190, 261
 Factor de Corrección para, 262
 Infinita, 190, 261
 Poisson, Distribución de, 118-120
 Como Aproximación a la Binominal, 120
 Potencia del Contraste, 317-328
 Probabilidad
 A Priori, 8
 A Posteriori, 10
 Axiomas de, 12, 13
 Condicional, 14, 17
 De un Suceso, 11, 12
 Función de, 38
 Producto, 17
 Suma, 19
 Producto
 de funciones de Densidad, 81
 Probabilidad, 17
 Punto Binominal, Distribución, 108
 Valor Esperado y Varianza, 133
 Punto Muestral, 11

Regresión, 499
 Múltiple, 499
 Simple, 499
 Supuestos, 503
 Residuos, 506
 Resultados
 de Experimentos Aleatorios, 8
 Excluyentes, 8
 Favorables, 8
 Igualmente Posibles, 8

Reunión de Sucesos, 13
 Riesgo, Función de, 220

Sesgo, 223
 Simple, Hipótesis, 301
 Snedecor, (Véase F de Snedecor, Distribución)
 Standard, Desviación, (Véase Desviación Típica)
 Student, (Véase t de Student, Distribución)
 Sucesos
 Complemento, 13
 Exhaustivos, 31
 Independientes, 17, 18
 Intersección de, 12
 Mutuamente Excluyentes, 12, 13
 Probabilidad de, 11, 12, 15, 17
 Reunión de, 13
 Simple, 7
 Compuesto, 7
 Suficiencia, 230-233
 Suficiente, Estimador, 230-233
 Suma de Variables,
 Función Generatriz de Momentos de, 96
 Valor Esperado de, 84-85
 Varianza de, 95-96
 Suma, Probabilidad, 19

Tamaño de la Muestra, 264-265, 271, 342-346, 349
 t de Student, Distribución, 163-165
 Tablas, 564
 Teorema de Bayes, 20
 Teorema de Cramer-Rao, 225-226
 Teorema de Fisher-Neyman, 232
 Teorema de Gauss-Markov, 523
 Teorema del Límite Central, 181-185, 199
 Término de perturbación, 495
 Heteroelasticidad, 505
 Homoeelasticidad, 504
 Tipo I y Tipo II, Errores, 305-312

Uniforme, Distribución, 136-137
 Uniformemente más Potente, Contraste, 324

Valor Esperado, 45 y siguientes
 Condicional, 80, 83
 de la Suma de Variables, 84, 95
 del Producto de Variables, 85, 95
 de una Función de Variables, 83, 95
 de una Variable Aleatoria, 45
 Propiedades, 46

Valores Críticos, 304
 Variable Aleatoria, (Véase Aleatoria, Variable)
 Variables, 488
 Dependiente, 488
 Desfasadas, 488
 Endógenas, 488
 Independientes, 488
 Predeterminadas, 488

Varianza, 49 y siguientes
 de la Media Muestral, 194
 de la Suma de Variables, 95-96
 Muestral, 195
 Distribución de, 202-204
 Propiedades, 50
 Venn, Diagrama de, 19
 Verosimilitud, Función de, 236

SEPARATA

La presente separata tiene por objeto presentar la fe de erratas del libro *Cálculo de Probabilidades e Inferencia Estadística con tópicos de Econometría*. En esta edición aparecen algunos errores, cuya única responsabilidad es del Autor, por lo que pido disculpas a todos los usuarios del texto. Recomendando que antes de iniciar su lectura, se use esta separata para las correcciones correspondientes. Al mismo tiempo debo agradecer a mis alumnos del Segundo Año de Economía de la UCAB de los cursos 1995-1996 y 1996-1997 que han descubierto la mayoría de los errores.

El Autor

Página N°	Línea N°	Dice	Debe decir
44	-1	$\frac{12}{36} + \frac{5}{36}$	$\frac{12}{36} - \frac{5}{36}$
69	-7	un	su
73	-7	$dx dy$	$dy dx$
87	-6	$E(x,y)$	$E(xy)$
88	-6	$2/3$	$-2/3$
92	-2	Varianza de dos	Varianza de la diferencia de dos
109	11	una de las h formas	una de las formas
148	-3 y -2	$\sqrt{2\pi\alpha}$	$\sqrt{2\pi\alpha}$
149	5 y 7	$\sqrt{2\pi\alpha}$	$\sqrt{2\pi\alpha}$
159	11	$a-\mu+1/2$	$a-\mu-1/2$
159	-3	$185-\mu+1/2$	$185-\mu-1/2$
160	12	e^{-w^2}	e^{-w^2}
168	7	$F\alpha(m,n)$	$F\alpha(n,m)$
211	8	17	16
211	-6	5,73	5,59
211	-6	3,37	3,35
213	15	Calcular	Calcular
			$P(-5,69 \leq \bar{x} - \bar{y} \leq 2,31)$
349	-12	11,1	11,1
451	21 y -8	μ_1, μ	$\mu_1 - \mu$
451	-13	μ_1, μ	$\mu_1 - \mu$
452	5 y 7	μ_1, μ	$\mu_1 - \mu$
452	5 y 7	μ_1, μ	$\mu_1 - \mu$
452	9	μ_1, μ_2	$\mu_1 - \mu_2$
507	Gráfico	$y_i = a + bx_i$	$\hat{y}_i = \hat{a} + \hat{b}x_i$
574	Ej. 2.31	29.376,66	13.376,66
575	Ej. 3.18	-1/144; -0,1163	-3/144; -0,3488
577	Ej. 5.23	0,003	0,001
582	Ej. 10.11	$p < 18$	$\mu < 18$
582	Ej. 10.13	$\alpha = 0,01$	$\alpha = 0,001$
582	Ej. 10.13	0,9887	0,998

ESTE EJEMPLAR SE TERMINO DE IMPRIMIR
EN LOS TALLERES DE EDITORIAL TEXTO
AV. EL CORTIJO, QTA. MARISA, N° 4
LOS ROSALES - CARACAS - VENEZUELA