

Distribución Normal, Teorema Central del Límite y Ley de los Grandes Números

Se realiza una encuesta a una muestra de habitantes de cierta ciudad del país A, para saber su opinión sobre la posible construcción de un centro comercial en dicha zona. El 30 % de los encuestados esta a favor de la construcción. Si el tamaño de la muestra es 400, diga:

- ¿Cuál es la distribución, la media y la desviación estándar de la proporción de la muestra?
- $\mathbb{P}$ (“La proporción de habitantes a favor del proyecto sea mayor al 40 %”).
- Usando la Ley de los Grandes Números, indique ¿cuántos habitantes deben ser encuestados para asegurar con un 95 % de seguridad que la frecuencia relativa de que alguno de ellos este de acuerdo con el proyecto diste 0,05 de la probabilidad teórica de dicho evento?

Respuesta:

Primero modelamos el comportamiento de un solo habitante encuestado. Como es una muestra aleatoria, asumimos independencia entre encuestados. Sea Y_i la variable aleatoria que representa la opinión del habitante i -ésimo (para $i = 1, 2, \dots, 400$).

$$Y_i = \begin{cases} 1 & \text{si está a favor} \\ 0 & \text{si no está a favor} \end{cases}$$

Esta variable sigue una distribución de Bernoulli con parámetro $p = 0,30$.

$$Y_i \sim \text{Bernoulli}(p = 0,30)$$

Sus parámetros teóricos son:

- **Esperanza:** $E[Y_i] = p = 0,30$
- **Varianza:** $VAR[Y_i] = p(1 - p) = 0,30 \cdot 0,70 = 0,21$

Si sumamos todas las respuestas individuales, obtenemos el número total de personas a favor. Llamemos a esta variable X .

$$X = \sum_{i=1}^{400} Y_i = Y_1 + Y_2 + \dots + Y_{400}$$

Por definición estadística, la suma de n variables Bernoulli independientes es una binomial:

$$X \sim \text{Binomial}(n = 400, p = 0,30)$$

a) **Distribución, media y desviación de la proporción:**

El enunciado nos pide la distribución de la proporción. La proporción muestral no es más que el promedio de las variables de Bernoulli individuales.

$$\hat{q} = \frac{X}{400} = \frac{\sum_{i=1}^{400} Y_i}{400}$$

Ahora por **TCL** la distribución del promedio de una muestra grande de variables independientes converge a una normal.

$$\hat{q} \sim N(\mu_{\hat{q}}; \sigma_{\hat{q}}^2)$$

- **Media:** Sabemos que $E[X] = n \cdot p$.

$$\mu_{\hat{q}} = E[\hat{q}] = E\left[\frac{X}{n}\right] = \frac{1}{n}E[X] = \frac{1}{n}(n \cdot p) = p$$

$$\mu_{\hat{q}} = 0,30$$

- **Varianza:** Sabemos que $VAR[X] = n \cdot p \cdot (1 - p)$.

$$\sigma_{\hat{q}}^2 = VAR[\hat{q}] = VAR\left[\frac{X}{n}\right] = \frac{1}{n^2}VAR[X] = \frac{1}{n^2}(n \cdot p \cdot (1 - p)) = \frac{p \cdot (1 - p)}{n}$$

$$\sigma_{\hat{q}}^2 = \frac{0,30 \cdot 0,70}{400} = 0,000525$$

- **Desviación estándar:**

$$\sigma_{\hat{q}} = \sqrt{\sigma_{\hat{q}}^2} = \sqrt{0,000525} \approx 0,0229$$

b) **Probabilidad de que la proporción sea mayor al 40 %**

Como demostramos en el inciso a), la variable $\hat{q}$ se comporta como una Normal, entonces estandarizando y buscando el correspondiente cuantil en la tabla de la normal obtenemos que:

$$P(\hat{q} > 0,40) = P\left(Z > \frac{0,40 - 0,30}{0,0229}\right) = P(Z > 4,37) \approx 0$$

Esto significa que no es posible que más del 40 % de la población esté de acuerdo, porque en realidad **solo el 30 % está de acuerdo**.

c) **Ley de los Grandes Números:**

Vamos a enfocarnos en dos cosas: qué tan cerca queremos estar de la realidad y qué tan seguros queremos estar de eso

- Cuando decimos que la frecuencia relativa no debe alejarse más de 0.05 (ϵ), eso es la distancia. Es como decir: “No quiero que mi resultado esté a más de 0.05 de la verdad”.
- Cuando pedimos estar seguros al 95 %, eso es la probabilidad mínima. Quiere decir: “Quiero tener al menos un 95 % de confianza de que mi resultado cumple con lo que deseo”.

Ahora como queremos acotar superiormente el error, por la **Desigualdad de Chebyshev** sabemos que la **Ley de Grandes Numeros** cumple

$$P(|\hat{q} - p| < \epsilon) \geq 1 - \frac{\sigma_{\hat{q}}^2}{\epsilon^2}$$

por lo que podemos ver la traducción a fórmula como:

$$P(|\text{Error}| < \epsilon) \geq \text{Seguridad} \Rightarrow 1 - \frac{\text{Varianza}}{\epsilon^2} \geq 0,95$$

Ahora, sustituyendo los datos y despejando n :

$$1 - \frac{\frac{0,21}{n}}{(0,05)^2} \geq 0,95 \Rightarrow \frac{0,21}{n \cdot (0,05)^2} \leq 0,05 \Rightarrow n \geq \frac{0,21}{0,000125} = 1680$$

Por lo tanto, debemos encuestar a 1680 personas o más ($n \geq 1680$) para cumplir con esa cota inferior de seguridad.

¡Importante! En este problema, el riesgo (0,05) y la distancia (0,05) son el mismo número por pura casualidad. ¡No los confundas!