

Intervalos de Confianza

Motivación:



Grupo muy grande (usualmente infinito) de datos a estudiar, visto como v.a. Poblacional X con Distribución de Probabilidades usualmente desconocida

Técnicas de Muestreo

Muestra Aleatoria

Conjunto finito de v.a. Independientes $(X_1, X_2, \dots, X_n)$ cuyas distribuciones de probabilidades son idénticas a la de la v.a. poblacional X

Estadística Descriptiva

Información sobre la Muestra Aleatoria

Medidas Descriptivas (Cuantitativas, Objetivas)
Gráficos Descriptivos (Cualitativos, Subjetivos)

Estadística Inferencial: Permite inferir información sobre la v.a. poblacional X

NOTA:

Una buena Muestra Aleatoria debe ser representativa de la Población, lo cual no es fácil lograr.

Def: Un **Estadístico** es cualquier v.a. T calculada usando una muestra aleatoria.

Ejemplos: $T = \text{Máx}(X_1, X_2, \dots, X_n)$, $T = \text{Mín}(X_1, X_2, \dots, X_n)$, etc.

Def: Distribución de Muestreo es la distribución de probabilidades que sigue un estadístico T

Def: Sea la constante θ el valor (usualmente desconocido) de una medida descriptiva de una v.a. poblacional X , un **Estimador Puntual Insesgado** de θ es un estadístico $\hat{\theta}$ tal que su Media (Esperanza, Valor Esperado) coincide con θ (o sea: $E(\hat{\theta}) = \theta$) para cualquier posible valor de θ
Ejemplos:

El Promedio Muestral $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ es un estimador puntual insesgado de la media poblacional

$\mu = E(X)$ pues $E(\bar{X}) = \mu$ con $\text{Var}(\bar{X}) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{n\sigma^2}{n^2} = \sigma^2/n$

La Varianza Muestral $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ es un estimador puntual insesgado de la varianza poblacional $\sigma^2 = \text{Var}(X)$ pues $E(S^2) = \sigma^2$ con $\text{Var}(S^2) = 2(\text{Var}(X))^2/(n-1) = 2\sigma^4/(n-1)$

TAREA: Investigar relación de Varianza Muestral $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ con valor $\sum_{i=1}^n (X_i)^2$

Distribución de Muestreo del Promedio Muestral $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$

Si la v.a. poblacional X sigue distribución de probabilidades *Normal* con Media $E(X) = \mu$, Varianza $\text{Var}(X) = \sigma^2$, entonces el Promedio Muestral $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ sigue distribución de probabilidades *Normal* con Media $E(\bar{X}) = \mu$, Varianza $\text{Var}(\bar{X}) = \sigma^2/n$ O sea: $X \sim N(\mu; \sigma^2) \rightarrow \bar{X} \sim N(\mu; \sigma^2/n)$

Distribución de Muestreo de la Varianza Muestral $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$

Teorema: Si la v.a. poblacional X sigue distribución de probabilidades *Normal* con Media $E(X) = \mu$, Varianza $\text{Var}(X) = \sigma^2$, entonces la v.a. $Y = \sum_{i=1}^n (X_i - \mu)^2 / \sigma^2$ (*) sigue distribución de probabilidades *Chi-cuadrado* con n grados de libertad (χ_n^2)

TAREA: Investigar Distribución *Chi-cuadrado*

(*) Nota: $Y = \sum_{i=1}^n Z_i^2$ con $Z_i \sim N(0;1)$ para $i=1,2,\dots,n$

Usando este teorema: Si la v.a. poblacional X sigue distribución de probabilidades *Normal* con Media $E(X) = \mu$, Varianza $\text{Var}(X) = \sigma^2$, entonces la v.a. resultante $(n-1)S^2/\sigma^2$ sigue distribución de probabilidades *Chi-cuadrado* con $n-1$ grados de libertad (χ_{n-1}^2)

O sea: $X \sim N(\mu; \sigma^2) \rightarrow (n-1)S^2/\sigma^2 \sim \chi_{n-1}^2$

Teorema: Si Z, Y son v.a. Independientes, con Z siguiendo distribución de probabilidades *Normal Standard*, Y siguiendo distribución *Chi-cuadrado* con k grados de libertad, entonces la v.a. resultante $Z/\sqrt{Y/k}$ sigue distribución de probabilidades *t-student* con k grados de libertad (t_k) (ver anexo)

O sea: Z, Y Independientes $\wedge Z \sim N(0;1) \wedge Y \sim \chi_k^2 \rightarrow Z/\sqrt{Y/k} \sim t_k$

Usando teoremas anteriores: Si la v.a. poblacional X sigue distribución de probabilidades *Normal* con Media $E(X) = \mu$, Varianza $\text{Var}(X) = \sigma^2$, entonces la v.a. resultante $\frac{\bar{X} - \mu}{S/\sqrt{n}}$ sigue distribución *t-student* con $n-1$ grados de libertad.

O sea: $X \sim N(\mu; \sigma^2) \rightarrow \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}$ con $S = \sqrt{S^2}$, con Varianza Muestral $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$

Def: **Cuantil α** de una v.a. X es el valor $x_{(\alpha)}$ donde la correspondiente *Fda* acumula probabilidad α
O sea: *Fda* $F(x_{(\alpha)}) = P(X \leq x_{(\alpha)}) = \alpha$

Estimación por Intervalo:

Def: Sea $\hat{\theta}$ un estimador puntual insesgado del valor constante desconocido θ (medida descriptiva de una v.a. poblacional X) [**LimInf** ; **LimSup**] es un **Intervalo de Confianza del 100(1- α)%** para θ si y solo si se cumple que $P(\text{LimInf} \leq \theta \leq \text{LimSup}) = 1 - \alpha$ donde **LimInf** , **LimSup** son *Estadísticos* (v.a.) calculados usando muestra aleatoria $(X_1, X_2, \dots, X_n)$

100(1- α)% se denomina **Nivel de Confianza** del intervalo [**LimInf** ; **LimSup**]

NOTA: Caber destacar aquí que una vez calculados valores numéricos de **LimInf** , **LimSup** , por ejemplo: si **LimInf**= a , **LimSup**= b , entonces ya no se puede hablar de probabilidad, pues la afirmación $a \leq \theta \leq b$ es *Verdad* ó *Falso*, sin incertidumbre, siendo a, θ, b valores fijos, así que **no tiene sentido afirmar $P(a \leq \theta \leq b) = 1 - \alpha$** , lo cual es similar a escribir **$P(7 < 8) = 1$ o $P(7 > 8) = 0$**

Interpretación práctica del Nivel de Confianza: Si usando 100 diferentes muestras aleatorias (de igual tamaño, de la misma población) se obtienen 100 intervalos de confianza del 100(1- α)% para θ entonces 100(1- α) es el valor esperado (esperanza) de la cantidad de veces que ocurre el evento aleatorio "**LimInf** $\leq \theta \leq$ **LimSup**", aunque no se puede saber con certeza en cuales de dichos intervalos se cumple que **LimInf** $\leq \theta \leq$ **LimSup** (o sea: el intervalo contiene a θ) pues valor θ es desconocido.

Como desarrollar Intervalo de Confianza del 100(1- α)% para θ : Partiendo de un estimador puntual insesgado $\hat{\theta}$ con distribución de muestreo conocida, se definen funciones **G_I** , **G_S** que solo dependen de θ (cuyo valor es desconocido) y de otros valores conocidos, de modo tal que se cumple **$P(G_I(\theta) \leq \hat{\theta} \leq G_S(\theta)) = 1 - \alpha$** operando luego convenientemente hasta obtener **$P(\text{LimInf} \leq \theta \leq \text{LimSup}) = 1 - \alpha$**

Ej: Sea una población *Normal* $X \sim N(\mu; \sigma^2)$ con Varianza **Var(X)**= σ^2 conocida (supuesto simplista), obtener Intervalo de Confianza del 100(1- α)% para la Media **E(X)**= μ

RESPUESTA: Partiendo del promedio muestral $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ (estimador puntual insesgado de μ) con distribución de muestreo $\bar{X} \sim N(\mu; \sigma^2/n)$ se define **$P(G_I(\mu) \leq \bar{X} \leq G_S(\mu)) = 1 - \alpha$** $\rightarrow$
Por Teorema de Estandarización de la Normal: con $(\bar{X} - \mu) / (\frac{\sigma}{\sqrt{n}}) = Z \sim N(0;1)$

$\rightarrow P((G_I(\mu) - \mu) / (\frac{\sigma}{\sqrt{n}}) \leq (\bar{X} - \mu) / (\frac{\sigma}{\sqrt{n}}) \leq (G_S(\mu) - \mu) / (\frac{\sigma}{\sqrt{n}})) = 1 - \alpha \rightarrow$

$\rightarrow P((G_I(\mu) - \mu) / (\frac{\sigma}{\sqrt{n}}) \leq Z \leq (G_S(\mu) - \mu) / (\frac{\sigma}{\sqrt{n}})) = 1 - \alpha \rightarrow$

Aprovechando simetría de la *fdp* $N(0;1)$ el intervalo de confianza también es simétrico, de modo que, por complemento: **$P(\text{Intervalo de Confianza no contiene } \mu) = 1 - (1 - \alpha) = \alpha \rightarrow$**

$\rightarrow P(Z < (G_I(\mu) - \mu) / (\frac{\sigma}{\sqrt{n}})) = P(Z > (G_S(\mu) - \mu) / (\frac{\sigma}{\sqrt{n}})) = \alpha/2 \rightarrow$

Siendo $z_{(\alpha/2)}$, $z_{(1-\alpha/2)}$ los respectivos *cuantiles* $\alpha/2$, $1-\alpha/2$ de la v.a. $Z \sim N(0;1)$

$\rightarrow (G_I(\mu) - \mu) / (\frac{\sigma}{\sqrt{n}}) = z_{(\alpha/2)} \wedge (G_S(\mu) - \mu) / (\frac{\sigma}{\sqrt{n}}) = z_{(1-\alpha/2)} \rightarrow$

Despejando:

$\rightarrow G_I(\mu) = \mu + (\frac{\sigma}{\sqrt{n}})z_{(\alpha/2)} \wedge G_S(\mu) = \mu + (\frac{\sigma}{\sqrt{n}})z_{(1-\alpha/2)} \rightarrow$

Por simetría de la *fdp* $N(0;1)$: $z_{(\alpha/2)} = -z_{(1-\alpha/2)}$

$\rightarrow P(\mu - (\frac{\sigma}{\sqrt{n}})z_{(1-\alpha/2)} \leq \bar{X} \leq \mu + (\frac{\sigma}{\sqrt{n}})z_{(1-\alpha/2)}) = 1 - \alpha \rightarrow$

Despejando:

$\rightarrow P(\bar{X} - (\frac{\sigma}{\sqrt{n}})z_{(1-\alpha/2)} \leq \mu \leq \bar{X} + (\frac{\sigma}{\sqrt{n}})z_{(1-\alpha/2)}) = 1 - \alpha$

Resultando el intervalo: [**LimInf** ; **LimSup**] con **LimInf** = $\bar{X} - \Delta$, **LimSup** = $\bar{X} + \Delta$, con $\Delta = (\frac{\sigma}{\sqrt{n}})z_{(1-\alpha/2)}$

Siendo *cuantil* $z_{(1-\alpha/2)}$ = valor de v.a. $Z \sim N(0;1)$ donde *Fda* ϕ vale $1 - \alpha/2$

O sea: **$P(Z \leq z_{(1-\alpha/2)}) = \phi(z_{(1-\alpha/2)}) = 1 - \alpha/2$** (disponible en tabla)

NOTAS:

Este Intervalo de Confianza es más ancho (menos preciso) al aumentar el Nivel de Confianza.
Este Intervalo de Confianza es menos ancho (más preciso) al aumentar el tamaño de la muestra (n)

Ej: Suponiendo una población *Normal* con desviación standard $\sigma=5$ de la cual se toma una muestra aleatoria con $n=16$ observaciones cuyo promedio muestral vale $\bar{X}=503,75$ calcular intervalos de confianza para la media poblacional μ con niveles de confianza 90% , 95% , 99%

RESPUESTA: Usando **LimInf** = $\bar{X} - \Delta$, **LimSup** = $\bar{X} + \Delta$, con $\Delta = (\frac{\sigma}{\sqrt{n}})z_{(1-\alpha/2)} = (5/4)z_{(1-\alpha/2)}$

Nivel de Confianza 100(1- α)%	Cuantil $z_{(1-\alpha/2)}$	LimInf	LimSup
90%	1,645	501,69	505,81
95%	1,96	501,30	506,20
99%	2,575	500,53	506,97

Nótese que ancho del intervalo aumenta al aumentar nivel de confianza.

Otros Casos Particulares:

Sea una población Normal $X \sim N(\mu; \sigma^2)$ con Media $E(X) = \mu$, Varianza $Var(X) = \sigma^2$ desconocida
El Intervalo de Confianza del $100(1-\alpha)\%$ para la Media $E(X) = \mu$ es [**LimInf** ; **LimSup**]
Con **LimInf** = $\bar{X} - \Delta$, **LimSup** = $\bar{X} + \Delta$, con $\Delta = (\frac{S}{\sqrt{n}})t_{(1-\alpha/2; n-1)}$ **TAREA:** Demostrar
Con Desviación Standard Muestral $S = \sqrt{S^2}$, con Varianza Muestral $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$
Siendo *cuantil* $t_{(1-\alpha/2; n)}$ = valor de v.a. con distribución *t-student* con $n-1$ grados de libertad
donde su *Fda* vale $1-\alpha/2$ (disponible en tabla)

NOTA: Similar al caso anterior, este Intervalo de Confianza es más ancho (menos preciso) al aumentar el Nivel de Confianza, pero menos ancho (más preciso) al aumentar tamaño de muestra. Lógicamente, el ancho de este Intervalo de Confianza también aumenta al aumentar la desviación standard muestral $S = \sqrt{S^2}$.

Ej: Suponiendo una población Normal con Varianza desconocida, de la cual se toma una muestra aleatoria con $n=16$ observaciones, cuyos respectivos promedio y desviación standard muestrales valen $\bar{X}=503,75$, $S=6,2$ calcular intervalos de confianza para la media poblacional μ con niveles de confianza 90%, 95%, 99%

RESPUESTA: Usando **LimInf** = $\bar{X} - \Delta$, **LimSup** = $\bar{X} + \Delta$, con $\Delta = (\frac{S}{\sqrt{n}})t_{(1-\alpha/2; n-1)} = (6,2/4)t_{(1-\alpha/2; 15)}$

Nivel de Confianza $100(1-\alpha)\%$	Cuantil $t_{(1-\alpha/2; 15)}$	LimInf	LimSup
90%	1,753	501,03	506,47
95%	2,131	500,45	507,05
99%	2,947	499,18	508,32

Sea una población $X \sim \text{Bernoulli}(q)$ con $0 < q < 1$, de la cual se tiene una muestra aleatoria $(X_1, \dots, X_n)$ usando el estimador puntual insesgado de q : $\hat{q} = \frac{1}{n} \sum_{i=1}^n X_i$ (promedio muestral) se tiene que $E(\hat{q}) = q$
 $Var(\hat{q}) = (1-q)q/n$ Si n es “grande” entonces (por *TCL*) $\hat{q}$ sigue distribución aproximadamente Normal
Se desarrolla Intervalo de Confianza (aproximado) del $100(1-\alpha)\%$ para q usando mismo procedimiento general empleado anteriormente: Se define $P(G_L(q) \leq \hat{q} \leq G_S(q)) = 1-\alpha \rightarrow$
Por Teorema de Estandarización de la Normal: con $(\hat{q} - q)/\sqrt{(1-q)q/n} = Z \sim N(0;1)$ (aproximado)
 $\rightarrow P((G_L(q)-q)/\sqrt{(1-q)q/n} \leq (\hat{q} - q)/\sqrt{(1-q)q/n} \leq (G_S(q)-q)/\sqrt{(1-q)q/n}) = 1-\alpha \rightarrow$
 $\rightarrow P((G_L(q)-q)/\sqrt{(1-q)q/n} \leq Z \leq (G_S(q)-q)/\sqrt{(1-q)q/n}) = 1-\alpha \rightarrow$
Aprovechando simetría de la *fdp* $N(0;1)$ el intervalo de confianza también es simétrico, de modo que, por complemento: $P(\text{Intervalo de Confianza no contiene } q) = 1-(1-\alpha) = \alpha \rightarrow$
 $\rightarrow P(Z < (G_L(q)-q)/\sqrt{(1-q)q/n}) = P(Z > (G_S(q)-q)/\sqrt{(1-q)q/n}) = \alpha/2 \rightarrow$
Siendo $z_{(\alpha/2)}$, $z_{(1-\alpha/2)}$ los respectivos cuantiles $\alpha/2$, $1-\alpha/2$ de la v.a. $Z \sim N(0;1)$
 $\rightarrow (G_L(q)-q)/\sqrt{(1-q)q/n} = z_{(\alpha/2)} \wedge (G_S(q)-q)/\sqrt{(1-q)q/n} = z_{(1-\alpha/2)} \rightarrow$
Despejando:
 $\rightarrow G_L(q) = q + z_{(\alpha/2)}\sqrt{(1-q)q/n} \wedge G_S(q) = q + z_{(1-\alpha/2)}\sqrt{(1-q)q/n} \rightarrow$
Por simetría de la *fdp* $N(0;1)$: $z_{(\alpha/2)} = -z_{(1-\alpha/2)}$
 $\rightarrow P(q - z_{(1-\alpha/2)}\sqrt{(1-q)q/n} \leq \hat{q} \leq q + z_{(1-\alpha/2)}\sqrt{(1-q)q/n}) = 1-\alpha \rightarrow$
Despejando:
 $\rightarrow P(\hat{q} - z_{(1-\alpha/2)}\sqrt{(1-q)q/n} \leq q \leq \hat{q} + z_{(1-\alpha/2)}\sqrt{(1-q)q/n}) = 1-\alpha \rightarrow$
Estas expresiones aún dependen del valor desconocido q , el cual a continuación se substituye por su estimador puntual insesgado $\hat{q} = \frac{1}{n} \sum_{i=1}^n X_i$ (promedio muestral)
 $\rightarrow P(\hat{q} - z_{(1-\alpha/2)}\sqrt{(1-\hat{q})\hat{q}/n} \leq q \leq \hat{q} + z_{(1-\alpha/2)}\sqrt{(1-\hat{q})\hat{q}/n}) = 1-\alpha$
Resultando el intervalo aproximado: [**LimInf** ; **LimSup**] con **LimInf** = $\hat{q} - \Delta$, **LimSup** = $\hat{q} + \Delta$
con $\Delta = z_{(1-\alpha/2)}\sqrt{(1-\hat{q})\hat{q}/n}$
Siendo *cuantil* $z_{(1-\alpha/2)}$ = valor de v.a. $Z \sim N(0;1)$ donde *Fda* ϕ vale $1-\alpha/2$
O sea: $P(Z \leq z_{(1-\alpha/2)}) = \phi(z_{(1-\alpha/2)}) = 1-\alpha/2$ (disponible en tabla)

Ej: Un productor de arroz afirma que su proporción de granos partidos es 5% En una muestra aleatoria de 200 granos de dicho arroz se observan 19 granos partidos. Calcular Intervalo de Confianza del 98% para la proporción de granos partidos ¿Resulta sospechosa la afirmación del productor? **RESPUESTA:** [**LimInf** ; **LimSup**] = $[\hat{q} - \Delta ; \hat{q} + \Delta]$ con $\Delta = z_{(1-\alpha/2)}\sqrt{(1-\hat{q})\hat{q}/n}$
Con $\hat{q} = 19/200 = 0,095$; *cuantil* $z_{(1-\alpha/2)} = z_{(0,99)} \cong 2,33$; $\sqrt{(1-\hat{q})\hat{q}/n} \cong 0.020733$
Resultado: [**LimInf** ; **LimSup**] = [0,0467 ; 0,1433] Este intervalo contiene a 0,05 pero con nivel de confianza del 95% se tiene intervalo más preciso (menos ancho) que no contiene a 0,05 (**TAREA:** Verificar) lo que es buena razón para sospechar que la afirmación del productor ($q=0,05$) es falsa.